

Universidade Federal de Uberlândia

Aula 1: Introdução à Aprendizagem por Reforço

Panorama da área • Decisão sequencial sob incerteza • Processos de Markov

Prof. Marcelo Keese Albertini
Universidade Federal de Uberlândia
adaptado de Emma Brunskill, CS234 (Stanford)
2026



1. **Panorama de RL** — o que é, por que importa, o que a distingue.
2. **Decisão sequencial sob incerteza** — agente, história, estado, Markov.
3. **Processos de Markov e MRPs** — retorno, função valor, Bellman.

Intuição

Objetivo do curso: *formular* → *escolher* → *implementar* → *avaliar*.

SEÇÃO 1

Panorama da aprendizagem por reforço

01

O que é aprendizagem por reforço?

Definição — Aprendizagem por reforço (RL)

Aprender, a partir de **experiência**, a tomar **boas decisões** sob **incerteza**.

- ▶ Núcleo da inteligência: agir e observar consequências.
- ▶ Teoria desde os anos 1950 — Bellman (programação dinâmica).
- ▶ Última década: de jogos a ciência experimental e LLMs.

RL hoje: o motor por trás dos sistemas de raciocínio

- ▶ **LLMs que raciocinam:** R1-Zero — RL em larga escala, sem supervisão; o1 — RL para cadeias de raciocínio.
- ▶ **Matemática de competição:** DeepMind, ouro na IMO (35/42).
- ▶ **Robótica:** manipulação delicada com RL + demonstrações.

Intuição

RLHF, RLVR, *test-time compute*... são RL. Este curso dá a base para essas siglas.

Uma década de resultados marcantes

- ▶ **Go** — AlphaGo Zero (Silver et al., *Nature* 2017): autojogo + RL.
- ▶ **Fusão nuclear** — controle de plasma em tokamak (Degraeve et al., *Nature* 2022).
- ▶ **COVID-19** — triagem adaptativa *Eurydice*, Grécia (Bastani et al., *Nature* 2021).
- ▶ **ChatGPT** — RLHF.

Jogos, física, saúde, linguagem — a teoria é a mesma.

Os quatro ingredientes da aprendizagem por reforço

Quatro desafios simultâneos:

1. **Otimização** — as *melhores* decisões, utilidade explícita.

Os quatro ingredientes da aprendizagem por reforço

Quatro desafios simultâneos:

1. **Otimização** — as *melhores* decisões, utilidade explícita.
2. **Consequências adiadas** — o agora afeta o futuro distante.

Os quatro ingredientes da aprendizagem por reforço

Quatro desafios simultâneos:

1. **Otimização** — as *melhores* decisões, utilidade explícita.
2. **Consequências adiadas** — o agora afeta o futuro distante.
3. **Exploração** — só se aprende o que se experimenta.

Os quatro ingredientes da aprendizagem por reforço

Quatro desafios simultâneos:

1. **Otimização** — as *melhores* decisões, utilidade explícita.
2. **Consequências adiadas** — o agora afeta o futuro distante.
3. **Exploração** — só se aprende o que se experimenta.
4. **Generalização** — agir bem no nunca visto.

Intuição

Supervisionado: só 4. Otimização clássica: só 1. Bandits: 1, 3, 4. RL: o problema completo.

Ingrediente 1: otimização

- ▶ Decidir de forma **ótima** — noção explícita de utilidade.
- ▶ Ex.: menor rota entre cidades — sequencial *sem* incerteza, modelo conhecido.

Intuição

Reward is enough (Silver, Singh, Precup, Sutton, 2021): maximizar recompensa bastaria para a maioria das capacidades inteligentes.

Ingrediente 2: consequências adiadas

Decisões de agora → resultados muito depois:

- ▶ poupar para a aposentadoria;
- ▶ chave no início da fase (*Montezuma's Revenge*).

Dois desafios:

- ▶ **Planejamento:** agora vs. ramificações de longo prazo.
- ▶ **Aprendizado:** **atribuição de crédito temporal** — qual decisão causou o quê?

Atenção

A recompensa chega sem etiqueta de causa.

Ingrediente 3: exploração

- ▶ Aprender agindo: tentar (e cair).
- ▶ As decisões determinam *quais dados* o agente obtém.
- ▶ **Contrafactuais**: a alternativa nunca é observada.

Intuição

O “rótulo” da ação não escolhida não existe → dilema **exploração vs. aproveitamento**.

Ingrediente 4: generalização

- ▶ **Política:** experiência passada $\rightarrow$ ações.
- ▶ Pré-programar? Atari: 84×84 pixels — espaço astronômico.
- ▶ A política precisa **generalizar**.

Aqui RL encontra deep learning.

Onde RL é particularmente poderosa

Duas categorias:

1. **Não há exemplos do comportamento desejado** — superar humanos ou sem dados.
Ex.: AlphaGo Zero, do zero.
2. **Busca gigante com resultado adiado** — enumeração impossível.
Ex.: AlphaTensor (2022), multiplicação de matrizes como jogo.

RL no mapa do aprendizado de máquina

	Supervisionado	Não supervisionado	Por reforço
Sinal de aprendizado	rótulo correto	nenhum rótulo	recompensa escalar, possivelmente atrasada
Dados	exemplo fixos, i.i.d.	fixos, i.i.d.	gerados pelas <i>próprias</i> ações do agente
Objetivo	prever bem	descobrir estrutura	<i>agir</i> bem ao longo do tempo
Erro informa...	a resposta certa	—	apenas <i>quão bom</i> foi o que se fez

Atenção

RL: dados não i.i.d. — mudar a política muda a distribuição dos dados.

Ementa oficial: o curso é de Inteligência Artificial

Ementa (ficha GBC063, FACOM/UFU)	Onde aparece no curso
Introdução à IA: definições, histórico, subdivisões (simbólico, conexionista, evolutivo, swarm); linguagens	Panorama nesta aula (Python é a linguagem do curso)
Solução de problemas: busca, busca informada, jogos e planejamento	MCTS e AlphaZero (aulas 13–14); planejamento em MDP (aula 2)
Representação do conhecimento; raciocínio lógico; sistemas especialistas	Panorama nesta aula (base de conhecimento + motor de inferência, encadeamentos progressivo/regressivo)
Conhecimento e raciocínio com incerteza	MDPs e bandits (todo o curso)
Aprendizagem: supervisionada, não supervisionada, por reforço	Mapa do AM (há pouco); RL é o núcleo (aulas 1–14)
Tópicos recentes em IA	DQN (aula 4), PPO (aulas 5–7), RLHF/DPO (aulas 7–8)

Atenção

Disciplina de IA: a ficha pede também fundamentos simbólicos — esta aula dá o panorama; o curso mergulha no RL.

Trajetoória do curso

- ▶ Processos de decisão de Markov e planejamento
- ▶ Avaliação de política sem modelo
- ▶ Controle sem modelo
- ▶ Busca de política (gradientes)
- ▶ RL *offline*, RLHF e DPO
- ▶ Exploração
- ▶ Tópicos avançados

Ao final, você deve saber

- ▶ definir os elementos-chave de RL;
- ▶ decidir *se e como* usar RL em um problema real;
- ▶ implementar os algoritmos clássicos;
- ▶ avaliar teórica e empiricamente a qualidade de um algoritmo.

SEÇÃO 2

Tomada de decisão sequencial sob incerteza

02

Exercício de aquecimento: um tutor de IA como processo de decisão

Teste sua compreensão

Tutor de IA: estudante sem adição nem subtração; exercícios de $+$ ou de $-$; $+1$ acerto, -1 erro.

Estados? Ações? Recompensa? Dinâmica? Política ótima? Bom incentivo para *aprender*?
Recompensa alternativa?

Atenção

Moral: a recompensa *define* o problema — mal projetada, vira só adições fáceis.

Decisão sequencial: o objetivo

Definição — Tomada de decisão sequencial

Selecionar ações para **maximizar a recompensa total esperada futura**.


Mesmo molde para:

- ▶ **Publicidade:** qual anúncio? cliques vs. retenção.
- ▶ **Robô e lava-louças:** qual junta mover? rápido vs. não quebrar.
- ▶ **Pressão arterial:** qual dose? agora vs. efeitos colaterais.

A interação agente-mundo (tempo discreto)

A cada passo t :

1. agente executa a_t ;
2. mundo emite o_t e r_t ;
3. agente decide a_{t+1} .



Intuição

Laço fechado: os dados de amanhã dependem da decisão de hoje.

História e estado

Definição — História h_t

Sequência de tudo que o agente fez e percebeu: $h_t = (a_1, o_1, r_1, \dots, a_t, o_t, r_t)$.

Definição — Estado s_t

Informação assumida como suficiente para determinar o que vem a seguir. Função da história: $s_t = f(h_t)$.

- ▶ História cresce sem limite; estado = **resumo** escolhido.
- ▶ Escolher f é decisão de *modelagem* — das mais importantes.

A hipótese de Markov

Definição — Estado de Markov (estado-informação)

s_t é de Markov sse

$$\mathbb{P}(s_{t+1} \mid s_t, a_t) = \mathbb{P}(s_{t+1} \mid h_t, a_t),$$

isto é, s_t é uma **estatística suficiente** da história.

Intuição

“O futuro é independente do passado, dado o presente.”

- ▶ Trivial: $s_t = h_t$ — mas o estado explode.
- ▶ Arte: o *menor* estado (quase) Markov.

Por que a hipótese de Markov é tão popular?

- ▶ Simples; satisfeita com um pouco de história no estado.
- ▶ Na prática: $s_t = o_t$.

O estado impacta:

- ▶ **custo computacional;**
- ▶ **dados necessários;**
- ▶ **desempenho final** — estado pobre viola Markov.

Teste sua compreensão

Xadrez: a configuração atual do tabuleiro (mais o jogador da vez) é Markov? E um único quadro de Atari com objetos em movimento?

Tipos de processos de decisão sequencial

Três eixos:

- ▶ **Estado observável?** Parcial → *POMDP*. Ex.: pôquer, robô com câmera.
- ▶ **Dinâmica determinística ou estocástica?**
- ▶ **Ações afetam o futuro?** Só recompensa imediata → *bandits*.

Curso começa no caso mais limpo: estado totalmente observável, dinâmica estocástica, ações afetam o futuro — o **MDP**.

Exemplo condutor: o *Mars Rover* como MDP

Um robô explorador numa fileira de sete posições



- ▶ **Estados:** posição, $\mathcal{S} = \{s_1, \dots, s_7\}$.
- ▶ **Ações:** $\mathcal{A} = \{\text{TentarEsquerda}, \text{TentarDireita}\}$ — o terreno pode derrapar.
- ▶ **Recompensas:** $+1$ em s_1 , $+10$ em s_7 , 0 no resto.

Pequeno o bastante para calcular à mão — nos acompanhará por várias aulas.

O modelo do MDP: como o agente representa o mundo

Modelo = representação, *do agente*, de como o mundo muda.

Definição — Modelo de transição (dinâmica)

Prevê o próximo estado: $p(s_{t+1} = s' \mid s_t = s, a_t = a)$.

Definição — Modelo de recompensa

Prevê a recompensa imediata: $r(s, a) = \mathbb{E}[r_t \mid s_t = s, a_t = a]$.

Atenção

O modelo pode estar *errado* — e em geral está. Boa parte de RL: agir bem apesar disso.

Mars Rover: um modelo estocástico

Parte do modelo de transição para TentarDireita:

$$0,5 = P(s_1 \mid s_1, \text{TD}) = P(s_2 \mid s_1, \text{TD}), \quad 0,5 = P(s_2 \mid s_2, \text{TD}) = P(s_3 \mid s_2, \text{TD}), \quad \dots$$

Modelo de recompensa: prevê $\hat{r} = 0$ em *todos* os estados.

- ▶ Metade das vezes derrapa e fica; metade avança.
- ▶ Recompensa prevista está **errada**: o mundo paga +1/+10.

Intuição

Modelo $\neq$ realidade: crença a ser corrigida pela experiência.

Política: o comportamento do agente

Definição — Política π

Determina como o agente escolhe ações.

- ▶ **Determinística:** $\pi : \mathcal{S} \rightarrow \mathcal{A}$, escrita $\pi(s) = a$.
- ▶ **Estocástica:** $\pi(a \mid s) = \mathbb{P}(a_t = a \mid s_t = s)$.

Exemplo no Mars Rover:

$$\pi(s_1) = \pi(s_2) = \dots = \pi(s_7) = \text{TentarDireita}.$$

Teste sua compreensão

A política acima é determinística ou estocástica? O ambiente estocástico (derrapagem) muda essa resposta?

Dois problemas fundamentais: avaliação e controle

Definição — Avaliação (*policy evaluation*)

Dada π : estimar a recompensa esperada ao segui-la. “*Quão boa é esta política?*”

Definição — Controle

Encontrar a *melhor* política. “*Qual é a melhor forma de agir?*”

Intuição

Quase todo algoritmo alterna: avaliar a política atual $\rightarrow$ melhorar. Avaliação é o primeiro degrau.

SEÇÃO 3

Processos de Markov e processos de recompensa de Markov

03

Estratégia: crescer em complexidade

Por ora: **modelo do mundo dado** — dinâmica e recompensa conhecidas, estados e ações finitos.

Em camadas:

1. **Processo de Markov** — estados e transições;
2. **Processo de recompensa de Markov (MRP)** — + recompensas e desconto;
3. **Processo de decisão de Markov (MDP)** — + ações (aula 2);
4. **Avaliação e controle em MDPs** — planejamento (aula 2).

Modelo dado → *planejamento* clássico; ainda sem aprendizado.

Processo de Markov (cadeia de Markov)

Processo estocástico *sem memória*: estados aleatórios com a propriedade de Markov.

Definição — Processo de Markov

- ▶ $\mathcal{S}$: conjunto (finito) de estados, $s \in \mathcal{S}$;
- ▶ P : modelo de transição, $p(s_{t+1} = s' \mid s_t = s)$.

Sem recompensas, sem ações.


Com N estados finitos, P é uma matriz $N \times N$:

$$P = \begin{pmatrix} P(s_1 \mid s_1) & P(s_2 \mid s_1) & \cdots & P(s_N \mid s_1) \\ P(s_1 \mid s_2) & P(s_2 \mid s_2) & \cdots & P(s_N \mid s_2) \\ \vdots & \vdots & \ddots & \vdots \\ P(s_1 \mid s_N) & P(s_2 \mid s_N) & \cdots & P(s_N \mid s_N) \end{pmatrix}$$

Linha i : distribuição do próximo estado a partir de s_i — soma 1.

Mars Rover como cadeia de Markov

Fixe qualquer regra de movimento e esqueça as ações: sobra uma cadeia



$$P = \begin{pmatrix} 0,6 & 0,4 & 0 & 0 & 0 & 0 & 0 \\ 0,4 & 0,2 & 0,4 & 0 & 0 & 0 & 0 \\ 0 & 0,4 & 0,2 & 0,4 & 0 & 0 & 0 \\ 0 & 0 & 0,4 & 0,2 & 0,4 & 0 & 0 \\ 0 & 0 & 0 & 0,4 & 0,2 & 0,4 & 0 \\ 0 & 0 & 0 & 0 & 0,4 & 0,2 & 0,4 \\ 0 & 0 & 0 & 0 & 0 & 0,4 & 0,6 \end{pmatrix}$$

Episódios: amostrando a cadeia

Partindo de s_4 , alguns episódios possíveis:

$s_4, s_5, s_6, s_7, s_7, s_7, \dots$

$s_4, s_4, s_5, s_4, s_5, s_6, \dots$

$s_4, s_3, s_2, s_1, \dots$

- ▶ Episódio = *realização* do processo estocástico.
- ▶ Regiões bem diferentes do espaço — a incerteza a quantificar.

Intuição

Episódios amostrados serão nossos *dados* (métodos sem modelo).

Processo de recompensa de Markov (MRP)

MRP = cadeia de Markov + recompensas.

Definição — Processo de recompensa de Markov

- ▶ $\mathcal{S}$: conjunto (finito) de estados;
- ▶ P : modelo de transição, $P(s_{t+1} = s' \mid s_t = s)$;
- ▶ R : função recompensa, $R(s) = \mathbb{E}[r_t \mid s_t = s]$;
- ▶ $\gamma \in [0, 1]$: fator de desconto.

Ainda sem ações.

- ▶ Com N estados, R é um vetor em $\mathbb{R}^N$.
- ▶ Mars Rover: $R(s_1) = +1$, $R(s_7) = +10$, resto 0.

Horizonte e retorno

Definição — Horizonte H

Número de passos de tempo por episódio. Pode ser infinito.

Definição — Retorno G_t (de um MRP)

Soma descontada das recompensas do passo t até H :

$$G_t = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \cdots + \gamma^{H-1} r_{t+H-1}$$

- ▶ G_t é **aleatório**: depende da trajetória sorteada.
- ▶ Peso geometricamente menor — o “juro” do tempo.

Função valor de estado

Definição — Função valor $V(s)$ (de um MRP)

Retorno esperado partindo de s :

$$V(s) = \mathbb{E}[G_t \mid s_t = s] = \mathbb{E}[r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \cdots + \gamma^{H-1} r_{t+H-1} \mid s_t = s]$$

Intuição

Retorno = o que *aconteceu*; valor = o que *se espera* em média.

Grande parte do curso: calcular, estimar e otimizar funções valor.

O fator de desconto γ

Por que descontar?

- ▶ **Matemática:** evita retornos infinitos ($H = \infty$).
- ▶ **Comportamento:** agimos como $\gamma < 1$.

Casos extremos:

- ▶ $\gamma = 0$: míope; $\gamma = 1$: futuro vale o mesmo.

Atenção

$H < \infty$: $\gamma = 1$ ok. $H = \infty$ e $\gamma = 1$: a soma pode divergir.

Calculando o valor de um MRP: a equação de Bellman

Para horizonte infinito, V satisfaz

$$V(s) = \underbrace{R(s)}_{\text{recompensa imediata}} + \underbrace{\gamma \sum_{s' \in \mathcal{S}} P(s' | s) V(s')}_{\text{soma descontada das recompensas futuras}}$$

Intuição

Agora + valor (descontado) de onde posso parar — um passo de recursão vira ponto fixo.

Primeira aparição de Bellman — reaparece em praticamente toda aula.

Forma matricial e solução analítica

Com estados finitos, Bellman vira sistema linear:

$$\begin{pmatrix} V(s_1) \\ \vdots \\ V(s_N) \end{pmatrix} = \begin{pmatrix} R(s_1) \\ \vdots \\ R(s_N) \end{pmatrix} + \gamma \begin{pmatrix} P(s_1 | s_1) & \cdots & P(s_N | s_1) \\ \vdots & \ddots & \vdots \\ P(s_1 | s_N) & \cdots & P(s_N | s_N) \end{pmatrix} \begin{pmatrix} V(s_1) \\ \vdots \\ V(s_N) \end{pmatrix}$$

Isolando V :

$$V = R + \gamma PV \implies (I - \gamma P)V = R \implies V = (I - \gamma P)^{-1}R$$

- ▶ $\gamma < 1$: $(I - \gamma P)$ invertível — solução única.
- ▶ Custo: $\sim O(N^3)$ — proibitivo para N grande.

Algoritmo — Avaliação iterativa do valor de um MRP

- ▶ Inicialize $V_0(s) = 0$ para todo s ;
- ▶ Para $k = 1, 2, \dots$ até a convergência:
 - para todo $s \in \mathcal{S}$:

$$V_k(s) = R(s) + \gamma \sum_{s' \in \mathcal{S}} P(s' | s) V_{k-1}(s')$$

- ▶ Custo por iteração: $O(|\mathcal{S}|^2)$.
- ▶ Converge: operador de Bellman é *contração* — prova na próxima aula.

- ▶ RL = **otimização** + **consequências adiadas** + **exploração** + **generalização**.
- ▶ Interação gera **história**; **estado** é o resumo; **Markov** diz quando basta.
- ▶ **Cadeias de Markov** → dinâmica; **MRPs** acrescentam recompensa e desconto.
- ▶ **Valor** $V(s)$ satisfaz **Bellman**: $O(N^3)$ analítico ou $O(N^2)$ /passo iterativo.

Intuição

Próxima aula: *ações* — MDPs, avaliação de política, iteração de política e de valor.

- ▶ Material adaptado e expandido de **CS234: Reinforcement Learning**, Emma Brunskill, Stanford (cs234.stanford.edu); parte da estrutura remonta às notas de David Silver (UCL/DeepMind).
- ▶ **Leitura:** Sutton & Barto, *Reinforcement Learning: An Introduction*, 2ª ed. — capítulos 1 e 3.
- ▶ Artigos citados: Silver et al. (*Nature* 2017); Degraeve et al. (*Nature* 2022); Bastani et al. (*Nature* 2021); Fawzi et al. (*Nature* 2022); Mnih et al. (*Nature* 2015).