

Universidade Federal de Uberlândia

Aula 1: Introdução à Aprendizagem por Reforço

Panorama da área • Decisão sequencial sob incerteza • Processos de Markov

Prof. Marcelo Keese Albertini
Universidade Federal de Uberlândia
adaptado de Emma Brunskill, CS234 (Stanford)
2026



1. **Panorama da aprendizagem por reforço** — o que é, por que importa, e o que a torna diferente de outros paradigmas de aprendizado de máquina.
2. **Tomada de decisão sequencial sob incerteza** — agente, mundo, história, estado e a hipótese de Markov.
3. **Processos de Markov e processos de recompensa de Markov** — nossos primeiros objetos matemáticos: retorno, função valor e a equação de Bellman.

Intuição

Ao final do curso, você saberá *formular* um problema real como um problema de decisão sequencial, *escolher* o algoritmo adequado, *implementá-lo* e *avaliar* criticamente seu desempenho.

SEÇÃO 1

Panorama da aprendizagem por reforço

01

O que é aprendizagem por reforço?

Definição — Aprendizagem por reforço (RL)

Aprender, a partir de **experiência** (dados de interação), a tomar **boas decisões** sob **incerteza**.

- ▶ É uma parte essencial da inteligência: agentes naturais e artificiais aprendem agindo no mundo e observando consequências.
- ▶ Constrói sobre uma teoria iniciada nos anos 1950 com Richard Bellman (programação dinâmica, princípio da otimalidade).
- ▶ Na última década, saiu dos laboratórios e produziu uma sequência de resultados marcantes — de jogos a ciência experimental e modelos de linguagem.

RL hoje: o motor por trás dos sistemas de raciocínio

- ▶ **Modelos de linguagem que raciocinam.** O DeepSeek-R1-Zero foi treinado com RL em larga escala *sem* etapa prévia de ajuste supervisionado, e ainda assim desenvolveu capacidades notáveis de raciocínio. A série o1 da OpenAI usa RL para ensinar o modelo a pensar produtivamente por cadeias de raciocínio.
- ▶ **Matemática de competição.** Sistemas da Google DeepMind atingiram desempenho de medalha de ouro na Olimpíada Internacional de Matemática (35 de 42 pontos), com soluções consideradas surpreendentes pelos organizadores.
- ▶ **Robótica.** Robôs de manipulação aprendem tarefas físicas delicadas — como preparar um café — combinando RL com demonstrações.

Intuição

RLHF, RLVR, *test-time compute*... Boa parte do vocabulário da IA atual é, no fundo, aprendizagem por reforço. Este curso constrói a base para entender essas siglas com precisão.

Uma década de resultados marcantes

- ▶ **Go além do nível humano** — AlphaGo/AlphaGo Zero (Silver et al., *Nature* 2017): autojogo + RL superam campeões mundiais em um jogo com $\sim 10^{170}$ configurações.
- ▶ **Controle de plasma em reatores de fusão** — (Degrave et al., *Nature* 2022): uma política aprendida controla em tempo real as bobinas magnéticas de um tokamak.
- ▶ **Triagem de COVID-19 em fronteiras** — (Bastani et al., *Nature* 2021): o sistema grego *Eurydice* alocou testes de forma adaptativa, detectando quase o dobro de casos que a triagem aleatória.
- ▶ **ChatGPT e alinhamento por RLHF** — RL a partir de *feedback* humano transformou modelos de linguagem em assistentes úteis.

Note a variedade: jogos, física experimental, saúde pública, linguagem. A teoria é a mesma.

Os quatro ingredientes da aprendizagem por reforço

RL envolve, em geral, quatro desafios simultâneos:

1. **Otimização** — queremos as *melhores* decisões, com noção explícita de utilidade.

Os quatro ingredientes da aprendizagem por reforço

RL envolve, em geral, quatro desafios simultâneos:

1. **Otimização** — queremos as *melhores* decisões, com noção explícita de utilidade.
2. **Consequências adiadas** — decisões de agora afetam resultados muito depois.

Os quatro ingredientes da aprendizagem por reforço

RL envolve, em geral, quatro desafios simultâneos:

1. **Otimização** — queremos as *melhores* decisões, com noção explícita de utilidade.
2. **Consequências adiadas** — decisões de agora afetam resultados muito depois.
3. **Exploração** — o agente só aprende sobre aquilo que experimenta.

Os quatro ingredientes da aprendizagem por reforço

RL envolve, em geral, quatro desafios simultâneos:

1. **Otimização** — queremos as *melhores* decisões, com noção explícita de utilidade.
2. **Consequências adiadas** — decisões de agora afetam resultados muito depois.
3. **Exploração** — o agente só aprende sobre aquilo que experimenta.
4. **Generalização** — a política precisa funcionar em situações nunca vistas.

Intuição

Aprendizado supervisionado tem só o item 4; otimização clássica tem só o item 1; *bandits* têm 1, 3 e 4. RL é o problema completo — e por isso é mais difícil e mais geral.

Ingrediente 1: otimização

- ▶ O objetivo é encontrar uma forma **ótima** (ou ao menos muito boa) de decidir, com uma noção explícita de utilidade da decisão.
- ▶ Exemplo clássico: menor rota entre duas cidades dada a malha viária — um problema de decisão sequencial *sem* incerteza e *com* modelo conhecido.

Intuição

Hipótese provocativa de Silver, Singh, Precup e Sutton (*Reward is enough*, 2021): maximizar recompensa seria um objetivo genérico suficiente para fazer emergir a maioria das capacidades que associamos à inteligência — percepção, linguagem, planejamento. Concorde ou não, a hipótese explica a ambição da área.

Ingrediente 2: consequências adiadas

Decisões de agora podem impactar resultados muito mais tarde:

- ▶ poupar hoje para a aposentadoria;
- ▶ pegar a chave no início da fase em *Montezuma's Revenge* para abrir uma porta muito depois.

Isso cria **dois** desafios distintos:

- ▶ **No planejamento:** é preciso pesar o benefício imediato contra as ramificações de longo prazo.
- ▶ **No aprendizado:** a **atribuição de crédito temporal** é difícil — qual das decisões passadas causou a recompensa alta (ou baixa) de agora?

Atenção

A recompensa chega sem etiqueta: nada nela diz *qual* ação a provocou. Distinguir causa de coincidência ao longo do tempo é um dos problemas centrais do curso.

Ingrediente 3: exploração

- ▶ O agente aprende sobre o mundo *tomando decisões* — é um cientista que experimenta: aprende-se a andar de bicicleta tentando (e caindo).
- ▶ As decisões determinam *quais dados* o agente obtém: só observamos a recompensa da ação que tomamos.
- ▶ **Dados censurados / contrafactuais:** nunca vemos o que *teria* acontecido com a outra escolha. Quem opta pela UFU em vez de outra universidade viverá experiências diferentes — e jamais observará a trajetória alternativa.

Intuição

No aprendizado supervisionado, o rótulo correto é dado para cada exemplo. Em RL, o “rótulo” da ação não escolhida simplesmente não existe. Este é o dilema **exploração vs. aproveitamento**, tema da parte final do curso.

Ingrediente 4: generalização

- ▶ Uma **política** é um mapeamento da experiência passada para ações.
- ▶ Por que não simplesmente *pré-programar* esse mapeamento?
- ▶ Exemplo (DQN em Atari, *Nature* 2015): a entrada é a imagem da tela. Com quadros de 84×84 pixels, o número de entradas possíveis é astronômico — nenhuma tabela ou conjunto de regras manuais cobre todos os casos.
- ▶ A política precisa **generalizar**: agir bem em estados que nunca apareceram no treinamento.

É aqui que RL encontra aprendizado profundo: redes neurais como aproximadores de políticas e funções valor (aulas futuras).

Onde RL é particularmente poderosa

Duas categorias de problema em que RL se destaca:

1. **Não há exemplos do comportamento desejado.** Ou porque a meta é *superar* o desempenho humano, ou porque simplesmente não existem dados para a tarefa.
Ex.: AlphaGo Zero aprendeu do zero, sem partidas humanas.
2. **Busca/otimização gigantesca com resultado adiado.** O espaço de soluções é grande demais para enumeração e a qualidade só é conhecida ao final.
Ex.: AlphaTensor (Fawzi et al. 2022) descobriu algoritmos de multiplicação de matrizes mais rápidos que os conhecidos, tratando a busca como um jogo.

RL no mapa do aprendizado de máquina

	Supervisionado	Não supervisionado	Por reforço
Sinal de aprendizado	rótulo correto	por nenhum rótulo	recompensa escalar, possivelmente atrasada
Dados	exemplo fixos, i.i.d.	fixos, i.i.d.	gerados pelas <i>próprias</i> ações do agente
Objetivo	prever bem	descobrir estrutura	<i>agir</i> bem ao longo do tempo
Erro informa...	a resposta certa	—	apenas <i>quão bom</i> foi o que se fez

Atenção

Em RL os dados não são i.i.d.: a política atual determina os estados visitados amanhã. Mudar a política muda a distribuição dos dados — uma dificuldade que não existe nos outros paradigmas.

Ementa oficial: o curso é de Inteligência Artificial

Ementa (ficha GBC063, FACOM/UFU)	Onde aparece no curso
Introdução à IA: definições, histórico, subdivisões (simbólico, conexionista, evolutivo, swarm); linguagens	Panorama nesta aula (Python é a linguagem do curso)
Solução de problemas: busca, busca informada, jogos e planejamento	MCTS e AlphaZero (aulas 13–14); planejamento em MDP (aula 2)
Representação do conhecimento; raciocínio lógico; sistemas especialistas	Panorama nesta aula (base de conhecimento + motor de inferência, encadeamentos progressivo/regressivo)
Conhecimento e raciocínio com incerteza	MDPs e bandits (todo o curso)
Aprendizagem: supervisionada, não supervisionada, por reforço	Mapa do AM (há pouco); RL é o núcleo (aulas 1–14)
Tópicos recentes em IA	DQN (aula 4), PPO (aulas 5–7), RLHF/DPO (aulas 7–8)

Atenção

A disciplina é de Inteligência Artificial: a ficha oficial pede também os fundamentos simbólicos. Esta aula dá o panorama e as pontes; o curso mergulha fundo no RL.

Trajetória do curso

- ▶ Processos de decisão de Markov e planejamento
- ▶ Avaliação de política sem modelo
- ▶ Controle sem modelo
- ▶ Busca de política (gradientes)
- ▶ RL *offline*, RLHF e DPO
- ▶ Exploração
- ▶ Tópicos avançados

Ao final, você deve saber

- ▶ definir os elementos-chave de RL;
- ▶ decidir *se e como* usar RL em um problema real;
- ▶ implementar os algoritmos clássicos;
- ▶ avaliar teórica e empiricamente a qualidade de um algoritmo.

SEÇÃO 2

Tomada de decisão sequencial sob incerteza

02

Exercício de aquecimento: um tutor de IA como processo de decisão

Teste sua compreensão

Um estudante inicialmente não sabe *adição* (mais fácil) nem *subtração* (mais difícil). Um agente tutor propõe exercícios de adição ou de subtração e recebe $+1$ quando o estudante acerta, -1 quando erra.

Modele como um processo de decisão: espaço de estados? Ações? Modelo de recompensa? O que a dinâmica representa aqui? Que comportamento uma política ótima produziria? Esse é o melhor incentivo para promover *aprendizado*? Que recompensa alternativa você proporia?

Atenção

Moral: a recompensa *define* o problema. Mal projetada, é otimizada ao pé da letra — o tutor passa a propor só adições fáceis.

Decisão sequencial: o objetivo

Definição — Tomada de decisão sequencial

Selecionar ações para **maximizar a recompensa total esperada futura**, o que pode exigir equilibrar ganhos imediatos e de longo prazo.


O mesmo molde serve para problemas muito diferentes:

- ▶ **Publicidade na web** — que anúncio exibir? Cliques agora vs. satisfação (e retenção) do usuário no longo prazo.
- ▶ **Robô esvaziando a lava-louças** — que junta mover? Pegar a louça rápido vs. não quebrar nada.
- ▶ **Controle de pressão arterial** — que dose prescrever? Reduzir a pressão agora vs. efeitos colaterais acumulados.

A interação agente-mundo (tempo discreto)

A cada passo de tempo t :

1. o agente executa a ação a_t ;
2. o mundo se atualiza dado a_t e emite a observação o_t e a recompensa r_t ;
3. o agente recebe o_t e r_t e decide a_{t+1} .



Intuição

Este laço fechado é a assinatura de RL: os dados de amanhã dependem da decisão de hoje. Não há como separar “coleta de dados” de “aprendizado”.

Definição — História h_t

A sequência de tudo que o agente já fez e percebeu: $h_t = (a_1, o_1, r_1, \dots, a_t, o_t, r_t)$. Em princípio, o agente escolhe a próxima ação com base em h_t .

Definição — Estado s_t

A informação assumida como suficiente para determinar o que acontece a seguir. É sempre uma *função da história*: $s_t = f(h_t)$.

- ▶ A história cresce sem limite; o estado é o **resumo** que escolhemos guardar.
- ▶ Escolher f é uma decisão de *modelagem* — e das mais importantes, como veremos.

A hipótese de Markov

Definição — Estado de Markov (estado-informação)

O estado s_t é de Markov se, e somente se,

$$\mathbb{P}(s_{t+1} \mid s_t, a_t) = \mathbb{P}(s_{t+1} \mid h_t, a_t),$$

isto é, s_t é uma **estatística suficiente** da história.

Intuição

“O futuro é independente do passado, dado o presente.” Se o estado resume tudo que importa, podemos jogar a história fora.

- ▶ Sempre é possível satisfazer Markov trivialmente: basta tomar $s_t = h_t$. Mas isso é inútil na prática — o estado explode.
- ▶ A arte está em achar o *menor* estado que ainda é (quase) Markov.

Por que a hipótese de Markov é tão popular?

- ▶ É simples, e muitas vezes pode ser satisfeita incluindo um pouco de história no estado (ex.: as últimas k observações).
- ▶ Na prática, é comum assumir que a observação mais recente basta: $s_t = o_t$.

A escolha da representação de estado tem impacto direto em:

- ▶ **complexidade computacional** — estados maiores custam mais;
- ▶ **quantidade de dados necessária** — mais dimensões, mais amostras;
- ▶ **desempenho final** — estado pobre demais viola Markov e degrada a política.

Teste sua compreensão

No xadrez, a configuração atual do tabuleiro (mais o jogador da vez) é um estado de Markov?
E a imagem de *um único quadro* de um jogo de Atari com objetos em movimento?

Tipos de processos de decisão sequencial

Três eixos para classificar um problema:

- ▶ **O estado é observável?** Se o agente vê apenas uma observação parcial do estado verdadeiro, temos um *POMDP* (processo de decisão de Markov parcialmente observável). Ex.: pôquer, robô com câmera.
- ▶ **A dinâmica é determinística ou estocástica?** Dada a ação, o próximo estado é único ou sorteado de uma distribuição?
- ▶ **As ações afetam apenas a recompensa imediata ou também o próximo estado?** No primeiro caso temos *bandits* (caso especial importante); no segundo, o problema sequencial completo.

Este curso começa pelo caso mais limpo: estado de Markov totalmente observável, dinâmica estocástica, ações que afetam o futuro — o **MDP**.

Exemplo condutor: o *Mars Rover* como MDP

Um robô explorador numa fileira de sete posições



- ▶ **Estados:** a posição do rover, $\mathcal{S} = \{s_1, \dots, s_7\}$.
- ▶ **Ações:** $\mathcal{A} = \{\text{TentarEsquerda}, \text{TentarDireita}\}$ — “tentar”, porque o terreno pode fazer o rover derrapar.
- ▶ **Recompensas:** $+1$ em s_1 , $+10$ em s_7 , 0 nos demais estados.

Este exemplo minúsculo nos acompanhará por várias aulas: é pequeno o bastante para calcular tudo à mão.

O modelo do MDP: como o agente representa o mundo

Um **modelo** é a representação, *do agente*, de como o mundo muda em resposta às suas ações.

Definição — Modelo de transição (dinâmica)

Prevê o próximo estado do agente: $p(s_{t+1} = s' \mid s_t = s, a_t = a)$.

Definição — Modelo de recompensa

Prevê a recompensa imediata: $r(s, a) = \mathbb{E}[r_t \mid s_t = s, a_t = a]$.

Atenção

O modelo do agente pode estar *errado* — e em geral está, ao menos no início. Boa parte de RL trata de agir bem apesar disso.

Mars Rover: um modelo estocástico

Parte do modelo de transição do agente para a ação TentarDireita:

$$0,5 = P(s_1 \mid s_1, \text{TD}) = P(s_2 \mid s_1, \text{TD}), \quad 0,5 = P(s_2 \mid s_2, \text{TD}) = P(s_3 \mid s_2, \text{TD}), \quad \dots$$

e um modelo de recompensa que prevê $\hat{r} = 0$ em *todos* os estados.

- ▶ Metade das vezes o rover derrapa e fica onde está; na outra metade, avança.
- ▶ O modelo de recompensa acima está **errado**: o mundo real paga +1 em s_1 e +10 em s_7 .

Intuição

Modelo $\neq$ realidade. O agente carrega uma *crença* sobre o mundo; a experiência serve para corrigi-la.

Política: o comportamento do agente

Definição — Política π

Determina como o agente escolhe ações.

- ▶ **Determinística:** $\pi : \mathcal{S} \rightarrow \mathcal{A}$, escrita $\pi(s) = a$.
- ▶ **Estocástica:** $\pi(a \mid s) = \mathbb{P}(a_t = a \mid s_t = s)$.

Exemplo no Mars Rover:

$$\pi(s_1) = \pi(s_2) = \dots = \pi(s_7) = \text{TentarDireita}.$$

Teste sua compreensão

A política acima é determinística ou estocástica? E o fato de o *ambiente* ser estocástico (o rover derrapa) muda essa resposta?

Dois problemas fundamentais: avaliação e controle

Definição — Avaliação (*policy evaluation*)

Dada uma política π , estimar/prever a recompensa esperada obtida ao segui-la.
“Quão boa é esta forma de agir?”

Definição — Controle

Otimização: encontrar a *melhor* política. “Qual é a melhor forma de agir?”

Intuição

Quase todos os algoritmos do curso alternam entre esses dois passos: avaliar a política atual e usá-la para melhorar. Dominar avaliação é o primeiro degrau — e é por ela que começamos, no cenário mais simples possível.

SEÇÃO 3

Processos de Markov e processos de recompensa de Markov

03

Estratégia: crescer em complexidade

Antes de enfrentar o problema completo (aprender e decidir), supomos por enquanto que o **modelo do mundo é dado** — dinâmica e recompensa conhecidas, com estados e ações finitos.

Construiremos a teoria em camadas:

1. **Processo de Markov** — só estados e transições;
2. **Processo de recompensa de Markov (MRP)** — + recompensas e desconto;
3. **Processo de decisão de Markov (MDP)** — + ações (aula 2);
4. **Avaliação e controle em MDPs** — planejamento (aula 2).

Com o modelo dado, isso é um problema clássico de *planejamento* em IA — ainda não há aprendizado.

Processo de Markov (cadeia de Markov)

Um processo estocástico *sem memória*: uma sequência de estados aleatórios com a propriedade de Markov.

Definição — Processo de Markov

- ▶ $\mathcal{S}$: conjunto (finito) de estados, $s \in \mathcal{S}$;
- ▶ P : modelo de transição, que especifica $p(s_{t+1} = s' \mid s_t = s)$.

Sem recompensas, sem ações.


Com um número finito N de estados, P é uma matriz $N \times N$:

$$P = \begin{pmatrix} P(s_1 \mid s_1) & P(s_2 \mid s_1) & \cdots & P(s_N \mid s_1) \\ P(s_1 \mid s_2) & P(s_2 \mid s_2) & \cdots & P(s_N \mid s_2) \\ \vdots & \vdots & \ddots & \vdots \\ P(s_1 \mid s_N) & P(s_2 \mid s_N) & \cdots & P(s_N \mid s_N) \end{pmatrix}$$

A linha i é a distribuição do próximo estado a partir de s_i — cada linha soma 1.

Mars Rover como cadeia de Markov

Fixe qualquer regra de movimento e esqueça as ações: sobra uma cadeia



$$P = \begin{pmatrix} 0,6 & 0,4 & 0 & 0 & 0 & 0 & 0 \\ 0,4 & 0,2 & 0,4 & 0 & 0 & 0 & 0 \\ 0 & 0,4 & 0,2 & 0,4 & 0 & 0 & 0 \\ 0 & 0 & 0,4 & 0,2 & 0,4 & 0 & 0 \\ 0 & 0 & 0 & 0,4 & 0,2 & 0,4 & 0 \\ 0 & 0 & 0 & 0 & 0,4 & 0,2 & 0,4 \\ 0 & 0 & 0 & 0 & 0 & 0,4 & 0,6 \end{pmatrix}$$

Episódios: amostrando a cadeia

Partindo de s_4 , alguns episódios possíveis:

$s_4, s_5, s_6, s_7, s_7, s_7, \dots$

$s_4, s_4, s_5, s_4, s_5, s_6, \dots$

$s_4, s_3, s_2, s_1, \dots$

- ▶ Cada episódio é uma *realização* do processo estocástico.
- ▶ Trajetórias distintas podem levar a regiões completamente diferentes do espaço de estados — eis a incerteza que precisamos quantificar.

Intuição

Mais adiante no curso, episódios amostrados serão nossos *dados*: métodos sem modelo estimam valores diretamente de trajetórias como essas.

Processo de recompensa de Markov (MRP)

Um MRP é uma cadeia de Markov + recompensas.

Definição — Processo de recompensa de Markov

- ▶ $\mathcal{S}$: conjunto (finito) de estados;
- ▶ P : modelo de transição, $P(s_{t+1} = s' \mid s_t = s)$;
- ▶ R : função recompensa, $R(s) = \mathbb{E}[r_t \mid s_t = s]$;
- ▶ $\gamma \in [0, 1]$: fator de desconto.

Ainda sem ações.

- ▶ Com N estados, R é um vetor em $\mathbb{R}^N$.
- ▶ No Mars Rover: $R(s_1) = +1$, $R(s_7) = +10$ e $R(s) = 0$ nos demais estados.

Horizonte e retorno

Definição — Horizonte H

Número de passos de tempo em cada episódio. Pode ser infinito; caso contrário, o processo é dito de *horizonte finito*.

Definição — Retorno G_t (de um MRP)

Soma descontada das recompensas do passo t até o horizonte H :

$$G_t = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \cdots + \gamma^{H-1} r_{t+H-1}$$

- ▶ G_t é uma variável *aleatória*: depende da trajetória sorteada.
- ▶ Cada recompensa futura entra com peso geometricamente menor — o “juro” do tempo.

Função valor de estado

Definição — Função valor $V(s)$ (de um MRP)

Retorno esperado partindo do estado s :

$$V(s) = \mathbb{E}[G_t \mid s_t = s] = \mathbb{E}[r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \cdots + \gamma^{H-1} r_{t+H-1} \mid s_t = s]$$

Intuição

O retorno é o que *aconteceu* numa trajetória; o valor é o que *esperamos* que aconteça em média. A função valor comprime toda a aleatoriedade futura em um único número por estado.

Grande parte deste curso consiste em calcular, estimar e otimizar funções valor.

O fator de desconto γ

Por que descontar o futuro?

- ▶ **Conveniência matemática:** evita retornos e valores infinitos quando $H = \infty$.
- ▶ **Plausibilidade comportamental:** pessoas frequentemente agem como se tivessem $\gamma < 1$ (preferem recompensa agora).

Casos extremos:

- ▶ $\gamma = 0$: só a recompensa imediata importa — agente míope;
- ▶ $\gamma = 1$: recompensa futura vale tanto quanto a imediata.

Atenção

Se os episódios são sempre finitos ($H < \infty$), pode-se usar $\gamma = 1$ sem risco. Com $H = \infty$ e $\gamma = 1$, a soma pode divergir.

Calculando o valor de um MRP: a equação de Bellman

A propriedade de Markov dá estrutura ao problema. Para horizonte infinito, a função valor de um MRP satisfaz

$$V(s) = \underbrace{R(s)}_{\text{recompensa imediata}} + \underbrace{\gamma \sum_{s' \in \mathcal{S}} P(s' | s) V(s')}_{\text{soma descontada das recompensas futuras}}$$

Intuição

O valor de hoje se decompõe em: o que ganho *agora* + o valor (descontado) de onde posso *parar*. Um passo de recursão troca um problema de horizonte infinito por uma equação de ponto fixo.

Esta é a primeira aparição da equação de Bellman — ela reaparecerá, com ações, em praticamente toda aula do curso.

Forma matricial e solução analítica

Com estados finitos, a equação de Bellman vira um sistema linear:

$$\begin{pmatrix} V(s_1) \\ \vdots \\ V(s_N) \end{pmatrix} = \begin{pmatrix} R(s_1) \\ \vdots \\ R(s_N) \end{pmatrix} + \gamma \begin{pmatrix} P(s_1 | s_1) & \cdots & P(s_N | s_1) \\ \vdots & \ddots & \vdots \\ P(s_1 | s_N) & \cdots & P(s_N | s_N) \end{pmatrix} \begin{pmatrix} V(s_1) \\ \vdots \\ V(s_N) \end{pmatrix}$$

Isolando V :

$$V = R + \gamma PV \implies (I - \gamma P)V = R \implies V = (I - \gamma P)^{-1}R$$

- ▶ Para $\gamma < 1$, a matriz $(I - \gamma P)$ é invertível — a solução existe e é única.
- ▶ Custo da solução direta: inverter uma matriz, $\sim O(N^3)$. Proibitivo para N grande.

Algoritmo iterativo: programação dinâmica

Algoritmo — Avaliação iterativa do valor de um MRP

- ▶ Inicialize $V_0(s) = 0$ para todo s ;
- ▶ Para $k = 1, 2, \dots$ até a convergência:
 - para todo $s \in \mathcal{S}$:

$$V_k(s) = R(s) + \gamma \sum_{s' \in \mathcal{S}} P(s' | s) V_{k-1}(s')$$

- ▶ Custo por iteração: $O(|\mathcal{S}|^2)$ — bem mais barato que $O(|\mathcal{S}|^3)$ quando poucas iterações bastam.
- ▶ Por que converge? Porque o operador de Bellman é uma *contração* — demonstraremos isso na próxima aula.

Resumo da aula

- ▶ Aprendizagem por reforço combina **otimização, consequências adiadas, exploração e generalização** — aprender a decidir bem sob incerteza.
- ▶ A interação agente–mundo gera uma **história**; o **estado** é o resumo dela, e a **hipótese de Markov** diz quando esse resumo basta.
- ▶ **Cadeias de Markov** modelam a dinâmica; **MRPs** acrescentam recompensa e desconto.
- ▶ O **valor** $V(s)$ é o retorno esperado, e satisfaz a **equação de Bellman** — resolvível analiticamente em $O(N^3)$ ou iterativamente a $O(N^2)$ por passo.

Intuição

Próxima aula: acrescentamos *ações* — processos de decisão de Markov, avaliação de políticas, e os algoritmos de iteração de política e de valor.

- ▶ Material adaptado e expandido de **CS234: Reinforcement Learning**, Emma Brunskill, Stanford University (cs234.stanford.edu); parte da estrutura introdutória remonta às notas de David Silver (UCL/DeepMind).
- ▶ **Leitura recomendada:** Sutton & Barto, *Reinforcement Learning: An Introduction*, 2ª ed. — capítulos 1 e 3 cobrem o conteúdo de hoje.
- ▶ Artigos citados: Silver et al. (*Nature* 2017); Degraeve et al. (*Nature* 2022); Bastani et al. (*Nature* 2021); Fawzi et al. (*Nature* 2022); Mnih et al. (*Nature* 2015).