

Aula 1 — Introdução à aprendizagem por reforço

Resumo de estudo • decisão sequencial, processos de Markov e a equação de Bellman

Ideia central

Aprendizagem por reforço é aprender, a partir de **experiência**, a tomar **boas decisões** sob **incerteza**. O que a distingue dos demais paradigmas: os dados que o agente verá amanhã dependem das decisões que ele tomar hoje.

1 Os quatro ingredientes

1. Otimização

Buscamos a *melhor* maneira de decidir, com uma noção explícita de utilidade. Não basta prever bem — é preciso agir bem.

3. Exploração

O agente só observa a recompensa da ação que tomou. O resultado das alternativas é um contrafactual que nunca se observa.

2. Consequências adiadas

A decisão de agora afeta resultados distantes. Cria dois problemas: pesar futuro no *planejamento* e a *atribuição de crédito temporal* no aprendizado.

4. Generalização

A política precisa agir bem em estados nunca vistos — daí o uso de aproximadores de função (redes neurais).

Aprendizado supervisionado tem apenas o item 4; otimização clássica, apenas o item 1; *bandits* têm 1, 3 e 4. RL é o problema completo.

2 Do laço agente–mundo ao estado de Markov

A cada passo t : o agente executa a_t ; o mundo se atualiza e emite observação o_t e recompensa r_t ; o agente recebe ambas e decide a_{t+1} .

Definição — história e estado

História: $h_t = (a_1, o_1, r_1, \dots, a_t, o_t, r_t)$ — tudo que o agente fez e percebeu.

Estado: $s_t = f(h_t)$ — o resumo da história que assumimos suficiente para determinar o que vem a seguir.

Definição — estado de Markov

s_t é de Markov se, e somente se, $\mathbb{P}(s_{t+1} \mid s_t, a_t) = \mathbb{P}(s_{t+1} \mid h_t, a_t)$, isto é, s_t é uma *estatística suficiente* da história.

Intuição

“O futuro é independente do passado, dado o presente.” Markov sempre pode ser satisfeito trivialmente tomando $s_t = h_t$ — mas isso é inútil, pois o estado explode. A arte está em achar o *menor* resumo que ainda é (quase) Markov. A escolha da representação de estado afeta diretamente o custo computacional, a quantidade de dados necessária e o desempenho final.

Três eixos para classificar um problema

- O estado é totalmente observável? Se não, é um **POMDP**.
- A dinâmica é determinística ou estocástica?
- As ações afetam apenas a recompensa imediata (**bandits**) ou também o próximo estado (problema sequencial completo)?

3 Cadeias de Markov e processos de recompensa

Definição — processo de Markov (cadeia)

Par (S, P) : um conjunto finito de estados e um modelo de transição $p(s_{t+1} = s' \mid s_t = s)$. *Sem ações, sem recompensas*. Com N estados, P é uma matriz $N \times N$ cujas linhas somam 1.

Definição — processo de recompensa de Markov (MRP)

Quádrupla $(\mathcal{S}, P, R, \gamma)$: acrescenta a função recompensa $R(s) = \mathbb{E}[r_t \mid s_t = s]$ e o fator de desconto $\gamma \in [0, 1]$. Ainda sem ações.

Horizonte, retorno e valor

$$G_t = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \dots + \gamma^{H-1} r_{t+H-1} \quad \text{retorno (variável aleatória)}$$
$$V(s) = \mathbb{E}[G_t \mid s_t = s] \quad \text{função valor (número por estado)}$$

Intuição

O *retorno* é o que aconteceu numa trajetória; o *valor* é o que esperamos em média. A função valor comprime toda a aleatoriedade futura em um único número por estado — é o objeto que calculamos, estimamos e otimizamos no curso inteiro.

Por que descontar

γ evita retornos infinitos quando $H = \infty$ e reflete a preferência observada por recompensa imediata. $\gamma = 0$: agente míope, $V(s) = R(s)$. $\gamma = 1$: futuro vale tanto quanto o presente — seguro apenas se $H < \infty$.

4 A equação de Bellman

A propriedade de Markov dá estrutura recursiva ao problema:

$$V(s) = \underbrace{R(s)}_{\text{recompensa imediata}} + \underbrace{\gamma \sum_{s' \in \mathcal{S}} P(s' \mid s) V(s')}_{\text{soma descontada das recompensas futuras}}$$

Em forma vetorial, $V = R + \gamma PV$, de onde saem os dois métodos de solução:

a) Solução analítica

$$(I - \gamma P) V = R \implies V = (I - \gamma P)^{-1} R$$

Para $\gamma < 1$ a matriz $(I - \gamma P)$ é invertível e a solução é única. Custo: $O(N^3)$.

b) Solução iterativa (programação dinâmica)

Algoritmo — avaliação iterativa do valor de um MRP

Inicialize $V_0(s) = 0$ para todo s . Para $k = 1, 2, \dots$ até a convergência, e para todo $s \in \mathcal{S}$:

$$V_k(s) = R(s) + \gamma \sum_{s' \in \mathcal{S}} P(s' \mid s) V_{k-1}(s')$$


Custo: $O(|\mathcal{S}|^2)$ por iteração.

Intuição

A iteração converge porque o operador de Bellman é uma *contração*: o erro cai geometricamente, $\|V_k - V\|_\infty \leq \gamma^k \|V_0 - V\|_\infty$. A prova vem na Aula 2 — por ora, observe o efeito na tabela da seção seguinte.

5 Exemplo trabalhado: Mars Rover

Sete posições; a cada passo o rover vai para cada lado com probabilidade 0,4 e permanece com o restante; as bordas absorvem o excedente. Recompensa +1 em s_1 , +10 em s_7 , 0 nos demais. Tome $\gamma = 0,9$.



k	s_1	s_2	s_3	s_4	s_5	s_6	s_7	$\ V_k - V\ _\infty$
0	0,00	0,00	0,00	0,00	0,00	0,00	0,00	40,97
1	1,00	0,00	0,00	0,00	0,00	0,00	10,00	30,97
2	1,54	0,36	0,00	0,00	0,00	3,60	15,40	25,57
3	1,96	0,62	0,13	0,00	1,30	6,19	19,61	21,36
4	2,28	0,86	0,25	0,51	2,46	8,64	22,82	18,15
5	2,54	1,07	0,54	1,07	3,74	10,66	25,43	15,54
V (exato)	6,91	6,05	6,87	9,61	15,01	24,58	40,97	—

O que ler nesta tabela.

- O valor *se espalha* a partir das fontes de recompensa: em $k = 1$ só s_1 e s_7 têm valor; a informação leva uma iteração para andar um estado. Em $k = 3$ ela ainda não chegou a s_4 .
- Na solução exata, $V(s_2) < V(s_1)$ e $V(s_3) < V(s_1)$, mas $V(s_4) > V(s_1)$: perto da borda esquerda vale a pena o +1 fácil; do meio para a direita, o +10 domina apesar de mais distante.
- A razão entre erros sucessivos (0,76; 0,83; 0,84; 0,85; ...) sobe em direção a $\gamma = 0,9$ — exatamente a taxa de contração prevista.

6 Armadilhas comuns

Atenção

- **Confundir retorno com valor.** G_t é aleatório e vale para *uma* trajetória; $V(s)$ é a esperança sobre todas elas.
- **Achar que política determinística implica trajetória determinística.** A política pode ser determinística e o ambiente estocástico: ações fixas, resultados variados.
- **Usar $\gamma = 1$ com horizonte infinito.** A soma pode divergir e $(I - \gamma P)$ deixa de ser invertível.
- **Tratar o modelo do agente como verdade.** No exemplo do CS234, o modelo de recompensa do rover prevê $\hat{r} = 0$ em todo estado — e está errado. Agir bem apesar disso é boa parte do curso.
- **Projetar recompensa ingenuamente.** O agente otimiza o que foi escrito, não o que se quis dizer: um tutor recompensado por acertos aprende a propor só exercícios fáceis.

7 Notação e vocabulário

Símbolo	Significado
$S, \mathcal{A}$	espaços de estados e ações
s_t, a_t, r_t	estado, ação, recompensa em t
h_t	história até t
$P(s' s)$	modelo de transição
$R(s)$	recompensa esperada em s
γ	fator de desconto
H	horizonte
G_t	retorno a partir de t
$V(s)$	função valor de estado
π	política
$\ \cdot\ _\infty$	norma do supremo

Inglês	Português
reinforcement learning	aprendizagem por reforço
state / action / reward	estado / ação / recompensa
policy	política
value function	função valor
return	retorno
horizon	horizonte
discount factor	fator de desconto
transition model	modelo de transição
policy evaluation	avaliação de política
contraction operator	operador de contração
<i>backup</i>	mantido em inglês

8 Exercícios

1. **Caso míope.** Mostre que, com $\gamma = 0$, a iteração converge em um único passo e $V(s) = R(s)$ para todo s .
2. **Propagação.** Sem calcular tudo, argumente quantas iterações são necessárias para que $V_k(s_4) > 0$ no exemplo acima. Generalize: qual a relação entre o número de iterações e a distância até a fonte de recompensa mais próxima?
3. **Onde fica o mínimo.** Com $\gamma = 0,5$, a solução exata é $V = (1,53; 0,37; 0,13; 0,22; 0,85; 3,59; 15,31)$. Em qual estado está o *menor* valor nesse caso? E na tabela de $\gamma = 0,9$? Explique por que o mínimo se desloca.
4. **Custos.** Para que valores de N e de número de iterações K a solução iterativa é mais barata que a analítica? Escreva a condição em função de N e K .

5. **Modelagem.** Modele como processo de decisão: um sistema de recomendação de vídeos que recebe +1 por clique. Defina estado, ação e recompensa; depois aponte qual comportamento indesejado essa recompensa pode induzir e proponha uma alternativa.
6. **Markov ou não.** Para cada caso, diga se a representação é de Markov e justifique: (a) tabuleiro de xadrez atual mais jogador da vez; (b) um único quadro de um jogo de Atari com objetos em movimento; (c) os quatro últimos quadros do mesmo jogo.

9 Respostas resumidas

- Com $\gamma = 0$ o termo futuro desaparece: $V_1(s) = R(s) + 0 = R(s)$, e $V_2 = V_1$. O ponto fixo é atingido na primeira iteração — o agente é míope por construção.
- $V_k(s) > 0$ apenas quando existe caminho de comprimento $\leq k - 1$ de s até algum estado com recompensa. Como s_4 dista 3 passos tanto de s_1 quanto de s_7 , é preciso $k \geq 4$ — e a tabela confirma: $V_4(s_4) = 0,51$ é o primeiro valor não nulo. Em geral, o valor se propaga um estado por iteração.
- Com $\gamma = 0,5$ o mínimo está em s_3 ; com $\gamma = 0,9$, em s_2 . Desconto forte encolhe o alcance do +10, então o pior lugar é o mais distante do +1 que ainda não sente a borda direita. Com $\gamma = 0,9$ o +10 irradia por toda a cadeia e empurra o ponto de equilíbrio para a esquerda.
- Iterativa: $K \cdot O(N^2)$; analítica: $O(N^3)$. A iterativa é mais barata quando $K < N$. O detalhe importante: K depende da precisão desejada e de γ ($K \approx \log \varepsilon / \log \gamma$), não de N — logo, para N grande a iterativa praticamente sempre vence.
- Estado: histórico e perfil do usuário; ação: vídeo recomendado; recompensa: +1 por clique. O comportamento induzido é *clickbait* — títulos sensacionalistas maximizam cliques sem entregar valor, e o sistema pode estreitar o interesse do usuário. Alternativas: tempo assistido em proporção à duração, avaliação explícita, ou retenção medida em janelas longas.
- (a) Sim, desde que o estado inclua também direitos de roque, possibilidade de *en passant* e contadores de repetição — só o arranjo das peças não basta. (b) Não: um único quadro não informa velocidade nem direção dos objetos. (c) Aproximadamente sim — empilhar quatro quadros recupera velocidade e aceleração, e foi exatamente a solução adotada pelo DQN em Atari.

10 Autoavaliação

Você domina esta aula se consegue, sem consultar o material:

- | | |
|---|--|
| ☐ explicar os quatro ingredientes de RL e dizer quais deles aparecem em aprendizado supervisionado e em <i>bandits</i> ; | ☐ escrever a equação de Bellman para um MRP e explicar cada termo; |
| ☐ escrever a condição de Markov e dar um exemplo de representação que a viola; | ☐ deduzir $V = (I - \gamma P)^{-1} R$ a partir de $V = R + \gamma PV$; |
| ☐ distinguir retorno de valor e dizer qual dos dois é aleatório; | ☐ comparar os custos das soluções analítica e iterativa; |
| ☐ enunciar a definição de MRP com seus quatro componentes; | ☐ calcular à mão as duas primeiras iterações do <i>Mars Rover</i> ; |
| | ☐ explicar o que acontece com $\gamma = 0$ e com $\gamma = 1$. |

11 Para ir além

- Simulador interativo desta aula** — cadeia do *Mars Rover*, iteração de Bellman passo a passo, gráfico de contração e amostragem de episódios: simulador-mars-rover.html.
- Leitura.** Sutton & Barto, *Reinforcement Learning: An Introduction*, 2ª ed., capítulos 1 e 3.
- Próxima aula.** Entram as ações: processos de decisão de Markov, avaliação de políticas e os algoritmos de iteração de política e de valor, com a prova de que o operador de Bellman é uma contração.