

De onde vem a equação de Bellman

complemento da Aula 1

Dedução a partir da definição de um processo de recompensa de Markov

A pergunta que esta nota responde: por que uma esperança sobre *infinitas trajetórias de comprimento infinito* pode ser reescrita como um sistema de $|\mathcal{S}|$ equações lineares? A resposta não é um truque só — são cinco passos, cada um usando uma ferramenta diferente. Vale separá-los, porque cada hipótese do modelo entra em um passo específico, e saber *onde* ela entra é saber o que quebra quando ela cai.

1 Ponto de partida

O que estamos supondo

Um **processo de recompensa de Markov** $(\mathcal{S}, P, R, \gamma)$ com:

- $\mathcal{S}$ finito, e transições $P(s' | s) = \mathbb{P}(s_{t+1} = s' | s_t = s)$ que **não dependem de t** (homogeneidade temporal);
- recompensa esperada $R(s) = \mathbb{E}[r_t | s_t = s]$, também independente de t , e **limitada**: $|R(s)| \leq R_{\max} < \infty$;
- horizonte **infinito** e desconto $\gamma \in [0, 1)$.

As duas definições que vamos manipular, e nada além delas:

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k}, \quad V(s) = \mathbb{E}[G_t | s_t = s].$$

G_t é uma *variável aleatória* — muda a cada trajetória sorteada. $V(s)$ é um *número* por estado. O objetivo é chegar em $V(s) = R(s) + \gamma \sum_{s'} P(s' | s) V(s')$.

2 A dedução, passo a passo

Passo 1 • álgebra pura

O retorno é **auto-similar**. Separe a primeira parcela e fator γ do que sobra:

$$G_t = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \dots = r_t + \gamma \underbrace{(r_{t+1} + \gamma r_{t+2} + \dots)}_{= G_{t+1}} \implies \boxed{G_t = r_t + \gamma G_{t+1}}$$

Nenhuma probabilidade foi usada aqui: isto vale trajetória a trajetória. É a observação que faz todo o resto funcionar — a **cauda** da soma, depois de fatorar γ , é uma cópia exata da soma original deslocada um passo.

Por que o desconto tem de ser geométrico

Suponha pesos quaisquer, $G_t = \sum_{k \geq 0} w_k r_{t+k}$. Para que a cauda seja proporcional a G_{t+1} , precisamos de uma constante c com $\sum_{k \geq 1} w_k r_{t+k} = c \sum_{k \geq 0} w_k r_{t+1+k}$ para *toda* sequência de recompensas — ou seja, $w_{k+1} = c w_k$ para todo k , o que força $w_k = w_0 c^k$.

O desconto geométrico não é apenas *suficiente* para haver recursão estacionária: é a *única* ponderação que a produz. Com γ^k o problema é auto-similar; com qualquer outro perfil de pesos, não existe equação de Bellman.

Passo 2 • linearidade da esperança

Passe a esperança para dentro. Condicionando a $s_t = s$ e usando $G_t = r_t + \gamma G_{t+1}$:

$$V(s) = \mathbb{E}[r_t | s_t = s] + \gamma \mathbb{E}[G_{t+1} | s_t = s] = R(s) + \gamma \mathbb{E}[G_{t+1} | s_t = s],$$

onde o primeiro termo é exatamente a definição de $R(s)$ no MRP.

Passo 3 • lei da esperança total

Abra o futuro pelo próximo estado. O termo difícil é $\mathbb{E}[G_{t+1} \mid s_t = s]$ — uma esperança sobre todo o futuro, condicionada ao presente. Particione pelos valores possíveis de s_{t+1} :

$$\mathbb{E}[G_{t+1} \mid s_t = s] = \sum_{s' \in \mathcal{S}} P(s' \mid s) \mathbb{E}[G_{t+1} \mid s_t = s, s_{t+1} = s'].$$

Esta identidade é sempre verdadeira, para qualquer processo estocástico. Ela não usa Markov nem homogeneidade — apenas reorganiza a esperança.

Passo 4 • propriedade de Markov

Esqueça de onde você veio. G_{t+1} é função apenas de $r_{t+1}, r_{t+2}, \dots$, que por sua vez dependem de $s_{t+1}, s_{t+2}, \dots$. A propriedade de Markov diz que, *dado* s_{t+1} , essa trajetória futura é independente de s_t e de toda a história anterior. Logo o condicionamento em $s_t = s$ é redundante e pode ser descartado:

$$\mathbb{E}[G_{t+1} \mid s_t = s, s_{t+1} = s'] = \mathbb{E}[G_{t+1} \mid s_{t+1} = s'].$$

Passo 5 • homogeneidade temporal + horizonte infinito

Reconheça o mesmo objeto. Como P e R não dependem de t , e como de $t + 1$ em diante ainda resta um futuro infinito — exatamente como restava em t — a esperança acima é a *mesma função* V aplicada em s' :

$$\mathbb{E}[G_{t+1} \mid s_{t+1} = s'] = V(s').$$

Encadeando os cinco passos:

Resultado

$$V(s) = \underbrace{R(s)}_{\text{recompensa imediata}} + \gamma \sum_{s' \in \mathcal{S}} P(s' \mid s) V(s') \quad \text{para todo } s \in \mathcal{S}.$$

Em forma vetorial, com $V, R \in \mathbb{R}^N$ e P a matriz $N \times N$ de transições: $V = R + \gamma PV$.

3 Onde cada hipótese entrou

Passo	Ferramenta	Hipótese consumida
1	álgebra elementar	desconto <i>geométrico</i>
2	linearidade da esperança	$\gamma < 1$ e recompensa limitada
3	lei da esperança total	<i>nenhuma</i> — sempre válida
4	—	propriedade de <i>Markov</i>
5	—	homogeneidade temporal + horizonte infinito

Leitura

Repare que Markov aparece **uma única vez**, e não onde a intuição sugere. Ele não é o que permite a recursão — quem faz isso é o desconto geométrico, no Passo 1. Markov é o que permite que a recursão seja escrita em termos de *estados* em vez de *histórias*. Sem ele a equação ainda existiria, na forma $V(h_t) = R(h_t) + \gamma \sum_{h'} P(h' \mid h_t) V(h')$, mas com um domínio que cresce exponencialmente com t — inútil na prática.

4 O que quebra quando cada hipótese cai

Desconto não geométrico. Sem $w_k = \gamma^k$, a cauda não é proporcional a G_{t+1} e o Passo 1 falha. Não há recursão estacionária, logo não há ponto fixo a resolver.

Estado não é de Markov. O Passo 4 falha e sobra $\mathbb{E}[G_{t+1} \mid s_t, s_{t+1}]$, que ainda depende de onde o processo veio. A função valor passa a ser indexada por histórias. É precisamente por isso que a escolha da representação de estado é uma decisão de modelagem tão crítica.

Horizonte finito. O Passo 5 falha: com n passos restantes o futuro não é “igual” ao presente. Escrevendo $V^{(n)}(s)$ para o valor com n passos pela frente, o que se obtém não é uma equação de ponto fixo, mas uma *recursão entre objetos diferentes*:

$$V^{(0)}(s) = 0, \quad V^{(n)}(s) = R(s) + \gamma \sum_{s'} P(s' | s) V^{(n-1)}(s').$$

Leitura

Esta é, letra por letra, a iteração de programação dinâmica vista em aula. A leitura vale ouro: V_k **da iteração não é “uma aproximação de V ” no sentido vago — é o valor exato do problema com horizonte k .** Convergir para V significa que o problema de horizonte k se aproxima do de horizonte infinito, e γ^k mede exatamente o quanto ainda falta.

$\gamma = 1$ **com horizonte infinito.** Duas falhas simultâneas, que são a mesma vista de dois ângulos. Do lado probabilístico, o Passo 2 perde a convergência absoluta: G_t pode nem estar definido. Do lado algébrico, $P1 = 1$ (as linhas somam 1), isto é, 1 é autovalor de P ; então $(I - P)1 = 0$ e a matriz $(I - \gamma P)$ é singular. A equação deixa de ter solução única.

5 Duas objeções que costumam aparecer

“ V aparece dos dois lados — isso não é circular?”

Não, porque a equação de Bellman *não é a definição* de V . A definição é $V(s) = \mathbb{E}[G_t | s_t = s]$, que não menciona V à direita. Bellman é uma *propriedade* que essa função demonstravelmente satisfaz — foi o que os cinco passos estabeleceram. A circularidade aparente é uma restrição sobre um objeto já definido, não uma tentativa de defini-lo.

Resta saber se a restrição determina V sozinha. Determina: para $\gamma < 1$, $(I - \gamma P)$ é invertível, então $V = (I - \gamma P)^{-1}R$ é a única solução.

“Como sei que a solução do sistema é a função valor, e não outra coisa?”

Porque as duas coincidem explicitamente. Como $\|\gamma P\|_\infty = \gamma < 1$, vale a série de Neumann:

$$(I - \gamma P)^{-1} = \sum_{k=0}^{\infty} \gamma^k P^k \quad \implies \quad V = \sum_{k=0}^{\infty} \gamma^k P^k R.$$

E $(P^k R)(s) = \mathbb{E}[r_{t+k} | s_t = s]$, pois P^k é a matriz de transição em k passos. Portanto

$$V(s) = \sum_{k=0}^{\infty} \gamma^k \mathbb{E}[r_{t+k} | s_t = s] = \mathbb{E}\left[\sum_{k=0}^{\infty} \gamma^k r_{t+k} \mid s_t = s\right] = \mathbb{E}[G_t | s_t = s],$$

que é a definição de onde partimos. O círculo se fecha: a solução do sistema linear é a soma descontada esperada, e não apenas algum ponto fixo conveniente.