

Aula 2: Tomando sequências de boas decisões dado um modelo do mundo

Processos de decisão de Markov • Avaliação • Iteração de política e de valor

Prof. Marcelo Keese Albertini
Universidade Federal de Uberlândia
adaptado de Emma Brunskill, CS234 (Stanford)
2026



Onde estamos no curso

AULA ANTERIOR

- ▶ Introdução à aprendizagem por reforço
- ▶ Componentes de um agente: **modelo**, **valor**, **política**
- ▶ Processos de Markov

HOJE

- ▶ Decidir bem com modelo conhecido
- ▶ Avaliação e controle em MDPs
- ▶ Iteração de política e de valor

PRÓXIMA AULA

- ▶ Avaliação de política *sem* modelo
- ▶ Monte Carlo e diferenças temporais

Intuição

Único momento do curso em que *tudo* é conhecido: de aprendizagem a **planejamento** — o alicerce teórico de todo o resto.

Do processo de Markov ao MDP

Avaliação de política (predição)

Controle: iteração de política

Controle: iteração de valor

Horizonte finito e síntese

Definição — os dois problemas

Dado o modelo $(\mathcal{S}, \mathcal{A}, P, R, \gamma)$:

1. **Predição** — qual o valor de uma política dada?
2. **Controle** — qual a melhor política possível?

Duas perguntas para começar

Teste sua compreensão

Em um processo de decisão de Markov, um fator de desconto γ **grande** significa que recompensas de *curto* prazo são muito mais influentes do que as de longo prazo.

Duas perguntas para começar

Teste sua compreensão

Em um processo de decisão de Markov, um fator de desconto γ **grande** significa que recompensas de *curto* prazo são muito mais influentes do que as de longo prazo.

Resposta

Falso. γ grande dá *mais* peso a recompensas distantes; $\gamma = 0$: míope; $\gamma \rightarrow 1$: épocas quase iguais.

Intuição

Fio condutor: dá para a política melhorar **monotonicamente** a cada iteração? Todos os algoritmos têm essa propriedade?

SEÇÃO 1

Do processo de Markov ao MDP

01

Resumo: a hierarquia de modelos

Definição — propriedade de Markov

O futuro é independente do passado dado o presente:

$$\mathbb{P}(s_{t+1} \mid s_t, a_t, s_{t-1}, \dots) = \mathbb{P}(s_{t+1} \mid s_t, a_t).$$

O estado é uma *estatística suficiente* da história.

Atenção

Markov é da **representação de estado** escolhida, não do mundo.

- ▶ **Processo de Markov** $(\mathcal{S}, P)$
só aleatoriedade
- ▶ **Processo de recompensa de Markov** $(\mathcal{S}, P, R, \gamma)$
+ **recompensa**: já dá para *avaliar*
- ▶ **Processo de decisão de Markov** $(\mathcal{S}, \mathcal{A}, P, R, \gamma)$
+ **ação**: agora há o que *decidir*

Intuição

Cada nível acrescenta um ingrediente; reaproveita os algoritmos do anterior.

Horizonte, retorno e função valor

Definição — horizonte H

Número de passos por episódio. Pode ser infinito; caso contrário, o processo é de *horizonte finito*.

Definição — retorno G_t

$$G_t = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \cdots + \gamma^{H-1} r_{t+H-1}$$

Definição — função valor $V(s)$

$$V(s) = \mathbb{E}[G_t \mid s_t = s]$$

Intuição

G_t **aleatória** a cada trajetória; $V(s)$ **número** — a esperança elimina o acaso. RL: estimar V por amostras de G_t .

Atenção

Mesmo $V(s)$, distribuições de G_t distintas: a média ignora o risco.

Por que descontar o futuro?

1. **Matemática:** com $|r| \leq R_{\max}$ e $\gamma < 1$, a série converge; $|G_t| \leq R_{\max}/(1 - \gamma)$.
2. **Modelagem:** γ é a probabilidade de o episódio *continuar*.
3. **Economia:** recompensa hoje vale mais do que amanhã.
4. **Algorítmica:** é $\gamma < 1$ que torna o operador de Bellman uma **contração** — fonte de todas as garantias de hoje.

Intuição

Horizonte efetivo $\approx \frac{1}{1 - \gamma}$ passos.

$$\gamma = 0,9 \Rightarrow \sim 10$$

$$\gamma = 0,99 \Rightarrow \sim 100$$

Atenção

$\gamma = 1$ só seguro com horizonte finito, ou estado terminal atingido com probabilidade 1.

Equação de Bellman para um MRP

A propriedade de Markov permite recursão

$$V(s) = \underbrace{R(s)}_{\text{recompensa imediata}} + \underbrace{\gamma \sum_{s' \in \mathcal{S}} P(s' | s) V(s')}_{\text{soma descontada do futuro}}$$

Intuição

Valor infinito em *um* passo de antecipação: agora + valor de onde posso parar.

Atenção

Sistema de $N = |\mathcal{S}|$ equações acopladas, não fórmula fechada.

Forma matricial e solução analítica

Empilhando os N estados: $V, R \in \mathbb{R}^N$ e $P \in \mathbb{R}^{N \times N}$.

$$\begin{bmatrix} V(s_1) \\ \vdots \\ V(s_N) \end{bmatrix} = \begin{bmatrix} R(s_1) \\ \vdots \\ R(s_N) \end{bmatrix} + \gamma \begin{bmatrix} P(s_1 | s_1) & \cdots & P(s_N | s_1) \\ \vdots & \ddots & \vdots \\ P(s_1 | s_N) & \cdots & P(s_N | s_N) \end{bmatrix} \begin{bmatrix} V(s_1) \\ \vdots \\ V(s_N) \end{bmatrix}$$

$$V = R + \gamma P V$$

$$(I - \gamma P) V = R$$

$$V = (I - \gamma P)^{-1} R$$

a inversa sempre existe se $\gamma < 1$

$\|\gamma P\|_\infty = \gamma < 1 \rightarrow$ a série de Neumann converge: $(I - \gamma P)^{-1} = \sum_{k \geq 0} (\gamma P)^k$. Termo k : recompensas k passos à frente.

Custo: $\Theta(N^3)$ — viável só para N moderado.

Algoritmo iterativo para o valor de um MRP

Algoritmo — avaliação iterativa (programação dinâmica)

- ▶ Inicialize $V_0(s) = 0$ para todo s
- ▶ Para $k = 1, 2, \dots$ até convergir, e para todo $s \in \mathcal{S}$:

$$V_k(s) \leftarrow R(s) + \gamma \sum_{s' \in \mathcal{S}} P(s' | s) V_{k-1}(s')$$

- ▶ Parada: $\|V_k - V_{k-1}\|_\infty \leq \varepsilon$ Custo por iteração: $O(|\mathcal{S}|^2)$

Intuição

$V_k(s)$: valor *exato* de s com exatamente k passos restantes.

Atenção

Analítico $\Theta(N^3)$ uma vez vs. iterativo $O(N^2)$ /iteração: para N grande vence o iterativo — o que sobrevive ao caso sem modelo.

Processo de decisão de Markov (MDP)

MDP = processo de recompensa de Markov + ações

Definição


Um MDP é a tupla $(\mathcal{S}, \mathcal{A}, P, R, \gamma)$:

- ▶ $\mathcal{S}$: conjunto finito de estados de Markov; $\mathcal{A}$: conjunto finito de ações;
- ▶ P : modelo de transição, um por ação — $P(s_{t+1} = s' \mid s_t = s, a_t = a)$;
- ▶ R : recompensa — $R(s_t = s, a_t = a) = \mathbb{E}[r_t \mid s_t = s, a_t = a]$;
- ▶ $\gamma \in [0, 1]$: fator de desconto.

Atenção

Literatura: $R(s)$, $R(s, a)$ ou $R(s, a, s')$; usaremos $R(s, a)$.

Exemplo: o MDP do Mars Rover



$$P(s' | s, a_1) = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 \end{bmatrix}$$

$$P(s' | s, a_2) = \begin{bmatrix} 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}$$

- ▶ 7 estados: posição do rover.
- ▶ 2 ações **determinísticas**.
- ▶ Bordas: ação que sairia do mapa mantém o rover parado.
- ▶ Recompensa: $+1$ em s_1 , $+10$ em s_7 , 0 nos demais.

Definição

Uma política específica que ação tomar em cada estado. Na forma geral, é uma distribuição condicional: $\pi(a | s) = \mathbb{P}(a_t = a | s_t = s)$.

- ▶ **Determinística:** $\pi(s) = a$ — massa concentrada em uma ação.
- ▶ **Estocástica:** massa distribuída entre ações.
- ▶ **Estacionária:** não depende de t .

Intuição

Estocástica: permite exploração, diferenciável nos parâmetros (gradiente de política), única ótima em jogos e MDPs parcialmente observáveis.

Atenção

Política *não* é plano: plano é sequência fixa de ações; política é **função reativa** do estado — robusta à estocasticidade.

MDP + política = MRP

Fixar política elimina a decisão: sobram aleatoriedade e recompensa.

$$R^\pi(s) = \sum_{a \in \mathcal{A}} \pi(a \mid s) R(s, a), \quad P^\pi(s' \mid s) = \sum_{a \in \mathcal{A}} \pi(a \mid s) P(s' \mid s, a).$$

Intuição

Observação mais rentável da aula: **tudo** que sabemos calcular para MRPs se aplica de imediato à *avaliação* de uma política — *predição* não exige teoria nova.

Atenção

O que não vem de graça é o **controle** (escolher π): entra o operador $\max$, e com ele a não linearidade.

SEÇÃO 2

Avaliação de política (predição)

02

Avaliação iterativa de política em um MDP

Algoritmo – avaliação de política

- ▶ Inicialize $V_0^\pi(s) = 0$ para todo s
- ▶ Para $k = 1, 2, \dots$ até convergir, e para todo $s \in \mathcal{S}$:

$$V_k^\pi(s) \leftarrow \sum_{a \in \mathcal{A}} \pi(a | s) \left[R(s, a) + \gamma \sum_{s' \in \mathcal{S}} P(s' | s, a) V_{k-1}^\pi(s') \right]$$


Backup de Bellman para uma política específica. π determinística $\rightarrow$ a soma externa desaparece:

$$V_k^\pi(s) \leftarrow R(s, \pi(s)) + \gamma \sum_{s' \in \mathcal{S}} P(s' | s, \pi(s)) V_{k-1}^\pi(s')$$

Atenção

Sem $\max$: a política já foi fixada; operador **linear** em V — permite resolver o sistema de forma fechada.

Exercício — uma iteração de avaliação



Exercício — Mars Rover

Agora a_1 **estocástica**: $p(s_6 \mid s_6, a_1) = 0,5$ e $p(s_7 \mid s_6, a_1) = 0,5$ (e assim por diante).

Recompensa: para toda ação, +1 em s_1 , +10 em s_7 , 0 nos demais. $\pi(s) = a_1$ para todo s , com $V_k = [1 \ 0 \ 0 \ 0 \ 0 \ 0 \ 10]$, $k = 1$ e $\gamma = 0,5$.

Calcule $V_{k+1}(s_6)$.

Exercício — resolução

Backup para política determinística, em um único estado:

$$V_{k+1}(s_6) = R(s_6, \pi(s_6)) + \gamma \sum_{s' \in \mathcal{S}} p(s' \mid s_6, a_1) V_k(s')$$


Dois termos não nulos: $p(\cdot \mid s_6, a_1)$ tem massa apenas em s_6 e s_7 :

$$\begin{aligned} V_{k+1}(s_6) &= \underbrace{0}_{R(s_6, a_1)} + \underbrace{0,5}_{\gamma} \cdot \left(0,5 \cdot \underbrace{0}_{V_k(s_6)} + 0,5 \cdot \underbrace{10}_{V_k(s_7)} \right) \\ &= 2,5 \end{aligned}$$

Intuição

Valor *difunde* para trás: cada rodada propaga um passo — iterações dependem do diâmetro do MDP.

Teste sua compreensão — o espaço de políticas



Teste sua compreensão

Em breve não bastará avaliar *uma* política: queremos encontrar a *melhor*. Vale a pena, então, entender o espaço de busca.

1. No *Mars Rover* — 7 estados discretos, 2 ações — quantas políticas **determinísticas** existem?
2. A política ótima de um MDP (a de maior valor) é **única**?

Teste sua compreensão — respostas

Resposta

1. $2^7 = 128$. Em geral, $|\mathcal{A}|^{|\mathcal{S}|}$ políticas determinísticas: escolha independente de ação para cada estado.
2. **Não**. Pode haver duas (ou infinitas) políticas com a *mesma* função valor máxima — basta dois valores Q empatarem no máximo. Única é a **função valor ótima** V^* , não o argumento que a atinge.

Intuição

V^* única, π^* não — reaparece o curso inteiro.

Três formas de avaliar uma política

Método	Custo	Exige Markov?	Exige modelo?
Analítico $(I - \gamma P^\pi)^{-1} R^\pi$	$\Theta(N^3)$, uma vez	sim	sim
Iterativo (DP)	$O(N^2)$ por varredura	sim	sim
Simulação (Monte Carlo)	$O(\text{episódios} \times H)$	não	não (só amostras)

Intuição

Simulação: média de muitos episódios — sem Markov, sem P nem R ; Hoeffding limita a rapidez com que a média se aproxima da esperança.

SEÇÃO 3

Controle: interação de política

03

O problema de controle

Horizonte infinito, $\gamma < 1$: a política ótima é

- ▶ **determinística** — aleatorizar não ajuda;
- ▶ **estacionária** — não depende de t ;
- ▶ **não necessariamente única** — pode haver empates.

$$\pi^*(s) = \arg \max_{\pi} V^{\pi}(s)$$

Já a **função valor ótima** V^* é única.

Intuição

Por que estacionária? Horizonte infinito: “o que resta do problema” é o mesmo em $t = 3$ e $t = 3000$ — em finito falha.

Buscar por enumeração é inviável

Enumerar todas as políticas determinísticas e avaliar cada uma?

- ▶ Número de políticas: $|\mathcal{A}|^{|\mathcal{S}|}$.
- ▶ Custo de avaliar cada uma: $\Theta(N^3)$ ou várias varreduras $O(N^2)$.

A **iteração de política** usa o valor da política atual para construir uma política melhor — sem testar candidatas às cegas.

$ \mathcal{S} $	$ \mathcal{A} $	políticas
7	2	128
20	4	$\approx 10^{12}$
100	4	$\approx 10^{60}$

Atenção

10^{60} excede os átomos da Via Láctea: enumeração não é “lenta” — é impossível.

Nova definição: valor de estado-ação Q

Definição — valor de estado-ação de uma política


$$Q^\pi(s, a) = R(s, a) + \gamma \sum_{s' \in \mathcal{S}} P(s' | s, a) V^\pi(s')$$

“Tome a ação a **agora** e siga π **daí em diante**.”

$$V^\pi(s) = \sum_{a \in \mathcal{A}} \pi(a | s) Q^\pi(s, a)$$

Intuição

V : “quão bom é este estado?”; Q : “quão boa é esta ação aqui?” — a pergunta necessária para *agir*.



Backup: um passo de antecipação a partir de s .

Passo de melhoria de política

Algoritmo — melhoria de política (*policy improvement*)

- ▶ Calcule o valor de estado-ação da política atual π_i : para todo $s \in \mathcal{S}$, $a \in \mathcal{A}$,

$$Q^{\pi_i}(s, a) = R(s, a) + \gamma \sum_{s' \in \mathcal{S}} P(s' | s, a) V^{\pi_i}(s')$$

- ▶ Construa a nova política, gulosa em relação a Q^{π_i} :

$$\pi_{i+1}(s) = \arg \max_a Q^{\pi_i}(s, a) \quad \forall s \in \mathcal{S}$$

Intuição

Nada garante *a priori*: π_{i+1} foi construída com V^{π_i} , o valor da política **antiga**; provar é o teorema da melhoria de política.

Algoritmo: iteração de política (PI)

Algoritmo — Iteração de Política

- ▶ $i \leftarrow 0$; inicialize π_0 aleatoriamente
- ▶ Enquanto $i = 0$ ou $\|\pi_i - \pi_{i-1}\|_1 > 0$:
 - $V^{\pi_i} \leftarrow$ avaliação de π_i
 - $\pi_{i+1} \leftarrow$ melhoria sobre V^{π_i}
 - $i \leftarrow i + 1$

A norma L_1 só verifica se a política mudou em *algum* estado.

Intuição

Alternar avaliação e melhoria: a **iteração de política generalizada**, esqueleto de quase todo algoritmo do curso.



Os dois processos se perseguem até o ponto fixo (V^*, π^*) .

Por que a melhoria funciona: a intuição

Para qualquer s , a melhor ação é ao menos tão boa quanto seguir a política antiga:

$$\max_a Q^{\pi_i}(s, a) \geq Q^{\pi_i}(s, \pi_i(s)) = R(s, \pi_i(s)) + \gamma \sum_{s'} P(s' | s, \pi_i(s)) V^{\pi_i}(s') = V^{\pi_i}(s)$$

- ▶ $\pi_{i+1}(s)$ **por um passo**, depois π_i para sempre: soma esperada ao menos tão boa.
- ▶ **Mas** a proposta é seguir π_{i+1} *sempre*, não só por um passo.

Atenção

Um passo não fecha a prova: repetir — telescópio de desigualdades — até $V^{\pi_{i+1}} \geq V^{\pi_i}$.

Melhoria monotônica de política

Definição — ordem parcial entre políticas

$V^{\pi_1} \geq V^{\pi_2}$ significa $V^{\pi_1}(s) \geq V^{\pi_2}(s)$ para **todo** $s \in \mathcal{S}$.

Proposição — melhoria monotônica

π_{i+1} = passo de melhoria sobre $\pi_i \rightarrow V^{\pi_{i+1}} \geq V^{\pi_i}$, desigualdade **estrita** em ao menos um estado se π_i for subótima.

Intuição

Resposta à pergunta da abertura: PI melhora *monotonicamente* a cada rodada; nem todo algoritmo garante isso — iteração de valor não tem para as políticas intermediárias.

Prova: melhoria monotônica

$$\begin{aligned} V^{\pi_i}(s) &\leq \max_a Q^{\pi_i}(s, a) = \max_a \left[R(s, a) + \gamma \sum_{s'} P(s' | s, a) V^{\pi_i}(s') \right] && \text{(i) o máximo domina} \\ &= R(s, \pi_{i+1}(s)) + \gamma \sum_{s'} P(s' | s, \pi_{i+1}(s)) V^{\pi_i}(s') && \text{(ii) definição de } \pi_{i+1} \\ &\leq R(s, \pi_{i+1}(s)) + \gamma \sum_{s'} P(s' | s, \pi_{i+1}(s)) \left[\max_{a'} Q^{\pi_i}(s', a') \right] && \text{(iii) aplica (i) em } s' \\ &= R(s, \pi_{i+1}(s)) + \gamma \sum_{s'} P(s' | s, \pi_{i+1}(s)) \left[R(s', \pi_{i+1}(s')) + \gamma \sum_{s''} P(s'' | s', \pi_{i+1}(s')) V^{\pi_i}(s'') \right] && \text{(iv) aplica (ii) em } s' \\ &\vdots && \text{repetir indefinidamente} \\ &= V^{\pi_{i+1}}(s) \end{aligned}$$

Atenção

A cada linha, mais um passo sob π_{i+1} e a cauda sob π_i ; no limite tudo é π_{i+1} — o resíduo some porque $\gamma^k \rightarrow 0$.

Teste sua compreensão — iteração de política

Algoritmo — Iteração de Política (espaços finitos)

- ▶ $i \leftarrow 0$; inicialize π_0 aleatoriamente
- ▶ Enquanto $i = 0$ ou $\|\pi_i - \pi_{i-1}\|_1 > 0$: avaliar π_i , melhorar para π_{i+1} , $i \leftarrow i + 1$

Teste sua compreensão

1. Se a política **não muda** em uma rodada, ela pode voltar a mudar depois?
2. Existe um **número máximo** de iterações de iteração de política?

Teste sua compreensão — respostas

Resposta

1. Não. Se $\pi_{i+1}(s) = \pi_i(s)$ para todo s , então $Q^{\pi_{i+1}} = Q^{\pi_i}$ (mesma política, mesmo valor). Logo

$$\pi_{i+2}(s) = \arg \max_a Q^{\pi_{i+1}}(s, a) = \arg \max_a Q^{\pi_i}(s, a) = \pi_{i+1}(s).$$

Ponto fixo atingido — e é ótimo.

Resposta

2. Sim: $|\mathcal{A}|^{|\mathcal{S}|}$. Pela monotonia, cada política só aparece em *uma* rodada (a menos que já seja ótima).

Intuição

Prática: poucas dezenas de iterações; Ye (2011): para γ fixo, PI é **fortemente polinomial**.

SEÇÃO 4

Controle: iteração de valor

04

Uma segunda estratégia de controle

ITERAÇÃO DE POLÍTICA

Mantém uma **política**; calcula seu valor de horizonte *infinito*; usa-o para propor uma política melhor.

Intuição

Eixos ortogonais: PI exata no *valor*, aproxima a *política*; VI exata na *otimalidade local*, aproxima o *horizonte*; ambas $\rightarrow (V^*, \pi^*)$.

Atenção

Em VI, os V_k intermediários em geral **não** são valor de política executável — valores ótimos de um problema truncado.

ITERAÇÃO DE VALOR

Mantém o **valor ótimo** de começar em cada estado com k passos de episódio restantes — itera com episódios cada vez mais longos.

Equação de Bellman e operador de backup

Definição — equação de Bellman (para uma política)

O valor de uma política deve satisfazer $V^\pi(s) = R^\pi(s) + \gamma \sum_{s' \in \mathcal{S}} P^\pi(s' | s) V^\pi(s')$.

Definição — operador de backup de Bellman $\mathcal{B}$

Devolve uma nova função valor sobre *todos* os estados, melhorando o valor quando há melhora possível:

$$\mathcal{B}V(s) = \max_a \left[R(s, a) + \gamma \sum_{s' \in \mathcal{S}} P(s' | s, a) V(s') \right]$$

Intuição

Soma ponderada por $\pi \rightarrow \max$ sobre ações: distingue predição de controle — e destrói a linearidade (sem solução por inversão de matriz).

Algoritmo: iteração de valor (VI)

Algoritmo — Iteração de Valor

- ▶ $k \leftarrow 1$; inicialize $V_0(s) = 0$ para todo s
- ▶ Repita até convergir (por ex., $\|V_{k+1} - V_k\|_\infty \leq \epsilon$): para cada $s \in \mathcal{S}$,

$$V_{k+1}(s) = \max_a \left[R(s, a) + \gamma \sum_{s' \in \mathcal{S}} P(s' | s, a) V_k(s') \right] \quad \text{ou seja,} \quad V_{k+1} = \mathcal{B}V_k$$

Ao final, extraia a política **gulosa** em relação ao último valor:

$$\pi(s) = \arg \max_a \left[R(s, a) + \gamma \sum_{s'} P(s' | s, a) V_{k+1}(s') \right]$$

Intuição

V_k : valor ótimo com k passos restantes; a gulosa extraída: ótima por $k + 1$ passos.

Iteração de política na linguagem de operadores

O operador de backup **para uma política fixa** π é

$$\mathcal{B}^\pi V(s) = R^\pi(s) + \gamma \sum_{s' \in \mathcal{S}} P^\pi(s' | s) V(s')$$

Avaliação de política = **ponto fixo** de $\mathcal{B}^\pi$:
aplicar até V parar de mudar,

$$V^\pi = \mathcal{B}^\pi \mathcal{B}^\pi \dots \mathcal{B}^\pi V.$$

Melhoria de política = um backup com
 $\max$, seguido de $\arg \max$:

$$\pi_{k+1}(s) = \arg \max_a \left[R(s, a) + \gamma \sum_{s'} P(s' | s, a) V^{\pi_k}(s') \right]$$

Intuição

VI itera $\mathcal{B}$ (com $\max$) desde o início; PI itera $\mathcal{B}^\pi$ (linear) até o ponto fixo e usa o $\max$ uma vez — lente para variantes híbridas.

Operador de contração

Definição — operador de contração

Seja O um operador e $\|\cdot\|$ uma norma. Se $\|OV - OV'\| \leq \|V - V'\|$ para todos V, V' , então O é um operador de *contração* (estrita, se vale com fator $\gamma < 1$).

Intuição

Mapa que **aproxima os pontos**: aplicado repetidamente, tudo colapsa em um único ponto fixo, não importa a partida.

VI converge?

Sim, se $\gamma < 1$ — ou se um estado terminal é atingido com probabilidade 1. Bellman é contração para $\gamma < 1$: a distância entre duas funções valor **encolhe** por um fator γ .

Prova: o backup de Bellman é uma contração ($\gamma < 1$)

Norma do supremo: $\|V - V'\|_\infty = \max_s |V(s) - V'(s)|$. Para cada s :

$$\begin{aligned} |\mathcal{B}V_k(s) - \mathcal{B}V_j(s)| &= \left| \max_a \left[R(s, a) + \gamma \sum_{s'} P(s' | s, a) V_k(s') \right] - \max_{a'} \left[R(s, a') + \gamma \sum_{s'} P(s' | s, a') V_j(s') \right] \right| \\ &\leq \max_a \left| R(s, a) + \gamma \sum_{s'} P(s' | s, a) V_k(s') - R(s, a) - \gamma \sum_{s'} P(s' | s, a) V_j(s') \right| && |\max f - \max g| \leq \max |f - g| \\ &= \max_a \left| \gamma \sum_{s'} P(s' | s, a) (V_k(s') - V_j(s')) \right| \leq \max_a \gamma \sum_{s'} P(s' | s, a) \|V_k - V_j\|_\infty && \text{cota termo a termo} \\ &= \gamma \|V_k - V_j\|_\infty \sum_{s'} P(s' | s, a) = \gamma \|V_k - V_j\|_\infty && \text{probabilidades somam 1} \end{aligned}$$

Tomando o máximo sobre s : $\|\mathcal{B}V_k - \mathcal{B}V_j\|_\infty \leq \gamma \|V_k - V_j\|_\infty$. □

Atenção

Mesmo com todas as desigualdades = igualdades, ainda é contração se $\gamma < 1$; a recompensa R **cancela**.

Da contração à convergência

ponto fixo de Banach aplicado a VI

Se $\gamma < 1$, então: (i) $\mathcal{B}$ tem um **único** ponto fixo, que é V^* ; (ii) VI converge a partir de **qualquer** inicialização V_0 ; e (iii) a convergência é geométrica: $\|V_k - V^*\|_\infty \leq \gamma^k \|V_0 - V^*\|_\infty$.

Consequências práticas:

- ▶ Inicialização não afeta o destino — só o tempo de viagem (uma boa inicialização *acelera*).
- ▶ γ perto de 1: convergência lenta — iterações crescem como $\frac{1}{1-\gamma}$.

Intuição

Parou com $\|V_{k+1} - V_k\|_\infty \leq \epsilon$? Então $\|V_{k+1} - V^*\|_\infty \leq \frac{\gamma \epsilon}{1-\gamma}$; a gulosa extraída perde no máximo $\frac{2\gamma \epsilon}{1-\gamma}$ em valor.

Prática recomendada (fora de aula)

Exercício — para consolidar

1. Prove que a iteração de valor converge para solução *única* em espaços discretos de estados e ações com $\gamma < 1$.
2. A inicialização dos valores em VI afeta alguma coisa? O quê — e o que ela *não* afeta?
3. A política extraída de VI a cada rodada é garantidamente **monotônica** (no problema real de horizonte infinito), como em PI?

Intuição

A terceira pergunta é a mais sutil: V_k converge *monotonicamente* em norma, mas as políticas gulosas extraídas podem oscilar em qualidade — contraste com PI.

SEÇÃO 5

Horizonte finito e síntese

05

Iteração de valor com horizonte finito H

Horizonte finito: VI deixa de ser aproximação e vira **o algoritmo exato**: V_k e π_k ótimos *quando restam k decisões*.

Algoritmo – VI para horizonte H

- ▶ Inicialize $V_0(s) = 0$ para todo s
- ▶ Para $k = 1, \dots, H$, e para cada s :

$$V_{k+1}(s) = \max_a \left[R(s, a) + \gamma \sum_{s'} P(s' | s, a) V_k(s') \right], \quad \pi_{k+1}(s) = \arg \max_a \left[R(s, a) + \gamma \sum_{s'} P(s' | s, a) V_k(s') \right]$$

Intuição

Guarde *todas* as $\pi_1, \dots, \pi_H$: no instante t , use π_{H-t} — indexada por **quantos passos restam**.

Avaliação por simulação (ponte para a próxima aula)

Alternativa para estimar o valor de uma política em horizonte finito:

- ▶ gere muitos **episódios** seguindo a política;
- ▶ calcule o retorno de cada episódio e tire a **média**;
- ▶ desigualdades de concentração limitam a rapidez com que a média se aproxima da esperança.


Intuição

Sem suposição markoviana — e, mais importante, sem **modelo**: basta poder *interagir*. Portão de entrada do RL.

Atenção

O preço: variância — precisão melhora só com $1/\sqrt{n}$ episódios. DP × Monte Carlo é o tema da Aula 3.

Exemplo: retornos amostrais no *Mars Rover* estocástico



Recompensa +1 em s_1 , +10 em s_7 , 0 nos demais. Episódios de $H = 4$ passos a partir de s_4 , com $\gamma = \frac{1}{2}$:

Episódio	Retorno $G = r_1 + \frac{1}{2}r_2 + \frac{1}{4}r_3 + \frac{1}{8}r_4$	Valor
s_4, s_5, s_6, s_7	$0 + \frac{1}{2} \cdot 0 + \frac{1}{4} \cdot 0 + \frac{1}{8} \cdot 10$	1,25
s_4, s_4, s_5, s_4	$0 + \frac{1}{2} \cdot 0 + \frac{1}{4} \cdot 0 + \frac{1}{8} \cdot 0$	0
s_4, s_3, s_2, s_1	$0 + \frac{1}{2} \cdot 0 + \frac{1}{4} \cdot 0 + \frac{1}{8} \cdot 1$	0,125

Intuição

Três amostras, três respostas — todas legítimas; $V(s_4)$ é a média da distribuição; estimá-lo bem exige muitos episódios.

A política ótima é estacionária em horizonte finito?

Teste sua compreensão

Em tarefas de horizonte **finito**, a política ótima é estacionária (independente do passo de tempo)?

A política ótima é estacionária em horizonte finito?

Teste sua compreensão

Em tarefas de horizonte **finito**, a política ótima é estacionária (independente do passo de tempo)?

Resposta

Em geral, não. A ação ótima depende de **quanto tempo resta**.

Intuição

Mars Rover em s_4 : passos sobrando $\rightarrow$ vale caminhar até o $+10$ em s_7 ; com **um único** passo, nenhuma direção alcança recompensa; dois ou três $\rightarrow +1$ e $+10$ competem. Ótima indexada pelo tempo: $\pi_t^*(s)$.

Iteração de valor *versus* iteração de política

	Iteração de valor	Iteração de política
O que mantém	valor ótimo p/ horizonte k	política + seu valor ∞
Passo	$V_{k+1} = \mathcal{B}V_k$	avaliar $\mathcal{B}^\pi$; melhorar c/ $\max$
Custo por iteração	$O(\mathcal{S} ^2 \mathcal{A})$	avaliação + $O(\mathcal{S} ^2 \mathcal{A})$
Nº de iterações	muitas e baratas	poucas e caras
Monotonia da política	não garantida	garantida
Parente em RL moderno	Q-learning	gradiente de política

Intuição

Iteração de política modificada: aplique $\mathcal{B}^\pi$ m vezes na avaliação; $m = 1 \rightarrow \text{VI}$, $m = \infty \rightarrow \text{PI}$; entre os extremos, quase tudo funciona — e costuma ser mais rápido que ambos.

Vocabulário de RL: modelos, políticas, valores

Definição — modelo

Representação matemática da dinâmica (P) e da recompensa (R).

Definição — política

Função que mapeia estados em ações (ou em distribuições sobre ações).

Definição — função valor

Recompensas futuras esperadas a partir de um estado (e/ou ação), quando se segue uma política específica.

Intuição

Três eixos que organizam *todo* o campo: algoritmos baseados em modelo, em valor ou em política — e as combinações.

O que você deve saber ao final desta aula

- ▶ **Definir:** MP, MRP, MDP, operador de Bellman, contração, modelo, valor Q , política.
- ▶ **Implementar:** iteração de valor e iteração de política.
- ▶ **Comparar:** prós e contras das abordagens de avaliação de política.
- ▶ **Provar:** propriedades de contração e melhoria monotônica.
- ▶ **Criticar:** limitações das abordagens e da hipótese de Markov.
- ▶ **Distinguir:** quais métodos de avaliação exigem a hipótese de Markov — e quais não.

Atenção

Dos três métodos de avaliação (analítico, programação dinâmica, simulação), quais exigem a hipótese de Markov?

PRÓXIMA AULA

Avaliação de política sem modelo

Monte Carlo • diferenças temporais • o primeiro contato com aprendizagem de verdade

Material adaptado de Emma Brunskill, CS234: Reinforcement Learning, Stanford University.