

Aprendizagem por Reforço • UFU

Aula 2: Tomando sequências de boas decisões dado um modelo do mundo

Processos de decisão de Markov • Avaliação • Iteração de política e de valor

Prof. Marcelo Keese Albertini
Universidade Federal de Uberlândia
adaptado de Emma Brunskill, CS234 (Stanford)
2026



Onde estamos no curso

AULA ANTERIOR

- ▶ Introdução à aprendizagem por reforço
- ▶ Componentes de um agente: **modelo**, **valor**, **política**
- ▶ Processos de Markov

HOJE

- ▶ Decidir bem *quando o modelo do mundo é conhecido*
- ▶ Avaliação e controle em MDPs
- ▶ Iteração de política e de valor

PRÓXIMA AULA

- ▶ Avaliação de política *sem* modelo do mundo
- ▶ Monte Carlo e diferenças temporais

Intuição

Hoje é o único momento do curso em que *tudo* é conhecido. O problema deixa de ser de aprendizagem e passa a ser de **planejamento** — e é por isso que ele fornece o alicerce teórico de todo o resto.

Do processo de Markov ao MDP

Avaliação de política (predição)

Controle: iteração de política

Controle: iteração de valor

Horizonte finito e síntese

Definição — os dois problemas

Dado o modelo $(\mathcal{S}, \mathcal{A}, P, R, \gamma)$:

1. **Predição** — qual o valor de uma política dada?
2. **Controle** — qual a melhor política possível?

Duas perguntas para começar

Teste sua compreensão

Em um processo de decisão de Markov, um fator de desconto γ **grande** significa que recompensas de *curto* prazo são muito mais influentes do que as de longo prazo.

Duas perguntas para começar

Teste sua compreensão

Em um processo de decisão de Markov, um fator de desconto γ **grande** significa que recompensas de *curto* prazo são muito mais influentes do que as de longo prazo.

Resposta

Falso. Um γ grande dá *mais* peso a recompensas distantes. No extremo, $\gamma = 0$ produz um agente míope; $\gamma \rightarrow 1$, um agente que trata todas as épocas quase igualmente.

Intuição

Fio condutor da aula. É possível construir algoritmos tais que, a cada iteração de computação, a política melhore **monotonicamente**? Todos os algoritmos têm essa propriedade?

SEÇÃO 1

Do processo de Markov ao MDP

01

Recapitulação: a hierarquia de modelos

Definição — propriedade de Markov

O futuro é independente do passado dado o presente:

$$\mathbb{P}(s_{t+1} \mid s_t, a_t, s_{t-1}, \dots) = \mathbb{P}(s_{t+1} \mid s_t, a_t).$$

O estado é uma *estatística suficiente* da história.

Atenção

Markov não é propriedade do mundo, e sim da **representação de estado** escolhida.

- ▶ **Processo de Markov** $(\mathcal{S}, P)$
só aleatoriedade
- ▶ **Processo de recompensa de Markov** $(\mathcal{S}, P, R, \gamma)$
+ **recompensa**: já dá para *avaliar*
- ▶ **Processo de decisão de Markov** $(\mathcal{S}, \mathcal{A}, P, R, \gamma)$
+ **ação**: agora há o que *decidir*

Intuição

Cada nível acrescenta um ingrediente — e reaproveita os algoritmos do anterior.

Horizonte, retorno e função valor

Definição — horizonte H

Número de passos por episódio. Pode ser infinito; caso contrário, o processo é de *horizonte finito*.

Definição — retorno G_t

$$G_t = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \cdots + \gamma^{H-1} r_{t+H-1}$$

Definição — função valor $V(s)$

$$V(s) = \mathbb{E}[G_t \mid s_t = s]$$

Intuição

G_t é variável **aleatória** — muda a cada trajetória. $V(s)$ é um **número**: a esperança já eliminou o acaso. Boa parte de RL consiste em estimar V a partir de amostras de G_t .

Atenção

Duas políticas com o mesmo $V(s)$ podem ter distribuições de G_t muito diferentes: a média ignora o risco.

Por que descontar o futuro?

1. **Matemática:** com $|r| \leq R_{\max}$ e $\gamma < 1$, a série converge e $|G_t| \leq R_{\max}/(1 - \gamma)$.
2. **Modelagem:** γ é a probabilidade de o episódio *continuar*.
3. **Economia:** recompensa hoje vale mais do que amanhã.
4. **Algorítmica:** é $\gamma < 1$ que torna o operador de Bellman uma **contração** — fonte de todas as garantias de hoje.

Intuição

Horizonte efetivo $\approx \frac{1}{1 - \gamma}$ passos.

$$\gamma = 0,9 \Rightarrow \sim 10$$

$$\gamma = 0,99 \Rightarrow \sim 100$$

Atenção

$\gamma = 1$ só é seguro com horizonte finito, ou se um estado terminal for atingido com probabilidade 1.

Equação de Bellman para um MRP

A propriedade de Markov permite recursão

$$V(s) = \underbrace{R(s)}_{\text{recompensa imediata}} + \underbrace{\gamma \sum_{s' \in \mathcal{S}} P(s' | s) V(s')}_{\text{soma descontada do futuro}}$$

Intuição

Todo o valor de uma trajetória infinita cabe em uma equação com *um* passo de antecipação. O valor de hoje se decompõe no que ganho agora mais o valor de onde posso parar.

Atenção

Isso é um **sistema** de $N = |\mathcal{S}|$ equações acopladas — uma por estado — e não uma fórmula fechada. Resolvê-lo é o assunto dos próximos slides.

Forma matricial e solução analítica

Empilhando os N estados: $V, R \in \mathbb{R}^N$ e $P \in \mathbb{R}^{N \times N}$.

$$\begin{bmatrix} V(s_1) \\ \vdots \\ V(s_N) \end{bmatrix} = \begin{bmatrix} R(s_1) \\ \vdots \\ R(s_N) \end{bmatrix} + \gamma \begin{bmatrix} P(s_1 | s_1) & \cdots & P(s_N | s_1) \\ \vdots & \ddots & \vdots \\ P(s_1 | s_N) & \cdots & P(s_N | s_N) \end{bmatrix} \begin{bmatrix} V(s_1) \\ \vdots \\ V(s_N) \end{bmatrix}$$

$$V = R + \gamma P V$$

$$(I - \gamma P) V = R$$

$$V = (I - \gamma P)^{-1} R$$

a inversa sempre existe se $\gamma < 1$

$\|\gamma P\|_\infty = \gamma < 1$, logo a série de Neumann converge: $(I - \gamma P)^{-1} = \sum_{k \geq 0} (\gamma P)^k$. O termo k é a contribuição das recompensas k passos à frente.

Custo: $\Theta(N^3)$ — viável só para N moderado.

Algoritmo iterativo para o valor de um MRP

Algoritmo — avaliação iterativa (programação dinâmica)

- ▶ Inicialize $V_0(s) = 0$ para todo s
- ▶ Para $k = 1, 2, \dots$ até convergir, e para todo $s \in \mathcal{S}$:

$$V_k(s) \leftarrow R(s) + \gamma \sum_{s' \in \mathcal{S}} P(s' | s) V_{k-1}(s')$$

- ▶ Parada: $\|V_k - V_{k-1}\|_\infty \leq \varepsilon$ Custo por iteração: $O(|\mathcal{S}|^2)$

Intuição

$V_k(s)$ é o valor *exato* de s quando restam exatamente k passos.

Atenção

Analítico $\Theta(N^3)$ uma vez *versus* iterativo $O(N^2)$ por iteração. Para N grande o iterativo vence — e é ele que sobrevive ao caso sem modelo.

Processo de decisão de Markov (MDP)

MDP = processo de recompensa de Markov + ações

Definição


Um MDP é a tupla $(\mathcal{S}, \mathcal{A}, P, R, \gamma)$:

- ▶ $\mathcal{S}$: conjunto finito de estados de Markov; $\mathcal{A}$: conjunto finito de ações;
- ▶ P : modelo de transição, um por ação — $P(s_{t+1} = s' \mid s_t = s, a_t = a)$;
- ▶ R : recompensa — $R(s_t = s, a_t = a) = \mathbb{E}[r_t \mid s_t = s, a_t = a]$;
- ▶ $\gamma \in [0, 1]$: fator de desconto.

Atenção

A recompensa aparece na literatura como $R(s)$, $R(s, a)$ ou $R(s, a, s')$. Usaremos $R(s, a)$.

Exemplo: o MDP do Mars Rover



$$P(s' | s, a_1) = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 \end{bmatrix}$$

$$P(s' | s, a_2) = \begin{bmatrix} 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}$$

- ▶ 7 estados: posição do rover.
- ▶ 2 ações **determinísticas**.
- ▶ Nas bordas, a ação que sairia do mapa mantém o rover parado.
- ▶ Recompensa: $+1$ em s_1 , $+10$ em s_7 , 0 nos demais.

Definição

Uma política específica que ação tomar em cada estado. Na forma geral, é uma distribuição condicional: $\pi(a | s) = \mathbb{P}(a_t = a | s_t = s)$.

- ▶ **Determinística:** $\pi(s) = a$ — massa concentrada em uma ação.
- ▶ **Estocástica:** massa distribuída entre ações.
- ▶ **Estacionária:** não depende de t .

Intuição

A forma estocástica permite exploração, é diferenciável nos parâmetros (gradiente de política) e é a única ótima em jogos e em MDPs parcialmente observáveis.

Atenção

Uma política *não* é um plano. Plano é sequência fixa de ações; política é **função reativa** do estado — e por isso robusta à estocasticidade.

MDP + política = MRP

Fixar uma política elimina a decisão: sobram aleatoriedade e recompensa.

$$R^\pi(s) = \sum_{a \in \mathcal{A}} \pi(a | s) R(s, a), \quad P^\pi(s' | s) = \sum_{a \in \mathcal{A}} \pi(a | s) P(s' | s, a).$$

Intuição

Esta é a observação mais rentável da aula. **Tudo** que sabemos calcular para MRPs — forma matricial, solução $(I - \gamma P^\pi)^{-1} R^\pi$, algoritmo iterativo $O(|\mathcal{S}|^2)$ — se aplica de imediato à *avaliação* de uma política. O problema de predição não exige teoria nova.

Atenção

O que não vem de graça é o **controle**: escolher π . É aí que entra o operador $\max$, e com ele a não linearidade.

SEÇÃO 2

Avaliação de política (predição)

02

Avaliação iterativa de política em um MDP

Algoritmo – avaliação de política

- ▶ Inicialize $V_0^\pi(s) = 0$ para todo s
- ▶ Para $k = 1, 2, \dots$ até convergir, e para todo $s \in \mathcal{S}$:

$$V_k^\pi(s) \leftarrow \sum_{a \in \mathcal{A}} \pi(a | s) \left[R(s, a) + \gamma \sum_{s' \in \mathcal{S}} P(s' | s, a) V_{k-1}^\pi(s') \right]$$


Este é o **backup de Bellman para uma política específica**. Se π for determinística, a soma externa desaparece:

$$V_k^\pi(s) \leftarrow R(s, \pi(s)) + \gamma \sum_{s' \in \mathcal{S}} P(s' | s, \pi(s)) V_{k-1}^\pi(s')$$

Atenção

Não há $\max$ aqui: a política já foi fixada. O operador é **linear** em V — e é isso que permite resolver o sistema de forma fechada.

Exercício — uma iteração de avaliação



Exercício — Mars Rover

Suponha agora que a_1 seja **estocástica**: $p(s_6 \mid s_6, a_1) = 0,5$ e $p(s_7 \mid s_6, a_1) = 0,5$ (e assim por diante).

Recompensa: para toda ação, +1 em s_1 , +10 em s_7 , 0 nos demais. Seja $\pi(s) = a_1$ para todo s , com $V_k = [1 \ 0 \ 0 \ 0 \ 0 \ 0 \ 10]$, $k = 1$ e $\gamma = 0,5$.

Calcule $V_{k+1}(s_6)$.

Exercício — resolução

Aplicamos o backup para política determinística, em um único estado:

$$V_{k+1}(s_6) = R(s_6, \pi(s_6)) + \gamma \sum_{s' \in \mathcal{S}} p(s' \mid s_6, a_1) V_k(s')$$


Somente dois termos são não nulos, pois $p(\cdot \mid s_6, a_1)$ tem massa apenas em s_6 e s_7 :

$$\begin{aligned} V_{k+1}(s_6) &= \underbrace{0}_{R(s_6, a_1)} + \underbrace{0,5}_{\gamma} \cdot \left(0,5 \cdot \underbrace{0}_{V_k(s_6)} + 0,5 \cdot \underbrace{10}_{V_k(s_7)} \right) \\ &= 2,5 \end{aligned}$$

Intuição

Valor *difunde* para trás pelas transições: na próxima varredura, s_5 também deixará de valer zero. Cada rodada propaga informação um passo — por isso o número de iterações depende do diâmetro do MDP.

Teste sua compreensão — o espaço de políticas



Teste sua compreensão

Em breve não bastará avaliar *uma* política: queremos encontrar a *melhor*. Vale a pena, então, entender o espaço de busca.

1. No *Mars Rover* — 7 estados discretos, 2 ações — quantas políticas **determinísticas** existem?
2. A política ótima de um MDP (a de maior valor) é **única**?

Teste sua compreensão — respostas

Resposta

1. $2^7 = 128$. Em geral, há $|\mathcal{A}|^{|\mathcal{S}|}$ políticas determinísticas: uma escolha independente de ação para cada estado.
2. **Não.** Pode haver duas (ou infinitas) políticas com a *mesma* função valor máxima — basta que em algum estado dois valores Q empatem no máximo. O que é único é a **função valor ótima** V^* , não o argumento que a atinge.

Intuição

Distinção que vale guardar: V^* é única, π^* não é. Isso reaparece o curso inteiro — por exemplo, ao comparar duas execuções que convergiram para políticas diferentes com desempenho idêntico.

Três formas de avaliar uma política

Método	Custo	Exige Markov?	Exige modelo?
Analítico $(I - \gamma P^\pi)^{-1} R^\pi$	$\Theta(N^3)$, uma vez	sim	sim
Iterativo (DP)	$O(N^2)$ por varredura	sim	sim
Simulação (Monte Carlo)	$O(\text{episódios} \times H)$	não	não (só amostras)

Intuição

A terceira linha é a ponte para a próxima aula: gere muitos episódios e tire a média dos retornos. Desigualdades de concentração (Hoeffding) limitam a rapidez com que a média se aproxima da esperança. Não é preciso supor estrutura markoviana — e, crucialmente, não é preciso conhecer P nem R .

SEÇÃO 3

Controle: interação de política

03

O problema de controle

Para um MDP de horizonte infinito com $\gamma < 1$, a política ótima é:

- ▶ **determinística** — aleatorizar não ajuda;
- ▶ **estacionária** — não depende de t ;
- ▶ **não necessariamente única** — pode haver empates.

$$\pi^*(s) = \arg \max_{\pi} V^{\pi}(s)$$

Já a **função valor ótima** V^* é única.

Intuição

Por que estacionária? Com horizonte infinito, “o que resta do problema” é o mesmo em $t = 3$ e em $t = 3000$. Em horizonte finito isso falha — voltaremos a esse ponto.

Buscar por enumeração é inviável

Uma opção seria enumerar todas as políticas determinísticas e avaliar cada uma.

- ▶ Número de políticas: $|\mathcal{A}|^{|\mathcal{S}|}$.
- ▶ Custo de avaliar cada uma: $\Theta(N^3)$ ou várias varreduras $O(N^2)$.

A **iteração de política** faz muito melhor: ela usa o valor da política atual para construir diretamente uma política melhor, em vez de testar candidatas às cegas.

$ \mathcal{S} $	$ \mathcal{A} $	políticas
7	2	128
20	4	$\approx 10^{12}$
100	4	$\approx 10^{60}$

Atenção

10^{60} excede em muito o número de átomos da Via Láctea. Enumeração não é “lenta”: é impossível.

Nova definição: valor de estado-ação Q

Definição — valor de estado-ação de uma política


$$Q^\pi(s, a) = R(s, a) + \gamma \sum_{s' \in \mathcal{S}} P(s' | s, a) V^\pi(s')$$

“Tome a ação a **agora** e siga π **daí em diante**.”

$$V^\pi(s) = \sum_{a \in \mathcal{A}} \pi(a | s) Q^\pi(s, a)$$

Intuição

V diz “quão bom é este estado?”; Q diz “quão boa é esta ação aqui?” — que é a pergunta necessária para *agir*. Daí o domínio de Q nos algoritmos sem modelo.



Backup: um passo de antecipação a partir de s .

Passo de melhoria de política

Algoritmo — melhoria de política (*policy improvement*)

- ▶ Calcule o valor de estado-ação da política atual π_i : para todo $s \in \mathcal{S}$, $a \in \mathcal{A}$,

$$Q^{\pi_i}(s, a) = R(s, a) + \gamma \sum_{s' \in \mathcal{S}} P(s' | s, a) V^{\pi_i}(s')$$

- ▶ Construa a nova política, gulosa em relação a Q^{π_i} :

$$\pi_{i+1}(s) = \arg \max_a Q^{\pi_i}(s, a) \quad \forall s \in \mathcal{S}$$

Intuição

Nada garante *a priori* que π_{i+1} seja melhor: ela foi construída com V^{π_i} , o valor da política *antiga*. Provar que a troca compensa é o teorema da melhoria de política.

Algoritmo: iteração de política (PI)

Algoritmo — Iteração de Política

- ▶ $i \leftarrow 0$; inicialize π_0 aleatoriamente
- ▶ Enquanto $i = 0$ ou $\|\pi_i - \pi_{i-1}\|_1 > 0$:
 - $V^{\pi_i} \leftarrow$ *avaliação* de π_i
 - $\pi_{i+1} \leftarrow$ *melhoria* sobre V^{π_i}
 - $i \leftarrow i + 1$

A norma L_1 só verifica se a política mudou em *algum* estado.

Intuição

Alternar avaliação e melhoria é a **iteração de política generalizada**, esqueleto de quase todo algoritmo do curso.



Os dois processos se perseguem até o ponto fixo (V^*, π^*) .

Por que a melhoria funciona: a intuição

Para qualquer estado s , escolher a melhor ação é pelo menos tão bom quanto seguir a política antiga:

$$\max_a Q^{\pi_i}(s, a) \geq Q^{\pi_i}(s, \pi_i(s)) = R(s, \pi_i(s)) + \gamma \sum_{s'} P(s' | s, \pi_i(s)) V^{\pi_i}(s') = V^{\pi_i}(s)$$

- ▶ Suponha que tomemos $\pi_{i+1}(s)$ **por um passo** e depois sigamos π_i para sempre: a soma esperada de recompensas é ao menos tão boa quanto sempre seguir π_i .
- ▶ **Mas** a política proposta é seguir π_{i+1} *sempre*, não só por um passo.

Atenção

O argumento de um passo não fecha a prova. É preciso aplicá-lo repetidamente — um telescópio de desigualdades — para concluir que $V^{\pi_{i+1}} \geq V^{\pi_i}$.

Melhoria monotônica de política

Definição — ordem parcial entre políticas

$V^{\pi_1} \geq V^{\pi_2}$ significa $V^{\pi_1}(s) \geq V^{\pi_2}(s)$ para **todo** $s \in \mathcal{S}$.

Proposição — melhoria monotônica

Seja π_{i+1} a política obtida pelo passo de melhoria aplicado a π_i . Então $V^{\pi_{i+1}} \geq V^{\pi_i}$, com desigualdade **estrita** em ao menos um estado se π_i for subótima.

Intuição

Eis a resposta à pergunta que abriu a aula: PI *de fato* melhora monotonicamente a cada rodada. Nem todo algoritmo tem essa garantia — iteração de valor não a tem para as políticas intermediárias.

Prova: melhoria monotônica

$$\begin{aligned} V^{\pi_i}(s) &\leq \max_a Q^{\pi_i}(s, a) = \max_a \left[R(s, a) + \gamma \sum_{s'} P(s' | s, a) V^{\pi_i}(s') \right] && \text{(i) o máximo domina} \\ &= R(s, \pi_{i+1}(s)) + \gamma \sum_{s'} P(s' | s, \pi_{i+1}(s)) V^{\pi_i}(s') && \text{(ii) definição de } \pi_{i+1} \\ &\leq R(s, \pi_{i+1}(s)) + \gamma \sum_{s'} P(s' | s, \pi_{i+1}(s)) \left[\max_{a'} Q^{\pi_i}(s', a') \right] && \text{(iii) aplica (i) em } s' \\ &= R(s, \pi_{i+1}(s)) + \gamma \sum_{s'} P(s' | s, \pi_{i+1}(s)) \left[R(s', \pi_{i+1}(s')) + \gamma \sum_{s''} P(s'' | s', \pi_{i+1}(s')) V^{\pi_i}(s'') \right] && \text{(iv) aplica (ii) em } s' \\ &\vdots && \text{repetir indefinidamente} \\ &= V^{\pi_{i+1}}(s) \end{aligned}$$

Atenção

A cada linha, mais um passo passa a ser executado sob π_{i+1} e a cauda continua sob π_i . No limite tudo é π_{i+1} , e o resíduo some porque $\gamma^k \rightarrow 0$.

Teste sua compreensão — iteração de política

Algoritmo — Iteração de Política (espaços finitos)

- ▶ $i \leftarrow 0$; inicialize π_0 aleatoriamente
- ▶ Enquanto $i = 0$ ou $\|\pi_i - \pi_{i-1}\|_1 > 0$: avaliar π_i , melhorar para π_{i+1} , $i \leftarrow i + 1$

Teste sua compreensão

1. Se a política **não muda** em uma rodada, ela pode voltar a mudar depois?
2. Existe um **número máximo** de iterações de iteração de política?

Teste sua compreensão — respostas

Resposta

1. Não. Se $\pi_{i+1}(s) = \pi_i(s)$ para todo s , então $Q^{\pi_{i+1}} = Q^{\pi_i}$ (mesma política, mesmo valor). Logo

$$\pi_{i+2}(s) = \arg \max_a Q^{\pi_{i+1}}(s, a) = \arg \max_a Q^{\pi_i}(s, a) = \pi_{i+1}(s).$$

O algoritmo atingiu um ponto fixo, e esse ponto fixo é ótimo.

Resposta

2. Sim: $|\mathcal{A}|^{|\mathcal{S}|}$. Pela monotonia, cada política só aparece em *uma* rodada (a menos que já seja ótima) — e esse é o número de políticas determinísticas.

Intuição

Na prática PI converge em poucas dezenas de iterações; Ye (2011) mostrou que, para γ fixo, PI é **fortemente polinomial**.

SEÇÃO 4

Controle: iteração de valor

04

Uma segunda estratégia de controle

ITERAÇÃO DE POLÍTICA

Mantém uma **política** e calcula seu valor de horizonte *infinito*; usa esse valor para propor uma política melhor.

ITERAÇÃO DE VALOR

Mantém o **valor ótimo** de começar em cada estado supondo que restam k passos de episódio — e itera considerando episódios cada vez mais longos.

Intuição

São dois eixos de aproximação ortogonais: PI é exata no *valor* e aproxima a *política*; VI é exata na *otimalidade local* e aproxima o *horizonte*. Ambas convergem para o mesmo par (V^*, π^*) .

Atenção

Em VI, os valores intermediários V_k em geral **não** correspondem ao valor de nenhuma política executável — são valores ótimos de um problema truncado.

Equação de Bellman e operador de backup

Definição — equação de Bellman (para uma política)

O valor de uma política deve satisfazer $V^\pi(s) = R^\pi(s) + \gamma \sum_{s' \in \mathcal{S}} P^\pi(s' | s) V^\pi(s')$.

Definição — operador de backup de Bellman $\mathcal{B}$

Devolve uma nova função valor sobre *todos* os estados, melhorando o valor quando há melhora possível:

$$\mathcal{B}V(s) = \max_a \left[R(s, a) + \gamma \sum_{s' \in \mathcal{S}} P(s' | s, a) V(s') \right]$$

Intuição

A troca da soma ponderada por π pelo $\max$ sobre ações é o que distingue predição de controle — e o que destrói a linearidade: com $\mathcal{B}$, a solução fechada por inversão de matriz deixa de existir.

Algoritmo: iteração de valor (VI)

Algoritmo – Iteração de Valor

- ▶ $k \leftarrow 1$; inicialize $V_0(s) = 0$ para todo s
- ▶ Repita até convergir (por ex., $\|V_{k+1} - V_k\|_\infty \leq \epsilon$): para cada $s \in \mathcal{S}$,

$$V_{k+1}(s) = \max_a \left[R(s, a) + \gamma \sum_{s' \in \mathcal{S}} P(s' | s, a) V_k(s') \right] \quad \text{ou seja,} \quad V_{k+1} = \mathcal{B}V_k$$

Ao final, extraia a política **gulosa** em relação ao último valor:

$$\pi(s) = \arg \max_a \left[R(s, a) + \gamma \sum_{s'} P(s' | s, a) V_{k+1}(s') \right]$$

Intuição

Leitura em horizonte: V_k é o valor ótimo se restarem k passos; a política gulosa extraída é a ação ótima quando se pode agir por $k + 1$ passos.

Iteração de política na linguagem de operadores

O operador de backup **para uma política fixa** π é

$$\mathcal{B}^\pi V(s) = R^\pi(s) + \gamma \sum_{s' \in \mathcal{S}} P^\pi(s' | s) V(s')$$

Avaliação de política = calcular o **ponto fixo** de $\mathcal{B}^\pi$: aplicar o operador até V parar de mudar,

$$V^\pi = \mathcal{B}^\pi \mathcal{B}^\pi \dots \mathcal{B}^\pi V.$$

Melhoria de política = um backup com $\max$, seguido de $\arg \max$:

$$\pi_{k+1}(s) = \arg \max_a \left[R(s, a) + \gamma \sum_{s'} P(s' | s, a) V^{\pi_k}(s') \right]$$

Intuição

Na mesma notação: VI itera $\mathcal{B}$ (com $\max$) desde o início; PI itera $\mathcal{B}^\pi$ (linear) até o ponto fixo e só então usa o $\max$ uma vez. Essa lente unificada prepara o terreno para variantes híbridas.

Operador de contração

Definição — operador de contração

Seja O um operador e $\|\cdot\|$ uma norma. Se $\|OV - OV'\| \leq \|V - V'\|$ para todos V, V' , então O é um operador de *contração* (estrita, se vale com fator $\gamma < 1$).

Intuição

Imagem mental: um mapa que **aproxima os pontos**. Aplicado repetidamente, todos colapsam em um único ponto fixo — não importa de onde se parta.

VI converge?

Sim, se $\gamma < 1$ — ou se um estado terminal é atingido com probabilidade 1. O backup de Bellman é uma contração para $\gamma < 1$: aplicado a duas funções valor distintas, a distância entre elas **encolhe** por um fator γ .

Prova: o backup de Bellman é uma contração ($\gamma < 1$)

Norma do supremo: $\|V - V'\|_\infty = \max_s |V(s) - V'(s)|$. Para cada s :

$$\begin{aligned} |BV_k(s) - BV_j(s)| &= \left| \max_a \left[R(s, a) + \gamma \sum_{s'} P(s' | s, a) V_k(s') \right] - \max_{a'} \left[R(s, a') + \gamma \sum_{s'} P(s' | s, a') V_j(s') \right] \right| \\ &\leq \max_a \left| R(s, a) + \gamma \sum_{s'} P(s' | s, a) V_k(s') - R(s, a) - \gamma \sum_{s'} P(s' | s, a) V_j(s') \right| && |\max f - \max g| \leq \max |f - g| \\ &= \max_a \left| \gamma \sum_{s'} P(s' | s, a) (V_k(s') - V_j(s')) \right| \leq \max_a \gamma \sum_{s'} P(s' | s, a) \|V_k - V_j\|_\infty && \text{cota termo a termo} \\ &= \gamma \|V_k - V_j\|_\infty \sum_{s'} P(s' | s, a) = \gamma \|V_k - V_j\|_\infty && \text{probabilidades somam 1} \end{aligned}$$

Tomando o máximo sobre s : $\|BV_k - BV_j\|_\infty \leq \gamma \|V_k - V_j\|_\infty$. □

Atenção

Mesmo que todas as desigualdades fossem igualdades, ainda seria contração se $\gamma < 1$. E a recompensa R **cancela** — a contração não depende dela.

Da contração à convergência

ponto fixo de Banach aplicado a VI

Se $\gamma < 1$, então: (i) $\mathcal{B}$ tem um **único** ponto fixo, que é V^* ; (ii) VI converge a partir de **qualquer** inicialização V_0 ; e (iii) a convergência é geométrica: $\|V_k - V^*\|_\infty \leq \gamma^k \|V_0 - V^*\|_\infty$.

Consequências práticas:

- ▶ A inicialização não afeta o destino — só o tempo de viagem (e uma boa inicialização *acelera*).
- ▶ γ perto de 1 torna a convergência lenta: o número de iterações cresce como $\frac{1}{1-\gamma}$.

Intuição

Parou com $\|V_{k+1} - V_k\|_\infty \leq \epsilon$? Então $\|V_{k+1} - V^*\|_\infty \leq \frac{\gamma \epsilon}{1-\gamma}$, e a política gulosa extraída perde no máximo $\frac{2\gamma \epsilon}{1-\gamma}$ em valor.

Prática recomendada (fora de aula)

Exercício — para consolidar

1. Prove que a iteração de valor converge para uma solução *única* em espaços discretos de estados e ações com $\gamma < 1$.
2. A inicialização dos valores em VI afeta alguma coisa? O quê exatamente — e o que ela *não* afeta?
3. O valor da política extraída de VI a cada rodada é garantidamente **monotônico** (se executada no problema real de horizonte infinito), como na iteração de política?

Intuição

A terceira pergunta é a mais sutil da aula: a *função valor* V_k converge monotonicamente em norma, mas a sequência de *políticas gulosas* extraídas pode oscilar em qualidade antes de estabilizar. Contraste direto com PI.

SEÇÃO 5

Horizonte finito e síntese

05

Iteração de valor com horizonte finito H

Em horizonte finito, VI deixa de ser aproximação e vira **o algoritmo exato**: V_k e π_k são o valor e a política ótimos *quando restam k decisões*.

Algoritmo – VI para horizonte H

- ▶ Inicialize $V_0(s) = 0$ para todo s
- ▶ Para $k = 1, \dots, H$, e para cada s :

$$V_{k+1}(s) = \max_a \left[R(s, a) + \gamma \sum_{s'} P(s' | s, a) V_k(s') \right], \quad \pi_{k+1}(s) = \arg \max_a \left[R(s, a) + \gamma \sum_{s'} P(s' | s, a) V_k(s') \right]$$

Intuição

Guarde *todas* as $\pi_1, \dots, \pi_H$: para agir no instante t , use π_{H-t} — a política indexada por **quantos passos restam**.

Avaliação por simulação (ponte para a próxima aula)

Alternativa para estimar o valor de uma política em horizonte finito:

- ▶ gere um grande número de **episódios** seguindo a política;
- ▶ calcule o retorno de cada episódio e tire a **média**;
- ▶ desigualdades de concentração limitam a rapidez com que a média se aproxima da esperança.


Intuição

Nenhuma suposição markoviana é necessária — e, mais importante, nenhum **modelo**: basta poder *interagir*. Este é o portão de entrada do RL propriamente dito.

Atenção

O preço: variância. Cada retorno é uma amostra ruidosa, e a precisão melhora só com $1/\sqrt{n}$ episódios. O contraste exato entre DP e Monte Carlo é o tema da Aula 3.

Exemplo: retornos amostrais no *Mars Rover* estocástico



Recompensa $+1$ em s_1 , $+10$ em s_7 , 0 nos demais. Episódios de $H = 4$ passos a partir de s_4 , com $\gamma = \frac{1}{2}$:

Episódio	Retorno $G = r_1 + \frac{1}{2}r_2 + \frac{1}{4}r_3 + \frac{1}{8}r_4$	Valor
s_4, s_5, s_6, s_7	$0 + \frac{1}{2} \cdot 0 + \frac{1}{4} \cdot 0 + \frac{1}{8} \cdot 10$	1,25
s_4, s_4, s_5, s_4	$0 + \frac{1}{2} \cdot 0 + \frac{1}{4} \cdot 0 + \frac{1}{8} \cdot 0$	0
s_4, s_3, s_2, s_1	$0 + \frac{1}{2} \cdot 0 + \frac{1}{4} \cdot 0 + \frac{1}{8} \cdot 1$	0,125

Intuição

Três amostras, três respostas — todas legítimas. $V(s_4)$ é a média dessa distribuição; estimá-lo bem exige muitos episódios.

A política ótima é estacionária em horizonte finito?

Teste sua compreensão

Em tarefas de horizonte **finito**, a política ótima é estacionária (independente do passo de tempo)?

A política ótima é estacionária em horizonte finito?

Teste sua compreensão

Em tarefas de horizonte **finito**, a política ótima é estacionária (independente do passo de tempo)?

Resposta

Em geral, não. A ação ótima depende de **quanto tempo resta**.

Intuição

Exemplo no *Mars Rover*: em s_4 , com muitos passos restantes vale a pena caminhar até o $+10$ em s_7 ; com **um único** passo restante, nenhuma das duas direções alcança recompensa — e com dois ou três, o $+1$ de s_1 e o $+10$ de s_7 competem de forma diferente a cada instante. A política ótima precisa ser indexada pelo tempo: $\pi_t^*(s)$.

Iteração de valor *versus* iteração de política

	Iteração de valor	Iteração de política
O que mantém	valor ótimo p/ horizonte k	política + seu valor ∞
Passo	$V_{k+1} = \mathcal{B}V_k$	avaliar $\mathcal{B}^\pi$; melhorar c/ $\max$
Custo por iteração	$O(\mathcal{S} ^2 \mathcal{A})$	avaliação + $O(\mathcal{S} ^2 \mathcal{A})$
Nº de iterações	muitas e baratas	poucas e caras
Monotonia da política	não garantida	garantida
Parente em RL moderno	Q-learning	gradiente de política

Intuição

Iteração de política modificada: no passo de avaliação, aplique $\mathcal{B}^\pi$ só m vezes. Com $m = 1$ recupera-se VI; com $m = \infty$, PI. Quase tudo entre os dois extremos funciona — e costuma ser mais rápido que ambos.

Vocabulário de RL: modelos, políticas, valores

Definição — modelo

Representação matemática da dinâmica (P) e da recompensa (R).

Definição — política

Função que mapeia estados em ações (ou em distribuições sobre ações).

Definição — função valor

Recompensas futuras esperadas a partir de um estado (e/ou ação), quando se segue uma política específica.

Intuição

Estes três objetos são os eixos que organizam *todo* o campo: algoritmos baseados em modelo, em valor ou em política — e as combinações entre eles.

O que você deve saber ao final desta aula

- ▶ **Definir:** MP, MRP, MDP, operador de Bellman, contração, modelo, valor Q , política.
- ▶ **Implementar:** iteração de valor e iteração de política.
- ▶ **Comparar:** prós e contras das abordagens de avaliação de política.
- ▶ **Provar:** propriedades de contração e melhoria monotônica.
- ▶ **Criticar:** limitações das abordagens e da hipótese de Markov.
- ▶ **Distinguir:** quais métodos de avaliação exigem a hipótese de Markov — e quais não.

Atenção

Pergunta de despedida, para levar à Aula 3: dos três métodos de avaliação vistos (analítico, programação dinâmica, simulação), quais exigem a hipótese de Markov?

PRÓXIMA AULA

Avaliação de política sem modelo

Monte Carlo • diferenças temporais • o primeiro contato com aprendizagem de verdade

Material adaptado de Emma Brunskill, CS234: Reinforcement Learning, Stanford University.