

Aula 2: Tomando sequências de boas decisões dado um modelo do mundo

Processos de decisão de Markov • Avaliação de política • Iteração de política e de valor

Prof. Marcelo Keese Albertini

Adaptado de Emma Brunskill, CS234: Reinforcement Learning, Stanford University • 2026

Contexto. Esta é a única aula do curso em que o agente conhece *tudo* sobre o mundo: a dinâmica P e a recompensa R . O problema deixa de ser de aprendizagem e passa a ser de **planejamento** — e é exatamente por isso que ela fornece o alicerce teórico de todo o resto. Dado o modelo $(\mathcal{S}, \mathcal{A}, P, R, \gamma)$, dois problemas nos ocupam:

1. **Predição (avaliação de política):** qual é o valor de uma política dada?
2. **Controle:** qual é a melhor política possível?

A pergunta que conduz a aula: *é possível construir algoritmos que, a cada iteração adicional de computação, melhorem a política monotonicamente? Todos os algoritmos têm essa propriedade?* A resposta, como veremos, é “sim, é possível — mas não é o que acontece com todos”.

1 Processos de recompensa de Markov

Definição — propriedade de Markov

O futuro é independente do passado dado o presente: $\mathbb{P}(s_{t+1} \mid s_t, a_t, s_{t-1}, a_{t-1}, \dots) = \mathbb{P}(s_{t+1} \mid s_t, a_t)$. O estado é uma *estatística suficiente* da história.

Markov não é uma propriedade do mundo, e sim da *representação de estado* que escolhemos: se a posição do rover não basta para prever o próximo passo, inclua a velocidade no estado — e a propriedade volta a valer. A modelagem se organiza em uma hierarquia em que cada nível acrescenta exatamente um ingrediente:

- ▶ **Processo de Markov** $(\mathcal{S}, P)$: apenas aleatoriedade;
- ▶ **Processo de recompensa de Markov** (MRP) $(\mathcal{S}, P, R, \gamma)$: acrescenta recompensa — já é possível avaliar;
- ▶ **Processo de decisão de Markov** (MDP) $(\mathcal{S}, \mathcal{A}, P, R, \gamma)$: acrescenta ação — agora há o que decidir.

Definição — horizonte, retorno e função valor

O **horizonte** H é o número de passos de tempo por episódio (possivelmente infinito). O **retorno** é a soma descontada das recompensas a partir de t ,

$$G_t = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \dots + \gamma^{H-1} r_{t+H-1},$$

e a **função valor de estado** é o retorno esperado partindo de s : $V(s) = \mathbb{E}[G_t \mid s_t = s]$.

Intuição

G_t é uma variável *aleatória* — muda a cada trajetória sorteada. $V(s)$ é um *número*: a esperança já eliminou o acaso. Boa parte da aprendizagem por reforço consiste em estimar V a partir de amostras de G_t .

1.1 Por que descontar o futuro?

Há quatro razões, de naturezas distintas. **Matemática:** com recompensas limitadas, $|r| \leq R_{\max}$, e $\gamma < 1$, a série geométrica converge e $|G_t| \leq R_{\max}/(1 - \gamma)$ — sem isso, o valor pode divergir e comparar políticas perde o sentido. **Modelagem:** γ pode ser lido como a probabilidade de o episódio *continuar* a cada passo. **Econômica:** recompensa hoje vale mais do que amanhã. **Algorítmica:** é $\gamma < 1$ que torna o operador de Bellman uma *contração* — a fonte de todas as garantias de convergência desta aula.

Uma regra prática útil: o *horizonte efetivo* de um problema descontado é da ordem de $1/(1 - \gamma)$ passos ($\gamma = 0,9 \Rightarrow \sim 10$ passos; $\gamma = 0,99 \Rightarrow \sim 100$).

Atenção

$\gamma = 1$ só é seguro em horizonte finito, ou quando um estado terminal é atingido com probabilidade 1 (tarefa episódica própria). Fora dessas condições, V pode divergir.

1.2 Equação de Bellman e suas soluções

A propriedade de Markov permite quebrar o retorno em *agora* + *depois*:

$$V(s) = \underbrace{R(s)}_{\text{recompensa imediata}} + \underbrace{\gamma \sum_{s' \in \mathcal{S}} P(s' | s) V(s')}_{\text{soma descontada do futuro}}$$

Todo o valor de uma trajetória infinita cabe em uma equação com um único passo de antecipação — é o princípio de otimalidade de Bellman. Atenção: isso é um *sistema* de $N = |\mathcal{S}|$ equações acopladas, uma por estado, e não uma fórmula fechada. Há duas maneiras clássicas de resolvê-lo.

Solução analítica. Empilhando os estados em vetores, $V, R \in \mathbb{R}^N$ e $P \in \mathbb{R}^{N \times N}$, a equação vira $V = R + \gamma PV$, donde

$$(I - \gamma P) V = R \quad \Rightarrow \quad V = (I - \gamma P)^{-1} R$$

a inversa sempre existe se $\gamma < 1$

Como $\|\gamma P\|_{\infty} = \gamma < 1$, a série de Neumann converge e $(I - \gamma P)^{-1} = \sum_{k \geq 0} (\gamma P)^k$. O termo de índice k tem leitura própria: é a contribuição das recompensas k passos à frente.

O custo é uma inversão de matriz, $\Theta(N^3)$ — viável apenas para N moderado.

Solução iterativa (programação dinâmica).

Algoritmo — avaliação iterativa de um MRP

Inicialize $V_0(s) = 0$ para todo s . Para $k = 1, 2, \dots$ até convergir (por exemplo, até $\|V_k -$

(continua) $V_{k-1} \|_{\infty} \leq \varepsilon$), atualize, para todo $s \in \mathcal{S}$:

$$V_k(s) \leftarrow R(s) + \gamma \sum_{s' \in \mathcal{S}} P(s' | s) V_{k-1}(s')$$

Custo por varredura: $O(|\mathcal{S}|^2)$.**Intuição**

$V_k(s)$ tem uma leitura própria: é o valor *exato* de s quando restam exatamente k passos de episódio. E na comparação de custos — analítico $\Theta(N^3)$ uma única vez *versus* iterativo $O(N^2)$ por varredura — o iterativo vence para N grande. Mais importante: é ele que sobrevive à passagem para o caso sem modelo.


2 Processos de decisão de Markov e políticas**Definição — processo de decisão de Markov**

Um MDP é a tupla $(\mathcal{S}, \mathcal{A}, P, R, \gamma)$, em que $\mathcal{S}$ é um conjunto finito de estados de Markov; $\mathcal{A}$ é um conjunto finito de ações; P é o modelo de dinâmica/transição, um por ação, $P(s_{t+1} = s' | s_t = s, a_t = a)$; R é a função de recompensa, $R(s, a) = \mathbb{E}[r_t | s_t = s, a_t = a]$; e $\gamma \in [0, 1]$ é o fator de desconto. Em resumo: MDP = MRP + ações.

Atenção

A recompensa aparece na literatura em três formatos — $R(s)$, $R(s, a)$ e $R(s, a, s')$. Neste curso usaremos predominantemente $R(s, a)$. Os três têm o mesmo poder expressivo (basta tomar esperanças), mas trocar de convenção no meio de uma dedução é uma fonte clássica de erro de sinal e de índice.

Exemplo condutor: o Mars Rover. Sete estados ($s_1, \dots, s_7$, a posição do rover em uma linha), duas ações determinísticas (a_1 : esquerda; a_2 : direita; nas bordas, a ação que sairia do mapa mantém o rover parado) e recompensas +1 em s_1 , +10 em s_7 e 0 nos demais estados. Cada linha das matrizes $P(\cdot | \cdot, a_1)$ e $P(\cdot | \cdot, a_2)$ é uma distribuição sobre o próximo estado; por serem determinísticas, cada linha tem um único 1.

**Definição — política**

Uma política especifica que ação tomar em cada estado. Na forma mais geral, é uma distribuição condicional: $\pi(a | s) = \mathbb{P}(a_t = a | s_t = s)$. Casos particulares: **determinística** ($\pi(s) = a$, massa concentrada em uma ação) e **estacionária** (independente de t).

Trabalhar com a forma estocástica desde o início não é preciosismo: ela permite exploração, é diferenciável nos parâmetros (o que habilitará os métodos de gradiente de política) e é a

única forma ótima em jogos e em MDPs parcialmente observáveis. É uma distinção que evita confusões futuras: uma política *não* é um plano. Um plano é uma sequência fixa de ações; uma política é uma *função reativa* do estado — ela responde ao que de fato aconteceu, e por isso é robusta à estocasticidade do ambiente.

2.1 A observação estrutural central: MDP + política = MRP

Fixar uma política elimina a decisão: sobram apenas aleatoriedade e recompensa. Um MDP com π fixada é exatamente o MRP $(\mathcal{S}, R^\pi, P^\pi, \gamma)$, com

$$R^\pi(s) = \sum_{a \in \mathcal{A}} \pi(a | s) R(s, a), \quad P^\pi(s' | s) = \sum_{a \in \mathcal{A}} \pi(a | s) P(s' | s, a).$$

Intuição

Esta é a observação mais rentável da aula: *tudo* que sabemos calcular para MRPs — forma matricial, solução analítica $(I - \gamma P^\pi)^{-1} R^\pi$, algoritmo iterativo — aplica-se imediatamente à *avaliação* de uma política em um MDP. O problema de predição não exige teoria nova. O que não vem de graça é o *controle*: escolher π . É aí que o operador max entra em cena, e com ele a não linearidade.

3 Avaliação de política (predição)

Algoritmo — avaliação iterativa de política

Inicialize $V_0^\pi(s) = 0$. Para $k = 1, 2, \dots$ até convergir, atualize, para todo $s \in \mathcal{S}$:

$$V_k^\pi(s) \leftarrow \sum_{a \in \mathcal{A}} \pi(a | s) \left[R(s, a) + \gamma \sum_{s' \in \mathcal{S}} P(s' | s, a) V_{k-1}^\pi(s') \right]$$

Este é o *backup de Bellman para uma política específica*. Se π é determinística, a soma externa desaparece: $V_k^\pi(s) \leftarrow R(s, \pi(s)) + \gamma \sum_{s'} P(s' | s, \pi(s)) V_{k-1}^\pi(s')$.

Note o que *não* há aqui: um max. A política já foi fixada, o operador é *linear* em V — e é isso que permite, alternativamente, resolver o sistema de forma fechada.

Exercício L2E1 — uma iteração de avaliação no Mars Rover

Suponha agora que a_1 seja *estocástica*: $p(s_6 | s_6, a_1) = 0,5$ e $p(s_7 | s_6, a_1) = 0,5$ (e análogamente nos demais estados). Recompensa: para toda ação, +1 em s_1 , +10 em s_7 , 0 nos demais. Seja $\pi(s) = a_1$ para todo s , com $V_k = [1 \ 0 \ 0 \ 0 \ 0 \ 0 \ 10]$, $k = 1$ e $\gamma = 0,5$. Calcule $V_{k+1}(s_6)$.

Resolução. Aplicamos o backup para política determinística em um único estado. Como $p(\cdot | s_6, a_1)$ tem massa apenas em s_6 e s_7 , somente dois termos são não nulos:

$$V_{k+1}(s_6) = \underbrace{0}_{R(s_6, a_1)} + \underbrace{0,5}_{\gamma} \cdot \left(0,5 \cdot \underbrace{0}_{V_k(s_6)} + 0,5 \cdot \underbrace{10}_{V_k(s_7)} \right) = 2,5$$

Intuição

Repare no mecanismo: o valor *difunde* para trás pelas transições. Na próxima varredura, s_5 também deixará de valer zero. Cada rodada propaga informação um passo — por isso o

(continua)

número de iterações necessárias depende do “diâmetro” do MDP.

Para discutir em aula

No *Mars Rover* — 7 estados, 2 ações — quantas políticas *determinísticas* existem? E a política ótima de um MDP (a de maior valor) é única?

Direção da resposta: $2^7 = 128$; em geral, $|\mathcal{A}|^{|\mathcal{S}|}$, uma escolha independente por estado. E não: pode haver duas (ou infinitas) políticas com a mesma função valor máxima — basta um empate no máximo de Q em algum estado. O que é único é a *função valor ótima* V^* , não o argumento que a atinge. Essa distinção reaparece o curso inteiro.

4 Controle por iteração de política

O problema de controle pede $\pi^*(s) = \arg \max_{\pi} V^{\pi}(s)$. Para um MDP de horizonte infinito com $\gamma < 1$, a política ótima é **determinística** (aleatorizar não ajuda), **estacionária** (não depende de t) e **não necessariamente única** (pode haver empates); já a função valor ótima V^* é única. Leia o $\arg \max$ com cuidado: ele afirma que existe uma política que maximiza o valor em *todos os estados ao mesmo tempo*. Em otimização multiobjetivo isso em geral não acontece; aqui acontece, por causa da estrutura de Bellman.

Enumerar candidatas está fora de cogitação: há $|\mathcal{A}|^{|\mathcal{S}|}$ políticas determinísticas ($|\mathcal{S}| = 100$ e $|\mathcal{A}| = 4$ já dão $4^{100} \approx 10^{60}$). A iteração de política faz muito melhor: usa o valor da política atual para construir diretamente uma política melhor.

Definição — valor de estado-ação Q

$$Q^{\pi}(s, a) = R(s, a) + \gamma \sum_{s' \in \mathcal{S}} P(s' | s, a) V^{\pi}(s')$$

Leitura: “tome a ação a agora e siga π daí em diante”. Vale a identidade $V^{\pi}(s) = \sum_a \pi(a | s) Q^{\pi}(s, a)$.

V responde “quão bom é este estado?”; Q responde “quão boa é esta ação neste estado?” — que é a pergunta que se precisa responder para *agir*. Daí o domínio de Q nos algoritmos sem modelo.

Algoritmo — Iteração de Política (PI)

$i \leftarrow 0$; inicialize $\pi_0(s)$ aleatoriamente. Enquanto $i = 0$ ou $\|\pi_i - \pi_{i-1}\|_1 > 0$ (a norma L_1 só verifica se a política mudou em *algum* estado):

1. **Avaliação:** $V^{\pi_i} \leftarrow$ valor de π_i (pela redução MDP + π = MRP da Seção 2);
2. **Melhoria:** calcule $Q^{\pi_i}(s, a)$ para todos s, a e tome a política gulosa $\pi_{i+1}(s) = \arg \max_a Q^{\pi_i}(s, a)$; faça $i \leftarrow i + 1$.

Intuição

Nada garante *a priori* que π_{i+1} seja melhor: ela foi construída com V^{π_i} , o valor da política antiga. Provar que a troca compensa é o teorema a seguir. E o esquema geral — alternar avaliação e melhoria — é a *iteração de política generalizada*, esqueleto de quase todo algoritmo do curso, inclusive Q-learning e métodos ator-crítico.

4.1 Melhoria monotônica

Escrevemos $V^{\pi_1} \geq V^{\pi_2}$ quando $V^{\pi_1}(s) \geq V^{\pi_2}(s)$ para *toda* $s \in \mathcal{S}$ (uma ordem parcial entre políticas).

Proposição — melhoria monotônica

Seja π_{i+1} a política obtida pelo passo de melhoria aplicado a π_i . Então $V^{\pi_{i+1}} \geq V^{\pi_i}$, com desigualdade *estrita* em ao menos um estado se π_i for subótima.

A intuição em duas frases. Para qualquer s , escolher a melhor ação é ao menos tão bom quanto seguir a política antiga: $\max_a Q^{\pi_i}(s, a) \geq Q^{\pi_i}(s, \pi_i(s)) = V^{\pi_i}(s)$. Isso mostra que tomar π_{i+1} *por um passo* e depois voltar a π_i não piora nada — mas a política proposta é seguir π_{i+1} *sempre*. O argumento de um passo não fecha a prova: é preciso aplicá-lo repetidamente, em um telescópio de desigualdades.

Demonstração

$$\begin{aligned} V^{\pi_i}(s) &\leq \max_a Q^{\pi_i}(s, a) = \max_a \left[R(s, a) + \gamma \sum_{s'} P(s' | s, a) V^{\pi_i}(s') \right] && \text{(i) o máximo domina} \\ &= R(s, \pi_{i+1}(s)) + \gamma \sum_{s'} P(s' | s, \pi_{i+1}(s)) V^{\pi_i}(s') && \text{(ii) definição de } \pi_{i+1} \\ &\leq R(s, \pi_{i+1}(s)) + \gamma \sum_{s'} P(s' | s, \pi_{i+1}(s)) \left[\max_{a'} Q^{\pi_i}(s', a') \right] && \text{(iii) aplica (i) em } s' \end{aligned}$$

Expandindo o colchete com (ii) aplicado em s' , aparece mais um passo executado sob π_{i+1} , com a cauda ainda avaliada sob π_i :

$$\leq R(s, \pi_{i+1}(s)) + \gamma \sum_{s'} P(s' | s, \pi_{i+1}(s)) \left[R(s', \pi_{i+1}(s')) + \gamma \sum_{s''} P(s'' | s', \pi_{i+1}(s')) V^{\pi_i}(s'') \right] \leq \dots$$

Repetindo indefinidamente, cada linha empurra a troca de política um passo adiante; o resíduo avaliado sob π_i é multiplicado por $\gamma^k \rightarrow 0$ e desaparece no limite, restando exatamente a definição de $V^{\pi_{i+1}}(s)$. Logo $V^{\pi_i}(s) \leq V^{\pi_{i+1}}(s)$ para todo s . ■

Para discutir em aula

Duas perguntas sobre o comportamento de PI. (1) Se a política não muda em uma rodada, ela pode voltar a mudar depois? (2) Existe um número máximo de rodadas?

Direção da resposta: (1) Não. Se $\pi_{i+1} = \pi_i$, então $Q^{\pi_{i+1}} = Q^{\pi_i}$ (mesma política, mesmo valor), logo $\pi_{i+2} = \arg \max_a Q^{\pi_{i+1}} = \arg \max_a Q^{\pi_i} = \pi_{i+1}$: ponto fixo — e esse ponto fixo é ótimo. (2) Sim: $|\mathcal{A}|^{|\mathcal{S}|}$. Pela monotonia, cada política só aparece em uma rodada (a menos que já seja ótima). Na prática, PI converge em poucas dezenas de rodadas; Ye (2011) mostrou que, para γ fixo, PI é *fortemente polinomial* em $|\mathcal{S}|$ e $|\mathcal{A}|$.

5 Controle por iteração de valor

A segunda estratégia de controle não mantém uma política: mantém o *valor ótimo* de começar em cada estado supondo que restam k passos de episódio — e itera considerando episódios cada vez mais longos. São dois eixos de aproximação ortogonais: PI é exata no *valor* e aproxima a *política*; VI é exata na otimalidade local e aproxima o *horizonte*. Ambas convergem para o mesmo par (V^*, π^*) .

Definição — operador de backup de Bellman $\mathcal{B}$

Aplicado a uma função valor qualquer, devolve uma nova função valor sobre todos os estados, melhorando o valor quando há melhora possível:

$$\mathcal{B}V(s) = \max_a \left[R(s, a) + \gamma \sum_{s' \in \mathcal{S}} P(s' | s, a) V(s') \right]$$

A troca da soma ponderada por π pelo max sobre ações é o que distingue predição de controle — e o que destrói a linearidade: com $\mathcal{B}$, a solução fechada por inversão de matriz deixa de existir.

Algoritmo — Iteração de Valor (VI)

Inicialize $V_0(s) = 0$. Repita $V_{k+1} = \mathcal{B}V_k$ até convergir (por exemplo, $\|V_{k+1} - V_k\|_\infty \leq \epsilon$). Ao final, extraia a política gulosa em relação ao último valor: $\pi(s) = \arg \max_a [R(s, a) + \gamma \sum_{s'} P(s' | s, a) V_{k+1}(s')]$.

Na linguagem de operadores, as duas famílias se unificam. Definindo o backup para uma política fixa, $\mathcal{B}^\pi V(s) = R^\pi(s) + \gamma \sum_{s'} P^\pi(s' | s) V(s')$, a avaliação de política é o cálculo do ponto fixo de $\mathcal{B}^\pi$ ($V^\pi = \mathcal{B}^\pi \mathcal{B}^\pi \dots \mathcal{B}^\pi V$), e a melhoria é um único backup com max seguido de arg max. VI itera $\mathcal{B}$ (com max) desde o início; PI itera $\mathcal{B}^\pi$ (linear) até o ponto fixo e só então usa o max uma vez.

Atenção

Em VI, os valores intermediários V_k em geral *não* correspondem ao valor de nenhuma política executável — são valores ótimos de um problema truncado em k passos. Consequência: a qualidade das políticas gulosas extraídas ao longo do caminho pode oscilar antes de estabilizar. A monotonia rodada a rodada é uma garantia de PI, não de VI.

5.1 Por que VI converge: contração**Definição — operador de contração**

Seja $\mathcal{O}$ um operador e $\|\cdot\|$ uma norma. Se $\|\mathcal{O}V - \mathcal{O}V'\| \leq \|V - V'\|$ para todos V, V' , então $\mathcal{O}$ é um operador de *contração* (estrita, se a desigualdade vale com um fator $\gamma < 1$).

Imagem mental: um mapa que *aproxima os pontos*. Aplicado repetidamente, todos os pontos colapsam em um único ponto fixo — não importa de onde se parta.

o backup de Bellman é uma contração para $\gamma < 1$

Na norma do supremo, $\|V - V'\|_\infty = \max_s |V(s) - V'(s)|$, vale $\|\mathcal{B}V - \mathcal{B}V'\|_\infty \leq \gamma \|V - V'\|_\infty$.

Demonstração

Para cada estado s , usando primeiro que a diferença de máximos é limitada pelo máximo das diferenças, $|\max_a f(a) - \max_{a'} g(a')| \leq \max_a |f(a) - g(a)|$:

$$\begin{aligned} |\mathcal{B}V_k(s) - \mathcal{B}V_j(s)| &\leq \max_a \left| R(s, a) + \gamma \sum_{s'} P(s' | s, a) V_k(s') - R(s, a) - \gamma \sum_{s'} P(s' | s, a) V_j(s') \right| \\ &= \max_a \gamma \left| \sum_{s'} P(s' | s, a) (V_k(s') - V_j(s')) \right| \leq \max_a \gamma \sum_{s'} P(s' | s, a) \|V_k - V_j\|_\infty \\ &= \gamma \|V_k - V_j\|_\infty \quad (\text{as probabilidades somam 1}). \end{aligned}$$

Tomando o máximo sobre s obtém-se a contração. Note dois detalhes: a recompensa R *cancela* — a contração não depende dela —, e mesmo que todas as desigualdades fossem igualdades ainda haveria contração, desde que $\gamma < 1$. ■

consequências (ponto fixo de Banach)

Se $\gamma < 1$: (i) $\mathcal{B}$ tem um *único* ponto fixo, que é V^* ; (ii) VI converge a partir de *qualquer* inicialização V_0 ; (iii) a convergência é geométrica, $\|V_k - V^*\|_\infty \leq \gamma^k \|V_0 - V^*\|_\infty$. Além disso, se o critério de parada $\|V_{k+1} - V_k\|_\infty \leq \epsilon$ foi atingido, então $\|V_{k+1} - V^*\|_\infty \leq \gamma\epsilon/(1 - \gamma)$, e a política gulosa extraída perde no máximo $2\gamma\epsilon/(1 - \gamma)$ em valor.

Duas consequências práticas: a inicialização não afeta o destino, só o tempo de viagem (e uma boa inicialização acelera); e γ perto de 1 torna a convergência lenta — o número de iterações cresce como $1/(1 - \gamma)$.

6 Horizonte finito e avaliação por simulação

6.1 VI em horizonte finito

Em horizonte finito, VI deixa de ser aproximação e vira o *algoritmo exato*: V_k e π_k são o valor e a política ótimos *quando restam k decisões*. Basta rodar o laço de VI por exatamente H iterações, guardando a cada passo também a política gulosa $\pi_{k+1}(s) = \arg \max_a [R(s, a) + \gamma \sum_{s'} P(s' | s, a) V_k(s')]$. Para agir no instante t , usa-se π_{H-t} — a política indexada por *quantos passos restam*.

Para discutir em aula

Em tarefas de horizonte *finito*, a política ótima é estacionária (independente do passo de tempo)?

Direção da resposta: em geral, não — a ação ótima depende de quanto tempo resta. No *Mars Rover*, em s_4 com muitos passos restantes vale caminhar até o +10 em s_7 ; com um único passo restante, nenhuma direção alcança recompensa; com dois ou três, o +1 de s_1 e o +10 de s_7 competem de forma diferente a cada instante. A política ótima precisa ser indexada pelo tempo: $\pi_t^*(s)$.

6.2 Avaliação por simulação (Monte Carlo)

Alternativa para estimar o valor de uma política: gere um grande número de *episódios* seguindo-a, calcule o retorno de cada um e tire a *média*. Desigualdades de concentração (como a de Hoeffding) limitam a rapidez com que a média se aproxima da esperança. Nenhuma suposição markoviana é necessária — e, mais importante, nenhum *modelo*: basta poder interagir. O preço é a variância: cada retorno é uma amostra ruidosa, e a precisão melhora apenas com $1/\sqrt{n}$ episódios.

Exemplo numérico. No *Mars Rover* estocástico (passeio aleatório: de cada estado interior, prob. 0,4 para cada vizinho e 0,2 de ficar parado; 0,6 de ficar parado nas bordas), com episódios de $H = 4$ passos a partir de s_4 e $\gamma = \frac{1}{2}$:

Episódio	Retorno $G = r_1 + \frac{1}{2}r_2 + \frac{1}{4}r_3 + \frac{1}{8}r_4$	Valor
s_4, s_5, s_6, s_7	$0 + \frac{1}{2} \cdot 0 + \frac{1}{4} \cdot 0 + \frac{1}{8} \cdot 10$	1,25
s_4, s_4, s_5, s_4	$0 + \frac{1}{2} \cdot 0 + \frac{1}{4} \cdot 0 + \frac{1}{8} \cdot 0$	0
s_4, s_3, s_2, s_1	$0 + \frac{1}{2} \cdot 0 + \frac{1}{4} \cdot 0 + \frac{1}{8} \cdot 1$	0,125

Três amostras, três respostas — todas legítimas. $V(s_4)$ é a média dessa distribuição (o cálculo

exato por programação dinâmica dá $V(s_4) \approx 0,088$; estimá-la bem exige muitos episódios. DP calcula a média sem nunca sortear; Monte Carlo sorteia sem nunca conhecer P . A Aula 3 vive exatamente nesse contraste.

7 Síntese

7.1 Comparação dos métodos

Três formas de avaliar uma política.

Método	Custo	Exige Markov?	Exige modelo?
Analítico $(I - \gamma P^\pi)^{-1} R^\pi$	$\Theta(N^3)$, uma vez	sim	sim
Iterativo (DP)	$O(N^2)$ por varredura	sim	sim
Simulação (Monte Carlo)	$O(\text{episódios} \times H)$	não	não (só amostras)

Os dois algoritmos de controle.

	Iteração de valor	Iteração de política
O que mantém	valor ótimo p/ horizonte k	política + seu valor ∞
Passo	$V_{k+1} = \mathcal{B}V_k$	avaliar $\mathcal{B}^\pi$; melhorar $c/\max$
Custo por iteração	$O(\mathcal{S} ^2 \mathcal{A})$	avaliação + $O(\mathcal{S} ^2 \mathcal{A})$
Nº de iterações	muitas e baratas	poucas e caras
Monotonia da política	não garantida	garantida
Parente em RL moderno	Q-learning	gradiente de política

Intuição

Iteração de política modificada: no passo de avaliação, em vez de iterar $\mathcal{B}^\pi$ até o ponto fixo, aplique-o apenas m vezes. Com $m = 1$ recupera-se VI; com $m = \infty$, PI. Quase tudo entre os dois extremos funciona — e costuma ser mais rápido que ambos.

7.2 Vocabulário

Modelo: representação matemática da dinâmica (P) e da recompensa (R). **Política:** função que mapeia estados em ações (ou distribuições sobre ações). **Função valor:** recompensas futuras esperadas a partir de um estado (e/ou ação), seguindo uma política específica. Estes três objetos organizam todo o campo: algoritmos baseados em modelo, em valor ou em política — e suas combinações.

7.3 O que você deve saber ao final desta aula

- ▶ **Definir:** MP, MRP, MDP, operador de Bellman, contração, modelo, valor Q , política.
- ▶ **Implementar:** iteração de valor e iteração de política.
- ▶ **Comparar:** prós e contras das abordagens de avaliação de política.
- ▶ **Provar:** propriedades de contração e a melhoria monotônica.

- **Criticar:** limitações das abordagens apresentadas e da hipótese de Markov — em particular, saber dizer quais métodos de avaliação exigem a hipótese de Markov e quais não.

7.4 Prática recomendada

Exercício — para consolidar fora de aula

1. Prove que a iteração de valor converge para uma solução *única* em espaços discretos de estados e ações com $\gamma < 1$.
2. A inicialização dos valores em VI afeta alguma coisa? O quê, exatamente — e o que ela não afeta?
3. O valor da política extraída de VI a cada rodada é garantidamente monotônico (se executada no problema real de horizonte infinito), como na iteração de política? *(Esta é a pergunta mais sutil da aula — compare com a caixa de atenção da Seção 5.)*
4. Implemente VI e PI para o *Mars Rover* e meça: quantas iterações cada um leva com $\gamma = 0,5$? E com $\gamma = 0,95$? O laboratório interativo da aula permite conferir suas respostas.

Próxima aula: avaliação de política sem modelo — Monte Carlo e diferenças temporais.