

Aprendizagem por Reforço

Aula 3: Avaliação de Política Sem Modelo

Estimando V^π sem saber como o mundo funciona

Monte Carlo • Diferença Temporal • Equivalência de Certeza

Prof. Marcelo Keese Albertini
Universidade Federal de Uberlândia
adaptado de Emma Brunskill, CS234 (Stanford)
2026



- ▶ **Aula passada:** processos de recompensa e de decisão de Markov; avaliação e controle de políticas *com* o modelo verdadeiro (dinâmica P e recompensa R conhecidas).
- ▶ **Hoje:** avaliar uma política π **sem** conhecer P nem R — apenas interagindo com o ambiente.
- ▶ **Próxima aula:** *controle* sem modelo — encontrar uma boa política a partir da experiência.

Intuição

Até agora, o agente “lia o manual do mundo”. A partir de hoje, ele precisa aprender *vivendo*: executa π , observa estados, ações e recompensas, e estima o quanto essa política vale.

Leitura recomendada: Sutton & Barto, seções 5.1, 5.5 e 6.1–6.3; David Silver, aula 4 (*Model-Free Prediction*).

Avaliação por experiência direta

Problema. Estimar o retorno esperado de π usando apenas dados coletados do ambiente (experiência direta).

- ▶ Em quase toda aplicação real (robótica, saúde, recomendação), **não temos** o modelo verdadeiro do mundo.
- ▶ Hoje os dados vêm da própria π (*on-policy*); o caso *off-policy* fica para adiante.

Teste sua compreensão

Que propriedades um bom método de avaliação de política deveria ter?

Pergunta para discussão conduzida em aula.

Avaliação por experiência direta

Problema. Estimar o retorno esperado de π usando apenas dados coletados do ambiente (experiência direta).

- ▶ Em quase toda aplicação real (robótica, saúde, recomendação), **não temos** o modelo verdadeiro do mundo.
- ▶ Hoje os dados vêm da própria π (*on-policy*); o caso *off-policy* fica para adiante.

Teste sua compreensão

Que propriedades um bom método de avaliação de política deveria ter?

Pergunta para discussão conduzida em aula.

Resposta

Consistência, eficiência estatística, atualização barata e pouca memória — a régua que usaremos na aula inteira.

O cardápio de hoje

Quatro maneiras de estimar V^π sem os modelos verdadeiros:

1. **Monte Carlo (MC):** valor = média dos retornos observados.
2. **Diferença Temporal (TD):** atualiza a cada passo, usando a própria estimativa como “palpite” do futuro.
3. **Equivalência de certeza:** estima um modelo por máxima verossimilhança e planeja nele como se fosse o verdadeiro.
4. **Avaliação em lote (batch):** o que muda quando os dados são fixos e finitos — e um exemplo em que MC e TD discordam.

Intuição

Os três primeiros ocupam cantos diferentes de um mesmo mapa: quanto do futuro cada atualização enxerga (profundidade) e quantos futuros ela considera (largura). Voltaremos a esse mapa no fim da aula.

SEÇÃO 1

Recordando a aula anterior

01

Aquecimento: iteração de valor $\times$ iteração de política

Teste sua compreensão

Em um MDP tabular, assintoticamente, a iteração de valor sempre produz uma política com o **mesmo valor** da política devolvida pela iteração de política. Verdadeiro ou falso?

Pergunta para discussão conduzida em aula.

Aquecimento: iteração de valor $\times$ iteração de política

Teste sua compreensão

Em um MDP tabular, assintoticamente, a iteração de valor sempre produz uma política com o **mesmo valor** da política devolvida pela iteração de política. Verdadeiro ou falso?

Pergunta para discussão conduzida em aula.

Resposta

Verdadeiro. Ambas convergem para a função valor ótima V^* e devolvem uma política com valor ótimo — os *caminhos* até lá é que diferem.

Aquecimento: quantas iterações a iteração de valor pode levar?

Teste sua compreensão

A iteração de valor pode precisar de **mais** de $|\mathcal{A}|^{|\mathcal{S}|}$ iterações para computar a função valor ótima? (Suponha $|\mathcal{A}|$ e $|\mathcal{S}|$ pequenos o bastante para cada rodada ser exata.)

Pergunta para discussão conduzida em aula.

Aquecimento: quantas iterações a iteração de valor pode levar?

Teste sua compreensão

A iteração de valor pode precisar de **mais** de $|\mathcal{A}|^{|\mathcal{S}|}$ iterações para computar a função valor ótima? (Suponha $|\mathcal{A}|$ e $|\mathcal{S}|$ pequenos o bastante para cada rodada ser exata.)

Pergunta para discussão conduzida em aula.

Resposta

Sim. Exemplo: MDP com um único estado e uma única ação, $r(s, a) = 1$, $\gamma = 0,9$ e $V_0(s) = 0$. Aqui $|\mathcal{A}|^{|\mathcal{S}|} = 1$, mas $V^*(s) = \frac{1}{1-\gamma} = 10$, e após a primeira iteração $V_1(s) = 1$: a convergência ao valor é *assintótica*. (A iteração de *política*, ao contrário, para em no máximo $|\mathcal{A}|^{|\mathcal{S}|}$ passos.)

Retorno e funções valor

Definição — Retorno G_t

Soma descontada das recompensas do passo t em diante: $G_t = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \gamma^3 r_{t+3} + \dots$

Definição — Função valor de estado $V^\pi(s)$

Retorno esperado ao partir de s e seguir π :

$$V^\pi(s) = \mathbb{E}_\pi [G_t \mid s_t = s]$$

Definição — Função valor de estado-ação $Q^\pi(s, a)$

Retorno esperado ao partir de s , executar a e depois seguir π : $Q^\pi(s, a) = \mathbb{E}_\pi [G_t \mid s_t = s, a_t = a]$

Programação dinâmica para avaliação (com modelo)

Se conhecemos P e R , a equação de Bellman dá um algoritmo iterativo:


$$V_k^\pi(s) = \underbrace{R(s, \pi(s))}_{\text{recompensa imediata}} + \gamma \underbrace{\sum_{s' \in \mathcal{S}} P(s' \mid s, \pi(s)) V_{k-1}^\pi(s')}_{\text{estimativa do futuro}}$$

- ▶ $V_k^\pi(s)$ é exatamente o valor de s com horizonte k ; antes da convergência, é uma *estimativa* de $V^\pi(s)$.
- ▶ O termo da direita substitui a esperança do retorno futuro $\mathbb{E}_\pi[r_{t+1} + \gamma r_{t+2} + \dots]$ pela estimativa V_{k-1}^π da iteração anterior.

Definição — *Bootstrapping*

Atualizar uma estimativa usando *outra estimativa* no lugar da quantidade verdadeira. A PD faz bootstrapping; guarde o termo — ele é a alma do TD.

O que a PD usa — e o que não teremos hoje



- ▶ A PD calcula a média **sobre todos** os próximos estados s' , ponderada por $P(s' \mid s, \pi(s))$ — para isso, precisa do modelo.
- ▶ Hoje só temos **amostras**: um s' por vez, sorteado pelo próprio ambiente.

Atenção

Sem o modelo, não dá para somar sobre s' — não sabemos as probabilidades. Toda a aula é sobre como contornar isso.

SEÇÃO 2

Avaliação de política por Monte Carlo

02

A ideia mais simples possível

$$V^\pi(s) = \mathbb{E}_{\tau \sim \pi} [G_t \mid s_t = s] \quad (\text{esperança sobre trajetórias } \tau \text{ geradas por } \pi)$$

Intuição

Valor é uma esperança — e esperanças se estimam com médias. Rode a política várias vezes, anote o retorno obtido a partir de cada estado e tire a média: **valor = retorno médio**.

- ▶ Não requer modelo de dinâmica nem de recompensa.
- ▶ Nem sequer assume que o estado é Markoviano!
- ▶ Requer episódios **finitos**: só podemos calcular G_t quando o episódio termina.
- ▶ Episódios podem ter comprimentos diferentes (estados terminais).

Algoritmo — MC de primeira visita (*first-visit*)

- ▶ Inicialize $N(s) = 0$, $G(s) = 0$ para todo $s \in \mathcal{S}$
- ▶ Repita:
 - Amostre um episódio i : $s_{i,1}, a_{i,1}, r_{i,1}, s_{i,2}, \dots, s_{i,T_i}, a_{i,T_i}, r_{i,T_i}$
 - Calcule $G_{i,t} = r_{i,t} + \gamma r_{i,t+1} + \gamma^2 r_{i,t+2} + \dots + \gamma^{T_i-t} r_{i,T_i}$
 - Para cada passo t do episódio: se t é a **primeira** visita ao estado s neste episódio:
 - $N(s) \leftarrow N(s) + 1$; $G(s) \leftarrow G(s) + G_{i,t}$
 - $V^\pi(s) \leftarrow G(s)/N(s)$

Cada estado contribui **no máximo uma amostra por episódio** — as amostras usadas na média são independentes entre episódios.

Algoritmo — MC de toda visita (*every-visit*)

- ▶ Idêntico ao anterior, exceto pela condição destacada:
- ▶ Para cada passo t do episódio, com $s = s_{i,t}$ (**toda** visita conta, não só a primeira):
 - $N(s) \leftarrow N(s) + 1$; $G(s) \leftarrow G(s) + G_{i,t}$
 - $V^\pi(s) \leftarrow G(s)/N(s)$
- ▶ Se a política revisita s dentro do mesmo episódio, cada visita gera uma amostra de retorno.
- ▶ Essas amostras são *correlacionadas* (compartilham o fim do episódio) — isso terá consequências estatísticas, como veremos.

Exemplo resolvido: Mars Rover



Exercício — MC no Mars Rover

Recompensas $R = [+1, 0, 0, 0, 0, 0, +10]$ para qualquer ação; s_1 e s_7 terminam o episódio. Trajetória observada:

$(s_3, a_1, 0, s_2, a_1, 0, s_2, a_1, 0, s_1, a_1, +1, \text{terminal})$

Com $\gamma < 1$, calcule as estimativas MC de **primeira visita** e de **toda visita** para $V(s_2)$.

Exemplo resolvido: solução

Retornos a partir de cada passo da trajetória $(s_3, 0) \rightarrow (s_2, 0) \rightarrow (s_2, 0) \rightarrow (s_1, +1) \rightarrow \text{fim}$:

$$G_1 = 0 + \gamma \cdot 0 + \gamma^2 \cdot 0 + \gamma^3 \cdot 1 = \gamma^3 \quad (\text{a partir de } s_3)$$

$$G_2 = 0 + \gamma \cdot 0 + \gamma^2 \cdot 1 = \gamma^2 \quad (1^{\text{a}} \text{ visita a } s_2)$$

$$G_3 = 0 + \gamma \cdot 1 = \gamma \quad (2^{\text{a}} \text{ visita a } s_2)$$

$$G_4 = 1 \quad (\text{a partir de } s_1)$$

► **Primeira visita:** só G_2 conta para s_2 : $V(s_2) = \gamma^2$

► **Toda visita:** média de G_2 e G_3 : $V(s_2) = \frac{\gamma^2 + \gamma}{2}$

Além disso: $V(s_3) = \gamma^3$, $V(s_1) = 1$, e os estados nunca visitados (s_4 a s_7) permanecem na inicialização.

MC incremental: a mesma média, sem guardar somas

A média pode ser atualizada amostra a amostra. Ao visitar s e observar o retorno $G_{i,t}$, com $N(s) \leftarrow N(s) + 1$:

$$V^\pi(s) = V^\pi(s) \frac{N(s) - 1}{N(s)} + \frac{G_{i,t}}{N(s)} = V^\pi(s) + \frac{1}{N(s)} (G_{i,t} - V^\pi(s))$$

Generalizando $\frac{1}{N(s)}$ para uma taxa de aprendizado α :

$$V^\pi(s_{i,t}) = V^\pi(s_{i,t}) + \alpha (G_{i,t} - V^\pi(s_{i,t}))$$

Intuição

Este é o molde de quase tudo que vem pela frente no curso: $\text{estimativa} \leftarrow \text{estimativa} + \alpha (\text{alvo} - \text{estimativa})$, com uma *taxa de aprendizado* α e um *alvo*. Muda-se o alvo, nasce um algoritmo novo.

Interlúdio estatístico: como julgar um estimador?

Modelo estatístico com parâmetro θ gera dados $x \sim P(x \mid \theta)$; um estimador $\hat{\theta} = \hat{\theta}(x)$ tenta recuperar θ .

Definição — Viés, variância e EQM

$$\text{Viés}(\hat{\theta}) = \mathbb{E}_{x|\theta}[\hat{\theta}] - \theta$$

$$\text{Var}(\hat{\theta}) = \mathbb{E}_{x|\theta}[(\hat{\theta} - \mathbb{E}[\hat{\theta}])^2]$$

$$\text{EQM}(\hat{\theta}) = \text{Var}(\hat{\theta}) + \text{Viés}(\hat{\theta})^2$$

Definição — Estimador consistente

Com n amostras e estimativa $\hat{\theta}_n$: para todo $\epsilon > 0$, $\lim_{n \rightarrow \infty} \mathbb{P}(|\hat{\theta}_n - \theta| > \epsilon) = 0$.

Viés zero implica consistência?

Teste sua compreensão

Se um estimador é não-viesado ($\text{viés} = 0$), ele é necessariamente consistente?

Pergunta para discussão conduzida em aula.

Viés zero implica consistência?

Teste sua compreensão

Se um estimador é não-viesado (viés = 0), ele é necessariamente consistente?

Pergunta para discussão conduzida em aula.

Resposta

Não. Exemplo: estimar a média de uma Gaussiana usando *apenas a primeira* observação, $\hat{\theta}_n = x_1$. É não-viesado ($\mathbb{E}[x_1] = \theta$), mas ignora os demais dados — a distribuição do erro não encolhe quando $n \rightarrow \infty$. Consistência exige que o estimador *aproveite* os dados novos.

Intuição

Viés e variância medem coisas diferentes: viés é “mirar no lugar errado”; variância é “tremar a mão”. O EQM cobra os dois.

Propriedades dos estimadores MC

- ▶ **Primeira visita:** estimador **não-viesado** de $\mathbb{E}_\pi[G_t \mid s_t = s]$. Pela lei dos grandes números, $V^\pi(s) \rightarrow \mathbb{E}_\pi[G_t \mid s_t = s]$ quando $N(s) \rightarrow \infty$.
- ▶ **Toda visita:** **viesado** (amostras correlacionadas dentro do episódio), porém **consistente** — e com frequência tem EQM *menor* na prática.
- ▶ **Incremental:** as propriedades dependem da taxa α .

Condições de convergência (Robbins–Monro)

Permitindo α variar por atualização ($\alpha_n(s_j)$ na n -ésima atualização do estado s_j), o MC incremental converge para $V^\pi(s_j)$ se

$$\sum_{n=1}^{\infty} \alpha_n(s_j) = \infty \quad \text{e} \quad \sum_{n=1}^{\infty} \alpha_n^2(s_j) < \infty.$$

Limitações do Monte Carlo

Atenção

O retorno G_t acumula a aleatoriedade de *todas* as ações, transições e recompensas até o fim do episódio: o estimador MC tem, em geral, **variância alta**.

- ▶ Reduzir essa variância pode exigir *muitos* dados — impraticável quando coletar dados é caro, lento ou arriscado (medicina, robôs físicos, educação).
- ▶ Exige cenário **episódico**: o episódio precisa *terminar* antes de qualquer atualização.
- ▶ Nada de tarefas contínuas / horizonte infinito.

Resumo: Monte Carlo

- ▶ Estima a esperança $V^\pi(s) = \mathbb{E}_\pi[G_t \mid s_t = s]$ por média empírica de retornos, com episódios amostrados de π .
- ▶ Simples; não requer modelo; **não assume Markov**.
- ▶ Converge para o valor verdadeiro sob hipóteses brandas.
- ▶ Às vezes é preferível à programação dinâmica *mesmo com o modelo em mãos* — por exemplo, quando $\mathcal{S}$ é gigantesco e só nos interessam alguns estados, ou quando o estado não é Markoviano.

SEÇÃO 3

Aprendizagem por Diferença Temporal

03

A ideia central do RL

Sutton e Barto apontam a aprendizagem por diferença temporal (TD) como a ideia mais central e original de toda a aprendizagem por reforço.

- ▶ Combinação de Monte Carlo (**amostra** do ambiente) com programação dinâmica (**bootstrapping**).
- ▶ Livre de modelo.
- ▶ Funciona em cenários episódicos e de horizonte infinito.
- ▶ Atualiza V **imediatamente** após cada tupla (s, a, r, s') — não espera o episódio acabar.

Intuição

O MC espera o fim do episódio para saber “quanto valeu”. O TD não espera: usa a recompensa de um passo e o *próprio palpite* sobre o estado seguinte como substituto do resto do futuro.

Do MC ao TD em uma linha

Atualização do MC incremental (alvo = retorno completo $G_{i,t}$):

$$V^\pi(s) = V^\pi(s) + \alpha (G_{i,t} - V^\pi(s))$$

Mas $G_t = r_t + \gamma G_{t+1}$, e $\mathbb{E}[G_{t+1}]$ é o valor do próximo estado... que já estamos estimando! Troque o futuro observado pela estimativa atual:

$$V^\pi(s_t) = V^\pi(s_t) + \alpha (r_t + \gamma V^\pi(s_{t+1}) - V^\pi(s_t))$$

Definição — Alvo TD e erro TD

O **alvo TD** é $r_t + \gamma V^\pi(s_{t+1})$; o **erro TD** é

$$\delta_t = r_t + \gamma V^\pi(s_{t+1}) - V^\pi(s_t).$$

A atualização é simplesmente $V^\pi(s_t) \leftarrow V^\pi(s_t) + \alpha \delta_t$.

Algoritmo TD(0)

Algoritmo – TD(0), ou TD de 1 passo

- ▶ Entrada: taxa de aprendizado α
 - ▶ Inicialize $V^\pi(s) = 0$ para todo $s \in \mathcal{S}$
 - ▶ Repita:
 - Amostre uma tupla (s_t, a_t, r_t, s_{t+1}) executando π
 - $V^\pi(s_t) \leftarrow V^\pi(s_t) + \alpha \underbrace{(r_t + \gamma V^\pi(s_{t+1}) - V^\pi(s_t))}_{\text{alvo TD}}$
- ▶ Cada tupla é usada uma vez, na hora — não é preciso armazenar episódios nem esperar que terminem.
 - ▶ Por isso serve para tarefas contínuas, sem estados terminais.
 - ▶ O “(0)” indica olhar 1 passo à frente; há uma família inteira, TD(λ), interpolando entre TD(0) e Monte Carlo.

Exemplo resolvido: TD no Mars Rover

Mesmo cenário: $R = [+1, 0, 0, 0, 0, 0, +10]$, $\pi(s) = a_1$ para todo s , e s_1, s_7 terminam o episódio. Mesma trajetória, processada agora tupla a tupla, com $\alpha = 1$ e V inicializado em zero:



1. $(s_3, 0, s_2)$: $V(s_3) \leftarrow 0 + \gamma \cdot 0 = 0$
2. $(s_2, 0, s_2)$: $V(s_2) \leftarrow 0 + \gamma \cdot 0 = 0$
3. $(s_2, 0, s_1)$: $V(s_2) \leftarrow 0 + \gamma \cdot 0 = 0$
4. $(s_1, +1, \top)$: $V(s_1) \leftarrow 1 + \gamma \cdot 0 = 1$

Resultado: $V = [1, 0, 0, 0, 0, 0, 0]$.

MC e TD divergem — no mesmo episódio!

Para a mesma trajetória (tomando $\gamma = 1$ para simplificar):

	$V(s_1)$	$V(s_2)$	$V(s_3)$
MC (primeira visita)	1	1	1
TD(0), $\alpha = 1$	1	0	0

- ▶ O MC propaga o desfecho $+1$ **para trás**, a todos os estados visitados no episódio.
- ▶ O TD(0) usa cada tupla **uma única vez**: quando s_2 foi atualizado, $V(s_1)$ ainda era 0 — a notícia não teve tempo de se propagar.
- ▶ Com mais episódios (ou repassando os dados), o TD também propaga a informação; a diferença é a *velocidade com que cada dado influencia* a estimativa.

Teste sua compreensão: o papel de α

Teste sua compreensão

Quais afirmações sobre o TD(0) são verdadeiras?

1. Com $\alpha = 0$, o alvo TD pesa mais que a estimativa antiga.
2. Com $\alpha = 1$, a estimativa é substituída pelo alvo TD.
3. Com $\alpha = 1$, em estados com vários sucessores possíveis, V pode oscilar para sempre.
4. Há MDPs determinísticos em que o TD com $\alpha = 1$ converge.

Pergunta para discussão conduzida em aula.

Teste sua compreensão: o papel de α

Teste sua compreensão

Quais afirmações sobre o TD(0) são verdadeiras?

1. Com $\alpha = 0$, o alvo TD pesa mais que a estimativa antiga.
2. Com $\alpha = 1$, a estimativa é substituída pelo alvo TD.
3. Com $\alpha = 1$, em estados com vários sucessores possíveis, V pode oscilar para sempre.
4. Há MDPs determinísticos em que o TD com $\alpha = 1$ converge.

Pergunta para discussão conduzida em aula.

Resposta

2, 3 e 4. Com $\alpha = 0$ nada é atualizado (1 é falsa); com $\alpha = 1$ a estimativa vira o alvo (2); alvo estocástico faz V quicar (3); alvo determinístico é fixo e converge (4).

Resumo: Diferença Temporal

- ▶ Amostra do ambiente (como MC) e faz bootstrapping (como PD).
- ▶ Livre de modelo; serve para cenários episódicos e contínuos.
- ▶ Atualiza a cada tupla (s, a, r, s') — aprendizado *online*.
- ▶ Estimador **viesado**: no começo, o alvo depende da inicialização de V .
- ▶ Em geral, variância **bem menor** que a do MC: o alvo TD contém uma única ação, recompensa e transição aleatórias, e não a sequência inteira.
- ▶ Consistente se α satisfaz as condições de Robbins–Monro (as mesmas do MC incremental).

SEÇÃO 4

Equivalência de certeza

04

E se estimássemos o modelo?

Terceira via, *baseada em modelo*: aprender $\hat{P}$ e $\hat{r}$ dos dados e **planejar** como se fossem verdadeiros.

Definição — Modelo de máxima verossimilhança (contagens)

Para cada par (s, a) com $N(s, a)$ visitas até agora:

$$\hat{P}(s' \mid s, a) = \frac{\# \{(s, a) \rightarrow s'\}}{N(s, a)}, \quad \hat{r}(s, a) = \frac{\text{soma das recompensas de } (s, a)}{N(s, a)}.$$

Algoritmo — Avaliação por equivalência de certeza

- ▶ A cada tupla (s, a, r, s') : atualize contagens e modelo $(\hat{P}, \hat{r})$
- ▶ Calcule V^π no MDP estimado com qualquer método de PD da aula 2 (*inicializar todos os pares (s, a)*)

Equivalência de certeza: custo e propriedades

- ▶ **Custo alto:** replanejar a cada atualização custa $O(|\mathcal{S}|^3)$ pela solução matricial analítica, ou $O(|\mathcal{S}|^2|\mathcal{A}|)$ por iteração dos métodos iterativos.
- ▶ **Eficiência estatística excelente:** cada tupla melhora o modelo inteiro, e o planejamento espreme toda a informação disponível.
- ▶ **Consistente** quando o processo é de fato Markoviano.
- ▶ Estende-se com naturalidade à avaliação *off-policy*: o modelo estimado não depende de qual política gerou os dados.

Intuição

O nome diz tudo: tratamos a estimativa *como se tivéssemos certeza dela*. Muito eficiente com poucos dados; muito caro em computação — o oposto exato do TD.

Exemplo resolvido: equivalência de certeza no Mars Rover

Mesma trajetória: $(s_3, a_1, 0, s_2, a_1, 0, s_2, a_1, 0, s_1, a_1, +1, \text{terminal})$

Modelo estimado por contagens:

- ▶ $\hat{r} = [+1, 0, 0, 0, 0, 0, 0]$ (só vimos recompensas em s_1, s_2, s_3)
- ▶ $\hat{p}(s_2 \mid s_3, a_1) = 1$; $\hat{p}(\text{terminal} \mid s_1, a_1) = 1$
- ▶ s_2 : duas visitas, uma ficou e outra desceu $\Rightarrow \hat{p}(s_2 \mid s_2, a_1) = \hat{p}(s_1 \mid s_2, a_1) = \frac{1}{2}$

Planejando no modelo (resolvendo $V = \hat{r} + \gamma \hat{P}V$):

$$V(s_1) = 1$$

$$V(s_2) = \gamma \left(\frac{1}{2} V(s_2) + \frac{1}{2} V(s_1) \right) \Rightarrow V(s_2) = \frac{\gamma}{2-\gamma} \quad V(s_3) = \gamma V(s_2) = \frac{\gamma^2}{2-\gamma}$$

Note: **um único episódio** já deu estimativas não-nulas aos três estados — nenhum dos métodos anteriores conseguiu isso.

SEÇÃO 5

Avaliação em lote

05

O cenário em lote (*batch*)

Até aqui, os dados chegavam em fluxo. Agora suponha um conjunto **fixo e finito** de K episódios coletados sob π :

$$\{ s_{k,1}, a_{k,1}, r_{k,1}, \dots, s_{k,T_k} \}_{k=1}^K$$

- ▶ Regime típico quando coletar dados novos é caro ou arriscado (prontuários médicos, logs de um sistema em produção).
- ▶ Ideia: **repassar** os mesmos episódios várias vezes, aplicando MC ou TD(0) até as estimativas estabilizarem.

Teste sua compreensão

Repassando os mesmos dados infinitas vezes, MC e TD(0) convergem para a *mesma* resposta?

Pergunta para discussão conduzida em aula.

Um exemplo minúsculo que separa MC de TD

Dois estados, A e B ; sem desconto ($\gamma = 1$); **8 episódios** observados:

1 episódio $A, 0, B, 0$, fim

6 episódios $B, 1$, fim

1 episódio $B, 0$, fim

Exercício — o que os dados dizem?

No regime em lote, quais os valores de $V(B)$ e de $V(A)$?

Um exemplo minúsculo que separa MC de TD

Dois estados, A e B ; sem desconto ($\gamma = 1$); **8 episódios** observados:

1 episódio	$A, 0, B, 0$, fim
6 episódios	$B, 1$, fim
1 episódio	$B, 0$, fim

Exercício — o que os dados dizem?

No regime em lote, quais os valores de $V(B)$ e de $V(A)$?

Resposta

$V(B) = \frac{6}{8} = 0,75$ — MC e TD concordam. Para $V(A)$, eles **discordam**: MC responde 0; TD(0) responde 0,75.

Por que discordam — e o que cada um “acredita”

Monte Carlo. Só há *um* retorno observado a partir de A , e ele valeu 0. Logo $V(A) = 0$: o MC ajusta-se aos **retornos que aconteceram**.

TD(0). Nos dados, A sempre levou a B com $r = 0$; então $V(A) = 0 + \gamma V(B) = 0,75$: o TD **acredita na estrutura de Markov** e generaliza via B .

Para onde cada método converge no lote

- ▶ **MC:** valores que minimizam o erro quadrático médio sobre os retornos observados.
- ▶ **TD(0):** V^π do MDP de máxima verossimilhança dos dados — a solução da **equivalência de certeza**.

Intuição

Se o mundo é mesmo Markoviano, a resposta do TD aproveita melhor os dados; se não é, a do MC é a mais honesta.

O modelo que o TD constrói sem querer

MDP de máxima verossimilhança estimado a partir dos 8 episódios



- ▶ Das 8 trajetórias, a única que passou por A foi para B com recompensa 0 $\Rightarrow \hat{p}(B | A) = 1, \hat{r}(A) = 0$.
- ▶ De B , seis vezes a recompensa foi 1 e duas vezes foi 0 $\Rightarrow \hat{r}(B) = 6/8 = 0,75$.
- ▶ Planejar nesse modelo dá $V(A) = 0 + \gamma V(B) = 0,75$ — **exatamente a resposta do TD(0) em lote.**

Intuição

O TD nunca escreve $\hat{P}$ nem $\hat{r}$ na memória, mas converge para a mesma resposta que a equivalência de certeza daria. É o preço e o prêmio de assumir Markov.

SEÇÃO 6

Comparando os métodos

06

Viés e variância dos alvos

Alvo	Viés	Variância
Retorno G_t (MC)	nenhum (1ª visita)	alta: episódio inteiro é aleatório
$r_t + \gamma V^\pi(s_{t+1})$ (TD)	sim (depende de V^π atual)	baixa: 1 passo aleatório


- ▶ **MC:** não-viesado (primeira visita), variância alta, consistente — *inclusive* com aproximação de função.
- ▶ **TD(0):** viesado, variância menor; converge para V^π na representação tabular, mas **pode não convergir com aproximação de função** (tema de aulas futuras).

Intuição

É o dilema viés-variância clássico, vestido de RL: o TD aceita um pouco de viés em troca de aprender mais rápido e com menos ruído.

Um mapa para os três métodos

Quantos futuros cada atualização considera (largura) $\times$ até onde ela olha antes de usar uma estimativa (profundidade)



A equivalência de certeza vive perto da PD: estima a esperança completa — mas num modelo aprendido dos dados.

Tabela comparativa

	MC	TD(0)	Equiv. certeza
Precisa de modelo?	não	não	não (estima um)
Faz bootstrapping?	não	sim	sim (via PD)
Exige episódios finitos?	sim	não	não
Assume Markov?	não	sim	sim
Viés	zero (1ª visita)	sim	sim (com poucos dados)
Variância	alta	baixa	baixa
Custo por atualização	baixo	baixíssimo	alto
Eficiência estatística	baixa	média	alta
Avaliação off-policy direta?	não	não	sim

Atenção

Não existe vencedor absoluto: a escolha depende de qual recurso é escasso — dados, computação ou memória — e de o estado ser Markoviano.

O que levamos desta aula

- ▶ Avaliação de política **sem modelo**: substituímos esperanças por *amostras* (MC), por *amostra + bootstrapping* (TD), ou por um *modelo estimado* (equivalência de certeza).
- ▶ O molde universal $\text{estimativa} \leftarrow \text{estimativa} + \alpha(\text{alvo} - \text{estimativa})$ reaparecerá na aula que vem — trocando V por Q e avaliação por **controle**.
- ▶ Viés, variância, consistência e custo computacional são a régua para comparar métodos — memorize a tabela.

Próxima aula: controle sem modelo — SARSA e Q-learning.

Material adaptado de Emma Brunskill, *CS234: Reinforcement Learning* (Stanford). Estrutura relacionada à aula 4 de David Silver; leituras em Sutton & Barto, seções 5.1, 5.5 e 6.1–6.3.

MATERIAL EXTRA

Exercícios opcionais

Exercício: MC incremental e suas variantes

Exercício — verdadeiro ou falso

Considere o MC incremental $V^\pi(s_{i,t}) \leftarrow V^\pi(s_{i,t}) + \alpha (G_{i,t} - V^\pi(s_{i,t}))$.

1. Com $\alpha = 1$, o MC incremental equivale ao MC de primeira visita.
2. Com $\alpha = \frac{1}{N(s_{i,t})}$, equivale ao MC de toda visita.
3. Usar $\alpha > \frac{1}{N(s_{i,t})}$ pode ajudar em domínios não-estacionários.

Exercício: MC incremental e suas variantes

Exercício — verdadeiro ou falso

Considere o MC incremental $V^\pi(s_{i,t}) \leftarrow V^\pi(s_{i,t}) + \alpha (G_{i,t} - V^\pi(s_{i,t}))$.

1. Com $\alpha = 1$, o MC incremental equivale ao MC de primeira visita.
2. Com $\alpha = \frac{1}{N(s_{i,t})}$, equivale ao MC de toda visita.
3. Usar $\alpha > \frac{1}{N(s_{i,t})}$ pode ajudar em domínios não-estacionários.

Resposta

(1) Falso. Com $\alpha = 1$ a estimativa vira o *último* retorno observado — não a média, e todas as visitas atualizam. **(2) Verdadeiro.** É exatamente a média incremental sobre todas as visitas. **(3) Verdadeiro.** Pesos maiores para dados recentes permitem “esquecer” um passado que já não descreve o ambiente.

Exercício: complete o quadro do Mars Rover

Exercício — os três métodos lado a lado

Para a trajetória $(s_3, a_1, 0, s_2, a_1, 0, s_2, a_1, 0, s_1, a_1, +1, \text{terminal})$, com V inicializado em zero:

1. Verifique as estimativas de primeira visita com $\gamma = 1$: $V = [1, 1, 1, 0, 0, 0, 0]$.
2. Verifique o TD(0) com $\alpha = 1$: $V = [1, 0, 0, 0, 0, 0, 0]$.
3. Refaça a conta da equivalência de certeza resolvendo $V = (I - \gamma \hat{P})^{-1} \hat{r}$ restrita aos estados $\{s_1, s_2, s_3, \text{terminal}\}$ e confirme $V(s_2) = \gamma/(2 - \gamma)$.

Intuição

Repare no contraste: o TD usou cada tupla uma vez e propagou pouco; o MC propagou o desfecho para todo o episódio; a equivalência de certeza extraiu o máximo — ao preço de inverter uma matriz.