

Aula 3 — Avaliação de política sem modelo

Como estimar V^π quando não conhecemos a dinâmica P nem a recompensa R • Monte Carlo, Diferença Temporal e Equivalência de certeza

Prof. Marcelo Keese Albertini • Universidade Federal de Uberlândia • adaptado de E. Brunskill, CS234 (Stanford)

O problema

Na aula passada conhecíamos P e R e resolvíamos Bellman por programação dinâmica. Agora temos apenas **experiência**: episódios gerados pela própria política π que queremos avaliar.

$$V^\pi(s) = \mathbb{E}_\pi[G_t \mid s_t = s], \quad G_t = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \dots$$

Intuição

Toda a aula é uma única pergunta: como substituir a *esperança* (que exige o modelo) por algo calculável a partir de *amostras*? Três respostas diferentes geram três algoritmos.

Com o modelo, a PD faz $V_k^\pi(s) = R(s, \pi(s)) + \gamma \sum_{s'} P(s' \mid s, \pi(s)) V_{k-1}^\pi(s')$. Trocar o futuro verdadeiro por uma *estimativa* dele chama-se **bootstrapping** — é o que separa TD de MC.

1. Monte Carlo (MC)

Ideia: valor é uma esperança, e esperanças se estimam com médias. Rode π até o fim do episódio, anote o retorno obtido a partir de cada estado visitado e tire a média.

Algoritmo — MC de primeira visita

Para cada episódio, com $G_{i,t}$ o retorno a partir do passo t : se t é a *primeira* visita a s no episódio i , faça $N(s) \leftarrow N(s) + 1$, $G(s) \leftarrow G(s) + G_{i,t}$ e $V^\pi(s) = G(s)/N(s)$.

Toda visita: idêntico, mas *toda* ocorrência de s no episódio conta. **Incremental:** a mesma média, escrita passo a passo,

$$V^\pi(s) \leftarrow V^\pi(s) + \alpha(G_{i,t} - V^\pi(s)),$$

com $\alpha = 1/N(s)$ recuperando exatamente a média de toda visita.

- ▶ Não precisa de modelo e **não assume Markov**.
- ▶ Primeira visita: *não-viesado*. Toda visita: viesado (amostras do mesmo episódio são correlacionadas), porém consistente e muitas vezes com EQM menor.
- ▶ **Variância alta** — G_t acumula o acaso do episódio inteiro.
- ▶ Só serve para tarefas **episódicas**: é preciso esperar o fim.

2. Diferença temporal — TD(0)

Ideia: não espere o fim. Como $G_t = r_t + \gamma G_{t+1}$ e já temos um palpite para o valor do próximo estado, use-o no lugar do futuro observado.

Definição — Alvo TD e erro TD

$$V^\pi(s_t) \leftarrow V^\pi(s_t) + \alpha \underbrace{(r_t + \gamma V^\pi(s_{t+1}) - V^\pi(s_t))}_{\text{alvo TD}},$$
$$\delta_t = r_t + \gamma V^\pi(s_{t+1}) - V^\pi(s_t).$$

- ▶ Atualiza a cada tupla (s, a, r, s') : aprendizado *online*, sem esperar o episódio e sem precisar que ele termine.
- ▶ **Amostra** (como MC) e **faz bootstrapping** (como PD).
- ▶ Viesado no começo (depende da inicialização), mas com **variância bem menor**: o alvo tem uma única transição aleatória.
- ▶ Tabular: converge para V^π . Com aproximação de função, pode não convergir.

Atenção

α é o botão do dilema: grande demais, V oscila em torno do alvo e nunca assenta; pequeno demais, demora a sair do valor inicial.

3. Equivalência de certeza

Ideia: se falta o modelo, estime-o e planeje nele *como se fosse verdadeiro*. Por contagens (máxima verossimilhança):

$$\hat{P}(s' | s, a) = \frac{\#\{(s, a) \rightarrow s'\}}{N(s, a)}, \quad \hat{r}(s, a) = \frac{\sum r \text{ em } (s, a)}{N(s, a)},$$

e resolve-se $V = \hat{r} + \gamma \hat{P}V$ por qualquer método da aula 2.

- ▶ **Muito eficiente em dados:** cada tupla melhora o modelo inteiro, e o planejamento espreme toda a informação disponível.
- ▶ **Muito cara em computação:** $O(|\mathcal{S}|^3)$ na solução matricial, $O(|\mathcal{S}|^2|\mathcal{A}|)$ por iteração nos métodos iterativos.
- ▶ Consistente se o processo é de fato Markoviano; estende-se naturalmente à avaliação *off-policy*.

4. Avaliação em lote

Com um conjunto **fixo** de K episódios, repassados infinitas vezes:

Para onde cada método converge

- ▶ **MC:** os valores que minimizam o erro quadrático sobre os *retornos observados*.
- ▶ **TD(0):** o V^π do MDP de máxima verossimilhança — exatamente a resposta da equivalência de certeza.

Exemplo A–B (Sutton & Barto, ex. 6.4). Dois estados, $\gamma = 1$, 8 episódios: $(A, 0, B, 0)$ uma vez; $(B, 1)$ seis vezes; $(B, 0)$ uma vez.

	$V(B)$	$V(A)$
Monte Carlo	0,75	0
TD(0) em lote	0,75	0,75

O MC vê um único retorno a partir de A , e ele valeu 0. O TD nota que A sempre levou a B com $r = 0$ e conclui $V(A) = \gamma V(B)$.

Intuição

Se o mundo é mesmo Markoviano, a resposta do TD aproveita melhor os dados. Se não é, a do MC é a mais honesta.

Tabela comparativa

	Monte Carlo	TD(0)	Equiv. de certeza
Precisa do modelo?	não	não	não (estima um)
Faz bootstrapping?	não	sim	sim (via PD)
Exige episódios finitos?	sim	não	não
Assume Markov?	não	sim	sim
Viés	zero (1ª visita)	sim, sobretudo no início	sim, com poucos dados
Variância	alta	baixa	baixa
Quando atualiza	fim do episódio	a cada transição	a cada transição
Custo por atualização	baixo	baixíssimo	alto
Eficiência em dados	baixa	média	alta
Off-policy direto?	não	não	sim

Não há vencedor absoluto: a escolha depende de qual recurso é escasso — dados, computação ou memória — e de o estado ser ou não Markoviano.

Exemplo numérico — Mars Rover



$R = [+1, 0, 0, 0, 0, 0, +10]$; s_1 e s_7 encerram o episódio; $\pi(s) = a_1$ para todo s . Trajetória observada, com $\gamma < 1$:

$(s_3, a_1, 0, s_2, a_1, 0, s_2, a_1, 0, s_1, a_1, +1, \text{fim})$

Retornos. $G_1 = \gamma^3$ (de s_3), $G_2 = \gamma^2$ (1ª visita a s_2), $G_3 = \gamma$ (2ª visita), $G_4 = 1$ (de s_1).

	$V(s_1)$	$V(s_2)$	$V(s_3)$
MC 1ª visita	1	γ^2	γ^3
MC toda visita	1	$\frac{\gamma^2 + \gamma}{2}$	γ^3
TD(0), $\alpha = 1$	1	0	0
Equiv. certeza	1	$\frac{\gamma}{2 - \gamma}$	$\frac{\gamma^2}{2 - \gamma}$

Por que o TD zera s_2 e s_3 ? Cada tupla é usada uma única vez: quando s_2 foi atualizado, $V(s_1)$ ainda valia 0 — a informação não teve tempo de se propagar para trás. **E por que a equivalência de certeza acerta os três?** Ela estimou $\hat{p}(s_2 | s_2) = \hat{p}(s_1 | s_2) = \frac{1}{2}$ e resolveu Bellman nesse modelo, extraíndo de um único episódio muito mais que os outros dois.

Convergência

Condições de Robbins–Monro

Tanto o MC incremental quanto o TD(0) convergem para $V^\pi(s)$ se a taxa de aprendizado satisfizer

$$\sum_{n=1}^{\infty} \alpha_n(s) = \infty \quad \text{e} \quad \sum_{n=1}^{\infty} \alpha_n^2(s) < \infty.$$

Vocabulário estatístico. Para um estimador $\hat{\theta}$: viés = $\mathbb{E}[\hat{\theta}] - \theta$; EQM = $\text{Var}(\hat{\theta}) + \text{viés}^2$; e $\hat{\theta}_n$ é *consistente* se $\mathbb{P}(|\hat{\theta}_n - \theta| > \epsilon) \rightarrow 0$ para todo $\epsilon > 0$. Não-viesado **não** implica consistente: estimar a média usando só a primeira observação é não-viesado e nunca melhora.

Para revisar

1. Por que o MC de toda visita é viesado, se ele também é uma média de retornos?
2. O que acontece com o TD(0) se $\alpha = 1$ e o estado tem mais de um sucessor possível? E se o MDP for determinístico?
3. Em que situação você preferiria o MC *mesmo conhecendo* o modelo verdadeiro?
4. No exemplo A–B, qual das duas respostas para $V(A)$ você defenderia se soubesse que o estado *não* é Markoviano?
5. Por que a equivalência de certeza serve para avaliação *off-policy* e o TD(0), na forma vista aqui, não?

Vocabulário para ler a literatura em inglês

Português	Inglês	Português	Inglês
avaliação de política	policy evaluation	alvo	target
sem modelo	model-free	taxa de aprendizado	learning rate
retorno	return	erro TD	TD error
fator de desconto	discount factor	em lote	batch
primeira visita	first-visit	viés–variância	bias–variance
toda visita	every-visit	estimador consistente	consistent estimator
bootstrapping	bootstrapping	erro quadrático médio	mean squared error
equivalência de certeza	certainty equivalence	dentro da política	on-policy
máxima verossimilhança	maximum likelihood	fora da política	off-policy

“Backup” e “bootstrapping” são mantidos em inglês por serem consagrados na literatura em português.

Leitura. Sutton & Barto, seções 5.1, 5.5 e 6.1–6.3. David Silver, aula 4 (*Model-Free Prediction*). **Próxima aula:** controle sem modelo — SARSA e Q-learning.