

Universidade Federal de Uberlândia

Aula 4: Controle sem modelo e aproximação de função valor

MC/TD em lote • ϵ -guloso e GLIE • SARSA e Q-learning • VFA • DQN

Prof. Marcelo Keese Albertini
Universidade Federal de Uberlândia
adaptado de Emma Brunskill, CS234 (Stanford)

2026



Plano de hoje

A aula em que o agente deixa de observar e passa a decidir

1. **Avaliação de política em lote** — o que MC e TD calculam quando os dados acabam.
2. **Melhoria de política generalizada** — Q e não V ; explorar sem perder a melhoria monotônica.
3. **Controle tabular sem modelo** — MC com ϵ -guloso, GLIE, SARSA e Q-learning.
4. **Aproximação de função valor** — abandonar a tabela para *generalizar*.
5. **Deep Q-Learning** — o que faltava para funcionar em Atari.

Intuição

Fio condutor: mesma linha de código, $estimativa \leftarrow estimativa + \alpha (alvo - estimativa)$, com quatro escolhas de *alvo*.

Onde estamos

Duas dimensões: temos o modelo? queremos avaliar ou decidir?

	Avaliar π (predição)	Escolher π (controle)
Com modelo	Avaliação de política (Aula 2)	Iteração de política / de valor (Aula 2)
Sem modelo	MC, TD(0) (Aula 3)	MC-controle, SARSA, Q-learning (hoje)

- ▶ Até aqui, tudo **tabular**: uma entrada por estado (ou por par estado-ação).
- ▶ Segunda metade quebra a hipótese: $|\mathcal{S}|$ grande demais para memória — quanto mais para visitar.

Recapitulação: os três estimadores da Aula 3

Estimar $V^\pi(s)$ executando π , sem conhecer P e R

- ▶ **Monte Carlo** — trajetória completa τ ; retorno observado G_t :

$$V^\pi(s) \leftarrow V^\pi(s) + \alpha(G_t(s) - V^\pi(s))$$

- ▶ **TD(0)** — tupla (s, a, r, s') ; *bootstrap* na própria estimativa:

$$V^\pi(s) \leftarrow V^\pi(s) + \alpha \underbrace{(r + \gamma V^\pi(s') - V^\pi(s))}_{\text{alvo TD}}$$

- ▶ **Equivalência de certeza** — estima $\hat{P}$ e $\hat{R}$ por máxima verossimilhança; PD sobre o MDP estimado.

Intuição

Os três já apareceram como *procedimentos*. Hoje: para *qual objeto* cada um converge com dados finitos e reciclados?

SEÇÃO 1

Avaliação de política em lote

01

Do fluxo para o lote

Batch (ou *offline*): o conjunto de dados é fixo

- ▶ Antes: cada tupla (s, a, r, s') usada **uma vez** e descartada.
- ▶ Em lote: K episódios armazenados, reprocessáveis à vontade.

Algoritmo — Avaliação de política em lote

- 1: Dado o conjunto fixo de K episódios
- 2: **repita** até convergir
- 3: amostre um episódio $k \sim \{1, \dots, K\}$
- 4: aplique a atualização de MC (ou de TD(0)) a esse episódio
- 5: **fim**

O exemplo A-B

Sutton & Barto (2018), Exemplo 6.4 — dois estados, $\gamma = 1$

Oito episódios observados:

Episódio	Frequência
$A, 0, B, 0$	1 vez
$B, 1$	6 vezes
$B, 0$	1 vez

Cada episódio termina após a última recompensa. A aparece **uma única vez** na base.

Definição

Estimativa a partir de B : em 8 visitas houve recompensa 1 em 6 delas, logo $V(B) = 6/8 = 0,75$ tanto por MC quanto por TD.

Teste sua compreensão

E $V(A)$? Rodando as atualizações sobre esses dados um número infinito de vezes, para que valor cada método converge?

Pergunta para discussão conduzida em aula.

O exemplo A-B: as duas respostas


Não é um erro de um dos métodos — eles otimizam critérios diferentes

Resposta

$$V_{MC}(A) = 0 \quad V_{TD}(A) = 0,75$$

Monte Carlo. Único retorno de A :
 $G = 0 + 0 = 0$. MC minimiza o erro quadrático sobre retornos *observados* $\rightarrow 0$.

TD(0). Alvo $r + \gamma V(B) = 0,75$: encadeia a informação de B , mesmo com A uma vez só.



Intuição

MDP de **máxima verossimilhança** implícito nos dados; TD(0) em lote converge para o V^π dele — por isso $V(A) = 0,75$.

Para onde MC e TD convergem no cenário em lote

Monte Carlo em lote

Converge para os valores que **minimizam o erro quadrático médio** em relação aos retornos observados, $V = \arg \min_V \sum_{k,t} (G_{k,t} - V(s_{k,t}))^2$. No exemplo A-B: $V(A) = 0$.

TD(0) em lote

Converge para o V^π do MDP de máxima verossimilhança estimado dos dados — **idêntico à equivalência de certeza**:

$$\hat{P}(s' | s, a) = \frac{\sum_k \mathbf{1}\{s_k = s, a_k = a, s_{k+1} = s'\}}{N(s, a)}, \quad \hat{R}(s, a) = \frac{\sum_k \mathbf{1}\{s_k = s, a_k = a\} r_k}{N(s, a)}$$

No exemplo A-B: $V(A) = 0,75$.

Qual das duas respostas é “a certa”?

Depende inteiramente de acreditarmos, ou não, na hipótese de Markov

Intuição

Ambiente **markoviano** → TD certo: o que se aprende sobre B vale para *qualquer* caminho até B . TD usa a estrutura; MC a ignora.

Atenção

Ambiente **não-markoviano** (observação parcial) → TD propaga hipótese falsa. MC, só retornos completos, mais robusto — ao custo de variância.

MC correto *sem* supor Markov; TD supõe e, quando vale, converge com muito menos dados.

Teste sua compreensão

Com prontuários médicos incompletos, você confiaria mais em MC ou em TD? Por quê?

Cr terios para comparar algoritmos de avalia  o

Custo computacional

- ▶ TD(0): $O(1)$ por transi  o, $O(L)$ por epis dio.
- ▶ MC: $O(L)$, mas s  *depois* do fim do epis dio.
- ▶ Eq. de certeza: sistema linear a cada atualiza  o — muito mais caro.

Efici ncia de dados

- ▶ Markov (TD, eq. de certeza) extrai mais de cada amostra; MC, quando ela n o vale.

	MC	TD(0)	Eq. cert.
Usa Markov	n�o	sim	sim
Vi�s	n�o	sim	sim
Vari�ncia	alta	baixa	baixa
Epis�dio completo	sim	n�o	n�o
Custo/atualiz.	$O(1)$	$O(1)$	alto
Efici�ncia dados	baixa	m�dia	alta

Fecho da avaliação de política

Estimar o retorno esperado de uma π dada, sem o MDP verdadeiro

- ▶ **Monte Carlo** — dados *on-policy* ou *off-policy* (amostragem por importância).
- ▶ **Diferença temporal** — TD(0) e variantes.
- ▶ **PD com equivalência de certeza** — construir o modelo e resolvê-lo.

Definição — A régua que usaremos o curso inteiro

Supõe Markov? É consistente? Qual o viés e a variância? Quantos dados precisa? Quanto custa por atualização?

Intuição

Avaliação é metade do problema; agora *escolher* a política — e o obstáculo novo: dados sobre ações que a política atual **não** toma.

SEÇÃO 2

Melhoria de política generalizada

02

Iteração de política sem modelo


O mesmo esqueleto da Aula 2 — com três buracos

Algoritmo — Iteração de política generalizada

- 1: Inicialize π
- 2: **repita**
- 3: *Avaliação*: estime Q^π
- 4: *Melhoria*: atualize π a partir de Q^π
- 5: **fim**

Atenção

Três buracos: (1) π determinística $\rightarrow Q(s, a)$ com $a \neq \pi(s)$ nunca observado; (2) melhoria usa $\hat{Q}$ ruidoso; (3) quanto avaliar antes de melhorar?



converge para π^* e Q^*

Por que Q e não V

Uma consequência silenciosa de não ter o modelo

- ▶ Com modelo, melhoria gulosa a partir de V :

$$\pi'(s) = \arg \max_{a \in \mathcal{A}} \left[R(s, a) + \gamma \sum_{s'} P(s' | s, a) V(s') \right]$$

- ▶ Sem modelo, R e P desconhecidos — expressão inútil. Com Q :

$$\pi'(s) = \arg \max_{a \in \mathcal{A}} Q(s, a)$$

melhoria imediata, sem conhecimento da dinâmica.

Intuição

$Q = V$ com a *informação de um passo do modelo embutida*. Por isso praticamente todo controle sem modelo aprende Q .

O problema da exploração

O dilema que separa RL de aprendizado supervisionado

Explorar

- ▶ Aprender exige experimentar.
- ▶ Dados sobre a só existem se π der probabilidade positiva a a .

Gulosa pura sobre $\hat{Q}$ pode travar para sempre: primeira amostra de uma ação boa ruim por azar $\rightarrow$ nunca mais escolhida, nem corrigida.

Explotar

- ▶ Passo explorando = passo sem colher recompensa conhecida.
- ▶ Em saúde e educação, explorar tem custo real.

Teste sua compreensão

O rover tenta “ir para a direita”, recebe 0 por azar. O que faz uma política gulosa pura daí em diante?

Políticas ϵ -gulosas

A solução mais simples que funciona — e a mais usada na prática

Definição — Política ϵ -gulosa em relação a $Q(s, a)$

Seja $|\mathcal{A}|$ o número de ações e $\epsilon \in [0, 1]$. Então

$$\pi(a \mid s) = \begin{cases} 1 - \epsilon + \frac{\epsilon}{|\mathcal{A}|}, & \text{se } a = \arg \max_{a'} Q(s, a') \\ \frac{\epsilon}{|\mathcal{A}|}, & \text{caso contrário.} \end{cases}$$

- ▶ Toda ação com probabilidade $\geq \epsilon/|\mathcal{A}| > 0$ — exploração garantida.
- ▶ $\epsilon = 1$: passeio aleatório. $\epsilon = 0$: guloso puro.
- ▶ Alternativa: *softmax*, $\pi(a \mid s) \propto e^{Q(s,a)/\tau}$, que explora ações *quase* boas.

A melhoria monotônica sobrevive à exploração

- ▶ Aula 2: iteração de política com P e R conhecidos melhora monotonicamente — prova supunha política **determinística**.
- ▶ ϵ -gulosa é estocástica de propósito. A garantia se perde?

Teorema — melhoria monotônica ϵ -gulosa

Seja π_i uma política ϵ -gulosa qualquer e seja π_{i+1} a política ϵ -gulosa em relação a Q^{π_i} . Então

$$V^{\pi_{i+1}}(s) \geq V^{\pi_i}(s) \quad \forall s \in \mathcal{S}.$$

Intuição

Explorar *para sempre* sem nunca piorar; custo: o ótimo entre as ϵ -gulosas carrega o ϵ — resíduo que a condição GLIE elimina.

Prova da melhoria monotônica ϵ -gulosa

O truque é escrever o máximo como uma média ponderada disfarçada

$$\begin{aligned} Q^{\pi_i}(s, \pi_{i+1}(s)) &= \sum_{a \in \mathcal{A}} \pi_{i+1}(a | s) Q^{\pi_i}(s, a) \\ &= \frac{\epsilon}{|\mathcal{A}|} \sum_{a \in \mathcal{A}} Q^{\pi_i}(s, a) + (1 - \epsilon) \max_a Q^{\pi_i}(s, a) \\ &\geq \frac{\epsilon}{|\mathcal{A}|} \sum_{a \in \mathcal{A}} Q^{\pi_i}(s, a) + (1 - \epsilon) \underbrace{\sum_{a \in \mathcal{A}} \frac{\pi_i(a | s) - \epsilon/|\mathcal{A}|}{1 - \epsilon} Q^{\pi_i}(s, a)}_{\text{pesos } \geq 0, \text{ somam } 1} \\ &= \sum_{a \in \mathcal{A}} \pi_i(a | s) Q^{\pi_i}(s, a) = V^{\pi_i}(s). \end{aligned}$$

Desigualdade: máximo $\geq$ *qualquer* combinação convexa; pesos ≥ 0 pois π_i é ϵ -gulosa ($\pi_i(a | s) \geq \epsilon/|\mathcal{A}|$).

De $Q^{\pi_i}(s, \pi_{i+1}(s)) \geq V^{\pi_i}(s)$ segue $V^{\pi_{i+1}} \geq V^{\pi_i}$ (teorema de melhoria, Aula 2). ■

SEÇÃO 3

Controle tabular sem modelo

03

Monte Carlo para Q

A avaliação da Aula 3, com o par (s, a) no lugar de s

Algoritmo — Avaliação de política Monte Carlo para Q^π (primeira visita)

```
1: Inicialize  $Q(s, a) = 0$ ,  $N(s, a) = 0$  para todo  $(s, a)$ ;  $k = 1$ ; política  $\pi$ 
2: repita
3:   gere o  $k$ -ésimo episódio  $(s_{k,1}, a_{k,1}, r_{k,1}, \dots, s_{k,T})$  seguindo  $\pi$ 
4:   calcule  $G_{k,t} = r_{k,t} + \gamma r_{k,t+1} + \gamma^2 r_{k,t+2} + \dots$  para todo  $t$ 
5:   para  $t = 1, \dots, T$  faça
6:     se é a primeira visita a  $(s_t, a_t)$  no episódio  $k$  então
7:        $N(s_t, a_t) += 1$ 
8:        $Q(s_t, a_t) += \frac{1}{N(s_t, a_t)} (G_{k,t} - Q(s_t, a_t))$ 
9:     fim
10:  fim;  $k += 1$ 
11: fim
```

Controle Monte Carlo *on-policy*

Avaliar e melhorar a cada episódio, com ϵ decrescente

Algoritmo — Controle MC *on-policy* com ϵ -guloso

```
1: Inicialize  $Q(s, a) = 0$ ,  $N(s, a) = 0$  para todo  $(s, a)$ ;  $\epsilon = 1$ ;  $k = 1$   
2:  $\pi_k \leftarrow \epsilon\text{-guloso}(Q)$  // política inicial  
3: repita  
4:   gere o episódio  $k$  seguindo  $\pi_k$  e calcule os retornos  $G_{k,t}$   
5:   para  $t = 1, \dots, T$  faça  
6:     se primeira visita a  $(s_t, a_t)$  então  $N \leftarrow N + 1$ ;  $Q(s_t, a_t) \leftarrow \frac{1}{N(s_t, a_t)} (G_{k,t} + Q(s_t, a_t))$   
7:   fim  
8:    $k \leftarrow k + 1$ ;  $\epsilon \leftarrow 1/k$  // exploração decrescente  
9:    $\pi_k \leftarrow \epsilon\text{-guloso}(Q)$  // melhoria de política  
10: fim
```

Exemplo trabalhado: MC-controle no *Mars Rover*

Sete estados, duas ações, $\gamma = 1$



- ▶ Recompensas: $R(\cdot, a_1) = [1 \ 0 \ 0 \ 0 \ 0 \ 0 \ +10]$, $R(\cdot, a_2) = [0 \ 0 \ 0 \ 0 \ 0 \ 0 \ +5]$.
- ▶ Início: $Q(s, a) = 0$, $\pi(s) = a_1$, $\epsilon = 0,5$.
- ▶ Trajetória amostrada da ϵ -gulosa:

$$\tau = (s_3, a_1, 0, s_2, a_2, 0, s_3, a_1, 0, s_2, a_2, 0, s_1, a_1, 1, \perp)$$

Teste sua compreensão

Qual é a estimativa MC de primeira visita de Q para cada par (s, a) após essa única trajetória? E qual passa a ser a política gulosa?

Pergunta para discussão conduzida em aula.

Exemplo trabalhado: solução

Com $\gamma = 1$, todo retorno é a soma das recompensas até o fim

Resposta

- ▶ $Q(\cdot, a_1) = [1 \ 0 \ 1 \ 0 \ 0 \ 0 \ 0]$
- ▶ $Q(\cdot, a_2) = [0 \ 1 \ 0 \ 0 \ 0 \ 0 \ 0]$
- ▶ Nova política gulosa:
 $\pi = [a_1 \ a_2 \ a_1 \ \text{empate} \ \dots]$

Primeiras visitas antes da recompensa 1 em s_1 : com $\gamma = 1$, cada par recebe retorno 1.

Teste sua compreensão

Com $\epsilon = 1/3$ e $|\mathcal{A}| = 2$, qual a probabilidade de a nova política escolher a_1 em s_1 ?

Exemplo trabalhado: solução

Com $\gamma = 1$, todo retorno é a soma das recompensas até o fim

Resposta

- ▶ $Q(\cdot, a_1) = [1 \ 0 \ 1 \ 0 \ 0 \ 0 \ 0]$
- ▶ $Q(\cdot, a_2) = [0 \ 1 \ 0 \ 0 \ 0 \ 0 \ 0]$
- ▶ Nova política gulosa:
 $\pi = [a_1 \ a_2 \ a_1 \ \text{empate} \ \dots]$

Primeiras visitas antes da recompensa 1 em s_1 : com $\gamma = 1$, cada par recebe retorno 1.

Teste sua compreensão

Com $\epsilon = 1/3$ e $|\mathcal{A}| = 2$, qual a probabilidade de a nova política escolher a_1 em s_1 ?

Resposta

$$1 - \epsilon + \frac{\epsilon}{|\mathcal{A}|} = 1 - \frac{1}{3} + \frac{1}{6} = \frac{5}{6}.$$

Erro comum: responder $2/3$, esquecendo que a exploração uniforme também pode cair na ação gulosa.

Guloso no limite com exploração infinita (GLIE)

A condição que transforma “nunca piora” em “converge para o ótimo”

Definição — GLIE (*Greedy in the Limit with Infinite Exploration*)

Uma sequência de políticas $\{\pi_i\}$ é GLIE se

1. todo par (s, a) é visitado infinitas vezes, $\lim_{i \rightarrow \infty} N_i(s, a) \rightarrow \infty$;
2. a política de comportamento converge para a gulosa,
 $\lim_{i \rightarrow \infty} \pi_i(a \mid s) \rightarrow \arg \max_a Q(s, a)$ com probabilidade 1.

As duas condições puxam em direções opostas. **Estratégia GLIE mais simples:** ϵ -guloso com $\epsilon_i = 1/i - \sum_i 1/i$ diverge, $\epsilon_i \rightarrow 0$.

Teorema — convergência do controle MC com GLIE

O controle Monte Carlo GLIE converge para a função valor de ação ótima: $Q(s, a) \rightarrow Q^*(s, a)$.

Controle com métodos de diferença temporal

Mesma receita, mas agora aprendendo a cada *passo*

Algoritmo — Iteração de política generalizada com TD

- 1: Inicialize π (e Q)
- 2: **repita**
- 3: *Avaliação*: atualize Q por diferença temporal usando dados da ϵ -gulosa
- 4: *Melhoria*: $\pi \leftarrow \epsilon\text{-guloso}(Q)$
- 5: **fim**

Vantagem: sem esperar o episódio — tarefas **contínuas**. Pergunta que separa os dois algoritmos: **qual Q do próximo estado entra no alvo?**

Intuição

SARSA usa a ação *de fato tomada*. **Q-learning** usa a *melhor* ação, tomada ou não. Um símbolo de diferença, consequências grandes.

Definição — Aprendizado on-policy

Estima e melhora a política *a partir da experiência gerada por ela mesma*. A política que age é a política que se aprende.

Exemplos: controle MC on-policy, SARSA.

Definição — Aprendizado off-policy

Estima e melhora uma política *alvo* usando dados coletados por uma política de *comportamento* diferente, π_b .

Exemplos: Q-learning, DQN, praticamente todo RL offline moderno.

- ▶ Off-policy permite aprender de **dados de arquivo**: prontuários, logs, demonstrações.
- ▶ Permite reutilizar experiência antiga — base do *replay* do DQN; também fonte da instabilidade com aproximação de função.

SARSA

O nome vem da quintupla usada na atualização: (s, a, r, s', a')

Definição — Atualização SARSA

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left(\underbrace{r_t + \gamma Q(s_{t+1}, a_{t+1})}_{\text{alvo: ação realmente tomada}} - Q(s_t, a_t) \right)$$

Algoritmo — SARSA com exploração ϵ -gulosa

- 1: Inicialize $Q(s, a)$; $t = 0$; estado inicial s_0 ; $\pi \leftarrow \epsilon\text{-guloso}(Q)$
- 2: Tome $a_t \sim \pi(s_t)$
- 3: **repita**
- 4: observe (r_t, s_{t+1}) e tome $a_{t+1} \sim \pi(s_{t+1})$
- 5: $Q(s_t, a_t) += \alpha(r_t + \gamma Q(s_{t+1}, a_{t+1}) - Q(s_t, a_t))$
- 6: $\pi \leftarrow \epsilon\text{-guloso}(Q)$; $t += 1$
- 7: **fim**

Q-learning

Aprender Q^* enquanto se age com outra política

Definição — Atualização Q-learning (Watkins, 1989)

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left(\underbrace{r_t + \gamma \max_{a'} Q(s_{t+1}, a')}_{\text{alvo: melhor ação possível}} - Q(s_t, a_t) \right)$$

Algoritmo — Q-learning com exploração ϵ -gulosa

- 1: Inicialize $Q(s, a)$ para todo $s \in \mathcal{S}$, $a \in \mathcal{A}$; $t = 0$; estado inicial s_0
- 2: Defina $\pi_b \leftarrow \epsilon\text{-guloso}(Q)$ *// política de comportamento*
- 3: **repita**
- 4: tome $a_t \sim \pi_b(s_t)$ e observe (r_t, s_{t+1})
- 5: $Q(s_t, a_t) += \alpha(r_t + \gamma \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t))$
- 6: $\pi_b \leftarrow \epsilon\text{-guloso}(Q)$; $t += 1$
- 7: **fim**

Convergência do Q-learning tabular

Teorema

Para MDPs com $\mathcal{S}$ e $\mathcal{A}$ finitos, o Q-learning converge para o valor de ação ótimo, $Q(s, a) \rightarrow Q^*(s, a)$, desde que **(i)** a sequência de políticas satisfaça a condição GLIE e **(ii)** os passos satisfaçam as condições de Robbins–Monro:

$$\sum_{t=1}^{\infty} \alpha_t = \infty, \quad \sum_{t=1}^{\infty} \alpha_t^2 < \infty.$$

Intuição

Primeira soma: erros iniciais *corrigíveis*; segunda: ruído *amortecido*. Ex.: $\alpha_t = 1/t$.

Prova: aproximação estocástica, contração do backup de Bellman, valores limitados. **Nenhuma das três sobrevive intacta à aproximação de função.**

SARSA vs. Q-learning no mesmo passo

Mars Rover com $\alpha = 0,5$, $\gamma = 1$, $Q(s_7, a_1) = 10$ e $Q(s_7, a_2) = 5$

SARSA — tupla $(s_6, a_1, 0, s_7, a_2, \dots)$:

$$Q(s_6, a_1) \leftarrow 0 + \alpha(0 + \gamma Q(s_7, a_2)) = 2,5$$

Usa a_2 : ação de fato tomada em s_7 , possivelmente por exploração.

Q-learning — tupla $(s_6, a_1, 0, s_7)$:

$$Q(s_6, a_1) \leftarrow 0 + \alpha(0 + \gamma \max_{a'} Q(s_7, a')) = 5$$

Usa $\max\{10, 5\} = 10$, ignorando a ação de fato escolhida.

Atenção


Inicialização de Q importa? **Assintoticamente não** — mas **muito** no início. Inicializar otimisticamente é, aliás, estratégia de exploração.

Intuição

Um símbolo separa “seguir esta política, com exploração e tudo” de “jogar perfeitamente a partir daqui”.

O que essa diferença provoca: o *cliff walking*

Sutton & Barto (2018), Exemplo 6.6 — o exemplo canônico da distinção



$r = -1$ por passo; penhasco: -100 e volta a I. Se $\epsilon \rightarrow 0$, ambos convergem à política ótima — mas *durante* o aprendizado, a cautela do SARSA costuma ser preferível.

- ▶ **Q-learning** aprende o caminho *ótimo*, rente ao penhasco; agindo ϵ -guloso, cai às vezes — **recompensa média pior**.
- ▶ **SARSA** aprende o caminho *seguro*, rota de cima: o alvo já contabiliza os passos exploratórios.

Teste sua compreensão: SARSA e Q-learning

Teste sua compreensão

Quais afirmações são verdadeiras?

1. Tanto SARSA quanto Q-learning podem atualizar a política após cada passo.
2. Se $\epsilon = 0$ em todos os instantes e Q é inicializado aleatoriamente, a atualização de SARSA coincide com a de Q-learning.

Pergunta para discussão conduzida em aula.

Teste sua compreensão: SARSA e Q-learning

Teste sua compreensão

Quais afirmações são verdadeiras?

1. Tanto SARSA quanto Q-learning podem atualizar a política após cada passo.
2. Se $\epsilon = 0$ em todos os instantes e Q é inicializado aleatoriamente, a atualização de SARSA coincide com a de Q-learning.

Pergunta para discussão conduzida em aula.

Resposta

As duas são verdadeiras. (1) Ambos incrementais: a política gulosa muda assim que Q muda. (2) $\epsilon = 0 \rightarrow a_{t+1} = \arg \max_{a'} Q(s_{t+1}, a')$; alvos coincidem. Perde-se a garantia de convergência, que exige GLIE.

Um viés escondido no $\max$

Expansão: por que o Q-learning superestima valores

- ▶ Alvo usa $\max_{a'} \hat{Q}(s', a')$ para estimar $\max_{a'} Q(s', a')$. Máximo de estimativas ruidosas: **enviesado para cima**:

$$\mathbb{E} \left[\max_{a'} \hat{Q}(s', a') \right] \geq \max_{a'} \mathbb{E} [\hat{Q}(s', a')]$$

(Jensen: $\max$ é convexo).

- ▶ Ação com sorte nas amostras $\rightarrow$ o $\max$ a seleciona; erro propagado pelo *bootstrapping*.

Intuição

Correção: **desacoplar seleção e avaliação** — um conjunto de estimativas escolhe o $\arg \max$, outro o avalia. Ideia do *Double Q-learning* — e, depois, do *Double DQN*.

SEÇÃO 4

Aproximação de função valor

04

Por que a tabela não basta

O momento em que $|\mathcal{S}|$ deixa de ser um número que se escreve

Domínio	$ \mathcal{S} $ aproximado
Mars Rover (Aula 2)	7
Gamão	10^{20}
Go (19×19)	10^{170}
Atari (4 quadros 84×84)	256^{28224}
Robô contínuo	incontável

Atenção

Não é só memória: mesmo cabendo, seria preciso *visitar* cada entrada ao menos uma vez para estimá-la.

Intuição

Palavra-chave: **generalização** — aprender sobre um estado e, com isso, saber de estados parecidos nunca visitados.

Evitar armazenar por estado o modelo (P, R) , o valor V , o valor de ação Q e a própria política π — reduz **memória**, **computação** e, sobretudo, a **experiência** necessária.

O problema, primeiro com um oráculo

Reduzir RL a aprendizado supervisionado antes de complicar

- ▶ Suponha um oráculo que devolve o valor verdadeiro $Q^\pi(s, a)$ para qualquer par consultado.
- ▶ Então: regressão comum sobre pares $((s, a), Q^\pi(s, a))$.
- ▶ Objetivo: $\mathbf{w}$ na família $\hat{Q}(s, a; \mathbf{w})$ que melhor aproxima Q^π .

Definição — Função de perda

$$J(\mathbf{w}) = \mathbb{E}_\pi \left[(Q^\pi(s, a) - \hat{Q}(s, a; \mathbf{w}))^2 \right]$$

$\nabla_{\mathbf{w}} J(\mathbf{w}) = -2 \mathbb{E}_\pi [(Q^\pi(s, a) - \hat{Q}(s, a; \mathbf{w})) \nabla_{\mathbf{w}} \hat{Q}(s, a; \mathbf{w})] \rightarrow$ passo por amostra $\Delta \mathbf{w} = -\frac{1}{2} \alpha \nabla_{\mathbf{w}} J(\mathbf{w})$:

$$\Delta \mathbf{w} = \alpha (Q^\pi(s, a) - \hat{Q}(s, a; \mathbf{w})) \nabla_{\mathbf{w}} \hat{Q}(s, a; \mathbf{w}).$$

SGD: uma (ou poucas) amostras no lugar da esperança. Em média, o passo é o mesmo do gradiente completo.

Aproximadores lineares e o caso tabular

Expansão: por que o tabular é um caso particular, e não uma alternativa

- ▶ Atributos por par: $\mathbf{x}(s, a) = [x_1(s, a), \dots, x_d(s, a)]^\top$, com

$$\hat{Q}(s, a; \mathbf{w}) = \mathbf{w}^\top \mathbf{x}(s, a), \quad \nabla_{\mathbf{w}} \hat{Q}(s, a; \mathbf{w}) = \mathbf{x}(s, a).$$

- ▶ Atualização:

$$\Delta \mathbf{w} = \alpha (\text{alvo} - \mathbf{w}^\top \mathbf{x}(s, a)) \mathbf{x}(s, a).$$

Definição — O tabular como caso especial

Tome $d = |\mathcal{S}||\mathcal{A}|$ e atributos *one-hot*: $x_i(s, a) = \mathbf{1}\{(s, a) = i\}$. Então $\mathbf{w}$ é a tabela, $\nabla_{\mathbf{w}} \hat{Q}$ seleciona uma única coordenada, e a atualização acima reduz-se exatamente ao Q-learning tabular. Não há dois algoritmos: há um só, com representações diferentes — no caso one-hot simplesmente não existe generalização.

Sem oráculo: Monte Carlo com aproximação de função

G_t : amostra **não-enviesada** (ruidosa) de $Q^\pi(s_t, a_t) \rightarrow$ substitui o oráculo: regressão sobre os pares $\langle (s_t, a_t), G_t \rangle$. Linear: mínimo global da perda quadrática.

Algoritmo — Avaliação de política MC com aproximação de função

- 1: Inicialize $\mathbf{w}$; $k = 1$
- 2: **repita**
- 3: gere o episódio k seguindo π
- 4: **para** $t = 1, \dots, L_k$ **faça**
- 5: **se** primeira visita a (s_t, a_t) **então**
- 6: $G_t = \sum_{j=t}^{L_k} \gamma^{j-t} r_{k,j}$; $\mathbf{w} += \alpha (G_t - \hat{Q}(s_t, a_t; \mathbf{w})) \nabla_{\mathbf{w}} \hat{Q}(s_t, a_t; \mathbf{w})$
- 7: **fim**
- 8: **fim**; $k += 1$
- 9: **fim**

TD(0) com aproximação de função

Três aproximações empilhadas, cada uma com seu preço

- ▶ Tabular: $V^\pi(s) \leftarrow V^\pi(s) + \alpha(r + \gamma V^\pi(s') - V^\pi(s))$ — alvo $r + \gamma V^\pi(s')$ já enviesado.
- ▶ Com aproximação, alvo $r + \gamma \hat{V}^\pi(s'; \mathbf{w})$: enviesado e aproximado.

Atenção

1. **Amostragem** — transição no lugar da esperança sobre P .
 2. **Bootstrapping** — própria estimativa no lugar do valor verdadeiro.
 3. **Aproximação de função** — projeção numa família paramétrica que talvez não contenha V^π .
- ▶ Perda: $J(\mathbf{w}) = \mathbb{E}_\pi[(r_j + \gamma \hat{V}(s_{j+1}; \mathbf{w}) - \hat{V}(s_j; \mathbf{w}))^2]$.
 - ▶ **Detalhe importante:** alvo tratado como *constante* ao derivar $\rightarrow$ não é o gradiente verdadeiro de J : **semigradiente**.

TD(0) com aproximação: o algoritmo

Algoritmo — Avaliação de política TD(0) com aproximação de função

- 1: Inicialize $\mathbf{w}$ e o estado s
- 2: **repita**
- 3: amostre $a \sim \pi(s)$; observe $r(s, a)$ e $s' \sim P(\cdot \mid s, a)$
- 4: $\Delta \mathbf{w} = \alpha(r + \gamma \hat{V}(s'; \mathbf{w}) - \hat{V}(s; \mathbf{w})) \nabla_{\mathbf{w}} \hat{V}(s; \mathbf{w})$; $\mathbf{w} += \Delta \mathbf{w}$
- 5: **se** s' não é terminal **então** $s \leftarrow s'$
- 6: **senão** reinicie o episódio, amostrando novo estado inicial s
- 7: **fim**

Intuição

Derivar o alvo $\rightarrow$ *gradiente residual*: estável, lento, exige duas amostras independentes do próximo estado. Semigradiente: mais rápido — ao custo das garantias.

SEÇÃO 5

Controle com aproximação e Deep Q-Learning

05

Controle com aproximação de função valor

- ▶ Valores de ação: $\hat{Q}^{\pi}(s, a; \mathbf{w}) \approx Q^{\pi}$.
- ▶ Intercalamos, como sempre:
 - avaliação aproximada: ajustar $\mathbf{w}$;
 - melhoria ϵ -gulosa sobre $\hat{Q}$.
- ▶ Sem $Q^{\pi}(s_t, a_t)$: substituímos por um **alvo**, exatamente como no tabular:

Molde geral $\Delta \mathbf{w} = \alpha (\text{alvo} - \hat{Q}(s_t, a_t; \mathbf{w})) \nabla_{\mathbf{w}} \hat{Q}(s_t, a_t; \mathbf{w})$

Monte Carlo alvo = G_t


SARSA alvo = $r + \gamma \hat{Q}(s', a'; \mathbf{w})$

Q-learning alvo = $r + \gamma \max_{a'} \hat{Q}(s', a'; \mathbf{w})$

Uma linha de código, três algoritmos: a Seção 3 troca “entrada da tabela” por “saída da rede”.

A “tríade mortal”

Quando os três se encontram, a convergência deixa de ser garantida



- ▶ Cada atualização: backup de Bellman aproximado, *projetado* sobre a família de funções.
- ▶ Backup: **contração**; projeção: pode ser **expansão**. A composição pode não contrair — oscila ou diverge.
- ▶ Dois a dois: seguros. Os três juntos: não.

Atenção

Contraexemplo: **Baird** (Sutton & Barto, 2018) — Q-learning linear diverge, pesos crescem sem limite.

Mapa das garantias de convergência

Expansão: o que se sabe, para avaliação e para controle

	Algoritmo	Tabular	Linear	Não-linear
Avaliação	MC	converge	converge	converge
	TD(0) on-policy	converge	converge [†]	pode divergir
	TD(0) off-policy	converge	pode divergir	pode divergir
Controle	MC-controle	converge	oscila próximo	pode divergir
	SARSA	converge	oscila próximo	pode divergir
	Q-learning	converge	pode divergir	pode divergir

[†] para um ponto fixo cujo erro é limitado por $\frac{1}{\gamma}$ vezes o erro da melhor aproximação da família.

Intuição

Q-learning com rede neural: sem garantia alguma. O DQN não resolve teoricamente — ele *engenheira* o problema para funcionar na prática.

Q-learning com redes neurais: o que dá errado

Tabular: converge para Q^* . Com aproximação: minimiza EQM por SGD usando alvo estimado — pode divergir.

Atenção

Dois problemas concretos, além da tríade:

1. **Correlação entre amostras.** Transições consecutivas são dependentes; SGD supõe amostras aproximadamente i.i.d.
2. **Alvos não-estacionários.** O alvo usa os mesmos pesos que atualizamos: perseguimos um alvo que se move.

Definição — As duas respostas do DQN (Mnih et al., 2015)

Repetição de experiência (*experience replay*) contra a correlação; **alvos fixos** (*fixed Q-targets*) contra a não-estacionariedade.

Repetição de experiência

Guardar o passado e reamostrá-lo fora de ordem

- ▶ **Buffer de repetição** $\mathcal{D}$: tuplas (s, a, r, s') já vividas (tipicamente 10^6 transições, janela deslizante).
- ▶ Repita:
 1. amostre $(s, a, r, s') \sim \mathcal{D}$ (ou um *minibatch*);
 2. alvo $r + \gamma \max_{a'} \hat{Q}(s', a'; \mathbf{w})$;
 3. atualize $\Delta \mathbf{w} = \alpha (r + \gamma \max_{a'} \hat{Q}(s', a'; \mathbf{w}) - \hat{Q}(s, a; \mathbf{w})) \nabla_{\mathbf{w}} \hat{Q}(s, a; \mathbf{w})$.

Intuição

Só possível porque Q-learning é **off-policy**: tuplas de políticas antigas não invalidam o alvo (que já usa o $\max$, não a ação escolhida). SARSA não pode sem correção. Resta o segundo problema: o alvo muda quando os pesos mudam.

Alvos fixos

Congelar a rede que produz o alvo por C atualizações

- ▶ **Dois** conjuntos de pesos:
 - $\mathbf{w}$ — pesos atualizados;
 - $\mathbf{w}^-$ — pesos da *rede-alvo*, cópia congelada.
- ▶ Alvo calculado com $\mathbf{w}^-$:

$$\Delta \mathbf{w} = \alpha \left(r + \gamma \max_{a'} \hat{Q}(s', a'; \mathbf{w}^-) - \hat{Q}(s, a; \mathbf{w}) \right) \nabla_{\mathbf{w}} \hat{Q}(s, a; \mathbf{w})$$

- ▶ A cada C passos, sincronize: $\mathbf{w}^- \leftarrow \mathbf{w}$.

Intuição

Entre sincronizações: regressão supervisionada comum, com rótulos fixos — a manobra que devolve estabilidade a quem, de outro modo, persegue a própria cauda.

DQN: o algoritmo completo

Algoritmo — Deep Q-Network (Mnih et al., 2015)

- 1: Entrada: C, α , buffer $\mathcal{D} = \{\}$; inicialize $\mathbf{w}, \mathbf{w}^- \leftarrow \mathbf{w}, t = 0$; obtenha s_0
- 2: **repita**
- 3: amostre a_t pela política ϵ -gulosa sobre $\hat{Q}(s_t, \cdot; \mathbf{w})$
- 4: observe r_t e s_{t+1} ; armazene (s_t, a_t, r_t, s_{t+1}) em $\mathcal{D}$
- 5: amostre um *minibatch* aleatório $\{(s_i, a_i, r_i, s_{i+1})\}$ de $\mathcal{D}$
- 6: **para** cada i no *minibatch* **faça**
- 7: $y_i = r_i$ se o episódio terminou em $i + 1$; $y_i = r_i + \gamma \max_{a'} \hat{Q}(s_{i+1}, a'; \mathbf{w}^-)$ caso contrário
- 8: passo de descida em $(y_i - \hat{Q}(s_i, a_i; \mathbf{w}))^2$: $\Delta \mathbf{w} = \alpha (y_i - \hat{Q}(s_i, a_i; \mathbf{w})) \nabla_{\mathbf{w}} \hat{Q}(s_i, a_i; \mathbf{w})$
- 9: **fim**; $t += 1$
- 10: **se** $t \bmod C = 0$ **então** $\mathbf{w}^- \leftarrow \mathbf{w}$
- 11: **fim**

Escolhas de projeto embutidas: arquitetura da rede, taxa de aprendizado, frequência C de sincronização, tamanho do buffer e como preenchê-lo antes de começar a aprender.

Teste sua compreensão: alvos fixos

Teste sua compreensão

No DQN o alvo usa um conjunto separado de pesos, $r + \gamma \max_{a'} \hat{Q}(s', a'; \mathbf{w}^-)$. Quais afirmações são verdadeiras?

1. Isso *dobra o tempo de computação* em relação a um método sem rede-alvo separada.
2. Isso *dobra o requisito de memória* em relação a um método sem rede-alvo separada.

Pergunta para discussão conduzida em aula.

Teste sua compreensão: alvos fixos

Teste sua compreensão

No DQN o alvo usa um conjunto separado de pesos, $r + \gamma \max_{a'} \hat{Q}(s', a'; \mathbf{w}^-)$. Quais afirmações são verdadeiras?

1. Isso *dobra o tempo de computação* em relação a um método sem rede-alvo separada.
2. Isso *dobra o requisito de memória* em relação a um método sem rede-alvo separada.


Pergunta para discussão conduzida em aula.

Resposta

Apenas a segunda. Memória dobra: dois conjuntos de pesos. O tempo *não* dobra: em ambos os casos, uma passagem para frente (alvo) + uma para frente/para trás (atualização). O extra é só a cópia $\mathbf{w}^- \leftarrow \mathbf{w}$ a cada C passos.

DQN em Atari

Aprendizado ponta a ponta, de pixels a valores de ação



- ▶ Estado s : pilha dos **4 últimos quadros** de pixels brutos — velocidade e direção, que um quadro único não revela.
- ▶ Saída: um $\hat{Q}(s, a)$ para cada uma das 18 posições de joystick, em uma única passagem.
- ▶ Recompensa: variação de pontuação (recortada em $[-1, 1]$).
- ▶ **A mesma arquitetura e os mesmos hiperparâmetros** em todos os jogos.

Quais ingredientes do DQN realmente importavam?

Estudo de ablação de Mnih et al. (2015): pontuação por jogo

Jogo	Linear	Rede profunda	DQN alvo fixo	DQN <i>replay</i>	DQN <i>replay</i> + alvo
Breakout	3	3	10	241	317
Enduro	62	29	141	831	1006
River Raid	2345	1453	2868	4102	7447
Seaquest	656	275	1003	823	2894
Space Invaders	301	302	373	826	1089

Atenção

Rede profunda, **sozinha**, chegou a *piorar* (Enduro: 62 $\rightarrow$ 29; Seaquest: 656 $\rightarrow$ 275). A diferença foram o *replay* e o alvo fixo.

Por que o *replay* ajuda tanto

Três efeitos, não um

1. **Descorrelaciona** o *minibatch* — aproxima a hipótese i.i.d. que o SGD supõe.
2. **Reaproveita** cada transição muitas vezes — eficiência de dados, o recurso caro quando cada amostra exige interação.
3. **Estabiliza a distribuição de treino**: sem buffer, mudança de política altera os dados na hora, e a rede “esquece” regiões que deixou de visitar (esquecimento catastrófico).

Intuição

Terceiro efeito, o mais subestimado: o buffer impede otimizar apenas para o presente. Replay sozinho já salta Breakout de 3 $\rightarrow$ 241.

Aperfeiçoamentos imediatos do DQN

- ▶ **Double DQN** (van Hasselt et al., AAAI 2016) — corrige o viés de maximização: a rede em treinamento *escolhe* a ação, a rede-alvo a *avalia*:

$$y = r + \gamma \hat{Q}(s', \arg \max_{a'} \hat{Q}(s', a'; \mathbf{w}); \mathbf{w}^-)$$

- ▶ **Repetição priorizada** (Schaul et al., ICLR 2016) — amostrar com probabilidade proporcional ao erro TD: aprender mais onde ainda se erra.
- ▶ **Dueling DQN** (Wang et al., ICML 2016) — decompor $\hat{Q}(s, a) = \hat{V}(s) + \hat{A}(s, a)$ em valor de estado e vantagem: aprende $\hat{V}(s)$ mesmo com ação irrelevante.

Intuição

Os três são ortogonais e combináveis — é o que faz o *Rainbow* (Hessel et al., 2018), somando seis dessas extensões.

O que você deve levar desta aula

Definição — Capacidades esperadas

- ▶ Implementar avaliação de política por MC e TD(0), tabular e com aproximação de função.
- ▶ Implementar controle por MC, SARSA e Q-learning, e explicar a diferença entre os alvos de SARSA e de Q-learning.
- ▶ Enunciar as condições GLIE e Robbins–Monro e dizer para que cada uma serve.
- ▶ Listar os três elementos da tríade mortal — aproximação de função, *bootstrapping* e aprendizado off-policy — e descrever qualitativamente o problema que geram.
- ▶ Explicar as duas ideias que tornaram o DQN viável: repetição de experiência e alvos fixos.

Próxima aula

- ▶ Até aqui, todo método aprendeu uma **função valor** e derivou a política dela por $\arg \max$.
- ▶ Limites: ações contínuas tornam o $\arg \max$ caro; políticas estocásticas ótimas não representáveis dessa forma.
- ▶ **Próxima aula: gradientes de política** — parametrizar π_θ diretamente e subir o gradiente do retorno esperado.



Intuição

Guarde a tríade mortal: ela reaparece, com outra roupa, em quase todo algoritmo profundo do restante do curso.