

Universidade Federal de Uberlândia

Aula 5: Gradientes de política I

Políticas parametrizadas • Razão de verossimilhança • REINFORCE • Linha de base e vantagem

Prof. Marcelo Keese Albertini
Universidade Federal de Uberlândia
adaptado de Emma Brunskill, CS234 (Stanford)

2026



Onde estamos

Do valor à política

- ▶ **Aulas 2–3:** com um modelo do mundo, calcular V^* e π^* por programação dinâmica.
- ▶ **Aula 4:** sem modelo, *aprender* $\hat{Q}(s, a; w)$ a partir de amostras — MC, SARSA, Q-learning, aproximação de função, DQN.
- ▶ **Hoje:** descartar o intermediário. Parametrizar *diretamente* a política $\pi_\theta(a \mid s)$ e subir o gradiente do retorno esperado.
- ▶ **Próxima aula:** tornar esse passo de gradiente confiável — gradiente natural, TRPO, PPO.

Intuição

Em todo o curso até aqui, a política foi um *subproduto* do valor: $\pi(s) = \arg \max_a \hat{Q}(s, a)$. Hoje ela vira o objeto de primeira classe, e o valor — quando aparecer — será apenas um auxiliar para reduzir variância.

Recapitulação: o que ficou da aula passada

Todo método de controle sem modelo da Aula 4 tinha a mesma forma — atualização incremental rumo a um *alvo*:

$$\Delta w = \alpha (\text{alvo} - \hat{Q}(s, a; w)) \nabla_w \hat{Q}(s, a; w)$$

Método	Alvo
Monte Carlo	G_t
SARSA	$r + \gamma \hat{Q}(s', a'; w)$
Q-learning	$r + \gamma \max_{a'} \hat{Q}(s', a'; w)$
DQN	$r + \gamma \max_{a'} \hat{Q}(s', a'; w^-)$, amostrado de um <i>buffer</i>

Atenção

E a **tríade mortal** — aproximação de função + *bootstrapping* + off-policy — que retira as garantias. O DQN não a resolve: contorna-a com repetição de experiência e alvos fixos.

SEÇÃO 1

Por que parametrizar a política

01

Três famílias de algoritmos



- ▶ Hoje construímos a coluna do meio; o ator-crítico aparece no fim da aula, quase de graça.
- ▶ Notação: w continua sendo os pesos de uma *função valor*; θ passa a ser os pesos da *política*.

Definição — Política estocástica parametrizada

$$\pi_{\theta}(a \mid s) = \mathbb{P}[a_t = a \mid s_t = s; \theta], \quad \theta \in \mathbb{R}^n$$

Uma distribuição sobre ações, diferenciável em θ sempre que é não nula. O objetivo é achar θ que maximize o valor da política.

- ▶ Em espaços discretos: uma rede que produz *logits* e uma *softmax* no fim.
- ▶ Em espaços contínuos: uma rede que produz a média (e talvez o desvio) de uma gaussiana.
- ▶ Continuamos **sem modelo**: nada de $P(s' \mid s, a)$ será necessário — e isso vai cair sozinho da matemática, o que é um dos fatos mais bonitos da aula.

Por que não bastam políticas determinísticas

Três motivos

1. **Ações contínuas.** O $\arg \max_a \hat{Q}(s, a)$ vira um problema de otimização *dentro* de cada passo. Com π_θ a ação sai por uma passagem para frente na rede.
2. **Estados perceptualmente ambíguos.** Se o agente não distingue dois estados, a melhor política pode exigir *aleatoriedade* — veremos o exemplo já a seguir.
3. **Suavidade.** Um ϵ -guloso muda de ação de forma descontínua quando dois valores $\hat{Q}$ se cruzam; π_θ muda suavemente com θ . Isso costuma dar convergência mais estável.

Intuição

Há um quarto motivo, moderno: quando a política é um modelo de linguagem, ela *já é* uma distribuição sobre tokens. Ajustá-la por gradiente de política é a coisa mais natural do mundo — é o que fazem RLHF, PPO e GRPO.

Exemplo: o corredor com estados sinônimos

Corredor de cinco casas. O agente enxerga apenas atributos locais do tipo

$$\phi(s, a) = \mathbf{1}\{\text{há parede ao N, } a = \text{mover para L}\} \quad (\text{e análogos para N, S, L, O})$$



- ▶ As casas 2 e 4 têm paredes ao N e ao S: geram **exatamente o mesmo vetor de atributos**. O agente não pode distingui-las.
- ▶ Comparemos duas abordagens: valor aproximado $Q_{\theta}(s, a) = f(\phi(s, a); \theta)$ contra política parametrizada $\pi_{\theta}(a | s) = g(\phi(s, a); \theta)$.

O corredor: por que o determinismo falha

Como 2 e 4 são indistinguíveis, *qualquer* política determinística é obrigada a escolher a mesma ação nas duas:

Atenção

Sempre para o Leste: da casa 2 chega ao objetivo; da casa 4 vai para a 5 e fica preso.
Sempre para o Oeste: simétrico. Em ambos os casos, *metade dos inícios nunca alcança o objetivo*.

Intuição

RL baseado em valor aprende uma política quase determinística. O ϵ salva no limite, mas o tempo esperado para escapar cresce como $1/\epsilon$: milhares de passos.

A política ótima aqui é estocástica

$\pi_\theta(L \mid \text{parede N e S}) = \pi_\theta(O \mid \text{parede N e S}) = 0,5$: um passeio aleatório local, que alcança o objetivo em poucos passos com alta probabilidade a partir de qualquer início.

Teste sua compreensão

Teste sua compreensão

O exemplo do corredor mostra que políticas estocásticas podem ser estritamente melhores que determinísticas.

Isso contradiz o teorema da Aula 2, que garante existir uma política *determinística* ótima para todo MDP finito? *Pergunta para discussão conduzida em aula.*

Teste sua compreensão

Teste sua compreensão

O exemplo do corredor mostra que políticas estocásticas podem ser estritamente melhores que determinísticas.

Isso contradiz o teorema da Aula 2, que garante existir uma política *determinística* ótima para todo MDP finito? *Pergunta para discussão conduzida em aula.*

Resposta

Não há contradição — o objeto mudou. O teorema vale para MDPs, em que a política é função do estado. Aqui a política é função da observação $\phi(s, \cdot)$, que não identifica o estado: estamos de fato num POMDP (ou, equivalentemente, numa classe restrita de políticas que não separa 2 de 4). Sob restrição de representação — ou sob observabilidade parcial — o ótimo pode exigir aleatoriedade.

SEÇÃO 2

O objetivo e o truque da razão de verossimilhança

02

O que exatamente vamos maximizar

Definição — Valor de uma política parametrizada

Para MDPs episódicos com estado inicial s_0 e horizonte T ,

$$V(\theta) := V(s_0, \theta) = \mathbb{E}_{\pi_\theta} \left[\sum_{t=0}^T R(s_t, a_t) \mid \pi_\theta, s_0 \right]$$

A esperança é sobre estados e ações visitados por π_θ .

Duas reescritas equivalentes — a escolha importa:

► **Por ação:** $V(s_0, \theta) = \sum_a \pi_\theta(a \mid s_0) Q(s_0, a, \theta)$ (Sutton & Barto, 13.2)

► **Por trajetória:** $V(\theta) = \sum_{\tau} P(\tau, \theta) R(\tau)$ (o caminho do boia)

Intuição

A segunda forma trata tudo como *otimização estocástica pura*: derivação curta, e válida bem além de MDPs.

Notação de trajetória

Definição — Trajetória, retorno e verossimilhança

$$\tau = (s_0, a_0, r_0, s_1, a_1, r_1, \dots, s_{T-1}, a_{T-1}, r_{T-1}, s_T)$$
$$R(\tau) = \sum_{t=0}^T R(s_t, a_t), \quad P(\tau; \theta) = \mu(s_0) \prod_{t=0}^{T-1} \underbrace{\pi_{\theta}(a_t \mid s_t)}_{\text{política}} \underbrace{P(s_{t+1} \mid s_t, a_t)}_{\text{dinâmica}}$$

O problema de otimização fica $\arg \max_{\theta} V(\theta) = \arg \max_{\theta} \sum_{\tau} P(\tau; \theta) R(\tau)$.

Atenção

Note quem depende de θ : **apenas** os fatores $\pi_{\theta}(a_t \mid s_t)$ — nem μ , nem a dinâmica, nem R .

Antes do gradiente: por que não otimização sem gradiente?

Maximizar $V(\theta)$ é otimização de caixa-preta. Existem métodos que *não* usam gradiente:

- ▶ **Busca aleatória:** perturbar θ , manter se melhorou.
- ▶ **Diferenças finitas:** $\partial V / \partial \theta_k \approx [V(\theta + \varepsilon e_k) - V(\theta)] / \varepsilon$.
- ▶ **Estratégias evolutivas** e *cross-entropy method*.

Por que insistir no gradiente

Diferenças finitas exigem $\mathcal{O}(n)$ avaliações *ruidosas* por passo — proibitivo com n na casa dos milhões. O gradiente analítico custa *uma* passagem para trás, qualquer que seja n .

Intuição

Não os descarte: são competitivos quando n é pequeno ou quando o simulador é barato e massivamente paralelo (Salimans et al., 2017).

Subida de gradiente na política

Definição — Gradiente de política

$$\Delta\theta = \alpha \nabla_{\theta} V(s_0, \theta), \quad \nabla_{\theta} V(s_0, \theta) = \begin{pmatrix} \partial V(s_0, \theta) / \partial \theta_1 \\ \vdots \\ \partial V(s_0, \theta) / \partial \theta_n \end{pmatrix}$$

Sobe-se esse gradiente rumo a um **máximo local**; α é o passo.

Atenção

Local, não global — a principal desvantagem da família. Em troca: convergência suave, ações contínuas e políticas estocásticas.

A dificuldade: $V(\theta) = \sum_{\tau} P(\tau; \theta) R(\tau)$ soma sobre um número astronômico de trajetórias, e não sabemos calcular $P(\tau; \theta)$.

O truque da razão de verossimilhança

$$\nabla_{\theta} V(\theta) = \nabla_{\theta} \sum_{\tau} P(\tau; \theta) R(\tau) = \sum_{\tau} \nabla_{\theta} P(\tau; \theta) R(\tau)$$

($R(\tau)$ não depende de θ)

O truque da razão de verossimilhança

$$\begin{aligned}\nabla_{\theta} V(\theta) &= \nabla_{\theta} \sum_{\tau} P(\tau; \theta) R(\tau) = \sum_{\tau} \nabla_{\theta} P(\tau; \theta) R(\tau) \\ &= \sum_{\tau} \frac{P(\tau; \theta)}{P(\tau; \theta)} \nabla_{\theta} P(\tau; \theta) R(\tau)\end{aligned}$$

($R(\tau)$ não depende de θ)

(multiplicar e dividir por $P(\tau; \theta)$)

O truque da razão de verossimilhança

$$\nabla_{\theta} V(\theta) = \nabla_{\theta} \sum_{\tau} P(\tau; \theta) R(\tau) = \sum_{\tau} \nabla_{\theta} P(\tau; \theta) R(\tau)$$

($R(\tau)$ não depende de θ)

$$= \sum_{\tau} \frac{P(\tau; \theta)}{P(\tau; \theta)} \nabla_{\theta} P(\tau; \theta) R(\tau)$$

(multiplicar e dividir por $P(\tau; \theta)$)

$$= \sum_{\tau} P(\tau; \theta) R(\tau) \underbrace{\frac{\nabla_{\theta} P(\tau; \theta)}{P(\tau; \theta)}}_{\text{razão de verossimilhança}} = \sum_{\tau} P(\tau; \theta) R(\tau) \nabla_{\theta} \log P(\tau; \theta) \quad (\text{pois } \nabla \log f = \nabla f / f)$$

O gradiente virou uma esperança

$\nabla_{\theta} V(\theta) = \mathbb{E}_{\tau \sim \pi_{\theta}} [R(\tau) \nabla_{\theta} \log P(\tau; \theta)]$ — e esperanças a gente estima por amostragem.

Estimador de Monte Carlo

Com m trajetórias $\tau^{(1)}, \dots, \tau^{(m)}$ coletadas rodando a política atual:

$$\nabla_{\theta} V(\theta) \approx \hat{g} = \frac{1}{m} \sum_{i=1}^m R(\tau^{(i)}) \nabla_{\theta} \log P(\tau^{(i)}; \theta)$$

- ▶ O estimador é **não enviesado**: $\mathbb{E}[\hat{g}] = \nabla_{\theta} V(\theta)$ exatamente, para qualquer m .
- ▶ Mas ainda parece inútil: $\log P(\tau; \theta)$ contém a dinâmica, que é desconhecida.
- ▶ **Próximo slide**: ao abrir o logaritmo, a dinâmica desaparece.

Intuição

Repare no que já conseguimos: transformamos “derivar uma soma sobre todas as trajetórias” em “rodar a política algumas vezes e tirar uma média”. Todo o resto da aula é reduzir a *variância* dessa média.

Decompondo a trajetória: a dinâmica cai fora

$$\nabla_{\theta} \log P(\tau^{(i)}; \theta) = \nabla_{\theta} \log \left[\underbrace{\mu(s_0)}_{\text{distrib. inicial}} \prod_{t=0}^{T-1} \underbrace{\pi_{\theta}(a_t \mid s_t)}_{\text{política}} \underbrace{P(s_{t+1} \mid s_t, a_t)}_{\text{modelo de dinâmica}} \right]$$

Decompondo a trajetória: a dinâmica cai fora

$$\begin{aligned}\nabla_{\theta} \log P(\tau^{(i)}; \theta) &= \nabla_{\theta} \log \left[\underbrace{\mu(s_0)}_{\text{distrib. inicial}} \prod_{t=0}^{T-1} \underbrace{\pi_{\theta}(a_t | s_t)}_{\text{política}} \underbrace{P(s_{t+1} | s_t, a_t)}_{\text{modelo de dinâmica}} \right] \\ &= \nabla_{\theta} \left[\log \mu(s_0) + \sum_{t=0}^{T-1} \log \pi_{\theta}(a_t | s_t) + \sum_{t=0}^{T-1} \log P(s_{t+1} | s_t, a_t) \right]\end{aligned}$$

Decompondo a trajetória: a dinâmica cai fora

$$\begin{aligned}\nabla_{\theta} \log P(\tau^{(i)}; \theta) &= \nabla_{\theta} \log \left[\underbrace{\mu(s_0)}_{\text{distrib. inicial}} \prod_{t=0}^{T-1} \underbrace{\pi_{\theta}(a_t | s_t)}_{\text{política}} \underbrace{P(s_{t+1} | s_t, a_t)}_{\text{modelo de dinâmica}} \right] \\ &= \nabla_{\theta} \left[\log \mu(s_0) + \sum_{t=0}^{T-1} \log \pi_{\theta}(a_t | s_t) + \sum_{t=0}^{T-1} \log P(s_{t+1} | s_t, a_t) \right] \\ &= \sum_{t=0}^{T-1} \underbrace{\nabla_{\theta} \log \pi_{\theta}(a_t | s_t)}_{\text{função escore}}\end{aligned}$$

Nenhum modelo de dinâmica é necessário

O logaritmo transforma produto em soma; a derivada aniquila o que não depende de θ . Sobra só a política — que *nós* escolhemos.

Gradiente de política por função escore

Estimador completo (REINFORCE ingênuo)

$$\nabla_{\theta} V(\theta) \approx \hat{g} = \frac{1}{m} \sum_{i=1}^m R(\tau^{(i)}) \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t^{(i)} \mid s_t^{(i)})$$

Tudo que é preciso para calculá-lo:

1. Rodar a política e guardar (s_t, a_t, r_t) .
2. Somar as recompensas de cada trajetória.
3. Derivar $\log \pi_{\theta}$ — diferenciação automática faz isso.

Intuição

Sem modelo, sem $\max$ sobre ações. Em compensação: precisamos de *episódios completos*, e o estimador é on-policy.

A função escore

Definição — Função escore (*score function*)

A derivada do logaritmo de uma verossimilhança parametrizada, $\nabla_{\theta} \log p(x; \theta)$. Aqui, $\nabla_{\theta} \log \pi_{\theta}(a \mid s)$: a direção em θ que *mais aumenta* a log-probabilidade de ter escolhido a em s .

Propriedade fundamental: o escore tem média zero

$$\mathbb{E}_{a \sim \pi_{\theta}(\cdot | s)} [\nabla_{\theta} \log \pi_{\theta}(a \mid s)] = \sum_a \pi_{\theta}(a \mid s) \frac{\nabla_{\theta} \pi_{\theta}(a \mid s)}{\pi_{\theta}(a \mid s)} = \nabla_{\theta} \sum_a \pi_{\theta}(a \mid s) = \nabla_{\theta} 1 = 0$$

Guarde esta identidade: é ela que provará, adiante, que uma *linha de base* não introduz vies.

Política softmax e seu escore

Ações discretas, atributos $\phi(s, a)$, pesos lineares:

$$\pi_{\theta}(a \mid s) = \frac{e^{\phi(s, a)^{\top} \theta}}{\sum_{a'} e^{\phi(s, a')^{\top} \theta}}$$

$$\begin{aligned} \nabla_{\theta} \log \pi_{\theta}(a \mid s) &= \nabla_{\theta} \left[\phi(s, a)^{\top} \theta - \log \sum_{a'} e^{\phi(s, a')^{\top} \theta} \right] \\ &= \phi(s, a) - \frac{\sum_{a'} \phi(s, a') e^{\phi(s, a')^{\top} \theta}}{\sum_{a'} e^{\phi(s, a')^{\top} \theta}} = \phi(s, a) - \mathbb{E}_{a' \sim \pi_{\theta}}[\phi(s, a')] \end{aligned}$$

Intuição

Atributo observado menos atributo esperado. Se a ação tomada era “mais típica” do que a média, o escore é pequeno; se era atípica, o escore é grande. Multiplicado por um retorno alto, isso empurra a política justamente na direção do que foi surpreendentemente bom.

Política gaussiana e seu escore

Para ações contínuas, $a \in \mathbb{R}$ (ou $\mathbb{R}^d$):

$$\mu_{\theta}(s) = \phi(s)^{\top} \theta, \quad a \sim \mathcal{N}(\mu_{\theta}(s), \sigma^2)$$

$$\nabla_{\theta} \log \pi_{\theta}(a | s) = \frac{(a - \mu_{\theta}(s)) \phi(s)}{\sigma^2}$$


- ▶ σ^2 pode ser fixa ou parametrizada — na prática funciona como **controle de exploração**, que a otimização vai encolhendo.
- ▶ Redes profundas substituem a forma linear sem alterar a derivação.

Atenção

O fator $1/\sigma^2$ explode quando $\sigma \rightarrow 0$: uma política que ficou quase determinística produz gradientes gigantescos e instáveis. É um dos modos de falha mais comuns em controle contínuo — limite σ por baixo.

Intuição do estimador por função escore

Forma genérica de cada termo, $\hat{g}_i = f(x_i) \nabla_{\theta} \log p(x_i; \theta)$:



- ▶ Andar na direção $\hat{g}_i$ **aumenta a log-probabilidade da amostra**, na proporção de quão boa ela foi.
- ▶ Vale mesmo que f seja **descontínua, desconhecida ou discreta**: nunca derivamos f , só $\log p$.

Por que isso é notável: *escore versus* reparametrização

Definição — Escore (o que fizemos)

$$\nabla_{\theta} \mathbb{E}_{x \sim p_{\theta}}[f(x)] = \mathbb{E}[f(x) \nabla_{\theta} \log p_{\theta}(x)]$$

- + f pode ser caixa-preta
- + serve para x discreto
- variância alta

Definição — Reparametrização

$$x = h_{\theta}(\epsilon), \quad \nabla_{\theta} \mathbb{E}[f] = \mathbb{E}[\nabla f \cdot \nabla_{\theta} h_{\theta}]$$

- + variância bem menor
- exige f diferenciável
- só para x contínuo

Intuição

Em RL a “função” é o *mundo*: o placar de um jogo, a preferência de um avaliador humano. Não há gradiente para pegar — por isso o estimador por escore, caro em variância e barato em suposições, é o que sobrevive.

Teorema do gradiente de política

Teorema (Sutton et al., 2000)

Para toda política diferenciável $\pi_\theta(a \mid s)$ e para qualquer um dos objetivos usuais — J_1 (recompensa episódica), J_{avR} (recompensa média por passo) ou $\frac{1}{1-\gamma} J_{\text{avV}}$ (valor médio) — o gradiente da política é

$$\nabla_\theta J(\theta) = \mathbb{E}_{\pi_\theta} \left[\nabla_\theta \log \pi_\theta(a \mid s) Q^{\pi_\theta}(s, a) \right]$$

- ▶ Generaliza o que derivamos: no lugar do retorno da trajetória inteira, aparece o valor da ação $Q^{\pi_\theta}(s, a)$.
- ▶ **O que o teorema evita:** a distribuição de estados d^{π_θ} também depende de θ , mas o gradiente *não* contém $\nabla_\theta d^{\pi_\theta}$ — esse é o resultado difícil (S&B, cap. 13.2).
- ▶ Todo o resto da aula consiste em escolher *o que colocar no lugar de* $Q^{\pi_\theta}(s, a)$.

Teste sua compreensão

Teste sua compreensão

Sobre o gradiente por razão de verossimilhança, quais afirmações são verdadeiras?

- (a) exige funções de recompensa diferenciáveis;
- (b) só pode ser usado com processos de decisão de Markov;
- (c) é útil principalmente em tarefas de horizonte infinito.

Pergunta para discussão conduzida em aula.

Teste sua compreensão

Teste sua compreensão

Sobre o gradiente por razão de verossimilhança, quais afirmações são verdadeiras?

- (a) exige funções de recompensa diferenciáveis;
- (b) só pode ser usado com processos de decisão de Markov;
- (c) é útil principalmente em tarefas de horizonte infinito.

Pergunta para discussão conduzida em aula.

Resposta

Nenhuma das três. (a) Nunca derivamos R , só $\log \pi_\theta$. (b) A derivação só usou que $P(\tau; \theta)$ fatora: vale para POMDPs, bandidos e geração de texto. (c) Ao contrário: supusemos episódios finitos.

SEÇÃO 3

Reduzindo a variância

03

O problema: não enviesado, mas ruidoso demais

$$\nabla_{\theta} V(\theta) \approx \frac{1}{m} \sum_{i=1}^m R(\tau^{(i)}) \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t^{(i)} \mid s_t^{(i)})$$

Atenção

Não enviesado — e **de variância altíssima**. O sinal que atribuímos a *cada* ação é o retorno da trajetória *inteira*: uma ação excelente no passo 3 recebe a culpa por um desastre no passo 300.

Três correções, nesta ordem, e cada uma é uma ideia independente:

1. **Estrutura temporal** — uma ação não pode influenciar o passado.
2. **Linha de base** — comparar o retorno com o esperado, não com zero.
3. **Alternativas ao retorno de Monte Carlo** — trocar variância por um pouco de viés (ator-crítico).

Correção 1: usar a estrutura temporal

Partindo de

$$\nabla_{\theta} \mathbb{E}_{\tau}[R] = \mathbb{E}_{\tau} \left[\left(\sum_{t=0}^{T-1} r_t \right) \left(\sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t \mid s_t) \right) \right]$$

Correção 1: usar a estrutura temporal

Partindo de

$$\nabla_{\theta} \mathbb{E}_{\tau}[R] = \mathbb{E}_{\tau} \left[\left(\sum_{t=0}^{T-1} r_t \right) \left(\sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \right) \right]$$

O mesmo argumento, aplicado a *uma única* recompensa $r_{t'}$, dá

$$\nabla_{\theta} \mathbb{E}[r_{t'}] = \mathbb{E} \left[r_{t'} \sum_{t=0}^{t'} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \right]$$

— só as ações *até* t' podem ter influenciado $r_{t'}$.

Correção 1: usar a estrutura temporal

Partindo de

$$\nabla_{\theta} \mathbb{E}_{\tau}[R] = \mathbb{E}_{\tau} \left[\left(\sum_{t=0}^{T-1} r_t \right) \left(\sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \right) \right]$$

O mesmo argumento, aplicado a *uma única* recompensa $r_{t'}$, dá

$$\nabla_{\theta} \mathbb{E}[r_{t'}] = \mathbb{E} \left[r_{t'} \sum_{t=0}^{t'} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \right]$$

— só as ações *até* t' podem ter influenciado $r_{t'}$.

Somando em t' e trocando a ordem dos somatórios:

$$\nabla_{\theta} V(\theta) = \mathbb{E} \left[\sum_{t'=0}^{T-1} r_{t'} \sum_{t=0}^{t'} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \right] = \mathbb{E} \left[\sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \sum_{t'=t}^{T-1} r_{t'} \right]$$

Correção 1: o resultado

Cada ação é creditada apenas pelo que veio depois

Como $\sum_{t'=t}^{T-1} r_{t'}^{(i)}$ é exatamente o retorno $G_t^{(i)}$,

$$\nabla_{\theta} V(\theta) \approx \frac{1}{m} \sum_{i=1}^m \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t^{(i)} \mid s_t^{(i)}) G_t^{(i)}$$

- ▶ Removemos os termos $r_{t'}$ com $t' < t$: em esperança eles valem **zero** (a ação não influencia o passado), mas contribuía com variância pura.
- ▶ Continua não enviesado, com variância estritamente menor.

Intuição

Princípio geral da aula: *remova do estimador tudo que tem esperança zero*. Não muda o alvo e reduz ruído — a linha de base, a seguir, é a mesma ideia.

REINFORCE: gradiente de política por Monte Carlo

Algoritmo — REINFORCE (Williams, 1992)

- ▶ Inicialize θ arbitrariamente
- ▶ **para** cada episódio $\{s_0, a_0, r_0, \dots, s_{T-1}, a_{T-1}, r_{T-1}\} \sim \pi_\theta$ **faça**
 - **para** $t = 0$ até $T - 1$ **faça**

$$\theta \leftarrow \theta + \alpha \nabla_\theta \log \pi_\theta(a_t | s_t) G_t$$

- **fim para**
 - ▶ **fim para**; devolva θ
-
- ▶ Combina razão de verossimilhança + estrutura temporal.
 - ▶ É **on-policy** e exige o episódio completo (precisa de G_t).
 - ▶ Publicado em 1992 — é o ancestral direto de tudo que vem depois.

Por que ainda não funciona bem

Um exemplo de três linhas

Bandido de duas ações, política softmax, recompensas $R(a_1) = 100$ e $R(a_2) = 101$.

- ▶ Ambos os retornos são grandes e positivos $\Rightarrow$ o estimador **aumenta a log-probabilidade das duas ações** em toda amostra.
- ▶ A diferença entre elas — o único sinal útil — é 1, sepultada num sinal de magnitude 100.
- ▶ Agora some +1000 a todas as recompensas. O gradiente *verdadeiro* não muda (o escore tem média zero), mas a **variância do estimador explode**.

Intuição

A escala absoluta da recompensa não deveria importar — e não importa em esperança. Ela só afeta o *ruído*. Consertar isso é exatamente o papel da linha de base.

Correção 2: introduzir uma linha de base

Definição — Linha de base $b(s)$

$$\nabla_{\theta} \mathbb{E}_{\tau}[R] = \mathbb{E}_{\tau} \left[\sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) (G_t - b(s_t)) \right]$$

Para **qualquer** b que dependa apenas do estado (não da ação), o estimador permanece não enviesado.

- ▶ Escolha quase ótima: o retorno esperado, $b(s_t) \approx \mathbb{E}[r_t + \dots + r_{T-1}] = V^{\pi}(s_t)$.
- ▶ **Leitura:** aumente a log-probabilidade de a_t na proporção de quanto o retorno foi *melhor que o esperado* naquele estado.

Intuição

De “esta ação rendeu 101” para “esta ação rendeu 0,5 acima da média deste estado”. O segundo sinal é comparável entre estados; o primeiro, não.

A linha de base não introduz viés — demonstração

$$\begin{aligned}\mathbb{E}_{\tau} [\nabla_{\theta} \log \pi_{\theta}(a_t | s_t) b(s_t)] &= \mathbb{E}_{s_{0:t}, a_{0:t-1}} \left[\mathbb{E}_{a_t} [\nabla_{\theta} \log \pi_{\theta}(a_t | s_t) b(s_t)] \right] && \text{(quebrar a esperança)} \\ &= \mathbb{E}_{s_{0:t}, a_{0:t-1}} \left[b(s_t) \mathbb{E}_{a_t} [\nabla_{\theta} \log \pi_{\theta}(a_t | s_t)] \right] && (b \text{ não depende de } a_t) \\ &= \mathbb{E} \left[b(s_t) \sum_a \pi_{\theta}(a | s_t) \frac{\nabla_{\theta} \pi_{\theta}(a | s_t)}{\pi_{\theta}(a | s_t)} \right] && \text{(razão de verossimilhança)} \\ &= \mathbb{E} \left[b(s_t) \nabla_{\theta} \sum_a \pi_{\theta}(a | s_t) \right] = \mathbb{E} [b(s_t) \nabla_{\theta} 1] = 0\end{aligned}$$

Consequência

Subtrair $b(s_t)$ altera a variância mas **não** a esperança: há liberdade total para escolher b minimizando o ruído. Atenção ao segundo passo — ele exige que b dependa só de s_t .

O algoritmo “baunilha” de gradiente de política

Algoritmo — Gradiente de política com linha de base

- ▶ Inicialize os parâmetros da política θ e a linha de base b
- ▶ **para** iteração $= 1, 2, \dots$ **faça**
 - Colete trajetórias executando a política atual
 - Em cada passo t de cada trajetória τ^i , calcule o retorno $G_t^i = \sum_{t'=t}^{T-1} r_{t'}$ e a vantagem $\hat{A}_t^i = G_t^i - b(s_t)$
 - **Reajuste a linha de base** minimizando $\sum_i \sum_t \|b(s_t) - G_t^i\|^2$
 - **Atualize a política** com $\hat{g} = \sum_{i,t} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \hat{A}_t^i$ (via SGD ou Adam)
- ▶ **fim para**

Intuição

Dois problemas supervisionados alternando: regressão (ajustar b) e subida de gradiente ponderada (ajustar π_{θ}).

Que linha de base escolher?

- ▶ **Constante:** $b =$ média dos retornos do lote. Trivial, já ajuda muito.
- ▶ **Dependente do estado:** $b(s) = \hat{V}^\pi(s; w)$, uma rede treinada por regressão. É a escolha padrão.
- ▶ **Ótima em variância:** a linha de base que minimiza $\text{Var}(\hat{g})$ é uma média dos retornos ponderada pelo escore ao quadrado,

$$b^* = \frac{\mathbb{E}[(\nabla_\theta \log \pi_\theta)^2 G_t]}{\mathbb{E}[(\nabla_\theta \log \pi_\theta)^2]}$$

Raramente vale o custo: $\hat{V}^\pi$ chega perto e é mais simples.

Atenção

Na prática faz-se também **normalização de vantagens** por lote: $\hat{A} \leftarrow (\hat{A} - \bar{\hat{A}})/(\sigma_{\hat{A}} + \varepsilon)$ — viés pequeno, e o passo α deixa de depender da escala da recompensa.

Teste sua compreensão

Teste sua compreensão

Um aluno propõe usar como linha de base $b(s_t, a_t) = \hat{Q}^\pi(s_t, a_t)$ — afinal, dizem os slides, a escolha quase ótima é “o retorno esperado”, e $\hat{Q}$ estima o retorno esperado com mais precisão que $\hat{V}$.

O estimador resultante ainda é não enviesado? O que ele calcularia? *Pergunta para discussão conduzida em aula.*

Teste sua compreensão

Teste sua compreensão

Um aluno propõe usar como linha de base $b(s_t, a_t) = \hat{Q}^\pi(s_t, a_t)$ — afinal, dizem os slides, a escolha quase ótima é “o retorno esperado”, e $\hat{Q}$ estima o retorno esperado com mais precisão que $\hat{V}$.

O estimador resultante ainda é não enviesado? O que ele calcularia? *Pergunta para discussão conduzida em aula.*

Resposta

Não. A demonstração de não-viés exige que b dependa apenas de s_t ; com b dependendo de a_t , não se pode retirá-la da esperança sobre ações. Pior: o termo subtraído seria exatamente $\mathbb{E}[\nabla_\theta \log \pi \cdot Q^\pi]$, ou seja, o gradiente inteiro — em esperança o estimador daria **zero** e a política nunca aprenderia.

SEÇÃO 4

Alternativas ao retorno de Monte Carlo

04

Onde estamos e o que falta

$$\nabla_{\theta} \mathbb{E}[R] \approx \frac{1}{m} \sum_{i=1}^m \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) (G_t^{(i)} - b(s_t))$$

- ✓ Estrutura temporal e linha de base — ambas no somatório acima.
- **Alternativas a G_t** como estimativa do retorno esperado.

Atenção

G_t^i estima o valor a partir de *uma única* execução: não enviesada, mas carregando o ruído de todas as transições e escolhas de ação até o fim do episódio.


Intuição

O remédio é o da Aula 4, quando comparamos MC e TD: introduzir **viés** via *bootstrapping* para comprar uma redução grande de **variância**.

Métodos ator-crítico

Definição — Ator e crítico

O **ator** é a política π_θ — decide o que fazer. O **crítico** é a função valor $\hat{V}(s; w)$ ou $\hat{Q}(s, a; w)$ — avalia o que o ator fez. Ambos são aprendidos e atualizados.



- ▶ O crítico troca o retorno bruto por uma estimativa *bootstrapped*: menos ruidosa, ligeiramente enviesada. A3C (Mnih et al., 2016) popularizou a arquitetura; A2C, PPO e SAC a herdaram.

A função vantagem

Partindo de $\nabla_{\theta} \mathbb{E}_{\tau}[R] \approx \mathbb{E}[\sum_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) (Q(s_t, a_t; w) - b(s_t))]$ e tomando $b(s) = \hat{V}^{\pi}(s)$:

Definição — Vantagem

$$A^{\pi}(s, a) = Q^{\pi}(s, a) - V^{\pi}(s) \quad \implies \quad \nabla_{\theta} \mathbb{E}_{\tau}[R] \approx \mathbb{E} \left[\sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \hat{A}^{\pi}(s_t, a_t) \right]$$

“Quanto esta ação é melhor do que a ação média neste estado.”

- ▶ Por construção, $\mathbb{E}_{a \sim \pi}[A^{\pi}(s, a)] = 0$: a vantagem é centrada.
- ▶ Positivo $\Rightarrow$ torne a ação mais provável; negativo $\Rightarrow$ menos. Sem esse centramento, “todas as ações ficam mais prováveis” — o que não faz sentido para uma distribuição.

Estimadores de n passos: um dial entre TD e MC

O crítico pode usar **qualquer mistura** entre alvo TD e alvo MC:

$$\hat{R}_t^{(1)} = r_t + \gamma \hat{V}(s_{t+1}), \quad \hat{R}_t^{(2)} = r_t + \gamma r_{t+1} + \gamma^2 \hat{V}(s_{t+2}), \quad \dots, \quad \hat{R}_t^{(\infty)} = \sum_{k \geq 0} \gamma^k r_{t+k}$$


Subtraindo a linha de base $\hat{V}(s_t)$, obtêm-se estimadores de vantagem:

$$\hat{A}_t^{(1)} = r_t + \gamma \hat{V}(s_{t+1}) - \hat{V}(s_t), \quad \hat{A}_t^{(\infty)} = \sum_{k \geq 0} \gamma^k r_{t+k} - \hat{V}(s_t)$$

Intuição

$\hat{A}_t^{(1)}$ é exatamente o **erro TD** δ_t da Aula 4, agora reaparecendo como sinal de aprendizado da *política*. O mesmo objeto, dois papéis.

O compromisso viés-variância



- ▶ n pequeno: alvo depende fortemente de $\hat{V}$, que está errado no início $\Rightarrow$ **viés**.
- ▶ n grande: alvo acumula o ruído de muitas transições $\Rightarrow$ **variância**.
- ▶ **GAE** (Schulman et al., 2016) toma uma média exponencial de todos os n com peso λ :
$$\hat{A}_t^{\text{GAE}} = \sum_{k \geq 0} (\gamma \lambda)^k \delta_{t+k}.$$
 É o padrão em PPO — e é exatamente o λ de $\text{TD}(\lambda)$.

Teste sua compreensão

Teste sua compreensão

Considerando

$$\hat{A}_t^{(1)} = r_t + \gamma \hat{V}(s_{t+1}) - \hat{V}(s_t), \quad \hat{A}_t^{(\infty)} = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \dots - \hat{V}(s_t)$$

Classifique cada um quanto a viés e variância. *Pergunta para discussão conduzida em aula.*

Teste sua compreensão

Teste sua compreensão

Considerando

$$\hat{A}_t^{(1)} = r_t + \gamma \hat{V}(s_{t+1}) - \hat{V}(s_t), \quad \hat{A}_t^{(\infty)} = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \dots - \hat{V}(s_t)$$

Classifique cada um quanto a viés e variância. *Pergunta para discussão conduzida em aula.*

Resposta

$\hat{A}_t^{(1)}$ tem **variância baixa e viés alto**: depende de uma única transição, mas herda todo o erro de $\hat{V}(s_{t+1})$.

$\hat{A}_t^{(\infty)}$ tem **variância alta e viés baixo**: usa recompensas reais até o fim (só $\hat{V}(s_t)$, a linha de base, é aproximada — e ela não introduz viés), ao custo de acumular o ruído de todo o episódio.

O algoritmo baunilha, versão final

Algoritmo — Gradiente de política com vantagem

- ▶ Inicialize os parâmetros da política θ e do crítico w
- ▶ **para** iteração = 1, 2, ... **faça**
 - Colete trajetórias executando π_θ
 - Em cada passo, calcule uma estimativa de vantagem $\hat{A}_{it}^{(n)}$ (escolha de n , ou $\text{GAE}(\lambda)$)
 - Ajuste o crítico: $w \leftarrow \arg \min_w \sum_{i,t} (\hat{V}(s_{it}; w) - \hat{R}_{it})^2$
 - Atualize a política com $\hat{g} = \sum_{i,t} \nabla_\theta \log \pi_\theta(a_t | s_t) \hat{A}_{it}^{(n)}$
- ▶ **fim para**

Intuição

Toda a família — REINFORCE, A2C, TRPO, PPO, GRPO — é este esqueleto com duas escolhas: *como estimar a vantagem* e *como limitar o passo*. A próxima aula trata da segunda.

SEÇÃO 5

Balanço e próximos passos

05

Vantagens e desvantagens do RL baseado em política

Definição — Vantagens

- ▶ Convergência suave, sem oscilação por troca de $\arg \max$.
- ▶ Eficaz em ações **contínuas** ou de alta dimensão.
- ▶ Aprende políticas **estocásticas**.

Atenção

- ▶ Converge a um **ótimo local**, não global.
- ▶ Avaliar a política é ineficiente e de **alta variância**.
- ▶ É **on-policy**: cada lote serve a uma atualização e é descartado.

Intuição

Escolha prática: ações discretas e simulador caro $\Rightarrow$ DQN. Ações contínuas ou política necessariamente estocástica $\Rightarrow$ gradiente de política. Os dois $\Rightarrow$ ator-crítico off-policy (SAC, DDPG).

- ▶ **Passo α é criticamente sensível.** Um passo grande demais destrói a política; como os dados seguintes são coletados *por ela*, não há como se recuperar. Este é o problema que motiva TRPO/PPO na próxima aula.
- ▶ **Colapso de entropia.** A política fica determinística cedo, a exploração morre, e o gradiente vai a zero. Remédio usual: um bônus de entropia $+\beta \mathcal{H}[\pi_\theta(\cdot \mid s)]$ no objetivo.
- ▶ **Normalize as vantagens** por lote; normalize também as observações.
- ▶ **Lotes grandes.** Gradiente de política precisa de muito mais amostras por atualização do que aprendizado supervisionado — a variância cai com $1/\sqrt{m}$.
- ▶ **Recompensas esparsas** continuam sendo o pior caso: se nenhuma trajetória do lote obtém recompensa, $\hat{g} \approx 0$ e nada acontece.

O que você deve levar desta aula

Definição — Capacidades esperadas

- ▶ Explicar por que uma política estocástica pode ser melhor sob observabilidade parcial.
- ▶ **Derivar** o gradiente por razão de verossimilhança e dizer por que a dinâmica desaparece.
- ▶ Calcular o escore de políticas softmax e gaussiana; implementar REINFORCE com e sem linha de base.
- ▶ Demonstrar que $b(s)$ não introduz viés — e o que quebra se ela depender da ação.
- ▶ Posicionar $\hat{A}^{(n)}$ no compromisso viés–variância.

Intuição

A moral: gradiente de política é “aumente a probabilidade do que deu certo”; o resto foi definir *o que conta como ter dado certo*.

Próxima aula

- ▶ O estimador está pronto; o *passo* não. Quão longe podemos andar em θ sem destruir a política que gera nossos dados?
- ▶ **Gradiente natural:** medir a distância entre políticas no espaço de *distribuições* (divergência KL), não no espaço de parâmetros.
- ▶ **TRPO e PPO:** garantir melhoria monotônica aproximada limitando a KL — e a versão barata, com razão de probabilidades recortada, que treina modelos de linguagem hoje.



Intuição

Leitura: Sutton & Barto (2018), cap. 13. Para o lado prático, o artigo de GAE (Schulman et al., 2016) é curto e vale cada página.