

Universidade Federal de Uberlândia

# Aula 5: Gradientes de política I

**Políticas parametrizadas • Razão de verossimilhança • REINFORCE •  
Linha de base e vantagem**

Prof. Marcelo Keese Albertini  
Universidade Federal de Uberlândia  
adaptado de Emma Brunskill, CS234 (Stanford)  
2026



# Onde estamos

## Do valor à política

- ▶ **Aulas 2–3:** com um modelo do mundo, calcular  $V^*$  e  $\pi^*$  por programação dinâmica.
- ▶ **Aula 4:** sem modelo, *aprender*  $\hat{Q}(s, a; w)$  a partir de amostras — MC, SARSA, Q-learning, aproximação de função, DQN.
- ▶ **Hoje:** descartar o intermediário. Parametrizar *diretamente* a política  $\pi_\theta(a \mid s)$  e subir o gradiente do retorno esperado.
- ▶ **Próxima aula:** tornar esse passo de gradiente confiável — gradiente natural, TRPO, PPO.

### Intuição

Em todo o curso até aqui, a política foi um *subproduto* do valor:  $\pi(s) = \arg \max_a \hat{Q}(s, a)$ . Hoje ela vira o objeto de primeira classe, e o valor — quando aparecer — será apenas um auxiliar para reduzir variância.

## Recapitulação: o que ficou da aula passada

Todo método de controle sem modelo da Aula 4 tinha a mesma forma — atualização incremental rumo a um *alvo*:

$$\Delta w = \alpha (\text{alvo} - \hat{Q}(s, a; w)) \nabla_w \hat{Q}(s, a; w)$$

| Método      | Alvo                                                                        |
|-------------|-----------------------------------------------------------------------------|
| Monte Carlo | $G_t$                                                                       |
| SARSA       | $r + \gamma \hat{Q}(s', a'; w)$                                             |
| Q-learning  | $r + \gamma \max_{a'} \hat{Q}(s', a'; w)$                                   |
| DQN         | $r + \gamma \max_{a'} \hat{Q}(s', a'; w^-)$ , amostrado de um <i>buffer</i> |

### Atenção

E a **tríade mortal** — aproximação de função + *bootstrapping* + off-policy — que retira as garantias. O DQN não a resolve: contorna-a com repetição de experiência e alvos fixos.

SEÇÃO 1

# Por que parametrizar a política

---

01

# Três famílias de algoritmos



- ▶ Hoje construímos a coluna do meio; o ator-crítico aparece no fim da aula, quase de graça.
- ▶ Notação:  $w$  continua sendo os pesos de uma *função valor*;  $\theta$  passa a ser os pesos da *política*.

## Definição — Política estocástica parametrizada

$$\pi_{\theta}(a \mid s) = \mathbb{P}[a_t = a \mid s_t = s; \theta], \quad \theta \in \mathbb{R}^n$$

Uma distribuição sobre ações, diferenciável em  $\theta$  sempre que é não nula. O objetivo é achar  $\theta$  que maximize o valor da política.

- ▶ Em espaços discretos: uma rede que produz *logits* e uma *softmax* no fim.
- ▶ Em espaços contínuos: uma rede que produz a média (e talvez o desvio) de uma gaussiana.
- ▶ Continuamos **sem modelo**: nada de  $P(s' \mid s, a)$  será necessário — e isso vai cair sozinho da matemática, o que é um dos fatos mais bonitos da aula.

# Por que não bastam políticas determinísticas

Três motivos

1. **Ações contínuas.** O  $\arg \max_a \hat{Q}(s, a)$  vira um problema de otimização *dentro* de cada passo. Com  $\pi_\theta$  a ação sai por uma passagem para frente na rede.
2. **Estados perceptualmente ambíguos.** Se o agente não distingue dois estados, a melhor política pode exigir *aleatoriedade* — veremos o exemplo já a seguir.
3. **Suavidade.** Um  $\epsilon$ -guloso muda de ação de forma descontínua quando dois valores  $\hat{Q}$  se cruzam;  $\pi_\theta$  muda suavemente com  $\theta$ . Isso costuma dar convergência mais estável.

## Intuição

Há um quarto motivo, moderno: quando a política é um modelo de linguagem, ela *já* é uma distribuição sobre tokens. Ajustá-la por gradiente de política é a coisa mais natural do mundo — é o que fazem RLHF, PPO e GRPO.

## Exemplo: o corredor com estados sinônimos

Corredor de cinco casas. O agente enxerga apenas atributos locais do tipo

$$\phi(s, a) = \mathbf{1}\{\text{há parede ao N, } a = \text{mover para L}\} \quad (\text{e análogos para N, S, L, O})$$



- ▶ As casas 2 e 4 têm paredes ao N e ao S: geram **exatamente o mesmo vetor de atributos**. O agente não pode distingui-las.
- ▶ Comparemos duas abordagens: valor aproximado  $Q_{\theta}(s, a) = f(\phi(s, a); \theta)$  contra política parametrizada  $\pi_{\theta}(a | s) = g(\phi(s, a); \theta)$ .



## O corredor: por que o determinismo falha

Como 2 e 4 são indistinguíveis, *qualquer* política determinística é obrigada a escolher a mesma ação nas duas:

### Atenção

**Sempre para o Leste:** da casa 2 chega ao objetivo; da casa 4 vai para a 5 e fica preso.

**Sempre para o Oeste:** simétrico. Em ambos os casos, *metade dos inícios nunca alcança o objetivo*.

### Intuição

RL baseado em valor aprende uma política quase determinística. O  $\epsilon$  salva no limite, mas o tempo esperado para escapar cresce como  $1/\epsilon$ : milhares de passos.

### A política ótima aqui é estocástica

$\pi_{\theta}(L \mid \text{parede N e S}) = \pi_{\theta}(O \mid \text{parede N e S}) = 0,5$ : um passeio aleatório local, que alcança o objetivo em poucos passos com alta probabilidade a partir de qualquer início.

## Teste sua compreensão

---

### Teste sua compreensão

O exemplo do corredor mostra que políticas estocásticas podem ser estritamente melhores que determinísticas.

Isso contradiz o teorema da Aula 2, que garante existir uma política *determinística* ótima para todo MDP finito? *Pergunta para discussão conduzida em aula.*

## Teste sua compreensão

### Teste sua compreensão

O exemplo do corredor mostra que políticas estocásticas podem ser estritamente melhores que determinísticas.

Isso contradiz o teorema da Aula 2, que garante existir uma política *determinística* ótima para todo MDP finito? *Pergunta para discussão conduzida em aula.*

### Resposta

**Não há contradição — o objeto mudou.** O teorema vale para MDPs, em que a política é função do *estado*. Aqui a política é função da *observação*  $\phi(s, \cdot)$ , que não identifica o estado: estamos de fato num POMDP (ou, equivalentemente, numa classe restrita de políticas que não separa 2 de 4). Sob restrição de representação — ou sob observabilidade parcial — o ótimo pode exigir aleatoriedade.

## SEÇÃO 2

# O objetivo e o truque da razão de verossimilhança

---

02

# O que exatamente vamos maximizar

## Definição — Valor de uma política parametrizada

Para MDPs episódicos com estado inicial  $s_0$  e horizonte  $T$ ,

$$V(\theta) := V(s_0, \theta) = \mathbb{E}_{\pi_\theta} \left[ \sum_{t=0}^T R(s_t, a_t) \mid \pi_\theta, s_0 \right]$$

A esperança é sobre estados e ações visitados por  $\pi_\theta$ .

Duas reescritas equivalentes — a escolha importa:

► **Por ação:**  $V(s_0, \theta) = \sum_a \pi_\theta(a \mid s_0) Q(s_0, a, \theta)$  (Sutton & Barto, 13.2)

► **Por trajetória:**  $V(\theta) = \sum_{\tau} P(\tau \mid \theta) R(\tau)$  (o caminho do boia)

## Intuição

A segunda forma trata tudo como *otimização estocástica pura*: derivação curta, e válida bem além de MDPs.

# Notação de trajetória

## Definição — Trajetória, retorno e verossimilhança

$$\tau = (s_0, a_0, r_0, s_1, a_1, r_1, \dots, s_{T-1}, a_{T-1}, r_{T-1}, s_T)$$

$$R(\tau) = \sum_{t=0}^T R(s_t, a_t), \quad P(\tau; \theta) = \mu(s_0) \prod_{t=0}^{T-1} \underbrace{\pi_{\theta}(a_t \mid s_t)}_{\text{política}} \underbrace{P(s_{t+1} \mid s_t, a_t)}_{\text{dinâmica}}$$

O problema de otimização fica  $\arg \max_{\theta} V(\theta) = \arg \max_{\theta} \sum_{\tau} P(\tau; \theta) R(\tau)$ .

### Atenção

Note quem depende de  $\theta$ : **apenas** os fatores  $\pi_{\theta}(a_t \mid s_t)$  — nem  $\mu$ , nem a dinâmica, nem  $R$ .

## Antes do gradiente: por que não otimização sem gradiente?

Maximizar  $V(\theta)$  é otimização de caixa-preta. Existem métodos que *não* usam gradiente:

- ▶ **Busca aleatória:** perturbar  $\theta$ , manter se melhorou.
- ▶ **Diferenças finitas:**  $\partial V / \partial \theta_k \approx [V(\theta + \varepsilon e_k) - V(\theta)] / \varepsilon$ .
- ▶ **Estratégias evolutivas e *cross-entropy method*.**

### Por que insistir no gradiente

Diferenças finitas exigem  $\mathcal{O}(n)$  avaliações *ruidosas* por passo — proibitivo com  $n$  na casa dos milhões. O gradiente analítico custa *uma* passagem para trás, qualquer que seja  $n$ .

### Intuição

Não os descarte: são competitivos quando  $n$  é pequeno ou quando o simulador é barato e massivamente paralelo (Salimans et al., 2017).

# Subida de gradiente na política

## Definição — Gradiente de política

$$\Delta\theta = \alpha \nabla_{\theta} V(s_0, \theta), \quad \nabla_{\theta} V(s_0, \theta) = \begin{pmatrix} \partial V(s_0, \theta) / \partial \theta_1 \\ \vdots \\ \partial V(s_0, \theta) / \partial \theta_n \end{pmatrix}$$

Sobe-se esse gradiente rumo a um **máximo local**;  $\alpha$  é o passo.

## Atenção

Local, não global — a principal desvantagem da família. Em troca: convergência suave, ações contínuas e políticas estocásticas.

A dificuldade:  $V(\theta) = \sum_{\tau} P(\tau; \theta) R(\tau)$  soma sobre um número astronômico de trajetórias, e não sabemos calcular  $P(\tau; \theta)$ .



## O truque da razão de verossimilhança

---

$$\nabla_{\theta} V(\theta) = \nabla_{\theta} \sum_{\tau} P(\tau; \theta) R(\tau) = \sum_{\tau} \nabla_{\theta} P(\tau; \theta) R(\tau)$$

( $R(\tau)$  não depende de  $\theta$ )

## O truque da razão de verossimilhança

---

$$\begin{aligned}\nabla_{\theta} V(\theta) &= \nabla_{\theta} \sum_{\tau} P(\tau; \theta) R(\tau) = \sum_{\tau} \nabla_{\theta} P(\tau; \theta) R(\tau) \\ &= \sum_{\tau} \frac{P(\tau; \theta)}{P(\tau; \theta)} \nabla_{\theta} P(\tau; \theta) R(\tau)\end{aligned}$$

( $R(\tau)$  não depende de  $\theta$ )

(multiplicar e dividir por  $P(\tau; \theta)$ )

## O truque da razão de verossimilhança

$$\begin{aligned}\nabla_{\theta} V(\theta) &= \nabla_{\theta} \sum_{\tau} P(\tau; \theta) R(\tau) = \sum_{\tau} \nabla_{\theta} P(\tau; \theta) R(\tau) && (R(\tau) \text{ não depende de } \theta) \\&= \sum_{\tau} \frac{P(\tau; \theta)}{P(\tau; \theta)} \nabla_{\theta} P(\tau; \theta) R(\tau) && (\text{multiplicar e dividir por } P(\tau; \theta)) \\&= \sum_{\tau} P(\tau; \theta) R(\tau) \underbrace{\frac{\nabla_{\theta} P(\tau; \theta)}{P(\tau; \theta)}}_{\text{razão de verossimilhança}} = \sum_{\tau} P(\tau; \theta) R(\tau) \nabla_{\theta} \log P(\tau; \theta) && (\text{pois } \nabla \log f = \nabla f / f)\end{aligned}$$

### O gradiente virou uma esperança

$\nabla_{\theta} V(\theta) = \mathbb{E}_{\tau \sim \pi_{\theta}} [R(\tau) \nabla_{\theta} \log P(\tau; \theta)]$  — e esperanças a gente estima por amostragem.

# Estimador de Monte Carlo

Com  $m$  trajetórias  $\tau^{(1)}, \dots, \tau^{(m)}$  coletadas rodando a política atual:

$$\nabla_{\theta} V(\theta) \approx \hat{g} = \frac{1}{m} \sum_{i=1}^m R(\tau^{(i)}) \nabla_{\theta} \log P(\tau^{(i)}; \theta)$$

- ▶ O estimador é **não enviesado**:  $\mathbb{E}[\hat{g}] = \nabla_{\theta} V(\theta)$  exatamente, para qualquer  $m$ .
- ▶ Mas ainda parece inútil:  $\log P(\tau; \theta)$  contém a dinâmica, que é desconhecida.
- ▶ **Próximo slide**: ao abrir o logaritmo, a dinâmica desaparece.

## Intuição

Repare no que já conseguimos: transformamos “derivar uma soma sobre todas as trajetórias” em “rodar a política algumas vezes e tirar uma média”. Todo o resto da aula é reduzir a *variância* dessa média.

## Decompondo a trajetória: a dinâmica cai fora

---

$$\nabla_{\theta} \log P(\tau^{(i)}; \theta) = \nabla_{\theta} \log \left[ \underbrace{\mu(s_0)}_{\text{distrib. inicial}} \prod_{t=0}^{T-1} \underbrace{\pi_{\theta}(a_t | s_t)}_{\text{política}} \underbrace{P(s_{t+1} | s_t, a_t)}_{\text{modelo de dinâmica}} \right]$$

## Decompondo a trajetória: a dinâmica cai fora

$$\begin{aligned}\nabla_{\theta} \log P(\tau^{(i)}; \theta) &= \nabla_{\theta} \log \left[ \underbrace{\mu(s_0)}_{\text{distrib. inicial}} \prod_{t=0}^{T-1} \underbrace{\pi_{\theta}(a_t | s_t)}_{\text{política}} \underbrace{P(s_{t+1} | s_t, a_t)}_{\text{modelo de dinâmica}} \right] \\ &= \nabla_{\theta} \left[ \log \mu(s_0) + \sum_{t=0}^{T-1} \log \pi_{\theta}(a_t | s_t) + \sum_{t=0}^{T-1} \log P(s_{t+1} | s_t, a_t) \right]\end{aligned}$$

## Decompondo a trajetória: a dinâmica cai fora

$$\begin{aligned}\nabla_{\theta} \log P(\tau^{(i)}; \theta) &= \nabla_{\theta} \log \left[ \underbrace{\mu(s_0)}_{\text{distrib. inicial}} \prod_{t=0}^{T-1} \underbrace{\pi_{\theta}(a_t | s_t)}_{\text{política}} \underbrace{P(s_{t+1} | s_t, a_t)}_{\text{modelo de dinâmica}} \right] \\&= \nabla_{\theta} \left[ \log \mu(s_0) + \sum_{t=0}^{T-1} \log \pi_{\theta}(a_t | s_t) + \sum_{t=0}^{T-1} \log P(s_{t+1} | s_t, a_t) \right] \\&= \sum_{t=0}^{T-1} \underbrace{\nabla_{\theta} \log \pi_{\theta}(a_t | s_t)}_{\text{função escore}}\end{aligned}$$

### Nenhum modelo de dinâmica é necessário

O logaritmo transforma produto em soma; a derivada aniquila o que não depende de  $\theta$ . Sobra só a política — que *nós* escolhemos.

# Gradiente de política por função escore

## Estimador completo (REINFORCE ingênuo)

$$\nabla_{\theta} V(\theta) \approx \hat{g} = \frac{1}{m} \sum_{i=1}^m R(\tau^{(i)}) \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t^{(i)} \mid s_t^{(i)})$$

Tudo que é preciso para calculá-lo:

1. Rodar a política e guardar  $(s_t, a_t, r_t)$ .
2. Somar as recompensas de cada trajetória.
3. Derivar  $\log \pi_{\theta}$  — diferenciação automática faz isso.

### Intuição

Sem modelo, sem  $\max$  sobre ações. Em compensação: precisamos de *episódios completos*, e o estimador é on-policy.



# A função escore

## Definição — Função escore (*score function*)

A derivada do logaritmo de uma verossimilhança parametrizada,  $\nabla_{\theta} \log p(x; \theta)$ . Aqui,  $\nabla_{\theta} \log \pi_{\theta}(a | s)$ : a direção em  $\theta$  que *mais aumenta* a log-probabilidade de ter escolhido  $a$  em  $s$ .

## Propriedade fundamental: o escore tem média zero

$$\mathbb{E}_{a \sim \pi_{\theta}(\cdot | s)} [\nabla_{\theta} \log \pi_{\theta}(a | s)] = \sum_a \pi_{\theta}(a | s) \frac{\nabla_{\theta} \pi_{\theta}(a | s)}{\pi_{\theta}(a | s)} = \nabla_{\theta} \sum_a \pi_{\theta}(a | s) = \nabla_{\theta} 1 = 0$$

Guarde esta identidade: é ela que provará, adiante, que uma *linha de base* não introduz viés.

## Política softmax e seu escore

Ações discretas, atributos  $\phi(s, a)$ , pesos lineares:

$$\pi_{\theta}(a \mid s) = \frac{e^{\phi(s,a)^{\top} \theta}}{\sum_{a'} e^{\phi(s,a')^{\top} \theta}}$$

$$\begin{aligned} \nabla_{\theta} \log \pi_{\theta}(a \mid s) &= \nabla_{\theta} \left[ \phi(s, a)^{\top} \theta - \log \sum_{a'} e^{\phi(s,a')^{\top} \theta} \right] \\ &= \phi(s, a) - \frac{\sum_{a'} \phi(s, a') e^{\phi(s,a')^{\top} \theta}}{\sum_{a'} e^{\phi(s,a')^{\top} \theta}} = \phi(s, a) - \mathbb{E}_{a' \sim \pi_{\theta}}[\phi(s, a')] \end{aligned}$$

### Intuição

**Atributo observado menos atributo esperado.** Se a ação tomada era “mais típica” do que a média, o escore é pequeno; se era atípica, o escore é grande. Multiplicado por um retorno alto, isso empurra a política justamente na direção do que foi surpreendentemente bom.

## Política gaussiana e seu escore

Para ações contínuas,  $a \in \mathbb{R}$  (ou  $\mathbb{R}^d$ ):

$$\mu_{\theta}(s) = \phi(s)^{\top} \theta, \quad a \sim \mathcal{N}(\mu_{\theta}(s), \sigma^2)$$

$$\nabla_{\theta} \log \pi_{\theta}(a | s) = \frac{(a - \mu_{\theta}(s)) \phi(s)}{\sigma^2}$$


- ▶  $\sigma^2$  pode ser fixa ou parametrizada — na prática funciona como **controle de exploração**, que a otimização vai encolhendo.
- ▶ Redes profundas substituem a forma linear sem alterar a derivação.

### Atenção

O fator  $1/\sigma^2$  explode quando  $\sigma \rightarrow 0$ : uma política que ficou quase determinística produz gradientes gigantescos e instáveis. É um dos modos de falha mais comuns em controle contínuo — limite  $\sigma$  por baixo.

# Intuição do estimador por função escore

Forma genérica de cada termo,  $\hat{g}_i = f(x_i) \nabla_{\theta} \log p(x_i; \theta)$ :



- ▶ Andar na direção  $\hat{g}_i$  **umenta a log-probabilidade da amostra**, na proporção de quão boa ela foi.
- ▶ Vale mesmo que  $f$  seja **descontínua, desconhecida ou discreta**: nunca derivamos  $f$ , só  $\log p$ .

# Por que isso é notável: *escore versus* reparametrização

## Definição — Escore (o que fizemos)

$$\nabla_{\theta} \mathbb{E}_{x \sim p_{\theta}}[f(x)] = \mathbb{E}[f(x) \nabla_{\theta} \log p_{\theta}(x)]$$

- +  $f$  pode ser caixa-preta
- + serve para  $x$  discreto
- variância alta

## Definição — Reparametrização

$$x = h_{\theta}(\epsilon), \quad \nabla_{\theta} \mathbb{E}[f] = \mathbb{E}[\nabla f \cdot \nabla_{\theta} h_{\theta}]$$

- + variância bem menor
- exige  $f$  diferenciável
- só para  $x$  contínuo

## Intuição

Em RL a “função” é o *mundo*: o placar de um jogo, a preferência de um avaliador humano. Não há gradiente para pegar — por isso o estimador por escore, caro em variância e barato em suposições, é o que sobrevive.

# Teorema do gradiente de política

## Teorema (Sutton et al., 2000)

Para toda política diferenciável  $\pi_\theta(a \mid s)$  e para qualquer um dos objetivos usuais —  $J_1$  (recompensa episódica),  $J_{avR}$  (recompensa média por passo) ou  $\frac{1}{1-\gamma} J_{avV}$  (valor médio) — o gradiente da política é

$$\nabla_\theta J(\theta) = \mathbb{E}_{\pi_\theta} \left[ \nabla_\theta \log \pi_\theta(a \mid s) Q^{\pi_\theta}(s, a) \right]$$

- ▶ Generaliza o que derivamos: no lugar do retorno da trajetória inteira, aparece o valor da ação  $Q^{\pi_\theta}(s, a)$ .
- ▶ **O que o teorema evita:** a distribuição de estados  $d^{\pi_\theta}$  também depende de  $\theta$ , mas o gradiente *não* contém  $\nabla_\theta d^{\pi_\theta}$  — esse é o resultado difícil (S&B, cap. 13.2).
- ▶ Todo o resto da aula consiste em escolher *o que colocar no lugar de*  $Q^{\pi_\theta}(s, a)$ .

## Teste sua compreensão

---

### Teste sua compreensão

Sobre o gradiente por razão de verossimilhança, quais afirmações são verdadeiras?

- (a) exige funções de recompensa diferenciáveis;
- (b) só pode ser usado com processos de decisão de Markov;
- (c) é útil principalmente em tarefas de horizonte infinito.

*Pergunta para discussão conduzida em aula.*

## Teste sua compreensão

### Teste sua compreensão

Sobre o gradiente por razão de verossimilhança, quais afirmações são verdadeiras?

- (a) exige funções de recompensa diferenciáveis;
- (b) só pode ser usado com processos de decisão de Markov;
- (c) é útil principalmente em tarefas de horizonte infinito.

*Pergunta para discussão conduzida em aula.*

### Resposta

**Nenhuma das três.** (a) Nunca derivamos  $R$ , só  $\log \pi_\theta$ . (b) A derivação só usou que  $P(\tau; \theta)$  fatora: vale para POMDPs, bandidos e geração de texto. (c) Ao contrário: supusemos episódios finitos.



SEÇÃO 3

## Reduzindo a variância

---

03

## O problema: não enviesado, mas ruidoso demais

$$\nabla_{\theta} V(\theta) \approx \frac{1}{m} \sum_{i=1}^m R(\tau^{(i)}) \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t^{(i)} \mid s_t^{(i)})$$

### Atenção

Não enviesado — e **de variância altíssima**. O sinal que atribuímos a *cada* ação é o retorno da trajetória *inteira*: uma ação excelente no passo 3 recebe a culpa por um desastre no passo 300.

Três correções, nesta ordem, e cada uma é uma ideia independente:

1. **Estrutura temporal** — uma ação não pode influenciar o passado.
2. **Linha de base** — comparar o retorno com o esperado, não com zero.
3. **Alternativas ao retorno de Monte Carlo** — trocar variância por um pouco de viés (ator-crítico).

## Correção 1: usar a estrutura temporal

---

Partindo de

$$\nabla_{\theta} \mathbb{E}_{\tau}[R] = \mathbb{E}_{\tau} \left[ \left( \sum_{t=0}^{T-1} r_t \right) \left( \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t \mid s_t) \right) \right]$$

## Correção 1: usar a estrutura temporal

---

Partindo de

$$\nabla_{\theta} \mathbb{E}_{\tau}[R] = \mathbb{E}_{\tau} \left[ \left( \sum_{t=0}^{T-1} r_t \right) \left( \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \right) \right]$$

O mesmo argumento, aplicado a *uma única* recompensa  $r_{t'}$ , dá

$$\nabla_{\theta} \mathbb{E}[r_{t'}] = \mathbb{E} \left[ r_{t'} \sum_{t=0}^{t'} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \right]$$

— só as ações *até*  $t'$  podem ter influenciado  $r_{t'}$ .

## Correção 1: usar a estrutura temporal

Partindo de

$$\nabla_{\theta} \mathbb{E}_{\tau}[R] = \mathbb{E}_{\tau} \left[ \left( \sum_{t=0}^{T-1} r_t \right) \left( \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \right) \right]$$

O mesmo argumento, aplicado a *uma única* recompensa  $r_{t'}$ , dá

$$\nabla_{\theta} \mathbb{E}[r_{t'}] = \mathbb{E} \left[ r_{t'} \sum_{t=0}^{t'} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \right]$$

— só as ações *até*  $t'$  podem ter influenciado  $r_{t'}$ .

Somando em  $t'$  e trocando a ordem dos somatórios:

$$\nabla_{\theta} V(\theta) = \mathbb{E} \left[ \sum_{t'=0}^{T-1} r_{t'} \sum_{t=0}^{t'} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \right] = \mathbb{E} \left[ \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \sum_{t'=t}^{T-1} r_{t'} \right]$$

## Correção 1: o resultado

### Cada ação é creditada apenas pelo que veio depois

Como  $\sum_{t'=t}^{T-1} r_{t'}^{(i)}$  é exatamente o retorno  $G_t^{(i)}$ ,

$$\nabla_{\theta} V(\theta) \approx \frac{1}{m} \sum_{i=1}^m \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t^{(i)} \mid s_t^{(i)}) G_t^{(i)}$$

- ▶ Removemos os termos  $r_{t'}$  com  $t' < t$ : em esperança eles valem **zero** (a ação não influencia o passado), mas contribuíam com variância pura.
- ▶ Continua não enviesado, com variância estritamente menor.

### Intuição

Princípio geral da aula: *remova do estimador tudo que tem esperança zero*. Não muda o alvo e reduz ruído — a linha de base, a seguir, é a mesma ideia.

# REINFORCE: gradiente de política por Monte Carlo

## Algoritmo — REINFORCE (Williams, 1992)

- ▶ Inicialize  $\theta$  arbitrariamente
- ▶ **para** cada episódio  $\{s_0, a_0, r_0, \dots, s_{T-1}, a_{T-1}, r_{T-1}\} \sim \pi_\theta$  **faça**
  - **para**  $t = 0$  até  $T - 1$  **faça**

$$\theta \leftarrow \theta + \alpha \nabla_\theta \log \pi_\theta(a_t | s_t) G_t$$

- **fim para**
  - ▶ **fim para**; devolva  $\theta$
- 
- ▶ Combina razão de verossimilhança + estrutura temporal.
  - ▶ É **on-policy** e exige o episódio completo (precisa de  $G_t$ ).
  - ▶ Publicado em 1992 — é o ancestral direto de tudo que vem depois.

## Por que ainda não funciona bem

Um exemplo de três linhas

Bandido de duas ações, política softmax, recompensas  $R(a_1) = 100$  e  $R(a_2) = 101$ .

- ▶ Ambos os retornos são grandes e positivos  $\Rightarrow$  o estimador **aumenta a log-probabilidade das duas ações** em toda amostra.
- ▶ A diferença entre elas — o único sinal útil — é 1, sepultada num sinal de magnitude 100.
- ▶ Agora some +1000 a todas as recompensas. O gradiente *verdadeiro* não muda (o escore tem média zero), mas a **variância do estimador explode**.

### Intuição

A escala absoluta da recompensa não deveria importar — e não importa em esperança. Ela só afeta o *ruído*. Consertar isso é exatamente o papel da linha de base.



## Correção 2: introduzir uma linha de base

### Definição — Linha de base $b(s)$

$$\nabla_{\theta} \mathbb{E}_{\tau}[R] = \mathbb{E}_{\tau} \left[ \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) (G_t - b(s_t)) \right]$$

Para **qualquer**  $b$  que dependa apenas do estado (não da ação), o estimador permanece não enviesado.

- ▶ Escolha quase ótima: o retorno esperado,  $b(s_t) \approx \mathbb{E}[r_t + \dots + r_{T-1}] = V^{\pi}(s_t)$ .
- ▶ **Leitura:** aumente a log-probabilidade de  $a_t$  na proporção de quanto o retorno foi *melhor que o esperado* naquele estado.

### Intuição

De “esta ação rendeu 101” para “esta ação rendeu 0,5 acima da média deste estado”. O segundo sinal é comparável entre estados; o primeiro, não.

# A linha de base não introduz viés — demonstração

$$\begin{aligned}\mathbb{E}_{\tau} [\nabla_{\theta} \log \pi_{\theta}(a_t | s_t) b(s_t)] &= \mathbb{E}_{s_{0:t}, a_{0:t-1}} \left[ \mathbb{E}_{a_t} [\nabla_{\theta} \log \pi_{\theta}(a_t | s_t) b(s_t)] \right] && \text{(quebrar a esperança)} \\ &= \mathbb{E}_{s_{0:t}, a_{0:t-1}} \left[ b(s_t) \mathbb{E}_{a_t} [\nabla_{\theta} \log \pi_{\theta}(a_t | s_t)] \right] && (b \text{ não depende de } a_t) \\ &= \mathbb{E} \left[ b(s_t) \sum_a \pi_{\theta}(a | s_t) \frac{\nabla_{\theta} \pi_{\theta}(a | s_t)}{\pi_{\theta}(a | s_t)} \right] && \text{(razão de verossimilhança)} \\ &= \mathbb{E} \left[ b(s_t) \nabla_{\theta} \sum_a \pi_{\theta}(a | s_t) \right] = \mathbb{E} [b(s_t) \nabla_{\theta} 1] = 0\end{aligned}$$

## Consequência

Subtrair  $b(s_t)$  altera a variância mas **não** a esperança: há liberdade total para escolher  $b$  minimizando o ruído. Atenção ao segundo passo — ele exige que  $b$  dependa só de  $s_t$ .

# O algoritmo “baunilha” de gradiente de política

## Algoritmo — Gradiente de política com linha de base

- ▶ Inicialize os parâmetros da política  $\theta$  e a linha de base  $b$
- ▶ **para** iteração = 1, 2, ... **faça**
  - Colete trajetórias executando a política atual
  - Em cada passo  $t$  de cada trajetória  $\tau^i$ , calcule o retorno  $G_t^i = \sum_{t'=t}^{T-1} r_{t'}^i$  e a vantagem  $\hat{A}_t^i = G_t^i - b(s_t)$
  - **Reajuste a linha de base** minimizando  $\sum_i \sum_t \|b(s_t) - G_t^i\|^2$
  - **Atualize a política** com  $\hat{g} = \sum_{i,t} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \hat{A}_t^i$  (via SGD ou Adam)
- ▶ **fim para**

## Intuição

Dois problemas supervisionados alternando: regressão (ajustar  $b$ ) e subida de gradiente ponderada (ajustar  $\pi_{\theta}$ ).

## Que linha de base escolher?

- ▶ **Constante:**  $b =$  média dos retornos do lote. Trivial, já ajuda muito.
- ▶ **Dependente do estado:**  $b(s) = \hat{V}^\pi(s; w)$ , uma rede treinada por regressão. É a escolha padrão.
- ▶ **Ótima em variância:** a linha de base que minimiza  $\text{Var}(\hat{g})$  é uma média dos retornos ponderada pelo escore ao quadrado,

$$b^* = \frac{\mathbb{E}[(\nabla_\theta \log \pi_\theta)^2 G_t]}{\mathbb{E}[(\nabla_\theta \log \pi_\theta)^2]}$$

Raramente vale o custo:  $\hat{V}^\pi$  chega perto e é mais simples.

### Atenção

Na prática faz-se também **normalização de vantagens** por lote:  $\hat{A} \leftarrow (\hat{A} - \bar{\hat{A}})/(\sigma_{\hat{A}} + \varepsilon)$  — viés pequeno, e o passo  $\alpha$  deixa de depender da escala da recompensa.

## Teste sua compreensão

### Teste sua compreensão

Um aluno propõe usar como linha de base  $b(s_t, a_t) = \hat{Q}^\pi(s_t, a_t)$  — afinal, dizem os slides, a escolha quase ótima é “o retorno esperado”, e  $\hat{Q}$  estima o retorno esperado com mais precisão que  $\hat{V}$ .

O estimador resultante ainda é não enviesado? O que ele calcularia? *Pergunta para discussão conduzida em aula.*

## Teste sua compreensão

### Teste sua compreensão

Um aluno propõe usar como linha de base  $b(s_t, a_t) = \hat{Q}^\pi(s_t, a_t)$  — afinal, dizem os slides, a escolha quase ótima é “o retorno esperado”, e  $\hat{Q}$  estima o retorno esperado com mais precisão que  $\hat{V}$ .

O estimador resultante ainda é não enviesado? O que ele calcularia? *Pergunta para discussão conduzida em aula.*

### Resposta

**Não.** A demonstração de não-viés exige que  $b$  dependa apenas de  $s_t$ ; com  $b$  dependendo de  $a_t$ , não se pode retirá-la da esperança sobre ações. Pior: o termo subtraído seria exatamente  $\mathbb{E}[\nabla_\theta \log \pi \cdot Q^\pi]$ , ou seja, o gradiente inteiro — em esperança o estimador daria **zero** e a política nunca aprenderia.

SEÇÃO 4

# Alternativas ao retorno de Monte Carlo

---

04

## Onde estamos e o que falta

$$\nabla_{\theta} \mathbb{E}[R] \approx \frac{1}{m} \sum_{i=1}^m \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) (G_t^{(i)} - b(s_t))$$

- ✓ Estrutura temporal e linha de base — ambas no somatório acima.
- **Alternativas a  $G_t$**  como estimativa do retorno esperado.

### Atenção

$G_t^i$  estima o valor a partir de *uma única* execução: não enviesada, mas carregando o ruído de todas as transições e escolhas de ação até o fim do episódio.

### Intuição


O remédio é o da Aula 4, quando comparamos MC e TD: introduzir **viés** via *bootstrapping* para comprar uma redução grande de **variância**.



# Métodos ator-crítico

## Definição — Ator e crítico

O **ator** é a política  $\pi_\theta$  — decide o que fazer. O **crítico** é a função valor  $\hat{V}(s; w)$  ou  $\hat{Q}(s, a; w)$  — avalia o que o ator fez. Ambos são aprendidos e atualizados.



- ▶ O crítico troca o retorno bruto por uma estimativa *bootstrapped*: menos ruidosa, ligeiramente enviesada. A3C (Mnih et al., 2016) popularizou a arquitetura; A2C, PPO e SAC a herdaram.

# A função vantagem

Partindo de  $\nabla_{\theta} \mathbb{E}_{\tau}[R] \approx \mathbb{E}[\sum_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) (Q(s_t, a_t; w) - b(s_t))]$  e tomando  $b(s) = \hat{V}^{\pi}(s)$ :

## Definição — Vantagem

$$A^{\pi}(s, a) = Q^{\pi}(s, a) - V^{\pi}(s) \quad \implies \quad \nabla_{\theta} \mathbb{E}_{\tau}[R] \approx \mathbb{E} \left[ \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \hat{A}^{\pi}(s_t, a_t) \right]$$

“Quanto esta ação é melhor do que a ação média neste estado.”

- ▶ Por construção,  $\mathbb{E}_{a \sim \pi}[A^{\pi}(s, a)] = 0$ : a vantagem é centrada.
- ▶ Positivo  $\Rightarrow$  torne a ação mais provável; negativo  $\Rightarrow$  menos. Sem esse centramento, “todas as ações ficam mais prováveis” — o que não faz sentido para uma distribuição.

## Estimadores de $n$ passos: um dial entre TD e MC

O crítico pode usar **qualquer mistura** entre alvo TD e alvo MC:

$$\hat{R}_t^{(1)} = r_t + \gamma \hat{V}(s_{t+1}), \quad \hat{R}_t^{(2)} = r_t + \gamma r_{t+1} + \gamma^2 \hat{V}(s_{t+2}), \quad \dots, \quad \hat{R}_t^{(\infty)} = \sum_{k \geq 0} \gamma^k r_{t+k}$$


Subtraindo a linha de base  $\hat{V}(s_t)$ , obtêm-se estimadores de vantagem:

$$\hat{A}_t^{(1)} = r_t + \gamma \hat{V}(s_{t+1}) - \hat{V}(s_t), \quad \hat{A}_t^{(\infty)} = \sum_{k \geq 0} \gamma^k r_{t+k} - \hat{V}(s_t)$$

### Intuição

$\hat{A}_t^{(1)}$  é exatamente o **erro TD**  $\delta_t$  da Aula 4, agora reaparecendo como sinal de aprendizado da *política*. O mesmo objeto, dois papéis.

# O compromisso viés–variância



- ▶  $n$  pequeno: alvo depende fortemente de  $\hat{V}$ , que está errado no início  $\Rightarrow$  **viés**.
- ▶  $n$  grande: alvo acumula o ruído de muitas transições  $\Rightarrow$  **variância**.
- ▶ **GAE** (Schulman et al., 2016) toma uma média exponencial de todos os  $n$  com peso  $\lambda$ :  
$$\hat{A}_t^{\text{GAE}} = \sum_{k \geq 0} (\gamma \lambda)^k \delta_{t+k}.$$
 É o padrão em PPO — e é exatamente o  $\lambda$  de  $\text{TD}(\lambda)$ .

## Teste sua compreensão

### Teste sua compreensão

Considerando

$$\hat{A}_t^{(1)} = r_t + \gamma \hat{V}(s_{t+1}) - \hat{V}(s_t), \quad \hat{A}_t^{(\infty)} = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \cdots - \hat{V}(s_t)$$

Classifique cada um quanto a viés e variância. *Pergunta para discussão conduzida em aula.*

## Teste sua compreensão

### Teste sua compreensão

Considerando

$$\hat{A}_t^{(1)} = r_t + \gamma \hat{V}(s_{t+1}) - \hat{V}(s_t), \quad \hat{A}_t^{(\infty)} = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \dots - \hat{V}(s_t)$$

Classifique cada um quanto a viés e variância. *Pergunta para discussão conduzida em aula.*

### Resposta

$\hat{A}_t^{(1)}$  tem **variância baixa e viés alto**: depende de uma única transição, mas herda todo o erro de  $\hat{V}(s_{t+1})$ .

$\hat{A}_t^{(\infty)}$  tem **variância alta e viés baixo**: usa recompensas reais até o fim (só  $\hat{V}(s_t)$ , a linha de base, é aproximada — e ela não introduz viés), ao custo de acumular o ruído de todo o episódio.

# O algoritmo baunilha, versão final

## Algoritmo — Gradiente de política com vantagem

- ▶ Inicialize os parâmetros da política  $\theta$  e do crítico  $w$
- ▶ **para** iteração = 1, 2, ... **faça**
  - Colete trajetórias executando  $\pi_\theta$
  - Em cada passo, calcule uma estimativa de vantagem  $\hat{A}_{it}^{(n)}$  (escolha de  $n$ , ou  $\text{GAE}(\lambda)$ )
  - Ajuste o crítico:  $w \leftarrow \arg \min_w \sum_{i,t} (\hat{V}(s_{it}; w) - \hat{R}_{it})^2$
  - Atualize a política com  $\hat{g} = \sum_{i,t} \nabla_\theta \log \pi_\theta(a_t | s_t) \hat{A}_{it}^{(n)}$
- ▶ **fim para**

## Intuição

Toda a família — REINFORCE, A2C, TRPO, PPO, GRPO — é este esqueleto com duas escolhas: *como estimar a vantagem* e *como limitar o passo*. A próxima aula trata da segunda.

SEÇÃO 5

## Balanço e próximos passos

---

05



# Vantagens e desvantagens do RL baseado em política

## Definição — Vantagens

- ▶ Convergência suave, sem oscilação por troca de  $\arg \max$ .
- ▶ Eficaz em ações **contínuas** ou de alta dimensão.
- ▶ Aprende políticas **estocásticas**.

## Atenção

- ▶ Converge a um **ótimo local**, não global.
- ▶ Avaliar a política é ineficiente e de **alta variância**.
- ▶ É **on-policy**: cada lote serve a uma atualização e é descartado.

## Intuição

Escolha prática: ações discretas e simulador caro  $\Rightarrow$  DQN. Ações contínuas ou política necessariamente estocástica  $\Rightarrow$  gradiente de política. Os dois  $\Rightarrow$  ator-crítico off-policy (SAC, DDPG).

- ▶ **Passo  $\alpha$  é criticamente sensível.** Um passo grande demais destrói a política; como os dados seguintes são coletados *por ela*, não há como se recuperar. Este é o problema que motiva TRPO/PPO na próxima aula.
- ▶ **Colapso de entropia.** A política fica determinística cedo, a exploração morre, e o gradiente vai a zero. Remédio usual: um bônus de entropia  $+\beta \mathcal{H}[\pi_{\theta}(\cdot | s)]$  no objetivo.
- ▶ **Normalize as vantagens** por lote; normalize também as observações.
- ▶ **Lotes grandes.** Gradiente de política precisa de muito mais amostras por atualização do que aprendizado supervisionado — a variância cai com  $1/\sqrt{m}$ .
- ▶ **Recompensas esparsas** continuam sendo o pior caso: se nenhuma trajetória do lote obtém recompensa,  $\hat{g} \approx 0$  e nada acontece.

# O que você deve levar desta aula

## Definição — Capacidades esperadas

- ▶ Explicar por que uma política estocástica pode ser melhor sob observabilidade parcial.
- ▶ **Derivar** o gradiente por razão de verossimilhança e dizer por que a dinâmica desaparece.
- ▶ Calcular o escore de políticas softmax e gaussiana; implementar REINFORCE com e sem linha de base.
- ▶ Demonstrar que  $b(s)$  não introduz viés — e o que quebra se ela depender da ação.
- ▶ Posicionar  $\hat{A}^{(n)}$  no compromisso viés–variância.

## Intuição

A moral: gradiente de política é “aumente a probabilidade do que deu certo”; o resto foi definir *o que conta como ter dado certo*.

## Próxima aula

- ▶ O estimador está pronto; o *passo* não. Quão longe podemos andar em  $\theta$  sem destruir a política que gera nossos dados?
- ▶ **Gradiente natural**: medir a distância entre políticas no espaço de *distribuições* (divergência KL), não no espaço de parâmetros.
- ▶ **TRPO** e **PPO**: garantir melhoria monotônica aproximada limitando a KL — e a versão barata, com razão de probabilidades recortada, que treina modelos de linguagem hoje.



### Intuição

Leitura: Sutton & Barto (2018), cap. 13. Para o lado prático, o artigo de GAE (Schulman et al., 2016) é curto e vale cada página.