

Aula 5 — Gradientes de política I

Políticas parametrizadas • Razão de verossimilhança • REINFORCE • Linha de base e vantagem

Prof. Marcelo Keese Albertini • Universidade Federal de Uberlândia

Material adaptado e expandido de CS234: *Reinforcement Learning*, Emma Brunskill (Stanford). Leitura complementar: Sutton & Barto (2018), cap. 13.

Como usar este handout

Este texto acompanha os slides da Aula 5 e é mais completo que eles em dois pontos: todas as passagens algébricas estão escritas por extenso, e há exercícios ao final com respostas comentadas. As caixas em âmbar (PARA DISCUTIR EM AULA) não têm resposta escrita de propósito — são os pontos que serão conduzidos presencialmente.

Roteiro

1. Por que parametrizar a política
2. O objetivo e a razão de verossimilhança
3. A função escore em duas famílias de políticas
4. Redução de variância: estrutura temporal e linha de base
5. Ator-crítico, vantagem e estimadores de n passos
6. Prática, formulário e exercícios

Pré-requisitos das aulas anteriores


- ▶ MDP, política, V^π e Q^π (Aula 2)
- ▶ Avaliação por Monte Carlo e por TD (Aula 3)
- ▶ Aproximação de função valor; MC versus TD como compromisso viés-variância (Aula 4)
- ▶ Gradiente, regra da cadeia, esperança condicional

Intuição

Em uma frase: até aqui a política era um subproduto do valor, $\pi(s) = \arg \max_a \hat{Q}(s, a)$. A partir de agora a política é o objeto que aprendemos, e o valor — quando aparecer — serve apenas para reduzir a variância do estimador do gradiente.

1 Por que parametrizar a política

1.1 As três famílias



Convenção de notação que usaremos o curso inteiro: w são pesos de uma *função valor*; θ são pesos de uma *política*.

Definição — Política estocástica parametrizada

$$\pi_{\theta}(a | s) = \mathbb{P}[a_t = a | s_t = s; \theta], \quad \theta \in \mathbb{R}^n,$$

diferenciável em θ sempre que é não nula. Em ações discretas, tipicamente uma *softmax* sobre *logits* produzidos por um modelo; em ações contínuas, tipicamente uma gaussiana cuja média (e possivelmente o desvio) sai do modelo.

1.2 Três razões para abandonar o arg max

- 1. Ações contínuas.** Extrair a política de $\hat{Q}$ exige resolver $\arg \max_a \hat{Q}(s, a)$ a cada passo de tempo — um problema de otimização aninhado. Com π_{θ} , obter a ação custa uma passagem para frente no modelo.
- 2. Observação ambígua.** Se dois estados diferentes produzem a mesma observação, a melhor política representável pode exigir aleatoriedade. É o exemplo da subseção seguinte.
- 3. Suavidade.** O ϵ -guloso muda de ação de forma descontínua quando dois valores $\hat{Q}$ se cruzam; π_{θ} varia continuamente com θ . Isso costuma produzir trajetórias de aprendizado mais estáveis.

Há ainda uma quarta razão, contemporânea: quando a política *já é* uma distribuição — um modelo de linguagem sobre tokens, por exemplo — ajustá-la por gradiente de política é a operação natural. É o que fazem RLHF, PPO e GRPO.

1.3 O corredor com estados sinônimos

Cinco casas em linha; o objetivo é a casa 3; as casas 1 e 5 são becos sem saída. O agente não observa o índice da casa: observa apenas atributos locais de parede, do tipo

$$\phi(s, a) = \mathbf{1}\{\text{há parede ao N, } a = \text{mover para L}\} \quad (\text{e análogos para N, S, L, O}).$$



As casas 2 e 4 têm paredes ao Norte e ao Sul e nada mais: produzem *exatamente* o mesmo vetor de atributos. As casas 1 e 5, ao contrário, são distinguíveis (uma tem parede a Oeste, a outra a Leste).

Atenção

Como 2 e 4 são indistinguíveis, toda política determinística é obrigada a escolher a *mesma* ação nas duas. Se escolher “Leste”, chega ao objetivo partindo da casa 2 mas fica presa partindo da casa 4; se escolher “Oeste”, o oposto. Em qualquer dos casos, metade dos inícios nunca alcança o objetivo, e o método baseado em valor — que aprende uma política quase determinística — depende do ϵ para escapar, com tempo de fuga da ordem de $1/\epsilon$ por casa.

A política ótima representável é estocástica

(continua)

Dentro da classe de políticas que enxergam apenas ϕ , o ótimo é

$$\pi_{\theta}(\text{Leste} \mid \text{parede N e S}) = \pi_{\theta}(\text{Oeste} \mid \text{parede N e S}) = 0,5.$$

O comportamento resultante é um passeio aleatório local, que alcança o objetivo em poucos passos com alta probabilidade a partir de qualquer início. Com custo de -1 por passo e início uniforme nas casas $\{1, 2, 4, 5\}$, o número esperado de passos é $3,5$.

Para discutir em aula

O exemplo mostra uma política estocástica estritamente melhor que qualquer determinística. Isso contradiz o teorema da Aula 2, segundo o qual todo MDP finito admite política determinística ótima?

2 O objetivo e a razão de verossimilhança

2.1 O que estamos maximizando

Definição — Valor de uma política parametrizada

Para MDPs episódicos com estado inicial s_0 e horizonte T ,

$$V(\theta) := V(s_0, \theta) = \mathbb{E}_{\pi_{\theta}} \left[\sum_{t=0}^T R(s_t, a_t) \mid \pi_{\theta}, s_0 \right],$$

onde a esperança é tomada sobre os estados e as ações visitados por π_{θ} .

Há duas maneiras equivalentes de reescrever esse valor, e a escolha define o caminho da derivação:

- ▶ **Por ação:** $V(s_0, \theta) = \sum_a \pi_{\theta}(a \mid s_0) Q(s_0, a, \theta)$. É o caminho de Sutton & Barto (cap. 13.2), que leva ao teorema do gradiente de política em sua forma geral.
- ▶ **Por trajetória:** $V(\theta) = \sum_{\tau} P(\tau; \theta) R(\tau)$. É o caminho que seguiremos: mais curto, e revela que o método vale bem além de MDPs.

Definição — Trajetória, retorno e verossimilhança

$$\tau = (s_0, a_0, r_0, s_1, a_1, r_1, \dots, s_{T-1}, a_{T-1}, r_{T-1}, s_T), \quad R(\tau) = \sum_{t=0}^T R(s_t, a_t),$$

$$P(\tau; \theta) = \mu(s_0) \prod_{t=0}^{T-1} \underbrace{\pi_{\theta}(a_t \mid s_t)}_{\text{política}} \underbrace{P(s_{t+1} \mid s_t, a_t)}_{\text{dinâmica}}$$

com μ a distribuição de estados iniciais. O problema é $\arg \max_{\theta} \sum_{\tau} P(\tau; \theta) R(\tau)$.

Atenção

Observe quem depende de θ nessa fatoração: **somente** os fatores $\pi_{\theta}(a_t \mid s_t)$. Nem μ , nem a dinâmica, nem a recompensa. Esse é o único fato de que a derivação inteira precisa.

2.2 Por que gradiente, e não busca direta

Maximizar $V(\theta)$ é, formalmente, otimização de caixa-preta, e existem métodos sem gradiente: busca aleatória, diferenças finitas, estratégias evolutivas, *cross-entropy method*. Diferenças finitas, por exemplo, estimam

$$\frac{\partial V}{\partial \theta_k} \approx \frac{V(\theta + \varepsilon e_k) - V(\theta)}{\varepsilon},$$

o que exige $\mathcal{O}(n)$ avaliações *ruidosas* de política por passo — inviável quando n está na casa dos milhões. O gradiente analítico custa uma única passagem para trás, independentemente de n , e ainda aproveita a estrutura temporal do problema. Métodos sem gradiente, porém, continuam competitivos com n pequeno ou com simuladores baratos e massivamente paralelos (Salimans et al., 2017).

2.3 O truque da razão de verossimilhança

Queremos $\nabla_{\theta} V(\theta)$ com $V(\theta) = \sum_{\tau} P(\tau; \theta) R(\tau)$. A dificuldade é dupla: a soma percorre um número astronômico de trajetórias, e não conhecemos $P(\tau; \theta)$. O truque a seguir resolve as duas de uma vez.

Derivação

$$\begin{aligned} \nabla_{\theta} V(\theta) &= \nabla_{\theta} \sum_{\tau} P(\tau; \theta) R(\tau) = \sum_{\tau} \nabla_{\theta} P(\tau; \theta) R(\tau) && R(\tau) \text{ não depende de } \theta \\ &= \sum_{\tau} \frac{P(\tau; \theta)}{P(\tau; \theta)} \nabla_{\theta} P(\tau; \theta) R(\tau) && \text{multiplicar e dividir por } P(\tau; \theta) \\ &= \sum_{\tau} P(\tau; \theta) R(\tau) \underbrace{\frac{\nabla_{\theta} P(\tau; \theta)}{P(\tau; \theta)}}_{\text{razão de verossimilhança}} && \text{agrupar} \\ &= \sum_{\tau} P(\tau; \theta) R(\tau) \nabla_{\theta} \log P(\tau; \theta) && \text{pois } \nabla \log f = \nabla f / f \end{aligned}$$

Ou seja,

$$\nabla_{\theta} V(\theta) = \mathbb{E}_{\tau \sim \pi_{\theta}} [R(\tau) \nabla_{\theta} \log P(\tau; \theta)]$$

O gradiente virou uma *esperança*, e esperanças se estimam por amostragem. Com m trajetórias coletadas rodando a política atual,

$$\nabla_{\theta} V(\theta) \approx \hat{g} = \frac{1}{m} \sum_{i=1}^m R(\tau^{(i)}) \nabla_{\theta} \log P(\tau^{(i)}; \theta),$$

estimador **não enviesado** para qualquer m . Falta, ainda, eliminar a dinâmica que está escondida dentro de $\log P$.

2.4 Decompondo a trajetória: a dinâmica desaparece

Decomposição

(continua)

$$\begin{aligned}
\nabla_{\theta} \log P(\tau; \theta) &= \nabla_{\theta} \log \left[\mu(s_0) \prod_{t=0}^{T-1} \pi_{\theta}(a_t | s_t) P(s_{t+1} | s_t, a_t) \right] \\
&= \nabla_{\theta} \left[\log \mu(s_0) + \sum_{t=0}^{T-1} \log \pi_{\theta}(a_t | s_t) + \sum_{t=0}^{T-1} \log P(s_{t+1} | s_t, a_t) \right] \\
&= \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t)
\end{aligned}$$

O logaritmo transforma produto em soma; a derivada em θ aniquila todo termo que não depende de θ . Sobram apenas os termos da política.

Juntando as duas peças, obtemos o estimador que dá nome à família:

$$\hat{g} = \frac{1}{m} \sum_{i=1}^m R(\tau^{(i)}) \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t^{(i)} | s_t^{(i)}). \quad (1)$$

Intuição

Para calcular (1) basta rodar a política, guardar (s_t, a_t, r_t) , somar as recompensas de cada episódio e derivar $\log \pi_{\theta}$ — o que a diferenciação automática faz sozinha. Nenhum modelo de dinâmica, nenhum max sobre ações. Em compensação, precisamos de episódios completos e o estimador é *on-policy*: dados coletados com um θ antigo não servem sem correção.

3 A função escore

Definição — Função escore

A derivada do logaritmo de uma verossimilhança parametrizada, $\nabla_{\theta} \log p(x; \theta)$. No nosso caso, $\nabla_{\theta} \log \pi_{\theta}(a | s)$: a direção em θ que mais aumenta a log-probabilidade de ter escolhido a ação a no estado s .

Propriedade fundamental: o escore tem média zero

$$\mathbb{E}_{a \sim \pi_{\theta}(\cdot | s)} [\nabla_{\theta} \log \pi_{\theta}(a | s)] = \sum_a \pi_{\theta}(a | s) \frac{\nabla_{\theta} \pi_{\theta}(a | s)}{\pi_{\theta}(a | s)} = \nabla_{\theta} \sum_a \pi_{\theta}(a | s) = \nabla_{\theta} 1 = 0.$$

Vale a pena registrar essa identidade agora: ela reaparece, sem disfarce, na demonstração de que a linha de base não introduz viés (Seção 4).

3.1 Política softmax

Para ações discretas, com atributos $\phi(s, a)$ e pesos lineares:

$$\begin{aligned}\pi_\theta(a | s) &= \frac{e^{\phi(s, a)^\top \theta}}{\sum_{a'} e^{\phi(s, a')^\top \theta}} \\ \nabla_\theta \log \pi_\theta(a | s) &= \nabla_\theta \left[\phi(s, a)^\top \theta - \log \sum_{a'} e^{\phi(s, a')^\top \theta} \right] \\ &= \phi(s, a) - \frac{\sum_{a'} \phi(s, a') e^{\phi(s, a')^\top \theta}}{\sum_{a'} e^{\phi(s, a')^\top \theta}} = \phi(s, a) - \mathbb{E}_{a' \sim \pi_\theta} [\phi(s, a')].\end{aligned}$$

Intuição

Atributo observado menos atributo esperado. Se a ação tomada era típica da política atual, o escore é pequeno; se era atípica, é grande. Multiplicado por um retorno alto, isso empurra a política exatamente na direção do que foi surpreendentemente bom.

No caso tabular (atributos *one-hot*, um parâmetro por ação), a expressão se reduz a $\nabla_\theta \log \pi_\theta(a) = e_a - \pi$, e o gradiente esperado tem forma fechada elegante:

$$\frac{\partial}{\partial \theta_a} \mathbb{E}[r] = \pi_\theta(a) (r_a - \mathbb{E}[r]). \quad (2)$$

Uma ação só ganha probabilidade se render *acima da média* — a linha de base já está aqui, escondida na própria álgebra do escore.

3.2 Política gaussiana

Para ações contínuas, com média linear nos atributos do estado:

$$\mu_\theta(s) = \phi(s)^\top \theta, \quad a \sim \mathcal{N}(\mu_\theta(s), \sigma^2), \quad \nabla_\theta \log \pi_\theta(a | s) = \frac{(a - \mu_\theta(s)) \phi(s)}{\sigma^2}.$$

O desvio σ pode ser fixo ou parametrizado; na prática funciona como um controle de exploração que a própria otimização vai encolhendo. Redes profundas substituem a forma linear sem alterar uma linha da derivação.

Atenção

O fator $1/\sigma^2$ explode quando $\sigma \rightarrow 0$: uma política que ficou quase determinística produz gradientes gigantescos e instáveis. É um dos modos de falha mais comuns em controle contínuo — imponha um limite inferior a σ .

3.3 Por que o estimador por escore é notável

Estimador por escore	Estimador por reparametrização
$\nabla_\theta \mathbb{E}_{x \sim p_\theta} [f(x)] = \mathbb{E} [f(x) \nabla_\theta \log p_\theta(x)]$	$x = h_\theta(\epsilon), \nabla_\theta \mathbb{E}[f] = \mathbb{E} [\nabla f \cdot \nabla_\theta h_\theta]$
+ f pode ser caixa-preta, descontínua ou desconhecida	+ variância bem menor
+ serve para x discreto	– exige f diferenciável
– variância alta	– só para x contínuo

Em aprendizagem por reforço, a “função” é o *mundo*: o placar de um jogo, a preferência de um avaliador humano, o resultado de um experimento. Não há gradiente para pegar. Por isso o estimador por escore — caro em variância, barato em suposições — é o que sobrevive.

Teorema do gradiente de política (Sutton et al., 2000)

Para toda política diferenciável $\pi_\theta(a | s)$ e para qualquer um dos objetivos usuais — J_1 (recompensa episódica), J_{avR} (recompensa média por passo) ou $\frac{1}{1-\gamma} J_{\text{avV}}$ (valor médio) — vale

$$\nabla_\theta J(\theta) = \mathbb{E}_{\pi_\theta} [\nabla_\theta \log \pi_\theta(a | s) Q^{\pi_\theta}(s, a)].$$

O teorema generaliza o que derivamos: no lugar do retorno da trajetória inteira aparece o valor da ação. O ponto tecnicamente difícil é que a distribuição de estados visitados d^{π_θ} também depende de θ , e ainda assim $\nabla_\theta d^{\pi_\theta}$ não aparece no resultado. Todo o restante da aula consiste em decidir o que colocar no lugar de $Q^{\pi_\theta}(s, a)$.

Para discutir em aula

Sobre o estimador (1), quais afirmações são verdadeiras? (a) exige funções de recompensa diferenciáveis; (b) só pode ser usado com processos de decisão de Markov; (c) é útil principalmente em tarefas de horizonte infinito.

4 Redução de variância

O estimador (1) é não enviesado e, ao mesmo tempo, de variância altíssima: o sinal atribuído a cada ação é o retorno da trajetória inteira. Uma decisão excelente no passo 3 recebe a culpa por um desastre no passo 300. Há três correções, e cada uma é uma ideia independente.

4.1 Correção 1: estrutura temporal

Partindo da forma fatorada,

$$\nabla_\theta \mathbb{E}_\tau[R] = \mathbb{E}_\tau \left[\left(\sum_{t=0}^{T-1} r_t \right) \left(\sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t | s_t) \right) \right],$$

o mesmo argumento aplicado a uma única recompensa $r_{t'}$ dá

$$\nabla_\theta \mathbb{E}[r_{t'}] = \mathbb{E} \left[r_{t'} \sum_{t=0}^{t'} \nabla_\theta \log \pi_\theta(a_t | s_t) \right],$$

pois apenas as ações tomadas até t' podem ter influenciado $r_{t'}$. Somando sobre t' e trocando a ordem dos somatórios:

$$\nabla_\theta V(\theta) = \mathbb{E} \left[\sum_{t'=0}^{T-1} r_{t'} \sum_{t=0}^{t'} \nabla_\theta \log \pi_\theta(a_t | s_t) \right] = \mathbb{E} \left[\sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t | s_t) \sum_{t'=t}^{T-1} r_{t'} \right].$$

O termo destacado é exatamente o retorno G_t , de modo que

$$\nabla_\theta V(\theta) \approx \frac{1}{m} \sum_{i=1}^m \sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t^{(i)} | s_t^{(i)}) G_t^{(i)}. \quad (3)$$

Intuição

Removemos os termos $r_{t'}$ com $t' < t$. Em esperança eles valem zero — uma ação não influencia o passado — mas contribuíam com ruído puro. Este é o princípio que organiza

(continua)

toda a seção: *remova do estimador tudo que tem esperança zero*; isso nunca muda o alvo e sempre reduz a variância.

Algoritmo — REINFORCE (Williams, 1992)

- ▶ Inicialize θ arbitrariamente.
- ▶ **para** cada episódio $\{s_0, a_0, r_0, \dots, s_{T-1}, a_{T-1}, r_{T-1}\} \sim \pi_\theta$ **faça**
 - **para** $t = 0$ até $T - 1$: $\theta \leftarrow \theta + \alpha \nabla_\theta \log \pi_\theta(a_t | s_t) G_t$
- ▶ **devolva** θ .

4.2 Por que ainda não basta

Considere um bandido de duas ações com $R(a_1) = 100$ e $R(a_2) = 101$. Os dois retornos são grandes e positivos, de modo que o estimador aumenta a log-probabilidade das *duas* ações em toda amostra; a diferença entre elas — o único sinal útil — vale 1, sepultada num sinal de magnitude 100. Pior: some +1000 a todas as recompensas. Pela identidade do escore de média zero, o gradiente verdadeiro **não muda**; a variância do estimador, sim, e cresce proporcionalmente ao deslocamento.

Atenção

A escala absoluta da recompensa não afeta o gradiente em esperança — afeta apenas o ruído. Corrigir isso é precisamente o papel da linha de base.

4.3 Correção 2: linha de base**Definição — Linha de base $b(s)$**

$$\nabla_\theta \mathbb{E}_\tau[R] = \mathbb{E}_\tau \left[\sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t | s_t) (G_t - b(s_t)) \right].$$

Para **qualquer** função b que dependa apenas do estado (não da ação), o estimador permanece não enviesado. A escolha quase ótima é o retorno esperado, $b(s_t) \approx V^\pi(s_t)$.

Demonstração

Basta mostrar que o termo subtraído tem esperança nula:

$$\begin{aligned} \mathbb{E}_\tau [\nabla_\theta \log \pi_\theta(a_t | s_t) b(s_t)] &= \mathbb{E}_{s_{0:t}, a_{0:t-1}} \left[\mathbb{E}_{a_t} [\nabla_\theta \log \pi_\theta(a_t | s_t) b(s_t)] \right] && \text{quebrar a esperança} \\ &= \mathbb{E}_{s_{0:t}, a_{0:t-1}} \left[b(s_t) \mathbb{E}_{a_t} [\nabla_\theta \log \pi_\theta(a_t | s_t)] \right] && b \text{ não depende de } a_t \\ &= \mathbb{E} \left[b(s_t) \sum_a \pi_\theta(a | s_t) \frac{\nabla_\theta \pi_\theta(a | s_t)}{\pi_\theta(a | s_t)} \right] && \text{razão de verossimilhança} \\ &= \mathbb{E} \left[b(s_t) \nabla_\theta \sum_a \pi_\theta(a | s_t) \right] = \mathbb{E} [b(s_t) \nabla_\theta 1] = 0. \end{aligned}$$

O segundo passo é o que exige b dependente apenas de s_t : com b função também da ação, ela não sai de dentro da esperança sobre a_t .

Interpretação prática: em vez de “esta ação rendeu 101”, o sinal passa a ser “esta ação rendeu 0,5 acima da média deste estado”. O segundo é comparável entre estados; o primeiro não é.

Algoritmo — Gradiente de política “baunilha”, com linha de base

- ▶ Inicialize os parâmetros da política θ e a linha de base b .
- ▶ **para** iteração = 1, 2, ... **faça**
 - Colete trajetórias executando a política atual.
 - Em cada passo t de cada trajetória τ^i , calcule o retorno $G_t^i = \sum_{t'=t}^{T-1} r_{t'}^i$ e a vantagem estimada $\hat{A}_t^i = G_t^i - b(s_t)$.
 - Reajuste a linha de base minimizando $\sum_i \sum_t (b(s_t) - G_t^i)^2$.
 - Atualize a política com $\hat{g} = \sum_{i,t} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \hat{A}_t^i$ (SGD ou Adam).

Intuição

São dois problemas supervisionados alternando: uma regressão (ajustar b aos retornos) e uma subida de gradiente ponderada (ajustar π_{θ}). Praticamente todo algoritmo moderno da família tem esse esqueleto.

4.4 Que linha de base escolher

- ▶ **Constante:** $b =$ média dos retornos do lote. Trivial de implementar e já resolve boa parte do problema.
- ▶ **Dependente do estado:** $b(s) = \hat{V}^{\pi}(s; w)$, treinada por regressão. É a escolha padrão.
- ▶ **Ótima em variância:** a linha de base que minimiza $\text{Var}(\hat{g})$ é a média dos retornos *ponderada pelo quadrado do escore*,

$$b^* = \frac{\mathbb{E}[(\nabla_{\theta} \log \pi_{\theta})^2 G_t]}{\mathbb{E}[(\nabla_{\theta} \log \pi_{\theta})^2]}.$$

Raramente compensa: $\hat{V}^{\pi}$ chega perto e é muito mais simples.

Na prática faz-se ainda **normalização de vantagens** por lote, $\hat{A} \leftarrow (\hat{A} - \bar{\hat{A}})/(\sigma_{\hat{A}} + \varepsilon)$. Isso introduz um viés pequeno, mas torna o passo α insensível à escala das recompensas.

Para discutir em aula

Um aluno propõe usar $b(s_t, a_t) = \hat{Q}^{\pi}(s_t, a_t)$ como linha de base — afinal, $\hat{Q}$ estima o retorno esperado com mais precisão que $\hat{V}$. O estimador resultante ainda é não enviesado? O que ele calcularia?

5 Ator-crítico, vantagem e estimadores de n passos

Depois das duas correções, o estimador está assim:


$$\nabla_{\theta} \mathbb{E}[R] \approx \frac{1}{m} \sum_{i=1}^m \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) (G_t^{(i)} - b(s_t)).$$

Falta a terceira correção: substituir $G_t^{(i)}$, que estima o valor a partir de *uma única* execução e carrega o ruído de todas as transições até o fim do episódio. O remédio é o mesmo da Aula 4, quando comparamos MC e TD: introduzir **viés** por meio de *bootstrapping* para comprar uma redução grande de **variância**.

5.1 Ator e crítico

Definição — Ator e crítico

O **ator** é a política π_θ — decide o que fazer. O **crítico** é a função valor $\hat{V}(s; w)$ ou $\hat{Q}(s, a; w)$ — avalia o que o ator fez. Ambos são aprendidos e atualizados a cada iteração.



Definição — Função vantagem

$$A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s) \quad \Rightarrow \quad \nabla_\theta \mathbb{E}_\tau[R] \approx \mathbb{E} \left[\sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t | s_t) \hat{A}^\pi(s_t, a_t) \right].$$

Lê-se: “quanto esta ação é melhor do que a ação média neste estado”. Por construção $\mathbb{E}_{a \sim \pi}[A^\pi(s, a)] = 0$ — a vantagem é centrada.

O centramento importa mais do que parece. Sem ele, um lote em que todos os retornos são positivos aumenta a probabilidade de *todas* as ações — o que não faz sentido para uma distribuição, já que as probabilidades somam 1. Com a vantagem, sinal positivo significa “torne esta ação mais provável” e negativo, “menos provável”.

5.2 Estimadores de n passos

O crítico pode usar qualquer mistura entre alvo TD e alvo Monte Carlo:

$$\hat{R}_t^{(1)} = r_t + \gamma \hat{V}(s_{t+1}), \quad \hat{R}_t^{(2)} = r_t + \gamma r_{t+1} + \gamma^2 \hat{V}(s_{t+2}), \quad \dots, \quad \hat{R}_t^{(\infty)} = \sum_{k \geq 0} \gamma^k r_{t+k}.$$

Subtraindo a linha de base $\hat{V}(s_t)$, obtêm-se estimadores de vantagem:

$$\hat{A}_t^{(1)} = r_t + \gamma \hat{V}(s_{t+1}) - \hat{V}(s_t) = \delta_t, \quad \hat{A}_t^{(\infty)} = \sum_{k \geq 0} \gamma^k r_{t+k} - \hat{V}(s_t).$$

Intuição

$\hat{A}^{(1)}$ é exatamente o **erro TD** δ_t da Aula 4, agora reaparecendo como sinal de aprendizado da *política*. O mesmo objeto matemático, dois papéis diferentes.



Com n pequeno, o alvo depende fortemente de $\hat{V}$, que está errado no início do treinamento: entra **viés**. Com n grande, o alvo acumula o ruído de muitas transições: entra **variância**. O estimador **GAE** (Schulman et al., 2016) evita ter que escolher um único n , tomando uma média exponencial de todos eles com peso λ :

$$\hat{A}_t^{\text{GAE}(\gamma, \lambda)} = \sum_{k \geq 0} (\gamma \lambda)^k \delta_{t+k},$$

que é o mesmo λ de TD(λ) e é o padrão usado em PPO.

Algoritmo — Gradiente de política com vantagem (versão final)

- ▶ Inicialize os parâmetros da política θ e do crítico w .
- ▶ **para** iteração = 1, 2, ... **faça**
 - Colete trajetórias executando π_θ .
 - Em cada passo, calcule a vantagem $\hat{A}_{it}^{(n)}$ (escolha de n , ou GAE(λ)).
 - Ajuste o crítico: $w \leftarrow \arg \min_w \sum_{i,t} (\hat{V}(s_{it}; w) - \hat{R}_{it})^2$.
 - Atualize a política com $\hat{g} = \sum_{i,t} \nabla_\theta \log \pi_\theta(a_t | s_t) \hat{A}_{it}^{(n)}$.

Toda a família — REINFORCE, A2C, A3C, TRPO, PPO, GRPO — é este esqueleto com duas escolhas: *como estimar a vantagem* e *como limitar o tamanho do passo*. A próxima aula trata da segunda.

Para discutir em aula

Classifique $\hat{A}^{(1)}$ e $\hat{A}^{(\infty)}$ quanto a viés e variância. Por que a aproximação $\hat{V}(s_t)$ que aparece nos dois não introduz viés, enquanto a $\hat{V}(s_{t+1})$ do primeiro introduz?

6 Prática, balanço e formulário

6.1 Vantagens e desvantagens da família

Vantagens	Desvantagens
Convergência suave, sem oscilação causada por troca de $\arg \max$.	Converge a um ótimo <i>local</i> , não global.
Eficaz em espaços de ação contínuos ou de alta dimensão.	Avaliar a política é ineficiente e de alta variância.
Aprende políticas estocásticas — necessário sob observabilidade parcial ou classe de políticas restrita.	É <i>on-policy</i> : cada lote serve a uma atualização e é descartado, o que a torna bem menos eficiente em amostras que o DQN com <i>replay</i> .

Regra prática de escolha: ações discretas com simulador caro sugerem DQN; ações contínuas, ou uma política que precisa ser estocástica, sugerem gradiente de política; querer as duas coisas leva a ator-crítico off-policy (DDPG, SAC).

6.2 Armadilhas que aparecem na primeira implementação

- ▶ **O passo α é criticamente sensível.** Um passo grande demais destrói a política; como os dados seguintes são coletados *por ela*, não há como se recuperar. É o problema que motiva TRPO e PPO.
- ▶ **Colapso de entropia.** A política fica determinística cedo, a exploração morre e o gradiente vai a zero. Remédio usual: um bônus de entropia $+\beta \mathcal{H}[\pi_\theta(\cdot | s)]$ no objetivo.

- ▶ **Escala.** Normalize as vantagens por lote e normalize também as observações.
- ▶ **Lotes grandes.** A variância do estimador cai com $1/\sqrt{m}$; gradiente de política precisa de muito mais amostras por atualização do que aprendizado supervisionado.
- ▶ **Recompensas esparsas** continuam sendo o pior caso: se nenhuma trajetória do lote obtém recompensa, $\hat{g} \approx 0$ e nada acontece.

6.3 Formulário

Resumo em cinco linhas

objetivo	$V(\theta) = \sum_{\tau} P(\tau; \theta) R(\tau)$
razão de verossimilhança	$\nabla_{\theta} V(\theta) = \mathbb{E}_{\tau} [R(\tau) \nabla_{\theta} \log P(\tau; \theta)]$
decomposição	$\nabla_{\theta} \log P(\tau; \theta) = \sum_t \nabla_{\theta} \log \pi_{\theta}(a_t s_t)$
REINFORCE com linha de base	$\hat{g} = \frac{1}{m} \sum_{i,t} \nabla_{\theta} \log \pi_{\theta}(a_t s_t) (G_t^i - b(s_t))$
forma geral (ator-crítico)	$\hat{g} = \frac{1}{m} \sum_{i,t} \nabla_{\theta} \log \pi_{\theta}(a_t s_t) \hat{A}_t$

Escore	softmax	$\phi(s, a) - \mathbb{E}_{a' \sim \pi_{\theta}} [\phi(s, a')]$
	gaussiana	$(a - \mu_{\theta}(s)) \phi(s) / \sigma^2$
Vantagem	n passos	$\hat{A}_t^{(n)} = \sum_{k < n} \gamma^k r_{t+k} + \gamma^n \hat{V}(s_{t+n}) - \hat{V}(s_t)$
	GAE(λ)	$\sum_{k \geq 0} (\gamma \lambda)^k \delta_{t+k}$, com $\delta_t = r_t + \gamma \hat{V}(s_{t+1}) - \hat{V}(s_t)$

6.4 Glossário de tradução

Inglês	Português	Inglês	Português
policy gradient	gradiente de política	baseline	linha de base
likelihood ratio	razão de verossimilhança	advantage	vantagem
score function	função escore	actor-critic	ator-crítico
trajectory / rollout	trajetória / episódio	bias-variance	viés-variância
step size	passo	on-policy	(mantido)

7 Exercícios

Exercício 5.1 — Escore da softmax tabular

Considere um único estado e três ações, com política softmax tabular $\pi(a) = e^{\theta_a} / \sum_{a'} e^{\theta_{a'}}$.

- Mostre que $\partial \log \pi(a) / \partial \theta_k = \mathbf{1}\{k = a\} - \pi(k)$.
- Conclua a expressão (2) para $\partial \mathbb{E}[r] / \partial \theta_a$.
- Com $r = (1, 2, 0)$ e $\theta = (0, 0, 0)$, calcule o gradiente esperado. Qual componente é positiva?

Exercício 5.2 — O deslocamento de recompensa

Seja um bandido de duas ações com política fixa $\pi = (0,5, 0,5)$, recompensas r_1, r_2 e um

(continua)

deslocamento constante c somado às duas.

- Mostre que o gradiente verdadeiro em θ_1 vale $\frac{1}{4}(r_1 - r_2)$, independentemente de c .
- Calcule a variância do estimador de uma amostra $\hat{g} = (r_a + c)(\mathbf{1}\{a = 1\} - \frac{1}{2})$ e mostre que ela cresce como c^2 .
- Repita com a linha de base $b = \mathbb{E}[r] + c$ e verifique que a variância deixa de depender de c .

Exercício 5.3 — Onde a demonstração quebra

Refaça a demonstração da Seção 4 com uma “linha de base” $b(s_t, a_t)$ que depende também da ação. Identifique exatamente qual passo deixa de valer e mostre que, se $b = Q^\pi$, o estimador tem esperança zero.

Exercício 5.4 — Estrutura temporal

Explique, sem contas, por que $\mathbb{E}[r_{t'} \nabla_\theta \log \pi_\theta(a_t | s_t)] = 0$ quando $t > t'$. Em seguida escreva a versão com desconto de (3).

Exercício 5.5 — Implementação

Implemente REINFORCE para o corredor da Seção 1 (custo -1 por passo, início uniforme nas casas $\{1, 2, 4, 5\}$, episódio truncado em 120 passos).

- Verifique que $\pi(\text{Leste} | \text{casa cinza})$ converge para aproximadamente 0,5.
- Compare o número médio de passos por episódio com o de um Q-learning ϵ -guloso sobre a mesma observação.
- Ligue e desligue a linha de base (média dos retornos do lote) e compare a variabilidade da curva de aprendizado.

Respostas comentadas

5.1 (a) Derive $\log \pi(a) = \theta_a - \log \sum_{a'} e^{\theta_{a'}}$: o primeiro termo contribui $\mathbf{1}\{k = a\}$ e o segundo, $-\pi(k)$. (b) $\partial \mathbb{E}[r] / \partial \theta_a = \sum_{a'} \pi(a') r_{a'} (\mathbf{1}\{a = a'\} - \pi(a)) = \pi(a)(r_a - \mathbb{E}[r])$. (c) Com $\pi = (1/3, 1/3, 1/3)$ e $\mathbb{E}[r] = 1$, o gradiente é $(0, 1/3, -1/3)$: apenas a componente de a_2 é positiva, pois só ela rende acima da média.

5.2 (a) $\mathbb{E}[\hat{g}] = \frac{1}{2}(r_1 + c)\frac{1}{2} + \frac{1}{2}(r_2 + c)(-\frac{1}{2}) = \frac{1}{4}(r_1 - r_2)$; o c se cancela porque $\mathbb{E}[\mathbf{1}\{a = 1\} - \frac{1}{2}] = 0$. (b) Como $(\mathbf{1}\{a = 1\} - \frac{1}{2})^2 = \frac{1}{4}$ sempre, $\mathbb{E}[\hat{g}^2] = \frac{1}{4}\mathbb{E}[(r_a + c)^2]$, que cresce como c^2 ; subtraindo o quadrado da média, que não depende de c , a variância também cresce como c^2 . (c) Com $b = \mathbb{E}[r] + c$, o fator vira $(r_a - \mathbb{E}[r])$ e o c desaparece antes de elevar ao quadrado.

5.3 O passo que quebra é o segundo da demonstração: com b dependendo de a_t , não é possível retirá-la de dentro de $\mathbb{E}_{a_t}[\cdot]$. Se $b = Q^\pi$, o termo subtraído é $\mathbb{E}[\nabla_\theta \log \pi \cdot Q^\pi]$ — exatamente o gradiente inteiro, pelo teorema do gradiente de política. O estimador teria esperança zero e a política nunca aprenderia.

5.4 A ação em t é escolhida depois de $r_{t'}$ ter sido gerada, logo $r_{t'}$ é independente de a_t dado s_t ; a esperança fatora e o score contribui com zero. Com desconto, $\hat{g} = \frac{1}{m} \sum_{i,t} \gamma^t \nabla_\theta \log \pi_\theta(a_t | s_t) G_t^{(i)}$ com $G_t^{(i)} = \sum_{t' > t} \gamma^{t'-t} r_{t'}$; na prática o fator γ^t externo costuma ser omitido, o que introduz um viés bem conhecido e geralmente tolerado.

5.5 Espera-se $\pi(\text{Leste}) \rightarrow 0,5$ nas casas cinzas e aproximadamente 3,5 passos por episódio; o Q-learning fixa uma ação nas casas cinzas e estabiliza num patamar bem mais alto, dependente

de ϵ . Sem linha de base a curva oscila visivelmente mais, embora convirja para o mesmo lugar — o estimador continua não enviesado. O laboratório interativo da aula reproduz os três itens.

Referências

- ▶ R. S. Sutton e A. G. Barto. *Reinforcement Learning: An Introduction*, 2ª ed., MIT Press, 2018 — capítulo 13.
- ▶ R. J. Williams. Simple statistical gradient-following algorithms for connectionist reinforcement learning. *Machine Learning*, 8:229–256, 1992.
- ▶ R. S. Sutton, D. McAllester, S. Singh e Y. Mansour. Policy gradient methods for reinforcement learning with function approximation. *NIPS*, 2000.
- ▶ J. Schulman, P. Moritz, S. Levine, M. Jordan e P. Abbeel. High-dimensional continuous control using generalized advantage estimation. *ICLR*, 2016.
- ▶ V. Mnih et al. Asynchronous methods for deep reinforcement learning. *ICML*, 2016.
- ▶ E. Brunskill. *CS234: Reinforcement Learning*, Stanford University — *Lecture 5: Policy Gradient I*. Material de origem desta aula.