

Universidade Federal de Uberlândia

Aula 6: Gradientes de política II variância, confiança e PPO

Linha de base • Ator-crítico • Limites de desempenho • PPO

Prof. Marcelo Keese Albertini
Universidade Federal de Uberlândia

adaptado de Emma Brunskill, CS234 (Stanford); seção avançada de Joshua Achiam

2026



Onde estamos

Três aulas sobre busca direta no espaço de políticas

Aula 5 — feito

Razão de verossimilhança, teorema do gradiente de política, REINFORCE.

Aula 6 — hoje

REINFORCE *funciona*, mas mal. Domar a variância; dar passos que não destroem a política.

Aula 7 — a seguir

GAE, teoria de melhoria monotônica e aprendizagem por imitação.

Intuição

A Aula 5 respondeu *para onde* andar. Hoje: **com que precisão** conhecemos essa direção, e **que passo** podemos dar sem cair.

Plano de hoje

1. **Linha de base** — por que subtrair $b(s)$ do retorno não muda o gradiente esperado, mas encolhe a variância; e qual é a melhor escolha de b .
2. **Alvos alternativos ao retorno de Monte Carlo** — de G_t ao crítico: ator-crítico e a função vantagem.
3. **Problemas estruturais do gradiente de política** — eficiência amostral, colapso de desempenho, e distância no espaço de *parâmetros* versus no espaço de *políticas*.
4. **Limites de desempenho relativo** — lema da diferença de desempenho, a aproximação $L_\pi(\pi')$ e a divergência KL.
5. **PPO** — penalidade KL adaptativa e objetivo recortado.

Os itens 3–5 seguem os slides de gradientes de política avançados de Joshua Achiam.

Teste sua compreensão

Selecione tudo o que é verdadeiro a respeito de gradientes de política:

1. $\nabla_{\theta} V(\theta) = \mathbb{E}_{\pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(s, a) Q^{\pi_{\theta}}(s, a)]$
2. θ é *sempre* incrementado na direção de $\nabla_{\theta} \ln \pi(s_t, a_t, \theta)$
3. Pares (s, a) com Q estimado maior têm, em média, sua probabilidade aumentada
4. Há garantia de convergência ao ótimo global da classe de políticas

Pergunta para discussão conduzida em aula.

Teste sua compreensão

Selecione tudo o que é verdadeiro a respeito de gradientes de política:

1. $\nabla_{\theta} V(\theta) = \mathbb{E}_{\pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(s, a) Q^{\pi_{\theta}}(s, a)]$
2. θ é *sempre* incrementado na direção de $\nabla_{\theta} \ln \pi(s_t, a_t, \theta)$
3. Pares (s, a) com Q estimado maior têm, em média, sua probabilidade aumentada
4. Há garantia de convergência ao ótimo global da classe de políticas

Pergunta para discussão conduzida em aula.

Resposta

1 e 3. O item 2 é falso: a direção é a do escore *multiplicado* por Q , e se inverte quando o retorno é negativo. O item 4 é falso: só há garantia de **ótimo local**.

SEÇÃO 1

Reduzindo a variância: a linha de base

01

REINFORCE: o ponto de partida

Algoritmo — REINFORCE (gradiente de política de Monte Carlo)

Inicialize θ arbitrariamente

para cada episódio $\{s_1, a_1, r_2, \dots, s_{T-1}, a_{T-1}, r_T\} \sim \pi_\theta$ **faça**

para $t = 1$ até $T - 1$ **faça**

$\theta \leftarrow \theta + \alpha \nabla_\theta \log \pi_\theta(s_t, a_t) G_t$

fim

fim **retorne** θ

REINFORCE: o ponto de partida

Algoritmo — REINFORCE (gradiente de política de Monte Carlo)

Inicialize θ arbitrariamente

para cada episódio $\{s_1, a_1, r_2, \dots, s_{T-1}, a_{T-1}, r_T\} \sim \pi_\theta$ **faça**

para $t = 1$ até $T - 1$ **faça**

$\theta \leftarrow \theta + \alpha \nabla_\theta \log \pi_\theta(s_t, a_t) G_t$

fim

fim **retorne** θ

Na forma de estimador com m trajetórias:

$$\nabla_\theta V(\theta) \approx \frac{1}{m} \sum_{i=1}^m R(\tau^{(i)}) \sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t^{(i)} | s_t^{(i)})$$

REINFORCE: o ponto de partida

Algoritmo — REINFORCE (gradiente de política de Monte Carlo)

Inicialize θ arbitrariamente

para cada episódio $\{s_1, a_1, r_2, \dots, s_{T-1}, a_{T-1}, r_T\} \sim \pi_\theta$ **faça**

para $t = 1$ até $T - 1$ **faça**

$\theta \leftarrow \theta + \alpha \nabla_\theta \log \pi_\theta(s_t, a_t) G_t$

fim

fim **retorne** θ

Na forma de estimador com m trajetórias:

$$\nabla_\theta V(\theta) \approx \frac{1}{m} \sum_{i=1}^m R(\tau^{(i)}) \sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t^{(i)} | s_t^{(i)})$$

Atenção

Não-viesado, porém muito ruidoso. Estar *certo em média* não é consolo se a variância é tão alta que o passo aponta para a direção errada na maioria dos lotes.

De onde vem a variância?

Três fontes distintas, com três remédios distintos

1. **Amostragem da trajetória.** τ é sorteada; o mesmo θ produz retornos diferentes a cada execução.
2. **Escala e deslocamento do retorno.** Se todos os retornos valem ≈ 100 , todo o gradiente empurra “para cima”, e o sinal útil é a *diferença* entre eles.
3. **Crédito temporal.** $R(\tau)$ multiplica o escore de **todas** as ações, inclusive as posteriores à recompensa — ruído puro.

Definição — Os três consertos

- ▶ **Estrutura temporal:** troque $R(\tau)$ por G_t (só o futuro conta) — visto na Aula 5.
- ▶ **Linha de base:** subtraia $b(s_t)$ — *hoje*.
- ▶ **Alvos alternativos:** troque G_t por um crítico — *hoje*.

Intuição

Os dois primeiros são **gratuitos**: reduzem variância sem viés. O terceiro troca viés por variância deliberadamente.

Definição — Gradiente de política com linha de base

$$\nabla_{\theta} \mathbb{E}_{\tau}[R] = \mathbb{E}_{\tau} \left[\sum_{t=0}^{T-1} \nabla_{\theta} \log \pi(a_t \mid s_t; \theta) \left(\sum_{t'=t}^{T-1} r_{t'} - b(s_t) \right) \right]$$

- ▶ Para **qualquer** b que dependa só do estado, e não da ação, o estimador continua não-viesado.
- ▶ Escolha quase ótima: o retorno esperado, $b(s_t) \approx \mathbb{E}[r_t + \dots + r_{T-1}]$.


Intuição

Leitura. Aumente a log-probabilidade de a_t na proporção em que o retorno foi *melhor do que o esperado* naquele estado. Sem linha de base, uma ação medíocre num estado excelente é reforçada tanto quanto uma excelente.


Por que isso importa: um exemplo de três ações

Mesmo estado, três ações, retornos 98, 101 e 104

Sem linha de base — pesos G_t



Com $b(s) = 101$ — pesos $G_t - b(s)$



Reforço quase igual para as três: o sinal (± 3) está afogado no nível (≈ 100).

a_1 é *desencorajada*, a_3 encorajada. A média do passo é a mesma; o ruído é muito menor.

Intuição

O **gradiente esperado é idêntico** nos dois painéis. Muda quantas trajetórias são necessárias para a média amostral chegar perto dele.

A linha de base não introduz viés

Basta mostrar que o termo extra tem esperança nula

$$\mathbb{E}_{\tau} [\nabla_{\theta} \log \pi(a_t | s_t; \theta) b(s_t)]$$

$$= \mathbb{E}_{s_{0:t}, a_{0:(t-1)}} \left[\mathbb{E}_{s_{(t+1):T}, a_{t:(T-1)}} [\nabla_{\theta} \log \pi(a_t | s_t; \theta) b(s_t)] \right] \quad (\text{quebra da esperança})$$

$$= \mathbb{E}_{s_{0:t}, a_{0:(t-1)}} \left[b(s_t) \mathbb{E}_{a_t} [\nabla_{\theta} \log \pi(a_t | s_t; \theta)] \right] \quad (b \text{ sai da esperança interna})$$

$$= \mathbb{E}_{s_{0:t}, a_{0:(t-1)}} \left[b(s_t) \sum_a \pi_{\theta}(a | s_t) \frac{\nabla_{\theta} \pi(a | s_t; \theta)}{\pi_{\theta}(a | s_t)} \right] \quad (\text{razão de verossimilhança, ao contrário})$$

$$= \mathbb{E}_{s_{0:t}, a_{0:(t-1)}} \left[b(s_t) \nabla_{\theta} \sum_a \pi(a | s_t; \theta) \right] = \mathbb{E}_{s_{0:t}, a_{0:(t-1)}} [b(s_t) \nabla_{\theta} 1] = 0 \quad (\text{normalização})$$

Intuição

Tudo se apoia em um fato só: $\sum_a \pi(a | s; \theta) = 1$ para todo θ , logo o gradiente dessa constante é nulo. É por isso que b não pode depender de a .

Por que a linha de base reduz a variância

A variância se decompõe aproximadamente por passo de tempo; concentre-se em um termo. Como a esperança **não depende de b** (acabamos de provar), minimizar a variância é minimizar só o momento de segunda ordem:

$$\arg \min_b \mathbb{E}_{s \sim d^\pi} \mathbb{E}_{a \sim \pi, G} \left[(\nabla_\theta \log \pi(a \mid s; \theta))^2 (G_t(s) - b(s))^2 \right]$$

Por que a linha de base reduz a variância

A variância se decompõe aproximadamente por passo de tempo; concentre-se em um termo. Como a esperança **não depende de b** (acabamos de provar), minimizar a variância é minimizar só o momento de segunda ordem:

$$\arg \min_b \mathbb{E}_{s \sim d^\pi} \mathbb{E}_{a \sim \pi, G} \left[(\nabla_\theta \log \pi(a \mid s; \theta))^2 (G_t(s) - b(s))^2 \right]$$

Linha de base de variância mínima

É um problema de **mínimos quadrados ponderados**. Derivando e igualando a zero:

$$b^*(s) = \frac{\mathbb{E} \left[(\nabla_\theta \log \pi(a \mid s; \theta))^2 G_t(s) \right]}{\mathbb{E} \left[(\nabla_\theta \log \pi(a \mid s; \theta))^2 \right]} \approx \mathbb{E}[G_t(s)] = V^\pi(s)$$

Isto é: a média dos retornos *ponderada pelo quadrado do escore*. Ignorando essa ponderação, sobra a média simples — a **função valor de estado**.

Algoritmo de gradiente de política “baunilha”

Algoritmo — Gradiente de política com linha de base aprendida

Inicialize o parâmetro da política θ e a linha de base b

para iteração = 1, 2, ... **faça**

 Colete um conjunto de trajetórias executando a política atual

 Em cada passo t de cada τ^i : retorno $G_t^i = \sum_{t' \geq t} r_{t'}^i$ e vantagem $\hat{A}_t^i = G_t^i - b(s_t^i)$

 Reajuste a linha de base minimizando $\sum_i \sum_t (b(s_t^i) - G_t^i)^2$

 Atualize a política com $\hat{g}$, soma de termos $\nabla_{\theta} \log \pi(a_t | s_t, \theta) \hat{A}_t$ (via SGD ou Adam)

fim

Intuição

Já é um método de **dois modelos** — um para a política, outro para o valor: estamos a um passo do ator-crítico. Note que b é ajustada com a *mesma* amostra que gera o gradiente; prático, mas correlaciona os dois.

Que outras linhas de base existem?

Definição — Funções valor como linha de base

Função valor de estado–ação:

$$Q^\pi(s, a) = \mathbb{E}_\pi[r_0 + \gamma r_1 + \gamma^2 r_2 + \cdots \mid s_0 = s, a_0 = a]$$

Função valor de estado — a linha de base natural:

$$V^\pi(s) = \mathbb{E}_\pi[r_0 + \gamma r_1 + \cdots \mid s_0 = s] = \mathbb{E}_{a \sim \pi}[Q^\pi(s, a)]$$

Outras escolhas usadas na prática:

- ▶ **Média do lote:** $b = \frac{1}{N} \sum G_t$. Constante, trivial, e já ajuda muito.
- ▶ **Regressão sobre atributos:**
 $b(s) = w^\top x(s)$.
- ▶ **Rede neural** treinada por regressão sobre G_t — o *crítico*.

Atenção

Normalizar as vantagens do lote ($\hat{A} \leftarrow (\hat{A} - \bar{\hat{A}}) / \sigma_{\hat{A}}$) é padrão em implementações — e *introduz* um viés pequeno.

SEÇÃO 2

Alvos alternativos: do retorno ao crítico

02

Escolhendo o alvo

G_t é uma estimativa de $V^\pi(s_t)$ obtida de uma única execução

- ▶ G_t^i é não-viesado para $V^\pi(s_t)$ — mas é uma amostra *única* de uma soma de muitas variáveis aleatórias.
- ▶ Reduza a variância **introduzindo viés**, via *bootstrapping* e aproximação de função.
- ▶ É o mesmo dilema de TD versus MC (Aula 3), agora aplicado ao alvo do gradiente de política.


Definição — Métodos ator-crítico

Mantêm representações explícitas **da política** (o ator) e **da função valor** (o crítico), e atualizam as duas. A estimativa de V ou Q é feita pelo crítico.

Intuição

O ator age; o crítico julga. A3C (Mnih et al., ICML 2016) popularizou a receita.

O laço ator–crítico



Atenção

O crítico transforma um retorno *observado até o fim do episódio* em um sinal disponível **no passo seguinte** — mas, se ele está errado, o ator otimiza a coisa errada. Os dois aprendem ao mesmo tempo, e a estabilidade dessa dança é assunto de metade da literatura da área.

Do retorno à vantagem

Partindo da forma com linha de base:

$$\nabla_{\theta} \mathbb{E}_{\tau}[R] = \mathbb{E}_{\tau} \left[\sum_{t=0}^{T-1} \nabla_{\theta} \log \pi(a_t | s_t; \theta) \left(\sum_{t'=t}^{T-1} r_{t'} - b(s_t) \right) \right]$$

Do retorno à vantagem

Partindo da forma com linha de base:

$$\nabla_{\theta} \mathbb{E}_{\tau}[R] = \mathbb{E}_{\tau} \left[\sum_{t=0}^{T-1} \nabla_{\theta} \log \pi(a_t | s_t; \theta) \left(\sum_{t'=t}^{T-1} r_{t'} - b(s_t) \right) \right]$$

Trocando o retorno amostral por um crítico $Q(s_t, a_t; w)$:

$$\nabla_{\theta} \mathbb{E}_{\tau}[R] \approx \mathbb{E}_{\tau} \left[\sum_{t=0}^{T-1} \nabla_{\theta} \log \pi(a_t | s_t; \theta) (Q(s_t, a_t; w) - b(s_t)) \right]$$

Do retorno à vantagem

Partindo da forma com linha de base:

$$\nabla_{\theta} \mathbb{E}_{\tau}[R] = \mathbb{E}_{\tau} \left[\sum_{t=0}^{T-1} \nabla_{\theta} \log \pi(a_t | s_t; \theta) \left(\sum_{t'=t}^{T-1} r_{t'} - b(s_t) \right) \right]$$

Trocando o retorno amostral por um crítico $Q(s_t, a_t; w)$:

$$\nabla_{\theta} \mathbb{E}_{\tau}[R] \approx \mathbb{E}_{\tau} \left[\sum_{t=0}^{T-1} \nabla_{\theta} \log \pi(a_t | s_t; \theta) (Q(s_t, a_t; w) - b(s_t)) \right]$$

E com a linha de base sendo uma estimativa de V , a expressão colapsa na **função vantagem**:

$$\nabla_{\theta} \mathbb{E}_{\tau}[R] \approx \mathbb{E}_{\tau} \left[\sum_{t=0}^{T-1} \nabla_{\theta} \log \pi(a_t | s_t; \theta) \hat{A}^{\pi}(s_t, a_t) \right]$$

Definição — Função vantagem

$A^{\pi}(s, a) = Q^{\pi}(s, a) - V^{\pi}(s)$: quanto a é melhor do que a ação *média* de π em s . Note que $\mathbb{E}_{a \sim \pi}[A^{\pi}(s, a)] = 0$ para todo s .

O catálogo de alvos

Todos dão o mesmo gradiente esperado — exceto os que não dão

Peso do escore	Nome	Viés	Variância
$R(\tau)$	retorno total da trajetória	nenhum	altíssima
$G_t = \sum_{t' \geq t} r_{t'}$	retorno futuro (estrutura temporal)	nenhum	muito alta
$G_t - b(s_t)$	retorno com linha de base	nenhum	alta
$G_t - V_w(s_t)$	vantagem de Monte Carlo	pequeno [†]	média
$\delta_t = r_t + \gamma V_w(s_{t+1}) - V_w(s_t)$	erro de TD	maior	baixa
$\hat{A}_t^{\text{GAE}(\gamma, \lambda)}$	vantagem generalizada	ajustável	ajustável

[†] o viés vem apenas do erro de aproximação de V_w ; se $V_w = V^\pi$, não há viés.

Intuição

Descer nesta tabela é caminhar do *Monte Carlo* para o *TD*. A última linha interpola entre as duas com um só parâmetro λ — assunto da próxima aula.

Teste sua compreensão

Trocamos o peso $G_t - b(s_t)$ por $\delta_t = r_t + \gamma V_w(s_{t+1}) - V_w(s_t)$.

1. A troca preserva a ausência de viés do estimador.
2. A troca reduz a variância.
3. Se $V_w = V^\pi$, então $\mathbb{E}[\delta_t \mid s_t, a_t] = A^\pi(s_t, a_t)$.
4. Uma linha de base $b(s, a)$ também manteria o estimador não-viesado.

Pergunta para discussão conduzida em aula.

Teste de compreensão — linha de base e vantagem

Teste sua compreensão

Trocamos o peso $G_t - b(s_t)$ por $\delta_t = r_t + \gamma V_w(s_{t+1}) - V_w(s_t)$.

1. A troca preserva a ausência de viés do estimador.
2. A troca reduz a variância.
3. Se $V_w = V^\pi$, então $\mathbb{E}[\delta_t \mid s_t, a_t] = A^\pi(s_t, a_t)$.
4. Uma linha de base $b(s, a)$ também manteria o estimador não-viesado.

Pergunta para discussão conduzida em aula.

Resposta

2 e 3. O item 1 é falso: há viés assim que $V_w \neq V^\pi$ — é o preço que pagamos. O item 4 é falso: a prova de não-viés exige tirar b de dentro de $\sum_a$.

SEÇÃO 3

Os problemas do gradiente de política

03

O problema de otimização, revisado

Os algoritmos de gradiente de política tentam resolver

$$\max_{\theta} J(\pi_{\theta}) := \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=0}^{\infty} \gamma^t r_t \right]$$

por subida de gradiente estocástica em θ , usando

$$g = \nabla_{\theta} J(\pi_{\theta}) = \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=0}^{\infty} \gamma^t \nabla_{\theta} \log \pi_{\theta}(a_t \mid s_t) A^{\pi_{\theta}}(s_t, a_t) \right]$$

O problema de otimização, revisado

Os algoritmos de gradiente de política tentam resolver

$$\max_{\theta} J(\pi_{\theta}) := \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=0}^{\infty} \gamma^t r_t \right]$$

por subida de gradiente estocástica em θ , usando

$$g = \nabla_{\theta} J(\pi_{\theta}) = \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=0}^{\infty} \gamma^t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) A^{\pi_{\theta}}(s_t, a_t) \right]$$

Atenção

Três limitações estruturais: (1) a eficiência amostral é ruim; (2) distância no *espaço de parâmetros* $\neq$ distância no *espaço de políticas*; (3) como consequência de (2), acertar o tamanho do passo é difícil — e errar pode ser catastrófico.

Limitação 1 — eficiência amostral

- ▶ Cada lote de dados é **descartado imediatamente** após um único passo de gradiente.
- ▶ Por quê? O gradiente de política é uma esperança *sob a política atual* — é **on-policy** por construção. Assim que θ muda, os dados envelhecem.

Duas maneiras de obter uma estimativa não-viesada:

- ▶ Amostrar trajetórias da própria política e formar a média amostral — *mais estável*.
- ▶ Usar trajetórias de outras políticas — *menos estável*.

Intuição

Oportunidade. Reaproveitar dados antigos para dar **vários** passos de gradiente antes de coletar novamente.


Atenção

Desafio. *Quantos* passos podemos dar antes que os dados deixem de descrever a política que estamos otimizando?

É a pergunta que o PPO responde no fim da aula.

Limitação 2 — o tamanho do passo

$\theta_{k+1} = \theta_k + \alpha_k \hat{g}_k$: um passo ruim pode ser irreversível




Atenção

Grande demais: colapso — e o colapso é *auto-reforçado*, porque a política ruim coleta dados ruins. **Pequeno demais:** progresso lento. E o tamanho “certo” **muda com θ** : nenhuma constante serve para a corrida inteira. Normalizar vantagens e usar Adam ajuda — mas resolve?

Limitação 3 — o problema é mais do que o passo

Considere $\pi_\theta(a=1) = \sigma(\theta)$, $\pi_\theta(a=2) = 1 - \sigma(\theta)$



Definição — Espaço de políticas

No caso tabular, o conjunto $\Pi = \{\pi \in \mathbb{R}^{|\mathcal{S}| \times |\mathcal{A}|} : \sum_a \pi_{sa} = 1, \pi_{sa} \geq 0\}$.

Intuição

A pergunta que organiza o resto da aula:
como atualizar de modo a **nunca mudar a política mais do que pretendíamos?**

SEÇÃO 4

Limites de desempenho relativo

04

O que queremos de uma regra de atualização

- ▶ Usar as trajetórias da política **mais recente** com a maior eficiência possível.
 - ▶ Dar passos que respeitem distância no **espaço de políticas**, não no espaço de parâmetros.
- Para isso, precisamos de uma identidade que relacione o desempenho de *duas* políticas.

Lema da diferença de desempenho

Para quaisquer políticas π e π' ,

$$J(\pi') - J(\pi) = \mathbb{E}_{\tau \sim \pi'} \left[\sum_{t=0}^{\infty} \gamma^t A^{\pi}(s_t, a_t) \right] = \frac{1}{1 - \gamma} \mathbb{E}_{\substack{s \sim d^{\pi'} \\ a \sim \pi'}} [A^{\pi}(s, a)]$$

Intuição

Leitura: a melhoria de π' sobre π é a vantagem média, medida com a régua antiga A^{π} , ao longo das trajetórias novas. Toda a teoria desta aula é uma tentativa de tornar essa expressão computável.

A distribuição descontada de estados futuros

Definição — d^π

$d^\pi(s) = (1 - \gamma) \sum_{t \geq 0} \gamma^t \mathbb{P}(s_t = s \mid \pi)$ — a frequência com que π visita s , com visitas tardias descontadas por γ^t . O fator $(1 - \gamma)$ normaliza: $\sum_s d^\pi(s) = 1$.

A distribuição descontada de estados futuros

Definição — d^π

$d^\pi(s) = (1 - \gamma) \sum_{t \geq 0} \gamma^t \mathbb{P}(s_t = s \mid \pi)$ — a frequência com que π visita s , com visitas tardias descontadas por γ^t . O fator $(1 - \gamma)$ normaliza: $\sum_s d^\pi(s) = 1$.

Substituindo no lema e reescrevendo a esperança sobre ações por amostragem por importância:

$$J(\pi') - J(\pi) = \frac{1}{1 - \gamma} \mathbb{E}_{\substack{s \sim d^{\pi'} \\ a \sim \pi'}} [A^\pi(s, a)] = \frac{1}{1 - \gamma} \mathbb{E}_{\substack{s \sim d^{\pi'} \\ a \sim \pi'}} \left[\frac{\pi'(a \mid s)}{\pi(a \mid s)} A^\pi(s, a) \right]$$

A distribuição descontada de estados futuros

Definição — d^π

$d^\pi(s) = (1 - \gamma) \sum_{t \geq 0} \gamma^t \mathbb{P}(s_t = s \mid \pi)$ — a frequência com que π visita s , com visitas tardias descontadas por γ^t . O fator $(1 - \gamma)$ normaliza: $\sum_s d^\pi(s) = 1$.

Substituindo no lema e reescrevendo a esperança sobre ações por **amostragem por importância**:

$$J(\pi') - J(\pi) = \frac{1}{1 - \gamma} \mathbb{E}_{\substack{s \sim d^{\pi'} \\ a \sim \pi'}} [A^\pi(s, a)] = \frac{1}{1 - \gamma} \mathbb{E}_{\substack{s \sim d^{\pi'} \\ a \sim \pi'}} \left[\frac{\pi'(a \mid s)}{\pi(a \mid s)} A^\pi(s, a) \right]$$

Atenção

Quase lá — as *ações* já vêm da política antiga. Resta $s \sim d^{\pi'}$: os **estados** ainda são visitados pela política nova, que é justamente a que ainda não temos.

Uma aproximação útil

E se simplesmente disséssemos $d^{\pi'} \approx d^{\pi}$?

$$J(\pi') - J(\pi) \approx \frac{1}{1 - \gamma} \mathbb{E}_{\substack{s \sim d^{\pi} \\ a \sim \pi}} \left[\frac{\pi'(a | s)}{\pi(a | s)} A^{\pi}(s, a) \right] := L_{\pi}(\pi')$$

Uma aproximação útil

E se simplesmente disséssemos $d^{\pi'} \approx d^{\pi}$?

$$J(\pi') - J(\pi) \approx \frac{1}{1 - \gamma} \mathbb{E}_{s \sim d^{\pi}} \left[\frac{\pi'(a | s)}{\pi(a | s)} A^{\pi}(s, a) \right] := L_{\pi}(\pi')$$

Limite de desempenho relativo (Achiam, Held, Tamar e Abbeel, 2017)

$$|J(\pi') - (J(\pi) + L_{\pi}(\pi'))| \leq C \sqrt{\mathbb{E}_{s \sim d^{\pi}} [D_{\text{KL}}(\pi' \| \pi) [s]]}$$

Intuição

O erro cometido ao trocar $d^{\pi'}$ por d^{π} é controlado pela **divergência KL média entre as políticas**. Se elas são próximas em KL, a aproximação é boa — e $L_{\pi}(\pi')$ vira um *substituto* legítimo do objetivo verdadeiro.

Divergência de Kullback–Leibler

Definição — D_{KL}

Para distribuições P e Q sobre uma variável discreta,

$$D_{KL}(P \parallel Q) = \sum_x P(x) \log \frac{P(x)}{Q(x)}$$

Entre políticas, em um estado s :

$$D_{KL}(\pi' \parallel \pi) [s] = \sum_{a \in \mathcal{A}} \pi'(a \mid s) \log \frac{\pi'(a \mid s)}{\pi(a \mid s)}$$

Propriedades

- ▶ $D_{KL}(P \parallel P) = 0$
- ▶ $D_{KL}(P \parallel Q) \geq 0$
- ▶ $D_{KL}(P \parallel Q) \neq D_{KL}(Q \parallel P)$ — **não é simétrica**, logo não é uma métrica.

Intuição

É a régua certa aqui porque mede diferença *entre distribuições*, e não entre os parâmetros que as geram — exatamente a distinção do slide da sigmoide.

O que ganhamos com a aproximação

$$L_{\pi}(\pi') = \frac{1}{1-\gamma} \mathbb{E}_{\substack{s \sim d^{\pi} \\ a \sim \pi}} \left[\frac{\pi'(a | s)}{\pi(a | s)} A^{\pi}(s, a) \right] = \mathbb{E}_{\tau \sim \pi} \left[\sum_{t=0}^{\infty} \gamma^t \frac{\pi'(a_t | s_t)}{\pi(a_t | s_t)} A^{\pi}(s_t, a_t) \right]$$

- ▶ Tudo do lado direito é estimável com trajetórias amostradas da política **antiga** π . Podemos otimizar π' sem coletar dados novos — isto é, dar **vários passos de gradiente por lote**.
- ▶ É parente da amostragem por importância, mas com uma diferença crucial: o peso depende *só do passo atual*, e não do histórico inteiro. Não há produto de t razões, logo os pesos não explodem nem desaparecem.

Atenção

A licença é condicional: $L_{\pi}(\pi')$ só aproxima o objetivo verdadeiro **enquanto π' ficar perto de π em KL**. Otimizar L_{π} sem restrição é otimizar um modelo fora de sua região de validade.

A região de confiança

curvas de nível de L_{π_k}



Intuição

Maximizar o substituto *dentro* da bola de KL é a ideia por trás de TRPO e, de forma aproximada e barata, do PPO. Fora da bola, o substituto deixa de ser informativo sobre o objetivo real.

Teste sua compreensão

Sobre $L_\pi(\pi')$ e o limite de desempenho relativo:

1. $L_\pi(\pi) = 0$.
2. Em $\pi' = \pi$, o gradiente de L_π coincide com o gradiente de política usual.
3. O limite deixa de valer se π' estiver longe de π .
4. Se $L_\pi(\pi') > 0$, então $J(\pi') > J(\pi)$.

Pergunta para discussão conduzida em aula.

Teste de compreensão — o substituto

Teste sua compreensão

Sobre $L_\pi(\pi')$ e o limite de desempenho relativo:

1. $L_\pi(\pi) = 0$.
2. Em $\pi' = \pi$, o gradiente de L_π coincide com o gradiente de política usual.
3. O limite deixa de valer se π' estiver longe de π .
4. Se $L_\pi(\pi') > 0$, então $J(\pi') > J(\pi)$.

Pergunta para discussão conduzida em aula.

Resposta

1 e 2. Em $\pi' = \pi$ a razão vale 1 e $\mathbb{E}_{a \sim \pi}[A^\pi] = 0$; derivando, reobtemos o gradiente da Aula 5 — L_π *estende* aquele gradiente. O item 3 é falso: o limite vale sempre, mas a folga fica grande demais para informar — daí o item 4 também ser falso.

Leituras recomendadas

- ▶ **Kakade e Langford (2002)** — *Approximately Optimal Approximate Reinforcement Learning*. A origem da ideia de atualização conservadora de políticas.
- ▶ **Schulman et al. (2015)** — *Trust Region Policy Optimization* (TRPO). A restrição de KL imposta exatamente, via gradiente natural.
- ▶ **Achiam et al. (2017)** — *Constrained Policy Optimization*. Origem do limite apresentado neste slide.
- ▶ **Schulman et al. (2017)** — *Proximal Policy Optimization Algorithms*. O que veremos a seguir.

Intuição

A sequência histórica é instrutiva: cada trabalho troca um pouco de rigor por muita simplicidade de implementação. O PPO é o extremo dessa troca — e é o que todo mundo usa.

SEÇÃO 5

Otimização proximal de política (PPO)

05

PPO: duas maneiras de não se afastar demais

Uma família de métodos que impõe a restrição de KL *aproximadamente*, sem gradiente natural

Definição — Penalidade KL adaptativa

A atualização resolve um problema **sem restrição**:

$$\theta_{k+1} = \arg \max_{\theta} L_{\theta_k}(\theta) - \beta_k \bar{D}_{\text{KL}}(\theta \| \theta_k)$$

com $\bar{D}_{\text{KL}}(\theta \| \theta_k) = \mathbb{E}_{s \sim d^{\pi_k}} [D_{\text{KL}}(\pi_{\theta_k}(\cdot | s) \| \pi_{\theta}(\cdot | s))]$. O coeficiente β_k **muda entre iterações** para fazer cumprir aproximadamente a restrição.

Definição — Objetivo recortado

Nenhuma penalidade explícita: a própria função objetivo é *achata* onde a política se afasta demais. É a variante mais usada — e a que vocês implementarão.

Intuição

TRPO resolve o problema com restrição de KL de forma exata e cara. O PPO faz um remendo barato que, empiricamente, funciona quase igual.

PPO com penalidade KL adaptativa

Algoritmo — PPO — penalidade KL adaptativa

Entrada: θ_0 , penalidade inicial β_0 , KL alvo δ

para $k = 0, 1, 2, \dots$ **faça**

 Colete trajetórias parciais $\mathcal{D}_k$ com $\pi_k = \pi(\theta_k)$

 Estime as vantagens $\hat{A}_t^{\pi_k}$ por qualquer método

 Calcule $\theta_{k+1} = \arg \max_{\theta} L_{\theta_k}(\theta) - \beta_k \bar{D}_{\text{KL}}(\theta \| \theta_k)$ com K passos de SGD por minilotes (Adam)

se $\bar{D}_{\text{KL}}(\theta_{k+1} \| \theta_k) \geq 1,5 \delta$ **então** $\beta_{k+1} = 2\beta_k$

senão se $\bar{D}_{\text{KL}}(\theta_{k+1} \| \theta_k) \leq \delta/1,5$ **então** $\beta_{k+1} = \beta_k/2$

fim

Intuição

O valor inicial de β **não importa muito** — ele se adapta rápido. Algumas iterações violam a restrição; a maioria não. E o K é o ponto central: é aqui que finalmente damos vários passos por lote.

PPO com objetivo recortado

Definição — Razão de probabilidades e objetivo L^{CLIP}

Seja $r_t(\theta) = \frac{\pi_\theta(a_t | s_t)}{\pi_{\theta_k}(a_t | s_t)}$. Então


$$L_{\theta_k}^{\text{CLIP}}(\theta) = \mathbb{E}_{\tau \sim \pi_k} \left[\sum_{t=0}^T \min \left(r_t(\theta) \hat{A}_t^{\pi_k}, \text{clip} \left(r_t(\theta), 1 - \epsilon, 1 + \epsilon \right) \hat{A}_t^{\pi_k} \right) \right]$$

onde ϵ é um hiperparâmetro (tipicamente $\epsilon = 0,2$). A atualização é $\theta_{k+1} = \arg \max_{\theta} L_{\theta_k}^{\text{CLIP}}(\theta)$.


- ▶ $r_t(\theta_k) = 1$: no início de cada época de otimização, a razão vale exatamente 1 e o objetivo coincide com L_{θ_k} .
- ▶ O $\min$ com a versão recortada torna o objetivo um **limite inferior pessimista** do substituto — nunca otimista quanto ao ganho de se afastar.

A geometria do recorte

L^{CLIP} em função de r , para um único passo de tempo



O ganho *satura* em $1 + \epsilon$: não há prêmio por aumentar mais a probabilidade da ação.



A punição *não* satura à direita: uma ação ruim que ficou muito mais provável continua sendo penalizada.

Por que o mínimo, e por que a assimetria

- ▶ $\hat{A}_t > 0$ (**ação boa**). O objetivo cresce com r até $1 + \epsilon$ e depois fica plano: o gradiente **zero**. O otimizador para de empurrar a ação para cima quando ela já ficou 20% mais provável.
- ▶ $\hat{A}_t < 0$ (**ação ruim**). O objetivo é plano à esquerda de $1 - \epsilon$ — não vale a pena reduzir mais — mas continua decrescendo à direita.

Intuição

A assimetria é deliberada. O $\min$ escolhe sempre o **ramo mais pessimista**: o recorte remove o incentivo para se afastar, mas *nunca* remove o incentivo para *voltar*. Se um passo anterior empurrou uma ação ruim para $r \gg 1$, o gradiente ainda existe para corrigi-lo.

Atenção

O recorte limita a *razão*, não a divergência KL. Não há garantia formal de melhoria monotônica — é uma heurística barata inspirada na teoria da seção anterior.

Teste sua compreensão

Considere os dois gráficos do slide anterior, com $\epsilon \in (0, 1)$.

1. O gráfico da esquerda mostra L^{CLIP} quando $A > 0$, e o da direita quando $A < 0$.
2. O gráfico da direita mostra L^{CLIP} quando $A > 0$, e o da esquerda quando $A < 0$.
3. Depende do valor de ϵ .

Pergunta para discussão conduzida em aula.

Teste de compreensão — o recorte do PPO

Teste sua compreensão

Considere os dois gráficos do slide anterior, com $\epsilon \in (0, 1)$.

1. O gráfico da esquerda mostra L^{CLIP} quando $A > 0$, e o da direita quando $A < 0$.
2. O gráfico da direita mostra L^{CLIP} quando $A > 0$, e o da esquerda quando $A < 0$.
3. Depende do valor de ϵ .

Pergunta para discussão conduzida em aula.

Resposta

1. Com $A > 0$ queremos r grande, e o recorte satura o *ganho* em $1 + \epsilon$ — patamar à direita. Com $A < 0$ o objetivo é negativo e o patamar aparece à esquerda, em $1 - \epsilon$. O valor de ϵ move os joelhos da curva, mas não troca os painéis.

PPO recortado: o algoritmo completo

Algoritmo — PPO com objetivo recortado

Entrada: θ_0 (ator), w_0 (crítico), ϵ , épocas K , tamanho do lote

para $k = 0, 1, 2, \dots$ **faça**

 Execute π_{θ_k} por T passos em N ambientes paralelos

 Estime as vantagens $\hat{A}_t$ (na prática, por GAE — Aula 7)

 Guarde $\log \pi_{\theta_k}(a_t | s_t)$: é o denominador de $r_t(\theta)$

para época = $1, \dots, K$ **faça**

 Para cada minilote: passo de Adam em $-L^{\text{CLIP}} + c_1 L^V - c_2 \mathcal{H}[\pi_\theta]$

fim

fim

Intuição

Três termos na perda: o objetivo recortado do **ator**; o erro quadrático do **crítico** (L^V); e um bônus de **entropia**, que impede a política de virar determinística cedo demais.

Valores usuais

- ▶ $\epsilon \approx 0,2$; $K \approx 3-10$ épocas por lote
- ▶ $c_1 \approx 0,5$ (crítico), $c_2 \approx 0,01$ (entropia)
- ▶ Vantagens normalizadas por minilote
- ▶ Corte de norma do gradiente em 0,5

Intuição

Monitore a KL empírica entre π_θ e π_{θ_k} e a **fração recortada**. Se a KL disparar, reduza K ou a taxa de aprendizado.

Atenção

Armadilhas frequentes

- ▶ Recalcular $\hat{A}_t$ dentro do laço de épocas: as vantagens são de π_{θ_k} e devem ficar *congeladas*.
- ▶ Esquecer de destacar o gradiente do denominador de r_t .
- ▶ K grande demais: a política se afasta, e o recorte sozinho não segura a KL.

Boa parte do desempenho publicado do PPO vem dessas escolhas de implementação, e não do objetivo em si.

O que você deve saber ao sair daqui

1. **Demonstrar** que uma linha de base $b(s)$ não introduz viés, e apontar exatamente onde a demonstração quebraria se b dependesse da ação.
2. **Explicar** por que a linha de base ótima é aproximadamente $V^\pi(s)$, e escrever o gradiente em termos da vantagem $A^\pi = Q^\pi - V^\pi$.
3. **Distinguir** distância no espaço de parâmetros de distância no espaço de políticas, e dizer por que a segunda é a que importa.
4. **Enunciar** o lema da diferença de desempenho e explicar qual aproximação transforma $L_\pi(\pi')$ em algo computável com dados antigos — e sob que condição ela é válida.
5. **Escrever** L^{CLIP} , desenhar seus dois ramos e justificar a assimetria entre eles.

Definição — O fio da aula

- ▶ Linha de base: variância menor, viés nenhum.
- ▶ Crítico: variância ainda menor, viés controlado.
- ▶ Substituto L_π : vários passos por lote.
- ▶ Recorte: mantém o substituto dentro da sua região de validade.

Intuição

Aula 7

- ▶ GAE: interpolar entre TD e MC com um parâmetro λ .
- ▶ Teoria de melhoria monotônica: quando o passo é *garantidamente* bom.
- ▶ Aprendizagem por imitação: clonagem de comportamento, DAGGER, RL inversa de máxima entropia.

Material adaptado de *CS234: Reinforcement Learning*, Emma Brunskill (Stanford); a seção de gradientes de política avançados segue os slides de Joshua Achiam.