

Aula 6: Gradientes de política II

Linha de base • Ator-crítico • Limites de desempenho relativo • PPO

Prof. Marcelo Keese Albertini

Adaptado de Emma Brunskill, CS234: Reinforcement Learning, Stanford University; seção de gradientes avançados a partir dos slides de Joshua Achiam • 2026

Contexto. A Aula 5 estabeleceu *para onde* andar: o teorema do gradiente de política dá uma direção de subida no espaço de parâmetros, e o REINFORCE a estima sem viés a partir de trajetórias. Esta aula ataca as duas perguntas que sobraram, e que decidem se o método é utilizável na prática:

- 1. Com que precisão conhecemos essa direção?** O estimador do REINFORCE é não-viesado, mas sua variância é tão alta que, em lotes de tamanho realista, o passo frequentemente aponta para o lado errado. A resposta é a *linha de base* e, depois dela, o *crítico*.
- 2. Qual o maior passo que podemos dar sem destruir a política?** Aqui o problema não é estatístico, e sim geométrico: a distância que medimos ($\Delta\theta$) não é a distância que importa ($\Delta\pi$). A resposta passa por um limite de desempenho relativo entre duas políticas e culmina no PPO.

O fio condutor é uma única troca, repetida em três níveis: **aceitar um pouco de viés para comprar redução de variância** e, em seguida, **aceitar uma aproximação para poder reutilizar dados** — sempre acompanhada de um mecanismo explícito que a mantém dentro de sua região de validade.

1 O estimador do REINFORCE e sua variância

Recordando a Aula 5, com m trajetórias amostradas de π_θ :

$$\nabla_\theta V(\theta) \approx \frac{1}{m} \sum_{i=1}^m R(\tau^{(i)}) \sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t^{(i)} | s_t^{(i)}).$$

Atenção

Não-viesado *não* significa utilizável. Um estimador com esperança correta e variância enorme produz, em cada lote, um passo cuja direção pode ter pouca relação com o gradiente verdadeiro. O que importa na prática é o erro quadrático médio a um dado orçamento de amostras.

1.1 Três fontes de variância, três remédios

- 1. Amostragem da trajetória.** τ é aleatória: o mesmo θ gera retornos diferentes a cada execução. Inevitável — é o preço de não ter modelo.
- 2. Escala e deslocamento do retorno.** Se todos os retornos valem aproximadamente 100, o estimador empurra *todas* as ações para cima; o sinal útil é a diferença entre elas, e essa diferença está afogada no nível comum. *Remédio: linha de base.*

- 3. Atribuição de crédito temporal.** O retorno total $R(\tau)$ multiplica o escore de todas as ações, inclusive as tomadas *depois* da recompensa, que não podem tê-la causado. *Remédio: estrutura temporal* — trocar $R(\tau)$ por G_t (feito na Aula 5).

Os itens 2 e 3 são *gratuitos*: reduzem a variância sem introduzir viés. Um quarto remédio — trocar G_t por um crítico — é diferente em natureza: troca viés por variância deliberadamente, e é o assunto da Seção 3.

2 A linha de base

Definição — Gradiente de política com linha de base

$$\nabla_{\theta} \mathbb{E}_{\tau}[R] = \mathbb{E}_{\tau} \left[\sum_{t=0}^{T-1} \nabla_{\theta} \log \pi(a_t | s_t; \theta) \left(\underbrace{\sum_{t'=t}^{T-1} r_{t'} - b(s_t)}_{G_t} \right) \right]$$

onde b é qualquer função **do estado apenas**. Para toda escolha de b nessas condições, o estimador permanece não-viesado.

Intuição

Leitura. Aumente a log-probabilidade de a_t na proporção em que o retorno obtido foi *melhor do que o esperado naquele estado*. Sem linha de base, uma ação medíocre tomada num estado excelente é reforçada tanto quanto uma ação excelente — porque o que se mede é o retorno absoluto, e não o mérito da ação.

2.1 Demonstração: a linha de base não introduz viés

Demonstração

Basta mostrar que o termo acrescentado tem esperança nula. Fixe t :

$$\begin{aligned} & \mathbb{E}_{\tau} [\nabla_{\theta} \log \pi(a_t | s_t; \theta) b(s_t)] \\ &= \mathbb{E}_{s_{0:t}, a_{0:(t-1)}} \left[\mathbb{E}_{s_{(t+1):T}, a_{t:(T-1)}} [\nabla_{\theta} \log \pi(a_t | s_t; \theta) b(s_t)] \right] && \text{(lei da esperança total)} \\ &= \mathbb{E}_{s_{0:t}, a_{0:(t-1)}} \left[b(s_t) \mathbb{E}_{a_t \sim \pi(\cdot | s_t)} [\nabla_{\theta} \log \pi(a_t | s_t; \theta)] \right] && (b(s_t) \text{ é constante na esperança interna e as variáveis após } t \text{ não aparecem}) \\ &= \mathbb{E}_{s_{0:t}, a_{0:(t-1)}} \left[b(s_t) \sum_a \pi_{\theta}(a | s_t) \frac{\nabla_{\theta} \pi(a | s_t; \theta)}{\pi_{\theta}(a | s_t)} \right] && \text{(razão de verossimilhança)} \\ &= \mathbb{E}_{s_{0:t}, a_{0:(t-1)}} \left[b(s_t) \nabla_{\theta} \sum_a \pi(a | s_t; \theta) \right] && \text{(soma finita: troca com o gradiente)} \\ &= \mathbb{E}_{s_{0:t}, a_{0:(t-1)}} [b(s_t) \nabla_{\theta} 1] = 0. && \text{(normalização de } \pi) \quad \blacksquare \end{aligned}$$

Atenção

O passo crítico é o terceiro. Ele exige tirar b de dentro de $\sum_a$. Se b dependesse da ação — $b(s, a)$ — isso seria impossível, o argumento desmoronaria, e o estimador ficaria viesado. Esta é a pergunta de prova mais comum sobre o tópico, e a resposta errada mais comum.

2.2 Por que a variância cai, e qual é a melhor linha de base

A variância do estimador se decompõe aproximadamente em uma soma sobre passos de tempo. Concentrando-se em um termo e escrevendo $\text{Var}[X] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$, observe que o segundo momento $(\mathbb{E}[X])^2$ **não depende de b** — é exatamente o que acabamos de demonstrar. Minimizar a variância equivale, portanto, a minimizar somente

$$\arg \min_b \mathbb{E}_{s \sim d^\pi} \mathbb{E}_{a \sim \pi(\cdot | s), G | s, a} \left[(\nabla_\theta \log \pi(a | s; \theta))^2 (G_t(s) - b(s))^2 \right].$$

Linha de base de variância mínima

Trata-se de um problema de **mínimos quadrados ponderados**, em que o peso de cada amostra é o quadrado do escore. Derivando em relação a $b(s)$ e igualando a zero:

$$b^*(s) = \frac{\mathbb{E}_{a \sim \pi, G} \left[(\nabla_\theta \log \pi(a | s; \theta))^2 G_t(s) \right]}{\mathbb{E}_{a \sim \pi, G} \left[(\nabla_\theta \log \pi(a | s; \theta))^2 \right]} \approx \mathbb{E}_{a \sim \pi, G} [G_t(s)] = V^\pi(s).$$

Ou seja: a linha de base ótima é a média dos retornos *ponderada pelo quadrado da norma do escore*. Ignorando essa ponderação — o que praticamente toda implementação faz — resta a média simples, que é precisamente a **função valor de estado** $V^\pi(s)$. É por isso que “linha de base” e “crítico de valor” acabam sendo a mesma coisa na prática.

2.3 Exemplo trabalhado: quanto exatamente se ganha?

Exercício resolvido — bandido de três ações

Considere um problema de um só estado com três ações, política *softmax* com $\theta = (0, 0, 0)$ — portanto $\pi = (\frac{1}{3}, \frac{1}{3}, \frac{1}{3})$ — e recompensas determinísticas $r = (98, 101, 104)$.

Para a *softmax*, o escore tem forma fechada: $\nabla_\theta \log \pi(a) = e_a - \pi$, onde e_a é o vetor canônico. Logo $\|\nabla_\theta \log \pi(a)\|^2 = 1 - \frac{1}{3} = \frac{2}{3}$ para toda ação a — os pesos do problema de mínimos quadrados são iguais, e portanto b^* é a *média simples* dos retornos, $b^* = 101$.

O estimador de uma única amostra é $\hat{g} = (e_a - \pi)(r(a) - b)$. Calculando a esperança e a variância total (traço da matriz de covariância):

	$\mathbb{E}[\hat{g}]$	$\mathbb{E}\ \hat{g}\ ^2$	Var total
sem linha de base ($b = 0$)	$(-1, 0, +1)$	6804,67	6802.67
com linha de base ($b = 101$)	$(-1, 0, +1)$	4,00	2,00

O gradiente esperado é **idêntico** nos dois casos, como a demonstração garante. A variância cai por um fator de $\approx 3\,400$. Traduzindo para orçamento de amostras: como o erro-padrão da média decai com $\sqrt{m}$, seriam necessárias cerca de 3 400 vezes mais trajetórias para o estimador sem linha de base atingir a mesma precisão.

Intuição

O exemplo é extremo de propósito, mas o mecanismo é geral: o ganho cresce com a razão entre o *nível* dos retornos e a sua *dispersão*. Ambientes com recompensa de sobrevivência (“+1 por passo vivo”), muito comuns, estão exatamente nesse regime.

3 Do retorno ao crítico: métodos ator–crítico

O retorno G_t^i é uma estimativa não-viesada de $V^\pi(s_t)$ obtida de uma *única* execução — soma de muitas variáveis aleatórias, com variância proporcional ao horizonte. A alternativa é reduzir essa variância **introduzindo viés**, via *bootstrapping* e aproximação de função. É exatamente o dilema TD versus Monte Carlo da Aula 3, agora aplicado ao alvo do gradiente de política.

Definição — Métodos ator–crítico

Mantêm representações explícitas *da política* (o **ator**, π_θ) e *da função valor* (o **crítico**, V_w), e atualizam as duas em paralelo. A estimativa de V ou Q que entra no gradiente de política é produzida pelo crítico, e não pelo retorno observado.

3.1 A função vantagem

Partindo da forma com linha de base e substituindo o retorno amostral por um crítico $Q(s_t, a_t; w)$, e depois tomando a linha de base como uma estimativa de V , a expressão colapsa em:

$$\nabla_\theta \mathbb{E}_\tau[R] \approx \mathbb{E}_\tau \left[\sum_{t=0}^{T-1} \nabla_\theta \log \pi(a_t | s_t; \theta) \hat{A}^\pi(s_t, a_t) \right], \quad A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s).$$

Propriedade fundamental da vantagem

$\mathbb{E}_{a \sim \pi(\cdot | s)}[A^\pi(s, a)] = 0$ para todo s .

Demonstração

Imediato da definição de V^π como esperança de Q^π sob a política: $\mathbb{E}_{a \sim \pi}[A^\pi(s, a)] = \mathbb{E}_{a \sim \pi}[Q^\pi(s, a)] - V^\pi(s) = V^\pi(s) - V^\pi(s) = 0$. ■

Intuição

A vantagem é, por construção, **centrada**: metade das ações da política atual tem vantagem positiva e metade negativa, em média ponderada. Essa é a razão estatística de sua eficácia — é a versão “com média zero” do sinal de aprendizado, e não apenas uma quantidade conveniente.

3.2 O catálogo de alvos

Todos os pesos abaixo podem substituir G_t no gradiente. Descer na tabela é caminhar do Monte Carlo puro para o TD puro.

Peso do escore	Nome	Viés	Variância
$R(\tau)$	retorno total da trajetória	nenhum	altíssima
$G_t = \sum_{t' \geq t} r_{t'}$	retorno futuro	nenhum	muito alta
$G_t - b(s_t)$	retorno com linha de base	nenhum	alta
$G_t - V_w(s_t)$	vantagem de Monte Carlo	só de V_w	média
$Q_w(s_t, a_t) - V_w(s_t)$	vantagem estimada	de Q_w e V_w	baixa
$\delta_t = r_t + \gamma V_w(s_{t+1}) - V_w(s_t)$	erro de TD	maior	muito baixa
$\hat{A}_t^{\text{GAE}(\gamma, \lambda)}$	vantagem generalizada	ajustável	ajustável

A última linha interpola continuamente entre as demais por meio de um único parâmetro $\lambda \in [0, 1]$, e é o assunto da Aula 7. Note que $\mathbb{E}[\delta_t | s_t, a_t] = A^\pi(s_t, a_t)$ *apenas* quando $V_w = V^\pi$; fora disso,

o erro de TD é um estimador viesado da vantagem, e esse viés é o preço explícito da redução de variância.

4 Os problemas estruturais do gradiente de política

O objetivo é $\max_{\theta} J(\pi_{\theta}) := \mathbb{E}_{\tau \sim \pi_{\theta}} [\sum_{t \geq 0} \gamma^t r_t]$, atacado por subida de gradiente estocástica com $g = \mathbb{E}_{\tau \sim \pi_{\theta}} [\sum_{t \geq 0} \gamma^t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) A^{\pi_{\theta}}(s_t, a_t)]$. Três limitações persistem mesmo com variância controlada.

4.1 Eficiência amostral

O gradiente de política é uma esperança **sob a política atual**: é *on-policy* por construção. Assim que θ muda, os dados coletados descrevem uma política que não existe mais, e o lote inteiro precisa ser descartado após um único passo de gradiente.

Intuição

Oportunidade. Reaproveitar dados antigos para dar *vários* passos antes de coletar de novo.

Desafio. Quantos passos podemos dar antes que os dados deixem de descrever a política que estamos otimizando? Esta é, literalmente, a pergunta que o PPO responde.

4.2 Espaço de parâmetros *versus* espaço de políticas

Definição — Espaço de políticas

No caso tabular, o conjunto de matrizes estocásticas por linha $\Pi = \{\pi \in \mathbb{R}^{|S| \times |A|} : \sum_a \pi_{sa} = 1, \pi_{sa} \geq 0\}$. O gradiente dá passos em θ ; o desempenho depende do deslocamento em Π . Não há razão para que a mesma régua sirva nos dois lugares.

Exercício resolvido — a política sigmoide

Seja $\pi_{\theta}(a=1) = \sigma(\theta)$ e $\pi_{\theta}(a=2) = 1 - \sigma(\theta)$, com um único parâmetro escalar. Compare dois passos de *mesmo tamanho* em θ :

Passo	π inicial	π final	$\Delta\pi$	$D_{\text{KL}}(\pi_{\text{final}} \parallel \pi_{\text{inicial}})$
$\theta : -1 \rightarrow +1 \quad (\Delta\theta = 2)$	0,2689	0,7311	0,4621	0,4621
$\theta : 4 \rightarrow 6 \quad (\Delta\theta = 2)$	0,9820	0,9975	0,0155	0,0107

O mesmo $\Delta\theta = 2$ produz mudanças de comportamento que diferem por um fator de 30 em probabilidade e de 43 em divergência KL. Um passo calibrado para a primeira região é catastrófico ou inútil na segunda, conforme a direção.

Atenção

Consequência prática: o colapso de desempenho. Um passo grande demais pode derrubar J para um patamar do qual não se sai — porque a política ruim coleta dados ruins, com os quais não se aprende a escapar. Passo pequeno demais significa progresso inaceitavelmente lento. E o tamanho “certo” *muda com* θ : nenhuma constante serve para a corrida inteira.

4.3 Uma observação: KL como métrica local

A ligação entre as duas colunas do exemplo anterior não é acidental. Para π' próxima de π , a expansão de Taylor de segunda ordem da divergência KL é

$$\bar{D}_{\text{KL}}(\theta + \Delta\theta \parallel \theta) \approx \frac{1}{2} \Delta\theta^\top F(\theta) \Delta\theta, \quad F(\theta) = \mathbb{E}_{s \sim d^\pi, a \sim \pi} \left[\nabla_\theta \log \pi_\theta(a \mid s) \nabla_\theta \log \pi_\theta(a \mid s)^\top \right],$$

onde F é a **matriz de informação de Fisher**. Ou seja: a KL é localmente uma norma quadrática cuja métrica depende de θ . Restringir a KL é medir o passo com a régua correta em cada ponto — e usar $F^{-1}g$ em vez de g como direção é precisamente o *gradiente natural*, sobre o qual o TRPO se constrói. O PPO evita calcular F , e paga por isso em rigor.

5 Limites de desempenho relativo entre duas políticas

Queremos uma regra de atualização que (i) use as trajetórias da política mais recente com a maior eficiência possível e (ii) dê passos que respeitem distância no espaço de políticas. Para isso precisamos relacionar o desempenho de *duas* políticas.

Lema da diferença de desempenho

Para quaisquer políticas π e π' ,

$$J(\pi') - J(\pi) = \mathbb{E}_{\tau \sim \pi'} \left[\sum_{t=0}^{\infty} \gamma^t A^\pi(s_t, a_t) \right] = \frac{1}{1-\gamma} \mathbb{E}_{\substack{s \sim d^{\pi'} \\ a \sim \pi'}} [A^\pi(s, a)],$$

onde $d^\pi(s) = (1-\gamma) \sum_{t \geq 0} \gamma^t \mathbb{P}(s_t = s \mid \pi)$ é a **distribuição descontada de estados futuros**.

Demonstração

Escreva a vantagem como um resíduo de Bellman: $A^\pi(s, a) = \mathbb{E}_{s'} [R(s, a) + \gamma V^\pi(s') - V^\pi(s)]$. Então

$$\begin{aligned} \mathbb{E}_{\tau \sim \pi'} \left[\sum_{t \geq 0} \gamma^t A^\pi(s_t, a_t) \right] &= \mathbb{E}_{\tau \sim \pi'} \left[\sum_{t \geq 0} \gamma^t r_t \right] + \mathbb{E}_{\tau \sim \pi'} \left[\sum_{t \geq 0} (\gamma^{t+1} V^\pi(s_{t+1}) - \gamma^t V^\pi(s_t)) \right] \\ &= J(\pi') + \mathbb{E}_{s_0} [-V^\pi(s_0)] = J(\pi') - J(\pi), \end{aligned}$$

pois a segunda soma é **telescópica** e sobra apenas o termo $t = 0$ com sinal negativo. A segunda igualdade do enunciado é a definição de $d^{\pi'}$: trocar $\sum_t \gamma^t \mathbb{E}_{s_t} [\cdot]$ por $\frac{1}{1-\gamma} \mathbb{E}_{s \sim d^{\pi'}} [\cdot]$. ■

Intuição

Leitura. A melhoria de π' sobre π é a vantagem média, medida com a *régua antiga* A^π , ao longo das *trajetórias novas*. Toda a teoria que segue é uma tentativa de tornar esse lado direito computável com dados que já temos.

5.1 Amostragem por importância e o obstáculo restante

Reescrevendo a esperança sobre ações com um peso de amostragem por importância:

$$J(\pi') - J(\pi) = \frac{1}{1-\gamma} \mathbb{E}_{\substack{s \sim d^{\pi'} \\ a \sim \pi'}} [A^\pi(s, a)] = \frac{1}{1-\gamma} \mathbb{E}_{\substack{s \sim d^{\pi'} \\ a \sim \pi}} \left[\frac{\pi'(a \mid s)}{\pi(a \mid s)} A^\pi(s, a) \right].$$

As ações já vêm da política antiga. O obstáculo que resta é $s \sim d^{\pi'}$: os **estados** ainda são visitados pela política nova, que é justamente a que ainda não temos.

5.2 A aproximação e o limite

E se simplesmente disséssemos $d^{\pi'} \approx d^\pi$?

$$J(\pi') - J(\pi) \approx \frac{1}{1-\gamma} \mathbb{E}_{s \sim d^\pi} \left[\frac{\pi'(a|s)}{\pi(a|s)} A^\pi(s, a) \right] := L_\pi(\pi').$$

Limite de desempenho relativo (Achiam, Held, Tamar e Abbeel, 2017)

$$|J(\pi') - (J(\pi) + L_\pi(\pi'))| \leq C \sqrt{\mathbb{E}_{s \sim d^\pi} [D_{\text{KL}}(\pi' \| \pi) [s]]}.$$

O erro cometido ao trocar $d^{\pi'}$ por d^π é controlado pela divergência KL média entre as políticas. Se elas são próximas em KL, a aproximação é boa e $L_\pi(\pi')$ torna-se um **substituto** legítimo do objetivo.

Definição — Divergência de Kullback–Leibler

$D_{\text{KL}}(P \| Q) = \sum_x P(x) \log \frac{P(x)}{Q(x)}$, e entre políticas num estado s : $D_{\text{KL}}(\pi' \| \pi) [s] = \sum_{a \in \mathcal{A}} \pi'(a|s) \log \frac{\pi'(a|s)}{\pi(a|s)}$. Propriedades: $D_{\text{KL}}(P \| P) = 0$; $D_{\text{KL}}(P \| Q) \geq 0$; $D_{\text{KL}}(P \| Q) \neq D_{\text{KL}}(Q \| P)$ — **não é simétrica**, logo não é uma métrica.

5.3 O que se ganha com a aproximação

$$L_\pi(\pi') = \mathbb{E}_{\tau \sim \pi} \left[\sum_{t=0}^{\infty} \gamma^t \frac{\pi'(a_t|s_t)}{\pi(a_t|s_t)} A^\pi(s_t, a_t) \right].$$

Tudo do lado direito é estimável com trajetórias amostradas da política **antiga**. Podemos otimizar π' sem coletar dados novos — isto é, dar *vários passos de gradiente por lote*.

Intuição

Por que os pesos não explodem. Na amostragem por importância aplicada a trajetórias inteiras, o peso é um *produto* de t razões, $\prod_{t'=0}^t \frac{\pi'(a_{t'}|s_{t'})}{\pi(a_{t'}|s_{t'})}$; mesmo diferenças minúsculas se acumulam multiplicativamente e o estimador degenera. Em L_π o peso depende **só do passo atual**. Não há produto, e portanto não há explosão nem desaparecimento.

Atenção

A licença é condicional. $L_\pi(\pi')$ só aproxima o objetivo verdadeiro *enquanto* π' *permanecer próxima de π em KL*. Maximizar L_π sem restrição alguma é otimizar um modelo fora de sua região de validade — e o máximo irrestrito costuma ser exatamente o lugar onde o modelo é menos confiável.

6 Otimização proximal de política (PPO)

O PPO é uma família de métodos que impõe a restrição de KL **de forma aproximada**, sem calcular gradientes naturais. Duas variantes.

6.1 Variante 1 — penalidade KL adaptativa

A atualização resolve um problema *sem restrição*, em que a KL entra como penalidade:

$$\theta_{k+1} = \arg \max_{\theta} L_{\theta_k}(\theta) - \beta_k \bar{D}_{\text{KL}}(\theta \| \theta_k), \quad \bar{D}_{\text{KL}}(\theta \| \theta_k) = \mathbb{E}_{s \sim d^{\pi_k}} [D_{\text{KL}}(\pi_{\theta_k}(\cdot | s) \| \pi_{\theta}(\cdot | s))].$$

Algoritmo — PPO com penalidade KL adaptativa

Entrada: θ_0 ; penalidade inicial β_0 ; KL alvo δ .

1. para $k = 0, 1, 2, \dots$:

- a) Colete trajetórias parciais $\mathcal{D}_k$ executando $\pi_k = \pi(\theta_k)$.
- b) Estime as vantagens $\hat{A}_t^{\pi_k}$ por qualquer método.
- c) Calcule $\theta_{k+1} = \arg \max_{\theta} L_{\theta_k}(\theta) - \beta_k \bar{D}_{\text{KL}}(\theta \| \theta_k)$ com K passos de SGD por minilotes (Adam).
- d) **se** $\bar{D}_{\text{KL}}(\theta_{k+1} \| \theta_k) \geq 1,5 \delta$ **então** $\beta_{k+1} \leftarrow 2\beta_k$;
senão se $\bar{D}_{\text{KL}}(\theta_{k+1} \| \theta_k) \leq \delta/1,5$ **então** $\beta_{k+1} \leftarrow \beta_k/2$.

O valor inicial de β importa pouco — ele se adapta rapidamente. Algumas iterações violam a restrição; a maioria não. O parâmetro decisivo é K : é aqui que finalmente damos *vários* passos de gradiente por lote de dados.

6.2 Variante 2 — objetivo recortado**Definição — Razão de probabilidades e objetivo L^{CLIP}**

Seja $r_t(\theta) = \frac{\pi_{\theta}(a_t | s_t)}{\pi_{\theta_k}(a_t | s_t)}$. Então

$$L_{\theta_k}^{\text{CLIP}}(\theta) = \mathbb{E}_{T \sim \pi_k} \left[\sum_{t=0}^T \min \left(r_t(\theta) \hat{A}_t, \text{clip} \left(r_t(\theta), 1 - \epsilon, 1 + \epsilon \right) \hat{A}_t \right) \right],$$

com ϵ hiperparâmetro (tipicamente 0,2), e $\theta_{k+1} = \arg \max_{\theta} L_{\theta_k}^{\text{CLIP}}(\theta)$.

No início de cada época de otimização temos $\theta = \theta_k$, logo $r_t = 1$ e $L^{\text{CLIP}} = L_{\theta_k}$: o objetivo recortado coincide com o substituto exatamente onde o substituto é confiável.

6.3 Análise caso a caso do recorte

Desenvolvendo o min nas seis combinações possíveis:

	$r_t < 1 - \epsilon$	$1 - \epsilon \leq r_t \leq 1 + \epsilon$	$r_t > 1 + \epsilon$
$\hat{A}_t > 0$ (ação boa)	$r_t \hat{A}_t$ ativo	$r_t \hat{A}_t$ ativo	$(1 + \epsilon) \hat{A}_t$ plano
$\hat{A}_t < 0$ (ação ruim)	$(1 - \epsilon) \hat{A}_t$ plano	$r_t \hat{A}_t$ ativo	$r_t \hat{A}_t$ ativo

“Plano” significa gradiente nulo em relação a θ : o otimizador deixa de empurrar naquela direção.

Intuição

A assimetria é deliberada. O min escolhe sempre o ramo mais *pessimista*. Para uma ação boa, o recorte remove o incentivo de aumentar sua probabilidade além de $1 + \epsilon$. Para uma ação ruim que já foi empurrada para $r_t \gg 1$ por um passo anterior, o gradiente **continua ativo** — o recorte nunca remove o incentivo de *voltar*. É exatamente o comportamento que se deseja de um mecanismo de segurança.

Atenção

O recorte limita a **razão**, não a divergência KL, e o limite é por amostra, não em média. Não há garantia formal de melhoria monotônica: o PPO recortado é uma heurística barata *inspirada*

(continua)

na teoria da seção anterior, não uma consequência dela. Na prática, deve-se monitorar a KL empírica.

6.4 O algoritmo completo, na forma usada em implementações

Algoritmo — PPO com objetivo recortado

Entrada: θ_0 (ator), w_0 (crítico), ϵ , épocas K , tamanho de minilote.

1. **para** $k = 0, 1, 2, \dots$:

- Execute π_{θ_k} por T passos em N ambientes paralelos.
- Estime as vantagens $\hat{A}_t$ (na prática, por GAE — Aula 7) e **congele-as**.
- Guarde $\log \pi_{\theta_k}(a_t | s_t)$: é o denominador de $r_t(\theta)$.
- para** época $= 1, \dots, K$, e para cada minilote: um passo de Adam sobre $-L^{\text{CLIP}} + c_1 L^V - c_2 \mathcal{H}[\pi_\theta]$.

São três termos na perda: o objetivo recortado do **ator**; o erro quadrático do **crítico**, $L^V = (V_w(s_t) - \hat{G}_t)^2$; e um bônus de **entropia** $\mathcal{H}$, que impede a política de se tornar determinística cedo demais e matar a exploração.

6.5 Valores usuais e armadilhas

- ▶ $\epsilon \approx 0,2$; K entre 3 e 10 épocas por lote; $c_1 \approx 0,5$; $c_2 \approx 0,01$.
- ▶ Vantagens normalizadas por minilote; corte da norma do gradiente em 0,5.
- ▶ **Monitorar** a KL empírica entre π_θ e π_{θ_k} e a *fração de amostras recortadas*. KL disparando $\Rightarrow$ reduzir K ou a taxa de aprendizado.

Atenção

Erros de implementação frequentes.

- ▶ *Recalcular* $\hat{A}_t$ dentro do laço de épocas. As vantagens são de π_{θ_k} e devem permanecer congeladas durante as K épocas.
- ▶ Não destacar o gradiente do denominador de $r_t(\theta)$: ele é uma constante, não uma função de θ .
- ▶ K grande demais. A política se afasta, e o recorte sozinho não segura a KL — é a falha mais comum e a mais difícil de diagnosticar, porque a curva de aprendizado piora lentamente em vez de quebrar.

Boa parte do desempenho publicado do PPO vem dessas escolhas de implementação, e não do objetivo em si.

7 Formulário

1. Gradiente de política com linha de base

$$\nabla_\theta J = \mathbb{E}_\tau \left[\sum_t \nabla_\theta \log \pi_\theta(a_t | s_t) (G_t - b(s_t)) \right], \quad \mathbb{E}[\nabla_\theta \log \pi_\theta(a | s) b(s)] = 0.$$

2. Linha de base ótima e vantagem

$$b^*(s) \approx V^\pi(s), \quad A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s), \quad \mathbb{E}_{a \sim \pi}[A^\pi(s, a)] = 0.$$

3. Distribuição descontada de estados e lema da diferença de desempenho

$$d^\pi(s) = (1 - \gamma) \sum_{t \geq 0} \gamma^t \mathbb{P}(s_t = s \mid \pi), \quad J(\pi') - J(\pi) = \frac{1}{1 - \gamma} \mathbb{E}_{\substack{s \sim d^{\pi'} \\ a \sim \pi'}}[A^\pi(s, a)].$$

4. Substituto e limite de desempenho relativo

$$L_\pi(\pi') = \frac{1}{1 - \gamma} \mathbb{E}_{\substack{s \sim d^\pi \\ a \sim \pi}} \left[\frac{\pi'(a \mid s)}{\pi(a \mid s)} A^\pi(s, a) \right] = \mathbb{E}_{\tau \sim \pi} \left[\sum_{t \geq 0} \gamma^t \frac{\pi'(a_t \mid s_t)}{\pi(a_t \mid s_t)} A^\pi(s_t, a_t) \right],$$

$$|J(\pi') - J(\pi) - L_\pi(\pi')| \leq C \sqrt{\mathbb{E}_{s \sim d^\pi} [D_{\text{KL}}(\pi' \parallel \pi) [s]]}.$$

5. PPO

$$r_t(\theta) = \frac{\pi_\theta(a_t \mid s_t)}{\pi_{\theta_k}(a_t \mid s_t)}, \quad L^{\text{CLIP}} = \mathbb{E} \left[\sum_t \min(r_t \hat{A}_t, \text{clip}(r_t, 1 - \epsilon, 1 + \epsilon) \hat{A}_t) \right].$$

6. KL local e informação de Fisher

$$\bar{D}_{\text{KL}}(\theta + \Delta\theta \parallel \theta) \approx \frac{1}{2} \Delta\theta^\top F(\theta) \Delta\theta, \quad F(\theta) = \mathbb{E} [\nabla_\theta \log \pi_\theta \nabla_\theta \log \pi_\theta^\top].$$

8 Exercícios**Exercício 1 — a linha de base precisa mesmo ser só do estado?**

Considere um bandido de duas ações com $\pi = (p, 1 - p)$ e recompensas r_1, r_2 . Tome a “linha de base” dependente da ação $b(a) = r(a)$, que zera todo o peso do escore.

- Calcule o gradiente esperado do estimador resultante.
- Compare-o com o gradiente verdadeiro. O estimador é viesado?
- Aponte o passo exato da demonstração da Seção 2 que falha.

Exercício 2 — deslocamento constante das recompensas

Suponha que todas as recompensas do problema sejam deslocadas por uma constante c : $r'(s, a) = r(s, a) + c$, em episódios de comprimento fixo T .

- Mostre que o gradiente *esperado* do REINFORCE não muda.
- Mostre que a variância do estimador de uma amostra cresce com c^2 .
- Explique por que introduzir $b(s) = \mathbb{E}[G_t]$ elimina completamente essa dependência em c .

Exercício 3 — o erro de TD como estimador da vantagem

Seja $\delta_t = r_t + \gamma V_w(s_{t+1}) - V_w(s_t)$.

- Mostre que, se $V_w = V^\pi$, então $\mathbb{E}[\delta_t \mid s_t = s, a_t = a] = A^\pi(s, a)$.
- Escreva o viés de δ_t como estimador da vantagem em função do erro $\varepsilon(s) = V_w(s) - V^\pi(s)$.
- Em que condição sobre ε esse viés se anula mesmo com $V_w \neq V^\pi$?

Exercício 4 — o substituto estende o gradiente de política

Seja $\pi_{\theta'}$ a política nova e π_{θ} a antiga.

- Mostre que $L_{\pi_{\theta}}(\pi_{\theta}) = 0$.
- Mostre que $\nabla_{\theta'} L_{\pi_{\theta}}(\pi_{\theta'})|_{\theta'=\theta}$ é exatamente o gradiente de política da Aula 5.
- Explique, a partir de (b), por que otimizar L_{π} por um único passo pequeno é equivalente a um passo de gradiente de política comum — e o que se ganha ao dar vários passos.

Exercício 5 — derivando a tabela do recorte

Sem consultar a tabela da Seção 6, deduza os seis casos de $\min(r\hat{A}, \text{clip}(r, 1 - \epsilon, 1 + \epsilon)\hat{A})$ conforme o sinal de $\hat{A}$ e a posição de r . Em seguida esboce as duas curvas $L^{\text{CLIP}}(r)$ e identifique, em cada uma, onde o gradiente é nulo.

Exercício 6 — calibrando o passo pela KL

Para a política sigmoide $\pi_{\theta}(a=1) = \sigma(\theta)$:

- Calcule numericamente o maior $\Delta\theta > 0$ tal que $D_{\text{KL}}(\pi_{\theta+\Delta\theta} \parallel \pi_{\theta}) \leq 0,01$, para $\theta = 0$ e para $\theta = 4$.
- Compare os dois valores. Qual seria o efeito de usar um passo constante calibrado em $\theta = 0$ quando a política já chegou a $\theta = 4$?
- Verifique a aproximação de Fisher da Seção 4 comparando o resultado exato com $\Delta\theta \approx \sqrt{2 \cdot 0,01 / F(\theta)}$, onde $F(\theta) = \sigma(\theta)(1 - \sigma(\theta))$ para esta família.

Exercício 7 — implementação

Na implementação de PPO da lista de exercícios, produza gráficos, ao longo do treinamento, de: (i) a KL empírica entre π_{θ} e π_{θ_k} ao fim de cada iteração; (ii) a fração de amostras em que o recorte foi ativado; (iii) o retorno médio. Rode com $K \in \{1, 4, 20\}$ épocas e relacione o que se vê em (i) e (ii) com o que acontece em (iii).

9 Para discutir em aula

Para discutir em aula

1. Uma linha de base que dependa da ação preservaria o não-viés do estimador? Onde exatamente a demonstração quebraria?
2. Trocar $G_t - b(s_t)$ por δ_t preserva o não-viés? Reduz a variância? As duas respostas são independentes uma da outra?
3. Se $L_\pi(\pi') > 0$, podemos concluir que $J(\pi') > J(\pi)$? E se soubermos, além disso, que a KL média é pequena?
4. O limite de desempenho relativo deixa de *valer* quando as políticas estão distantes, ou apenas de ser *informativo*?
5. Nos dois gráficos de L^{CLIP} , qual corresponde a $A > 0$ e qual a $A < 0$? A resposta depende de ϵ ?
6. Por que o recorte é assimétrico — por que não achatar a curva dos dois lados? O que se perderia?
7. O PPO garante melhoria monotônica? Se não, o que herda da Seção 5?

Referências

- ▶ S. Kakade e J. Langford. *Approximately Optimal Approximate Reinforcement Learning*. ICML, 2002.
- ▶ J. Schulman, S. Levine, P. Moritz, M. Jordan e P. Abbeel. *Trust Region Policy Optimization*. ICML, 2015.
- ▶ J. Achiam, D. Held, A. Tamar e P. Abbeel. *Constrained Policy Optimization*. ICML, 2017.
- ▶ J. Schulman, F. Wolski, P. Dhariwal, A. Radford e O. Klimov. *Proximal Policy Optimization Algorithms*. arXiv:1707.06347, 2017.
- ▶ V. Mnih et al. *Asynchronous Methods for Deep Reinforcement Learning (A3C)*. ICML, 2016.

Material adaptado e expandido de *CS234: Reinforcement Learning*, Emma Brunskill, Stanford University; a seção de gradientes de política avançados segue os slides de Joshua Achiam.