

Universidade Federal de Uberlândia

Aula 7: Gradientes de política II e Aprendizagem por imitação

Amostragem por importância • PPO • GAE • Melhoria monotônica • Imitação e RL inverso

Prof. Marcelo Keese Albertini
Universidade Federal de Uberlândia
adaptado de Emma Brunskill, CS234 (Stanford)
2026



Onde estamos

Da estimativa do gradiente ao tamanho do passo

- ▶ **Aulas 2–3.** Com um modelo do mundo, calcular V^* e π^* por programação dinâmica.
- ▶ **Aula 4.** Sem modelo, aprender $\hat{Q}(s, a; w)$ a partir de amostras.
- ▶ **Aulas 5–6.** Parametrizar a política e subir o gradiente de $J(\pi_\theta)$; medir distância entre políticas no espaço de *distribuições*.
- ▶ **Hoje, primeira metade.** Fechar a família: como reaproveitar dados de uma política velha (**amostragem por importância**), como o **PPO** torna isso barato, como o **GAE** equilibra viés e variância na vantagem, e *por que* tudo isso funciona (teoria da melhoria monotônica).
- ▶ **Hoje, segunda metade.** E se não houvermos recompensa alguma, mas sim **demonstrações**? Clonagem de comportamento, DAgger, RL inverso.

Intuição

As duas metades se encontram no fim: os métodos que hoje ajustam modelos de linguagem juntam PPO (primeira metade) com uma recompensa *aprendida* a partir de preferências humanas (segunda metade).

1. **Amostragem por importância** — a ferramenta que permite avaliar uma política nova com dados de outra, e por que ela sozinha não basta.
2. **Otimização proximal de política (PPO)** — penalidade KL adaptativa e objetivo recortado.
3. **Estimador generalizado de vantagem (GAE)** — um botão único, λ , que percorre todo o espectro entre TD(0) e Monte Carlo.
4. **Teoria da melhoria monotônica** — o limite de desempenho relativo e o argumento de *majorizar-maximizar* que justifica TRPO e PPO.
5. **Aprendizagem por imitação** — clonagem de comportamento, erros compostos, DAgger.
6. **RL inverso** — recompensa linear em atributos, casamento de expectativas, e o princípio da máxima entropia.

SEÇÃO 1

Reaproveitar dados: amostragem por importância

01

O que ainda incomoda no gradiente de política

Os algoritmos de gradiente de política resolvem

$$\max_{\theta} J(\pi_{\theta}) := \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=0}^{\infty} \gamma^t r_t \right], \quad g = \nabla_{\theta} J(\pi_{\theta}) = \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t \geq 0} \gamma^t \nabla_{\theta} \log \pi_{\theta}(a_t \mid s_t) A^{\pi}(s_t, a_t) \right].$$

- ▶ **Eficiência amostral ruim.** O estimador é *on-policy*: cada lote de trajetórias serve a uma atualização e é descartado.
- ▶ **Distância em $\theta \neq$ distância em π .** O passo é dado no espaço de parâmetros, mas o que estraga (ou salva) o aprendizado é o deslocamento no espaço de *políticas*.

Definição — Espaço de políticas


No caso tabular, o conjunto de matrizes estocásticas

$$\Pi = \left\{ p \in \mathbb{R}^{|\mathcal{S}| \times |\mathcal{A}|} : \sum_a p_{sa} = 1, p_{sa} \geq 0 \right\}.$$

A parametrização $\theta \mapsto \pi_{\theta}$ é um mergulho de $\mathbb{R}^n$ em Π — e esse mergulho *distorce distâncias*.

O mesmo passo em θ , dois deslocamentos muito diferentes

Política gaussiana $\pi_{\theta}(a | s) = \mathcal{N}(\mu_{\theta}(s), \sigma^2)$. Desloque μ da mesma quantidade $\Delta\mu = 0,5$ nos dois casos:



Atenção

Um único passo α não pode estar certo nos dois regimes. É por isso que a taxa de aprendizado do gradiente de política é notoriamente difícil de ajustar — e por que faz sentido controlar o passo pela **divergência KL** entre as políticas, não pela norma em θ .

Amostragem por importância

Definição — Identidade de mudança de medida

Para estimar uma esperança sob P usando amostras de Q (com $Q(x) > 0$ sempre que $P(x)f(x) \neq 0$):

$$\mathbb{E}_{x \sim P}[f(x)] = \mathbb{E}_{x \sim Q}\left[\frac{P(x)}{Q(x)}f(x)\right] \approx \frac{1}{|\mathcal{D}|} \sum_{x \in \mathcal{D}} \frac{P(x)}{Q(x)}f(x), \quad \mathcal{D} \sim Q.$$

A razão $P(x)/Q(x)$ é o **peso de importância** de x .

- ▶ A identidade é exata — o estimador é **não-viesado** para qualquer Q admissível.
- ▶ O problema nunca é o viés. É a **variância**.

Intuição

Intuição: reponderamos cada amostra pelo quanto ela era *mais provável sob P do que sob Q* . Se Q raramente visita uma região onde Pf é grande, as poucas amostras que caem lá carregam um peso enorme — e o estimador passa a depender delas.

A variância do estimador de importância

Com N amostras i.i.d. de Q , escrevendo $\hat{\mu}_Q$ para o estimador:

$$\begin{aligned}\text{Var}(\hat{\mu}_Q) &= \frac{1}{N} \text{Var}_{x \sim Q} \left[\frac{P(x)}{Q(x)} f(x) \right] = \frac{1}{N} \left(\mathbb{E}_{x \sim Q} \left[\frac{P(x)^2}{Q(x)^2} f(x)^2 \right] - \mathbb{E}_{x \sim Q} \left[\frac{P(x)}{Q(x)} f(x) \right]^2 \right) \\ &= \frac{1}{N} \left(\mathbb{E}_{x \sim P} \left[\frac{P(x)}{Q(x)} f(x)^2 \right] - \mathbb{E}_{x \sim P} [f(x)]^2 \right).\end{aligned}$$

Atenção

O termo destacado é o vilão. Ele pesa $f(x)^2$ pela razão P/Q : se P/Q for grande exatamente onde f é grande, a variância explode — e pode ser *infinita* mesmo com P e Q perfeitamente bem-comportadas.

- ▶ Diagnóstico prático: o *tamanho amostral efetivo* $\text{ESS} = (\sum_i \omega_i)^2 / \sum_i \omega_i^2$, com $\omega_i = P(x_i)/Q(x_i)$. Se $\text{ESS} \ll N$, poucas amostras estão fazendo todo o trabalho.

Amostragem por importância no gradiente de política

Comprimindo π_θ para θ na notação

$$\begin{aligned} g = \nabla_\theta J(\theta) &= \mathbb{E}_{\tau \sim \theta} \left[\sum_{t \geq 0} \gamma^t \nabla_\theta \log \pi_\theta(a_t \mid s_t) A^\theta(s_t, a_t) \right] \\ &= \sum_{\tau} \sum_{t \geq 0} \gamma^t P(\tau_t \mid \theta) \nabla_\theta \log \pi_\theta(a_t \mid s_t) A^\theta(s_t, a_t) \\ &= \mathbb{E}_{\tau \sim \theta'} \left[\sum_{t \geq 0} \frac{P(\tau_t \mid \theta)}{P(\tau_t \mid \theta')} \gamma^t \nabla_\theta \log \pi_\theta(a_t \mid s_t) A^\theta(s_t, a_t) \right]. \end{aligned}$$

Amostragem por importância no gradiente de política

Comprimindo π_θ para θ na notação

$$\begin{aligned} g = \nabla_\theta J(\theta) &= \mathbb{E}_{\tau \sim \theta} \left[\sum_{t \geq 0} \gamma^t \nabla_\theta \log \pi_\theta(a_t | s_t) A^\theta(s_t, a_t) \right] \\ &= \sum_{\tau} \sum_{t \geq 0} \gamma^t P(\tau_t | \theta) \nabla_\theta \log \pi_\theta(a_t | s_t) A^\theta(s_t, a_t) \\ &= \mathbb{E}_{\tau \sim \theta'} \left[\sum_{t \geq 0} \frac{P(\tau_t | \theta)}{P(\tau_t | \theta')} \gamma^t \nabla_\theta \log \pi_\theta(a_t | s_t) A^\theta(s_t, a_t) \right]. \end{aligned}$$

A razão colapsa: dinâmica e distribuição inicial aparecem nos dois lados.

$$\frac{P(\tau_t | \theta)}{P(\tau_t | \theta')} = \frac{\cancel{\mu(s_0)} \prod_{t'=0}^t \cancel{P(s_{t'+1} | s_{t'}, a_{t'})} \pi_\theta(a_{t'} | s_{t'})}{\cancel{\mu(s_0)} \prod_{t'=0}^t \cancel{P(s_{t'+1} | s_{t'}, a_{t'})} \pi_{\theta'}(a_{t'} | s_{t'})} = \prod_{t'=0}^t \frac{\pi_\theta(a_{t'} | s_{t'})}{\pi_{\theta'}(a_{t'} | s_{t'})}.$$

Intuição

É o mesmo cancelamento da Aula 5: modelo do mundo desconhecido, mas irrelevante.

O produto é uma bomba-relógio

$$\frac{P(\tau_t \mid \theta)}{P(\tau_t \mid \theta')} = \prod_{t'=0}^t \frac{\pi_{\theta}(a_{t'} \mid s_{t'})}{\pi_{\theta'}(a_{t'} \mid s_{t'})}$$

Suponha que em cada passo a razão valha 1,02 — políticas praticamente indistinguíveis, 2% de diferença por ação.

t	$\prod$ razões
10	1,22
50	2,69
100	7,24
500	$2,0 \times 10^4$

Atenção

Diferenças minúsculas *multiplicadas* ao longo do horizonte viram uma diferença enorme. Na direção oposta, o peso vai a zero e a trajetória some do estimador.

Intuição

A pergunta central desta primeira metade da aula: como aproveitar de forma eficiente os dados que já temos da política velha, sem pagar o preço da razão de importância sobre trajetórias inteiras?

Teste sua compreensão

Teste sua compreensão

Um estimador por amostragem por importância é não-viesado para qualquer proposta Q admissível. Então por que não coletamos um único lote gigante com π_{θ_0} e reutilizamos para sempre, reponderando?

Pergunta para discussão conduzida em aula.

Teste sua compreensão

Teste sua compreensão

Um estimador por amostragem por importância é não-viesado para qualquer proposta Q admissível. Então por que não coletamos um único lote gigante com π_{θ_0} e reutilizamos para sempre, reponderando?

Pergunta para discussão conduzida em aula.

Resposta

Porque **não-viesado não é o mesmo que útil**. À medida que θ se afasta de θ_0 , a variância cresce até que o tamanho amostral efetivo caia para ordem de uma ou duas trajetórias: o estimador continua correto *em esperança*, mas cada realização é lixo. Os métodos de hoje atacam isso por dois lados — **limitar o quanto θ pode se afastar** (região de confiança, penalidade KL, recorte) e **substituir a razão de trajetórias por uma razão de um único passo**.

SEÇÃO 2

Objetivo substituto e PPO

02

O objetivo substituto

Uma razão de um passo no lugar do produto

A identidade de desempenho relativo (Kakade e Langford, 2002):

$$J(\pi') - J(\pi) = \frac{1}{1 - \gamma} \mathbb{E}_{\substack{s \sim d^{\pi'} \\ a \sim \pi'}} [A^{\pi}(s, a)],$$

com $d^{\pi}(s) = (1 - \gamma) \sum_{t \geq 0} \gamma^t \mathbb{P}(s_t = s \mid \pi)$, a *ocupação descontada*.

Atenção

O incômodo: os estados vêm de $d^{\pi'}$, política que ainda não executamos.

O objetivo substituto

Uma razão de um passo no lugar do produto

A identidade de desempenho relativo (Kakade e Langford, 2002):

$$J(\pi') - J(\pi) = \frac{1}{1 - \gamma} \mathbb{E}_{\substack{s \sim d^{\pi'} \\ a \sim \pi'}} [A^\pi(s, a)],$$

com $d^\pi(s) = (1 - \gamma) \sum_{t \geq 0} \gamma^t \mathbb{P}(s_t = s \mid \pi)$, a *ocupação descontada*.

Atenção

O incômodo: os estados vêm de $d^{\pi'}$, política que ainda não executamos.

Definição — Objetivo substituto $\mathcal{L}_\pi(\pi')$

Trocamos $d^{\pi'}$ por d^π (que *temos*) e reponderamos apenas a ação:

$$\mathcal{L}_\pi(\pi') := \frac{1}{1 - \gamma} \mathbb{E}_{\substack{s \sim d^\pi \\ a \sim \pi}} \left[\frac{\pi'(a \mid s)}{\pi(a \mid s)} A^\pi(s, a) \right].$$

Uma razão *por passo*, não um produto — estimável com os dados de π .

PPO: duas maneiras de manter π' perto de π

Variante 1 — penalidade KL adaptativa

Resolve um problema *irrestrito*:

$$\theta_{k+1} = \arg \max_{\theta} \mathcal{L}_{\theta_k}(\theta) - \beta_k \bar{D}_{\text{KL}}(\theta \parallel \theta_k).$$

O coeficiente β_k é ajustado entre iterações: se a KL medida ficou acima do alvo, aumenta-se β ; se ficou abaixo, diminui-se — restrição KL aproximada.

Variante 2 — objetivo recortado (a que usaremos)

Seja $r_t(\theta) = \frac{\pi_{\theta}(a_t \mid s_t)}{\pi_{\theta_k}(a_t \mid s_t)}$. Então

$$\mathcal{L}_{\theta_k}^{\text{CLIP}}(\theta) = \mathbb{E}_{\tau \sim \pi_k} \left[\sum_{t=0}^T \min(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t) \right],$$

com ϵ típico 0,2 e $\theta_{k+1} = \arg \max_{\theta} \mathcal{L}_{\theta_k}^{\text{CLIP}}(\theta)$.

Teste sua compreensão

Os dois ramos do objetivo recortado

$$\mathcal{L}^{\text{CLIP}} = \min(r \hat{A}, \text{clip}(r, 1 - \epsilon, 1 + \epsilon) \hat{A}), \quad \epsilon \in (0, 1)$$

gráfico A





gráfico B



Teste sua compreensão

Qual dos dois gráficos corresponde a $A > 0$ e qual a $A < 0$? *Pergunta para discussão conduzida em aula.*

Lendo os dois ramos

Resposta

Gráfico A: $A > 0$. **Gráfico B:** $A < 0$.

Se $A > 0$ (ação boa): queremos aumentar r . O objetivo cresce linearmente até $r = 1 + \epsilon$ e *satura*. Passado esse ponto o gradiente é zero: não há mais incentivo em empurrar a probabilidade da ação para cima.

Se $A < 0$ (ação ruim): queremos diminuir r . O objetivo é constante para $r < 1 - \epsilon$ — já reduzimos o suficiente, pare. Mas do outro lado ele *decrece sem limite*.

Atenção

Duas leituras que costumam escapar:

- ▶ O recorte remove o *incentivo* de ir mais longe; ele **não impede** que r fique grande. Se a primeira época de otimização já jogou r para 3, o recorte não a traz de volta.
- ▶ Para $A < 0$ o objetivo é ilimitado inferiormente — uma ação ruim pode ser punida arbitrariamente. É uma assimetria real do PPO.

Intuição

O min faz de $\mathcal{L}^{\text{CLIP}}$ um limitante *pessimista* (inferior) do substituto não recortado: nunca somos otimistas sobre o ganho de nos afastar.

PPO recortado: o algoritmo

Algoritmo — PPO com objetivo recortado

- ▶ Inicialize os parâmetros da política θ_0 e do crítico w_0 .
- ▶ **para** $k = 0, 1, 2, \dots$ **faça**
 - Colete um lote $\mathcal{D}_k$ de trajetórias executando π_{θ_k} por T passos, guardando $\log \pi_{\theta_k}(a_t | s_t)$.
 - Calcule os retornos $\hat{R}_t$ e as vantagens $\hat{A}_t$ (GAE truncado — próxima seção); normalize $\hat{A}$ no lote.
 - **para** época = $1, \dots, K$ (tipicamente $K \in [3, 10]$) **faça**
 - Para cada minilote: suba o gradiente de $\mathcal{L}_{\theta_k}^{\text{CLIP}}(\theta) + c_H \mathbb{H}[\pi_\theta] - c_v (\hat{V}_w(s_t) - \hat{R}_t)^2$.
 - Interrompa cedo se $\bar{D}_{\text{KL}}(\theta || \theta_k)$ ultrapassar o alvo.

Intuição

O ganho essencial está no laço interno: **várias atualizações de gradiente com o mesmo lote**. É de onde vem a eficiência amostral — e é exatamente por isso que precisamos do recorte, porque a partir da segunda época os dados já são *off-policy*.

Por que pegou

- ▶ Eficiência de dados: K passos de gradiente por lote coletado.
- ▶ Só primeiras derivadas — sem inverter matriz de Fisher, sem gradiente conjugado (diferentemente do TRPO).
- ▶ Poucas linhas a mais que o REINFORCE.
- ▶ Robusto o bastante para virar padrão — inclusive no ajuste de modelos de linguagem por RLHF.

O que ele não promete

- ▶ Converge a ótimo *local*, como todo gradiente de política.
- ▶ A melhoria monotônica é *aproximada*: o recorte é uma heurística inspirada na teoria, não uma implementação dela.
- ▶ Sensível a detalhes de implementação (normalização de vantagem e de observação, recorte do gradiente, taxa decrescente, λ do GAE).

Atenção

A ideia de *atualização conservadora de política* — não confie no substituto longe do ponto onde ele foi construído — é anterior ao PPO e remonta ao início dos anos 2000 (*conservative policy iteration*, Kakade e Langford). O PPO é a encarnação barata dessa ideia.

SEÇÃO 3

GAE: um botão para o viés e a variância

03

Recapitulação: estimadores de n passos e o erro TD

Da Aula 5, a família de estimadores de vantagem:

$$\hat{A}_t^{(1)} = r_t + \gamma V(s_{t+1}) - V(s_t)$$

$$\hat{A}_t^{(2)} = r_t + \gamma r_{t+1} + \gamma^2 V(s_{t+2}) - V(s_t)$$

$$\hat{A}_t^{(\infty)} = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \dots - V(s_t)$$

Definição — Erro de diferença temporal

$$\delta_t^V := r_t + \gamma V(s_{t+1}) - V(s_t)$$

é o *resíduo de Bellman* de um passo — e, se $V = V^\pi$, um estimador não-viesado de $A^\pi(s_t, a_t)$.

Intuição


Reparação central: $\hat{A}_t^{(1)} = \delta_t^V$. Todo o resto desta seção é descobrir que os estimadores de n passos são somas de δ 's.

Tudo é soma telescópica

$$\hat{A}_t^{(1)} = \delta_t^V = r_t + \gamma V(s_{t+1}) - V(s_t)$$

$$\hat{A}_t^{(2)} = \delta_t^V + \gamma \delta_{t+1}^V = r_t + \gamma r_{t+1} + \gamma^2 V(s_{t+2}) - V(s_t)$$

$$\hat{A}_t^{(k)} = \sum_{l=0}^{k-1} \gamma^l \delta_{t+l}^V = \sum_{l=0}^{k-1} \gamma^l r_{t+l} + \gamma^k V(s_{t+k}) - V(s_t)$$



Intuição

Os V internos se cancelam aos pares: sobram o *bootstrapping* na ponta e a linha de base no início.

Estimador generalizado de vantagem (GAE)

Em vez de escolher *um* k , tome a média exponencialmente ponderada de todos:

$$\begin{aligned}\hat{A}_t^{\text{GAE}(\gamma, \lambda)} &= (1 - \lambda)(\hat{A}_t^{(1)} + \lambda \hat{A}_t^{(2)} + \lambda^2 \hat{A}_t^{(3)} + \dots) \\ &= (1 - \lambda)(\delta_t^V + \lambda(\delta_t^V + \gamma \delta_{t+1}^V) + \lambda^2(\delta_t^V + \gamma \delta_{t+1}^V + \gamma^2 \delta_{t+2}^V) + \dots) \\ &= (1 - \lambda)(\delta_t^V(1 + \lambda + \lambda^2 + \dots) + \gamma \delta_{t+1}^V(\lambda + \lambda^2 + \dots) + \gamma^2 \delta_{t+2}^V(\lambda^2 + \lambda^3 + \dots) + \dots) \\ &= (1 - \lambda)\left(\delta_t^V \frac{1}{1 - \lambda} + \gamma \lambda \delta_{t+1}^V \frac{1}{1 - \lambda} + \gamma^2 \lambda^2 \delta_{t+2}^V \frac{1}{1 - \lambda} + \dots\right) \\ &= \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l}^V\end{aligned}$$

Intuição

Um desconto exponencial de razão $\gamma \lambda$ aplicado aos erros TD futuros. Schulman et al., *High-Dimensional Continuous Control Using Generalized Advantage Estimation*, ICLR 2016.

Os dois extremos

$$\lambda = 0$$

$$\hat{A}_t = \delta_t^V = r_t + \gamma V(s_{t+1}) - V(s_t)$$

A vantagem de **TD(0)**. Usa uma recompensa real e o resto vem de V .

- ▶ Variância mínima.
- ▶ **Viés** se $V \neq V^\pi$: o erro de $V(s_{t+1})$ entra no alvo.

$$\lambda = 1$$

$$\hat{A}_t = \sum_{l \geq 0} \gamma^l \delta_{t+l}^V = G_t - V(s_t)$$

A vantagem de **Monte Carlo**. Os V internos telescopam e somem.

- ▶ Variância máxima (soma de todas as recompensas aleatórias).
- ▶ $-V(s_t)$ é linha de base: não envies a o gradiente nem se V errar.

Atenção

Cuidado: $\lambda = 1$ não dá estimador pontual não-viesado de $A^\pi - \mathbb{E}[\hat{A}_t] = Q^\pi(s_t, a_t) - V(s_t)$, igual a A^π só se $V = V^\pi$. Não-viesado, para qualquer V , é o **gradiente**: a diferença é função só do estado.

Teste sua compreensão

$$\hat{A}_t^{\text{GAE}(\gamma, \lambda)} = \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l}^V, \quad \delta_t^V = r_t + \gamma V(s_{t+1}) - V(s_t)$$

Teste sua compreensão

Considere $\text{GAE}(\gamma, 0)$ e $\text{GAE}(\gamma, 0,99)$. Quais são verdadeiras?

- (a) $\text{GAE}(\gamma, 0,99)$ é a vantagem calculada com um retorno TD(0).
- (b) $\text{GAE}(\gamma, 0)$ é a vantagem calculada com um retorno TD(0).
- (c) A *variância* de $\text{GAE}(\gamma, 0)$ tende a ser maior.
- (d) O *viés* de $\text{GAE}(\gamma, 0)$ tende a ser maior.

Pergunta para discussão conduzida em aula.

Teste sua compreensão

$$\hat{A}_t^{\text{GAE}(\gamma, \lambda)} = \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l}^V, \quad \delta_t^V = r_t + \gamma V(s_{t+1}) - V(s_t)$$

Teste sua compreensão

Considere $\text{GAE}(\gamma, 0)$ e $\text{GAE}(\gamma, 0,99)$. Quais são verdadeiras?

- (a) $\text{GAE}(\gamma, 0,99)$ é a vantagem calculada com um retorno TD(0).
- (b) $\text{GAE}(\gamma, 0)$ é a vantagem calculada com um retorno TD(0).
- (c) A *variância* de $\text{GAE}(\gamma, 0)$ tende a ser maior.
- (d) O *viés* de $\text{GAE}(\gamma, 0)$ tende a ser maior.

Pergunta para discussão conduzida em aula.

Resposta

Verdadeiras: **(b)** e **(d)**. A (a) troca os papéis; a (c) inverte a relação.

γ e λ fazem coisas diferentes



Definição — γ — desconto do *problema*

Define qual objetivo estamos otimizando. Reduzi-lo introduz viés em relação ao problema original, mas o problema muda de fato.

Definição — λ — desconto do *estimador*

Não muda o objetivo; muda apenas como estimamos a vantagem. Age sobre o quanto confiamos no crítico.

Atenção

Os dois aparecem multiplicados ($\gamma\lambda$), o que os faz parecer intercambiáveis. Não são: γ está no problema, λ está no estimador.

Medindo o compromisso

Corredor de 8 estados, $\gamma = 0,99$, política logística de um parâmetro

Gradiente exato $\partial J / \partial \theta = -0,2075$. Estimamos com $\text{GAE}(\gamma, \lambda)$ sobre 30 000 trajetórias, variando o crítico:

λ	$\hat{V} = V^\pi$ (exato)		$\hat{V} = 0,75 V^\pi$		$\hat{V} \equiv 0$	
	viés	desvio	viés	desvio	viés	desvio
0,00	+0,002	0,63	+0,121	0,84	+0,478	2,25
0,80	+0,001	0,90	+0,097	1,21	+0,386	3,29
0,95	+0,001	1,12	+0,033	1,57	+0,128	4,41
1,00	+0,001	1,23	-0,005	1,75	-0,024	5,03

Atenção

Olhe a célula em negrito. Sem crítico e com $\lambda = 0$, o viés **+0,478** é *maior em módulo* que o próprio gradiente $-0,2075$: em média o estimador aponta para o **lado errado**. Nenhuma quantidade de amostras corrige isso.

Por que $\lambda \approx 0,95$, e não $\lambda = 0$

Com um lote de m trajetórias, o desvio cai como $1/\sqrt{m}$ — mas o viés **não** cai. A raiz do erro quadrático médio, $\sqrt{\text{viés}^2 + \text{desvio}^2/m}$, com $\hat{V} = 0,75 V^\pi$:

λ	$m = 1$	$m = 10$	$m = 100$	$m = 1000$
0,00	0,849	0,292	0,147	0,124
0,80	1,219	0,396	0,155	0,104
0,95	1,566	0,496	0,160	0,059
0,98	1,672	0,529	0,168	0,054

Intuição

O λ **ótimo cresce com o tamanho do lote**. Com poucas trajetórias a variância domina e vale a pena aceitar viés (λ pequeno); com lotes grandes a variância já está controlada e o viés passa a ser o gargalo. Os valores usuais na literatura ($\lambda \in [0,9; 0,99]$) são a resposta certa para o regime em que o PPO opera: milhares de passos por atualização.

GAE truncado: como o PPO realmente calcula

A soma infinita é impossível; corta-se no fim do lote de T passos:

$$\hat{A}_t = \sum_{l=0}^{T-t-1} (\gamma\lambda)^l \delta_{t+l}^V.$$

Algoritmo — Cálculo em uma varredura reversa (custo $\mathcal{O}(T)$)

- ▶ $\hat{A}_T \leftarrow 0$
 - ▶ **para** $t = T - 1$ até 0 **faça**
 - $\delta_t \leftarrow r_t + \gamma \hat{V}(s_{t+1}) (1 - \text{fim}_t) - \hat{V}(s_t)$
 - $\hat{A}_t \leftarrow \delta_t + \gamma\lambda (1 - \text{fim}_t) \hat{A}_{t+1}$
 - ▶ Alvo do crítico: $\hat{R}_t \leftarrow \hat{A}_t + \hat{V}(s_t)$.
-
- ▶ **Benefício:** atualiza-se a cada T passos, sem esperar o fim do episódio.
 - ▶ O truncamento introduz viés (a cauda além de T some), pequeno se $(\gamma\lambda)^T \ll 1$. O indicador fim_t zera o *bootstrapping* em estados terminais — erro clássico de implementação.

SEÇÃO 4

Por que isso funciona: melhoria monotônica

04

Voltando ao limite entre duas políticas

Da aula passada: usamos d^π no lugar de $d^{\pi'}$. *Por quê?* Porque não temos amostras de $d^{\pi'}$. Mas a troca custa alguma coisa — e a teoria diz exatamente quanto.

Limite de desempenho relativo (Achiam, Held, Tamar, Abbeel, 2017)

$$\left| J(\pi') - (J(\pi) + \mathcal{L}_\pi(\pi')) \right| \leq C \sqrt{\mathbb{E}_{s \sim d^\pi} [D_{\text{KL}}(\pi' \parallel \pi)[s]]},$$

com $\mathcal{L}_\pi(\pi') = \frac{1}{1-\gamma} \mathbb{E}_{s \sim d^\pi, a \sim \pi} \left[\frac{\pi'(a|s)}{\pi(a|s)} A^\pi(s, a) \right]$ e C proporcional a $\frac{\gamma \max_s |\mathbb{E}_{a \sim \pi'} A^\pi(s, a)|}{(1-\gamma)^2}$.

Intuição


Leitura em uma frase: *o substituto é confiável exatamente na medida em que as duas políticas estão próximas em KL*. A aproximação não é ruim — ela é ruim *longe*, com erro controlado.

De um limite a um algoritmo

Tirando o valor absoluto e ficando com o lado que interessa:

$$J(\pi') - J(\pi) \geq \mathcal{L}_\pi(\pi') - C\sqrt{\mathbb{E}_{s \sim d^\pi}[D_{\text{KL}}(\pi' \parallel \pi)[s]]}.$$

- ▶ Se **maximizarmos o lado direito** em π' , garantimos melhoria do lado esquerdo.
- ▶ É um algoritmo de **majorizar-maximizar** (MM) aplicado ao objetivo verdadeiro.
- ▶ E o milagre prático: os *dois* termos do lado direito são estimáveis com amostras de π — a política que já rodamos.



Intuição

Mesmo esqueleto de EM e do ponto proximal: minorante que toca a função no ponto atual, maximize-o, repita.

A garantia de melhoria

Proposição

Se π_k e π_{k+1} estão relacionadas por

$$\pi_{k+1} = \arg \max_{\pi'} \mathcal{L}_{\pi_k}(\pi') - C \sqrt{\mathbb{E}_{s \sim d^{\pi_k}} [D_{\text{KL}}(\pi' \| \pi_k)[s]]},$$

então $J(\pi_{k+1}) \geq J(\pi_k)$.

Demonstração. Basta exibir um ponto viável com valor 0:

1. π_k é viável, e $D_{\text{KL}}(\pi_k \| \pi_k)[s] = 0$ para todo s .
2. $\mathcal{L}_{\pi_k}(\pi_k) = \frac{1}{1-\gamma} \mathbb{E}_{s \sim d^{\pi_k}, a \sim \pi_k} [A^{\pi_k}(s, a)] = 0$, pois a vantagem tem média zero sob a própria política.
3. Logo o objetivo em π_k vale 0 e o ótimo é ≥ 0 ; pelo limite anterior, $J(\pi_{k+1}) - J(\pi_k) \geq 0$. ■

Intuição

A demonstração sobrevive se a otimização for restrita a uma classe parametrizada Π_θ , desde que $\pi_k \in \Pi_\theta$ — por isso vale para redes neurais.

Por que ninguém usa esse algoritmo literalmente

$$\pi_{k+1} = \arg \max_{\pi'} \mathcal{L}_{\pi_k}(\pi') - C \sqrt{\mathbb{E}_{s \sim d^{\pi_k}} [D_{\text{KL}}(\pi' \parallel \pi_k)[s]]}$$

Atenção

O C que a teoria fornece cresce como $\gamma/(1 - \gamma)^2$. Com $\gamma = 0,99$ isso é da ordem de 10^4 : a penalidade domina o substituto e os passos ficam *absurdamente pequenos*. A garantia é verdadeira e inútil.

Intuição

Duas saídas, e as duas abandonam a constante teórica: transformar a penalidade em **restrição** com um raio δ escolhido à mão (região de confiança, TRPO), ou **ajustar** o coeficiente da penalidade por realimentação (PPO).

Três aproximações do mesmo algoritmo idealizado

TRPO	PPO–penalidade	PPO–recorte
Substitui a penalidade por uma restrição rígida $\bar{D}_{KL} \leq \delta$	Mantém a penalidade, mas ajusta β_k para atingir uma KL alvo	Abandona a KL: recorta a razão em $[1 - \epsilon, 1 + \epsilon]$
Passo natural + busca em linha; precisa de gradiente conjugado	Só primeiras derivadas; um hiperparâmetro extra	Só primeiras derivadas; um hiperparâmetro (ϵ)
Caro por iteração	Intermediário	Barato e simples de implementar

Intuição

A teoria da melhoria monotônica não é *executada* por nenhum dos três. Ela explica *por que* vale a pena restringir o passo — e é essa explicação, não a fórmula, que sobreviveu à prática.

Teste sua compreensão

Teste sua compreensão

Sobre o REINFORCE, quais afirmações são verdadeiras?

- (a) Acrescentar uma linha de base ajuda a reduzir a variância das atualizações.
- (b) Ele converge para um ótimo global.
- (c) Pode ser inicializado com uma política determinística subótima e ainda assim convergir para um ótimo local, dados passos adequados.
- (d) Um único passo de gradiente pode produzir uma política *pior* que a inicial em retorno obtido.

Pergunta para discussão conduzida em aula.

Teste sua compreensão

Teste sua compreensão

Sobre o REINFORCE, quais afirmações são verdadeiras?

- (a) Acrescentar uma linha de base ajuda a reduzir a variância das atualizações.
- (b) Ele converge para um ótimo global.
- (c) Pode ser inicializado com uma política determinística subótima e ainda assim convergir para um ótimo local, dados passos adequados.
- (d) Um único passo de gradiente pode produzir uma política *pior* que a inicial em retorno obtido.

Pergunta para discussão conduzida em aula.


Resposta

(a) e **(d)** são verdadeiras. **(b)** é falsa: a otimização é não-convexa e converge a ótimos locais. **(c)** é falsa e vale insistir: uma política *determinística* nunca toma as demais ações — sem exploração, o gradiente não enxerga as alternativas. **(d)** é a motivação desta seção.

Balanço da primeira metade

Definição — Gradientes de política — o que ficou

- ▶ Família muito usada, bem além deste curso.
- ▶ Funciona quando a recompensa **não é diferenciável**.
- ▶ Quase sempre combinada com valor sem modelo: *ator-crítico*.
- ▶ O crítico entra por duas portas — linha de base (variância) e *bootstrapping* (viés); o GAE interpola entre elas.



Atenção

Tudo isso pressupõe que existe uma **função de recompensa**. E se não existir — se tudo o que temos for alguém fazendo a tarefa corretamente?

SEÇÃO 5

Aprendizagem por imitação

05

Aprender a partir de decisões e resultados passados

Em muitos domínios já *existem* políticas de decisão muito boas — executadas por pessoas — e o que queremos é automatizá-las.

Ideia 1 — humano fornece a recompensa

A pessoa avalia as decisões que o algoritmo de RL toma.

- + Supervisão simples e barata por episódio.
- Complexidade amostral altíssima: o agente precisa de milhões de episódios, e cada um precisa ser avaliado.

Ideia 2 — aprendizagem por imitação

A pessoa *demonstra* o comportamento desejado.

- + Uma demonstração carrega muito mais informação que um número.
- Como generalizar para situações que o especialista nunca enfrentou?

Intuição

A escolha é frequentemente sobre *qual canal de comunicação é mais fácil para o humano*. Especificar uma recompensa que produza direção defensiva é difícil; dirigir defensivamente por vinte minutos é fácil.

Recompensas densas e o problema de especificá-las

Recompensas **densas no tempo** guiam o agente de perto e tornam o aprendizado muito mais rápido que uma recompensa terminal esparsa. Como obtê-las?

Atenção

Projetá-las à mão (*reward shaping*) costuma ser frágil. O agente otimiza o que foi escrito, não o que se queria: uma penalidade por tempo mal calibrada produz um robô que trava, um bônus por velocidade produz um robô que capota.

Intuição

Especificá-las implicitamente por demonstrações. Em vez de escrever R , mostre trajetórias boas e deixe o algoritmo inferir que função de recompensa as tornaria ótimas.

Ex.: navegação em terreno não estruturado (Silver et al., 2010); rodovia simulada (Abbeel e Ng, 2004); estacionamento (Abbeel et al., 2008).

Definição — Aprendizagem por demonstração


O especialista fornece trajetórias. Útil quando é mais fácil *demonstrar* o comportamento do que especificar uma recompensa que o gere ou a política diretamente.

Formulação do problema

Definição — Dados de entrada

- ▶ Espaço de estados $\mathcal{S}$ e de ações $\mathcal{A}$;
- ▶ Modelo de transição $P(s' | s, a)$;
- ▶ **Nenhuma função de recompensa R** ;
- ▶ Um conjunto de demonstrações do especialista $\tau_j = (s_0, a_0, s_1, a_1, \dots)$, com ações sorteadas de π^* .


Três perguntas distintas, três famílias de métodos:



Intuição

A terceira é a mais ambiciosa: com a recompensa correta em mãos, a política resultante pode *superar* o especialista — o que a clonagem, por construção, nunca faz.

RL direto e RL inverso



Atenção

O problema direto (a) é bem-posto: dado R , existe V^* único. O inverso (b) é **mal-posto**. Voltaremos a isso — é a dificuldade central de todo o RL inverso.

Intuição

Por que se dar ao trabalho de recuperar R em vez de copiar a política? Porque a recompensa é a descrição *mais transferível* de uma tarefa: ela continua válida se a dinâmica mudar, se o corpo do robô mudar, se o horizonte mudar. A política, não.

SEÇÃO 6

Clonagem de comportamento e DAgger

06

Clonagem de comportamento

Definição — Redução a aprendizado supervisionado

1. Fixe uma classe de políticas (rede neural, árvore de decisão, ...).
2. Trate os pares $(s_0, a_0), (s_1, a_1), (s_2, a_2), \dots$ das demonstrações como um conjunto de treinamento com *entrada* s e *rótulo* a .
3. Ajuste $\hat{\pi} = \arg \min_{\pi} \sum_i \ell(\pi(s_i), a_i)$.

É isso. Nenhuma recompensa, nenhum modelo de transição, nenhuma interação com o ambiente.

Dois sucessos históricos

- ▶ **ALVINN** (Pomerleau, NIPS 1989): rede rasa mapeando imagem de câmera em ângulo de direção; dirigiu um veículo em vias reais.
- ▶ Aprender a pilotar em simulador de voo (Sammur et al., ICML 1992).

Intuição

Continua muito usada. Com arquiteturas recorrentes ou de sequência (*BC-RNN*), a clonagem é uma linha de base forte em manipulação robótica a partir de demonstrações humanas *offline* (Mandlekar et al., CoRL 2021).

O problema: erros que se compõem



Atenção

O aprendizado supervisionado supõe pares (s, a) **i.i.d.** e ignora a estrutura temporal. Mas em um MDP o *próprio erro* muda a distribuição dos estados seguintes: cada desvio leva o agente para uma região onde ele foi menos treinado, onde erra mais, e assim por diante.

ϵT ou ϵT^2 ?

Se os erros fossem independentes

Erro no instante t com probabilidade $\leq \epsilon$:

$$\mathbb{E}[\text{total de erros}] \leq \epsilon T.$$

Com deriva de distribuição

Um erro em t tira o agente da distribuição de treinamento pelo *resto* do episódio:

$$\mathbb{E}[\text{total}] \lesssim \epsilon(T + (T - 1) + \dots + 1) \sim \epsilon T^2.$$

Resultado formal: Ross e Bagnell (AISTATS 2010), Teorema 2.1.

Com $\epsilon = 0,01$ (99% de acerto por passo):

T	i.i.d.	com deriva	razão
10	0,1	0,5	5×
100	1,0	37,2	37×
500	5,0	401,7	80×
1000	10,0	901,0	90×

(Modelo: uma vez fora da distribuição, o agente erra sempre.)

Intuição

Em $T = 1000$ passos, uma acurácia de 99% produz um agente que passa 90% **do episódio** errado.

Descasamento de distribuições, dito com precisão

Definição — A hipótese que quebra

No aprendizado supervisionado, $(x, y) \sim \mathcal{D}$ tanto no treino quanto no teste. Em um MDP:

$$\text{treino: } s_t \sim \mathcal{D}_{\pi^*}, \quad \text{teste: } s_t \sim \mathcal{D}_{\pi_\theta}.$$

E $\mathcal{D}_{\pi_\theta}$ depende da política aprendida: a distribuição de teste é resultado do treino, não um dado.

Intuição

É a patologia do RL *off-policy* por outro ângulo: os dados vêm de uma política e a avaliação ocorre sob outra. Lá a resposta foi reponderar; aqui será *consertar os dados*.

Teste sua compreensão

Por que não basta coletar mais demonstrações do especialista? Em que situação isso realmente resolveria, e por que ela raramente ocorre? *Pergunta para discussão conduzida em aula.*

Dagger: agregação de conjuntos de dados


Intuição

A ideia em uma frase: **obtenha rótulos do especialista nos estados que a sua política visita**, e não apenas nos que o especialista visitaria.

Algoritmo — DAgger (Ross, Gordon e Bagnell, 2011)

- ▶ $\mathcal{D} \leftarrow \emptyset$; $\hat{\pi}_1 \leftarrow$ política inicial qualquer (ou clonagem sobre as demonstrações).
- ▶ **para** $i = 1, \dots, N$ **faça**
 - $\pi_i \leftarrow \beta_i \pi^* + (1 - \beta_i) \hat{\pi}_i$ (mistura; $\beta_i \rightarrow 0$)
 - Execute π_i e colete as trajetórias visitadas.
 - **Pergunte ao especialista** qual ação ele tomaria em cada estado visitado: $\mathcal{D}_i = \{(s, \pi^*(s))\}$.
 - $\mathcal{D} \leftarrow \mathcal{D} \cup \mathcal{D}_i$; treine $\hat{\pi}_{i+1}$ em todo o $\mathcal{D}$.
- ▶ Devolva a melhor $\hat{\pi}_i$ segundo validação.
- ▶ Como o conjunto agregado cobre os estados induzidos pela própria política, o treino e o teste passam a compartilhar a distribuição.
- ▶ Análise via *aprendizado online sem arrependimento*: o erro volta a ser $\mathcal{O}(\epsilon T)$, **linear** em T .

Dagger: o preço



Atenção

Limitação central: o especialista precisa estar *disponível online* para rotular estados arbitrários — inclusive estados esquisitos, nos quais ele jamais estaria, e nos quais talvez nem saiba o que faria. Rotular quadro a quadro é caro, cansativo e, em domínios como voo ou cirurgia, impraticável em tempo real.

Intuição

Duas saídas usuais: rotulação *offline* em lote (grava-se a execução e o especialista rotula depois) e **HG-Dagger**, em que o humano só intervém quando julga necessário — o que também dá um sinal de onde a política é insegura.

SEÇÃO 7

RL inverso com recompensa linear

07

Recompensa linear em atributos

Definição — Modelo

$$R(s) = w^\top x(s), \quad w \in \mathbb{R}^n, \quad x : \mathcal{S} \rightarrow \mathbb{R}^n.$$

Os atributos $x(s)$ são dados (distância ao meio da pista, velocidade, proximidade de obstáculo, ...). O que se quer descobrir é o vetor de **pesos** w — ou seja, *o que o especialista valoriza*.

Substituindo na função valor:

$$\begin{aligned} V^\pi(s_0) &= \mathbb{E}_\pi \left[\sum_{t \geq 0} \gamma^t R(s_t) \mid s_0 \right] = \mathbb{E}_\pi \left[\sum_{t \geq 0} \gamma^t w^\top x(s_t) \mid s_0 \right] \\ &= w^\top \mathbb{E}_\pi \left[\sum_{t \geq 0} \gamma^t x(s_t) \mid s_0 \right] = w^\top \mu(\pi). \end{aligned}$$

Definição — Expectativas de atributos $\mu(\pi) \in \mathbb{R}^n$

A frequência descontada com que a política π acumula cada atributo, partindo de s_0 . Uma política é resumida, para todos os efeitos de comparação de valor, por n números.

Da otimalidade do especialista a uma condição sobre w

Se as demonstrações vêm da política *ótima* π^* para a recompensa verdadeira $R^* = w^{*\top}x$, então por definição de otimalidade

$$V^* = w^{*\top} \mu(\pi^*) \geq V^\pi = w^{*\top} \mu(\pi) \quad \text{para toda política } \pi.$$

Condição de identificação

Basta encontrar w^* tal que

$$w^{*\top} \mu(\pi^*) \geq w^{*\top} \mu(\pi) \quad \forall \pi \neq \pi^*.$$

Ou seja: um vetor de pesos sob o qual o especialista bate todo mundo.

Atenção

Duas dificuldades imediatas. (i) O conjunto de restrições é enorme — uma por política. (ii) $w = 0$ satisfaz todas elas com igualdade. A formulação, como está, é vazia.

Casamento de expectativas de atributos

E se, em vez de recuperar w , buscássemos direto uma política que *se comporte* como o especialista?

Casamento de atributos (Abbeel e Ng, 2004)

Se $\|\mu(\pi) - \mu(\pi^*)\|_1 \leq \epsilon$, então para todo w com $\|w\|_\infty \leq 1$ vale, por Hölder,

$$|w^\top \mu(\pi) - w^\top \mu(\pi^*)| \leq \epsilon.$$

Intuição

Garantia forte: se as expectativas de atributos casam, a política é quase tão boa quanto a do especialista **para qualquer recompensa linear nesses atributos** — inclusive a verdadeira. Contornamos a ambiguidade em vez de resolvê-la.

Atenção

O peso da hipótese migrou para x : se um atributo relevante ficou de fora, nenhuma garantia o alcança.

Aprendizado por aprendizagem: iteração de margem máxima

Algoritmo — Aprendizado por aprendizagem via RL inverso

- ▶ Estime $\mu(\pi^*)$ pela média empírica dos atributos descontados nas demonstrações.
- ▶ Escolha $\pi^{(0)}$ qualquer e calcule $\mu(\pi^{(0)})$.
- ▶ **para** $j = 1, 2, \dots$ **faça**
 - **Passo de margem:** resolva

$$\max_{t, \|w\|_2 \leq 1} t \quad \text{s.a.} \quad w^\top \mu(\pi^*) \geq w^\top \mu(\pi^{(i)}) + t, \quad i < j.$$

- **Passo de RL:** resolva o MDP com $R = w^\top x$, obtendo $\pi^{(j)}$; calcule $\mu(\pi^{(j)})$.
- Pare se $t \leq \epsilon$.

Intuição

É uma máquina de vetores de suporte alternando com um planejador: a cada rodada, procura-se a recompensa que mais *separa* o especialista das políticas já geradas, e então a melhor política para essa recompensa. Quando ninguém mais consegue separá-los, as expectativas casaram.

Teste sua compreensão

Teste sua compreensão

Dados $\mathcal{S}$, $\mathcal{A}$, o modelo $P(s' \mid s, a)$ e demonstrações de uma política ótima π^* , mas nenhuma recompensa. Sobre a função R que se quer inferir:

- (a) Existe uma única R que torna a política do especialista ótima.
- (b) Existem muitas R que tornam a política do especialista ótima.
- (c) Depende do MDP.

Pergunta para discussão conduzida em aula.

Teste sua compreensão

Teste sua compreensão

Dados $\mathcal{S}$, $\mathcal{A}$, o modelo $P(s' | s, a)$ e demonstrações de uma política ótima π^* , mas nenhuma recompensa. Sobre a função R que se quer inferir:

- (a) Existe uma única R que torna a política do especialista ótima.
- (b) Existem muitas R que tornam a política do especialista ótima.
- (c) Depende do MDP.

Pergunta para discussão conduzida em aula.

Resposta

(b) — e mais: existe um conjunto **infinito**. Dois argumentos imediatos: (i) $R \equiv 0$ torna *toda* política ótima, inclusive a do especialista; (ii) escalar R por qualquer $c > 0$, ou somar uma constante, preserva a ordenação das políticas. Mais geralmente, transformações do tipo $R'(s, a, s') = R(s, a, s') + \gamma\Phi(s') - \Phi(s)$ preservam a política ótima para qualquer Φ (*potential-based shaping*, Ng, Harada e Russell, 1999).

Ambiguidade: o problema estrutural do RL inverso

Atenção

Duas ambiguidades, não uma.

1. Infinitas funções de recompensa induzem a mesma política ótima.
2. Infinitas políticas *estocásticas* produzem as mesmas expectativas de atributos.

Qual escolher? Nada no problema, como formulado, responde.



Princípio de desempate:
entre todas as distribuições
compatíveis com os dados,
escolha a *menos* comprometida.

SEÇÃO 8

RL inverso de máxima entropia

08

Contagens de atributos por trajetória

Definição — Notação desta seção

Contagem de atributos de uma trajetória e média empírica sobre m demonstrações:

$$\mu_{\tau_j} = \sum_{s_i \in \tau_j} x(s_i), \quad \tilde{\mu} = \frac{1}{m} \sum_{j=1}^m \mu_{\tau_j}.$$

Atenção

Convenção *diferente* da usada até aqui: soma sobre uma trajetória, sem desconto. É a do artigo de Ziebart et al. (2008).

Intuição

Reformulação-chave: em um MDP determinístico de horizonte H e com recompensa linear, uma política fica *completamente especificada* por sua distribuição sobre trajetórias. “Qual política?” vira “qual distribuição sobre caminhos?”.

Princípio da máxima entropia

Problema variacional (Ziebart et al., 2008)

Entre todas as distribuições sobre trajetórias que reproduzem as contagens de atributos observadas, escolha a de **maior entropia**:

$$\max_P - \sum_{\tau} P(\tau) \log P(\tau) \quad \text{s.a.} \quad \sum_{\tau} P(\tau) \mu_{\tau} = \tilde{\mu}, \quad \sum_{\tau} P(\tau) = 1.$$

Intuição

“Nenhuma preferência além do que os dados exigem.” Qualquer distribuição de entropia menor afirma sobre o especialista algo que as demonstrações não sustentam.

A solução: família exponencial

A solução do problema variacional (Jaynes, 1957):

$$P(\tau_j \mid w) = \frac{1}{Z(w)} \exp(w^\top \mu_{\tau_j}) = \frac{1}{Z(w)} \exp\left(\sum_{s_i \in \tau_j} w^\top x(s_i)\right), \quad Z(w) = \sum_{\tau} \exp(w^\top \mu_{\tau}).$$

Definição — Leitura

Forte preferência por caminhos de alta recompensa; caminhos de recompensa *igual* são igualmente prováveis. E maximizar a entropia sob as restrições equivale a maximizar a verossimilhança dos dados sob essa família.

MDPs estocásticos

Em geral a dinâmica não é determinística, e a distribuição sobre caminhos passa a depender *também* do ambiente, não só dos pesos:

$$P(\tau_j \mid w, P(s' \mid s, a)) \approx \frac{\exp(w^\top \mu_{\tau_j})}{Z(w, P)} \prod_{s_i, a_i \in \tau_j} P(s_{i+1} \mid s_i, a_i).$$

Atenção

Dois efeitos se misturam: um caminho pode ser frequente porque o especialista o *quer* (peso w) ou porque a dinâmica o *empurra* para lá (termo $\prod P$). Separar os dois é o trabalho do modelo de transição — e é exatamente aqui que ele se torna indispensável.

Intuição

Um caso famoso: se o especialista quase sempre acaba no mesmo lugar, isso pode revelar uma preferência forte, ou apenas que todos os caminhos levam ali. Sem saber a dinâmica, as duas explicações são indistinguíveis.

Escolha w que maximiza a verossimilhança das demonstrações:

$$w^* = \arg \max_w \sum_{\text{exemplos}} \log P(\tau \mid w).$$

Gradiente

$$\nabla L(w) = \tilde{\mu} - \sum_{\tau} P(\tau \mid w) \mu_{\tau} = \tilde{\mu} - \sum_{s_i} D(s_i) x(s_i),$$

onde $D(s)$ é a **frequência esperada de visitação** de s sob a política induzida pelos pesos atuais.

Intuição

O gradiente é a diferença entre *o que o especialista fez* e *o que o modelo atual faria*: se o modelo já reproduz as contagens observadas, ele é nulo. É a forma canônica de todo modelo de máxima entropia.

Calculando as frequências de visitação

Algoritmo — Frequências esperadas de estado (Ziebart et al., 2008)

- ▶ **Regressiva** ($t = H, \dots, 1$), com $Z_s \leftarrow 1$ nos terminais: $Z_{a,s} \leftarrow \sum_{s'} P(s' | s, a) e^{w^\top x(s)} Z_{s'}$,
 $Z_s \leftarrow \sum_a Z_{a,s}$.
- ▶ **Política local:** $\pi_w(a | s) = Z_{a,s} / Z_s$.
- ▶ **Progressiva:** $D_{t+1}(s') \leftarrow \sum_{s,a} D_t(s) \pi_w(a | s) P(s' | s, a)$, $D(s) = \sum_t D_t(s)$.
- ▶ $w \leftarrow w + \eta(\tilde{\mu} - \sum_s D(s)x(s))$; repita.

Intuição

É o *forward-backward* dos modelos ocultos de Markov, com a exponencial da recompensa no lugar da emissão. E $\log Z_s$ é um *máximo suave*: uma equação de Bellman com SOFTMAX no lugar do $\max$.

Teste sua compreensão

Teste sua compreensão

Para calcular $D(s)$ é preciso conhecer o modelo de transição. A clonagem de comportamento precisava dele? E o DAGger? *Pergunta para discussão conduzida em aula.*

Teste sua compreensão

Teste sua compreensão

Para calcular $D(s)$ é preciso conhecer o modelo de transição. A clonagem de comportamento precisava dele? E o DAgger? *Pergunta para discussão conduzida em aula.*

Resposta

Não, e não. A clonagem só precisa dos pares (s, a) — é aprendizado supervisionado puro, sem qualquer interação. O DAgger precisa *executar* a política no mundo (ou em um simulador) e de um especialista para rotular, mas nunca precisa da distribuição $P(s' | s, a)$ explicitamente.

O MaxEnt IRL, ao contrário, precisa do modelo — ou da capacidade de simular — porque tem de calcular *o que a política atual faria*, e não apenas comparar com o que o especialista fez. É o preço de recuperar uma recompensa em vez de copiar um comportamento.

Balanço do RL inverso de máxima entropia

Definição — Por que foi tão influente

- ▶ Critério **princiado** para escolher entre as infinitas recompensas compatíveis.
- ▶ Absorve demonstrações subótimas ou ruidosas: deixam de ser contradições e viram amostras de baixa probabilidade.
- ▶ Conecta RL inverso a verossimilhança e modelos probabilísticos.

Atenção

- ▶ Exige **conhecer o modelo de transição** (ou poder simular).
- ▶ Cada passo de gradiente exige resolver um planejamento — caro.
- ▶ Continua refém da escolha de x ; versões modernas aprendem os atributos com redes (*guided cost learning*).

Intuição

GAIL (Ho e Ermon, 2016) fecha o círculo: em vez de recuperar R e depois planejar, treina junto um discriminador (especialista vs. aprendiz) e a política — o discriminador faz o papel da recompensa.

De recompensas aprendidas a políticas

- ▶ Métodos de RL inverso entregam uma *recompensa*. Em geral o que se quer é uma *política* cujo desempenho iguale ou supere a do especialista.
- ▶ Caminho direto: pegue $\hat{R}$ e rode RL comum com ela — é o que a iteração de margem máxima faz internamente.
- ▶ Caminho mais curto: aprender a política diretamente (GAIL, e variantes adversariais).

Definição — O elo com o que se faz hoje

Frequentemente não temos demonstrações, mas **pares de preferência**: “a resposta y_1 é melhor que y_2 ”. Ajusta-se um modelo de recompensa a essas comparações (tipicamente Bradley-Terry) e então otimiza-se a política com **PPO** — exatamente o algoritmo da primeira metade desta aula.

Intuição

Esse cenário — aprender recompensa de comparações — é o dos *dueling bandits*, e volta em breve no curso. As duas metades de hoje eram, o tempo todo, as duas metades do mesmo sistema.

SEÇÃO 9

Síntese

09

Mapa dos métodos de imitação

Método	Precisa de	Erro	Limitação principal
Clonagem de comportamento	demonstrações	$\mathcal{O}(\epsilon T^2)$	deriva de distribuição; nunca supera o especialista
DAgger	especialista <i>online</i>	$\mathcal{O}(\epsilon T)$	rotulação interativa cara ou impossível
RL inverso linear	modelo + atributos	—	ambiguidade; depende inteiramente de x
MaxEnt IRL	modelo + atributos	—	planejamento a cada passo de gradiente
GAIL	simulador	—	instabilidade adversarial; sem R interpretável

Intuição

Uma leitura da tabela: quanto mais barata a supervisão exigida, mais frágil a garantia. A clonagem pede o mínimo e entrega o mínimo; o RL inverso pede um modelo do mundo e entrega algo transferível.

O que você deve levar desta aula

Definição — Capacidades esperadas

- ▶ Escrever a identidade de amostragem por importância e explicar por que a *variância*, não o viés, é o obstáculo.
- ▶ Mostrar que a razão de trajetórias colapsa em um produto de razões de política — e por que esse produto é instável.
- ▶ Enunciar as duas variantes do PPO e **ler o gráfico do recorte** nos dois sinais da vantagem.
- ▶ Derivar $\hat{A}^{\text{GAE}(\gamma, \lambda)} = \sum_l (\gamma \lambda)^l \delta_{t+l}^V$ e identificar os casos $\lambda = 0$ e $\lambda = 1$.
- ▶ Demonstrar a garantia de melhoria monotônica a partir do limite de desempenho relativo, e dizer por que o C da teoria inviabiliza o uso literal.
- ▶ Definir clonagem de comportamento e explicar em que ela difere de RL.
- ▶ Explicar o argumento ϵT versus ϵT^2 e como o DAgger recupera o regime linear.
- ▶ Justificar por que o problema de RL inverso é mal-posto e como o casamento de atributos e a máxima entropia respondem a isso.

Leituras

- ▶ Schulman et al., *Generalized Advantage Estimation*, ICLR 2016.
- ▶ Schulman et al., *Proximal Policy Optimization Algorithms*, 2017.
- ▶ Achiam, Held, Tamar e Abbeel, *Constrained Policy Optimization*, ICML 2017.
- ▶ Ross, Gordon e Bagnell, *A Reduction of Imitation Learning...*, AISTATS 2011.
- ▶ Ziebart et al., *Maximum Entropy Inverse RL*, AAAI 2008.
- ▶ Ho e Ermon, *Generative Adversarial Imitation Learning*, NeurIPS 2016.
- ▶ Sun, Venkatraman, Gordon, Boots e Bagnell, ICML 2017 — teoria entre imitação e RL.

Intuição

Próxima aula. Aprender recompensas quando só há *preferências* entre pares de resultados, e a exploração como problema de primeira classe.

Atenção

Uma pergunta em aberto para levar: a clonagem de comportamento, por construção, tem o especialista como teto. O RL inverso, não. O que exatamente permite ultrapassar quem nos ensinou?