

Aula 7 — Gradientes de política II e Aprendizagem por imitação

Amostragem por importância • Objetivo substituto e PPO • GAE • Melhoria monotônica • Clonagem de comportamento, DAGger e RL inverso

Prof. Marcelo Keese Albertini • Universidade Federal de Uberlândia

Material adaptado e expandido de CS234: *Reinforcement Learning*, Emma Brunskill (Stanford), Lecture 7.

Leitura complementar: Schulman et al. (2016, 2017); Ross, Gordon e Bagnell (2011); Ziebart et al. (2008).

A Aula 5 nos deu um *estimador* do gradiente da política. A Aula 6 mostrou que saber a direção não basta: falta o *tamanho do passo*, e medi-lo no espaço de parâmetros é a coisa errada a fazer. Esta aula fecha o assunto de duas maneiras — uma prática (PPO e GAE, que é o que se implementa) e uma teórica (por que o esquema funciona) — e depois muda de assunto: e quando não há recompensa nenhuma, apenas alguém que já sabe fazer a tarefa?

Intuição

Fio condutor da primeira metade. Todo método desta aula responde à mesma pergunta: *quanto posso mexer na política antes que os dados que tenho deixem de descrevê-la?* A resposta honesta é um limite teórico; a resposta que se usa na prática é o recorte do PPO. Vale conhecer as duas e saber onde uma vira a outra.

Fio condutor da segunda metade. Sem recompensa, sobra a demonstração. Ou se copia o *comportamento* (clonagem, DAGger) ou se infere a *intenção* (RL inverso). A primeira é barata e tem o especialista como teto; a segunda é cara e, em princípio, não tem.

Como usar este handout

Este texto acompanha os slides da Aula 7 e é mais completo que eles em três pontos: as passagens algébricas estão escritas por inteiro (em especial a soma geométrica do GAE e a demonstração de melhoria monotônica), há pseudocódigo pronto para implementar, e há exercícios ao final. As caixas **âmbar** marcam perguntas para discussão em aula — não têm resposta escrita aqui de propósito.

1 O problema do passo, e por que reponderar não resolve

1.1 De onde viemos

O gradiente da política, na forma que já derivamos,

$$g = \nabla_{\theta} J(\pi_{\theta}) = \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t \geq 0} \gamma^t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) A^{\pi_{\theta}}(s_t, a_t) \right],$$

é um estimador não-viesado, e sabemos reduzir sua variância (linha de base, vantagem, estimadores de n passos). Restam duas limitações, ambas sobre o uso desse gradiente:

- 1. Eficiência amostral ruim.** Cada lote de trajetórias é gasto em *um* passo de gradiente e descartado, porque depois do passo a política mudou e os dados viraram off-policy.

2. Distância no espaço de parâmetros não é distância no espaço de políticas. Este é o ponto conceitual. O espaço de políticas tabulares é o simplexo

$$\Pi = \left\{ \pi \in \mathbb{R}^{|S| \times |A|} : \sum_a \pi_{sa} = 1, \pi_{sa} \geq 0 \right\},$$

mas o gradiente anda em θ . O mesmo $\|\Delta\theta\|$ pode produzir uma mudança imperceptível de comportamento em uma região e uma política completamente diferente em outra. É por isso que ajustar o passo α é tão desagradável em gradiente de política e tão fácil em regressão logística.

Atenção

A consequência prática do item 2 é assimétrica e vale enunciá-la: em aprendizado supervisionado, um passo grande demais produz uma época ruim e a próxima corrige. Em RL, um passo grande demais produz uma política ruim, que coleta *dados ruins*, com os quais se estima um gradiente ruim. O erro se realimenta.

1.2 Amostragem por importância: a tentativa óbvia

Se o problema é que os dados vieram da política antiga, a ferramenta clássica para corrigir é a amostragem por importância.

Definição — Amostragem por importância

Para estimar $\mathbb{E}_{x \sim P}[f(x)]$ com amostras de Q (com $Q(x) > 0$ sempre que $P(x) > 0$):

$$\mathbb{E}_{x \sim P}[f(x)] = \mathbb{E}_{x \sim Q} \left[\frac{P(x)}{Q(x)} f(x) \right] \approx \frac{1}{|\mathcal{D}|} \sum_{x \in \mathcal{D}} \frac{P(x)}{Q(x)} f(x), \quad \mathcal{D} \sim Q.$$

A razão $P(x)/Q(x)$ é o *peso de importância* de x .

O estimador é não-viesado para qualquer Q admissível. O preço está na variância:

$$\begin{aligned} \text{Var}(\hat{\mu}_Q) &= \frac{1}{N} \text{Var}_{x \sim Q} \left[\frac{P(x)}{Q(x)} f(x) \right] \\ &= \frac{1}{N} \left(\mathbb{E}_{x \sim Q} \left[\frac{P(x)^2}{Q(x)^2} f(x)^2 \right] - \mathbb{E}_{x \sim Q} \left[\frac{P(x)}{Q(x)} f(x) \right]^2 \right) \\ &= \frac{1}{N} \left(\mathbb{E}_{x \sim P} \left[\frac{P(x)}{Q(x)} f(x)^2 \right] - \mathbb{E}_{x \sim P} [f(x)]^2 \right). \end{aligned}$$

O termo destacado é o problema: se P/Q for grande justamente onde f^2 é grande, a variância explode. O viés continua zero — e isso é uma armadilha, porque um estimador não-viesado com variância enorme produz, em um único lote, números arbitrariamente errados.

1.3 Por que os pesos explodem em trajetórias

Aplicando a ideia ao gradiente, com θ' a política que gerou os dados:

$$\begin{aligned} g &= \nabla_{\theta} J(\theta) = \mathbb{E}_{\tau \sim \theta} \left[\sum_{t \geq 0} \gamma^t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) A^{\theta}(s_t, a_t) \right] \\ &= \sum_{\tau} \sum_{t \geq 0} \gamma^t P(\tau_t | \theta) \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) A^{\theta}(s_t, a_t) \\ &= \mathbb{E}_{\tau \sim \theta'} \left[\sum_{t \geq 0} \frac{P(\tau_t | \theta)}{P(\tau_t | \theta')} \gamma^t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) A^{\theta}(s_t, a_t) \right]. \end{aligned}$$

A razão de trajetórias colapsa exatamente como na Aula 5 — a dinâmica desconhecida e a distribuição inicial aparecem nos dois lados e se cancelam:

$$\frac{P(\tau_t | \theta)}{P(\tau_t | \theta')} = \frac{\cancel{\mu(s_0)} \prod_{t'=0}^t \cancel{P(s_{t'+1} | s_{t'}, a_{t'})} \pi_\theta(a_{t'} | s_{t'})}{\cancel{\mu(s_0)} \prod_{t'=0}^t \cancel{P(s_{t'+1} | s_{t'}, a_{t'})} \pi_{\theta'}(a_{t'} | s_{t'})} = \prod_{t'=0}^t \frac{\pi_\theta(a_{t'} | s_{t'})}{\pi_{\theta'}(a_{t'} | s_{t'})}.$$

Atenção

O peso é um **produto de $t+1$ razões**. Ainda que cada fator esteja em $[0,95; 1,05]$, com $t = 200$ o produto vive no intervalo $[0,95^{201}; 1,05^{201}] \approx [3 \cdot 10^{-5}; 2 \cdot 10^4]$. Diferenças minúsculas, multiplicadas duzentas vezes, viram uma diferença enorme. Na prática, um punhado de trajetórias domina o lote inteiro e as demais são numericamente ignoradas.

A pergunta que organiza o resto da seção é a de Schulman e coautores: *como reaproveitar os dados da política antiga sem pagar o produto?*

Para discutir em aula

O peso de importância explode com o horizonte. Isso sugere um remédio óbvio — cortar o horizonte, ou descontar mais forte. Que preço se paga? Em que tipo de tarefa esse preço é aceitável e em que tipo é fatal?

2 Objetivo substituto: uma razão em vez de um produto

2.1 A identidade exata de Kakade e Langford

Existe uma expressão *exata* para a diferença de desempenho entre duas políticas:

Identidade de desempenho relativo (Kakade e Langford, 2002)

$$J(\pi') - J(\pi) = \frac{1}{1-\gamma} \mathbb{E}_{\substack{s \sim d^{\pi'} \\ a \sim \pi'}} [A^\pi(s, a)], \quad d^\pi(s) = (1-\gamma) \sum_{t \geq 0} \gamma^t \mathbb{P}(s_t = s | \pi),$$

onde d^π é a *distribuição de ocupação descontada* de π .

A identidade tem uma leitura bonita: *a nova política é melhor exatamente na medida em que, nos estados que ela visita, ela escolhe ações com vantagem positiva segundo a política antiga*. O incômodo é igualmente claro: os estados vêm de $d^{\pi'}$, e π' é justamente a política que ainda não executamos.

2.2 A troca, e o que ela custa

Trocamos $d^{\pi'}$ por d^π — que temos — e reponderamos apenas a ação:

Definição — Objetivo substituto $\mathcal{L}_\pi(\pi')$

$$\mathcal{L}_\pi(\pi') := \frac{1}{1-\gamma} \mathbb{E}_{\substack{s \sim d^\pi \\ a \sim \pi}} \left[\frac{\pi'(a | s)}{\pi(a | s)} A^\pi(s, a) \right].$$

Note a diferença essencial em relação à seção anterior: aqui há **uma razão por passo**, não um produto sobre a trajetória. É isso que torna o estimador utilizável.

A troca não é gratuita, e a teoria diz exatamente quanto custa:

Limite de desempenho relativo (Achiam, Held, Tamar e Abbeel, 2017)

$$\left| (J(\pi') - J(\pi)) - \mathcal{L}_\pi(\pi') \right| \leq C \sqrt{\mathbb{E}_{s \sim d^\pi} [D_{\text{KL}}(\pi' \parallel \pi)[s]]}, \quad C = \frac{\gamma \max_s |\mathbb{E}_{a \sim \pi'} [A^\pi(s, a)]|}{(1 - \gamma)^2}.$$

Em palavras: o substituto é confiável na exata medida em que as duas políticas estão próximas em divergência KL. A aproximação não é ruim — ela é ruim *longe*, com erro controlado.

Intuição

Repare no fator $(1 - \gamma)^{-2}$ em C . Com $\gamma = 0,99$ ele vale 10^4 : a constante teórica é astronômica. Guarde isso; será o motivo pelo qual ninguém implementa o algoritmo teórico literalmente (Seção 4).

3 PPO: duas maneiras de ficar perto

O *Proximal Policy Optimization* (PPO) é uma família de métodos que impõe a restrição de KL *de modo aproximado*, sem calcular gradientes naturais e sem resolver o sistema linear do TRPO.

3.1 Variante 1 — penalidade KL adaptativa

Resolve-se um problema irrestrito,

$$\theta_{k+1} = \arg \max_{\theta} \mathcal{L}_{\theta_k}(\theta) - \beta_k \bar{D}_{\text{KL}}(\theta \parallel \theta_k),$$

e o coeficiente β_k é reajustado entre iterações: se a KL medida no lote ficou acima do alvo, aumenta-se β ; se ficou muito abaixo, diminui-se. É um controlador proporcional grosseiro sobre a restrição.



3.2 Variante 2 — objetivo recortado (a que se usa)**Definição — Objetivo recortado**

Seja $r_t(\theta) = \frac{\pi_\theta(a_t \mid s_t)}{\pi_{\theta_k}(a_t \mid s_t)}$ a razão de probabilidades *de um passo*. Então

$$\mathcal{L}_{\theta_k}^{\text{CLIP}}(\theta) = \mathbb{E}_{\tau \sim \pi_k} \left[\sum_{t=0}^T \min(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t) \right],$$

com ϵ hiperparâmetro (tipicamente 0,2), e $\theta_{k+1} = \arg \max_{\theta} \mathcal{L}_{\theta_k}^{\text{CLIP}}(\theta)$.

A expressão parece opaca até que se separe em dois casos. Como $\hat{A}_t$ é um número fixo dentro do lote, o min escolhe entre duas retas em r :



- ▶ Se $A_t > 0$ (a ação foi melhor que a média), queremos aumentar r . O objetivo cresce linearmente até $r = 1 + \epsilon$ e então satura: o gradiente zera, e não há mais incentivo em empurrar a probabilidade da ação para cima.
- ▶ Se $A_t < 0$, queremos diminuir r . O objetivo é *constante* para $r < 1 - \epsilon$ — já reduzimos o suficiente, pare — mas decresce sem limite do outro lado.

Atenção

Duas leituras que costumam escapar:

- ▶ O recorte remove o *incentivo* de ir mais longe; ele **não impede** que r fique grande. Se a primeira época de otimização já levou r a 3, o recorte não a traz de volta — por isso PPO limita o número de épocas por lote e, em implementações sérias, monitora a KL e interrompe cedo.
- ▶ Para $A < 0$ o objetivo é ilimitado inferiormente: uma ação ruim pode ser punida arbitrariamente. É uma assimetria real do método, não um detalhe.

Intuição

O min faz de $\mathcal{L}^{\text{CLIP}}$ um limitante *pessimista* (inferior) do substituto não recortado: nunca somos otimistas a respeito do ganho de nos afastarmos da política que gerou os dados. É a mesma filosofia dos limites inferiores em RL conservador.

3.3 O algoritmo, como se implementa

Algoritmo — PPO com objetivo recortado

- 1: Inicialize os parâmetros da política θ_0 e do crítico w_0 .
- 2: **para** $k = 0, 1, 2, \dots$ **faça**
- 3: Colete um lote $\mathcal{D}_k$ de trajetórias executando π_{θ_k} por T passos; guarde $\log \pi_{\theta_k}(a_t | s_t)$ para cada passo.
- 4: Calcule os retornos e as vantagens $\hat{A}_t$ por GAE truncado (Seção 4); normalize $\hat{A}$ no lote.
- 5: **para** época = $1, \dots, K$ (tipicamente $K \in [3, 10]$) **faça**
- 6: **para** cada minilote de $\mathcal{D}_k$ **faça**
- 7: $r_t(\theta) \leftarrow \exp(\log \pi_{\theta}(a_t | s_t) - \log \pi_{\theta_k}(a_t | s_t))$
- 8: Suba o gradiente de $\mathcal{L}^{\text{CLIP}} - c_1 (\hat{V}_w(s_t) - \hat{R}_t)^2 + c_2 H[\pi_{\theta}(\cdot | s_t)]$.
- 9: Interrompa as épocas cedo se $\hat{D}_{\text{KL}}(\theta || \theta_k)$ ultrapassar o alvo.

Três detalhes de implementação que separam um PPO que funciona de um que não funciona:

1. A razão é calculada por diferença de log-probabilidades, nunca por divisão de probabilidades — estabilidade numérica.
2. Normalizar $\hat{A}$ por lote (subtrair a média, dividir pelo desvio) é quase obrigatório; sem isso a

escala do gradiente varia entre lotes e o ϵ fixo perde sentido.

3. O **bônus de entropia** $c_2 H[\pi_\theta]$ evita o colapso prematuro para uma política quase determinística, que mataria a exploração.

Atenção

O ganho real de eficiência amostral está no laço interno (linha 5): várias atualizações de gradiente com o *mesmo* lote. E é exatamente daí que vem a necessidade do recorte — a partir da segunda época, os dados já são off-policy em relação à política que está sendo otimizada.

Para discutir em aula

O PPO tem quatro hiperparâmetros interagindo: ϵ , o número de épocas K , o tamanho do lote e a taxa de aprendizado. Aumentar K e diminuir ϵ tem efeito parecido sobre a KL final. São intercambiáveis? O que distingue um do outro?

4 GAE: um botão único para o compromisso viés-variância

Falta responder de onde vem o $\hat{A}_t$ que aparece dentro do objetivo do PPO.

4.1 Estimadores de n passos e o erro TD

Da Aula 5, os estimadores de vantagem com horizonte crescente:

$$\begin{aligned}\hat{A}_t^{(1)} &= r_t + \gamma V(s_{t+1}) - V(s_t), & \hat{A}_t^{(2)} &= r_t + \gamma r_{t+1} + \gamma^2 V(s_{t+2}) - V(s_t), & \dots \\ \hat{A}_t^{(\infty)} &= r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \dots - V(s_t) = G_t - V(s_t).\end{aligned}$$

Definindo o **erro TD**

$$\delta_t^V := r_t + \gamma V(s_{t+1}) - V(s_t),$$

todos eles se escrevem como somas telescópicas de erros TD:

$$\begin{aligned}\hat{A}_t^{(1)} &= \delta_t^V \\ \hat{A}_t^{(2)} &= \delta_t^V + \gamma \delta_{t+1}^V \\ \hat{A}_t^{(k)} &= \sum_{l=0}^{k-1} \gamma^l \delta_{t+l}^V = \sum_{l=0}^{k-1} \gamma^l r_{t+l} + \gamma^k V(s_{t+k}) - V(s_t).\end{aligned}$$

Demonstração

Verificação do caso $k = 2$, que já contém a ideia:

$$\begin{aligned}\delta_t^V + \gamma \delta_{t+1}^V &= [r_t + \gamma V(s_{t+1}) - V(s_t)] + \gamma [r_{t+1} + \gamma V(s_{t+2}) - V(s_{t+1})] \\ &= r_t + \gamma r_{t+1} + \gamma^2 V(s_{t+2}) - V(s_t) + \underbrace{\gamma V(s_{t+1}) - \gamma V(s_{t+1})}_{=0}.\end{aligned}$$

Os termos $\gamma^l V(s_{t+l})$ internos cancelam aos pares; sobram o *bootstrapping* na ponta ($+\gamma^k V(s_{t+k})$) e a linha de base no início ($-V(s_t)$). O caso geral segue por indução.

4.2 A derivação do GAE

Definição — Estimador generalizado de vantagem (Schulman et al., 2016)

Média exponencialmente ponderada dos estimadores de k passos, com peso $(1 - \lambda)\lambda^{k-1}$ para $\hat{A}^{(k)}$:

$$\hat{A}_t^{\text{GAE}(\gamma, \lambda)} = (1 - \lambda)(\hat{A}_t^{(1)} + \lambda \hat{A}_t^{(2)} + \lambda^2 \hat{A}_t^{(3)} + \dots).$$

A forma acima é inútil para implementar — exige todos os $\hat{A}^{(k)}$. A mágica é que ela colapsa. Escrevendo cada $\hat{A}^{(k)}$ como soma de erros TD e reagrupando por δ :

$$\begin{aligned} \hat{A}_t^{\text{GAE}} &= (1 - \lambda) \left(\delta_t^V + \lambda(\delta_t^V + \gamma \delta_{t+1}^V) + \lambda^2(\delta_t^V + \gamma \delta_{t+1}^V + \gamma^2 \delta_{t+2}^V) + \dots \right) \\ &= (1 - \lambda) \left(\delta_t^V (1 + \lambda + \lambda^2 + \dots) + \gamma \delta_{t+1}^V (\lambda + \lambda^2 + \dots) + \gamma^2 \delta_{t+2}^V (\lambda^2 + \lambda^3 + \dots) + \dots \right) \\ &= (1 - \lambda) \left(\delta_t^V \frac{1}{1 - \lambda} + \gamma \lambda \delta_{t+1}^V \frac{1}{1 - \lambda} + \gamma^2 \lambda^2 \delta_{t+2}^V \frac{1}{1 - \lambda} + \dots \right) \\ &= \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l}^V. \end{aligned}$$

Intuição

O passo crítico é a segunda linha: trocar a ordem dos somatórios. O coeficiente que multiplica $\gamma^l \delta_{t+l}^V$ é $\lambda^l + \lambda^{l+1} + \dots = \lambda^l / (1 - \lambda)$, e o fator $(1 - \lambda)$ da frente cancela exatamente esse denominador. Vale conferir o expoente com atenção: é $(\gamma \lambda)^l$, com *ambos* os fatores.

O resultado é notável: uma média infinita de estimadores de todos os horizontes tem a mesma forma — e o mesmo custo — de um único estimador de um passo, apenas com γ substituído por $\gamma \lambda$.

4.3 Os dois extremos

	$\lambda = 0$	$\lambda = 1$
Estimador	$\hat{A}_t = \delta_t^V$	$\hat{A}_t = \sum_{l \geq 0} \gamma^l \delta_{t+l}^V = G_t - V(s_t)$
Equivale a	vantagem de TD(0)	vantagem de Monte Carlo
Variância	mínima (uma recompensa aleatória)	máxima (todas as recompensas)
Viés	alto sempre que $V \neq V^\pi$	nenhum no gradiente resultante

Atenção

Cuidado com a formulação de “ $\lambda = 1$ é não-viesado”. Como *estimador pontual* da vantagem, $\mathbb{E}[\hat{A}_t] = Q^\pi(s_t, a_t) - V(s_t)$, que só é igual a $A^\pi(s_t, a_t)$ se $V = V^\pi$. O que é não-viesado, para *qualquer* V , é o **gradiente** resultante — porque a diferença $V^\pi(s_t) - V(s_t)$ é uma função só do estado, e funções só do estado são linhas de base, cuja contribuição ao gradiente tem esperança zero (Aula 5).

Na prática, escolhe-se $\lambda \in (0, 1)$; valores entre 0,9 e 0,97 são o padrão na literatura. O botão λ é conceitualmente o mesmo dos traços de elegibilidade de TD(λ), aplicado à vantagem em vez do retorno.

4.4 GAE truncado e a varredura reversa

A soma infinita é impraticável; corta-se no fim do lote de T passos:

$$\hat{A}_t = \sum_{l=0}^{T-t-1} (\gamma\lambda)^l \delta_{t+l}^V.$$

Algoritmo — Cálculo em uma varredura reversa, custo $\mathcal{O}(T)$

- 1: $\hat{A}_T \leftarrow 0$
- 2: **para** $t = T - 1$ **até** 0 **faça**
- 3: $\delta_t \leftarrow r_t + \gamma \hat{V}(s_{t+1}) (1 - \text{fim}_t) - \hat{V}(s_t)$
- 4: $\hat{A}_t \leftarrow \delta_t + \gamma\lambda (1 - \text{fim}_t) \hat{A}_{t+1}$
- 5: Alvo do crítico: $\hat{R}_t \leftarrow \hat{A}_t + \hat{V}(s_t)$

O benefício é operacional: basta rodar a política por T passos antes de atualizar, sem esperar o episódio terminar. O truncamento introduz um viés adicional (a cauda além de T é ignorada), pequeno quando $(\gamma\lambda)^T \ll 1$. O indicador fim_t zera o *bootstrapping* em estados terminais — omiti-lo é o erro de implementação mais comum nesta rotina, e produz um agente que “espera recompensa depois da morte”.

Para discutir em aula

Com $\gamma = 0,99$ e $\lambda = 0,95$, temos $\gamma\lambda \approx 0,94$ e a meia-vida do peso é de cerca de 11 passos. Como escolher T à luz disso? E o que acontece com o viés se o episódio típico durar 1000 passos e $T = 128$?

5 Por que isso funciona: melhoria monotônica

5.1 Do limite ao algoritmo

Retirando o módulo do limite da Seção 2, fica a desigualdade que interessa:

$$J(\pi') - J(\pi) \geq \mathcal{L}_\pi(\pi') - C \sqrt{\mathbb{E}_{s \sim d^\pi} [D_{\text{KL}}(\pi' \parallel \pi)[s]]}.$$

O lado direito é um **minorante** do ganho verdadeiro — e, ao contrário do lado esquerdo, é estimável com amostras de π apenas. Isso sugere um algoritmo: em vez de maximizar o que não se pode medir, maximize o minorante.

Proposição — garantia de melhoria

Se π_k e π_{k+1} estão relacionadas por

$$\pi_{k+1} = \arg \max_{\pi'} \mathcal{L}_{\pi_k}(\pi') - C \sqrt{\mathbb{E}_{s \sim d^{\pi_k}} [D_{\text{KL}}(\pi' \parallel \pi_k)[s]]},$$

então $J(\pi_{k+1}) \geq J(\pi_k)$.

Demonstração

A demonstração é curta e vale sabê-la de cor, porque o truque reaparece em vários lugares do RL moderno. Basta exibir um ponto viável cujo valor do objetivo seja zero.

1. π_k pertence ao domínio da otimização, logo é um ponto viável.

(continua)

2. No ponto $\pi' = \pi_k$, o substituto se anula:

$$\mathcal{L}_{\pi_k}(\pi_k) = \frac{1}{1-\gamma} \mathbb{E}_{s \sim d^{\pi_k}, a \sim \pi_k} [A^{\pi_k}(s, a)] = 0,$$

porque $\mathbb{E}_{a \sim \pi} [A^\pi(s, a)] = 0$ para todo s — a vantagem tem média zero sob a própria política que a define.

3. Também $D_{\text{KL}}(\pi_k \| \pi_k)[s] = 0$ para todo s , de modo que o termo de penalidade se anula.

4. Logo o objetivo avaliado em π_k vale exatamente 0; como π_{k+1} é o *máximo*, o valor ótimo é ≥ 0 .

5. Pelo limite de desempenho relativo, $J(\pi_{k+1}) - J(\pi_k) \geq 0$. ■

Duas observações sobre o alcance da demonstração. Primeira: ela não usa nada sobre a forma de π , então continua valendo se restringirmos a otimização a uma classe parametrizada Π_θ — basta que $\pi_k \in \Pi_\theta$. É por isso que o argumento sobrevive a redes neurais. Segunda: a melhoria garantida pode ser zero; o teorema diz que não pioramos, não que avançamos.

Intuição

O esquema tem nome: **maximização de minorante** (*majorize-minimize*). Constrói-se uma função que toca a verdadeira no ponto atual e fica sempre abaixo dela; maximiza-se essa função; repete-se. É o mesmo esqueleto do algoritmo EM e dos métodos de ponto proximal. Reconhecer o padrão é mais útil do que memorizar a fórmula.

5.2 Por que ninguém usa isso literalmente

A constante C contém $(1 - \gamma)^{-2}$. Com $\gamma = 0,99$, C é da ordem de $10^4 \cdot \max_s |\mathbb{E}_a[A^\pi]|$: a penalidade domina o substituto e o passo ótimo é minúsculo. O algoritmo teoricamente correto é praticamente inútil.

Abordagem	O que faz com a KL	O que se perde
Teoria (acima) TRPO	penalidade com C teórico <i>restrição</i> $\bar{D}_{\text{KL}} \leq \delta$ resolvida por gradiente natural	passos inúteis de tão pequenos custo por iteração (produto Hessiana-vetor, gradiente conjugado)
PPO	penalidade com β ajustado, ou recorte da razão	a garantia formal; sobra uma heurística que funciona

Atenção

Esta é uma lição metodológica que transcende o PPO: o valor do teorema não está na constante, está na *forma* do limite. Ele diz que a penalidade certa é uma função crescente da KL — e é essa forma que os métodos práticos preservam, trocando a constante por um hiperparâmetro calibrado empiricamente.

5.3 Balanço da primeira metade

Definição — O que fica de PPO e GAE

- ▶ **Eficiência amostral:** vários passos de gradiente por lote, em vez de um.
- ▶ **Estabilidade:** o recorte (ou a restrição de KL) aumenta a chance de melhoria monotônica, sem garanti-la.
- ▶ **Escopo:** converge para ótimos *locais*. Como todo gradiente de política.

(continua)

- **Relevância:** é o método padrão em controle contínuo e a base do ajuste por RLHF de modelos de linguagem.

6 Aprendizagem por imitação: quando não há recompensa

6.1 O problema

Em muitos domínios já *existem* políticas de decisão muito boas — executadas por pessoas — e o que se quer é automatizá-las. Há duas maneiras de aproveitar a pessoa:

	Humano fornece recompensa	Humano demonstra
Canal Vantagem	avalia decisões do agente supervisão simples e barata por episódio	executa a tarefa uma demonstração carrega muito mais informação que um número
Problema	complexidade amostral altíssima: milhões de episódios, cada um a ser avaliado	como generalizar para situações que o especialista nunca enfrentou?

Há ainda um terceiro caminho, que é o das recompensas projetadas à mão (*reward shaping*). Recompensas densas no tempo guiam o agente de perto e aceleram muito o aprendizado, mas escrevê-las é notoriamente frágil: o agente otimiza o que foi escrito, não o que se queria. Uma penalidade por tempo mal calibrada produz um robô que trava; um bônus por velocidade produz um robô que capota. Demonstrações são uma forma de especificar a recompensa *implicitamente*.

Definição — Formulação do problema

Dados: espaços $\mathcal{S}$ e $\mathcal{A}$; modelo de transição $P(s' | s, a)$; **nenhuma** função de recompensa; e um conjunto de demonstrações $(s_0, a_0, s_1, a_1, \dots)$ com ações extraídas da política do especialista π^* .

Três perguntas distintas, que dão origem a três famílias de métodos:

1. **Clonagem de comportamento:** dá para aprender π^* diretamente por aprendizado supervisionado?
2. **RL inverso:** dá para recuperar R ?
3. **Aprendizado por aprendizagem** (*apprenticeship learning*): dá para usar o R recuperado para obter uma boa política?

Intuição

A escolha entre recompensa e demonstração é, no fundo, sobre *qual canal de comunicação é mais fácil para o humano*. Especificar uma recompensa que produza direção defensiva é difícil; dirigir defensivamente por vinte minutos é fácil.

6.2 Clonagem de comportamento

A redução é direta: trate o problema como aprendizado supervisionado. Fixe uma classe de políticas (rede neural, árvore de decisão) e ajuste π_θ aos pares $(s_0, a_0), (s_1, a_1), \dots$ minimizando uma perda de classificação (ações discretas) ou de regressão (ações contínuas).

Dois sucessos históricos merecem menção: ALVINN (Pomerleau, 1989), que dirigia um veículo a partir de imagens de uma câmera com uma rede rasa, e o piloto de simulador de voo de Sammut et al. (1992). Em versões modernas — redes recorrentes ou *transformers* sobre janelas de observação, como no BC-RNN de Mandelkar et al. (2021) — a clonagem é extensivamente usada em manipulação robótica e funciona muito bem quando os dados cobrem bem o espaço de estados visitado.

Atenção

Note o que a clonagem **não** exige: nenhum modelo de transição, nenhuma interação com o ambiente, nenhuma recompensa. É o método mais barato do curso inteiro. Todo o resto desta seção existe porque esse barateamento tem um preço.

6.3 O preço: erros compostos

O aprendizado supervisionado supõe pares (s, a) i.i.d. e ignora a estrutura temporal. Se os erros fossem independentes no tempo, com probabilidade de erro $\leq \varepsilon$ por passo, teríamos

$$\mathbb{E}[\text{número de erros}] \leq \varepsilon T.$$

Mas erros em um MDP não são independentes: um erro leva o agente a um estado que o especialista nunca visitou, sobre o qual a política não tem informação, o que torna o próximo erro mais provável, e assim por diante.

Intuição do resultado de Ross e Bagnell

Se o agente erra pela primeira vez em t , todos os $T - t$ passos seguintes podem estar fora da distribuição de treino. Somando sobre o instante do primeiro erro:

$$\mathbb{E}[\text{número de erros}] \lesssim \varepsilon (T + (T - 1) + \dots + 1) \propto \varepsilon T^2.$$

O enunciado formal é o Teorema 2.1 de Ross e Bagnell (AISTATS 2010); o argumento acima é uma aproximação da ideia, não a demonstração.

A diferença entre εT e εT^2 é o que se chama de **descasamento de distribuições**:

Definição — A hipótese que quebra

No aprendizado supervisionado, $(x, y) \sim \mathcal{D}$ tanto no treino quanto no teste. Em um MDP,

$$\text{treino: } s_t \sim \mathcal{D}_{\pi^*}, \quad \text{teste: } s_t \sim \mathcal{D}_{\pi_\theta},$$

e $\mathcal{D}_{\pi_\theta}$ *depende da política que estamos aprendendo*: a distribuição de teste é um resultado do treinamento, não um dado do problema.

Intuição

É a patologia do RL *off-policy* vista de outro ângulo: os dados vêm de uma política e a avaliação acontece sob outra. Lá a resposta foi reponderar (amostragem por importância); aqui a resposta será *consertar os dados*.

6.4 DAgger: agregação de conjuntos de dados

Algoritmo — DAgger (Ross, Gordon e Bagnell, 2011)

- 1: $\mathcal{D} \leftarrow$ demonstrações iniciais do especialista; treine π_1 em $\mathcal{D}$.
- 2: **para** $i = 1, \dots, N$ **faça**
- 3: Execute π_i no ambiente e colete os estados visitados $\{s_1, \dots, s_m\}$.
- 4: **Consulte o especialista** sobre cada um desses estados, obtendo $\{(s_j, \pi^*(s_j))\}$.
- 5: $\mathcal{D} \leftarrow \mathcal{D} \cup \{(s_j, \pi^*(s_j))\}$ (agregação, nunca descarte)
- 6: Treine π_{i+1} no $\mathcal{D}$ acumulado.

A ideia em uma frase: *obter rótulos do especialista ao longo do caminho que a política aprendida realmente percorre*. O conjunto de treino passa a cobrir a distribuição de estados induzida pela própria política, que é a distribuição de teste — e o descasamento desaparece. Sob as hipóteses do artigo, DAgger produz uma política determinística estacionária com bom desempenho sob a distribuição que ela mesma induz, com erro voltando a escalar como εT .

Atenção

A limitação, que é séria. O especialista precisa estar disponível *durante* o treinamento, para rotular estados que ele não escolheu visitar — e frequentemente estados ruins, em que ele nunca estaria. Duas dificuldades:

- ▶ O custo humano é recorrente, não um lote único de demonstrações.
- ▶ Rotular fora de contexto é difícil e ruidoso: “o que você faria neste estado?” é uma pergunta muito mais difícil do que “dirija bem por vinte minutos”. Em domínios com dinâmica rápida, a resposta pode nem ser bem definida.

Para discutir em aula

Por que não basta simplesmente coletar mais demonstrações do especialista? Em que situação isso realmente resolveria o problema de erros compostos, e por que essa situação raramente ocorre na prática?

7 RL inverso: inferir a intenção

7.1 Recompensa linear em atributos

Suponha que a recompensa seja linear sobre um vetor de atributos do estado:

$$R(s) = w^\top x(s), \quad w \in \mathbb{R}^n, \quad x : \mathcal{S} \rightarrow \mathbb{R}^n.$$

O valor de uma política herda a linearidade:

$$\begin{aligned} V^\pi(s_0) &= \mathbb{E}_\pi \left[\sum_{t \geq 0} \gamma^t R(s_t) \mid s_0 \right] = \mathbb{E}_\pi \left[\sum_{t \geq 0} \gamma^t w^\top x(s_t) \mid s_0 \right] \\ &= w^\top \underbrace{\mathbb{E}_\pi \left[\sum_{t \geq 0} \gamma^t x(s_t) \mid s_0 \right]}_{\mu(\pi)} = w^\top \mu(\pi). \end{aligned}$$

Definição — Expectativas de atributos $\mu(\pi)$

(continua)

$\mu(\pi)$ é a frequência descontada esperada com que cada atributo é encontrado ao seguir π a partir de s_0 . É o objeto que substitui a trajetória: duas políticas com o mesmo μ têm o mesmo valor sob *qualquer* recompensa linear nesses atributos.

Se as demonstrações vêm de uma política ótima π^* para a recompensa verdadeira $R^* = w^{*\top}x$, então por definição de otimalidade $V^* \geq V^\pi$ para toda π , ou seja

$$w^{*\top} \mu(\pi^*) \geq w^{*\top} \mu(\pi) \quad \forall \pi.$$

Identificar w^* é, portanto, encontrar um vetor de pesos sob o qual o especialista bata todo mundo.

7.2 Ambiguidade: o problema estrutural do RL inverso

Atenção

Não existe um R único. Existe uma **infinitude** deles.

- ▶ $w = 0$ satisfaz a desigualdade acima com igualdade para toda política: se nada importa, o especialista é (vacuamente) ótimo.
- ▶ Escalar w por qualquer constante positiva preserva a ordenação das políticas.
- ▶ Somar a R um *potencial* $\gamma\Phi(s') - \Phi(s)$ não altera a política ótima (*reward shaping* de Ng, Harada e Russell, 1999).
- ▶ E, mais geralmente, há uma vizinhança inteira de recompensas para as quais a mesma política continua ótima.

Além disso, existem infinitas políticas *estocásticas* que reproduzem as mesmas expectativas de atributos. O problema é duplamente subdeterminado, e todo método de RL inverso é, essencialmente, uma escolha de critério de desempate.

7.3 Casamento de expectativas de atributos

Uma saída elegante: em vez de recuperar w , buscar diretamente uma política que *se comporte* como o especialista.

Casamento de atributos (Abbeel e Ng, 2004)

Se $\|\mu(\pi) - \mu(\pi^*)\|_1 \leq \epsilon$, então para todo w com $\|w\|_\infty \leq 1$ vale, pela desigualdade de Hölder,

$$|w^\top \mu(\pi) - w^\top \mu(\pi^*)| \leq \epsilon.$$

Demonstração

Hölder com o par conjugado $(1, \infty)$: para vetores u, v , $|u^\top v| \leq \|u\|_1 \|v\|_\infty$. Aplicando a $u = \mu(\pi) - \mu(\pi^*)$ e $v = w$,

$$|w^\top (\mu(\pi) - \mu(\pi^*))| \leq \|\mu(\pi) - \mu(\pi^*)\|_1 \|w\|_\infty \leq \epsilon \cdot 1.$$

Como $V^\pi = w^\top \mu(\pi)$, a desigualdade é exatamente uma cota sobre a diferença de valores.

Intuição

A garantia é forte de um jeito incomum: se as expectativas de atributos casam, a política é quase tão boa quanto a do especialista **para qualquer recompensa linear nesses atributos** — inclusive a verdadeira, que continuamos sem conhecer. Contornamos a ambiguidade em vez de resolvê-la.

Atenção

O peso da hipótese migrou de R para x . Se um atributo que importa ao especialista não estiver em x , nenhuma garantia o alcança — a política pode casar todos os atributos observados e ainda assim se comportar de modo inaceitável na dimensão esquecida. Escolher x é o trabalho difícil e raramente é discutido.

8 RL inverso de máxima entropia

8.1 Que distribuição escolher?

Considere todas as trajetórias de H passos em um MDP determinístico. Para uma recompensa linear, uma política fica completamente especificada por sua distribuição sobre trajetórias. Muitas distribuições reproduzem as expectativas de atributos observadas — qual escolher?

Definição — Princípio da máxima entropia (Jaynes, 1957; Ziebart et al., 2008)

Escolha a distribuição *sem nenhuma preferência adicional* além de casar as expectativas de atributos dos dados:

$$\max_P - \sum_{\tau} P(\tau) \log P(\tau) \quad \text{sujeito a} \quad \sum_{\tau} P(\tau) \mu_{\tau} = \tilde{\mu}, \quad \sum_{\tau} P(\tau) = 1,$$

onde $\mu_{\tau} = \sum_{s_i \in \tau} x(s_i)$ são as contagens de atributos de uma trajetória e $\tilde{\mu} = \frac{1}{m} \sum_{j=1}^m \mu_{\tau_j}$ é a média observada nas m demonstrações.

Atenção

Atenção à mudança de definição: aqui μ_{τ} é a soma de atributos ao longo de *uma* trajetória, e não a expectativa descontada $\mu(\pi)$ da seção anterior. Os dois objetos usam a mesma letra na literatura e são frequentemente confundidos.

8.2 A forma exponencial e a verossimilhança

A solução do problema de máxima entropia com restrições lineares é da família exponencial:

$$P(\tau_j | w) = \frac{1}{Z(w)} \exp(w^{\top} \mu_{\tau_j}) = \frac{1}{Z(w)} \exp\left(\sum_{s_i \in \tau_j} w^{\top} x(s_i)\right), \quad Z(w) = \sum_{\tau} \exp(w^{\top} \mu_{\tau}).$$

A leitura é imediata, e é dela que vem o apelo do método: **caminhos de alto retorno são exponencialmente mais prováveis, e caminhos de retorno igual são igualmente prováveis**. O modelo não supõe alguém perfeito — supõe alguém que erra, e que erra menos quando o erro custa mais.

Em MDPs estocásticos a distribuição sobre caminhos depende também da dinâmica:

$$P(\tau_j | w, P) \approx \frac{\exp(w^{\top} \mu_{\tau_j})}{Z(w, P)} \prod_{s_i, a_i \in \tau_j} P(s_{i+1} | s_i, a_i).$$

8.3 Ajustar w : o gradiente é uma diferença de frequências

Escolhe-se w por máxima verossimilhança das demonstrações:

$$w^* = \arg \max_w L(w) = \arg \max_w \sum_{\text{exemplos}} \log P(\tau | w).$$

Gradiente da log-verossimilhança

$$\nabla L(w) = \tilde{\mu} - \sum_{\tau} P(\tau | w) \mu_{\tau} = \tilde{\mu} - \sum_{s_i} D(s_i) x(s_i),$$

onde $D(s_i)$ é a **frequência esperada de visita** do estado s_i sob a política induzida pelos pesos atuais.

Intuição

O gradiente é a diferença entre *o que o especialista fez* e *o que o modelo atual faria*. Se o modelo visita um estado mais do que o especialista, o peso dos atributos daquele estado desce. É a mesma estrutura do gradiente de modelos de máxima entropia em geral: dado observado menos expectativa do modelo.

O laço de otimização fica:

Algoritmo — MaxEnt IRL (Ziebart et al., 2008)

- 1: Calcule $\tilde{\mu}$ a partir das demonstrações.
- 2: Inicialize w .
- 3: **repita**
- 4: Resolva o MDP com $R_w(s) = w^{\top} x(s)$ (programação dinâmica *soft*) para obter a política de máxima entropia.
- 5: Propague para a frente as frequências de visita $D(s)$ dessa política.
- 6: $w \leftarrow w + \alpha(\tilde{\mu} - \sum_s D(s)x(s))$.
- 7: **até** convergir

Atenção

A linha 4 é o custo do método: **cada iteração resolve um MDP inteiro**. E a linha 5 precisa do modelo de transição — ou, na falta dele, da capacidade de interagir com o ambiente para amostrá-lo. Compare com a clonagem de comportamento, que não precisa de nenhum dos dois. Essa é a troca central desta segunda metade da aula.

8.4 De recompensas aprendidas a políticas

O RL inverso entrega uma função de recompensa; o que normalmente se quer é uma *política* cujo desempenho iguale ou supere o do especialista. Duas rotas:

1. **Em dois estágios:** aprenda R por RL inverso e depois rode RL comum com essa recompensa. Simples, mas paga duas vezes o custo computacional e propaga os erros do primeiro estágio.
2. **Diretamente:** aprenda a política sem materializar a recompensa. É o que faz o GAIL (Ho e Ermon, 2016), com uma formulação adversarial em que um discriminador tenta separar trajetórias do especialista das do agente, e o agente é treinado por gradiente de política para enganá-lo — fechando o círculo com a primeira metade desta aula.

Intuição

Por que a recompensa é um objeto melhor que a política para transferir conhecimento? Porque ela é frequentemente mais *compacta* e mais *portável*: a intenção “chegue rápido sem bater” sobrevive à troca do carro, do mapa e da dinâmica; a política de direção, não. É também a razão pela qual o RL inverso pode, em princípio, superar o especialista — se

(continua)

o especialista tinha boas intenções e execução ruim, otimizar a intenção supera imitar a execução.

Para discutir em aula

A clonagem de comportamento, por construção, tem o especialista como teto. O RL inverso, não. O que exatamente permite ultrapassar quem nos ensinou — e que hipótese precisa ser verdadeira para que isso aconteça de fato?

9 Síntese e formulário**9.1 As cinco linhas que resumem a primeira metade**

Identidade exata	$J(\pi') - J(\pi) = \frac{1}{1-\gamma} \mathbb{E}_{s \sim d^{\pi'}, a \sim \pi'} [A^\pi(s, a)]$
Substituto (estimável)	$\mathcal{L}_\pi(\pi') = \frac{1}{1-\gamma} \mathbb{E}_{s \sim d^\pi, a \sim \pi} \left[\frac{\pi'(a s)}{\pi(a s)} A^\pi(s, a) \right]$
Preço da troca	$ (J(\pi') - J(\pi)) - \mathcal{L}_\pi(\pi') \leq C \sqrt{\mathbb{E}_{s \sim d^\pi} [D_{\text{KL}}(\pi' \parallel \pi)]}$
PPO recortado	$\mathcal{L}^{\text{CLIP}} = \mathbb{E}[\sum_t \min(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t)]$
Vantagem (GAE)	$\hat{A}_t = \sum_{l \geq 0} (\gamma \lambda)^l \delta_{t+l}^V, \quad \delta_t^V = r_t + \gamma V(s_{t+1}) - V(s_t)$

9.2 Mapa dos métodos de imitação

Método	O que aprende	Precisa de P ?	Especialista no laço?	Limitação central
Clonagem	política, por supervisão	não	não	erros compostos (ϵT^2)
Dagger	política, iterativamente	não	sim	custo humano recorrente
Casamento de atributos	política que casa μ	sim	não	depende inteiramente de x
MaxEnt IRL	recompensa w	sim	não	resolve um MDP por iteração
GAIL	política, de modo adversarial	não (usa simulador)	não	instabilidade do treino adversarial

9.3 O que você deve saber fazer**Definição — Capacidades esperadas**

- Explicar por que os pesos de importância sobre trajetórias explodem, e por que a razão de *um passo* do substituto não sofre do mesmo mal.
- Enunciar a identidade de Kakade–Langford e dizer qual termo é inestimável e por quê.
- Ler o objetivo recortado nos dois casos ($A > 0$ e $A < 0$) e explicar por que ele não impede que r fique grande.
- **Derivar** a forma fechada do GAE a partir da média exponencialmente ponderada, indicando onde a soma geométrica é usada.
- Situar $\lambda = 0$ e $\lambda = 1$ no compromisso viés–variância, com a ressalva correta sobre o que é não-viesado.

(continua)

- ▶ Reproduzir a demonstração de melhoria monotônica e apontar exatamente onde $\mathbb{E}_{a \sim \pi}[A^\pi] = 0$ é usada.
- ▶ Definir clonagem de comportamento e explicar em que ela difere de RL.
- ▶ Explicar o argumento εT contra εT^2 e o que DAgger muda.
- ▶ Argumentar por que o RL inverso é subdeterminado, e como o casamento de atributos e a máxima entropia lidam com isso de maneiras diferentes.

10 Exercícios**Exercício 1 — O produto que explode**

Suponha $\pi_\theta(a_t | s_t) / \pi_{\theta'}(a_t | s_t) \in [1 - \eta, 1 + \eta]$ para todo t , com $\eta = 0,02$.

1. Escreva o intervalo em que vive o peso de importância de uma trajetória de $t + 1 = 100$ passos.
2. Calcule numericamente os extremos. Compare com $\eta = 0,05$ e $t + 1 = 500$.
3. Explique por que o viés do estimador continua zero enquanto isso.

Resposta parcial. O intervalo é $[(1-\eta)^{100}, (1+\eta)^{100}] \approx [0,133; 7,24]$: uma variação de $\pm 2\%$ por passo vira um fator 54 entre os extremos. Com $\eta = 0,05$ e 500 passos, $[(0,95)^{500}, (1,05)^{500}] \approx [7,3 \cdot 10^{-12}; 3,9 \cdot 10^{10}]$ — quase vinte e duas ordens de grandeza.

Exercício 2 — Os dois ramos do recorte

Escreva $\mathcal{L}^{\text{CLIP}}$ como função explícita de r em cada caso, sem o min:

1. Mostre que, para $A > 0$, $\mathcal{L}^{\text{CLIP}}(r) = A \cdot \min(r, 1 + \epsilon)$.
2. Mostre que, para $A < 0$, $\mathcal{L}^{\text{CLIP}}(r) = A \cdot \max(r, 1 - \epsilon)$.
3. Conclua que em ambos os casos $\mathcal{L}^{\text{CLIP}}(r) \leq rA$, isto é, o objetivo recortado é um limitante inferior do substituto.

Exercício 3 — GAE em um episódio curto

Um episódio de três passos, com $\gamma = 0,9$:

t	0	1	2
r_t	0	0	10
$\hat{V}(s_t)$	4	6	8

$\hat{V}(s_3) = 0$ (estado terminal).

1. Calcule $\delta_0^V, \delta_1^V, \delta_2^V$.
2. Calcule $\hat{A}_0$ para $\lambda = 0$, $\lambda = 0,5$ e $\lambda = 1$.
3. Verifique que, com $\lambda = 1$, $\hat{A}_0 = G_0 - \hat{V}(s_0)$.

Resposta. $\delta_2^V = 10 + 0,9 \cdot 0 - 8 = 2$; $\delta_1^V = 0 + 0,9 \cdot 8 - 6 = 1,2$; $\delta_0^V = 0 + 0,9 \cdot 6 - 4 = 1,4$. Para $\lambda = 0$: $\hat{A}_0 = 1,4$. Para $\lambda = 0,5$: $\hat{A}_0 = 1,4 + 0,45 \cdot 1,2 + 0,45^2 \cdot 2 = 2,345$. Para $\lambda = 1$: $\hat{A}_0 = 1,4 + 0,9 \cdot 1,2 + 0,81 \cdot 2 = 4,1$, e de fato $G_0 = 0,9^2 \cdot 10 = 8,1$, com $8,1 - 4 = 4,1$.

Exercício 4 — Onde a demonstração usa a hipótese

Na demonstração de melhoria monotônica, o passo 2 afirma $\mathbb{E}_{a \sim \pi}[A^\pi(s, a)] = 0$.

1. Demonstre essa identidade a partir de $A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s)$.
2. Onde exatamente a demonstração quebraria se a vantagem fosse medida sob uma polí-

(continua)

tica diferente daquela que gera as ações?

3. A garantia sobrevive se restringirmos π' a uma classe parametrizada Π_θ ? Justifique.

Exercício 5 — εT contra εT^2

Considere um agente clonado com erro por passo $\varepsilon = 0,01$ e horizonte $T = 200$.

1. Sob a hipótese i.i.d. ingênua, qual o número esperado de erros?
2. Sob a estimativa εT^2 , qual é?
3. Interprete: o que significa um número esperado de erros maior que T ?

Comentário. A resposta do item 3 é a chave: o limite εT^2 passa a ser vacuamente satisfeito quando ultrapassa T , o que revela o regime em que a clonagem simplesmente não oferece garantia alguma.

Exercício 6 — A ambiguidade, concretamente

Considere um MDP com dois estados $\{s_1, s_2\}$, duas ações e recompensa linear $R(s) = w^\top x(s)$ com $x(s_1) = (1, 0)^\top$ e $x(s_2) = (0, 1)^\top$.

1. Exiba dois vetores w distintos e não proporcionais para os quais a mesma política determinística é ótima.
2. Mostre que $w = 0$ torna *qualquer* política ótima.
3. Que restrição adicional o casamento de atributos impõe para eliminar a degenerescência do item 2?

Exercício 7 — Implementação

Implemente PPO com GAE em um ambiente clássico de controle contínuo.

1. Registre, ao longo do treino, a KL empírica entre π_θ e π_{θ_k} ao fim de cada época interna. Ela cresce com K ? Como?
2. Varie $\epsilon \in \{0,05; 0,2; 0,5\}$ mantendo o resto fixo e compare as curvas de aprendizado e a fração de amostras recortadas.
3. Varie $\lambda \in \{0; 0,95; 1\}$ e meça a variância empírica de $\hat{A}$ por lote. O comportamento bate com a tabela da Seção 4?
4. Remova o fator $(1 - \text{fim}_t)$ da varredura reversa e descreva o que acontece.

Exercício 8 — Clonagem e DAgger no mesmo ambiente

Treine um especialista por RL até um bom desempenho e use-o como oráculo.

1. Faça clonagem de comportamento com N demonstrações, para vários N , e trace o desempenho contra N .
2. Implemente DAgger com o mesmo orçamento *total* de rótulos e compare.
3. Meça, em cada caso, a distância entre a distribuição de estados de treino e a de teste (por exemplo, com um classificador que tente distingui-las). A distância cai com DAgger?

Leituras

- ▶ **Sutton e Barto (2018)**, cap. 13 — gradientes de política; seção 12.1 para a intuição de λ nos traços de elegibilidade.
- ▶ **Schulman, Moritz, Levine, Jordan e Abbeel (2016)**, *High-Dimensional Continuous Control Using Generalized Advantage Estimation*, ICLR — o artigo do GAE; curto e vale cada página.
- ▶ **Schulman, Wolski, Dhariwal, Radford e Klimov (2017)**, *Proximal Policy Optimization Algorithms* — o artigo do PPO.
- ▶ **Achiam, Held, Tamar e Abbeel (2017)**, *Constrained Policy Optimization*, ICML — os limites de desempenho relativo usados aqui.
- ▶ **Ross, Gordon e Bagnell (2011)**, *A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning*, AISTATS — DAgger e a análise de erros compostos.
- ▶ **Abbeel e Ng (2004)**, *Apprenticeship Learning via Inverse Reinforcement Learning*, ICML — casamento de expectativas de atributos.
- ▶ **Ziebart, Maas, Bagnell e Dey (2008)**, *Maximum Entropy Inverse Reinforcement Learning*, AAAI.
- ▶ **Ho e Ermon (2016)**, *Generative Adversarial Imitation Learning*, NeurIPS.
- ▶ **Sun, Venkatraman, Gordon, Boots e Bagnell (2017)**, ICML — a teoria na fronteira entre imitação e RL.

Intuição

Próxima aula. Aprender recompensas quando não há demonstrações completas, mas apenas *preferências* entre pares de resultados ($y_1 \succ y_2$) — o cenário dos *dueling bandits* e o que sustenta o ajuste por feedback humano. E, na sequência, a exploração como problema de primeira classe.