

Universidade Federal de Uberlândia

Aula 8: Aprendizagem por imitação, aprendizado de recompensa e RLHF

Erros compostos • DAGGER • RL inverso • Bradley-Terry • RLHF • DPO

Prof. Marcelo Keese Albertini
Universidade Federal de Uberlândia
adaptado de Emma Brunskill, CS234 (Stanford)
2026



Onde estamos

Da recompensa dada à recompensa aprendida

- ▶ **Aulas 2–3:** com modelo, calcular V^* e π^* por programação dinâmica. **Aula 4:** sem modelo, aprender $\hat{Q}$ de amostras.
- ▶ **Aulas 5–6:** parametrizar a política e subir o gradiente do retorno — REINFORCE, ator-crítico, TRPO, PPO.
- ▶ **Aula 7:** sem recompensa escrita? Primeira resposta: *copie um especialista*.
- ▶ **Hoje:** por que copiar não basta; *inferir* a recompensa; *preferências humanas* — o caminho até o RLHF e o DPO.

Intuição

A partir de hoje R vira *objeto de aprendizado* — quase todos os problemas novos nascem daí.

Recapitulação da aula passada

Teste sua compreensão

Quais afirmações sobre o **REINFORCE** são verdadeiras?

- (a) Uma linha de base reduz a variância das atualizações.
- (b) O método converge para um ótimo *global*.
- (c) Pode partir de uma política determinística subótima e ainda convergir a um ótimo local.
- (d) Um passo de gradiente pode *piorar* a política.

Pergunta para discussão conduzida em aula.

Recapitulação da aula passada

Teste sua compreensão

Quais afirmações sobre o **REINFORCE** são verdadeiras?

- (a) Uma linha de base reduz a variância das atualizações.
- (b) O método converge para um ótimo *global*.
- (c) Pode partir de uma política determinística subótima e ainda convergir a um ótimo local.
- (d) Um passo de gradiente pode *piorar* a política.

Pergunta para discussão conduzida em aula.

Resposta

(a) e (d). (b): o objetivo é não convexo em θ . (c): uma política determinística nunca amostra as demais ações $\rightarrow$ sem gradiente $\rightarrow$ presa onde começou.

1. Imitação e erros compostos

por que clonar degrada como T^2 ; o que o DAGGER faz

2. Aprendizado de recompensa

RL inverso, não unicidade de R , máxima entropia

3. Humanos no laço

espectro de esforço humano; comparações baratas

4. Modelo de Bradley-Terry

de preferências ruidosas a uma recompensa escalar

5. RLHF

o *pipeline* de três etapas e a penalidade KL

6. DPO


eliminar o modelo de recompensa por álgebra

Intuição

Fio condutor: “de onde vem o sinal de recompensa quando não há placar?”

Por que isto virou o assunto central

RL como etapa final de treinamento de modelos de linguagem



- ▶ Duas primeiras etapas: supervisionadas. Terceira: RL — e é a que exige que exista uma *recompensa*.
- ▶ Ninguém sabe escrever “responda de forma útil e honesta” como uma $R(s, a)$; todos sabem dizer *qual de duas respostas é melhor*.

SEÇÃO 1

Imitação e erros compostos

01

O problema de aprendizagem por imitação

Definição — Aprendizagem por imitação

Dados: espaços $\mathcal{S}$ e $\mathcal{A}$, possivelmente um modelo de transição $P(s' \mid s, a)$, e um conjunto de demonstrações

$$\mathcal{D} = \{(s_0, a_0, s_1, a_1, \dots)\}, \quad a_t \sim \pi^E(\cdot \mid s_t),$$

geradas por um **especialista** π^E . *Não há função de recompensa*. Objetivo: obter uma política tão boa quanto π^E .

- ▶ **Clonagem de comportamento** (Aula 7): classificação — aprenda $\pi(a \mid s)$ por perda supervisionada sobre os pares (s, a) .
- ▶ Simples, rápido, sem interação com o ambiente — resultados históricos (ALVINN, 1989) e atuais (o “SFT” dos LLMs).

O que a clonagem de comportamento supõe — e o que ela ignora

Definição — A hipótese emprestada

Aprendizado supervisionado supõe pares (x, y) **i.i.d.**, extraídos da *mesma* distribuição no treino e no teste.

No MDP, falso duas vezes: estados de uma trajetória **dependentes** no tempo; a distribuição deles depende da **política** que os gera.

Intuição

O problema estrutural da imitação: as ações do aluno mudam as perguntas da prova. (Ross & Bagnell, 2011.)


Atenção

Deslocamento de distribuição. Treino: $s_t \sim d^{\pi^E}$; teste: $s_t \sim d^{\pi}$. O classificador é bom *onde o especialista esteve* — e um erro basta para sair dessa região.

Erros independentes no tempo: o caso benigno

Suponha que, a cada passo, a política clonada erre com probabilidade ε , e que *um erro não afete os estados seguintes*:

$$\mathbb{E}[\text{total de erros}] \leq \varepsilon T.$$



Intuição

Agente “volta ao trilho” sozinho após cada erro: custo **linear** no horizonte — a intuição do supervisionado.


Pergunta da aula: *o que muda quando um erro desloca a trajetória?*

Erros compostos: o custo real

Um erro em t leva o agente a um estado que o especialista nunca visitou. Sem garantia — pessimismo: *todos* os $T - t$ passos restantes comprometidos:

$$\begin{aligned}\mathbb{E}[\text{erros}] &\lesssim \varepsilon(T + (T - 1) + \dots + 1) \\ &= \varepsilon \frac{T(T + 1)}{2} \propto \varepsilon T^2\end{aligned}$$


Argumento heurístico; o resultado formal é o Teorema 2.1 de Ross & Bagnell (AISTATS 2010).



Atenção

Com $\varepsilon = 1\%$ e $T = 1000$: 10 vs. $\sim 10^4$ erros. A política “com 99% de acerto” é inutilizável.

A geometria do problema



Intuição

O erro não é “ruído em torno da resposta certa”: é **desvio que se realimenta** — longe do suporte dos dados, pior a política; pior a política, mais longe ela vai.

Teste sua compreensão

Teste sua compreensão

Uma equipe treina um piloto automático por clonagem de comportamento e o carro sai da pista após alguns minutos. A proposta é *coletar dez vezes mais demonstrações do motorista*. Isso resolve o problema? Em que sentido ajuda e em que sentido não? Que dado atacaria a causa em vez do sintoma? *Pergunta para discussão conduzida em aula.*

Teste sua compreensão


Teste sua compreensão

Uma equipe treina um piloto automático por clonagem de comportamento e o carro sai da pista após alguns minutos. A proposta é *coletar dez vezes mais demonstrações do motorista*. Isso resolve o problema? Em que sentido ajuda e em que sentido não? Que dado atacaria a causa em vez do sintoma? *Pergunta para discussão conduzida em aula.*

Resposta

Reduz ε , mas **não muda o expoente**. Mais dados do motorista são mais dados da região *onde ele dirige bem* — e o problema está fora dela. Ataca a causa obter rótulos **nos estados que a política aprendida visita**.

DAGGER: agregação de conjuntos de dados



- ▶ Ideia: *rótulos do especialista ao longo do caminho que a política aprendida percorre.*
- ▶ Política determinística com bom desempenho **sob a distribuição de estados que ela mesma induz.**
- ▶ Redução a aprendizado *online* sem arrependimento — o custo volta a ser $O(\epsilon T)$.

DAGGER: o algoritmo

Algoritmo — DAGGER (Ross et al., 2011)

- ▶ Inicialize $\mathcal{D} \leftarrow \emptyset$ e π_1 (por exemplo, o próprio π^E ou uma clonagem inicial)
- ▶ **para** $i = 1, 2, \dots, N$ **faça**
 - Defina $\hat{\pi}_i = \beta_i \pi^E + (1 - \beta_i) \pi_i$ (mistura; $\beta_i \rightarrow 0$)
 - Execute $\hat{\pi}_i$ e colete as trajetórias de estados visitados
 - Consulte o especialista em cada estado visitado: $\mathcal{D}_i = \{(s, \pi^E(s))\}$
 - Agregue: $\mathcal{D} \leftarrow \mathcal{D} \cup \mathcal{D}_i$
 - Treine π_{i+1} minimizando a perda de classificação sobre *todo* o $\mathcal{D}$
- ▶ **fim para:** devolva a melhor π_i segundo validação

Intuição

A mistura β_i evita tempo demais em estados catastróficos no início, quando π_i ainda é ruim — o instrutor que segura o volante.

DAGGER: a limitação decisiva

Teste sua compreensão

O DAGGER converte um erro $O(\epsilon T^2)$ em $O(\epsilon T)$. Qual é o preço — e por que ele inviabiliza o método em boa parte das aplicações modernas? *Pergunta para discussão conduzida em aula.*

DAGGER: a limitação decisiva

Teste sua compreensão

O DAGGER converte um erro $O(\epsilon T^2)$ em $O(\epsilon T)$. Qual é o preço — e por que ele inviabiliza o método em boa parte das aplicações modernas? *Pergunta para discussão conduzida em aula.*

Resposta

Ele exige um **especialista disponível durante todo o treinamento**, capaz de rotular estados arbitrários sob demanda.

- ▶ **Custo:** a supervisão escala com estados visitados, não com demonstrações.
- ▶ **Contexto:** “o que você faria *agora*?” num quadro congelado produz rótulos ruins.
- ▶ **Segurança:** para rotular um estado é preciso chegar até ele — e alguns não devem ser visitados.

Balanço da imitação

	Clonagem	DAGGER	RL inverso
Erro no horizonte	$O(\varepsilon T^2)$	$O(\varepsilon T)$	depende do planejador
Interage com o ambiente	não	sim	sim
Precisa do especialista <i>durante</i> o treino	não	sim	não
O que produz	uma política	uma política	uma recompensa
Generaliza para novas dinâmicas	não	não	sim

Intuição

Última linha: a *recompensa* é a descrição mais **compacta e transferível** da tarefa. Mude o carro ou a estrada: a política se refaz; a intenção, não.

SEÇÃO 2


Aprendizado de recompensa

02

Inverter o problema

Definição — Aprendizado por reforço inverso

Dados $\mathcal{S}$, $\mathcal{A}$, o modelo de transição $P(s' \mid s, a)$ e demonstrações $(s_0, a_0, s_1, a_1, \dots)$ com $a_t \sim \pi^E(\cdot \mid s_t)$, mas **sem** função de recompensa: inferir uma R sob a qual o comportamento observado seja ótimo.



- ▶ Recompensa: descrição **mais sucinta** da tarefa (Ng & Russell, 2000); recuperada, replaneja-se em outra dinâmica.
- ▶ Antes de qualquer algoritmo: uma pergunta de identificabilidade.

Teste sua compreensão

Teste sua compreensão

Suponha que a política do especialista π^E seja ótima. Sobre a recompensa R que a explica:

1. existe uma única R que torna π^E ótima;
2. existem muitas R que tornam π^E ótima;
3. depende do MDP.

Justifique exibindo, se possível, um contraexemplo. *Pergunta para discussão conduzida em aula.*

Teste sua compreensão

Teste sua compreensão

Suponha que a política do especialista π^E seja *ótima*. Sobre a recompensa R que a explica:

1. existe uma única R que torna π^E ótima;
2. existem muitas R que tornam π^E ótima;
3. depende do MDP.

Justifique exibindo, se possível, um contraexemplo. *Pergunta para discussão conduzida em aula.*

Resposta

Existe um conjunto infinito de R compatíveis. O caso mais brutal: $R \equiv 0$ torna *toda* política ótima. Sem restrições, o problema é mal posto — e o RL inverso consiste em escolher *qual* solução preferir.

As três fontes de ambiguidade

Atenção

1. **Degenerescência.** $R \equiv 0$ (ou qualquer constante) explica qualquer comportamento.

Atenção

2. **Escala.** Se R explica π^E , cR com $c > 0$ também: $\arg \max$ não muda.

Intuição

Invariância 2 reaparece em Bradley–Terry: recompensa de LLM sem escala absoluta. Escolher entre infinitas soluções: **estrutura + critério de desempate.**

Atenção

3. **Modelagem por potencial.** Para qualquer $\Phi : \mathcal{S} \rightarrow \mathbb{R}$,

$$R'(s, a, s') = R(s, a, s') + \gamma \Phi(s') - \Phi(s)$$

preserva *exatamente* as políticas ótimas (Ng, Harada & Russell, 1999).

Estrutura: recompensa linear em atributos

Suponha $R(s) = w^\top x(s)$, com atributos $x(s) \in \mathbb{R}^n$ conhecidos. O valor vira o produto interno com a **esperança de atributos**:

$$V^\pi = \mathbb{E} \left[\sum_{t \geq 0} \gamma^t w^\top x(s_t) \mid \pi \right] = w^\top \underbrace{\mathbb{E} \left[\sum_{t \geq 0} \gamma^t x(s_t) \mid \pi \right]}_{\mu(\pi)} = w^\top \mu(\pi).$$

Consequência

Se $\|w\|_1 \leq 1$ e $\|\mu(\pi) - \mu(\pi^E)\|_1 \leq \epsilon$, então $|w^\top \mu(\pi) - w^\top \mu(\pi^E)| \leq \epsilon$ para todo w admissível: **casar as esperanças de atributos basta**.

Intuição

Em vez de descobrir “o que o especialista queria”, basta *comportar-se como ele estatisticamente*.

Desempate: o princípio da máxima entropia

Muitas distribuições sobre trajetórias casam as esperanças de atributos. **Escolha a menos comprometida com o que não foi observado** — a de maior entropia:

$$\max_P - \sum_{\tau} P(\tau) \log P(\tau) \quad \text{sujeito a} \quad \sum_{\tau} P(\tau) x(\tau) = \tilde{x}_E, \quad \sum_{\tau} P(\tau) = 1.$$

Desempate: o princípio da máxima entropia

Muitas distribuições sobre trajetórias casam as esperanças de atributos. **Escolha a menos comprometida com o que não foi observado** — a de maior entropia:

$$\max_P - \sum_{\tau} P(\tau) \log P(\tau) \quad \text{sujeito a} \quad \sum_{\tau} P(\tau) x(\tau) = \tilde{x}_E, \quad \sum_{\tau} P(\tau) = 1.$$

A solução por multiplicadores de Lagrange é uma família exponencial:

$$P(\tau \mid w) = \frac{1}{Z(w)} \exp(w^\top x(\tau)), \quad x(\tau) = \sum_t \gamma^t x(s_t).$$

Intuição

Leitura: especialista **aproximadamente** ótimo — trajetórias melhores exponencialmente mais prováveis, mas erros possíveis.

Ziebart et al., *Maximum Entropy Inverse Reinforcement Learning*, AAAI 2008.

MaxEnt IRL: como se aprende w

Máxima verossimilhança sobre as demonstrações $\mathcal{D}$, com

$$w^* = \arg \max_w \sum_{\tau \in \mathcal{D}} \log P(\tau \mid w):$$

$$\nabla_w \mathcal{L} = \underbrace{\tilde{x}_E}_{\text{atributos observados}} - \underbrace{\mathbb{E}_{\tau \sim P(\cdot|w)} [x(\tau)]}_{\text{atributos do modelo atual}}.$$

Algoritmo — MaxEnt IRL

Repita até convergir: (i) *laço interno* — resolva o MDP com a recompensa atual $w^\top x(s)$ e obtenha π e as visitas esperadas de estados; (ii) calcule o gradiente acima e atualize w .

Atenção

Laço interno: resolver um MDP inteiro a cada passo de gradiente. Guided Cost Learning (Finn et al., 2016) troca por amostragem por importância — equivalência com GANs: a recompensa é o discriminador.

Balanço: aprendizagem por imitação

- ▶ **É poderosa.** Demonstrações: a forma mais natural de comunicar uma tarefa a uma máquina, e existem em abundância.
- ▶ **Muitas extensões:** imitação a partir de observação (sem ações), com um único exemplo, a partir de vídeo humano.
- ▶ **Máxima entropia é a ideia central:** transformar “explicar comportamento” em verossimilhança bem posta.
- ▶ **Mas** pressupõe um especialista que *sabe fazer* a tarefa. E se as pessoas só souberem *reconhecer* uma execução boa?

Intuição


Ponte: escrever um soneto é difícil; dizer qual de dois é melhor, nem tanto — o RLHF é construído sobre essa assimetria.

SEÇÃO 3

Pessoas no laço de treinamento

03

Como uma pessoa pode ajudar a treinar um agente



- ▶ Formas: demonstrar, corrigir, pontuar, comparar, restringir, interromper.
- ▶ A escolha importa: agentes que igualem o desempenho humano e respeitem valores humanos.

Recompensa dada por pessoas: o caminho ingênuo

- ▶ **TAMER** (Knox & Stone, 2008): “bom” ou “ruim” enquanto o agente age; treina-se um modelo do reforço humano.
- ▶ **Robôs ensináveis** (Thomaz & Breazeal, 2008): pessoas *não* dão reforço como a teoria supõe — antecipam, premiam intenção e *orientam*, não só avaliam.

Atenção

Pedir números falha por **calibração** (o “7” de uma pessoa não é o de outra, nem o dela na semana seguinte), **ruído** (variância alta) e **esforço** (atenção contínua).

Intuição

Saída (psicometria, pré-RL): não pergunte *quanto*; pergunte *qual dos dois*.

Comparações par a par

Definição — Por que comparar é mais fácil

- ▶ Mais fácil que escrever uma recompensa à mão.
- ▶ Mais confiável que atribuir nota escalar.
- ▶ Exige só julgamento *relativo*, estável entre avaliadores.

- ▶ Recomendação há décadas: *interleaving* mais sensível que medir cada ordenação.
- ▶ Pode-se **escolher quais pares perguntar**: aprendizado ativo de preferências (Sadigh et al., 2017).

Atenção

Perda: comparações dão apenas uma **ordem**, e RL precisa de um *número*. Reconstruir a escala é o papel do modelo de Bradley–Terry.

SEÇÃO 4

Do par ao número: Bradley–Terry


04

O modelo de Bradley–Terry (1952)

Caso simples: k ações $b_1, \dots, b_k$, sem estado nem contexto (um *bandido* de k braços).
Comparações **ruidosas**, recompensa latente $r(\cdot)$:

$$\mathbb{P}(b_i \succ b_j) = \frac{\exp(r(b_i))}{\exp(r(b_i)) + \exp(r(b_j))} = \sigma(r(b_i) - r(b_j)) = p_{ij}$$

- ▶ *Softmax* entre dois itens — ou regressão logística sobre a **diferença** de recompensas.
- ▶ **Transitividade estocástica**: p_{ik} fica determinado por p_{ij} e p_{jk} — hipótese forte, testável.



A recompensa latente não é única — de novo

Invariância a translação

Para qualquer constante c , substituir $r(\cdot)$ por $r(\cdot) + c$ deixa *todas* as probabilidades p_{ij} inalteradas, pois só entra a diferença $r(b_i) - r(b_j)$.

- ▶ Sem hipóteses adicionais, o modelo latente de recompensa não é identificável (mesma lição do RL inverso).
- ▶ Bradley–Terry: a **hipótese estrutural** que reduz a indeterminação a uma única constante — normalizável fixando, por exemplo, $\sum_i r(b_i) = 0$.

Atenção

Consequência prática: o valor absoluto que um modelo de recompensa de LLM devolve **não significa nada**. Só diferenças entre respostas ao *mesmo* prompt são interpretáveis — por isso a normalização por prompt é padrão na implementação.

Que item é “o melhor”? Três respostas

Definição — Vencedor de Condorcet

b_i tal que $\mathbb{P}(b_i \succ b_j) > 0,5$ para *todo* $j \neq i$. Pode não existir.

Definição — Vencedor de Copeland

b_i com o maior número de vitórias par a par: pontuação igual ao número de itens que ele vence menos o número dos que o vencem.

Definição — Vencedor de Borda

b_i que maximiza a pontuação esperada, onde a pontuação contra b_j é 1 se $b_i \succ b_j$, 0,5 em caso de empate, e 0 caso contrário.

Intuição

Bandidos “em duelo” buscavam o vencedor de Copeland. **Sob Bradley–Terry os três critérios coincidem** (transitividade estocástica elimina ciclos) — quando o modelo *falha*, a escolha importa. (Yue et al., JCSS 2012.)

Ajustando os parâmetros: entropia cruzada

Suponha N tuplas (b_i, b_j, μ) : $\mu = 1$ se a pessoa marcou $b_i \succ b_j$, 0,5 em caso de empate, 0 caso contrário. Maximizar a verossimilhança = minimizar a entropia cruzada:

$$\mathcal{L}(r) = - \sum_{(b_i, b_j, \mu) \in \mathcal{D}} \left[\mu \log \mathbb{P}(b_i \succ b_j) + (1 - \mu) \log \mathbb{P}(b_j \succ b_i) \right].$$

Intuição

Isto é **regressão logística** com atributos $e_i - e_j$ e coeficientes r — convexa, solução única dada a normalização.

Atenção

Se os dados forem *separáveis* (um item nunca perde), a verossimilhança empurra $r \rightarrow \infty$: regularização não é opcional.

De itens para trajetórias

Mesma construção trocando “item” por *trajetória*: $\tau^1 = (s_0, a_7, s_{14}, \dots)$ e $\tau^2 = (s_0, a_6, s_{12}, \dots)$, somas de recompensas latentes $R^1 = \sum_i r_i^1$ e $R^2 = \sum_i r_i^2$:

$$\hat{\mathbb{P}}(\tau^1 \succ \tau^2) = \frac{\exp(\sum_i r_i^1)}{\exp(\sum_i r_i^1) + \exp(\sum_i r_i^2)} = \sigma(R^1 - R^2).$$

- ▶ Agora r é uma **rede neural** $r_\phi(s, a)$, treinada pela mesma perda de entropia cruzada.
- ▶ Com r_ϕ em mãos: RL comum — rode PPO com a recompensa aprendida.

Atenção

O que a soma implica: a preferência é atribuída à trajetória *inteira*, mas o modelo aprende uma recompensa *por passo* — **atribuição de crédito**, agora dentro do sinal de supervisão.

O resultado que abriu a porta

Christiano et al. (2017), *Deep RL from Human Preferences*:

- ▶ Tarefa: agente simulado executa um *backflip* — sem recompensa escrita possível.
- ▶ Interface: dois cliques curtos; qual está mais próximo do desejado.
- ▶ Custo total: cerca de **900 comparações** de um avaliador humano.
- ▶ Recompensa treinada *em paralelo* com a política; consultas onde ele está mais incerto.

Intuição

Novecentos bits de feedback compraram o que nenhuma recompensa escrita à mão havia produzido: *avaliar* é muito mais barato que *especificar*.

Atenção


O mesmo algoritmo, sem mudança conceitual, cinco anos depois alinharia modelos de linguagem.

SEÇÃO 5

RLHF: preferências em escala

05

O pipeline de três etapas



- ▶ Etapa 1: exatamente a clonagem de comportamento da Aula 7.
- ▶ Etapas 2 e 3: as duas metades de “como maximizar algo que não sabemos escrever?”

Etapa 2: aprender o modelo de recompensa

Coleta: prompt x , várias respostas com π_{SFT} , pessoa ordena um par. y_w preferida (*winning*), y_ℓ preterida (*losing*).

$$\mathcal{L}(\phi) = -\mathbb{E}_{(x, y_w, y_\ell) \sim \mathcal{D}} \left[\log \sigma(r_\phi(x, y_w) - r_\phi(x, y_\ell)) \right]$$

- ▶ r_ϕ : o próprio LLM com a camada final trocada por uma saída escalar.
- ▶ Uma resposta inteira recebe **um** número: a soma de recompensas por token do slide anterior colapsa numa recompensa terminal.

Intuição

Valide o modelo de recompensa antes de otimizar contra ele. Acurácia em julgamentos humanos retidos; modelos grandes com dados suficientes se aproximam da concordância entre dois humanos — o teto real.

Stiennon et al., *Learning to summarize from human feedback*, NeurIPS 2020.

Etapa 3: otimizar sem destruir o modelo


$$\max_{\pi_{\theta}} \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi_{\theta}(\cdot | x)} \left[\underbrace{r_{\phi}(x, y)}_{\text{recompensa aprendida}} - \beta \underbrace{\log \frac{\pi_{\theta}(y | x)}{\pi_{\text{ref}}(y | x)}}_{\text{penalidade por se afastar}} \right]$$

- ▶ Em esperança o segundo termo é $\beta \text{KL}(\pi_{\theta}(\cdot | x) \parallel \pi_{\text{ref}}(\cdot | x))$; paga-se um preço sempre que $\pi_{\theta}(y | x) > \pi_{\text{ref}}(y | x)$.
- ▶ Otimização: PPO, tratando cada token como uma ação.

Atenção

Por que a penalidade é indispensável. r_{ϕ} é um modelo ajustado a dados finitos, válido apenas onde π_{SFT} gera texto. Maximizá-la sem restrição leva o modelo a *explorar as falhas do avaliador* — o fenômeno de *reward hacking*. A KL mantém a política dentro do domínio onde r_{ϕ} ainda é confiável.

Sobre-otimização: a lei de Goodhart, com números



Intuição

“Quando uma medida se torna um alvo, ela deixa de ser uma boa medida.” r_ϕ é um **substituto** da preferência humana; otimizá-lo demais melhora o substituto e piora o objeto.

- ▶ β : o controle desse compromisso.
- ▶ A distância KL entre política e referência é a variável natural do eixo horizontal — não o número de passos de otimização.

O que se observou na prática

- ▶ **RLHF supera pré-treino + ajuste supervisionado** em avaliação humana — vantagem cresce com a escala (Stiennon et al., 2020).
- ▶ **InstructGPT** (Ouyang et al., 2022): o *pipeline* em dezenas de milhares de tarefas; modelo muito menor, alinhado, foi preferido a um bem maior sem alinhamento.
- ▶ **Comparações controladas** (Dubois et al., 2023), GPT-4 como avaliador substituto: PPO funciona, mas linhas de base simples — *best-of- n* e treinar sobre as saídas “boas” — vão surpreendentemente longe.

Intuição

Lição de engenharia: boa parte do ganho vem de **ter um bom modelo de recompensa**, não da sofisticação do otimizador. RL é a parte cara e frágil: dá para eliminá-la?

SEÇÃO 6

DPO: preferência direta

06


O que incomoda no RLHF

Atenção

- ▶ **Quatro modelos na memória:** política, referência, recompensa e crítico.
- ▶ **Amostragem online** a cada passo — lento e caro.
- ▶ **PPO é sensível** a passo, recorte e normalização.
- ▶ Duas etapas de treino, com erros que se compõem.

Intuição

A recompensa é só um *intermediário* entre preferências e política. Relação em forma fechada → **substituir uma pela outra** e treinar a política direto sobre os pares. (Rafailov et al., 2023.)



Passo 1: a solução em forma fechada

Política ótima do objetivo com regularização KL

O máximo de $\mathbb{E}_{y \sim \pi}[r(x, y)] - \beta \text{KL}(\pi(\cdot | x) \parallel \pi_{\text{ref}}(\cdot | x))$ é atingido por

$$\pi_r(y | x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y | x) \exp\left(\frac{1}{\beta} r(x, y)\right), \quad Z(x) = \sum_y \pi_{\text{ref}}(y | x) \exp\left(\frac{1}{\beta} r(x, y)\right).$$

Passo 1: a solução em forma fechada

Política ótima do objetivo com regularização KL

O máximo de $\mathbb{E}_{y \sim \pi}[r(x, y)] - \beta \text{KL}(\pi(\cdot | x) \parallel \pi_{\text{ref}}(\cdot | x))$ é atingido por

$$\pi_r(y | x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y | x) \exp\left(\frac{1}{\beta} r(x, y)\right), \quad Z(x) = \sum_y \pi_{\text{ref}}(y | x) \exp\left(\frac{1}{\beta} r(x, y)\right).$$

Prova em três linhas. Divida por β e complete o logaritmo:

$$\begin{aligned} \max_{\pi} \mathbb{E}_{y \sim \pi} \left[\frac{1}{\beta} r - \log \frac{\pi}{\pi_{\text{ref}}} \right] &= \min_{\pi} \mathbb{E}_{y \sim \pi} \left[\log \frac{\pi(y | x)}{\frac{1}{Z(x)} \pi_{\text{ref}}(y | x) e^{r(x, y)/\beta}} \right] - \log Z(x) \\ &= \min_{\pi} \text{KL}(\pi(\cdot | x) \parallel \pi_r(\cdot | x)) - \log Z(x). \end{aligned}$$

Como $Z(x)$ não depende de π e a divergência KL é mínima (e nula) apenas quando os argumentos coincidem, o mínimo é $\pi = \pi_r$. ■

Passo 2: inverter a relação

A forma fechada é inútil como *algoritmo*: $Z(x)$ soma sobre todas as respostas possíveis — intratável. Mas ela pode ser **invertida**.

$$\pi_r(y \mid x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y \mid x) e^{r(x,y)/\beta} \iff r(x, y) = \beta \log \frac{\pi_r(y \mid x)}{\pi_{\text{ref}}(y \mid x)} + \beta \log Z(x)$$

Intuição

Leitura: *toda* função de recompensa pode ser escrita como uma razão logarítmica entre uma política e a referência — positiva se a política gosta da resposta *mais* que o modelo de referência, negativa se gosta menos.

- ▶ O termo problemático $\beta \log Z(x)$ depende apenas de x .
- ▶ E o modelo de Bradley–Terry, felizmente, só enxerga *diferenças* de recompensa para o mesmo x .

Passo 3: substituir — e ver Z desaparecer

Partindo de $\mathbb{P}(y_w \succ y_\ell \mid x) = \sigma(r(x, y_w) - r(x, y_\ell))$ e substituindo a expressão anterior:

$$r(x, y_w) - r(x, y_\ell) = \beta \log \frac{\pi_\theta(y_w \mid x)}{\pi_{\text{ref}}(y_w \mid x)} - \beta \log \frac{\pi_\theta(y_\ell \mid x)}{\pi_{\text{ref}}(y_\ell \mid x)} + \underbrace{\beta \log Z(x) - \beta \log Z(x)}_{= 0}$$

Passo 3: substituir — e ver Z desaparecer

Partindo de $\mathbb{P}(y_w \succ y_\ell \mid x) = \sigma(r(x, y_w) - r(x, y_\ell))$ e substituindo a expressão anterior:

$$r(x, y_w) - r(x, y_\ell) = \beta \log \frac{\pi_\theta(y_w \mid x)}{\pi_{\text{ref}}(y_w \mid x)} - \beta \log \frac{\pi_\theta(y_\ell \mid x)}{\pi_{\text{ref}}(y_\ell \mid x)} + \underbrace{\beta \log Z(x) - \beta \log Z(x)}_{= 0}$$

Levando à perda de entropia cruzada, obtém-se um objetivo que só envolve a política:

Perda do DPO

$$\mathcal{L}_{\text{DPO}}(\pi_\theta; \pi_{\text{ref}}) = -\mathbb{E}_{(x, y_w, y_\ell) \sim \mathcal{D}} \left[\log \sigma \left(\beta \log \frac{\pi_\theta(y_w \mid x)}{\pi_{\text{ref}}(y_w \mid x)} - \beta \log \frac{\pi_\theta(y_\ell \mid x)}{\pi_{\text{ref}}(y_\ell \mid x)} \right) \right]$$

Perda **supervisionada** sobre um conjunto *fixo* de pares — sem amostragem, sem crítico, sem modelo de recompensa explícito.

O que o gradiente do DPO faz

$$\nabla_{\theta} \mathcal{L}_{\text{DPO}} = -\beta \mathbb{E}_{(x, y_w, y_{\ell})} \left[\underbrace{\sigma(\hat{r}_{\theta}(x, y_{\ell}) - \hat{r}_{\theta}(x, y_w))}_{\text{peso: quão errado o modelo está}} \left(\underbrace{\nabla_{\theta} \log \pi_{\theta}(y_w | x)}_{\text{aumentar}} - \underbrace{\nabla_{\theta} \log \pi_{\theta}(y_{\ell} | x)}_{\text{diminuir}} \right) \right]$$

com $\hat{r}_{\theta}(x, y) = \beta \log \frac{\pi_{\theta}(y|x)}{\pi_{\text{ref}}(y|x)}$ a **recompensa implícita** definida pela própria política.

Intuição

Gradiente de política “suba o que deu certo, desça o que deu errado” — com **peso adaptativo**: quase zero nos pares que o modelo já ordena corretamente, esforço nos que ele ainda erra. É o que impede o colapso da máxima verossimilhança ingênua sobre y_w .

Teste sua compreensão

Teste sua compreensão

O DPO nunca constrói um modelo de recompensa. Ainda assim, dizemos que ele tem uma “recompensa implícita”.

(i) Onde ela está? (ii) O termo $\beta \log Z(x)$ cancelou — isso significa que ele é irrelevante, ou que apenas não é *necessário*? (iii) Que hipótese do RLHF o DPO herda inteira, sem enfraquecer?

Pergunta para discussão conduzida em aula.

Teste sua compreensão

Teste sua compreensão

O DPO nunca constrói um modelo de recompensa. Ainda assim, dizemos que ele tem uma “recompensa implícita”.

(i) Onde ela está? (ii) O termo $\beta \log Z(x)$ cancelou — isso significa que ele é irrelevante, ou que apenas não é *necessário*? (iii) Que hipótese do RLHF o DPO herda inteira, sem enfraquecer?

Pergunta para discussão conduzida em aula.

Resposta

(i) Na razão $\beta \log(\pi_\theta / \pi_{\text{ref}})$: os pesos da política são o modelo de recompensa reparametrizado.
(ii) Ele existe e fixa a normalização; só não precisa ser conhecido, pois a perda depende apenas de diferenças com o mesmo x . (iii) O **modelo de Bradley-Terry**. Se ele falha, DPO e RLHF falham juntos.

O que se ganha e o que se perde

	RLHF (PPO)	DPO
Modelos em memória	4	2
Dados	<i>online</i> (regerados)	<i>offline</i> , fixos
Estabilidade	sensível a hiperparâmetros	perda supervisionada
Rotular dados novos	possível a qualquer momento	exige nova coleta
Compromisso recompensa/KL	explorado eficientemente	idem, com menos custo
Explorar fora do conjunto	sim	não

Atenção

A última linha é a limitação real: o DPO só pode reordenar o que já está no conjunto de dados; ele nunca descobre uma resposta melhor que ninguém escreveu. Daí as variantes *iterativas* (geração, rotulagem, DPO).


Definição — Experimento controlado

1. Gerar resenhas positivas de filmes com GPT-2 XL.
2. Usar um classificador de sentimento como recompensa “de ouro”.
3. Construir preferências sintéticas a partir dela.
4. Otimizar com PPO e com DPO.

Resultado: para o *mesmo* desvio KL, o DPO obtém recompensa igual ou maior — fronteira de compromisso melhor.

- ▶ Com recompensa de ouro conhecida, a comparação é limpa: sem dúvida sobre a qualidade do modelo de recompensa.
- ▶ Em escala, DPO e variantes: padrão em famílias abertas (Zephyr, Mistral, Llama 3).
- ▶ Extensões próximas: **CPL**, mesma ideia para preferências sobre *trajetórias* de controle, fora da linguagem.

O mapa depois do DPO



Intuição

Ramo de cima move o estado da arte em raciocínio: correção *verificável* (uma prova, um teste unitário, uma resposta numérica) → recompensa dada de novo — a sobre-otimização desta aula desaparece.

SEÇÃO 7

Balanço

07

O que você deve levar desta aula

Definição — Capacidades esperadas

- ▶ Explicar a degradação $O(\epsilon T^2)$ da clonagem, e por que mais dados não corrigem o expoente.
- ▶ Descrever o DAGGER, sua garantia e por que ele não escala.
- ▶ Argumentar que a recompensa do RL inverso não é única; listar as três invariâncias.
- ▶ Escrever Bradley–Terry e a perda correspondente, para itens e para trajetórias.
- ▶ Descrever as três etapas do RLHF e o papel da penalidade KL.
- ▶ **Derivar** o DPO e interpretar seu gradiente.

Intuição

Moral: sem placar, alguém precisa fornecê-lo — *quem fornece, a que custo, quanto confiar.*

Artigos fundamentais

- ▶ Ross, Gordon & Bagnell (2011) — DAGGER.
- ▶ Ng & Russell (2000) — RL inverso.
- ▶ Ziebart et al. (2008) — MaxEnt IRL.
- ▶ Christiano et al. (2017) — preferências humanas.
- ▶ Ouyang et al. (2022) — InstructGPT.
- ▶ Rafailov et al. (2023) — DPO.

Atenção

Pergunta que a técnica não responde: *de quem* são as preferências usadas para rotular os pares. Escolha de projeto, não detalhe de implementação.

Contexto mais amplo

- ▶ Preferências humanas: interseção de **escolha social, economia computacional** e IA — literatura anterior ao aprendizado de máquina.
- ▶ Teoremas de impossibilidade (Arrow) afetam “alinhar” um modelo a um *grupo* com preferências conflitantes.