

Universidade Federal de Uberlândia

Aula 9: Aprendizagem por reforço eficiente em dados I

Bandidos multi-braços • Arrependimento • ϵ -guloso • Otimismo e UCB

Prof. Marcelo Keese Albertini
Universidade Federal de Uberlândia
adaptado de Emma Brunskill, CS234 (Stanford)

2026



Retomando a aula anterior

Aprendizagem a partir de preferências humanas

Teste sua compreensão

Quais afirmações são verdadeiras?

1. RLHF e DPO ambos aprendem uma representação **explícita** de um modelo de recompensa a partir de preferências.
2. Ambos estão limitados a ser, no máximo, tão bons quanto os melhores exemplos dos pares de preferência.
3. O DPO não utiliza política de referência.

Pergunta para discussão conduzida em aula.

Retomando a aula anterior

Aprendizagem a partir de preferências humanas

Teste sua compreensão

Quais afirmações são verdadeiras?

1. RLHF e DPO ambos aprendem uma representação **explícita** de um modelo de recompensa a partir de preferências.
2. Ambos estão limitados a ser, no máximo, tão bons quanto os melhores exemplos dos pares de preferência.
3. O DPO não utiliza política de referência.

Pergunta para discussão conduzida em aula.

Resposta

Nenhuma das três. (1) DPO dispensa o modelo explícito: a recompensa fica *implícita* em $\log \frac{\pi_{\theta}}{\pi_{\text{ref}}}$. (2) Otimizar uma recompensa aprendida permite *superar* os exemplos vistos. (3) π_{ref} é parte constitutiva da perda do DPO.

Onde estamos no curso

- ▶ **Aulas 1–2:** planejamento com modelo conhecido.
- ▶ **Aulas 3–4:** avaliação e controle sem modelo.
- ▶ **Aulas 5–7:** gradientes de política, métodos modernos.
- ▶ **Aula 8:** aprendizagem a partir de preferências.
- ▶ **Aulas 9–10:** **eficiência de dados** — quantas interações são *necessárias*?

Intuição

Antes: “o algoritmo converge para a política ótima?” Agora: “quantos erros ele comete no caminho?”

Atenção

Convergência assintótica é critério barato: testar todas as ações um milhão de vezes e depois agir otimamente “converge” — e é inútil se cada teste custa um paciente, um cliente ou uma hora de robô.

Os quatro ingredientes, revisitados

A aprendizagem por reforço envolve:

- ▶ **Otimização** — encontrar boas decisões.
- ▶ **Generalização** — inferir sobre o que não foi visto.
- ▶ **Consequências adiadas** — hoje afeta amanhã.
- ▶ **Exploração** — decidir o que experimentar.

Definição — Estratégia desta aula

Isolar a **exploração** removendo temporariamente as consequências adiadas. O objeto resultante — o *bandido multi-braços* — é simples o bastante para admitir análise exata, e as ideias sobrevivem intactas quando as consequências adiadas voltam (Aula 10).

O que vamos construir hoje

CENÁRIOS

Onde o agente age.

- ▶ Bandidos (decisão única)
- ▶ MDPs (Aula 10)

ARCABOUÇOS

Como se mede qualidade.

- ▶ Arrependimento
- ▶ Arrependimento bayesiano
- ▶ PAC (Aula 10)

ABORDAGENS

Classes de algoritmos.

- ▶ Guloso, ϵ -guloso
- ▶ Otimismo (UCB)
- ▶ Casamento de probabilidade

Intuição

A matriz cenário $\times$ arcabouço $\times$ abordagem não é ponto a ponto: **uma mesma abordagem costuma atender vários arcabouços em vários cenários** — o otimismo, visto hoje em bandidos, reaparece quase sem alteração em MDPs.

SEÇÃO 1

Bandidos multi-braços

01

Como julgar um algoritmo de aprendizagem

CrITÉRIOS que já usamos, em ordem crescente de exigência:

1. **Custo computacional** por iteração.
2. **Converge?** Existe um ponto fixo e o algoritmo o alcança?
3. **Converge para o ótimo?**
4. **Com que rapidez** alcança a política ótima?
5. **Quantos erros comete no caminho?**

Atenção

O critério (5) é o único que fala do *custo da própria aprendizagem* — e o que importa em ensaios clínicos, precificação, recomendação e robótica: cada decisão subótima é dano real, não número numa curva de treino.

Bandido multi-braços


Definição — Bandido multi-braços

Uma tupla $(\mathcal{A}, \mathcal{R})$ onde

- ▶ $\mathcal{A}$ é um conjunto *conhecido* de m ações (“braços”);
- ▶ $\mathcal{R}_a(r) = \mathbb{P}[r \mid a]$ é uma distribuição de recompensas *desconhecida*, uma para cada braço.


A cada passo o agente escolhe $a_t \in \mathcal{A}$; o ambiente devolve $r_t \sim \mathcal{R}_{a_t}$. Objetivo: maximizar $\sum_{\tau} r_{\tau}$.

- ▶ Sem estado: a ação de hoje não altera o problema de amanhã.
- ▶ O único acoplamento entre passos é **informacional**: o que aprendi ontem muda o que escolho hoje.



MDP de **um único estado**:
todas as ações voltam a s .

Bandido, bandido contextual, MDP



Intuição

A exploração é *difícil* nos três casos, por razões diferentes: no bandido, basta decidir *o que testar*. No MDP, é preciso decidir também *como chegar* ao lugar onde vale a pena testar — exploração profunda.

- ▶ Anúncios, notícias e recomendação: bandidos contextuais, na prática, movimentam bilhões.
- ▶ Ensaios clínicos adaptativos: bandidos puros com restrições éticas.
- ▶ Toda a teoria de hoje é o caso base das cotas de amostra para MDPs.

Exemplo condutor: como tratar um dedo do pé quebrado

- ▶ Decidir o melhor tratamento para pacientes com fratura de dedo do pé.
- ▶ Três opções: **(1)** cirurgia, **(2)** imobilização com esparadrapo no dedo vizinho (*buddy taping*), **(3)** não fazer nada.
- ▶ Desfecho binário: consolidou (+1) ou não (0) após seis semanas, por radiografia.
- ▶ Cada braço é uma variável de Bernoulli com parâmetro desconhecido θ_i .

Atenção

Exemplo **fictício** — os números não representam a eficácia real de nenhum tratamento ortopédico.

Definição — Parâmetros verdadeiros (desconhecidos)

cirurgia a_1	$\theta_1 = 0,95$
esparadrapo a_2	$\theta_2 = 0,90$
nada a_3	$\theta_3 = 0,10$

Teste sua compreensão: modelando o problema

Teste sua compreensão

Modelando o tratamento como bandido de 3 braços, cada um Bernoulli com parâmetro desconhecido θ_i , quais são verdadeiras?

1. Puxar um braço / tomar uma ação corresponde a o dedo ter consolidado ou não.
2. Um bandido descreve melhor este problema do que um MDP porque tratar cada paciente envolve múltiplas decisões.
3. Depois de tratar um paciente, se $\theta_i \neq 0$ e $\theta_i \neq 1$ para todo i , às vezes o dedo consolida e às vezes não.

Pergunta para discussão conduzida em aula.

Teste sua compreensão: modelando o problema

Teste sua compreensão

Modelando o tratamento como bandido de 3 braços, cada um Bernoulli com parâmetro desconhecido θ_i , quais são verdadeiras?

1. Puxar um braço / tomar uma ação corresponde a o dedo ter consolidado ou não.
2. Um bandido descreve melhor este problema do que um MDP porque tratar cada paciente envolve múltiplas decisões.
3. Depois de tratar um paciente, se $\theta_i \neq 0$ e $\theta_i \neq 1$ para todo i , às vezes o dedo consolida e às vezes não.

Pergunta para discussão conduzida em aula.

Resposta

Apenas a (3). (1) é falsa: puxar o braço é *escolher o tratamento* — a consolidação é a *recompensa*. (2) tem a conclusão certa pelo motivo errado: o bandido serve porque cada paciente envolve *uma única* decisão. (3) é a definição de recompensa estocástica.

O algoritmo guloso

Algoritmo — Guloso

Estime o valor de cada ação por avaliação de Monte Carlo:

$$\hat{Q}_t(a) = \frac{1}{N_t(a)} \sum_{i=1}^t r_i \mathbb{1}(a_i = a) \approx Q(a) = \mathbb{E}[R(a)],$$

e escolha sempre a ação de maior valor estimado:

$$a_t = \arg \max_{a \in \mathcal{A}} \hat{Q}_{t-1}(a).$$

Forma incremental, sem guardar o histórico:

$$\hat{Q}_t(a_t) = \hat{Q}_{t-1}(a_t) + \frac{1}{N_t(a_t)} (r_t - \hat{Q}_{t-1}(a_t)).$$

Intuição

O mesmo molde das aulas anteriores, com $\alpha = 1/N$: a média exata.

O guloso trava

Uma rodada de amostragem inicial, e o destino selado

Algoritmo — Execução

1. Amostre cada braço uma vez:

- ▶ $a_1, r \sim \text{Bernoulli}(0,95)$, obtém 0 $\Rightarrow \hat{Q}(a_1) = 0$
- ▶ $a_2, r \sim \text{Bernoulli}(0,90)$, obtém +1 $\Rightarrow \hat{Q}(a_2) = 1$
- ▶ $a_3, r \sim \text{Bernoulli}(0,10)$, obtém 0 $\Rightarrow \hat{Q}(a_3) = 0$

2. Qual a probabilidade de o guloso escolher cada braço em seguida? (empates resolvidos uniformemente)

O guloso trava

Uma rodada de amostragem inicial, e o destino selado

Algoritmo — Execução

1. Amostre cada braço uma vez:

- ▶ $a_1, r \sim \text{Bernoulli}(0,95)$, obtém 0 $\Rightarrow \hat{Q}(a_1) = 0$
- ▶ $a_2, r \sim \text{Bernoulli}(0,90)$, obtém +1 $\Rightarrow \hat{Q}(a_2) = 1$
- ▶ $a_3, r \sim \text{Bernoulli}(0,10)$, obtém 0 $\Rightarrow \hat{Q}(a_3) = 0$

2. Qual a probabilidade de o guloso escolher cada braço em seguida? (empates resolvidos uniformemente)

Resposta

$\mathbb{P}(a_2) = 1$. O máximo é único.

O guloso trava

Uma rodada de amostragem inicial, e o destino selado

Algoritmo — Execução

1. Amostre cada braço uma vez:

- ▶ $a_1, r \sim \text{Bernoulli}(0,95)$, obtém 0 $\Rightarrow \hat{Q}(a_1) = 0$
- ▶ $a_2, r \sim \text{Bernoulli}(0,90)$, obtém +1 $\Rightarrow \hat{Q}(a_2) = 1$
- ▶ $a_3, r \sim \text{Bernoulli}(0,10)$, obtém 0 $\Rightarrow \hat{Q}(a_3) = 0$

2. Qual a probabilidade de o guloso escolher cada braço em seguida? (empates resolvidos uniformemente)

Resposta

$\mathbb{P}(a_2) = 1$. O máximo é único.

Atenção

O guloso jamais encontrará o melhor braço. Escolhido a_2 , os outros dois permanecem congelados em $\hat{Q} = 0$: nunca mais são testados. A cirurgia — de fato superior — ficou eliminada por um único paciente azarado.

Intuição

A falha não é de estimação, é de *cobertura*: o estimador de Monte Carlo é não viesado apenas para os braços que continuam sendo amostrados.

SEÇÃO 2

Arrependimento

02

Um critério formal: arrependimento

Definição — Arrependimento (*regret*)

Valor de ação: $Q(a) = \mathbb{E}[r \mid a]$. Valor ótimo: $V^* = Q(a^*) = \max_{a \in \mathcal{A}} Q(a)$.

Perda de oportunidade em um passo:

$$\ell_t = \mathbb{E}[V^* - Q(a_t)],$$

onde a esperança é sobre a política de decisão usada para escolher a_t .

Arrependimento total até t :

$$L_t = \mathbb{E}\left[\sum_{\tau=1}^t V^* - Q(a_\tau)\right].$$

Intuição

Maximizar recompensa acumulada $\iff$ minimizar arrependimento total: mesmo objetivo, sinal trocado, deslocamento tV^* . Mas o arrependimento é *comparável entre problemas*.

Decomposição: lacunas $\times$ contagens

- ▶ $N_t(a)$: número de vezes que a ação a foi escolhida até t .
- ▶ **Lacuna** Δ_a : diferença de valor entre a e a ação ótima, $\Delta_a = V^* - Q(a)$.

$$L_t = \mathbb{E} \left[\sum_{\tau=1}^t V^* - Q(a_\tau) \right] = \sum_{a \in \mathcal{A}} \mathbb{E}[N_t(a)] (V^* - Q(a)) = \sum_{a \in \mathcal{A}} \mathbb{E}[N_t(a)] \Delta_a$$

Intuição

Bom algoritmo: **contagens pequenas onde as lacunas são grandes**. O problema: as lacunas são exatamente o que não sabemos — se soubéssemos Δ_a , não haveria nada a aprender.

Atenção

Toda a dificuldade da exploração está nesta frase. Não é preciso estimar Q bem em todo braço: basta estimar bem o suficiente para *ordenar* — menos amostras onde a lacuna é grande, mais onde ela é pequena.

Arrependimento do guloso, passo a passo

$\theta = (0,95; 0,90; 0,10)$, portanto $\Delta = (0; 0,05; 0,85)$

Ação	Ação ótima	Recompensa obs.	Arrepend. do passo	Acumulado
a_1	a_1	0	0,00	0,00
a_2	a_1	1	0,05	0,05
a_3	a_1	0	0,85	0,90
a_2	a_1	1	0,05	0,95
a_2	a_1	0	0,05	1,00

Atenção

Linhas 2 e 4: a recompensa observada foi +1 e mesmo assim houve arrependimento — não compara com o que aconteceu, mas com o que aconteceria *em média* sob a melhor ação.

Intuição

Em a_2 para sempre: cada passo adicional custa 0,05. Ao fim de T decisões, $L_T \approx 0,05 T$: **arrependimento linear**. A curva nunca achata.

Uma limitação incômoda — e a saída

Atenção

Em qualquer aplicação real **não é possível calcular o arrependimento**: ele exige conhecer a recompensa esperada da melhor ação, que é justamente a incôgnita. A tabela anterior só pôde ser preenchida porque nós fixamos θ .

Definição — O que se faz em vez disso

Demonstra-se uma **cota superior** para o arrependimento potencial de um algoritmo *em qualquer problema de bandido* de uma dada classe. A garantia é uniforme sobre os ambientes, não estimada a partir dos dados.


Definição — Cota independente do problema

Limita L_T como função apenas de T e m (e.g. $O(\sqrt{mT \log T})$). É a garantia de *pior caso*.

Definição — Cota dependente do problema

Limita L_T em função das lacunas Δ_a (e.g. $O(\sum_a \log T / \Delta_a)$). É afiada em problemas fáceis e explode quando as lacunas somem.

As duas cotas descrevem o mesmo algoritmo



Intuição

“Bom” = **sublinear**: $L_T/T \rightarrow 0$ — a fração de decisões erradas tende a zero. Explorar para sempre: linear; nunca explorar: também. Existe algo no meio? Sim.

SEÇÃO 3

€-guloso

03

O algoritmo ϵ -guloso

Algoritmo — ϵ -guloso

A cada passo:

- ▶ com probabilidade $1 - \epsilon$, escolha $a_t = \arg \max_{a \in \mathcal{A}} \hat{Q}_t(a)$;
 - ▶ com probabilidade ϵ , escolha uma ação uniformemente ao acaso.
-
- ▶ Garante que *todo* braço continua sendo amostrado: $N_t(a) \rightarrow \infty$ para todo a .
 - ▶ Logo $\hat{Q}_t(a) \rightarrow Q(a)$ para todo a (lei dos grandes números) — a falha de cobertura do guloso desaparece.
 - ▶ Já usamos isto nas Aulas 4 e 6, para MDPs.

Atenção

O preço é permanente: com ϵ fixo, uma fração ϵ dos passos é deliberadamente subótima — **para sempre**, muito depois de já saber qual é o melhor braço.

Algoritmo — Execução, com $\epsilon = 0,1$

1. Amostre cada braço uma vez:

- ▶ $a_1, r \sim \text{Bernoulli}(0,95)$: $+1, \hat{Q}(a_1) = 1$
- ▶ $a_2, r \sim \text{Bernoulli}(0,90)$: $+1, \hat{Q}(a_2) = 1$
- ▶ $a_3, r \sim \text{Bernoulli}(0,10)$: $0, \hat{Q}(a_3) = 0$

2. Qual a probabilidade de puxar cada braço em seguida? (empates uniformes)

ϵ -guloso no exemplo dos dedos

Algoritmo — Execução, com $\epsilon = 0,1$

1. Amostre cada braço uma vez:

- ▶ $a_1, r \sim \text{Bernoulli}(0,95)$: $+1, \hat{Q}(a_1) = 1$
- ▶ $a_2, r \sim \text{Bernoulli}(0,90)$: $+1, \hat{Q}(a_2) = 1$
- ▶ $a_3, r \sim \text{Bernoulli}(0,10)$: $0, \hat{Q}(a_3) = 0$

2. Qual a probabilidade de puxar cada braço em seguida? (empates uniformes)

Resposta

Empate entre a_1 e a_2 na parte gulosa:

$$\mathbb{P}(a_1) = \mathbb{P}(a_2) = \underbrace{\frac{0,9}{2}}_{\text{gulosa}} + \underbrace{\frac{0,1}{3}}_{\text{aleat.}} = 0,4833,$$

$$\mathbb{P}(a_3) = \frac{0,1}{3} = 0,0333.$$

ϵ -guloso no exemplo dos dedos

Algoritmo — Execução, com $\epsilon = 0,1$

1. Amostre cada braço uma vez:

- ▶ $a_1, r \sim \text{Bernoulli}(0,95)$: $+1, \hat{Q}(a_1) = 1$
- ▶ $a_2, r \sim \text{Bernoulli}(0,90)$: $+1, \hat{Q}(a_2) = 1$
- ▶ $a_3, r \sim \text{Bernoulli}(0,10)$: $0, \hat{Q}(a_3) = 0$

2. Qual a probabilidade de puxar cada braço em seguida? (empates uniformes)

Resposta

Empate entre a_1 e a_2 na parte gulosa:

$$\mathbb{P}(a_1) = \mathbb{P}(a_2) = \underbrace{\frac{0,9}{2}}_{\text{gulosa}} + \underbrace{\frac{0,1}{3}}_{\text{aleat.}} = 0,4833,$$

$$\mathbb{P}(a_3) = \frac{0,1}{3} = 0,0333.$$

Intuição

Sim, a_3 voltará a ser escolhido — cerca de $T/30$ pacientes receberão “não fazer nada”, um tratamento que já sabemos ser péssimo.

Teste sua compreensão: arrependimento do ϵ -guloso

Teste sua compreensão

Lembre que $L_t = \sum_a \mathbb{E}[N_t(a)] \Delta_a$, e que informalmente um algoritmo tem **arrependimento linear** se toma uma ação não ótima numa fração constante dos passos. Suponha que exista a com $\Delta_a > 0$. Quais são verdadeiras?

1. ϵ -guloso com $\epsilon = 0,1$ pode ter arrependimento linear.
2. ϵ -guloso com $\epsilon = 0$ pode ter arrependimento linear.

Pergunta para discussão conduzida em aula.

Teste sua compreensão: arrependimento do ϵ -guloso

Teste sua compreensão

Lembre que $L_t = \sum_a \mathbb{E}[N_t(a)] \Delta_a$, e que informalmente um algoritmo tem **arrependimento linear** se toma uma ação não ótima numa fração constante dos passos. Suponha que exista a com $\Delta_a > 0$. Quais são verdadeiras?

1. ϵ -guloso com $\epsilon = 0,1$ pode ter arrependimento linear.
2. ϵ -guloso com $\epsilon = 0$ pode ter arrependimento linear.

Pergunta para discussão conduzida em aula.

Resposta

As duas — por motivos opostos, o que é o ponto da pergunta. $\epsilon = 0,1$: *explora demais* — braços ruins numa fração fixa ϵ/m dos passos, para sempre, e $L_T \geq \frac{\epsilon}{m} (\sum_a \Delta_a) T$. $\epsilon = 0$: *explora de menos* — é o guloso, que pode travar num braço subótimo e pagar ΔT . No exemplo dos dedos, a taxa com $\epsilon = 0,1$ é $\frac{0,1}{3} (0,05 + 0,85) = 0,03$ por passo.

Explorar sempre e nunca explorar falham igual

Nunca explorar

$\epsilon = 0$
trava em braço subótimo

$$L_T = \Theta(T)$$

Explorar decrescendo

$\epsilon_t \downarrow 0$ na taxa certa,
ou otimismo

$$L_T = O(\log T)$$

Explorar sempre

ϵ fixo
erra fração fixa

$$L_T = \Theta(T)$$

ϵ decrescente (Auer, Cesa-Bianchi e Fischer, 2002)

Se $\Delta = \min_{a: \Delta_a > 0} \Delta_a$ e escolhemos $\epsilon_t = \min\left\{1, \frac{cm}{\Delta^2 t}\right\}$ com $c > 0$ apropriado, então o ϵ_t -guloso atinge arrependimento **logarítmico** em T .

Atenção

O agendamento ótimo depende de Δ , que é desconhecido. Por isso o ϵ -guloso decrescente é teoricamente correto mas praticamente frágil — e por que vale a pena procurar algo que se adapte sozinho.

Interlúdio: explorar-depois-comprometer

O algoritmo mais simples com arrependimento sublinear

Algoritmo — ETC (*explore-then-commit*)

Puxe cada braço exatamente k vezes (mk passos de exploração); depois disso, escolha para sempre o braço de maior média empírica.

Com recompensas 1-sub-gaussianas e dois braços:

$$L_T \leq k\Delta + (T - 2k) \Delta \exp\left(-\frac{k\Delta^2}{4}\right).$$

- ▶ 1º termo: o custo pago de explorar.
- ▶ 2º: o risco de se comprometer com o braço errado.
- ▶ Otimizando k e o pior Δ : $L_T = O(T^{2/3})$.

Intuição

Sublinear, portanto “bom” — mas $T^{2/3}$ está longe de $\sqrt{T}$: **separar** exploração e exploração em fases estanques desperdiça o que se aprendeu *durante* a exploração para abandonar cedo um braço ruim.

Atenção

Exploração e exploração devem ser entrelaçadas, não sequenciadas.

Quão bom é possível ser? Limite inferior

- ▶ O desempenho de *qualquer* algoritmo é determinado pela semelhança entre o braço ótimo e os demais.
- ▶ Problemas difíceis têm braços que *parecem* iguais mas têm médias diferentes: é preciso muita amostra para separá-los.
- ▶ Formalmente: a lacuna Δ_a e a divergência $D_{\text{KL}}(\mathcal{R}_a \parallel \mathcal{R}_{a^*})$.

Teorema (Lai e Robbins, 1985)

O arrependimento total assintótico de qualquer algoritmo consistente é ao menos logarítmico no número de passos:

$$\lim_{t \rightarrow \infty} L_t \geq \log t \sum_{a: \Delta_a > 0} \frac{\Delta_a}{D_{\text{KL}}(\mathcal{R}_a \parallel \mathcal{R}_{a^*})}.$$

Intuição

Boa notícia disfarçada de má: o limite inferior é **sublinear**. Nada proíbe um algoritmo de acertar quase sempre — e $\log t$ é o melhor que se pode esperar.

Lendo o limite inferior nos números do exemplo

Para braços de Bernoulli, $D_{\text{KL}}(\theta_a \| \theta_*) = \theta_a \log \frac{\theta_a}{\theta_*} + (1 - \theta_a) \log \frac{1 - \theta_a}{1 - \theta_*}$.

Braço	θ_a	Δ_a	$D_{\text{KL}}(\theta_a \ 0,95)$	Δ_a / D_{KL}
esparadrapo a_2	0,90	0,05	0,0207	2,42
nada a_3	0,10	0,85	2,3762	0,36

Atenção

A inversão é o ponto: o braço **quase tão bom** (a_2 , lacuna minúscula) contribui *sete vezes mais* para o limite inferior do que o braço obviamente ruim. Distinguir 0,90 de 0,95 custa muitas amostras; descartar 0,10 custa poucas.

Intuição

Em $T = 1000$, o piso de Lai–Robbins vale $(2,42 + 0,36) \log 1000 \approx 19$. Compare com o arrependimento do guloso, ≈ 50 , e com o do ϵ -guloso fixo, ≈ 30 . Há espaço.

SEÇÃO 4

Otimismo diante da incerteza

04

O princípio do otimismo

Definição — Otimismo diante da incerteza

Escolha ações que **poderiam** ter valor alto — não as que *parecem* ter valor alto.

O princípio do otimismo

Definição — Otimismo diante da incerteza

Escolha ações que **poderiam** ter valor alto — não as que *parecem* ter valor alto.

Por quê? Há apenas dois desfechos possíveis, e ambos são bons:

Desfecho 1 — acertamos

Braço com média alta de fato: colhemos recompensa alta. Nenhum arrependimento.

Desfecho 2 — aprendemos

Média baixa: puxá-lo reduz (em esperança) sua média estimada e a incerteza. O braço é rebaixado e não volta a enganar.

O princípio do otimismo

Definição — Otimismo diante da incerteza

Escolha ações que **poderiam** ter valor alto — não as que *parecem* ter valor alto.

Por quê? Há apenas dois desfechos possíveis, e ambos são bons:

Desfecho 1 — acertamos

Braço com média alta de fato: colhemos recompensa alta. Nenhum arrependimento.

Desfecho 2 — aprendemos

Média baixa: puxá-lo reduz (em esperança) sua média estimada e a incerteza. O braço é rebaixado e não volta a enganar.

Intuição

Otimismo é **autocorretivo**: só se pode estar excessivamente otimista por um número limitado de puxadas — cada puxada corrige o excesso. Essa contagem — “quantas vezes posso me enganar antes de ser desmentido?” — vira a demonstração da cota.

Cotas superiores de confiança

Definição — UCB

Estime uma cota superior de confiança $U_t(a)$ para cada valor de ação, tal que $Q(a) \leq U_t(a)$ com alta probabilidade. A cota depende de $N_t(a)$: quanto mais puxamos, mais estreita. Então

$$a_t = \arg \max_{a \in \mathcal{A}} U_t(a).$$



De onde vem a largura da barra

Definição — Variável σ -sub-gaussiana

X com $\mathbb{E}[X] = 0$ é σ -sub-gaussiana se $\mathbb{E}[e^{\lambda X}] \leq e^{\lambda^2 \sigma^2 / 2}$ para todo $\lambda \in \mathbb{R}$. Sua cauda decai ao menos tão rápido quanto a de uma gaussiana de desvio σ .

Corolário 5.5 (Lattimore e Szepesvári, *Bandit Algorithms*)

Sejam $X_i - \mu$ independentes e σ -sub-gaussianas, e $\hat{\mu} = \frac{1}{n} \sum_{t=1}^n X_t$. Então, para todo $\varepsilon \geq 0$,

$$\mathbb{P}(\hat{\mu} \geq \mu + \varepsilon) \leq \exp\left(-\frac{n\varepsilon^2}{2\sigma^2}\right), \quad \mathbb{P}(\hat{\mu} \leq \mu - \varepsilon) \leq \exp\left(-\frac{n\varepsilon^2}{2\sigma^2}\right).$$

Intuição

Recompensas em $[0, 1]$ — como as do nosso exemplo — são $\frac{1}{2}$ -sub-gaussianas pelo lema de Hoeffding. Usar $\sigma = 1$ é apenas conservador: barras mais largas que o necessário, nunca mais estreitas.

Invertendo a desigualdade

Pergunta operacional: “*dado* um risco δ que aceito correr, qual ε ?”

$$\delta = \exp\left(-\frac{n\varepsilon^2}{2\sigma^2}\right) \iff \varepsilon = \sqrt{\frac{2\sigma^2 \log(1/\delta)}{n}}.$$

Cota superior de confiança

Para qualquer $\delta \in (0, 1]$, com probabilidade ao menos $1 - \delta$,

$$\mu \leq \hat{\mu} + \sqrt{\frac{2\sigma^2 \log(1/\delta)}{n}}.$$

Atenção

Cota *unilateral*. Para controlar $|\hat{\mu} - \mu|$ é preciso aplicar as duas caudas com união de eventos: tomando $\delta' = \delta/2$, com probabilidade ao menos $1 - \delta$, $|\mu - \hat{\mu}| \leq \sqrt{2\sigma^2 \log(2/\delta)/n}$.

O algoritmo UCB1

Algoritmo — UCB1 (Auer, Cesa-Bianchi e Fischer, 2002)

Supondo recompensas 1-sub-gaussianas ($\sigma^2 = 1$):

$$a_t = \arg \max_{a \in \mathcal{A}} \left[\underbrace{\hat{Q}(a)}_{\text{exploração}} + \underbrace{\sqrt{\frac{2 \log(1/\delta)}{N_t(a)}}}_{\text{bônus de exploração}} \right].$$

- ▶ Sem parâmetro de exploração para ajustar: o bônus é *deduzido*, não escolhido.
- ▶ O bônus decai como $1/\sqrt{N}$ — braços pouco testados recebem crédito automaticamente.
- ▶ Braços nunca testados têm bônus infinito: o algoritmo começa amostrando cada braço uma vez.

Intuição

A escolha de δ . Fixo, o bônus não encolhe com o tempo. Tomando $\delta = 1/t^2$ obtém-se a versão *anytime*, $\hat{Q}(a) + \sqrt{4 \log t / N_t(a)}$ — a fórmula clássica com $\log t$ no numerador, que é a que se usa na prática.

UCB1 no exemplo dos dedos

$\delta = 0,1$, logo o bônus vale $2,146/\sqrt{N(a)}$; início com cada braço puxado uma vez, obtendo $(+1, +1, 0)$

t	$U(a_1)$	$U(a_2)$	$U(a_3)$	escolhe	r	arrepent. acum.
3	3,146	3,146	2,146	a_1	+1	0,90
4	2,517	3,146	2,146	a_2	+1	0,95
5	2,517	2,517	2,146	a_1	+1	0,95
6	2,239	2,517	2,146	a_2	0	1,00
7	2,239	1,906	2,146	a_1	+1	1,00
8	2,073	1,906	2,146	a_3	0	1,85
9	2,073	1,906	1,517	a_1	+1	1,85

Intuição

Em $t = 8$, a_3 é escolhido *apesar* de $\hat{Q}(a_3) = 0$: bônus intocado desde a primeira puxada ultrapassou os dos outros dois, que encolheram. O otimismo cobra a dívida de exploração — uma vez.

Atenção

Em $t = 9$, com resultado 0, $U(a_3)$ despenca para 1,517 e o braço sai de cena — ao passo que o ϵ -guloso voltaria a ele em 3,3% dos passos *indefinidamente*.

SEÇÃO 5

A cota de arrependimento do UCB

05

O nível de confiança δ é sutil

- ▶ A cota $\mathbb{P}(\mu > \hat{\mu} + \varepsilon) \leq \delta$ vale para **um** braço, em **um** instante, com n **fixo**.
- ▶ O algoritmo consulta m braços a cada um de T passos, e N é aleatório, escolhido pelo próprio algoritmo.
- ▶ Precisamos que *nenhuma* dessas cotas falhe. União de eventos: $\mathbb{P}(\bigcup_i E_i) \leq \sum_i \mathbb{P}(E_i)$.

Atenção

Todas simultâneas com probabilidade $1 - \delta$: cada cota precisa de risco $\delta/(mT)$. Como δ entra como $\log(1/\delta)$, o preço é apenas $\log(mT)$ — **logarítmico no número de cotas**. União de eventos, brutal como parece, é aceitável aqui.

Intuição

Este é o motivo técnico da escolha $\delta = 1/n^2$ na demonstração a seguir: n passos $\times$ risco $1/n^2$ dá risco total $1/n$, que contribui com $n \cdot \frac{1}{n} = 1$ puxada extra — desprezível.

Cota de arrependimento do UCB — montagem

Sejam $\Delta_i = \mu^* - \mu_i$ e $N_i(n)$ as puxadas do braço i até o passo n . Já sabemos:

$$L_n = \sum_{i: \Delta_i > 0} \Delta_i \mathbb{E}[N_i(n)].$$

Definição — O “bom evento” G_i

A média do braço i nunca ultrapassa sua cota, e a cota do braço ótimo nunca cai abaixo de μ^* :

$$G_i := \left\{ \mu_i \leq \min_t \text{UCB}_i(t, \delta) \right\} \cap \left\{ \mu^* < \min_t \text{UCB}_{a^*}(t, \delta) \right\}, \quad \text{com } \text{UCB}_i(t, \delta) = \hat{Q}_i(t-1) + \sqrt{\frac{2 \log(1/\delta)}{N_{t-1}(i)}}.$$

$$\mathbb{E}[N_i(n)] \leq \underbrace{u_i}_{\text{determinístico}} + \underbrace{\mathbb{P}(G_i^c) n}_{\text{probabilidade minúscula}}, \quad u_i := \frac{2 \log(1/\delta)}{\Delta_i^2}.$$

Intuição

No bom evento: puxadas limitadas por argumento determinístico; fora dele, por n — probabilidade minúscula.

Cota de arrependimento do UCB — o passo central

Afirmação

Se G_i vale, então o braço subótimo $i \neq a^*$ é puxado no máximo $u_i = 2 \log(1/\delta)/\Delta_i^2$ vezes.

Demonstração (por contradição). Suponha G_i e que $N_t(i) > u_i$ em algum instante t em que i seria escolhido. Como o bônus decresce em N ,

$$\text{UCB}_i(t, \delta) \leq \mu_i + \sqrt{\frac{2 \log(1/\delta)}{u_i}} = \mu_i + \sqrt{\Delta_i^2} = \mu_i + \Delta_i = \mu^*.$$

Mas, por definição de G_i , $\mu^* < \text{UCB}_{a^*}(t, \delta)$. Logo $\text{UCB}_i(t, \delta) < \text{UCB}_{a^*}(t, \delta)$ e o braço i **não pode** ser selecionado em t — contradição. □

Intuição

A conta em uma frase: u_i **puxadas encolhem o bônus até ele caber exatamente dentro da lacuna**. A partir daí o otimismo já não consegue disfarçar a inferioridade do braço. Note que $u_i \propto 1/\Delta_i^2$: braços quase tão bons quanto o ótimo são puxados muitas vezes — e isso é *correto*, porque errar entre eles custa pouco.

Cota de arrependimento do UCB — fecho

Tomando $\delta = 1/n^2$: o risco por cota é $1/n^2$, e a união sobre os n instantes dá $\mathbb{P}(G_i^c) \leq n\delta = 1/n$. Assim

$$\mathbb{E}[N_i(n)] \leq \frac{2 \log(n^2)}{\Delta_i^2} + n \cdot \frac{1}{n} = \frac{4 \log n}{\Delta_i^2} + 1,$$

e portanto

Cota dependente do problema

$$L_n \lesssim \sum_{i: \Delta_i > 0} \frac{4 \log n}{\Delta_i} + \sum_i \Delta_i.$$

Intuição

Logarítmico em n — a ordem do piso de Lai e Robbins. O UCB é ótimo em taxa; a diferença está na constante.

Atenção

O segundo somatório é o custo irreduzível de puxar cada braço uma vez. E a cota *explode* quando $\Delta_i \rightarrow 0$: não pode ser a história toda.

A cota independente do problema

Cota anterior inútil com lacuna minúscula. Solução: **partir os braços em dois grupos** num limiar Δ à escolha.

$$L_n \leq \underbrace{n\Delta}_{\substack{\text{braços com } \Delta_i \leq \Delta: \\ \text{errar custa pouco}}} + \underbrace{\sum_{i: \Delta_i > \Delta} \frac{4 \log n}{\Delta_i}}_{\substack{\text{braços com } \Delta_i > \Delta: \\ \text{são descartados rápido}} \leq n\Delta + \frac{4m \log n}{\Delta}.$$

Minimizando em Δ : $\Delta^* = \sqrt{4m \log n / n}$

Cota de pior caso

$$L_n \leq 4\sqrt{m n \log n} = O(\sqrt{m n \log n}).$$

Intuição

Piso minimax $\Omega(\sqrt{mn})$: UCB1 a um fator $\sqrt{\log n}$ (MOSS, KL-UCB eliminam). **O mesmo algoritmo** satisfaz as duas cotas: adapta-se sozinho à dificuldade do problema.

Verificando as cotas nos números do exemplo

$m = 3$, $\Delta = (0; 0,05; 0,85)$, $n = 1000$

Referência	L_{1000}
Piso de Lai–Robbins	≈ 19
Cota do UCB, dependente do problema	≈ 586
Cota do UCB, independente do problema	≈ 576
Guloso (travado em a_2)	≈ 50
ϵ -guloso, $\epsilon = 0,1$	≈ 30

Atenção

Cotas do UCB piores que o desempenho observado dos métodos ingênuos — não é erro: cota de *pior caso* vale para todo bandido com estas lacunas; números do guloso, para esta realização.

Intuição

A comparação honesta é assintótica: em $n = 10^6$ o guloso paga 5×10^4 e o ϵ -guloso 3×10^4 , ambos lineares, contra $\approx 1,2 \times 10^3$ da cota do UCB. As curvas se cruzam — e nunca mais se reencontram.

SEÇÃO 6

Variações e encerramento

06

Teste sua compreensão: e se usássemos a cota *inferior*?

Teste sua compreensão

Uma alternativa seria escolher sempre o braço de maior **cota inferior** de confiança, $a_t = \arg \max_a [\hat{Q}(a) - \sqrt{2 \log(1/\delta)/N_t(a)}]$. Isso garante arrependimento baixo? Considere o caso de dois braços. *Pergunta para discussão conduzida em aula.*

Teste sua compreensão: e se usássemos a cota inferior?

Teste sua compreensão

Uma alternativa seria escolher sempre o braço de maior **cota inferior** de confiança, $a_t = \arg \max_a [\hat{Q}(a) - \sqrt{2 \log(1/\delta)/N_t(a)}]$. Isso garante arrependimento baixo? Considere o caso de dois braços. *Pergunta para discussão conduzida em aula.*

Resposta

Não — é pior que o guloso. O bônus vira *penalidade* por incerteza: braços pouco testados ficam artificialmente ruins, e são justamente os que precisavam ser testados. Com $\mu_1 = 0,5$, $\mu_2 = 0,6$ e puxadas iniciais $r_1 = 1$, $r_2 = 0$, temos $LCB_1 = 1 - c > LCB_2 = -c$. Cada nova puxada de a_1 encolhe sua penalidade ($LCB_1 \rightarrow 0,5$), enquanto LCB_2 fica congelado. O braço 2 nunca mais é testado: arrependimento $0,1 T$.

Intuição

O otimismo é autocorretivo; o pessimismo, autoconfirmatório. (O pessimismo tem seu lugar em RL *offline*, onde não se pode testar hipóteses e evitar o desconhecido é o que se deseja.)

Uma segunda família: casamento de probabilidade

Definição — Arrependimento bayesiano

Coloque uma *priori* $p(\theta)$ sobre os parâmetros do bandido e meça a média do arrependimento sob ela:

$$\text{BayesReg}_T = \mathbb{E}_{\theta \sim p}[L_T(\theta)].$$

Critério mais brando que o de pior caso — e que admite algoritmos notavelmente simples.

Algoritmo — Amostragem de Thompson (Thompson, 1933)

A cada passo: **(1)** amostre um parâmetro da posteriori, $\tilde{\theta}_a \sim p(\theta_a \mid \text{histórico})$ para cada a ; **(2)** aja como se $\tilde{\theta}$ fosse a verdade, $a_t = \arg \max_a Q_{\tilde{\theta}}(a)$; **(3)** observe r_t e atualize a posteriori.

Intuição

Cada braço é escolhido com probabilidade *igual à probabilidade posterior de ele ser o ótimo*. A exploração não é imposta por um bônus — ela emerge da incerteza da posteriori, e desaparece sozinha quando a incerteza some.

Thompson com braços de Bernoulli

Priori conjugada: $\theta_a \sim \text{Beta}(\alpha_a, \beta_a)$. Após observar r , a atualização é contagem pura:

$$\alpha_a \leftarrow \alpha_a + r, \quad \beta_a \leftarrow \beta_a + (1 - r).$$

Com priori uniforme $\text{Beta}(1, 1)$ e as mesmas três primeiras puxadas $(+1, +1, 0)$:

Braço	Posteriori	$\mathbb{E}[\theta]$	$\mathbb{P}(\text{é o melhor})$
a_1	$\text{Beta}(2, 1)$	0,667	0,467
a_2	$\text{Beta}(2, 1)$	0,667	0,467
a_3	$\text{Beta}(1, 2)$	0,333	0,066

Intuição

ϵ -guloso daria 3,3% a a_3 *para sempre*. Thompson dá 6,6% *agora*, quando ainda há dúvida legítima, e essa fração cai sozinha à medida que a posteriori de a_3 se concentra perto de 0,1.

Atenção

$\mathbb{P}(\text{melhor}) \neq$ ordenação das médias: a_3 tem média posterior bem menor, mas 6,6% de chance de ser o melhor — com uma única observação, a cauda ainda é gorda.

Garantias e comparação com o otimismo

Garantias da amostragem de Thompson

Arrependimento bayesiano $O(\sqrt{mT \log T})$. E, embora bayesiano por construção, Thompson também satisfaz cotas *frequentistas* $O(\sum_i \log T / \Delta_i)$, sendo assintoticamente ótimo para braços de Bernoulli (Agrawal e Goyal, 2012; Kaufmann *et al.*, 2012).

Definição — A simetria com o UCB

Ambos escolhem por um valor *plausível*, não pelo esperado. O UCB toma o **quantil superior** da incerteza; Thompson toma uma **amostra** dela. Um é determinístico e pessimista quanto ao risco; o outro é aleatório e calibrado.

Atenção

A aleatoriedade de Thompson é uma vantagem prática subestimada: em sistemas com decisões *em lote* (mil usuários atendidos com a mesma política), o UCB daria a todos o mesmo braço, enquanto Thompson diversifica automaticamente.

Panorama comparativo

Algoritmo	Arrepend.	Parâmetro	Por que falha ou funciona
Guloso	$\Theta(T)$	—	trava; nunca corrige um azar inicial
ϵ -guloso, ϵ fixo	$\Theta(T)$	ϵ	explora uniformemente, para sempre
ϵ_t -guloso, $\epsilon_t \propto 1/t$	$O(\log T)$	c, Δ	ótimo em taxa, mas exige conhecer Δ
ETC	$O(T^{2/3})$	k	separa as fases; não se adapta
UCB1	$O(\log T)$	δ (ou nenhum)	bônus deduzido; adapta-se às lacunas
Thompson	$O(\log T)$	priori	explora na medida da dúvida posterior
<i>Piso (Lai–Robbins)</i>	$\Omega(\log T)$	—	<i>ninguém faz melhor</i>

Intuição

Empiricamente, Thompson costuma bater o UCB1 apesar de garantias semelhantes — o bônus do UCB é calibrado para o pior caso, enquanto a posteriori usa a forma real da incerteza. Em compensação, o UCB não exige escolher uma priori nem amostrar dela.

Resumo da aula

- ▶ O **bandido multi-braços** isola a exploração ao remover as consequências adiadas: um MDP de um estado só.
- ▶ O **arrependimento** $L_T = \sum_a \mathbb{E}[N_T(a)] \Delta_a$ mede o custo da aprendizagem. “Bom” = sublinear.
- ▶ O **guloso** tem arrependimento linear por falta de cobertura; o **ϵ -guloso fixo**, por excesso permanente de exploração.
- ▶ **Lai e Robbins**: nenhum algoritmo faz melhor que $\Omega(\log T)$, com constante Δ_a / D_{KL} .
- ▶ O **otimismo** resolve o dilema sem conhecer as lacunas: o bônus $\sqrt{2 \log(1/\delta) / N}$ sai da concentração, e a demonstração conta quantas puxadas bastam para o bônus caber dentro da lacuna.
- ▶ **UCB1**: $O(\sum_i \log T / \Delta_i)$ e $O(\sqrt{mT \log T})$ — ótimo em taxa nos dois arcabouços.

Intuição

Bandidos são o lugar mais simples para ver estas ideias, mas elas se estendem a MDPs quase sem alteração. **Próxima aula**: exploração em MDPs — aprendizagem PAC, otimismo em modelos (R-MAX, UCRL) e cotas de complexidade amostral.

- ▶ Material adaptado e expandido de **CS234: Reinforcement Learning**, Emma Brunskill, Stanford University; parte da estrutura remonta às notas de David Silver (UCL/DeepMind).
- ▶ **Referência central:** Lattimore & Szepesvári, *Bandit Algorithms* (Cambridge, 2020) — Capítulos 4 a 8 cobrem toda a aula, com as demonstrações completas.
- ▶ Sutton & Barto, *Reinforcement Learning: An Introduction*, 2ª ed., Capítulo 2.
- ▶ **Artigos:** Lai & Robbins (1985); Auer, Cesa-Bianchi & Fischer, *Machine Learning* (2002); Thompson (1933); Agrawal & Goyal (2012); Kaufmann, Korda & Munos (2012); Russo *et al.*, *A Tutorial on Thompson Sampling* (2018).
- ▶ **Expansões desta versão** em relação ao original: bandidos contextuais, explorar-depois-comprometer, leitura numérica do piso de Lai–Robbins, cota independente do problema com a otimização do limiar, contraexemplo detalhado da cota inferior, e a seção de amostragem de Thompson.