

Aula 9: Aprendizagem eficiente em dados I

Bandidos multi-braços • Arrependimento • ϵ -guloso • Otimismo e UCB

Prof. Marcelo Keese Albertini

Adaptado e expandido de Emma Brunskill, CS234: Reinforcement Learning, Stanford University • 2026

Do que trata esta aula. Até agora perguntamos se um algoritmo *converge* para a política ótima. Essa pergunta é surpreendentemente barata: um procedimento que teste cada ação um milhão de vezes e só depois passe a agir bem satisfaz o critério — e é inútil se cada teste custa um paciente, um cliente ou uma hora de robô. A partir de hoje o critério muda para algo mais exigente: **quantos erros o algoritmo comete no caminho?**

Para atacar essa pergunta isolamos o ingrediente responsável por ela. Dos quatro elementos da aprendizagem por reforço — otimização, generalização, consequências adiadas e exploração — retiramos temporariamente as consequências adiadas. O que sobra é o *bandido multi-braços*: simples o bastante para admitir análise exata, e rico o bastante para que as ideias sobrevivam intactas quando as consequências adiadas voltarem, na Aula 10.

1 O cenário: bandidos multi-braços

Definição — Bandido multi-braços

Uma tupla $(\mathcal{A}, \mathcal{R})$ em que $\mathcal{A}$ é um conjunto *conhecido* de m ações (“braços”) e $\mathcal{R}_a(r) = \mathbb{P}[r \mid a]$ é uma distribuição de recompensas *desconhecida*, uma para cada braço. A cada passo t o agente escolhe $a_t \in \mathcal{A}$ e o ambiente devolve $r_t \sim \mathcal{R}_{a_t}$. O objetivo é maximizar $\sum_{\tau=1}^T r_\tau$.

Um bandido é um MDP de **um único estado**: todas as ações levam de volta ao mesmo lugar. Não há dinâmica a aprender, não há desconto, não há crédito a atribuir ao longo do tempo. O único acoplamento entre passos é **informacional** — o que aprendi ontem muda o que escolho hoje, mas não muda o problema que enfrento hoje.

Vale situar o objeto numa escala de generalidade:

Modelo	Estado	Consequência adiada
Bandido	inexistente	não
Bandido contextual	sorteado i.i.d. a cada passo	não
MDP	evolui em função da ação	sim

A exploração é difícil nos três casos, mas por razões distintas. No bandido, basta decidir *o que testar*. No MDP é preciso decidir também *como chegar* até onde vale a pena testar — o que se chama exploração profunda, e que é substancialmente mais difícil.

Exemplo condutor

Decidir o melhor tratamento para pacientes com fratura de dedo do pé, com três opções: cirurgia (a_1), imobilização com esparadrapo no dedo vizinho (a_2) e não fazer nada (a_3). O desfecho é

binário — o dedo consolidou (+1) ou não (0) após seis semanas, avaliado por radiografia. Cada braço é uma Bernoulli com parâmetro desconhecido θ_i .

Atenção

Exemplo fictício. Os valores $\theta = (0,95; 0,90; 0,10)$ usados adiante não representam a eficácia real de nenhum tratamento ortopédico; servem apenas para que nós possamos calcular quantidades que o algoritmo não conhece.

Para discutir em aula

Ao modelar isso como bandido de três braços, é verdade que “puxar um braço corresponde a o dedo ter consolidado ou não”? E que “o bandido é melhor que um MDP porque tratar cada paciente envolve múltiplas decisões”?

Direção da resposta: as duas são falsas. Puxar o braço é **escolher o tratamento**; a consolidação é a *recompensa*, não a ação — confundir os dois é o erro de modelagem mais comum entre iniciantes. E o bandido serve justamente porque cada paciente envolve *uma* única decisão, sem estado que evolua. O que é verdade é que, com $\theta_i \in (0, 1)$, o desfecho permanece aleatório mesmo com o tratamento fixado — é essa aleatoriedade que torna a estimação necessária.

2 O algoritmo guloso e por que ele falha

Algoritmo — Guloso

Estime cada valor de ação por Monte Carlo e escolha o máximo:

$$\hat{Q}_t(a) = \frac{1}{N_t(a)} \sum_{i=1}^t r_i \mathbf{1}(a_i = a) \approx Q(a) = \mathbb{E}[R(a)], \quad a_t = \arg \max_{a \in \mathcal{A}} \hat{Q}_{t-1}(a).$$

Na forma incremental, sem armazenar o histórico: $\hat{Q}_t(a_t) = \hat{Q}_{t-1}(a_t) + \frac{1}{N_t(a_t)}(r_t - \hat{Q}_{t-1}(a_t))$ — o molde de sempre, com $\alpha = 1/N$.

Considere a execução em que cada braço é amostrado uma vez e os resultados são 0, +1, 0, respectivamente. As estimativas ficam $\hat{Q} = (0, 1, 0)$, o máximo é único, e o guloso escolhe a_2 com probabilidade 1. A partir daí, $\hat{Q}(a_2)$ converge para $0,9 > 0$ enquanto os outros dois permanecem congelados em zero, porque nunca mais são testados.

Atenção

O guloso jamais encontrará o melhor braço. A cirurgia — de fato superior — foi eliminada por um único paciente azarado. A falha não é de estimação: o estimador de Monte Carlo é não viesado. A falha é de **cobertura**. Ele é não viesado apenas para os braços que continuam sendo amostrados.

3 Arrependimento: o critério formal

Definição — Arrependimento (regret)

Com $Q(a) = \mathbb{E}[r \mid a]$ e $V^* = Q(a^*) = \max_a Q(a)$, a perda de oportunidade de um passo é $\ell_t = \mathbb{E}[V^* - Q(a_t)]$, e o **arrependimento total** até t é

$$L_t = \mathbb{E} \left[\sum_{\tau=1}^t V^* - Q(a_\tau) \right].$$

A esperança é tomada sobre a política de decisão usada para escolher a_τ (e sobre a aleatoriedade das recompensas, que a alimenta).

Maximizar a recompensa acumulada e minimizar o arrependimento total são o mesmo objetivo: diferem por um sinal e pelo deslocamento constante tV^* . A vantagem de trabalhar com o arrependimento é que ele já vem descontado da dificuldade intrínseca do ambiente, e por isso é **comparável entre problemas**.

A decomposição que organiza tudo

Agrupando os termos por ação em vez de por instante:

$$L_t = \mathbb{E} \left[\sum_{\tau=1}^t V^* - Q(a_\tau) \right] = \sum_{a \in \mathcal{A}} \mathbb{E}[N_t(a)] (V^* - Q(a)) = \sum_{a \in \mathcal{A}} \mathbb{E}[N_t(a)] \Delta_a,$$

onde $N_t(a)$ é a contagem de escolhas de a e $\Delta_a = V^* - Q(a)$ é a **lacuna** do braço a .

Intuição

Um bom algoritmo mantém **contagens pequenas onde as lacunas são grandes**. O obstáculo é que as lacunas são exatamente o que não se sabe — se soubéssemos Δ_a , não haveria nada a aprender. Toda a dificuldade da exploração cabe nessa frase.

Note também o que *não* é preciso: estimar Q com precisão em todo braço. Basta estimar bem o suficiente para **ordenar** — e ordenar exige poucas amostras onde a lacuna é grande, muitas onde ela é pequena. Essa assimetria reaparecerá literalmente na cota do UCB, como $1/\Delta_i^2$.

Uma tabela e uma armadilha

Com $\theta = (0,95; 0,90; 0,10)$, temos $\Delta = (0; 0,05; 0,85)$. Para uma sequência de cinco decisões:

Ação	Ação ótima	Recompensa obs.	Arrepend. do passo	Acumulado
a_1	a_1	0	0,00	0,00
a_2	a_1	1	0,05	0,05
a_3	a_1	0	0,85	0,90
a_2	a_1	1	0,05	0,95
a_2	a_1	0	0,05	1,00

Atenção

Olhe as linhas 2 e 4: a recompensa observada foi +1 e mesmo assim houve arrependimento.

(continua)

O arrependimento não compara com o que aconteceu, mas com o que aconteceria *em média* sob a melhor ação. Um resultado feliz obtido com a ação errada continua sendo um erro — e é essa a razão de o arrependimento ser o critério certo para decisões repetidas.

Se o guloso permanecer em a_2 , cada passo adicional custa 0,05 e $L_T \approx 0,05 T$: **arrependimento linear**, curva que nunca achata.

O que se pode e o que não se pode medir

Em qualquer aplicação real **não é possível calcular o arrependimento**: ele exige conhecer a recompensa esperada da melhor ação, que é a incógnita. A tabela acima só pôde ser preenchida porque nós fixamos θ . O que se faz em vez disso é demonstrar uma **cota superior** válida em *qualquer* problema de uma dada classe. Há dois sabores:

Tipo de cota	Função de	Caráter
Independente do problema	T e m apenas, e.g. $O(\sqrt{mT \log T})$	garantia de pior caso
Dependente do problema	lacunas Δ_a , e.g. $O(\sum_a \log T / \Delta_a)$	afiada em problemas fáceis

O critério de qualidade é **sublinearidade**: $L_T/T \rightarrow 0$, ou seja, a fração de decisões erradas tende a zero.

4 ϵ -guloso: as duas formas de falhar**Algoritmo — ϵ -guloso**

Com probabilidade $1 - \epsilon$ escolha $a_t = \arg \max_a \hat{Q}_t(a)$; com probabilidade ϵ escolha uniformemente ao acaso.

O algoritmo resolve o problema de cobertura: todo braço é amostrado infinitas vezes, logo $\hat{Q}_t(a) \rightarrow Q(a)$ para todo a . O preço é permanente. Retomando o exemplo, se as três primeiras puxadas derem $(+1, +1, 0)$ e $\epsilon = 0,1$, então (com empates resolvidos uniformemente)

$$\mathbb{P}(a_1) = \mathbb{P}(a_2) = \underbrace{\frac{0,9}{2}}_{\text{parte gulosa}} + \underbrace{\frac{0,1}{3}}_{\text{parte aleatória}} = 0,4833, \quad \mathbb{P}(a_3) = \frac{0,1}{3} = 0,0333.$$

Cerca de um paciente em trinta receberá “não fazer nada” — um tratamento que já sabemos ser péssimo — e isso continuará valendo depois de dez mil pacientes.

Para discutir em aula

Assumindo que exista a com $\Delta_a > 0$: o ϵ -guloso com $\epsilon = 0,1$ pode ter arrependimento linear? E com $\epsilon = 0$?

Direção da resposta: as duas, e por motivos opostos — que é o ponto da pergunta. Com $\epsilon = 0,1$ o algoritmo explora **demais**, puxando braços ruins numa fração fixa ϵ/m dos passos para sempre, de modo que $L_T \geq \frac{\epsilon}{m} (\sum_a \Delta_a) T$. Com $\epsilon = 0$ ele explora **de menos**: é o guloso, que trava. No exemplo dos dedos, a taxa com $\epsilon = 0,1$ é $\frac{0,1}{3} (0,05 + 0,85) = 0,03$ por passo.

ϵ decrescente (Auer, Cesa-Bianchi e Fischer, 2002)

Seja $\Delta = \min_{a: \Delta_a > 0} \Delta_a$. Com o agendamento $\epsilon_t = \min\{1, cm/(\Delta^2 t)\}$ para $c > 0$ apropriado, o ϵ_t -guloso atinge arrependimento **logarítmico** em T .

Atenção

O agendamento ótimo depende de Δ , que é desconhecido — é a mesma quantidade que gostaríamos de estimar. Por isso o ϵ -guloso decrescente é teoricamente correto mas praticamente frágil: erra-se o agendamento e volta-se a uma das duas falhas. Isso motiva procurar um método que se calibre sozinho.

Interlúdio: explorar-depois-comprometer

O algoritmo mais simples com arrependimento sublinear puxa cada braço exatamente k vezes e depois se compromete para sempre com o de maior média empírica. Com recompensas 1-sub-gaussianas e dois braços,

$$L_T \leq \underbrace{k\Delta}_{\text{custo pago de explorar}} + \underbrace{(T - 2k)\Delta \exp(-k\Delta^2/4)}_{\text{risco de comprometer-se errado}},$$

e otimizando k e depois o pior Δ obtém-se $L_T = O(T^{2/3})$.

Sublinear, portanto “bom” pelo nosso critério — mas $T^{2/3}$ está longe de $\sqrt{T}$. A perda vem de **separar** exploração e exploração em fases estanques: o ETC não usa o que aprendeu *durante* a exploração para abandonar cedo um braço obviamente ruim. A lição que organiza o resto da aula é que **exploração e exploração devem ser entrelaçadas, não sequenciadas**.

5 Quão bom é possível ser**Teorema (Lai e Robbins, 1985)**

Para qualquer algoritmo consistente, o arrependimento total assintótico é ao menos logarítmico:

$$\lim_{t \rightarrow \infty} L_t \geq \log t \sum_{a: \Delta_a > 0} \frac{\Delta_a}{D_{\text{KL}}(\mathcal{R}_a \| \mathcal{R}_{a^*})}.$$

A dificuldade de um problema de bandido é a *semelhança* entre o braço ótimo e os demais: problemas difíceis têm braços que parecem iguais mas têm médias diferentes. A divergência D_{KL} mede exatamente quantas amostras são necessárias para distinguir duas distribuições.

Para braços de Bernoulli, $D_{\text{KL}}(\theta_a \| \theta_*) = \theta_a \log \frac{\theta_a}{\theta_*} + (1 - \theta_a) \log \frac{1 - \theta_a}{1 - \theta_*}$, o que nos dá, no exemplo:

Braço	θ_a	Δ_a	$D_{\text{KL}}(\theta_a \ 0,95)$	Δ_a / D_{KL}
esparadrapo a_2	0,90	0,05	0,0207	2,42
nada a_3	0,10	0,85	2,3762	0,36

Intuição

A inversão é o que vale reter: o braço **quase tão bom** (a_2 , lacuna minúscula) contribui *sete vezes mais* para o piso do que o braço obviamente ruim. Distinguir 0,90 de 0,95 custa muitas amostras; descartar 0,10 custa poucas. Em $T = 1000$ o piso vale $(2,42 + 0,36) \log 1000 \approx 19$,

(continua)

contra ≈ 50 do guloso e ≈ 30 do ϵ -guloso fixo. Há bastante espaço — e o limite inferior ser *sublinear* é a boa notícia disfarçada de má.

6 Otimismo diante da incerteza

Definição — O princípio

Escolha ações que **poderiam** ter valor alto — não as que *parecem* ter valor alto.

A justificativa é que só há dois desfechos possíveis, e ambos são bons. Se o braço de fato tem média alta, colhemos recompensa alta e não há arrependimento. Se tem média baixa, puxá-lo reduz em esperança tanto sua média estimada quanto a incerteza sobre ela — o braço é rebaixado e não volta a enganar.

Intuição

O otimismo é **autocorretivo**: só se pode estar excessivamente otimista sobre um braço por um número *limitado* de puxadas, porque cada puxada corrige o excesso. Essa contagem — “quantas vezes posso me enganar antes de ser desmentido?” — é literalmente a demonstração da cota, como se verá.

De onde sai a largura da barra de confiança

Definição — Variável σ -sub-gaussiana

X com $\mathbb{E}[X] = 0$ é σ -sub-gaussiana se $\mathbb{E}[e^{\lambda X}] \leq e^{\lambda^2 \sigma^2 / 2}$ para todo $\lambda \in \mathbb{R}$; isto é, sua cauda decai ao menos tão rápido quanto a de uma gaussiana de desvio σ .

Corolário 5.5 (Lattimore e Szepesvári, *Bandit Algorithms*)

Sejam $X_i - \mu$ independentes e σ -sub-gaussianas, e $\hat{\mu} = \frac{1}{n} \sum_{t=1}^n X_t$. Então, para todo $\varepsilon \geq 0$,

$$\mathbb{P}(\hat{\mu} \geq \mu + \varepsilon) \leq \exp\left(-\frac{n\varepsilon^2}{2\sigma^2}\right), \quad \mathbb{P}(\hat{\mu} \leq \mu - \varepsilon) \leq \exp\left(-\frac{n\varepsilon^2}{2\sigma^2}\right).$$

Recompensas em $[0, 1]$ — como as do exemplo — são $\frac{1}{2}$ -sub-gaussianas pelo lema de Hoeffding; adotar $\sigma = 1$, como faremos, é apenas conservador: as barras saem mais largas que o necessário, nunca mais estreitas.

A desigualdade responde “qual a probabilidade de errar por ε ?”. O que queremos é a pergunta operacional invertida: dado um risco δ que aceito correr, qual ε ? Basta igualar e resolver:

$$\delta = \exp\left(-\frac{n\varepsilon^2}{2\sigma^2}\right) \iff \varepsilon = \sqrt{\frac{2\sigma^2 \log(1/\delta)}{n}} \implies \mu \leq \hat{\mu} + \sqrt{\frac{2\sigma^2 \log(1/\delta)}{n}} \text{ com prob. } \geq 1 - \delta.$$

Atenção

Esta é uma cota **unilateral**. Para controlar $|\hat{\mu} - \mu|$ é preciso aplicar as duas caudas com união de eventos: tomando $\delta' = \delta/2$, com probabilidade ao menos $1 - \delta$ vale $|\mu - \hat{\mu}| \leq \sqrt{2\sigma^2 \log(2/\delta)/n}$. Confundir as duas é o erro mais comum ao implementar intervalos de confiança em bandidos.

Algoritmo — UCB1 (Auer, Cesa-Bianchi e Fischer, 2002)

Supondo recompensas 1-sub-gaussianas,

$$a_t = \arg \max_{a \in \mathcal{A}} \left[\underbrace{\hat{Q}(a)}_{\text{exploração}} + \underbrace{\sqrt{\frac{2 \log(1/\delta)}{N_t(a)}}}_{\text{bônus de exploração}} \right].$$

Braços nunca testados têm bônus infinito, de modo que o algoritmo começa amostrando cada braço uma vez.

O bônus não é um parâmetro de ajuste: ele é *deduzido* da desigualdade de concentração. Com δ fixo, porém, ele não encolhe com o tempo; tomando $\delta = 1/t^2$ obtém-se a versão *anytime* $\hat{Q}(a) + \sqrt{4 \log t / N_t(a)}$, que é a fórmula clássica usada na prática.

O UCB1 no exemplo, passo a passo

Com $\delta = 0,1$ o bônus vale $2,146/\sqrt{N(a)}$. Partindo das três puxadas iniciais com resultados $(+1, +1, 0)$:

t	$U(a_1)$	$U(a_2)$	$U(a_3)$	escolhe	r	arrep. acum.
3	3,146	3,146	2,146	a_1	+1	0,90
4	2,517	3,146	2,146	a_2	+1	0,95
5	2,517	2,517	2,146	a_1	+1	0,95
6	2,239	2,517	2,146	a_2	0	1,00
7	2,239	1,906	2,146	a_1	+1	1,00
8	2,073	1,906	2,146	a_3	0	1,85
9	2,073	1,906	1,517	a_1	+1	1,85

Duas linhas merecem atenção. Em $t = 8$ o braço a_3 é escolhido *apesar* de $\hat{Q}(a_3) = 0$: seu bônus, intocado desde a primeira puxada, acabou ultrapassando os índices dos outros dois, que encolheram com as puxadas repetidas. O otimismo cobra a dívida de exploração — *uma* vez. Em $t = 9$, com o resultado 0, o índice de a_3 despenca para 1,517 e o braço sai de cena. Compare com o ϵ -guloso, que voltaria a a_3 em 3,3% dos passos indefinidamente.

7 A cota de arrependimento do UCB

Antes da demonstração, um ponto técnico que costuma ser subestimado. A cota $\mathbb{P}(\mu > \hat{\mu} + \epsilon) \leq \delta$ vale para *um* braço, em *um* instante, com n fixo. O algoritmo, porém, consulta m braços a cada um de n passos, e as contagens são aleatórias — escolhidas pelo próprio algoritmo. Precisamos que *nenhuma* dessas cotas falhe, o que se obtém por união de eventos, $\mathbb{P}(\bigcup_i E_i) \leq \sum_i \mathbb{P}(E_i)$.

Intuição

A união de eventos parece cara, mas não é: como δ entra na fórmula por meio de $\log(1/\delta)$, exigir $\delta/(mn)$ em vez de δ custa apenas $\log(mn)$ — **logarítmico no número de cotas**. É isso que torna a escolha $\delta = 1/n^2$ inofensiva: risco total $n \cdot 1/n^2 = 1/n$, que se traduz em uma única puxada extra em esperança.

Demonstração

Sejam $\Delta_i = \mu^* - \mu_i$ e $N_i(n)$ o número de puxadas do braço i até o passo n . Sabemos que $L_n = \sum_{i: \Delta_i > 0} \Delta_i \mathbb{E}[N_i(n)]$, de modo que basta limitar as contagens.

(continua)

Bom evento. Defina

$$G_i := \left\{ \mu_i \leq \min_t \text{UCB}_i(t, \delta) \right\} \cap \left\{ \mu^* < \min_t \text{UCB}_{a^*}(t, \delta) \right\}, \quad \text{UCB}_i(t, \delta) = \hat{Q}_i(t-1) + \sqrt{\frac{2 \log(1/\delta)}{N_{t-1}(i)}}.$$

A estratégia é: *no bom evento, limitar as puxadas por um argumento determinístico; fora dele, limitar por n e mostrar que sua probabilidade é minúscula.* Formalmente, $\mathbb{E}[N_i(n)] \leq u_i + \mathbb{P}(G_i^c) n$, com $u_i := 2 \log(1/\delta) / \Delta_i^2$.

Afirmção. Se G_i vale, o braço subótimo $i \neq a^*$ é puxado no máximo u_i vezes.

Demonstração (por contradição). Suponha G_i e que $N_t(i) > u_i$ em algum instante t no qual i seria escolhido. Como o bônus é decrescente em N ,

$$\text{UCB}_i(t, \delta) \leq \mu_i + \sqrt{\frac{2 \log(1/\delta)}{u_i}} = \mu_i + \sqrt{\Delta_i^2} = \mu_i + \Delta_i = \mu^*.$$

Mas, por definição de G_i , tem-se $\mu^* < \text{UCB}_{a^*}(t, \delta)$. Logo $\text{UCB}_i(t, \delta) < \text{UCB}_{a^*}(t, \delta)$ e o braço i não pode ser selecionado em t — contradição. $\square$

Fecho. Tomando $\delta = 1/n^2$, a união sobre os n instantes dá $\mathbb{P}(G_i^c) \leq n\delta = 1/n$, e portanto

$$\mathbb{E}[N_i(n)] \leq \frac{2 \log(n^2)}{\Delta_i^2} + n \cdot \frac{1}{n} = \frac{4 \log n}{\Delta_i^2} + 1 \Rightarrow L_n \lesssim \sum_{i: \Delta_i > 0} \frac{4 \log n}{\Delta_i} + \sum_i \Delta_i.$$

Intuição

A conta em uma frase: u_i **puxadas encolhem o bônus até ele caber exatamente dentro da lacuna**; a partir daí o otimismo já não consegue disfarçar a inferioridade do braço. E note $u_i \propto 1/\Delta_i^2$ — braços quase tão bons quanto o ótimo são puxados *muitas* vezes. Isso não é um defeito: errar entre eles custa pouco, e a cota de arrependimento envolve $\Delta_i \cdot u_i \propto 1/\Delta_i$, que continua controlado.

Da cota dependente à cota de pior caso

A cota acima é inútil quando alguma lacuna é minúscula, pois $1/\Delta_i$ explode. A saída é **partir os braços em dois grupos** num limiar Δ escolhido por nós:

$$L_n \leq \underbrace{n\Delta}_{\text{braços com } \Delta_i \leq \Delta: \text{errar custa pouco}} + \underbrace{\sum_{i: \Delta_i > \Delta} \frac{4 \log n}{\Delta_i}}_{\text{braços com } \Delta_i > \Delta: \text{descartados rápido}} \leq n\Delta + \frac{4m \log n}{\Delta}.$$

Derivando em Δ e igualando a zero obtém-se $\Delta^* = \sqrt{4m \log n/n}$, e portanto $L_n \leq 4\sqrt{m n \log n} = O(\sqrt{m n \log n})$.

Intuição

O piso minimax é $\Omega(\sqrt{mn})$: o UCB1 fica a um fator $\sqrt{\log n}$ do ótimo, eliminável por variantes (MOSS, KL-UCB). E o mesmo algoritmo, sem alteração alguma, satisfaz *as duas cotas simultaneamente* — ele se adapta sozinho à dificuldade do problema, o que é exatamente o que se pedia e o que nem o ϵ_t -guloso nem o ETC entregam.

Uma comparação que precisa ser lida com cuidado

Referência ($m = 3, \Delta = (0; 0,05; 0,85), n = 1000$)	L_{1000}
Piso de Lai–Robbins	≈ 19
Cota do UCB, dependente do problema	≈ 586
Cota do UCB, independente do problema	≈ 576
Guloso, travado em a_2 (<i>desempenho observado</i>)	≈ 50
ϵ -guloso com $\epsilon = 0,1$ (<i>desempenho observado</i>)	≈ 30

Atenção

As cotas do UCB são *piores* que o desempenho observado dos métodos ingênuos — e isso não é um erro, é o que significa uma cota de **pior caso**. Ela vale para todo bandido de três braços com estas lacunas, inclusive os construídos adversarialmente; os números do guloso valem para esta realização particular. A comparação honesta é assintótica: em $n = 10^6$ o guloso paga 5×10^4 e o ϵ -guloso 3×10^4 , ambos crescendo linearmente, contra $\approx 1,2 \times 10^3$ da cota do UCB, crescendo como $\log n$. As curvas se cruzam e nunca mais se reencontram.

8 Duas variações que valem conhecer

Por que a cota inferior não serve

Para discutir em aula

E se escolhêssemos sempre o braço de maior *cota inferior*, $a_t = \arg \max_a [\hat{Q}(a) - \sqrt{2 \log(1/\delta)/N_t(a)}]$? Isso garante arrependimento baixo? Considere dois braços.

Direção da resposta: não — é pior que o guloso. O bônus vira **penalidade** por incerteza, de modo que braços pouco testados ficam artificialmente ruins; e são justamente os que precisavam ser testados. Com $\mu_1 = 0,5$, $\mu_2 = 0,6$ e puxadas iniciais $r_1 = 1$, $r_2 = 0$, temos $LCB_1 = 1 - c > LCB_2 = -c$, e escolhe-se a_1 . Cada nova puxada de a_1 *encolhe* sua penalidade, e $LCB_1 \rightarrow 0,5$; já LCB_2 permanece congelado em $-c$. O braço 2 nunca mais é testado: arrependimento $0,1 T$, linear. A assimetria é a lição — **o otimismo é autocorretivo, o pessimismo é autoconfirmatório**. (O pessimismo tem seu lugar em RL *offline*, onde não se pode testar hipóteses e evitar o desconhecido é precisamente o que se deseja.)

Amostragem de Thompson

Definição — Arrependimento bayesiano

Com uma *priori* $p(\theta)$ sobre os parâmetros do bandido, $\text{BayesReg}_T = \mathbb{E}_{\theta \sim p}[L_T(\theta)]$. Critério mais brando que o de pior caso, e que admite algoritmos notavelmente simples.

Algoritmo — Amostragem de Thompson (Thompson, 1933)

A cada passo: **(1)** amostre $\tilde{\theta}_a \sim p(\theta_a \mid \text{histórico})$ para cada braço; **(2)** aja *como se* $\tilde{\theta}$ fosse a verdade, $a_t = \arg \max_a Q_{\tilde{\theta}}(a)$; **(3)** observe r_t e atualize a posteriori.

O nome vem da propriedade que a define: cada braço é escolhido com probabilidade igual à *probabilidade posterior de ele ser o ótimo*. A exploração não é imposta por um bônus — emerge da incerteza da posteriori, e desaparece sozinha quando a incerteza some.

Para braços de Bernoulli a priori conjugada é $\theta_a \sim \text{Beta}(\alpha_a, \beta_a)$, e a atualização é contagem pura: $\alpha_a \leftarrow \alpha_a + r$ e $\beta_a \leftarrow \beta_a + (1 - r)$. Com priori uniforme $\text{Beta}(1, 1)$ e as mesmas três primeiras puxadas $(+1, +1, 0)$:

Braço	Posteriori	$\mathbb{E}[\theta]$	$\mathbb{P}(\text{é o melhor})$
a_1	$\text{Beta}(2, 1)$	0,667	0,467
a_2	$\text{Beta}(2, 1)$	0,667	0,467
a_3	$\text{Beta}(1, 2)$	0,333	0,066

Compare com o ϵ -guloso, que daria 3,3% a a_3 *para sempre*: Thompson dá 6,6% *agora*, quando ainda há dúvida legítima, e essa fração cai sozinha à medida que a posteriori se concentra. Note ainda que $\mathbb{P}(\text{é o melhor})$ não é a ordenação das médias — com uma única observação a cauda ainda é gorda.

Garantias

Arrependimento bayesiano $O(\sqrt{mT \log T})$. E, embora bayesiano por construção, Thompson satisfaz também cotas frequentistas $O(\sum_i \log T / \Delta_i)$, sendo assintoticamente ótimo para braços de Bernoulli (Agrawal e Goyal, 2012; Kaufmann, Korda e Munos, 2012).

Intuição

A simetria com o UCB é elegante: ambos escolhem por um valor *plausível*, não pelo esperado. O UCB toma o **quantil superior** da incerteza; Thompson toma uma **amostra** dela. Empiricamente Thompson costuma vencer, porque o bônus do UCB é calibrado para o pior caso enquanto a posteriori usa a forma real da incerteza. Em compensação, o UCB dispensa escolher priori e amostrar dela. Há ainda uma vantagem prática subestimada de Thompson: em decisões *em lote* (mil usuários atendidos com a mesma política), o UCB daria a todos o mesmo braço, enquanto Thompson diversifica automaticamente.

9 Síntese

Algoritmo	Arrepend.	Parâmetro	Por que falha ou funciona
Guloso	$\Theta(T)$	—	trava; nunca corrige um azar inicial
ϵ -guloso, ϵ fixo	$\Theta(T)$	ϵ	explora uniformemente, para sempre
ϵ_t -guloso, $\epsilon_t \propto 1/t$	$O(\log T)$	c, Δ	ótimo em taxa, mas exige conhecer Δ
ETC	$O(T^{2/3})$	k	separa as fases; não se adapta
UCB1	$O(\log T)$	δ	bônus deduzido; adapta-se às lacunas
Thompson	$O(\log T)$	priori	explora na medida da dúvida posterior
Piso (Lai–Robbins)	$\Omega(\log T)$	—	<i>ninguém faz melhor</i>

Atenção

Cinco confusões a evitar.

1. Arrependimento não é “recompensa que deixei de observar”: é comparação com a *média* da melhor ação. Ganhar +1 com a ação errada ainda é arrependimento positivo.
2. Arrependimento não é computável em aplicações reais; o que se computa são cotas.
3. Uma cota superior de pior caso pode ser numericamente pior que o desempenho observado de um método ruim, em horizontes curtos. Isso não invalida a cota.

(continua)

4. A cota de concentração é unilateral; controlar $|\hat{\mu} - \mu|$ exige $\log(2/\delta)$, não $\log(1/\delta)$.
5. δ fixo no UCB não é a versão *anytime*. Sem $\delta = 1/t^2$ (ou equivalente), o bônus não acompanha o crescimento do número de cotas simultâneas.

10 Exercícios

Exercício 9.1 — Decomposição do arrependimento

Demonstre a identidade $\mathbb{E}[\sum_{\tau=1}^t (V^* - Q(a_\tau))] = \sum_a \mathbb{E}[N_t(a)] \Delta_a$ explicitando onde se usa linearidade da esperança e onde se usa a definição de $N_t(a)$.

Exercício 9.2 — Quando o guloso acerta

No exemplo dos dedos, estime por simulação a probabilidade de o guloso acabar travado em cada braço, partindo da rodada inicial de uma puxada por braço (empates resolvidos uniformemente). Antes de simular, escreva a probabilidade que você obteria supondo que o empate inicial se resolve de uma vez; compare com o valor simulado e explique a diferença. Por fim, comente por que uma probabilidade alta de acerto não salva o método.

Exercício 9.3 — Taxa do ϵ -guloso

Mostre que, se a parte gulosa do ϵ -guloso identificar corretamente a^* a partir de certo instante, então $L_T \rightarrow \frac{\epsilon}{m} (\sum_a \Delta_a) T$. Calcule a constante no exemplo com $\epsilon = 0,1$.

Exercício 9.4 — Otimizando o ETC

A partir de $L_T \leq k\Delta + T\Delta e^{-k\Delta^2/4}$, encontre o k ótimo e mostre que, tomando o pior Δ , resulta $L_T = O(T^{2/3})$.

Exercício 9.5 — O bônus e a lacuna

Verifique que $u_i = 2 \log(1/\delta) / \Delta_i^2$ é exatamente o número de puxadas para o qual o bônus iguala a lacuna. Em seguida, calcule u_2 e u_3 do exemplo com $\delta = 1/n^2$ e $n = 1000$, e comente a diferença de ordem de grandeza.

Exercício 9.6 — Implementação

Implemente guloso, ϵ -guloso (ϵ fixo e $\epsilon_t \propto 1/t$), UCB1 e Thompson para o bandido de três braços do exemplo. Rode 200 repetições de $T = 5000$ passos e trace o arrependimento médio acumulado em escala semilogarítmica no eixo horizontal. Confirme que as curvas do UCB e de Thompson ficam retas nessa escala, e as demais não.

Respostas resumidas

9.1. Escreva $V^* - Q(a_\tau) = \sum_a \mathbf{1}(a_\tau = a) \Delta_a$; troque a ordem dos somatórios (finitos, logo lícito) e use a linearidade; reconheça $\sum_\tau \mathbf{1}(a_\tau = a) = N_t(a)$. A esperança só pode entrar depois da troca, porque $N_t(a)$ é aleatório.

9.2. A conta ingênua — repartir o empate inicial uniformemente e declarar o vencedor — dá $\approx 0,50$ para a_1 . A simulação (20 000 execuções) dá $\approx 0,76$ para a_1 , $0,24$ para a_2 e $0,001$ para a_3 . A diferença é instrutiva: **um empate em $\hat{Q} = 1$ não se resolve de uma vez**. O braço sorteado é puxado de novo e, se falhar, sua média cai abaixo da do outro empatado, devolvendo a vez a ele. O empate vira uma disputa que dura enquanto os dois seguirem acertando — e essa disputa favorece quem tem o maior θ , isto é, a_1 . Ainda assim o método não se salva: em $\approx 24\%$ das execuções o arrependimento é linear, e é a *esperança* do arrependimento, não a mediana, que a análise mede. Ela permanece $\Theta(T)$.

9.3. A parte gulosa contribui 0 e a aleatória escolhe cada braço com probabilidade ϵ/m , custando Δ_a cada. No exemplo, $\frac{0,1}{3}(0 + 0,05 + 0,85) = 0,03$ por passo.

9.4. Derivando em k : $\Delta = T \Delta \frac{\Delta^2}{4} e^{-k\Delta^2/4}$, donde $k^* = \frac{4}{\Delta^2} \log \frac{T\Delta^2}{4}$ e $L_T = O\left(\frac{\log(T\Delta^2)}{\Delta}\right)$. Como o pior caso é $\Delta \sim T^{-1/3}$, resulta $O(T^{2/3})$.

9.5. Iguale $\sqrt{2 \log(1/\delta)/u} = \Delta$ e resolva. Com $\delta = 10^{-6}$, $2 \log(1/\delta) = 27,6$: $u_2 = 27,6/0,05^2 \approx 1,1 \times 10^4$ e $u_3 = 27,6/0,85^2 \approx 38$. O braço inequivocamente ruim é descartado em algumas dezenas de puxadas; o braço quase tão bom exigiria mais puxadas do que o horizonte — e é justamente por isso que confundi-lo custa pouco.

9.6. Espera-se ver: guloso e ϵ -guloso de ϵ fixo crescendo linearmente; UCB1 e Thompson formando retas na escala semilog, o que indica $\Theta(\log T)$; e Thompson tipicamente abaixo do UCB1 por um fator constante.

11 Notação e glossário

Símbolo	Leitura	Inglês
L_T	arrependimento total até T	(total) regret
ℓ_t	arrependimento de um passo	per-step regret
Δ_a	lacuna do braço a , $V^* - Q(a)$	gap
$N_t(a)$	contagem de escolhas de a até t	count
$U_t(a)$	cota superior de confiança	upper confidence bound
δ	risco tolerado por cota	confidence level
m	número de braços	number of arms
$D_{\text{KL}}(\cdot \parallel \cdot)$	divergência de Kullback–Leibler	KL divergence
—	braço / bandido multi-braços	arm / multi-armed bandit
—	otimismo diante da incerteza	optimism in the face of uncertainty
—	casamento de probabilidade	probability matching
—	explorar-depois-comprometer	explore-then-commit
—	sub-gaussiana	sub-Gaussian
—	união de eventos	union bound

Intuição

Próxima aula. As mesmas três ideias — arrependimento como critério, otimismo como abordagem, concentração como ferramenta — reaparecem em MDPs, onde é preciso decidir não só o que testar, mas como chegar ao lugar onde vale a pena testar. Veremos aprendizagem

(continua)

PAC, otimismo em modelos (R-MAX, UCRL) e cotas de complexidade amostral.

Leituras. Lattimore & Szepesvári, *Bandit Algorithms* (Cambridge, 2020), capítulos 4 a 8 — referência central, com as demonstrações completas. Sutton & Barto, *Reinforcement Learning: An Introduction*, 2ª ed., capítulo 2. Artigos: Lai & Robbins (1985); Auer, Cesa-Bianchi & Fischer, *Machine Learning* (2002); Thompson (1933); Agrawal & Goyal (2012); Kaufmann, Korda & Munos (2012); Russo et al., *A Tutorial on Thompson Sampling* (2018).