

# Aula 9: Aprendizagem eficiente em dados I

Bandidos multi-braços • Arrependimento •  $\epsilon$ -guloso • Otimismo e UCB

Prof. Marcelo Keese Albertini

Adaptado e expandido de Emma Brunskill, CS234: Reinforcement Learning, Stanford University • 2026

**Do que trata esta aula.** Até agora perguntamos se um algoritmo *converge* para a política ótima. Essa pergunta é surpreendentemente barata: um procedimento que teste cada ação um milhão de vezes e só depois passe a agir bem satisfaz o critério — e é inútil se cada teste custa um paciente, um cliente ou uma hora de robô. A partir de hoje o critério muda para algo mais exigente: **quantos erros o algoritmo comete no caminho?**

Para atacar essa pergunta isolamos o ingrediente responsável por ela. Dos quatro elementos da aprendizagem por reforço — otimização, generalização, consequências adiadas e exploração — retiramos temporariamente as consequências adiadas. O que sobra é o *bandido multi-braços*: simples o bastante para admitir análise exata, e rico o bastante para que as ideias sobrevivam intactas quando as consequências adiadas voltarem, na Aula 10.

## 1 O cenário: bandidos multi-braços

### Definição — Bandido multi-braços

Uma tupla  $(\mathcal{A}, \mathcal{R})$  em que  $\mathcal{A}$  é um conjunto *conhecido* de  $m$  ações (“braços”) e  $\mathcal{R}_a(r) = \mathbb{P}[r \mid a]$  é uma distribuição de recompensas *desconhecida*, uma para cada braço. A cada passo  $t$  o agente escolhe  $a_t \in \mathcal{A}$  e o ambiente devolve  $r_t \sim \mathcal{R}_{a_t}$ . O objetivo é maximizar  $\sum_{\tau=1}^T r_\tau$ .

Um bandido é um MDP de **um único estado**: todas as ações levam de volta ao mesmo lugar. Não há dinâmica a aprender, não há desconto, não há crédito a atribuir ao longo do tempo. O único acoplamento entre passos é **informacional** — o que aprendi ontem muda o que escolho hoje, mas não muda o problema que enfrento hoje.

Vale situar o objeto numa escala de generalidade:

| Modelo             | Estado                       | Consequência adiada |
|--------------------|------------------------------|---------------------|
| Bandido            | inexistente                  | não                 |
| Bandido contextual | sorteado i.i.d. a cada passo | não                 |
| MDP                | evolui em função da ação     | sim                 |

A exploração é difícil nos três casos, mas por razões distintas. No bandido, basta decidir *o que testar*. No MDP é preciso decidir também *como chegar* até onde vale a pena testar — o que se chama exploração profunda, e que é substancialmente mais difícil.

### Exemplo condutor

Decidir o melhor tratamento para pacientes com fratura de dedo do pé, com três opções: cirurgia ( $a_1$ ), imobilização com esparadrapo no dedo vizinho ( $a_2$ ) e não fazer nada ( $a_3$ ). O desfecho é

binário — o dedo consolidou (+1) ou não (0) após seis semanas, avaliado por radiografia. Cada braço é uma Bernoulli com parâmetro desconhecido  $\theta_i$ .

### Atenção

**Exemplo fictício.** Os valores  $\theta = (0,95; 0,90; 0,10)$  usados adiante não representam a eficácia real de nenhum tratamento ortopédico; servem apenas para que *nós* possamos calcular quantidades que o algoritmo não conhece.

### Para discutir em aula

Ao modelar isso como bandido de três braços, é verdade que “puxar um braço corresponde a o dedo ter consolidado ou não”? E que “o bandido é melhor que um MDP porque tratar cada paciente envolve múltiplas decisões”?

*Direção da resposta:* as duas são falsas. Puxar o braço é **escolher o tratamento**; a consolidação é a *recompensa*, não a ação — confundir os dois é o erro de modelagem mais comum entre iniciantes. E o bandido serve justamente porque cada paciente envolve *uma única* decisão, sem estado que evolua. O que é verdade é que, com  $\theta_i \in (0, 1)$ , o desfecho permanece aleatório mesmo com o tratamento fixado — é essa aleatoriedade que torna a estimação necessária.

## 2 O algoritmo guloso e por que ele falha

### Algoritmo — Guloso

Estime cada valor de ação por Monte Carlo e escolha o máximo:

$$\hat{Q}_t(a) = \frac{1}{N_t(a)} \sum_{i=1}^t r_i \mathbf{1}(a_i = a) \approx Q(a) = \mathbb{E}[R(a)], \quad a_t = \arg \max_{a \in \mathcal{A}} \hat{Q}_{t-1}(a).$$

Na forma incremental, sem armazenar o histórico:  $\hat{Q}_t(a_t) = \hat{Q}_{t-1}(a_t) + \frac{1}{N_t(a_t)}(r_t - \hat{Q}_{t-1}(a_t))$  — o molde de sempre, com  $\alpha = 1/N$ .

Considere a execução em que cada braço é amostrado uma vez e os resultados são 0, +1, 0, respectivamente. As estimativas ficam  $\hat{Q} = (0, 1, 0)$ , o máximo é único, e o guloso escolhe  $a_2$  com probabilidade 1. A partir daí,  $\hat{Q}(a_2)$  converge para 0,9 > 0 enquanto os outros dois permanecem congelados em zero, porque nunca mais são testados.

### Atenção

**O guloso jamais encontrará o melhor braço.** A cirurgia — de fato superior — foi eliminada por um único paciente azarado. A falha não é de estimação: o estimador de Monte Carlo é não viesado. A falha é de **cobertura**. Ele é não viesado apenas para os braços que continuam sendo amostrados.

### 3 Arrependimento: o critério formal

#### Definição — Arrependimento (*regret*)

Com  $Q(a) = \mathbb{E}[r \mid a]$  e  $V^* = Q(a^*) = \max_a Q(a)$ , a perda de oportunidade de um passo é  $\ell_t = \mathbb{E}[V^* - Q(a_t)]$ , e o **arrependimento total** até  $t$  é

$$L_t = \mathbb{E} \left[ \sum_{\tau=1}^t V^* - Q(a_\tau) \right].$$

A esperança é tomada sobre a política de decisão usada para escolher  $a_\tau$  (e sobre a aleatoriedade das recompensas, que a alimenta).

Maximizar a recompensa acumulada e minimizar o arrependimento total são o mesmo objetivo: diferem por um sinal e pelo deslocamento constante  $tV^*$ . A vantagem de trabalhar com o arrependimento é que ele já vem descontado da dificuldade intrínseca do ambiente, e por isso é **comparável entre problemas**.

#### A decomposição que organiza tudo

Agrupando os termos por ação em vez de por instante:

$$L_t = \mathbb{E} \left[ \sum_{\tau=1}^t V^* - Q(a_\tau) \right] = \sum_{a \in \mathcal{A}} \mathbb{E}[N_t(a)] (V^* - Q(a)) = \sum_{a \in \mathcal{A}} \mathbb{E}[N_t(a)] \Delta_a,$$

onde  $N_t(a)$  é a contagem de escolhas de  $a$  e  $\Delta_a = V^* - Q(a)$  é a **lacuna** do braço  $a$ .

#### Intuição

Um bom algoritmo mantém **contagens pequenas onde as lacunas são grandes**. O obstáculo é que as lacunas são exatamente o que não se sabe — se soubéssemos  $\Delta_a$ , não haveria nada a aprender. Toda a dificuldade da exploração cabe nessa frase.

Note também o que *não* é preciso: estimar  $Q$  com precisão em todo braço. Basta estimar bem o suficiente para **ordenar** — e ordenar exige poucas amostras onde a lacuna é grande, muitas onde ela é pequena. Essa assimetria reaparecerá literalmente na cota do UCB, como  $1/\Delta_i^2$ .

#### Uma tabela e uma armadilha

Com  $\theta = (0,95; 0,90; 0,10)$ , temos  $\Delta = (0; 0,05; 0,85)$ . Para uma sequência de cinco decisões:

| Ação  | Ação ótima | Recompensa obs. | Arrepend. do passo | Acumulado |
|-------|------------|-----------------|--------------------|-----------|
| $a_1$ | $a_1$      | 0               | 0,00               | 0,00      |
| $a_2$ | $a_1$      | 1               | 0,05               | 0,05      |
| $a_3$ | $a_1$      | 0               | 0,85               | 0,90      |
| $a_2$ | $a_1$      | 1               | 0,05               | 0,95      |
| $a_2$ | $a_1$      | 0               | 0,05               | 1,00      |

#### Atenção

Olhe as linhas 2 e 4: **a recompensa observada foi +1 e mesmo assim houve arrependimento**. O arrependimento não compara com o que aconteceu, mas com o que

**(continua)**

aconteceria *em média* sob a melhor ação. Um resultado feliz obtido com a ação errada continua sendo um erro — e é essa a razão de o arrependimento ser o critério certo para decisões repetidas.

Se o guloso permanecer em  $a_2$ , cada passo adicional custa 0,05 e  $L_T \approx 0,05 T$ : **arrependimento linear**, curva que nunca achata.

**O que se pode e o que não se pode medir**

Em qualquer aplicação real **não é possível calcular o arrependimento**: ele exige conhecer a recompensa esperada da melhor ação, que é a incógnita. A tabela acima só pôde ser preenchida porque nós fixamos  $\theta$ . O que se faz em vez disso é demonstrar uma **cota superior** válida em *qualquer* problema de uma dada classe. Há dois sabores:

| Tipo de cota             | Função de                                               | Caráter                    |
|--------------------------|---------------------------------------------------------|----------------------------|
| Independente do problema | $T$ e $m$ apenas, e.g. $O(\sqrt{mT \log T})$            | garantia de pior caso      |
| Dependente do problema   | lacunas $\Delta_a$ , e.g. $O(\sum_a \log T / \Delta_a)$ | afiada em problemas fáceis |

O critério de qualidade é **sublinearidade**:  $L_T/T \rightarrow 0$ , ou seja, a fração de decisões erradas tende a zero.

**4  $\epsilon$ -guloso: as duas formas de falhar****Algoritmo —  $\epsilon$ -guloso**

Com probabilidade  $1 - \epsilon$  escolha  $a_t = \arg \max_a \hat{Q}_t(a)$ ; com probabilidade  $\epsilon$  escolha uniformemente ao acaso.

O algoritmo resolve o problema de cobertura: todo braço é amostrado infinitas vezes, logo  $\hat{Q}_t(a) \rightarrow Q(a)$  para todo  $a$ . O preço é permanente. Retomando o exemplo, se as três primeiras puxadas derem  $(+1, +1, 0)$  e  $\epsilon = 0,1$ , então (com empates resolvidos uniformemente)

$$\mathbb{P}(a_1) = \mathbb{P}(a_2) = \underbrace{\frac{0,9}{2}}_{\text{parte gulosa}} + \underbrace{\frac{0,1}{3}}_{\text{parte aleatória}} = 0,4833, \quad \mathbb{P}(a_3) = \frac{0,1}{3} = 0,0333.$$

Cerca de um paciente em trinta receberá “não fazer nada” — um tratamento que já sabemos ser péssimo — e isso continuará valendo depois de dez mil pacientes.

**Para discutir em aula**

Assumindo que exista  $a$  com  $\Delta_a > 0$ : o  $\epsilon$ -guloso com  $\epsilon = 0,1$  pode ter arrependimento linear? E com  $\epsilon = 0$ ?

**Direção da resposta:** as duas, e por motivos *opostos* — que é o ponto da pergunta. Com  $\epsilon = 0,1$  o algoritmo explora **demais**, puxando braços ruins numa fração fixa  $\epsilon/m$  dos passos para sempre, de modo que  $L_T \geq \frac{\epsilon}{m} (\sum_a \Delta_a) T$ . Com  $\epsilon = 0$  ele explora **de menos**: é o guloso, que trava. No exemplo dos dedos, a taxa com  $\epsilon = 0,1$  é  $\frac{0,1}{3} (0,05 + 0,85) = 0,03$  por passo.

**$\epsilon$  decrescente (Auer, Cesa-Bianchi e Fischer, 2002)**

Seja  $\Delta = \min_{a: \Delta_a > 0} \Delta_a$ . Com o agendamento  $\epsilon_t = \min\{1, c m / (\Delta^2 t)\}$  para  $c > 0$  apropriado, o  $\epsilon_t$ -guloso atinge arrependimento **logarítmico** em  $T$ .

**Atenção**

O agendamento ótimo depende de  $\Delta$ , que é desconhecido — é a mesma quantidade que gostaríamos de estimar. Por isso o  $\epsilon$ -guloso decrescente é teoricamente correto mas praticamente frágil: erra-se o agendamento e volta-se a uma das duas falhas. Isso motiva procurar um método que se calibre sozinho.

**Interlúdio: explorar-depois-comprometer**

O algoritmo mais simples com arrependimento sublinear puxa cada braço exatamente  $k$  vezes e depois se compromete para sempre com o de maior média empírica. Com recompensas 1-sub-gaussianas e dois braços,

$$L_T \leq \underbrace{k\Delta}_{\text{custo pago de explorar}} + \underbrace{(T - 2k) \Delta \exp(-k\Delta^2/4)}_{\text{risco de comprometer-se errado}},$$

e otimizando  $k$  e depois o pior  $\Delta$  obtém-se  $L_T = O(T^{2/3})$ .

Sublinear, portanto “bom” pelo nosso critério — mas  $T^{2/3}$  está longe de  $\sqrt{T}$ . A perda vem de **separar** exploração e exploração em fases estanques: o ETC não usa o que aprendeu *durante* a exploração para abandonar cedo um braço obviamente ruim. A lição que organiza o resto da aula é que **exploração e exploração devem ser entrelaçadas, não sequenciadas**.

**5 Quão bom é possível ser****Teorema (Lai e Robbins, 1985)**

Para qualquer algoritmo consistente, o arrependimento total assintótico é ao menos logarítmico:

$$\lim_{t \rightarrow \infty} L_t \geq \log t \sum_{a: \Delta_a > 0} \frac{\Delta_a}{D_{\text{KL}}(\mathcal{R}_a \| \mathcal{R}_{a^*})}.$$

A dificuldade de um problema de bandido é a *semelhança* entre o braço ótimo e os demais: problemas difíceis têm braços que parecem iguais mas têm médias diferentes. A divergência  $D_{\text{KL}}$  mede exatamente quantas amostras são necessárias para distinguir duas distribuições.

Para braços de Bernoulli,  $D_{\text{KL}}(\theta_a \| \theta_*) = \theta_a \log \frac{\theta_a}{\theta_*} + (1 - \theta_a) \log \frac{1 - \theta_a}{1 - \theta_*}$ , o que nos dá, no exemplo:

| Braço             | $\theta_a$ | $\Delta_a$ | $D_{\text{KL}}(\theta_a \  0,95)$ | $\Delta_a / D_{\text{KL}}$ |
|-------------------|------------|------------|-----------------------------------|----------------------------|
| esparadrapo $a_2$ | 0,90       | 0,05       | 0,0207                            | <b>2,42</b>                |
| nada $a_3$        | 0,10       | 0,85       | 2,3762                            | 0,36                       |

**Intuição**

A inversão é o que vale reter: o braço **quase tão bom** ( $a_2$ , lacuna minúscula) contribui *sete vezes mais* para o piso do que o braço obviamente ruim. Distinguir 0,90 de 0,95 custa muitas amostras; descartar 0,10 custa poucas. Em  $T = 1000$  o piso vale  $(2,42 + 0,36) \log 1000 \approx 19$ ,

*(continua)*

contra  $\approx 50$  do guloso e  $\approx 30$  do  $\epsilon$ -guloso fixo. Há bastante espaço — e o limite inferior ser *sublinear* é a boa notícia disfarçada de má.

## 6 Otimismo diante da incerteza

### Definição — O princípio

Escolha ações que **poderiam** ter valor alto — não as que *parecem* ter valor alto.

A justificativa é que só há dois desfechos possíveis, e ambos são bons. Se o braço de fato tem média alta, colhemos recompensa alta e não há arrependimento. Se tem média baixa, puxá-lo reduz em esperança tanto sua média estimada quanto a incerteza sobre ela — o braço é rebaixado e não volta a enganar.

### Intuição

O otimismo é **autocorretivo**: só se pode estar excessivamente otimista sobre um braço por um número *limitado* de puxadas, porque cada puxada corrige o excesso. Essa contagem — “quantas vezes posso me enganar antes de ser desmentido?” — é literalmente a demonstração da cota, como se verá.

## De onde sai a largura da barra de confiança

### Definição — Variável $\sigma$ -sub-gaussiana

$X$  com  $\mathbb{E}[X] = 0$  é  $\sigma$ -sub-gaussiana se  $\mathbb{E}[e^{\lambda X}] \leq e^{\lambda^2 \sigma^2 / 2}$  para todo  $\lambda \in \mathbb{R}$ ; isto é, sua cauda decai ao menos tão rápido quanto a de uma gaussiana de desvio  $\sigma$ .

### Corolário 5.5 (Lattimore e Szepesvári, *Bandit Algorithms*)

Sejam  $X_i - \mu$  independentes e  $\sigma$ -sub-gaussianas, e  $\hat{\mu} = \frac{1}{n} \sum_{t=1}^n X_t$ . Então, para todo  $\varepsilon \geq 0$ ,

$$\mathbb{P}(\hat{\mu} \geq \mu + \varepsilon) \leq \exp\left(-\frac{n\varepsilon^2}{2\sigma^2}\right), \quad \mathbb{P}(\hat{\mu} \leq \mu - \varepsilon) \leq \exp\left(-\frac{n\varepsilon^2}{2\sigma^2}\right).$$

Recompensas em  $[0, 1]$  — como as do exemplo — são  $\frac{1}{2}$ -sub-gaussianas pelo lema de Hoeffding; adotar  $\sigma = 1$ , como faremos, é apenas conservador: as barras saem mais largas que o necessário, nunca mais estreitas.

A desigualdade responde “qual a probabilidade de errar por  $\varepsilon$ ?”. O que queremos é a pergunta operacional invertida: dado um risco  $\delta$  que aceito correr, qual  $\varepsilon$ ? Basta igualar e resolver:

$$\delta = \exp\left(-\frac{n\varepsilon^2}{2\sigma^2}\right) \iff \varepsilon = \sqrt{\frac{2\sigma^2 \log(1/\delta)}{n}} \implies \mu \leq \hat{\mu} + \sqrt{\frac{2\sigma^2 \log(1/\delta)}{n}} \text{ com prob. } \geq 1 - \delta.$$

### Atenção

Esta é uma cota **unilateral**. Para controlar  $|\hat{\mu} - \mu|$  é preciso aplicar as duas caudas com união de eventos: tomando  $\delta' = \delta/2$ , com probabilidade ao menos  $1 - \delta$  vale  $|\mu - \hat{\mu}| \leq \sqrt{2\sigma^2 \log(2/\delta)/n}$ . Confundir as duas é o erro mais comum ao implementar intervalos de confiança em bandidos.

**Algoritmo — UCB1 (Auer, Cesa-Bianchi e Fischer, 2002)**

Supondo recompensas 1-sub-gaussianas,

$$a_t = \arg \max_{a \in \mathcal{A}} \left[ \underbrace{\hat{Q}(a)}_{\text{exploração}} + \underbrace{\sqrt{\frac{2 \log(1/\delta)}{N_t(a)}}}_{\text{bônus de exploração}} \right].$$

Braços nunca testados têm bônus infinito, de modo que o algoritmo começa amostrando cada braço uma vez.

O bônus não é um parâmetro de ajuste: ele é *deduzido* da desigualdade de concentração. Com  $\delta$  fixo, porém, ele não encolhe com o tempo; tomando  $\delta = 1/t^2$  obtém-se a versão *anytime*  $\hat{Q}(a) + \sqrt{4 \log t / N_t(a)}$ , que é a fórmula clássica usada na prática.

**O UCB1 no exemplo, passo a passo**

Com  $\delta = 0,1$  o bônus vale  $2,146/\sqrt{N(a)}$ . Partindo das três puxadas iniciais com resultados  $(+1, +1, 0)$ :

| $t$ | $U(a_1)$     | $U(a_2)$     | $U(a_3)$     | escolhe | $r$ | arrep. acum. |
|-----|--------------|--------------|--------------|---------|-----|--------------|
| 3   | <b>3,146</b> | 3,146        | 2,146        | $a_1$   | +1  | 0,90         |
| 4   | 2,517        | <b>3,146</b> | 2,146        | $a_2$   | +1  | 0,95         |
| 5   | <b>2,517</b> | 2,517        | 2,146        | $a_1$   | +1  | 0,95         |
| 6   | 2,239        | <b>2,517</b> | 2,146        | $a_2$   | 0   | 1,00         |
| 7   | <b>2,239</b> | 1,906        | 2,146        | $a_1$   | +1  | 1,00         |
| 8   | 2,073        | 1,906        | <b>2,146</b> | $a_3$   | 0   | 1,85         |
| 9   | <b>2,073</b> | 1,906        | 1,517        | $a_1$   | +1  | 1,85         |

Duas linhas merecem atenção. Em  $t = 8$  o braço  $a_3$  é escolhido *apesar* de  $\hat{Q}(a_3) = 0$ : seu bônus, intocado desde a primeira puxada, acabou ultrapassando os índices dos outros dois, que encolheram com as puxadas repetidas. O otimismo cobra a dívida de exploração — *uma vez*. Em  $t = 9$ , com o resultado 0, o índice de  $a_3$  despenca para 1,517 e o braço sai de cena. Compare com o  $\epsilon$ -guloso, que voltaria a  $a_3$  em 3,3% dos passos indefinidamente.

**7 A cota de arrependimento do UCB**

Antes da demonstração, um ponto técnico que costuma ser subestimado. A cota  $\mathbb{P}(\mu > \hat{\mu} + \epsilon) \leq \delta$  vale para *um* braço, em *um* instante, com  $n$  fixo. O algoritmo, porém, consulta  $m$  braços a cada um de  $n$  passos, e as contagens são aleatórias — escolhidas pelo próprio algoritmo. Precisamos que *nenhuma* dessas cotas falhe, o que se obtém por união de eventos,  $\mathbb{P}(\bigcup_i E_i) \leq \sum_i \mathbb{P}(E_i)$ .

**Intuição**

A união de eventos parece cara, mas não é: como  $\delta$  entra na fórmula por meio de  $\log(1/\delta)$ , exigir  $\delta/(mn)$  em vez de  $\delta$  custa apenas  $\log(mn)$  — **logarítmico no número de cotas**. É isso que torna a escolha  $\delta = 1/n^2$  inofensiva: risco total  $n \cdot 1/n^2 = 1/n$ , que se traduz em uma única puxada extra em esperança.

**Demonstração**

Sejam  $\Delta_i = \mu^* - \mu_i$  e  $N_i(n)$  o número de puxadas do braço  $i$  até o passo  $n$ . Sabemos que  $L_n = \sum_{i: \Delta_i > 0} \Delta_i \mathbb{E}[N_i(n)]$ , de modo que basta limitar as contagens.

(continua)

**Bom evento.** Defina

$$G_i := \left\{ \mu_i \leq \min_t \text{UCB}_i(t, \delta) \right\} \cap \left\{ \mu^* < \min_t \text{UCB}_{a^*}(t, \delta) \right\}, \quad \text{UCB}_i(t, \delta) = \hat{Q}_i(t-1) + \sqrt{\frac{2 \log(1/\delta)}{N_{t-1}(i)}}.$$

A estratégia é: *no bom evento, limitar as puxadas por um argumento determinístico; fora dele, limitar por  $n$  e mostrar que sua probabilidade é minúscula.* Formalmente,  $\mathbb{E}[N_i(n)] \leq u_i + \mathbb{P}(G_i^c) n$ , com  $u_i := 2 \log(1/\delta) / \Delta_i^2$ .

**Afirmção.** Se  $G_i$  vale, o braço subótimo  $i \neq a^*$  é puxado no máximo  $u_i$  vezes.

**Demonstração (por contradição).** Suponha  $G_i$  e que  $N_t(i) > u_i$  em algum instante  $t$  no qual  $i$  seria escolhido. Como o bônus é decrescente em  $N$ ,

$$\text{UCB}_i(t, \delta) \leq \mu_i + \sqrt{\frac{2 \log(1/\delta)}{u_i}} = \mu_i + \sqrt{\Delta_i^2} = \mu_i + \Delta_i = \mu^*.$$

Mas, por definição de  $G_i$ , tem-se  $\mu^* < \text{UCB}_{a^*}(t, \delta)$ . Logo  $\text{UCB}_i(t, \delta) < \text{UCB}_{a^*}(t, \delta)$  e o braço  $i$  não pode ser selecionado em  $t$  — contradição.  $\square$

**Fecho.** Tomando  $\delta = 1/n^2$ , a união sobre os  $n$  instantes dá  $\mathbb{P}(G_i^c) \leq n\delta = 1/n$ , e portanto

$$\mathbb{E}[N_i(n)] \leq \frac{2 \log(n^2)}{\Delta_i^2} + n \cdot \frac{1}{n} = \frac{4 \log n}{\Delta_i^2} + 1 \implies L_n \lesssim \sum_{i: \Delta_i > 0} \frac{4 \log n}{\Delta_i} + \sum_i \Delta_i.$$

**Intuição**

A conta em uma frase:  $u_i$  **puxadas encolhem o bônus até ele caber exatamente dentro da lacuna**; a partir daí o otimismo já não consegue disfarçar a inferioridade do braço. E note  $u_i \propto 1/\Delta_i^2$  — braços quase tão bons quanto o ótimo são puxados  *muitas*  vezes. Isso não é um defeito: errar entre eles custa pouco, e a cota de arrependimento envolve  $\Delta_i \cdot u_i \propto 1/\Delta_i$ , que continua controlado.

**Da cota dependente à cota de pior caso**

A cota acima é inútil quando alguma lacuna é minúscula, pois  $1/\Delta_i$  explode. A saída é **partir os braços em dois grupos** num limiar  $\Delta$  escolhido por nós:

$$L_n \leq \underbrace{n\Delta}_{\text{braços com } \Delta_i \leq \Delta: \text{errar custa pouco}} + \underbrace{\sum_{i: \Delta_i > \Delta} \frac{4 \log n}{\Delta_i}}_{\text{braços com } \Delta_i > \Delta: \text{descartados rápido}} \leq n\Delta + \frac{4m \log n}{\Delta}.$$

Derivando em  $\Delta$  e igualando a zero obtém-se  $\Delta^* = \sqrt{4m \log n/n}$ , e portanto  $L_n \leq 4\sqrt{m n \log n} = O(\sqrt{mn \log n})$ .

**Intuição**

O piso minimax é  $\Omega(\sqrt{mn})$ : o UCB1 fica a um fator  $\sqrt{\log n}$  do ótimo, eliminável por variantes (MOSS, KL-UCB). E o mesmo algoritmo, sem alteração alguma, satisfaz *as duas* cotas simultaneamente — ele se adapta sozinho à dificuldade do problema, o que é exatamente o que se pedia e o que nem o  $\epsilon_t$ -guloso nem o ETC entregam.



## Uma comparação que precisa ser lida com cuidado

| Referência ( $m = 3, \Delta = (0; 0,05; 0,85), n = 1000$ )              | $L_{1000}$    |
|-------------------------------------------------------------------------|---------------|
| Piso de Lai–Robbins                                                     | $\approx 19$  |
| Cota do UCB, dependente do problema                                     | $\approx 586$ |
| Cota do UCB, independente do problema                                   | $\approx 576$ |
| Guloso, travado em $a_2$ ( <i>desempenho observado</i> )                | $\approx 50$  |
| $\epsilon$ -guloso com $\epsilon = 0,1$ ( <i>desempenho observado</i> ) | $\approx 30$  |

### Atenção

As cotas do UCB são *piores* que o desempenho observado dos métodos ingênuos — e isso não é um erro, é o que significa uma cota de **pior caso**. Ela vale para todo bandido de três braços com estas lacunas, inclusive os construídos adversarialmente; os números do guloso valem para *esta* realização particular. A comparação honesta é assintótica: em  $n = 10^6$  o guloso paga  $5 \times 10^4$  e o  $\epsilon$ -guloso  $3 \times 10^4$ , ambos crescendo linearmente, contra  $\approx 1,2 \times 10^3$  da cota do UCB, crescendo como  $\log n$ . As curvas se cruzam e nunca mais se reencontram.

## 8 Duas variações que valem conhecer

### Por que a cota inferior não serve

#### Para discutir em aula

E se escolhêssemos sempre o braço de maior *cota inferior*,  $a_t = \arg \max_a [\hat{Q}(a) - \sqrt{2 \log(1/\delta)/N_t(a)}]$ ? Isso garante arrependimento baixo? Considere dois braços.

*Direção da resposta:* não — é pior que o guloso. O bônus vira **penalidade** por incerteza, de modo que braços pouco testados ficam artificialmente ruins; e são justamente os que precisavam ser testados. Com  $\mu_1 = 0,5$ ,  $\mu_2 = 0,6$  e puxadas iniciais  $r_1 = 1$ ,  $r_2 = 0$ , temos  $LCB_1 = 1 - c > LCB_2 = -c$ , e escolhe-se  $a_1$ . Cada nova puxada de  $a_1$  *encolhe* sua penalidade, e  $LCB_1 \rightarrow 0,5$ ; já  $LCB_2$  permanece congelado em  $-c$ . O braço 2 nunca mais é testado: arrependimento  $0,1 T$ , linear. A assimetria é a lição — **o otimismo é autocorretivo, o pessimismo é autoconfirmatório**. (O pessimismo tem seu lugar em RL *offline*, onde não se pode testar hipóteses e evitar o desconhecido é precisamente o que se deseja.)

## Amostragem de Thompson

### Definição — Arrependimento bayesiano

Com uma *priori*  $p(\theta)$  sobre os parâmetros do bandido,  $\text{BayesReg}_T = \mathbb{E}_{\theta \sim p}[L_T(\theta)]$ . Critério mais brando que o de pior caso, e que admite algoritmos notavelmente simples.

### Algoritmo — Amostragem de Thompson (Thompson, 1933)

A cada passo: **(1)** amostre  $\tilde{\theta}_a \sim p(\theta_a \mid \text{histórico})$  para cada braço; **(2)** aja *como se*  $\tilde{\theta}$  fosse a verdade,  $a_t = \arg \max_a Q_{\tilde{\theta}}(a)$ ; **(3)** observe  $r_t$  e atualize a posteriori.

O nome vem da propriedade que a define: cada braço é escolhido com probabilidade igual à *probabilidade posterior de ele ser o ótimo*. A exploração não é imposta por um bônus — emerge da incerteza da posteriori, e desaparece sozinha quando a incerteza some.

Para braços de Bernoulli a priori conjugada é  $\theta_a \sim \text{Beta}(\alpha_a, \beta_a)$ , e a atualização é contagem pura:  $\alpha_a \leftarrow \alpha_a + r$  e  $\beta_a \leftarrow \beta_a + (1 - r)$ . Com priori uniforme  $\text{Beta}(1, 1)$  e as mesmas três primeiras puxadas  $(+1, +1, 0)$ :

| Braço | Posteriori          | $\mathbb{E}[\theta]$ | $\mathbb{P}(\text{é o melhor})$ |
|-------|---------------------|----------------------|---------------------------------|
| $a_1$ | $\text{Beta}(2, 1)$ | 0,667                | 0,467                           |
| $a_2$ | $\text{Beta}(2, 1)$ | 0,667                | 0,467                           |
| $a_3$ | $\text{Beta}(1, 2)$ | 0,333                | <b>0,066</b>                    |

Compare com o  $\epsilon$ -guloso, que daria 3,3% a  $a_3$  *para sempre*: Thompson dá 6,6% *agora*, quando ainda há dúvida legítima, e essa fração cai sozinha à medida que a posteriori se concentra. Note ainda que  $\mathbb{P}(\text{é o melhor})$  não é a ordenação das médias — com uma única observação a cauda ainda é gorda.

### Garantias

Arrependimento bayesiano  $O(\sqrt{mT \log T})$ . E, embora bayesiano por construção, Thompson satisfaz também cotas frequentistas  $O(\sum_i \log T / \Delta_i)$ , sendo assintoticamente ótimo para braços de Bernoulli (Agrawal e Goyal, 2012; Kaufmann, Korda e Munos, 2012).

### Intuição

A simetria com o UCB é elegante: ambos escolhem por um valor *plausível*, não pelo esperado. O UCB toma o **quantil superior** da incerteza; Thompson toma uma **amostra** dela. Empiricamente Thompson costuma vencer, porque o bônus do UCB é calibrado para o pior caso enquanto a posteriori usa a forma real da incerteza. Em compensação, o UCB dispensa escolher priori e amostrar dela. Há ainda uma vantagem prática subestimada de Thompson: em decisões *em lote* (mil usuários atendidos com a mesma política), o UCB daria a todos o mesmo braço, enquanto Thompson diversifica automaticamente.

## 9 Síntese

| Algoritmo                                      | Arrepend.        | Parâmetro   | Por que falha ou funciona                  |
|------------------------------------------------|------------------|-------------|--------------------------------------------|
| Guloso                                         | $\Theta(T)$      | —           | trava; nunca corrige um azar inicial       |
| $\epsilon$ -guloso, $\epsilon$ fixo            | $\Theta(T)$      | $\epsilon$  | explora uniformemente, para sempre         |
| $\epsilon_t$ -guloso, $\epsilon_t \propto 1/t$ | $O(\log T)$      | $c, \Delta$ | ótimo em taxa, mas exige conhecer $\Delta$ |
| ETC                                            | $O(T^{2/3})$     | $k$         | separa as fases; não se adapta             |
| UCB1                                           | $O(\log T)$      | $\delta$    | bônus deduzido; adapta-se às lacunas       |
| Thompson                                       | $O(\log T)$      | priori      | explora na medida da dúvida posterior      |
| <i>Piso (Lai–Robbins)</i>                      | $\Omega(\log T)$ | —           | <i>ninguém faz melhor</i>                  |

### Atenção

#### Cinco confusões a evitar.

1. Arrependimento não é “recompensa que deixei de observar”: é comparação com a *média* da melhor ação. Ganhar +1 com a ação errada ainda é arrependimento positivo.
2. Arrependimento não é computável em aplicações reais; o que se computa são cotas.
3. Uma cota superior de pior caso pode ser numericamente pior que o desempenho observado de um método ruim, em horizontes curtos. Isso não invalida a cota.

**(continua)**

4. A cota de concentração é unilateral; controlar  $|\hat{\mu} - \mu|$  exige  $\log(2/\delta)$ , não  $\log(1/\delta)$ .
5.  $\delta$  fixo no UCB não é a versão *anytime*. Sem  $\delta = 1/t^2$  (ou equivalente), o bônus não acompanha o crescimento do número de cotas simultâneas.

## 10 Exercícios

### Exercício 9.1 — Decomposição do arrependimento

Demonstre a identidade  $\mathbb{E}[\sum_{\tau=1}^t (V^* - Q(a_\tau))] = \sum_a \mathbb{E}[N_t(a)] \Delta_a$  explicitando onde se usa linearidade da esperança e onde se usa a definição de  $N_t(a)$ .

### Exercício 9.2 — Quando o guloso acerta

No exemplo dos dedos, estime por simulação a probabilidade de o guloso acabar travado em cada braço, partindo da rodada inicial de uma puxada por braço (empates resolvidos uniformemente). Antes de simular, escreva a probabilidade que você obterá supondo que o empate inicial se resolve de uma vez; compare com o valor simulado e explique a diferença. Por fim, comente por que uma probabilidade alta de acerto não salva o método.

### Exercício 9.3 — Taxa do $\epsilon$ -guloso

Mostre que, se a parte gulosa do  $\epsilon$ -guloso identificar corretamente  $a^*$  a partir de certo instante, então  $L_T \rightarrow \frac{\epsilon}{m} (\sum_a \Delta_a) T$ . Calcule a constante no exemplo com  $\epsilon = 0,1$ .

### Exercício 9.4 — Otimizando o ETC

A partir de  $L_T \leq k\Delta + T\Delta e^{-k\Delta^2/4}$ , encontre o  $k$  ótimo e mostre que, tomando o pior  $\Delta$ , resulta  $L_T = O(T^{2/3})$ .

### Exercício 9.5 — O bônus e a lacuna

Verifique que  $u_i = 2 \log(1/\delta) / \Delta_i^2$  é exatamente o número de puxadas para o qual o bônus iguala a lacuna. Em seguida, calcule  $u_2$  e  $u_3$  do exemplo com  $\delta = 1/n^2$  e  $n = 1000$ , e comente a diferença de ordem de grandeza.

### Exercício 9.6 — Implementação

Implemente guloso,  $\epsilon$ -guloso ( $\epsilon$  fixo e  $\epsilon_t \propto 1/t$ ), UCB1 e Thompson para o bandido de três braços do exemplo. Rode 200 repetições de  $T = 5000$  passos e trace o arrependimento médio acumulado em escala semilogarítmica no eixo horizontal. Confirme que as curvas do UCB e de Thompson ficam retas nessa escala, e as demais não.

## Respostas resumidas

**9.1.** Escreva  $V^* - Q(a_\tau) = \sum_a \mathbf{1}(a_\tau = a) \Delta_a$ ; troque a ordem dos somatórios (finitos, logo lícito) e use a linearidade; reconheça  $\sum_\tau \mathbf{1}(a_\tau = a) = N_t(a)$ . A esperança só pode entrar depois da troca, porque  $N_t(a)$  é aleatório.

**9.2.** A conta ingênua — repartir o empate inicial uniformemente e declarar o vencedor — dá  $\approx 0,50$  para  $a_1$ . A simulação (20 000 execuções) dá  $\approx 0,76$  para  $a_1$ ,  $0,24$  para  $a_2$  e  $0,001$  para  $a_3$ . A diferença é instrutiva: **um empate em  $\hat{Q} = 1$  não se resolve de uma vez**. O braço sorteado é puxado de novo e, se falhar, sua média cai abaixo da do outro empatado, devolvendo a vez a ele. O empate vira uma disputa que dura enquanto os dois seguirem acertando — e essa disputa favorece quem tem o maior  $\theta$ , isto é,  $a_1$ . Ainda assim o método não se salva: em  $\approx 24\%$  das execuções o arrependimento é linear, e é a *esperança* do arrependimento, não a mediana, que a análise mede. Ela permanece  $\Theta(T)$ .

**9.3.** A parte gulosa contribui 0 e a aleatória escolhe cada braço com probabilidade  $\epsilon/m$ , custando  $\Delta_a$  cada. No exemplo,  $\frac{0,1}{3}(0 + 0,05 + 0,85) = 0,03$  por passo.

**9.4.** Derivando em  $k$ :  $\Delta = T \Delta \frac{\Delta^2}{4} e^{-k\Delta^2/4}$ , donde  $k^* = \frac{4}{\Delta^2} \log \frac{T\Delta^2}{4}$  e  $L_T = O\left(\frac{\log(T\Delta^2)}{\Delta}\right)$ . Como o pior caso é  $\Delta \sim T^{-1/3}$ , resulta  $O(T^{2/3})$ .

**9.5.** Iguale  $\sqrt{2 \log(1/\delta)/u} = \Delta$  e resolva. Com  $\delta = 10^{-6}$ ,  $2 \log(1/\delta) = 27,6$ :  $u_2 = 27,6/0,05^2 \approx 1,1 \times 10^4$  e  $u_3 = 27,6/0,85^2 \approx 38$ . O braço inequivocamente ruim é descartado em algumas dezenas de puxadas; o braço quase tão bom exigiria mais puxadas do que o horizonte — e é justamente por isso que confundi-lo custa pouco.

**9.6.** Espera-se ver: guloso e  $\epsilon$ -guloso de  $\epsilon$  fixo crescendo linearmente; UCB1 e Thompson formando retas na escala semilog, o que indica  $\Theta(\log T)$ ; e Thompson tipicamente abaixo do UCB1 por um fator constante.

## 11 Notação e glossário

| Símbolo                                | Leitura                             | Inglês                              |
|----------------------------------------|-------------------------------------|-------------------------------------|
| $L_T$                                  | arrependimento total até $T$        | (total) regret                      |
| $\ell_t$                               | arrependimento de um passo          | per-step regret                     |
| $\Delta_a$                             | lacuna do braço $a$ , $V^* - Q(a)$  | gap                                 |
| $N_t(a)$                               | contagem de escolhas de $a$ até $t$ | count                               |
| $U_t(a)$                               | cota superior de confiança          | upper confidence bound              |
| $\delta$                               | risco tolerado por cota             | confidence level                    |
| $m$                                    | número de braços                    | number of arms                      |
| $D_{\text{KL}}(\cdot \parallel \cdot)$ | divergência de Kullback–Leibler     | KL divergence                       |
| —                                      | braço / bandido multi-braços        | arm / multi-armed bandit            |
| —                                      | otimismo diante da incerteza        | optimism in the face of uncertainty |
| —                                      | casamento de probabilidade          | probability matching                |
| —                                      | explorar-depois-comprometer         | explore-then-commit                 |
| —                                      | sub-gaussiana                       | sub-Gaussian                        |
| —                                      | união de eventos                    | union bound                         |

### Intuição

**Próxima aula.** As mesmas três ideias — arrependimento como critério, otimismo como abordagem, concentração como ferramenta — reaparecem em MDPs, onde é preciso decidir não só *o que* testar, mas *como chegar* ao lugar onde vale a pena testar. Veremos

(continua)

aprendizagem PAC, otimismo em modelos (R-MAX, UCRL) e cotas de complexidade amostral.

**Leituras.** Lattimore & Szepesvári, *Bandit Algorithms* (Cambridge, 2020), capítulos 4 a 8 — referência central, com as demonstrações completas. Sutton & Barto, *Reinforcement Learning: An Introduction*, 2ª ed., capítulo 2. Artigos: Lai & Robbins (1985); Auer, Cesa-Bianchi & Fischer, *Machine Learning* (2002); Thompson (1933); Agrawal & Goyal (2012); Kaufmann, Korda & Munos (2012); Russo *et al.*, *A Tutorial on Thompson Sampling* (2018).