

Aprendizagem por imitação, aprendizado de recompensa e RLHF

Erros compostos • DAGGER • RL inverso • Bradley–Terry • RLHF • DPO

Prof. Marcelo Keese Albertini

Adaptado e expandido de CS234 — *Reinforcement Learning*, Emma Brunskill, Stanford University

1 De onde vem a recompensa

Em todas as aulas anteriores a função de recompensa R era um dado do problema. Escrevíamos $R(s, a)$, e todo o restante — programação dinâmica, Q-learning, gradiente de política — consistia em *maximizá-la*. Esta aula retira essa premissa. O que fazer quando ninguém sabe escrever a recompensa?

Há três respostas, e elas organizam a aula:

1. **Copiar quem sabe fazer.** É a aprendizagem por imitação. Simples, e com um modo de falha específico que estudaremos com cuidado: o erro cresce com o *quadrado* do horizonte.
2. **Inferir a recompensa a partir do comportamento.** É o aprendizado por reforço inverso. Mais ambicioso, porque a recompensa é transferível — e mal posto, porque infinitas recompensas explicam os mesmos dados.
3. **Perguntar a pessoas o que elas preferem.** É o caminho que produziu o RLHF e o DPO. Explora uma assimetria: escrever uma boa resposta é difícil; reconhecer qual de duas é melhor, nem tanto.

Intuição

Um fio percorre a aula inteira e vale ser dito desde já: **a recompensa nunca é identificável sozinha**. Ela aparece três vezes — no RL inverso, no modelo de Bradley–Terry e no DPO — sempre determinada apenas a menos de transformações que não alteram o comportamento ótimo. Reconhecer essa regularidade organiza metade do conteúdo.

2 Aprendizagem por imitação

2.1 O problema

Definição — Aprendizagem por imitação

São dados os espaços $\mathcal{S}$ e $\mathcal{A}$, possivelmente um modelo de transição $P(s' \mid s, a)$, e um conjunto de demonstrações

$$\mathcal{D} = \{(s_0, a_0, s_1, a_1, \dots)\}, \quad a_t \sim \pi^E(\cdot \mid s_t),$$

produzidas por um especialista π^E . **Não há função de recompensa.** O objetivo é obter uma política cujo desempenho se aproxime do de π^E .

A abordagem mais direta, vista na aula anterior, é a **clonagem de comportamento**: tratar o problema como classificação supervisionada, aprendendo $\pi(a \mid s)$ que minimize uma perda sobre

os pares (s, a) observados. É o que faz o ALVINN de 1989 (uma rede de duas camadas que dirigia um furgão) e o que faz a etapa de *ajuste por instruções* de um modelo de linguagem moderno — separadas por trinta e cinco anos, é o mesmo algoritmo.

2.2 A hipótese emprestada, e por que ela falha

Aprendizado supervisionado supõe pares (x, y) independentes e identicamente distribuídos, extraídos da *mesma* distribuição no treino e no teste. Num MDP, isso é falso duas vezes. Os estados de uma trajetória são dependentes no tempo, e — o que é mais grave — a distribuição de estados depende da política que os gera:

$$\text{treino: } s_t \sim d^{\pi^E}, \quad \text{teste: } s_t \sim d^{\pi}.$$

O classificador é bom onde há dados, isto é, onde o especialista esteve. Basta um erro para que o agente saia dessa região, e ali não existe garantia alguma. Pior: fora da região, a política tende a errar mais, o que a leva ainda mais longe. O erro se **realimenta**.

Atenção

Esta é a diferença estrutural entre imitação e classificação, e não uma dificuldade prática contornável com engenharia. Em aprendizado supervisionado, o conjunto de teste é fixo. Em imitação, *as ações do aluno determinam quais perguntas cairão na prova*.

2.3 Contabilizando os erros

Caso benigno. Suponha que a política erre com probabilidade ε em cada passo e que um erro *não* afete os estados seguintes — como se um mecanismo externo devolvesse o agente ao trilho. Por linearidade da esperança,

$$\mathbb{E}[\text{total de erros}] \leq \varepsilon T.$$

Custo linear no horizonte, exatamente o que a intuição supervisionada prevê.

Caso real. Se um erro em t leva a um estado fora do suporte dos dados, a suposição pessimista é que todos os $T - t$ passos restantes fiquem comprometidos. Somando sobre o instante em que o primeiro erro ocorre:

$$\mathbb{E}[\text{total de erros}] \lesssim \varepsilon (T + (T - 1) + \dots + 1) = \varepsilon \frac{T(T + 1)}{2} = O(\varepsilon T^2).$$

Demonstração

O argumento acima é heurístico e serve para fixar o expoente; o resultado formal é o Teorema 2.1 de Ross & Bagnell (AISTATS 2010). Enunciado em termos de custo esperado J , com ℓ a perda de classificação 0–1 sob a distribuição do especialista e custo por passo limitado por 1:

$$J(\hat{\pi}) \leq J(\pi^E) + T^2 \varepsilon, \quad \varepsilon = \mathbb{E}_{s \sim d^{\pi^E}} [\ell(s, \hat{\pi})].$$

O fator T^2 não é frouxidão da análise: existe uma família de MDPs em que ele é atingido. A construção usa um estado “absorvente ruim” alcançável por um único erro, e do qual o especialista nunca demonstrou como sair — precisamente porque ele nunca erra.

Os números tornam a diferença concreta. Com $\varepsilon = 1\%$ e $T = 1000$ passos, o caso benigno prevê 10 erros; o caso real, da ordem de 10^4 . Uma política com 99% de acurácia de classificação é, em uma tarefa sequencial longa, inutilizável.

Para discutir em aula

Um sistema de direção autônoma treinado por clonagem sai da pista após alguns minutos. A equipe propõe coletar dez vezes mais demonstrações do motorista humano. Discuta: em que sentido isso ajuda, em que sentido não ajuda, e que tipo de dado adicional atacaria a causa em vez do sintoma.

2.4 DAGGER: rotular onde a política realmente vai

A leitura correta do problema aponta o remédio. Se a dificuldade é que a política visita estados sobre os quais não há dados, então é preciso obter rótulos do especialista *exatamente nesses estados*.

Algoritmo — DAGGER — Dataset Aggregation (Ross, Gordon & Bagnell, 2011)

- ▶ Inicialize $\mathcal{D} \leftarrow \emptyset$ e π_1 (o próprio π^E , ou uma clonagem inicial).
- ▶ **para** $i = 1, \dots, N$:
 - defina a política de amostragem $\hat{\pi}_i = \beta_i \pi^E + (1 - \beta_i) \pi_i$, com $\beta_i \rightarrow 0$;
 - execute $\hat{\pi}_i$ e registre os estados visitados;
 - consulte o especialista em cada estado visitado, formando $\mathcal{D}_i = \{(s, \pi^E(s))\}$;
 - agregue $\mathcal{D} \leftarrow \mathcal{D} \cup \mathcal{D}_i$;
 - treine π_{i+1} minimizando a perda de classificação sobre *todo* o $\mathcal{D}$ acumulado.
- ▶ Devolva a melhor π_i segundo um conjunto de validação.

Formalmente, o DAGGER é uma redução do problema de imitação a aprendizado *online* sem arrependimento: cada iteração é uma rodada de um jogo em que o aprendiz escolhe uma política e o adversário escolhe a distribuição de estados. Um algoritmo sem arrependimento (*follow the leader* sobre o conjunto agregado é suficiente) garante que exista i com

$$J(\pi_i) \leq J(\pi^E) + O(T\varepsilon) + o(1),$$

recuperando a dependência *linear* em T . A agregação — treinar sempre sobre todo o histórico, e não apenas sobre o lote mais recente — é o que torna o algoritmo estável; treinar só sobre $\mathcal{D}_i$ produz oscilação.

Intuição

O papel da mistura β_i : nas primeiras iterações π_i ainda é ruim, e executá-la pura significa passar todo o tempo em estados catastróficos, dos quais se aprende pouco. É a lógica do instrutor de autoescola que mantém a mão no volante no início e a retira gradualmente.

Atenção

O preço do DAGGER. Ele exige um especialista disponível durante todo o treinamento, capaz de rotular estados arbitrários sob demanda. Três consequências tornam isso proibitivo em escala:

- ▶ **custo** — a supervisão humana passa a escalar com o número de estados visitados, não com o número de demonstrações;
- ▶ **contexto** — perguntar a uma pessoa “o que você faria *agora*?” diante de um quadro congelado, sem o histórico que a levaria até ali, produz rótulos de qualidade duvidosa;
- ▶ **segurança** — para rotular um estado é preciso visitá-lo, e alguns estados não devem ser visitados nem uma vez.

2.5 Comparação

	Clonagem	DAGGER	RL inverso	
Erro no horizonte	$O(\varepsilon T^2)$	$O(\varepsilon T)$	depende do planejador	
Interage com o ambiente	não	sim	sim	
Especialista durante o treino	não	sim	não	
O que produz	política	política	recompensa	
Transfere para nova dinâmica	não	não	sim	

A última linha é o argumento decisivo a favor de aprender a recompensa: ela é a descrição mais compacta e transferível de uma tarefa. Troque o veículo, a estrada ou o corpo do robô e a política precisa ser refeita do zero; a *intenção* permanece.

3 Aprendizado de recompensa (RL inverso)

3.1 Formulação e não-identificabilidade

Definição — Aprendizado por reforço inverso

Dados $\mathcal{S}$, $\mathcal{A}$, o modelo $P(s' | s, a)$ e demonstrações de π^E , mas sem R : inferir uma função de recompensa sob a qual o comportamento observado seja ótimo.

A primeira pergunta a fazer é de identificabilidade, e a resposta é desconfortável: **existe um conjunto infinito de recompensas compatíveis**. O contraexemplo mais brutal é $R \equiv 0$, sob a qual toda política é ótima — inclusive a do especialista. Há três fontes distintas de ambiguidade, e vale separá-las:

- Degenerescência.** Qualquer recompensa constante explica qualquer comportamento.
- Escala.** Se R explica π^E , então cR com $c > 0$ também: multiplicar por uma constante positiva não altera nenhum arg max.
- Modelagem por potencial.** Para qualquer $\Phi : \mathcal{S} \rightarrow \mathbb{R}$,

$$R'(s, a, s') = R(s, a, s') + \gamma \Phi(s') - \Phi(s)$$

induz *exatamente* o mesmo conjunto de políticas ótimas (Ng, Harada & Russell, 1999).

Demonstração

A invariância 3 é imediata quando se olha o retorno. Ao longo de uma trajetória, os termos de potencial telescopam:

$$\sum_{t=0}^{T-1} \gamma^t (\gamma \Phi(s_{t+1}) - \Phi(s_t)) = \gamma^T \Phi(s_T) - \Phi(s_0).$$

O retorno sob R' difere do retorno sob R por $-\Phi(s_0)$, que não depende da política, e por $\gamma^T \Phi(s_T)$, que desaparece quando $T \rightarrow \infty$ com $\gamma < 1$ ou quando Φ se anula nos estados terminais. Ordenações entre políticas ficam preservadas. $\square$

Intuição

Reter a invariância 2: ela reaparecerá idêntica no modelo de Bradley–Terry, onde a recompensa latente só é determinada a menos de uma constante aditiva. É a razão técnica pela qual o valor absoluto devolvido pelo modelo de recompensa de um LLM não significa nada isoladamente.

3.2 Estrutura: recompensa linear em atributos

Escolher entre infinitas soluções exige impor estrutura. A hipótese clássica é linearidade em um vetor de atributos conhecido $x(s) \in \mathbb{R}^n$, com $R(s) = w^\top x(s)$. O valor de uma política vira então um produto interno com a **esperança de atributos descontada**:

$$V^\pi = \mathbb{E} \left[\sum_{t \geq 0} \gamma^t w^\top x(s_t) \mid \pi \right] = w^\top \underbrace{\mathbb{E} \left[\sum_{t \geq 0} \gamma^t x(s_t) \mid \pi \right]}_{\mu(\pi)} = w^\top \mu(\pi).$$

Casas atributos basta

Se $\|w\|_1 \leq 1$ e $\|\mu(\pi) - \mu(\pi^E)\|_1 \leq \epsilon$, então

$$|w^\top \mu(\pi) - w^\top \mu(\pi^E)| \leq \|w\|_\infty \|\mu(\pi) - \mu(\pi^E)\|_1 \leq \epsilon$$

para *todo* w admissível. Ou seja: não é preciso identificar w ; basta igualar as esperanças de atributos.

Isso muda a natureza do problema. Em vez de descobrir “o que o especialista queria”, basta comportar-se como ele estatisticamente, atributo por atributo. O preço é que a qualidade do resultado passa a depender inteiramente da escolha dos atributos — se $x(\cdot)$ não captura a dimensão relevante da tarefa, nenhum algoritmo a recuperará.

3.3 Desempate: máxima entropia

Muitas distribuições sobre trajetórias casam as esperanças de atributos. O princípio da máxima entropia escolhe a *menos comprometida* com o que não foi observado:

$$\max_P - \sum_\tau P(\tau) \log P(\tau) \quad \text{s.a.} \quad \sum_\tau P(\tau) x(\tau) = \tilde{x}_E, \quad \sum_\tau P(\tau) = 1.$$

Demonstração

Formando o lagrangiano $\mathcal{L} = - \sum_\tau P \log P + w^\top (\tilde{x}_E - \sum_\tau P x(\tau)) + \lambda(1 - \sum_\tau P)$ e anulando $\partial \mathcal{L} / \partial P(\tau)$:

$$-\log P(\tau) - 1 - w^\top x(\tau) - \lambda = 0 \implies P(\tau) \propto \exp(w^\top x(\tau)).$$

(O sinal de w é convenção; absorvendo-o, obtém-se a forma usual.) Normalizando,

$$P(\tau | w) = \frac{1}{Z(w)} \exp(w^\top x(\tau)), \quad x(\tau) = \sum_t \gamma^t x(s_t). \square$$

A leitura é importante: o especialista é tratado como **aproximadamente** ótimo. Trajetórias melhores são exponencialmente mais prováveis, mas erros não são impossíveis — uma descrição muito mais fiel de uma pessoa do que a hipótese de otimalidade exata.

Ajusta-se w por máxima verossimilhança, e o gradiente tem forma memorável:

$$\nabla_w \mathcal{L} = \underbrace{\tilde{x}_E}_{\text{atributos observados}} - \underbrace{\mathbb{E}_{\tau \sim P(\cdot|w)} [x(\tau)]}_{\text{atributos previstos pelo modelo}}$$

— “observado menos esperado”, a mesma forma do gradiente de qualquer família exponencial (e a mesma que apareceu no score da política softmax, na Aula 5).

Atenção

O termo de esperança exige *resolver o MDP inteiro* a cada passo de gradiente, para obter as frequências de visita sob a recompensa corrente. É o gargalo do método. Guided Cost Learning (Finn et al., 2016) o substitui por amostragem por importância com uma política treinada em paralelo, e ao fazê-lo revela a equivalência estrutural com redes adversárias: a recompensa desempenha o papel do discriminador, e a política, o do gerador.

Para discutir em aula

Imitação pressupõe alguém que *sabe executar* a tarefa. Enumere domínios em que existem avaliadores competentes mas não executores competentes. O que muda metodologicamente quando o especialista sabe julgar, mas não sabe fazer?

4 Preferências humanas

4.1 O espectro de esforço

Há muitas formas de uma pessoa ajudar a treinar um agente, e elas se ordenam naturalmente pelo esforço exigido:



A tentativa histórica de pedir *números* diretamente — TAMER (Knox & Stone, 2008), em que a pessoa aperta “bom” ou “ruim” enquanto o agente age — esbarra em três dificuldades. **Calibração:** o “7” de uma pessoa não é o de outra, nem o dela mesma na semana seguinte. **Ruído:** julgamentos absolutos têm variância alta. **Esforço:** exige atenção contínua. Estudos com robôs ensináveis (Thomaz & Breazeal, 2008) mostraram ainda que as pessoas não usam o canal de recompensa como a teoria de RL supõe: elas antecipam, premiam intenção e tentam *orientar* em vez de apenas avaliar — comportamento que viola frontalmente o modelo formal.

A saída, conhecida em psicomетria muito antes de existir aprendizado de máquina: não pergunte *quanto*; pergunte *qual dos dois*. Comparações par a par exigem só um julgamento relativo, que é estável entre avaliadores e barato de coletar. Quando o custo por consulta importa, é possível ainda *escolher* quais pares apresentar, maximizando informação — aprendizado ativo de preferências (Sadigh et al., RSS 2017).

O que se perde é a escala. Comparações fornecem apenas uma *ordem*, e RL precisa de um *número*. Reconstruir a escala a partir da ordem é exatamente o papel do modelo a seguir.

4.2 O modelo de Bradley–Terry

Definição — Bradley–Terry (1952)

Dados k itens $b_1, \dots, b_k$ e uma recompensa latente $r(\cdot)$, a probabilidade de uma pessoa preferir b_i a b_j é

$$\mathbb{P}(b_i \succ b_j) = \frac{\exp(r(b_i))}{\exp(r(b_i)) + \exp(r(b_j))} = \sigma(r(b_i) - r(b_j)) = p_{ij},$$

com $\sigma(z) = 1/(1 + e^{-z})$ a função logística.

Três consequências merecem atenção.

(i) É regressão logística. Escrevendo r como vetor de coeficientes e $e_i - e_j$ como vetor de atributos da comparação, o modelo é literalmente uma regressão logística. Toda a maquinaria clássica se aplica: a log-verossimilhança é côncava, o ajuste é um problema convexo, e há solução única uma vez fixada a normalização.

(ii) A recompensa é identificável apenas a menos de constante aditiva. Substituir $r(\cdot)$ por $r(\cdot) + c$ não altera nenhum p_{ij} , pois só entra a diferença. É a mesma invariância de escala vista no RL inverso, e implica que os valores absolutos de um modelo de recompensa não são interpretáveis — só diferenças, e só entre respostas ao mesmo prompt. Daí a prática de normalizar as recompensas por prompt antes de otimizar.

(iii) Transitividade estocástica. O modelo impõe que p_{ik} fique determinado por p_{ij} e p_{jk} . Preferências humanas cíclicas — comuns quando há múltiplos critérios em conflito, ou múltiplos avaliadores — violam essa hipótese, e nenhuma quantidade de dados as acomoda dentro do modelo.

Ajuste por entropia cruzada

Com N tuplas (b_i, b_j, μ) , onde $\mu = 1$ se a pessoa marcou $b_i \succ b_j$, $\mu = 0,5$ em caso de empate e $\mu = 0$ caso contrário, maximizar a verossimilhança equivale a minimizar

$$\mathcal{L}(r) = - \sum_{(b_i, b_j, \mu) \in \mathcal{D}} \left[\mu \log \mathbb{P}(b_i \succ b_j) + (1 - \mu) \log \mathbb{P}(b_j \succ b_i) \right].$$

Atenção

Se os dados forem *separáveis* — algum item nunca perde — a verossimilhança é maximizada empurrando $r \rightarrow \infty$, e o ajuste não converge. Regularização não é refinamento opcional aqui; é o que mantém o problema bem posto. É o mesmo fenômeno da separação perfeita em regressão logística.

Que item é “o melhor”?

Quando as comparações não vêm de um modelo de Bradley–Terry, “melhor” deixa de ser óbvio. Três critérios clássicos da teoria da escolha social:

- ▶ **Condorcet:** b_i tal que $\mathbb{P}(b_i \succ b_j) > 0,5$ para todo $j \neq i$. Pode não existir.
- ▶ **Copeland:** b_i com o maior número de vitórias par a par (vitórias menos derrotas). Sempre existe.
- ▶ **Borda:** b_i que maximiza a pontuação esperada, contando 1 por vitória, 0,5 por empate e 0 por derrota.

Historicamente, os algoritmos de banditos “em duelo” (k braços, consultas de dois em dois) buscavam o vencedor de Copeland (Yue, Broder, Kleinberg & Joachims, JCSS 2012). **Sob Bradley–Terry os três critérios coincidem**, porque a transitividade estocástica elimina os ciclos; a distinção só passa a importar quando o modelo falha — que é precisamente o regime das preferências humanas agregadas sobre questões controversas.

4.3 De itens para trajetórias

A mesma construção vale trocando “item” por *trajetória*. Para τ^1 e τ^2 com somas de recompensas latentes $R^1 = \sum_i r_i^1$ e $R^2 = \sum_i r_i^2$:

$$\hat{\mathbb{P}}(\tau^1 \succ \tau^2) = \frac{\exp(\sum_i r_i^1)}{\exp(\sum_i r_i^1) + \exp(\sum_i r_i^2)} = \sigma(R^1 - R^2).$$

Agora r é uma rede neural $r_\phi(s, a)$, treinada pela mesma perda. Com r_ϕ em mãos, o problema volta a ser RL comum: rode PPO usando a recompensa aprendida.


Intuição

Note o que a soma implica: a preferência é dada sobre a trajetória *inteira*, mas o modelo aprende uma recompensa *por passo*. Trata-se de um problema de atribuição de crédito — o mesmo que estruturou as aulas de diferenças temporais — agora deslocado para dentro do sinal de supervisão.

O resultado que estabeleceu a viabilidade prática foi Christiano et al. (2017), *Deep RL from Human Preferences*: um agente simulado aprendeu a executar um *backflip* — comportamento para o qual ninguém sabe escrever uma recompensa — a partir de cerca de **900 comparações** de um avaliador humano, com o modelo de recompensa treinado em paralelo com a política e as consultas concentradas onde ele estava mais incerto. Novecentos bits de feedback compraram um comportamento que nenhuma recompensa escrita à mão havia produzido.

5 RLHF

5.1 As três etapas



A etapa 1 é exatamente a clonagem de comportamento da seção 2 — com todos os seus limites. As etapas 2 e 3 são as duas metades da pergunta “como maximizar algo que não sabemos escrever?”.

5.2 Etapa 2: o modelo de recompensa

Para um prompt x , geram-se várias respostas com π_{SFT} e pede-se a uma pessoa que ordene um par. Escrevendo y_w para a preferida e y_ℓ para a preterida:

$$\mathcal{L}(\phi) = -\mathbb{E}_{(x, y_w, y_\ell) \sim \mathcal{D}} \left[\log \sigma(r_\phi(x, y_w) - r_\phi(x, y_\ell)) \right].$$

Na prática, r_ϕ é o próprio modelo de linguagem com a camada de saída trocada por um escalar, e a soma de recompensas por token colapsa numa recompensa terminal atribuída à resposta completa.

Intuição

Valide o modelo de recompensa antes de otimizar contra ele. A métrica natural é a acurácia em prever julgamentos humanos retidos. Modelos grandes, treinados com dados suficientes, aproximam-se da concordância entre dois avaliadores humanos — que é o teto real do problema, não 100% (Stiennon et al., 2020).

5.3 Etapa 3: otimizar sem destruir o modelo

$$\max_{\pi_\theta} \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi_\theta(\cdot | x)} \left[\underbrace{r_\phi(x, y)}_{\text{recompensa aprendida}} - \beta \underbrace{\log \frac{\pi_\theta(y | x)}{\pi_{\text{ref}}(y | x)}}_{\text{penalidade por se afastar}} \right]$$

Em esperança, o segundo termo é $\beta \text{KL}(\pi_\theta(\cdot | x) \parallel \pi_{\text{ref}}(\cdot | x))$. Paga-se um preço sempre que $\pi_\theta(y | x) > \pi_{\text{ref}}(y | x)$: o modelo pode mudar, mas não pode sair do lugar. A otimização usa PPO, tratando cada token como uma ação.

Atenção

Por que a penalidade é indispensável. r_ϕ é um modelo estatístico ajustado a dados finitos, válido apenas na região onde π_{SFT} gera texto. Maximizá-lo sem restrição leva a política a *explorar as falhas do avaliador* em vez de melhorar a resposta — é o *reward hacking*. A penalidade KL mantém a política dentro do domínio onde r_ϕ ainda é confiável.

Sobre-otimização: a lei de Goodhart quantificada

“Quando uma medida se torna um alvo, ela deixa de ser uma boa medida.” Empiricamente, ao aumentar a distância KL entre política e referência, a recompensa *medida* r_ϕ cresce monotonicamente enquanto a qualidade avaliada por pessoas sobe, atinge um máximo e depois *cai*. O coeficiente β é, na prática, o controle desse compromisso — e a variável natural do eixo é a distância KL, não o número de passos de otimização.

O que se observou

- ▶ RLHF supera pré-treino mais ajuste supervisionado em avaliação humana, e a vantagem cresce com a escala (Stiennon et al., 2020).
- ▶ **InstructGPT** (Ouyang et al., 2022) levou o *pipeline* a dezenas de milhares de tarefas; um modelo muito menor, alinhado, foi preferido a um modelo bem maior sem alinhamento.
- ▶ Comparações controladas com GPT-4 como avaliador substituto (Dubois et al., 2023) confirmam que PPO funciona — mas mostram que linhas de base simples, como *best-of-n* e treinar sobre as saídas melhor classificadas, vão surpreendentemente longe.

A lição de engenharia: boa parte do ganho vem de *ter um bom modelo de recompensa*, não da sofisticação do otimizador. Se o RL é a parte cara e frágil, cabe perguntar se dá para eliminá-la.

6 DPO: otimização direta de preferências

6.1 A ideia

O modelo de recompensa é apenas um intermediário entre preferências e política. Se existir uma relação em forma fechada entre recompensa e política ótima, é possível substituir uma pela outra e treinar a política *diretamente* sobre os pares — eliminando o modelo de recompensa, o crítico, a amostragem online e a instabilidade do PPO. A derivação tem três passos.

6.2 Passo 1: a política ótima em forma fechada

Solução do objetivo com regularização KL

O máximo de $\mathbb{E}_{y \sim \pi}[r(x, y)] - \beta \text{KL}(\pi(\cdot | x) \parallel \pi_{\text{ref}}(\cdot | x))$ é atingido por

$$\pi_r(y | x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y | x) \exp\left(\frac{1}{\beta} r(x, y)\right), \quad Z(x) = \sum_y \pi_{\text{ref}}(y | x) \exp\left(\frac{1}{\beta} r(x, y)\right).$$

Demonstração

Divida o objetivo por β e complete o logaritmo:

$$\begin{aligned} \max_{\pi} \mathbb{E}_{y \sim \pi} \left[\frac{1}{\beta} r(x, y) - \log \frac{\pi(y | x)}{\pi_{\text{ref}}(y | x)} \right] &= \min_{\pi} \mathbb{E}_{y \sim \pi} \left[\log \frac{\pi(y | x)}{\pi_{\text{ref}}(y | x)} - \frac{1}{\beta} r(x, y) \right] \\ &= \min_{\pi} \mathbb{E}_{y \sim \pi} \left[\log \frac{\pi(y | x)}{\frac{1}{Z(x)} \pi_{\text{ref}}(y | x) e^{r(x, y)/\beta}} \right] - \log Z(x) \\ &= \min_{\pi} \text{KL}(\pi(\cdot | x) \parallel \pi_r(\cdot | x)) - \log Z(x). \end{aligned}$$

Como $Z(x)$ não depende de π , e a divergência KL é não negativa e nula somente quando os argumentos coincidem, o mínimo ocorre em $\pi = \pi_r$. $\square$

6.3 Passo 2: inverter a relação

A forma fechada é inútil como algoritmo: $Z(x)$ soma sobre todas as respostas possíveis, o que é intratável. Mas ela pode ser *invertida*:

$$\pi_r(y | x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y | x) e^{r(x, y)/\beta} \iff r(x, y) = \beta \log \frac{\pi_r(y | x)}{\pi_{\text{ref}}(y | x)} + \beta \log Z(x)$$

Toda função de recompensa pode, portanto, ser escrita como uma razão logarítmica entre uma política e a referência. A razão é positiva quando a política gosta da resposta *mais* que o modelo de referência, e negativa quando gosta menos. O termo problemático $\beta \log Z(x)$ depende apenas de x — e o modelo de Bradley–Terry só enxerga *diferenças* de recompensa para o mesmo x .

6.4 Passo 3: substituir

$$r(x, y_w) - r(x, y_\ell) = \beta \log \frac{\pi_\theta(y_w | x)}{\pi_{\text{ref}}(y_w | x)} - \beta \log \frac{\pi_\theta(y_\ell | x)}{\pi_{\text{ref}}(y_\ell | x)} + \underbrace{\beta \log Z(x) - \beta \log Z(x)}_{=0}$$

Levando isso à perda de entropia cruzada do modelo de recompensa, obtém-se um objetivo que envolve *apenas* a política:

Perda do DPO (Rafailov et al., NeurIPS 2023)

$$\mathcal{L}_{\text{DPO}}(\pi_\theta; \pi_{\text{ref}}) = -\mathbb{E}_{(x, y_w, y_\ell) \sim \mathcal{D}} \left[\log \sigma \left(\beta \log \frac{\pi_\theta(y_w | x)}{\pi_{\text{ref}}(y_w | x)} - \beta \log \frac{\pi_\theta(y_\ell | x)}{\pi_{\text{ref}}(y_\ell | x)} \right) \right]$$

Uma perda supervisionada, sobre um conjunto fixo de pares. Sem amostragem, sem crítico, sem modelo de recompensa explícito.

6.5 O gradiente e sua leitura

Definindo a **recompensa implícita** $\hat{r}_\theta(x, y) = \beta \log \frac{\pi_\theta(y|x)}{\pi_{\text{ref}}(y|x)}$,

$$\nabla_\theta \mathcal{L}_{\text{DPO}} = -\beta \mathbb{E}_{(x, y_w, y_\ell)} \left[\underbrace{\sigma(\hat{r}_\theta(x, y_\ell) - \hat{r}_\theta(x, y_w))}_{\text{peso: quão errado o modelo está}} (\nabla_\theta \log \pi_\theta(y_w | x) - \nabla_\theta \log \pi_\theta(y_\ell | x)) \right].$$

A estrutura é a do gradiente de política — aumente a log-probabilidade do que foi preferido, diminua a do que foi preterido — com um **peso adaptativo** que quase se anula nos pares que o modelo já ordena corretamente e concentra o esforço nos que ele ainda erra. Esse peso é o que distingue o DPO de treinar ingenuamente por máxima verossimilhança sobre y_w , que colapsaria a distribuição.

Intuição

Onde está o modelo de recompensa no DPO? *Nos pesos da política.* A razão $\beta \log(\pi_\theta/\pi_{\text{ref}})$ é um modelo de recompensa reparametrizado; o termo $\beta \log Z(x)$ continua existindo e fixando a normalização, apenas não precisa ser conhecido, porque a perda só depende de diferenças com o mesmo x .

6.6 O que se ganha e o que se perde

	RLHF (PPO)	DPO
Modelos em memória	4	2
Dados	<i>online</i> , regerados	<i>offline</i> , fixos
Estabilidade	sensível a hiperparâmetros	perda supervisionada
Rotular dados novos	a qualquer momento	exige nova coleta
Explorar fora do conjunto	sim	não

A última linha é a limitação real: o DPO só reordena o que já está no conjunto de dados, e nunca descobre uma resposta melhor que ninguém escreveu. Daí as variantes *iterativas*, que alternam geração com a política corrente, rotulagem e uma nova rodada de DPO.

Empiricamente, num experimento controlado — gerar resenhas positivas com GPT-2 XL, usar um classificador de sentimento como recompensa “de ouro”, construir preferências sintéticas a partir dela e otimizar com PPO e com DPO — o DPO obtém recompensa igual ou maior para o *mesmo* desvio KL da referência. Em escala, DPO e variantes tornaram-se padrão em famílias abertas de modelos (Zephyr, Mistral, Llama 3). A mesma ideia foi levada para preferências sobre trajetórias de controle, fora do domínio de linguagem, sob o nome CPL.

Para discutir em aula

O DPO herda inteira a hipótese de Bradley–Terry: preferências ruidosas, transitivas, geradas por uma recompensa latente escalar. Discuta situações realistas em que essa hipótese falha — múltiplos avaliadores com valores conflitantes, respostas incomparáveis, critérios em conflito — e o que se poderia fazer nesses casos.

6.7 Onde a área foi depois

Duas direções se destacam. A primeira afrouxa hipóteses de Bradley–Terry: IPO substitui a logística por um objetivo que não satura, KTO dispensa pares (bastam rótulos binários de aprovação), ORPO funde ajuste supervisionado e alinhamento numa única etapa.

A segunda é mais radical: quando a correção pode ser **verificada** — uma prova formal, um teste unitário que passa, uma resposta numérica conferível — a recompensa deixa de ser aprendida e volta a ser *dada*. É o regime de RLVR (*RL with verifiable rewards*) e de algoritmos como GRPO, que dispensam tanto o modelo de recompensa quanto o crítico. Nesse regime, todos os problemas de sobre-otimização discutidos nesta aula simplesmente desaparecem — o que explica por que ele domina o trabalho recente em raciocínio.

7 Formulário

Objeto	Expressão
Erro da clonagem	$J(\hat{\pi}) \leq J(\pi^E) + T^2 \varepsilon$
Erro do DAGGER	$J(\pi_i) \leq J(\pi^E) + O(T\varepsilon) + o(1)$
Invariância por potencial	$R' = R + \gamma\Phi(s') - \Phi(s)$ preserva π^*
Valor com atributos	$V^\pi = w^\top \mu(\pi), \quad \mu(\pi) = \mathbb{E}[\sum_t \gamma^t x(s_t) \mid \pi]$
MaxEnt IRL	$P(\tau \mid w) \propto \exp(w^\top x(\tau)); \quad \nabla_w \mathcal{L} = \tilde{x}_E - \mathbb{E}_P[x(\tau)]$
Bradley–Terry	$\mathbb{P}(b_i \succ b_j) = \sigma(r(b_i) - r(b_j))$
Modelo de recompensa	$\mathcal{L}(\phi) = -\mathbb{E}[\log \sigma(r_\phi(x, y_w) - r_\phi(x, y_\ell))]$
Objetivo do RLHF	$\max_{\pi_\theta} \mathbb{E}[r_\phi(x, y)] - \beta \text{KL}(\pi_\theta \parallel \pi_{\text{ref}})$
Política ótima	$\pi_r(y \mid x) \propto \pi_{\text{ref}}(y \mid x) e^{r(x, y)/\beta}$
Recompensa implícita	$\hat{r}_\theta(x, y) = \beta \log \frac{\pi_\theta(y \mid x)}{\pi_{\text{ref}}(y \mid x)}$
Perda do DPO	$-\mathbb{E}[\log \sigma(\hat{r}_\theta(x, y_w) - \hat{r}_\theta(x, y_\ell))]$

8 Exercícios

Exercício 8.1 — O expoente

Considere um MDP determinístico em cadeia com T passos, em que um único erro leva a um estado absorvente de custo 1 por passo, e o especialista nunca visita esse estado. Mostre que o custo esperado da política clonada é $\Theta(\varepsilon T^2)$ quando $\varepsilon T \ll 1$. Explique por que o limite superior de Ross & Bagnell é, portanto, justo.

Exercício 8.2 — Modelagem por potencial

Verifique explicitamente, num MDP de três estados à sua escolha, que $R' = R + \gamma\Phi(s') - \Phi(s)$ preserva a política ótima mas *altera* V^* . Que função Φ tornaria $V^* \equiv 0$?

Exercício 8.3 — Bradley–Terry, invariâncias

(a) Mostre que r e $r + c$ induzem as mesmas probabilidades p_{ij} . (b) Mostre que *não* vale o mesmo para cr com $c \neq 1$: descreva o efeito de $c \rightarrow \infty$ e de $c \rightarrow 0$ sobre as preferências previstas. (c) Que interpretação isso dá ao coeficiente β do DPO?

Exercício 8.4 — Condorcet sem Bradley–Terry

Construa uma matriz 3×3 de probabilidades p_{ij} com um ciclo ($p_{12}, p_{23}, p_{31} > 0,5$). Mostre que não há vencedor de Condorcet, calcule os vencedores de Copeland e de Borda, e argumente por que nenhuma recompensa escalar reproduz essa matriz.

Exercício 8.5 — Deduzindo o DPO

Refaça a derivação das três etapas sem consultar o texto. No passo 3, explique com precisão *por que* $\log Z(x)$ cancela, e o que aconteceria se as duas respostas de um par viessem de prompts *diferentes*.

Exercício 8.6 — Implementação

Implemente o DPO num problema de brinquedo: um bandido com $k = 8$ braços, π_{ref} uniforme, recompensa “de ouro” r^* conhecida, e pares gerados segundo Bradley–Terry a partir de r^* . Compare (i) treinar um modelo de recompensa e depois otimizar a política com penalidade KL, e (ii) DPO direto. Trace a fronteira recompensa $\times$ KL para vários valores de β .

Respostas comentadas dos dois primeiros

8.1. Seja E o instante do primeiro erro. Para $\varepsilon T \ll 1$, $\mathbb{P}(E = t) \approx \varepsilon$ e o custo condicional é $T - t$. Logo $\mathbb{E}[\text{custo}] \approx \varepsilon \sum_{t=1}^T (T - t) = \varepsilon T(T - 1)/2$. O limite superior é atingido porque a construção realiza o pior caso: nenhum estado após o erro pertence ao suporte dos dados, e o custo é máximo em todos.

8.2. A política ótima é preservada pelo argumento telescópico da seção 3.1. Já V^* muda por $-\Phi(s)$: de fato, $V'^*(s) = V^*(s) - \Phi(s)$. Portanto $\Phi = V^*$ torna $V'^* \equiv 0$ — o que revela que modelagem por potencial com o potencial “certo” é exatamente o que transforma o problema em trivial, e por que Φ é tipicamente escolhida como uma *aproximação* de V^* .

9 Glossário e leituras

Inglês	Português usado no curso
imitation learning	aprendizagem por imitação
behavior cloning	clonagem de comportamento
compounding errors	erros compostos
distribution shift	deslocamento de distribuição
inverse RL	aprendizado por reforço inverso
reward shaping (potential-based)	modelagem de recompensa por potencial
feature expectations	esperanças de atributos
pairwise comparison	comparação par a par
preference learning	aprendizado de preferências
reward model	modelo de recompensa
reward hacking / overoptimization	exploração da recompensa / sobre-otimização
preferred / dispreferred response	resposta preferida / preterida

Leituras principais. Ross, Gordon & Bagnell (2011), *A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning*; Ng & Russell (2000), *Algorithms for Inverse Reinforcement Learning*; Ziebart, Maas, Bagnell & Dey (2008), *Maximum Entropy Inverse Reinforcement Learning*; Christiano et al. (2017), *Deep Reinforcement Learning from Human Preferences*; Stiennon et al. (2020), *Learning to Summarize from Human Feedback*; Ouyang et al. (2022), *Training Language Models to Follow Instructions with Human Feedback*; Rafailov et al. (2023), *Direct Preference Optimization*.

Atenção

Uma pergunta que a técnica não responde, e que vale trazer para a sala: *de quem* são as preferências usadas para rotular os pares, e quem decide isso. Agregar preferências de um grupo com valores conflitantes esbarra em teoremas de impossibilidade conhecidos desde Arrow — de modo que “alinhar a preferências humanas” é, no plural, uma escolha de projeto, não um detalhe de implementação.