

Aula 10: Aprendizado rápido II

A cota de arrependimento do UCB e o problema do alinhamento

Arrependimento • Prova da cota do UCB • PAC e bandits bayesianos • Alinhamento de valores

Prof. Marcelo Keese Albertini
Universidade Federal de Uberlândia
adaptado de Emma Brunskill, CS234 (Stanford)
2026



Onde estamos

- ▶ **Aula anterior.** O *bandit* multiarmado, a noção de **arrependimento** e o UCB como encarnação do princípio do *otimismo diante da incerteza*.
- ▶ **Hoje.** Duas coisas de natureza muito diferente: a **prova** de que o UCB tem arrependimento logarítmico; e o **problema do alinhamento** — já sabemos otimizar uma função recompensa, falta perguntar *qual*.
- ▶ **Próxima aula.** Aprendizado bayesiano e MDPs: exploração eficiente quando as ações também mudam o estado.

Intuição

A primeira metade da aula é a mais técnica do curso; a segunda, a menos técnica. Elas se encontram num ponto: uma cota de arrependimento garante que otimizamos bem o *objetivo que escrevemos*, e não diz nada sobre ele ser o objetivo certo.

Plano de hoje

1. **Revisão** — bandits, arrependimento, concentração e UCB, com a decomposição do arrependimento por braço.
2. **A cota do UCB** — enunciado, roteiro e prova completa (Teorema 7.1 de Lattimore & Szepesvári), leitura da cota, versão minimax e cotas inferiores.
3. **Além do arrependimento** — o critério PAC, bandits bayesianos e amostragem de Thompson.
4. **Alinhamento de valores** — o que significa “fazer o que realmente queremos”, em três interpretações e dois estudos de caso.

Os itens 1–3 continuam diretamente a Aula 9. O item 4 corresponde à palestra convidada de Wanheng Hu (Stanford EIS/HAI) na versão original do curso.

SEÇÃO 1

Revisão: bandits, arrependimento e UCB

01

Teste de compreensão — bandits multiarmados

Teste sua compreensão

Quais das afirmações abaixo são verdadeiras?

1. Algoritmos que minimizam o arrependimento também maximizam a recompensa acumulada.
2. A menos de constantes, o UCB escolhe $\arg \max_a \hat{Q}_t(a) + f\left(\sqrt{1/N_t(a)}\right)$, para alguma função crescente f .
3. O UCB ainda aprenderia a puxar o braço ótimo mais que os demais com o bônus $\sqrt[4]{\log(t/\delta)/N_t(a)}$.
4. Com um bônus *constante* $b = 5$, o algoritmo é otimista quanto às recompensas empíricas, mas ainda pode sofrer arrependimento *linear*.
5. Um bandit de K braços é como um MDP de um único estado com K ações.

Pergunta para discussão conduzida em aula.

Teste de compreensão — comentários

As cinco são verdadeiras — por razões distintas

1. Verdadeira *por definição*: $L_n = nV^* - \mathbb{E}[\sum_t r_t]$ e nV^* não depende do algoritmo.
2. O que importa na forma do bônus é ser **decrecente em $N_t(a)$** : quanto mais puxo, menos incerto estou. Constantes e dependência em t mexem nas constantes da cota, não na natureza do algoritmo.
3. A raiz quarta encolhe *mais devagar* que a quadrada, logo explora *mais*: o braço ótimo ainda domina, com arrependimento pior. Bônus grandes demais custam caro; pequenos demais custam *tudo*.
4. O ponto crítico. Com b constante, a diferença entre os índices é a mesma que sem bônus: o otimismo só funciona se for **maior para o que é menos conhecido**. Um bônus constante nunca desfaz uma estimativa azarada — arrependimento $\Theta(n)$.
5. $|\mathcal{S}| = 1$, sem transições, γ irrelevante: é o menor MDP em que exploração ainda é um problema.

O bandit multiarmado: notação

Definição — Bandit multiarmado

Um par $(\mathcal{A}, \mathcal{R})$: conjunto *conhecido* de K ações (“braços”) e distribuições *desconhecidas* $\mathcal{R}_a(r) = \mathbb{P}[r \mid a]$. A cada passo o agente escolhe a_t e o ambiente devolve $r_t \sim \mathcal{R}_{a_t}$; o objetivo é maximizar $\sum_{\tau \leq n} r_\tau$.



$Q(a_1)$



$Q(a_2)$



V^*



$Q(a_4)$

$Q(a) = \mathbb{E}[r \mid a]$; $V^* = \max_a Q(a)$;
 $\Delta_i = V^* - Q(a_i)$ é a *lacuna* do braço i —
o custo, por passo, de puxá-lo em vez do
ótimo.

Escrevemos $\hat{Q}_t(a)$ para a média empírica do braço a e $N_t(a)$ para o número de vezes que ele foi escolhido até t .

Definição — Arrependimento instantâneo e total

$$\ell_t = \mathbb{E}[V^* - Q(a_t)], \quad L_n = \mathbb{E}\left[\sum_{t=1}^n (V^* - Q(a_t))\right].$$

- ▶ Maximizar recompensa acumulada $\iff$ minimizar arrependimento total.
- ▶ A esperança é sobre tudo: ruído das recompensas e aleatoriedade do algoritmo. A comparação é com o **melhor braço fixo em retrospecto**.

Intuição

A pergunta certa não é “ L_n é pequeno?” — ele cresce com n em qualquer algoritmo — e sim **como** ele cresce. Sublinear ($L_n/n \rightarrow 0$) significa que o agente acaba jogando quase sempre o braço ótimo; linear significa que erra uma fração constante do tempo, para sempre.

A decomposição que organiza toda a análise

Decomposição do arrependimento por braço

Para qualquer algoritmo e qualquer horizonte n : $L_n = \sum_{i=1}^K \Delta_i \mathbb{E}[N_n(a_i)]$.

Prova. Como $\sum_i N_n(a_i) = n$,

$$L_n = \mathbb{E}\left[\sum_{t=1}^n (V^* - Q(a_t))\right] = \mathbb{E}\left[\sum_{i=1}^K N_n(a_i) (V^* - Q(a_i))\right] = \sum_{i=1}^K \Delta_i \mathbb{E}[N_n(a_i)]. \quad \square$$

Intuição

A identidade converte um problema sobre *recompensas* num problema sobre *contagens*. Toda a prova de hoje é uma única tarefa: mostrar que $\mathbb{E}[N_n(a_i)] = O(\log n / \Delta_i^2)$. Braços péssimos são fáceis de descartar; o trabalho está nos braços *quase* tão bons quanto o ótimo.

Por que isso importa fora do quadro-negro


Triagem de COVID-19 nas fronteiras da Grécia — Bastani et al., *Nature* (2021)

O sistema *Eurydice* decidia **quais viajantes testar**, com orçamento fixo de testes por dia:

- ▶ **contextual** — o braço é um perfil de viajante (origem, idade, ponto de entrada);
- ▶ **não estacionário** — a prevalência muda semana a semana;
- ▶ **em lotes**, com **atraso** de dias no resultado e **restrição** de orçamento.

Detectou cerca do dobro de casos assintomáticos que a triagem aleatória.

Nenhuma dessas complicações está no modelo limpo que vamos analisar — e é justamente por isso que vale entendê-lo bem: é a peça que todas as variantes reutilizam.



A ferramenta: concentração

Definição — Variável σ -subgaussiana

X de média zero com $\mathbb{E}[e^{\lambda X}] \leq e^{\lambda^2 \sigma^2 / 2}$ para todo $\lambda \in \mathbb{R}$. Recompensas em $[0, 1]$ são $\frac{1}{2}$ -subgaussianas (Hoeffding); assumiremos $\sigma = 1$ para não carregar constantes.

A única cota que usaremos

Se $\hat{\mu}_s$ é a média de s amostras i.i.d. de média μ e ruído 1-subgaussiano, então para todo $\varepsilon > 0$

$$\mathbb{P}(\hat{\mu}_s \geq \mu + \varepsilon) \leq e^{-s\varepsilon^2/2}, \quad \mathbb{P}(\hat{\mu}_s \leq \mu - \varepsilon) \leq e^{-s\varepsilon^2/2}.$$

Intuição

Equivalentemente: com probabilidade $\geq 1 - \delta$, $|\hat{\mu}_s - \mu| < \sqrt{2 \log(1/\delta)/s}$. Leia como uma **barra de erro** — e é exatamente esse comprimento que o UCB usa como bônus.

O algoritmo UCB

Algoritmo — UCB(δ)

Puxe cada braço uma vez. Para $t = K + 1, \dots, n$, escolha

$$a_t = \arg \max_{a \in \mathcal{A}} \underbrace{\hat{Q}_{t-1}(a)}_{\text{o que já sei}} + \underbrace{\sqrt{\frac{2 \log(1/\delta)}{N_{t-1}(a)}}}_{\text{bônus de exploração}} = \arg \max_a \text{UCB}_a(t-1, \delta),$$

observe r_t e atualize $\hat{Q}_t(a_t)$ e $N_t(a_t)$.

- ▶ **Duas leituras do índice:** o extremo superior de um intervalo de confiança de nível $1 - \delta$ para $Q(a)$; ou o valor do braço *no melhor dos mundos plausíveis*.
- ▶ **Por que funciona:** se o braço é bom, jogá-lo é barato; se é ruim, jogá-lo revela isso e o índice cai. Não há um terceiro desfecho.

SEÇÃO 2

A cota de arrependimento do UCB

02

O resultado principal

Teorema (cota de arrependimento do UCB)

Para o $\text{UCB}(\delta)$ num bandit estocástico de K braços com ruído 1-subgaussiano e qualquer horizonte n , tomando $\delta = 1/n^2$,

$$L_n \leq 3 \sum_{i=1}^K \Delta_i + \sum_{i: \Delta_i > 0} \frac{16 \log n}{\Delta_i}.$$


Leitura em três tempos:

- ▶ o primeiro termo **não cresce com n** : é o preço fixo de experimentar cada braço um punhado de vezes;
- ▶ o segundo cresce como $\log n$ — *sublinear*, logo $L_n/n \rightarrow 0$;
- ▶ braços com lacuna pequena contribuem *mais* ($1/\Delta_i$).

Teorema 7.1 de Lattimore & Szepesvári, *Bandit Algorithms* (2020).

Roteiro da prova

Cinco passos; o resto é álgebra



Intuição

A ideia estrutural de toda análise de bandits: separe o mundo num **evento bom**, em que as barras de erro se comportam como prometido, e seu complemento, de probabilidade minúscula. No evento bom argumenta-se *deterministicamente*; fora dele usa-se a cota trivial $N_n(a_i) \leq n$.

Sem perda de generalidade a_1 é o braço ótimo ($\Delta_1 = 0$). Fixamos um braço subótimo a_i e trabalhamos com ele até o fim.

Passo 1 — o evento bom

Definição — Evento bom G_i

Com $\hat{\mu}_{i,s}$ = média das s primeiras recompensas do braço i e um inteiro u_i a escolher,

$$G_i = \underbrace{\left\{ Q(a_1) < \min_{t \in [n]} \text{UCB}_{a_1}(t, \delta) \right\}}_{(*)} \cap \underbrace{\left\{ \hat{\mu}_{i,u_i} + \sqrt{\frac{2 \log(1/\delta)}{u_i}} < Q(a_1) \right\}}_{(**)}$$

- ▶ $(*)$: o braço ótimo nunca é subestimado — seu índice fica acima da média verdadeira em todos os n passos.
- ▶ $(**)$: o braço i foi desmascarado — após u_i puxadas, mesmo com o bônus seu índice cai abaixo de $Q(a_1)$.

Intuição

Se as duas valem, o UCB não tem como escolher o braço i mais de u_i vezes — é o Passo 2.

Passo 2 — no evento bom, $N_n(a_i) \leq u_i$

Prova por contradição. Suponha $N_n(a_i) > u_i$. Então existe um instante t com $N_{t-1}(a_i) = u_i$ e $a_t = a_i$. Nesse instante,

$$\begin{aligned} \text{UCB}_{a_i}(t-1, \delta) &= \hat{\mu}_{i, u_i} + \sqrt{\frac{2 \log(1/\delta)}{u_i}} < Q(a_1) && \text{por } (**) \\ &< \text{UCB}_{a_1}(t-1, \delta) && \text{por } (*) \end{aligned}$$

Ou seja, o índice do braço ótimo era estritamente maior — e o UCB teria escolhido a_1 , não a_i . Contradição. □

Intuição

Este passo é **puramente determinístico**: toda a probabilidade foi empurrada para a definição de G_i , e aqui só se usa que o algoritmo é um $\arg \max$.

Passo 2 (cont.) — separando os dois mundos

$$\mathbb{E}[N_n(a_i)] = \mathbb{E}[\mathbf{1}\{G_i\}N_n(a_i)] + \mathbb{E}[\mathbf{1}\{G_i^c\}N_n(a_i)] \leq \underbrace{u_i}_{\text{Passo 2}} + \underbrace{n \mathbb{P}(G_i^c)}_{N_n \leq n}$$

- ▶ O primeiro termo é o **custo do aprendizado**: quantas amostras bastam para distinguir a_i de a_1 .
- ▶ O segundo é o **custo do azar**: se as barras de erro falharem, o algoritmo pode gastar todo o horizonte no braço errado.

Atenção

Toda a arte está em equilibrar os dois: u_i pequeno torna (**) improvável; δ grande torna (*) improvável. Vamos limitar $\mathbb{P}(G_i^c)$ e só então escolher u_i e δ .

Passo 3a — a probabilidade de (*) falhar

Se (*) falha, existe t com $Q(a_1) \geq \text{UCB}_{a_1}(t, \delta)$. Como o número de puxadas do braço 1 é algum $s \in \{1, \dots, n\}$,

$$\left\{ Q(a_1) \geq \min_{t \in [n]} \text{UCB}_{a_1}(t, \delta) \right\} \subseteq \bigcup_{s=1}^n \left\{ Q(a_1) \geq \hat{\mu}_{1,s} + \sqrt{\frac{2 \log(1/\delta)}{s}} \right\}.$$

Pela cota da união e pela concentração com $\varepsilon = \sqrt{2 \log(1/\delta)/s}$:

$$\mathbb{P}((*) \text{ falha}) \leq \sum_{s=1}^n e^{-s \cdot \frac{2 \log(1/\delta)}{2s}} = n \delta.$$

Intuição

O expoente cancela exatamente o s do denominador: cada barra de erro falha com probabilidade δ , e pagamos $n\delta$ por exigir que *todas* valham. É essa exigência uniforme em t que forçará $\delta \sim n^{-2}$.

Passo 3b — a probabilidade de $(**)$ falhar

Suponha u_i grande o bastante para que, para algum $c \in (0, 1)$,

$$\Delta_i - \sqrt{\frac{2 \log(1/\delta)}{u_i}} \geq c \Delta_i. \quad (\star)$$

Como $Q(a_1) = Q(a_i) + \Delta_i$:

$$\begin{aligned} \mathbb{P}((**) \text{ falha}) &= \mathbb{P}\left(\hat{\mu}_{i,u_i} - Q(a_i) \geq \Delta_i - \sqrt{\frac{2 \log(1/\delta)}{u_i}}\right) \\ &\leq \mathbb{P}(\hat{\mu}_{i,u_i} - Q(a_i) \geq c \Delta_i) \leq \exp\left(-\frac{u_i c^2 \Delta_i^2}{2}\right), \end{aligned}$$

usando $(\star)$ e depois a concentração. Somando com o Passo 3a:

$$\mathbb{E}[N_n(a_i)] \leq u_i + n\left(n\delta + \exp\left(-\frac{u_i c^2 \Delta_i^2}{2}\right)\right).$$

Passo 4 — escolhendo u_i

A desigualdade $(\star)$ é uma condição sobre u_i :

$$(1 - c)\Delta_i \geq \sqrt{\frac{2 \log(1/\delta)}{u_i}} \iff (1 - c)^2 \Delta_i^2 \geq \frac{2 \log(1/\delta)}{u_i} \iff u_i \geq \frac{2 \log(1/\delta)}{(1 - c)^2 \Delta_i^2}.$$

Tomamos o menor inteiro admissível, $u_i = \lceil 2 \log(1/\delta) / ((1 - c)^2 \Delta_i^2) \rceil$, e usamos $\exp(-u_i c^2 \Delta_i^2 / 2) \leq \delta^{c^2 / (1 - c)^2}$:

$$\mathbb{E}[N_n(a_i)] \leq 1 + \frac{2 \log(1/\delta)}{(1 - c)^2 \Delta_i^2} + n^2 \delta + n \delta^{c^2 / (1 - c)^2}.$$

Intuição

Duas forças opostas: aumentar u_i encolhe o termo exponencial, mas u_i aparece somado diretamente. Falta escolher c (quanta folga exigimos) e δ (quanta confiança).

Passo 5 — fechando as contas

Escolha $c = \frac{1}{2}$ e $\delta = 1/n^2$; então $c^2/(1-c)^2 = 1$ e $\log(1/\delta) = 2 \log n$:

$$\frac{2 \log(1/\delta)}{(1-c)^2 \Delta_i^2} = \frac{16 \log n}{\Delta_i^2}, \quad n^2 \delta + n \delta = 1 + \frac{1}{n} \leq 2.$$

Logo, para todo braço subótimo, $\mathbb{E}[N_n(a_i)] \leq 3 + 16 \log n / \Delta_i^2$ e, pela decomposição do Passo 0,

$$L_n = \sum_i \Delta_i \mathbb{E}[N_n(a_i)] \leq 3 \sum_{i=1}^K \Delta_i + \sum_{i: \Delta_i > 0} \frac{16 \log n}{\Delta_i}. \quad \blacksquare$$

O “3” é 1 (do teto em u_i) mais 2 (da probabilidade de azar) — constante, independente de n .

Como ler a cota

$$L_n \leq \underbrace{3 \sum_{i=1}^K \Delta_i}_{\text{constante em } n} + \underbrace{\sum_{i: \Delta_i > 0} \frac{16 \log n}{\Delta_i}}_{\text{cresce como } \log n}$$


- ▶ **Em n :** $O(\log n)$; com $n = 10^6$, $\log n \approx 14$.
- ▶ **Em Δ_i :** braços *péssimos* custam pouco, pois são identificados em poucas amostras. Em K : linear.
- ▶ **O que a cota não diz:** nada sobre variância ou sobre uma execução individual — é afirmação sobre a média.

Atenção

A cota **explode quando $\Delta_i \rightarrow 0$** — artefato da escrita, não do algoritmo: se Δ_i é minúsculo, puxar o braço i quase não custa. Precisamos de uma segunda leitura.

A tensão: braços quase ótimos

Um braço com lacuna Δ contribui no máximo $\min\{n\Delta, 16 \log n / \Delta\}$



- ▶ Δ_i *grande*: descartado depressa, custa pouco.
- ▶ Δ_i *minúsculo*: pode ser puxado quase sempre, mas cada puxada custa quase nada.
- ▶ O pior caso está no meio — grande o bastante para doer, pequeno o bastante para confundir.

Intuição

Esse “pior Δ ” é o que um adversário escolheria ao projetar a instância mais difícil. Formalizá-lo dá a cota independente da distribuição.

Cota independente da distribuição (minimax)

Corolário

Para o mesmo $\text{UCB}(1/n^2)$ e *qualquer* instância de K braços: $L_n \leq 3 \sum_i \Delta_i + 8\sqrt{Kn \log n}$.

Prova. Fixe um limiar $\Delta > 0$ e parta o somatório:

$$L_n = \sum_{i: \Delta_i < \Delta} \Delta_i \mathbb{E}[N_n(a_i)] + \sum_{i: \Delta_i \geq \Delta} \Delta_i \mathbb{E}[N_n(a_i)] \leq n\Delta + 3 \sum_i \Delta_i + \frac{16K \log n}{\Delta},$$

pois $\sum_i \mathbb{E}[N_n(a_i)] = n$. Minimizando $n\Delta + 16K \log n / \Delta$ obtém-se $\Delta^* = \sqrt{16K \log n / n}$ e valor $8\sqrt{Kn \log n}$. $\square$

Intuição

Duas cotas, dois regimes: a de $\log n$ é *dependente da instância*, ótima quando as lacunas são bem separadas; a de $\sqrt{Kn \log n}$ é *uniforme* e vale mesmo quando as lacunas conspiram.

Isso é bom? As cotas inferiores

Lai & Robbins (1985)

Para todo algoritmo *consistente*, em bandits de Bernoulli, $\liminf_n L_n / \log n \geq \sum_{i: \Delta_i > 0} \Delta_i / \text{KL}(\mathcal{R}_{a_i} \| \mathcal{R}_{a^*})$.

Cota inferior minimax

Para todo algoritmo existe uma instância de K braços com $L_n = \Omega(\sqrt{Kn})$.

- ▶ O $\log n$ é **inevitável**. O UCB é ótimo em ordem, com constante subótima ($1/\Delta_i$ em vez de Δ_i/KL).
- ▶ O $\sqrt{Kn}$ também é; o UCB paga um $\sqrt{\log n}$ a mais. **MOSS** e **KL-UCB** eliminam esses fatores.
- ▶ **Moral:** otimismo diante da incerteza não é uma heurística razoável — é essencialmente a resposta certa.

Letras miúdas que valem a pena

- ▶ $\delta = 1/n^2$ **exige conhecer n** . A versão *anytime* usa $\delta_t = 1/t^2$, ou seja bônus $\sqrt{2 \log t / N_t(a)}$ — é o “UCB1” da maioria dos textos.
- ▶ **Independência.** A concentração foi aplicada às u_i primeiras amostras do braço i , não às efetivamente coletadas — $N_n(a_i)$ é aleatório. A construção de recompensas pré-sorteadas em tabela é o que legitima o passo.
- ▶ **Ruído.** Com recompensas em $[0, 1]$ o parâmetro é $\frac{1}{2}$, o que melhora as constantes por um fator 4.
- ▶ **Estacionariedade.** A prova usa que $Q(a)$ é fixo. Em ambientes não estacionários é preciso esquecer o passado (janelas, descontos) e a garantia muda de forma.

Teste sua compreensão

Em que ponto exato da prova a estacionariedade foi usada? E se as recompensas tivessem caudas pesadas, qual passo quebraria primeiro?

Pergunta para discussão conduzida em aula.

SEÇÃO 3

Além do arrependimento: PAC e bandits bayesianos

03

Três maneiras de dizer “aprendeu rápido”

Critério	Pergunta que responde	Garantia típica
arrependimento	quanta recompensa perdi no caminho?	$L_n = O(\log n)$ ou $O(\sqrt{Kn})$
PAC	quantas amostras até <i>apontar</i> um braço quase ótimo?	$O(\sum_i \Delta_i^{-2} \log(K/\delta))$ puxadas
bayesiano	quão bem me saio em média sobre instâncias do <i>prior</i> ?	$\text{BayesReg}_n = O(\sqrt{Kn \log K})$

Intuição

São *perguntas diferentes*, não versões melhores ou piores do mesmo problema. Arrependimento importa quando cada decisão é real (tratar um paciente); PAC, quando há fase de teste barata e implantação cara (ensaios clínicos); bayesiano, quando há conhecimento prévio honesto.

O critério PAC: “provavelmente aproximadamente correto”

Definição — Algoritmo (ε, δ) -PAC

Após T puxadas devolve um braço $\hat{a}$ com $\mathbb{P}(Q(\hat{a}) \geq V^* - \varepsilon) \geq 1 - \delta$. O menor T é a **complexidade amostral**.

Algoritmo — Eliminação sucessiva

Comece com $\mathcal{A}_1 = \mathcal{A}$. Na rodada ℓ : puxe cada braço sobrevivente uma vez; elimine todo a com $\hat{Q}(a) + \beta_\ell < \max_{a'} \hat{Q}(a') - \beta_\ell$, onde $\beta_\ell = \sqrt{2 \log(K \ell^2 / \delta) / \ell}$; pare quando restar um braço ou $2\beta_\ell \leq \varepsilon$.


Complexidade amostral $O(\sum_{i: \Delta_i > 0} \Delta_i^{-2} \log(K/\delta))$ — a *mesma* dependência Δ^{-2} do u_i da prova do UCB. Não é coincidência: é o custo de distinguir duas médias a distância Δ .

Bandits bayesianos

Até aqui $Q(a)$ era um número fixo e desconhecido. A visão bayesiana o trata como **aleatório**, com uma crença atualizada por Bayes a cada observação.

Definição — Modelo Beta-Bernoulli

Recompensas em $\{0, 1\}$ com média θ_a e prior $\text{Beta}(\alpha_a, \beta_a)$. Após S_a sucessos e F_a falhas, a posterior é $\text{Beta}(\alpha_a + S_a, \beta_a + F_a)$.



Mais dados, posterior mais concentrada. A *largura* é a incerteza que o algoritmo vai explorar.

Amostragem de Thompson

Algoritmo — *Thompson sampling* (1933)

A cada passo t : sorteie $\tilde{\theta}_a \sim \mathbb{P}(\theta_a \mid \text{dados})$ para cada braço; jogue $a_t = \arg \max_a \tilde{\theta}_a$; observe r_t e atualize a posterior do braço jogado.

- ▶ Uma linha de código, uma ideia profunda: jogue cada braço com a *probabilidade de que ele seja o melhor*.
- ▶ Braços incertos têm posteriores largas e chance razoável de sortear valor alto: a exploração **emerge**, sem bônus explícito.
- ▶ Empiricamente costuma bater o UCB; teoricamente atinge as mesmas ordens.

Intuição

UCB é otimismo *determinístico* (o melhor cenário plausível); Thompson é otimismo *estocástico* (um cenário plausível sorteado). Caminhos opostos, mesmo destino.

Definição

Se a instância é sorteada de um prior $\mathbb{P}_0$, define-se $\text{BayesReg}_n = \mathbb{E}_{\text{instância} \sim \mathbb{P}_0}[L_n]$.

- ▶ É uma exigência *mais fraca* que a frequentista: o algoritmo pode ir mal em instâncias raras, desde que vá bem em média.
- ▶ Em troca, permite análises elegantes — a técnica do *information ratio* (Russo & Van Roy) dá $\text{BayesReg}_n \leq \sqrt{\frac{1}{2}Kn \log K}$ para Thompson.

A ponte para a próxima aula

Intuição

Para onde isso vai. Num MDP, agir muda também o *estado*: explorar deixa de ser “puxar um braço” e passa a ser “alcançar uma região do espaço de estados”. Os três critérios reaparecem: arrependimento (UCRL), PAC (R-max, MBIE) e bayesiano (PSRL). O bônus $\sqrt{\log(1/\delta)/N}$ provado hoje reaparece aplicado a pares (s, a) .

Teste sua compreensão

Por que um bônus por par (s, a) não basta em MDPs, sendo preciso propagar o otimismo pela equação de Bellman?

Pergunta para discussão conduzida em aula.

SEÇÃO 4

Alinhamento de valores

04

Uma mudança de pergunta

Tudo que fizemos até aqui — iteração de valor, Q-learning, gradientes de política, UCB — responde a uma única pergunta:

“Dada uma função recompensa, como maximizá-la bem e depressa?”

Esta seção faz a pergunta anterior a essa:

“Qual função recompensa? E quem decide?”

Intuição

Quanto melhor o otimizador, mais fielmente ele persegue exatamente o que foi escrito — inclusive os erros. Capacidade e alinhamento não são a mesma coisa: melhorar a primeira sem a segunda *amplifica* o problema.

Adaptado da palestra convidada de Wanheng Hu (Embedded EthiCS / HAI, Stanford), baseada em material de Dan Webber.

O maximizador de cliques de papel

Definição

Uma IA projetada para gerenciar a produção de uma fábrica recebe o objetivo de maximizar a fabricação de cliques de papel — e passa a converter primeiro a Terra, depois porções crescentes do universo observável, em cliques. (Bostrom, 2014)

- ▶ O exemplo é absurdo de propósito, mas o *mecanismo* é banal: o objetivo estava **subespecificado** e o otimizador preencheu a lacuna.
- ▶ As restrições que qualquer gerente assumiria eram implícitas — e implícito não entra na função recompensa.
- ▶ Nenhuma superinteligência é necessária: sistemas modestos já fazem isso em escala menor.

Atenção

Lei de Goodhart. Quando uma medida vira alvo, deixa de ser boa medida. Em RL isso não é um risco ocasional — é o comportamento *esperado* de um bom otimizador.

Casos reais: quando o agente vence o jogo errado

- ▶ **Do barco à pista.** Num jogo de corrida de barcos, o agente descobriu que dar voltas em círculo colhendo itens de bônus rendia mais pontos que terminar a prova — e nunca cruzou a linha de chegada. A recompensa era “pontos”; o objetivo era “vencer”.
- ▶ **Enganar o avaliador.** Um braço robótico treinado com feedback humano aprendeu a pôr a mão *entre a câmera e o objeto*, para parecer tê-lo agarrado.
- ▶ **Do entretenimento ao tratamento.** Recomendadores que maximizam engajamento favorecem o sensacionalismo e estreitam o repertório do usuário — nada disso escrito na função objetivo.
- ▶ **Bugs de simulação.** Agentes em simuladores físicos exploram falhas do integrador numérico para “voar”: ótimo para o problema formulado, inútil para o pretendido.

Intuição

O padrão é sempre o mesmo: há uma medida observável e barata correlacionada com o que queremos, e o otimizador acha a região em que a correlação quebra.

O problema, enunciado

Definição — Alinhamento de valores

Como projetar agentes de IA que façam o que *realmente queremos* que eles façam?

- ▶ O que realmente queremos é quase sempre mais sutil do que o que *dizemos* querer: operamos com um vasto pano de fundo de pressupostos difíceis de formalizar e fáceis de esquecer por serem óbvios.
- ▶ Não se resolve isso apenas “dando instruções melhores”: especificar uma função recompensa completa é tão difícil quanto especificar completamente uma intenção.
- ▶ E piora quando quem instrui não é especialista — o caso da maioria dos usuários de IA.

Atenção

Há uma ambiguidade escondida em “o que realmente queremos”: ela admite ao menos **três leituras**, que nem sempre coincidem, e cada uma leva a um projeto técnico distinto.

Interpretação 1 — alinhar às *intenções*

Definição

Um agente é alinhado se faz o que o usuário *pretendia* que ele fizesse.

- ▶ A IA dos cliques está desalinhada porque falhou em inferir a intenção verdadeira (maximizar produção *sujeito a restrições*) a partir da instrução literal.
- ▶ A solução seria traduzir instruções subespecificadas em intenções plenamente especificadas, incluindo condições não ditas.
- ▶ Gabriel (2020): captar a intenção pode exigir um modelo praticamente completo da linguagem e da interação humanas.

Atenção

Objeção. Intenções nem sempre rastreiam o que realmente queremos. Se pretendo maximizar cliques porque quero retorno sobre o investimento, e a IA sabe que outro produto renderia mais, obedecer minha intenção me dá o que eu quero?

Interpretação 2 — alinhar às *preferências reveladas*

Definição

Um agente é alinhado se faz o que o usuário *prefere* — inferido do comportamento e do *feedback*, não das declarações.

É a leitura tecnicamente mais familiar: é o que fazem a **aprendizagem por reforço inverso** (inferir R de trajetórias) e o **RLHF** (ajustar um modelo de recompensa a comparações).

Atenção

Três dificuldades. (i) Exige treinar sobre observação do usuário — caro, ruidoso e invasivo. (ii) **Não identificabilidade:** infinitas funções de recompensa são consistentes com um conjunto finito de comportamentos — a degenerescência clássica do IRL (Ng & Russell, 2000), em que recompensa constante explica *qualquer* política. (iii) Preferências sobre situações inéditas não se extrapolam de comportamento rotineiro.

A objeção reaparece um nível acima: assim como intenções divergem de preferências, preferências podem divergir do que é bom para mim.

Interpretação 3 — alinhar aos *melhores interesses*

Definição

Um agente é alinhado se faz o que é objetivamente melhor para o usuário.

- ▶ Diferentemente da intenção e da preferência revelada, o “melhor interesse objetivo” **não é determinável empiricamente**: é uma questão filosófica, não científica.
- ▶ **Má notícia**: filósofos discordam sobre o que é bom para uma pessoa — prazer? satisfação de desejos? bens objetivos como saúde e conhecimento?
- ▶ **Boa notícia**: há muito acordo prático — saúde, segurança, liberdade, conhecimento, relações e dignidade são quase universalmente tidos como bons.

Intuição

Para engenharia, o acordo prático costuma bastar — não é preciso resolver a teoria do bem-estar para concordar sobre os casos claros. O desacordo aparece nas margens, e é lá que as decisões de projeto ficam difíceis.

Autonomia e paternalismo

- ▶ Um dos bens mais reconhecidos é a **autonomia**: escolher por si mesmo como viver, *mesmo quando a escolha não é a melhor*.
- ▶ Tensão interna à terceira interpretação: agir pelo bem de alguém contra a vontade dessa pessoa é **paternalismo**, que prejudica um interesse real.
- ▶ Logo, mesmo um sistema que mire os melhores interesses tem razão para levar a sério intenções e preferências declaradas: as três interpretações são pesos num compromisso.

Alinhar a...	Mecanismo técnico	Falha característica
intenções	seguir instruções, esclarecer ambiguidade	literalismo; obediência a pedidos ruins
preferências reveladas	IRL, RLHF, modelos de recompensa	bajulação; vício; não identificabilidade
melhores interesses	regras, restrições, recusas	paternalismo; imposição de valores

Estudo de caso 1 — bajulação

Definição — Bajulação (*sycophancy*)

O sistema concorda com o usuário ou valida suas crenças mesmo quando elas são falsas, prejudiciais ou irracionais.

Observada em modelos treinados com RLHF, e com mecanismo transparente à luz desta aula: avaliadores humanos recompensam respostas que *parecem* úteis e agradáveis, e o modelo otimiza para agradar, não para ser verdadeiro. Goodhart em estado puro — “aprovação humana” é medida barata correlacionada com “resposta boa”.

Teste sua compreensão

Qual das três interpretações de alinhamento a bajulação melhor ilustra? Se você projetasse o processo de RLHF, o que mudaria para reduzi-la — e qual efeito colateral sua correção teria?

Estudo de caso 2 — agentes de IA

Imagine um agente pessoal que reserva viagens, compra, negocia com outros agentes e gerencia sua agenda.

Intuição

Preferências reveladas. Aprende seus padrões e age sozinho, por rapidez — às vezes sem perguntar.

Atenção

Melhores interesses. Acrescenta atrito pelo bem-estar de longo prazo: pergunta, recusa ou amplia a informação.

Teste sua compreensão

Quando o agente deve agir sem perguntar? Quando deve deferir? E existe caso em que ele deve *resistir* ao usuário — sob que autoridade?

Pergunta para discussão conduzida em aula.

“Quanto atrito” não é escolha de interface, e sim de qual interpretação de alinhamento o sistema encarna.

O que — ou quem — ficou de fora?

Pessoas que não são o usuário

- ▶ Toda a discussão anterior tem exatamente *um* beneficiário: intenções de quem? preferências de quem? interesses de quem?
- ▶ Quase toda decisão tem terceiros afetados: o candidato não contratado, o vizinho vigiado, o autor não creditado.
- ▶ Um agente perfeitamente alinhado ao usuário pode ser **perfeitamente prejudicial** aos demais — e nada em “maximize a utilidade do usuário” detecta isso. Em economia: **externalidades**; aqui: recompensa definida sobre o espaço errado.

Teste sua compreensão

Se dois agentes, cada um alinhado ao seu dono, negociam entre si, o resultado é bom para alguém? Que garantias de RL sobrevivem num ambiente com outros agentes que aprendem?

Pergunta para discussão conduzida em aula.

Onde o filósofo vira técnico

- ▶ **Sobreotimização do modelo de recompensa.** Em RLHF treina-se a política contra um $\hat{r}$ aprendido; quanto mais se otimiza $\hat{r}$, mais a política se afasta da região em que $\hat{r}$ é fiel — e a qualidade verdadeira *cai* depois de certo ponto. As curvas de sobreotimização são a versão empírica da lei de Goodhart.
- ▶ **Regularização por KL.** A correção padrão é penalizar $KL(\pi || \pi_{\text{ref}})$. Não conserta o objetivo; apenas limita quão longe o otimizador pode ir ao explorar suas falhas.
- ▶ **Recompensas verificáveis (RLVR).** Em matemática e código a recompensa pode ser *checada*, não estimada — o que elimina a bajulação, mas só existe onde há verificador.
- ▶ **Supervisão escalável.** Se o avaliador humano não consegue julgar a tarefa, o *feedback* deixa de ser sinal e vira ruído dirigido. Debate, decomposição de tarefas e crítica assistida são tentativas de resposta.
- ▶ **Incerteza sobre a recompensa.** Tratar R como desconhecida e manter uma posterior sobre ela — a maquinaria bayesiana da seção anterior, aplicada ao objetivo em vez de à dinâmica. Um agente incerto sobre o que você quer tem incentivo a perguntar, e a não desativar o próprio botão de desligar.

Parte técnica

- ▶ $L_n = \sum_i \Delta_i \mathbb{E}[N_n(a_i)]$ reduz tudo a contar puxadas.
- ▶ Evento bom mais cota trivial fora dele: o esqueleto da análise.
- ▶ UCB: $L_n \leq 3 \sum_i \Delta_i + \sum_i 16 \log n / \Delta_i$, e $O(\sqrt{Kn \log n})$ no pior caso.
- ▶ Cotas inferiores: $\log n$ e $\sqrt{Kn}$ são inevitáveis.
- ▶ Thompson é o irmão estocástico do UCB.

Intuição

O elo entre as metades: **a cota de arrependimento é condicional à função recompensa**. Ela garante convergência rápida ao ótimo de R e é silenciosa sobre a escolha de R — e a segunda metade da aula mora nesse silêncio.

Parte de alinhamento

- ▶ Otimizar bem o objetivo errado é pior, não melhor.
- ▶ “O que realmente queremos” tem três leituras — intenções, preferências reveladas, melhores interesses — e elas conflitam.
- ▶ Autonomia impede que a terceira vença as outras.
- ▶ Bajulação e agentes autônomos concretizam a tensão; terceiros afetados estão fora de toda a formulação usual.

Para ir além

- ▶ T. Lattimore e C. Szepesvári. *Bandit Algorithms*. Cambridge University Press, 2020 — seção 7.1 para a prova de hoje, capítulos 8–9 para minimax e cotas inferiores.
- ▶ P. Auer, N. Cesa-Bianchi e P. Fischer. Finite-time analysis of the multiarmed bandit problem. *Machine Learning*, 2002.
- ▶ T. L. Lai e H. Robbins. Asymptotically efficient adaptive allocation rules. *Advances in Applied Mathematics*, 1985.
- ▶ D. Russo, B. Van Roy et al. A tutorial on Thompson sampling. *Foundations and Trends in Machine Learning*, 2018.
- ▶ H. Bastani et al. Efficient and targeted COVID-19 border testing via reinforcement learning. *Nature*, 2021.
- ▶ A. Ng e S. Russell. Algorithms for inverse reinforcement learning. *ICML*, 2000 — não identificabilidade da recompensa.
- ▶ I. Gabriel. Artificial intelligence, values, and alignment. *Minds and Machines*, 2020 — a taxonomia usada nesta aula.
- ▶ N. Bostrom. *Superintelligence*. Oxford University Press, 2014.
- ▶ E. Brunskill. *CS234: Reinforcement Learning*, Stanford — *Lecture 10: Fast Reinforcement Learning*, com palestra convidada sobre alinhamento de valores por Wanheng Hu.