

Universidade Federal de Uberlândia

Aula 11: Bandits bayesianos e amostragem de Thompson

Conjugação Beta–Bernoulli • Casamento de probabilidade • Arrependimento bayesiano

Prof. Marcelo Keese Albertini
Universidade Federal de Uberlândia
adaptado de Emma Brunskill, CS234 (Stanford)
2026



Plano de hoje

Segunda metade do bloco de *aprendizagem rápida*

1. **Retomada** — bandits, arrependimento e o que o otimismo (UCB) resolve e o que ele deixa de fora.
2. **Inferência bayesiana** — prior, posterior, conjugação e o par Beta–Bernoulli, que é tudo de que precisaremos hoje.
3. **Bandits bayesianos** — Bayes-UCB e *casamento de probabilidade*.
4. **Amostragem de Thompson** — o algoritmo de quatro linhas que implementa casamento de probabilidade sem nunca calculá-lo.
5. **Arrependimento bayesiano** — como se avalia desempenho quando existe um prior, e o que se sabe provar.
6. **Além** — Gittins, bandits contextuais e a ponte de volta para MDPs.

A aula passada foi *otimismo* diante da incerteza; hoje é *amostragem* diante da incerteza.

SEÇÃO 1

Retomada: bandits, arrependimento e otimismo

01

Onde estamos

Definição — Bandit multiarmado

Par $(\mathcal{A}, \mathcal{R})$:

- ▶ $\mathcal{A}$: conjunto **conhecido** de m ações (braços);
- ▶ $\mathcal{R}^a(r) = \mathbb{P}[r \mid a]$: distribuição **desconhecida** de recompensas do braço a .

A cada passo t o agente escolhe $a_t \in \mathcal{A}$ e o ambiente devolve $r_t \sim \mathcal{R}^{a_t}$.

- ▶ Um bandit é um MDP de **um único estado**: a ação não muda onde você está, só o que você ganha e o que você aprende.
- ▶ Com $\gamma = 0$, a equação de Bellman vira $Q(a) = \mathbb{E}[r \mid a]$ — sem futuro, só a média.
- ▶ Toda a dificuldade que sobra é **exploração**.

Intuição

O bandit é o laboratório mínimo do dilema exploração–aproveitamento.

Arrependimento: a métrica da aula

Seja $V^* = \max_{a \in \mathcal{A}} Q(a)$ o valor do melhor braço e $\Delta_a = V^* - Q(a)$ a **lacuna** do braço a .

Definição — Arrependimento por passo e arrependimento total

$$\ell_t = \mathbb{E}[V^* - Q(a_t)], \quad L_T = \mathbb{E}\left[\sum_{t=1}^T V^* - Q(a_t)\right] = \sum_{a \in \mathcal{A}} \mathbb{E}[N_T(a)] \Delta_a,$$

onde $N_T(a)$ é o número de vezes que a foi puxado até T .

- ▶ Maximizar recompensa acumulada $\iff$ minimizar arrependimento total.
- ▶ A segunda igualdade é a chave da análise: **arrependimento é contagem de erros ponderada pela gravidade de cada erro**. Provar uma cota de arrependimento é provar que braços ruins são puxados poucas vezes.

Meta: arrependimento *sublinear*, $L_T/T \rightarrow 0$.

Retomada guiada: bandits determinísticos

Teste sua compreensão

Num problema de bandit com recompensas **determinísticas** (cada braço devolve sempre o mesmo valor), o que acontece com o UCB?

Ele tem arrependimento sublinear com probabilidade 1? Ou existe probabilidade estritamente positiva de arrependimento linear? Ou a divisão por $N_t(a)$ quebra o algoritmo em ambientes determinísticos?

Pergunta para discussão conduzida em aula.

- ▶ Vale destacar o papel do termo de confiança $\sqrt{2 \ln t / N_t(a)}$: ele existe para cobrir o *ruído amostral* da média empírica.
- ▶ Convém examinar o que sobra desse papel quando a variância é zero, e o que o algoritmo faz nos primeiros m passos, quando nenhum braço foi puxado ainda.

O que o otimismo faz — e o que ele não faz

UCB (aula passada)

$$a_t = \arg \max_{a \in \mathcal{A}} \underbrace{\hat{Q}_t(a)}_{\text{média empírica}} + \underbrace{\sqrt{\frac{2 \ln t}{N_t(a)}}}_{\text{bônus de incerteza}}$$

- ▶ Arrependimento $O\left(\sum_{a: \Delta_a > 0} \frac{\ln T}{\Delta_a}\right)$ — logarítmico, ótimo em ordem.
- ▶ Não precisa de nenhum conhecimento prévio além de uma cota nas recompensas.

Atenção

Três limitações que motivam a aula de hoje:

1. **É determinístico.** Com *feedback* em lote, repete a mesma escolha até chegar retorno.
2. **Ignora conhecimento prévio.** Sabendo que uma droga cura $\approx 90\%$, o UCB começa do zero mesmo assim.
3. **O bônus é genérico,** e por isso conservador demais para a distribuição que você de fato tem.

SEÇÃO 2

Inferência bayesiana em vinte minutos

02

A virada bayesiana

Até aqui não supusemos *nada* sobre $\mathcal{R}$ além de limites nas recompensas. A abordagem bayesiana faz o oposto: parte de uma distribuição **a priori** sobre os parâmetros e a atualiza com os dados.

Definição — Modelo bayesiano de um braço

A recompensa do braço i segue $r \sim p(r \mid \theta_i)$ com θ_i **desconhecido**. Damos a θ_i um prior $p(\theta_i)$ e, observado r_{i1} , atualizamos por Bayes:

$$p(\theta_i \mid r_{i1}) = \frac{p(r_{i1} \mid \theta_i) p(\theta_i)}{p(r_{i1})} = \frac{p(r_{i1} \mid \theta_i) p(\theta_i)}{\int p(r_{i1} \mid \theta_i) p(\theta_i) d\theta_i}.$$

Intuição

Mudança de objeto: em vez da estimativa pontual $\hat{Q}(a)$ com uma barra de erro colada por fora, carregamos uma **distribuição inteira** sobre $Q(a)$.

Anatomia da regra de Bayes

$$\underbrace{p(\theta | r)}_{\text{posterior}} = \frac{\overbrace{p(r | \theta)}^{\text{verossimilhança}} \overbrace{p(\theta)}^{\text{prior}}}{\underbrace{\int p(r | \theta) p(\theta) d\theta}_{\text{evidência (constante em } \theta)}} \propto p(r | \theta) p(\theta)$$

- ▶ O denominador não depende de θ : serve só para normalizar.
- ▶ **A dificuldade prática é a integral.** Sem estrutura adicional, ela não tem forma fechada — resta MCMC ou inferência variacional.

Atenção

A cada passo o bandit faz *uma* atualização. Se ela custar um MCMC, o algoritmo é inviável. Conjugação não é elegância matemática: é requisito de engenharia.

Conjugação

Definição — Prior conjugado

Um prior $p(\theta)$ é **conjugado** para uma verossimilhança $p(r \mid \theta)$ se o posterior $p(\theta \mid r)$ pertence à *mesma família paramétrica* do prior.

- ▶ A atualização vira um mapa entre hiperparâmetros, tipicamente somas: custo e memória $O(1)$ por observação.
- ▶ Toda família exponencial admite prior conjugado.

Recompensa	Prior conjugado	Uso típico
Bernoulli(θ)	$\text{Beta}(\alpha, \beta)$	clique, cura/falha, acerto
Gaussiana, σ^2 conhecida	$\mathcal{N}(\mu_0, \sigma_0^2)$	recompensa contínua
Categórica sobre K valores	$\text{Dirichlet}(\alpha_1 \dots \alpha_K)$	nota de 1 a 5
Poisson(λ)	$\text{Gama}(\alpha, \beta)$	contagens

Hoje só a primeira linha; as demais adaptam a aula a outros tipos de recompensa sem mudar a lógica.

O par Beta–Bernoulli

Recompensa binária: $r \in \{0, 1\}$, $r \sim \text{Bernoulli}(\theta)$. Exemplos: clique em anúncio, sucesso/fracasso de um tratamento, conversão de venda.

Definição — Distribuição Beta

$$p(\theta \mid \alpha, \beta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^{\alpha-1}(1 - \theta)^{\beta-1}, \quad \theta \in [0, 1], \quad \alpha, \beta > 0.$$

$$\mathbb{E}[\theta] = \frac{\alpha}{\alpha + \beta}, \quad \text{moda} = \frac{\alpha - 1}{\alpha + \beta - 2}, \quad \text{Var}[\theta] = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}.$$

- ▶ Beta(1, 1) é a **uniforme** em $[0, 1]$: ignorância total.
- ▶ A variância cai como $1/(\alpha + \beta)$: quanto mais dados, mais concentrada.

A atualização é somar 1 em um dos dois contadores

Conjugação Beta-Bernoulli

Se $\theta \sim \text{Beta}(\alpha, \beta)$ e observamos $r \in \{0, 1\}$ com $r \sim \text{Bernoulli}(\theta)$, então

$$\theta \mid r \sim \text{Beta}(\alpha + r, \beta + 1 - r).$$

Demonstração. Basta acompanhar os expoentes:

$$p(\theta \mid r) \propto \underbrace{\theta^r (1 - \theta)^{1-r}}_{\text{verossimilhança}} \cdot \underbrace{\theta^{\alpha-1} (1 - \theta)^{\beta-1}}_{\text{prior}} = \theta^{(\alpha+r)-1} (1 - \theta)^{(\beta+1-r)-1},$$


o núcleo de uma $\text{Beta}(\alpha + r, \beta + 1 - r)$; a constante se ajusta sozinha. $\square$

Intuição

Pseudo-contagens. $\alpha - 1$ e $\beta - 1$ são sucessos e fracassos *imaginários* embutidos no prior. Partindo de $\text{Beta}(1, 1)$, após S sucessos e F fracassos a média posterior é $\frac{S+1}{S+F+2}$ — a estimativa de Laplace, com dois dados fantasmas que impedem a certeza absoluta cedo demais.

O posterior se concentra

Um braço, cinco estágios: $\text{Beta}(1, 1) \rightarrow \text{Beta}(2, 1) \rightarrow \text{Beta}(4, 1) \rightarrow \text{Beta}(8, 2) \rightarrow \text{Beta}(30, 4)$



- ▶ A massa migra para a direita e encolhe: a média sobe de 0,5 para $30/34 \approx 0,88$ e o desvio-padrão cai de 0,29 para 0,055.
- ▶ A largura da curva é a incerteza — e é ela que dosará a exploração, sem que precisemos escrever nenhum bônus.

SEÇÃO 3

Bandits bayesianos

03

Definição — Bandit bayesiano

Um bandit em que se explora conhecimento prévio sobre as recompensas, $p[\mathcal{R}]$. A cada passo computa-se o posterior $p[\mathcal{R} \mid h_t]$, onde $h_t = (a_1, r_1, \dots, a_{t-1}, r_{t-1})$, e o posterior guia a exploração.

Intuição

O posterior é o **estado de conhecimento** do agente. Ele resume o histórico inteiro em $2m$ números — e, como veremos, é um estado no sentido literal: um MDP se esconde aí dentro.

Duas famílias de algoritmos usam esse posterior para explorar. Vejamos as duas.

Duas maneiras de explorar com o posterior

Bayes-UCB

Escolha um quantil alto do posterior:

$$a_t = \arg \max_a q_{1-1/t}(p(Q(a) \mid h_t))$$

Otimismo com o bônus *calibrado pelo posterior*, em vez de uma cota de concentração genérica. (Kaufmann, Cappé e Garivier, 2012.)

Casamento de probabilidade

Escolha cada ação com a probabilidade de que ela seja a melhor:

$$\pi(a \mid h_t) = \mathbb{P}[Q(a) > Q(a') \ \forall a' \neq a \mid h_t]$$

Sem otimismo explícito — só honestidade sobre a chance de cada braço ser o ótimo.

Se o prior for acurado, ambos batem os métodos que ignoram conhecimento prévio. Se for enganoso, ambos pagam por isso — voltaremos a esse ponto.

Casamento de probabilidade, de perto

$$\pi(a \mid h_t) = \mathbb{P}[Q(a) > Q(a'), \forall a' \neq a \mid h_t]$$

- ▶ **Por que é razoável.** Ações incertas têm cauda mais gorda, logo maior chance de serem o máximo — a exploração emerge da própria definição, sem bônus ad hoc.
- ▶ **Por que é difícil.** Calcular essa probabilidade analiticamente a partir dos posteriores exige uma integral m -dimensional a cada passo. Para m braços com posteriores Beta não há forma fechada simples.

Atenção

Cuidado com o nome. Em psicologia experimental, “*probability matching*” designa escolher a alternativa A numa fração das vezes igual à *frequência com que A dá recompensa* — e isso é comprovadamente subótimo. Aqui a probabilidade é outra: a de que A seja o **melhor braço**, dada a evidência acumulada. Os dois procedimentos coincidem apenas no caso degenerado de um braço só.

SEÇÃO 4

Amostragem de Thompson

04

O algoritmo

Algoritmo — Amostragem de Thompson (Thompson, 1933)

1. Inicialize um prior $p(\mathcal{R}^a)$ para cada braço a .
2. **para** $t = 1, 2, \dots$ **faça**
3. para cada a , **sorteie** $\tilde{\mathcal{R}}^a \sim p(\mathcal{R}^a \mid h_t)$ e calcule $\tilde{Q}(a) = \mathbb{E}[\tilde{\mathcal{R}}^a]$;
4. jogue $a_t = \arg \max_{a \in \mathcal{A}} \tilde{Q}(a)$;
5. observe r_t e atualize o posterior de a_t por Bayes.
6. **fim**

Intuição

Leia o passo 3 como: “*finja que um dos mundos compatíveis com meus dados é o verdadeiro — e aja de forma ótima nele.*” Daí o outro nome: **amostragem posterior**.

No caso Bernoulli o passo 3 sorteia $\tilde{\theta}_a \sim \text{Beta}(\alpha_a, \beta_a)$ e o passo 6 soma 1 em α_{a_t} ou em β_{a_t} .

Thompson implementa casamento de probabilidade

Equivalência

A probabilidade de a amostragem de Thompson escolher o braço a no passo t é exatamente $\pi(a \mid h_t)$, a probabilidade posterior de que a seja o braço ótimo.

Demonstração. O braço jogado por Thompson é $\arg \max_a \tilde{Q}(a)$, com $\tilde{Q} \sim p(\cdot \mid h_t)$. Logo


$$\begin{aligned}\mathbb{P}[a_t = a] &= \mathbb{E}_{\tilde{Q} \sim p(\cdot \mid h_t)} \left[\mathbb{1}(a = \arg \max_{a' \in \mathcal{A}} \tilde{Q}(a')) \right] \\ &= \mathbb{P}[Q(a) > Q(a'), \forall a' \neq a \mid h_t] = \pi(a \mid h_t),\end{aligned}$$

onde a segunda igualdade é a definição de esperança de uma indicadora sob o posterior. $\square$

Intuição

Em uma frase: **amostrar do posterior e tomar o $\arg \max$ é um estimador de Monte Carlo com uma única amostra** da integral que não sabíamos calcular — e uma amostra basta, porque tudo de que precisávamos era a ação sorteada segundo aquela distribuição.

Por que isso equilibra exploração e aproveitamento



- ▶ Sortear um ponto de cada curva e ficar com o maior dá, nesta crença: cirurgia 84,5%, esparadrapo 15,5%, nada $\approx 0\%$.
- ▶ O braço quase certamente ruim **some sozinho**; o plausível continua sendo testado *na medida da sua plausibilidade*.
- ▶ Concentrados os posteriores, a aleatoriedade evapora e o algoritmo vira guloso — **sem cronograma, sem hiperparâmetro**.

Exemplo: três modos de tratar um dedo quebrado

Parâmetros verdadeiros (desconhecidos do agente): cirurgia $\theta_1 = 0,95$ • esparadrapo $\theta_2 = 0,90$ • nada $\theta_3 = 0,10$

Prior: $\theta_i \sim \text{Beta}(1, 1)$ para os três braços.

Passo	Posteriores antes	Amostras	Escolha	Resultado e atualização
1	(1, 1) (1, 1) (1, 1)	0,30 0,50 0,60	a_3	$r = 0 \Rightarrow \theta_3 \sim \text{Beta}(1, 2)$
2	(1, 1) (1, 1) (1, 2)	0,70 0,50 0,30	a_1	$r = 1 \Rightarrow \theta_1 \sim \text{Beta}(2, 1)$
3	(2, 1) (1, 1) (1, 2)	0,71 0,65 0,10	a_1	$r = 1 \Rightarrow \theta_1 \sim \text{Beta}(3, 1)$
4	(3, 1) (1, 1) (1, 2)	0,75 0,45 0,40	a_1	$r = 1 \Rightarrow \theta_1 \sim \text{Beta}(4, 1)$

Atenção

Exemplo **fictício**: estes não são os desfechos reais das opções de tratamento para um dedo quebrado. O caso serve só para acompanhar a aritmética.

A mesma sequência, dois algoritmos

Passo	Otimismo	Thompson
1	a_1	a_3
2	a_2	a_1
3	a_3	a_1
4	a_1	a_1
5	a_2	a_1

- ▶ **Otimismo é sistemático:** varre os braços, porque o bônus $\sqrt{2 \ln t / N_t(a)}$ é enorme quando $N_t(a)$ é pequeno. Puxar a_3 é *obrigatório*.
- ▶ **Thompson é oportunista:** começou com azar, mas uma única observação $r = 0$ bastou para descartar o braço ruim.

Intuição

O otimismo *tem de* experimentar cada braço até sua incerteza cair; Thompson dispensa braços que a evidência já tornou implausíveis. (Numa amostra o TS ganha, noutra perde — o que se compara é a **média**.)


Thompson Bernoulli em seis linhas

```
alfa = np.ones(K); beta = np.ones(K)    # prior Beta(1,1) por braco
for t in range(T):
    theta = rng.beta(alfa, beta)         # 1 amostra de cada posterior
    a = int(np.argmax(theta))            # otimo no mundo sorteado
    r = puxar(a)                         # recompensa em {0,1}
    alfa[a] += r; beta[a] += 1 - r       # atualizacao conjugada
```

- ▶ Nenhum hiperparâmetro de exploração. Nenhum cronograma. Nenhuma cota de concentração.
- ▶ Custo por passo: $O(m)$ tempo, $O(m)$ memória. O mesmo do ϵ -guloso.
- ▶ Para recompensas contínuas, troque as duas últimas linhas pela atualização Normal–Normal; a estrutura não muda.

Evidência empírica no exemplo dos três tratamentos

Arrependimento acumulado médio sobre 1500 execuções, $\theta = (0,95; 0,90; 0,10)$



A curva de Thompson é a única que visivelmente achata. Em $T = 2000$: TS 9,2 • guloso 26,5 • UCB 45,7 • ε-guloso 68,6.

Uma armadilha que este gráfico esconde

O guloso aparece *acima* do UCB. Isso não contradiz a teoria — expõe o que uma curva média em horizonte curto consegue esconder.

Horizonte T	1.000	5.000	20.000
Guloso — arrependimento médio	13,2	58,9	229,9
Guloso — execuções presas no braço subótimo	23%	23%	23%
Thompson — arrependimento médio	9,2	13,0	15,7

Atenção

O guloso tem arrependimento **linear**: em 23% das execuções trava em a_2 e nunca mais sai. Só parece bom porque $\Delta_2 = 0,05$ é minúsculo — a reta tem inclinação pequena, mas é reta. Quadruplicar T quadruplica seu arrependimento; o de Thompson cresce como $\ln T$.

Moral: nunca compare algoritmos de exploração em um único horizonte, nem olhando só a média.

SEÇÃO 5

Arrependimento bayesiano

05

Dois modos de medir desempenho

Definição — Frequentista

Parâmetros verdadeiros e fixos θ ; a esperança é sobre o histórico gerado pelo algoritmo $\mathcal{A}$:

$$\text{Arrep}(\mathcal{A}, T; \theta) = \mathbb{E}_{\mathcal{A}} \left[\sum_{t=1}^T Q(a^*) - Q(a_t) \mid \theta \right]$$

Definição — Bayesiano

Há um prior p_{θ} sobre os parâmetros, e a média é tirada também sobre ele:

$$\text{ArrepBayes}(\mathcal{A}, T) = \mathbb{E}_{\theta \sim p_{\theta}} [\text{Arrep}(\mathcal{A}, T; \theta)]$$

Intuição

Consequência imediata: $\text{ArrepBayes}(\mathcal{A}, T) \leq \sup_{\theta} \text{Arrep}(\mathcal{A}, T; \theta)$ — **toda cota frequentista uniforme já é uma cota bayesiana**. A recíproca é falsa, e aí mora a diferença de dificuldade entre as duas análises.

Otimismo como técnica de demonstração

Suponha que $U_t(a)$ seja, com alta probabilidade, uma cota superior de $Q(a)$. No evento em que a cota vale,

$$\text{Arrep}(\mathcal{A}, T; \theta) = \mathbb{E} \left[\sum_{t=1}^T Q(a^*) - Q(a_t) \right] \leq \mathbb{E} \left[\sum_{t=1}^T U_t(a_t) - Q(a_t) \right].$$

- ▶ O passo usa duas coisas: $Q(a^*) \leq U_t(a^*)$ (a cota vale para o ótimo) e $U_t(a^*) \leq U_t(a_t)$ (o algoritmo escolheu a_t por ter o maior índice).
- ▶ À direita não sobra nada sobre a^* : o arrependimento virou a soma das larguras de confiança dos braços efetivamente puxados — e cotar isso é contar puxadas.

Intuição

Eis por que o otimismo é onipresente na teoria de bandits: não é só uma heurística, é o artifício que faz a demonstração fechar. E a análise bayesiana de Thompson usa **esse mesmo artifício**, embora o algoritmo não seja otimista.

O que se sabe provar

Garantia	Cota	Observação
UCB, frequentista	$O(\sqrt{mT \ln T})$	também $O(\sum_a \ln T / \Delta_a)$, dependente das lacunas
Thompson, bayesiano	$O(\sqrt{mT \ln T})$	Russo e Van Roy (2014), via <i>razão de informação</i> ; vale para qualquer prior
Thompson, frequentista	$O(\sqrt{mT \ln T})$	Agrawal e Goyal (2012, 2013), Bernoulli com prior Beta; constantes piores que as do UCB
Cota inferior (qualquer algoritmo)	$\Omega(\sqrt{mT})$	Lai e Robbins (1985); Auer et al. (2002)

- ▶ **Em ordem de grandeza, empate:** amostragem posterior tem as mesmas cotas do UCB, a menos de constantes.
- ▶ Na prática o TS costuma vencer — sobretudo em bandits **contextuais**, onde calibrar o bônus de otimismo é difícil.

Quando o prior atrapalha

As garantias bayesianas são *em média sobre o prior*. Se o prior for ruim, não há promessa nenhuma.

Dois braços: $\theta_{\text{ruim}} = 0,10$ e $\theta_{\text{bom}} = 0,50$.

Prior do braço ruim	Puxadas dele	Arrep. em $T = 1000$
Beta(1, 1) — uniforme	13,6	5,4
Beta(100, 1) — enganoso	204,0	81,6

Atenção

Beta(100, 1) afirma, antes de qualquer dado, que o braço acerta $\approx 99\%$ das vezes. Trazê-lo de volta à realidade exige cerca de cem fracassos, cada um deles um passo desperdiçado: o arrependimento fica $15\times$ maior.

Prática recomendada: priors *fracos* ($\alpha + \beta$ pequeno), salvo evidência histórica real. Um prior informativo é uma afirmação empírica e deve ser defendida como tal.

Compreensão guiada: Thompson e otimismo sob *feedback* em lote

Teste sua compreensão

Um portal de notícias recebe milhares de acessos por segundo. Com frequência, um novo leitor chega **antes** de sabermos se o leitor anterior clicou.

Nesse regime, o que se pode dizer sobre a comparação entre amostragem de Thompson e algoritmos de otimismo? E o que muda se o prior inicial for muito enganoso?

Pergunta para discussão conduzida em aula.

- ▶ Vale explorar a natureza **determinística** do UCB (histórico congelado $\Rightarrow$ índice congelado) e contrastá-la com a natureza **estocástica** do TS.
- ▶ Convém separar a pergunta empírica (o que funciona melhor aqui?) da teórica (quem tem a cota mais forte neste cenário?).

SEÇÃO 6

Além de Thompson: Gittins e o MDP de crenças

06

Definição — Bandit contextual

A cada passo, o ambiente sorteia i.i.d. um **contexto** x_t que afeta a recompensa de cada braço. O agente vê x_t , escolhe a_t e recebe $r_t \sim \mathcal{R}(\cdot \mid x_t, a_t)$.

- ▶ Recomendação de notícias: braços = artigos; contexto = perfil do leitor; recompensa = 1 se houve clique ($Q(x, a)$ = taxa de cliques).
- ▶ Fica entre o bandit e o MDP: há generalização entre situações, mas a ação ainda não move o estado.
- ▶ TS estende-se sem esforço: mantenha um posterior sobre os *parâmetros do modelo* $Q_w(x, a)$ (por exemplo, w linear com posterior gaussiano), sorteie $\tilde{w}$, jogue $\arg \max_a Q_{\tilde{w}}(x_t, a)$.
- ▶ Chapelle e Li (2010) mostraram empiricamente que o TS iguala ou supera o LinUCB em recomendação de notícias, com implementação mais simples e maior robustez a atrasos.

Thompson é ótimo?

Dado um prior e um horizonte conhecido, existe uma política que maximiza a recompensa esperada. TS não é, em geral, essa política.

- ▶ **Formalmente**, o problema bayesiano é um MDP: o estado é a **crença** (todos os pares (α_a, β_a)), a ação é o braço, e a transição é a atualização de Bayes. Chama-se *MDP de crenças*, e a política ótima sai de programação dinâmica sobre ele.
- ▶ **Computacionalmente**, isso é inviável de forma ingênua: o número de crenças alcançáveis cresce combinatoriamente com o horizonte, e a política é uma função de todo o histórico.

Intuição

Note a inversão: o bandit começou como o caso *fácil* do MDP (um estado só). Ao exigirmos otimalidade sob incerteza, ele volta a ser um MDP — de estado contínuo e alta dimensão. **A incerteza é, ela própria, um estado.**

Índice de Gittins

Definição — Política de índice

Política que calcula um índice de valor real para cada braço, usando somente as estatísticas *daquele braço* e o horizonte, e joga o braço de maior índice. (Definição de Lattimore e Szepesvári, *Bandit Algorithms*, 2019.)

Teorema do índice (Gittins, 1979)

Para um bandit bayesiano com braços **independentes** e critério de recompensa esperada **descontada** em horizonte infinito, a política ótima é uma política de índice: jogue sempre o braço de maior índice de Gittins.

- ▶ Resultado notável: reduz um problema m -dimensional a m problemas unidimensionais independentes.
- ▶ **Limitações.** Exige braços independentes, quebra com horizonte finito, é caro de calcular e não se estende ao caso contextual. Daí o uso de TS ou UCB na prática.

De volta ao RL: amostragem posterior em MDPs

A ideia de Thompson não depende de o problema ser um bandit.

Método	O que se sorteia	Referência
PSRL	um MDP inteiro do posterior sobre (P, R) , por episódio	Osband et al. (2013)
RLSVI	pesos ruidosos da função valor linear	Osband et al. (2016)
<i>Bootstrapped</i> DQN	uma das K cabeças da rede, por episódio	Osband et al. (2016)

Intuição

O padrão é sempre o mesmo: **sorteie um mundo plausível, aja de forma ótima nele por um episódio inteiro, atualize**. Manter a mesma amostra durante todo o episódio é o que produz *exploração profunda* — uma sequência *coerente* de decisões exploratórias, que o ϵ -guloso, sorteando de novo a cada passo, nunca alcança.

SEÇÃO 7

Síntese

07

Quatro estratégias, lado a lado

	ϵ -guloso	UCB	Thompson	Gittins
Usa conhecimento prévio	não	não	sim	sim
Determinístico	não	sim	não	sim
Arrependimento	linear (se ϵ fixo)	$O(\ln T)$	$O(\ln T)$	—
Ótimo (dado prior)	não	não	não	sim [†]
Custo por passo	$O(m)$	$O(m)$	$O(m)$	alto
Estende a contextual	sim	sim	sim, bem	não
Hiperparâmetro de exploração	ϵ	constante do bônus	nenhum	—

[†] Sob independência entre braços e critério descontado em horizonte infinito.

Intuição

ϵ -guloso explora *cegamente*, UCB explora *sistematicamente*, Thompson explora *na proporção da dúvida*. Só o último deixa os dados decidirem quanto.

Arrependimento e PAC no exemplo-brinquedo

Cirurgia 0,95 • esparadrapo 0,90 • nada 0,10, com tolerância $\varepsilon = 0,05$

Otimismo	TS	Ótimo	Arrep. otimismo	Otimismo em ε ?	Arrep. TS / TS em ε ?
a_1	a_3	a_1	0	sim	0,85 / não
a_2	a_1	a_1	0,05	sim	0 / sim
a_3	a_1	a_1	0,85	não	0 / sim
a_1	a_1	a_1	0	sim	0 / sim
a_2	a_1	a_1	0,05	sim	0 / sim
Total			0,95	4/5	0,85 / 4/5

- ▶ “Dentro de ε ” é o critério **PAC**: $\mathbb{1}(Q(a_t) \geq Q(a^*) - \varepsilon)$ — conta passos *quase ótimos*, sem pesar o tamanho do erro.
- ▶ Os critérios discordam: o arrependimento penaliza a_3 dezessete vezes mais que a_2 ; o PAC trata a_2 como acerto e a_3 como erro. **Escolher entre eles é decisão de projeto** — dano acumulado num ensaio clínico, boa configuração final numa busca de hiperparâmetros.

O que você deve dominar

- ▶ Explicar como bandits multiarmados se relacionam com MDPs, e por que o bandit isola o problema de exploração.
- ▶ Definir arrependimento e PAC, e dizer em que situação cada um é o critério apropriado.
- ▶ Demonstrar por que o UCB tem arrependimento sublinear, e dar exemplos em que guloso, ϵ -guloso e pessimismo têm arrependimento linear.
- ▶ Derivar a conjugação Beta–Bernoulli e ler (α, β) como pseudo-contagens.
- ▶ **Implementar** o UCB e a amostragem de Thompson para recompensas Bernoulli.
- ▶ Demonstrar que amostragem de Thompson implementa casamento de probabilidade.
- ▶ Distinguir arrependimento frequentista de bayesiano e explicar por que cotas frequentistas uniformes implicam cotas bayesianas.

Onde estamos e para onde vamos

- ▶ **Aula passada:** bandits, arrependimento, otimismo diante da incerteza (UCB) e PAC.
- ▶ **Hoje:** bandits bayesianos, amostragem de Thompson, arrependimento bayesiano e índice de Gittins.
- ▶ **A seguir:** levar exploração eficiente ao MDP completo, onde a ação move o estado e a exploração precisa ser *profunda*, não apenas local.

Intuição

Para levar: o otimismo age como se o melhor mundo plausível fosse verdade; Thompson, como se um mundo plausível sorteado ao acaso fosse verdade. Ambos exploram o bastante; só o segundo dispensa que você diga quanto.

Leituras. Sutton e Barto, *Reinforcement Learning*, 2.^a ed., cap. 2 (seções 2.7 e 2.9) • Russo, Van Roy, Kazerouni, Osband e Wen, *A Tutorial on Thompson Sampling* (2018) • Lattimore e Szepesvári, *Bandit Algorithms* (2020), caps. 34–36 • Chapelle e Li, *An Empirical Evaluation of Thompson Sampling* (NeurIPS 2011).