

Universidade Federal de Uberlândia

# Aula 11: Bandits bayesianos e amostragem de Thompson

Conjugação Beta–Bernoulli • Casamento de probabilidade •  
Arrependimento bayesiano

Prof. Marcelo Keese Albertini  
Universidade Federal de Uberlândia  
adaptado de Emma Brunskill, CS234 (Stanford)  
2026



# Plano de hoje

Segunda metade do bloco de *aprendizagem rápida*

---

1. **Retomada** — bandits, arrependimento e o que o otimismo (UCB) resolve e o que ele deixa de fora.
2. **Inferência bayesiana** — prior, posterior, conjugação e o par Beta–Bernoulli, que é tudo de que precisaremos hoje.
3. **Bandits bayesianos** — Bayes-UCB e *casamento de probabilidade*.
4. **Amostragem de Thompson** — o algoritmo de quatro linhas que implementa casamento de probabilidade sem nunca calculá-lo.
5. **Arrependimento bayesiano** — como se avalia desempenho quando existe um prior, e o que se sabe provar.
6. **Além** — Gittins, bandits contextuais e a ponte de volta para MDPs.

A aula passada foi *otimismo* diante da incerteza; hoje é *amostragem* diante da incerteza.

## SEÇÃO 1

# Retomada: bandits, arrependimento e otimismo

---

01

## Definição — Bandit multiarmado

Par  $(\mathcal{A}, \mathcal{R})$ :

- ▶  $\mathcal{A}$ : conjunto conhecido de  $m$  ações (braços);
- ▶  $\mathcal{R}^a(r) = \mathbb{P}[r \mid a]$ : distribuição desconhecida de recompensas do braço  $a$ .

A cada passo  $t$  o agente escolhe  $a_t \in \mathcal{A}$  e o ambiente devolve  $r_t \sim \mathcal{R}^{a_t}$ .

- ▶ Um bandit é um MDP de um único estado: a ação não muda onde você está, só o que você ganha e o que você aprende.
- ▶ Com  $\gamma = 0$ , a equação de Bellman vira  $Q(a) = \mathbb{E}[r \mid a]$  — sem futuro, só a média.
- ▶ Toda a dificuldade que sobra é exploração.

## Intuição

O bandit é o laboratório mínimo do dilema exploração–aproveitamento.

## Arrependimento: a métrica da aula

Seja  $V^* = \max_{a \in \mathcal{A}} Q(a)$  o valor do melhor braço e  $\Delta_a = V^* - Q(a)$  a **lacuna** do braço  $a$ .

### Definição — Arrependimento por passo e arrependimento total

$$\ell_t = \mathbb{E}[V^* - Q(a_t)], \quad L_T = \mathbb{E}\left[\sum_{t=1}^T V^* - Q(a_t)\right] = \sum_{a \in \mathcal{A}} \mathbb{E}[N_T(a)] \Delta_a,$$

onde  $N_T(a)$  é o número de vezes que  $a$  foi puxado até  $T$ .

- ▶ Maximizar recompensa acumulada  $\iff$  minimizar arrependimento total.
- ▶ A segunda igualdade é a chave da análise: **arrependimento é contagem de erros ponderada pela gravidade de cada erro**. Provar uma cota de arrependimento é provar que braços ruins são puxados poucas vezes.

Meta: arrependimento *sublinear*,  $L_T/T \rightarrow 0$ .

## Retomada guiada: bandits determinísticos

### Teste sua compreensão

Num problema de bandit com recompensas **determinísticas** (cada braço devolve sempre o mesmo valor), o que acontece com o UCB?

Ele tem arrependimento sublinear com probabilidade 1? Ou existe probabilidade estritamente positiva de arrependimento linear? Ou a divisão por  $N_t(a)$  quebra o algoritmo em ambientes determinísticos?

*Pergunta para discussão conduzida em aula.*

- ▶ Vale destacar o papel do termo de confiança  $\sqrt{2 \ln t / N_t(a)}$ : ele existe para cobrir o *ruído amostral* da média empírica.
- ▶ Convém examinar o que sobra desse papel quando a variância é zero, e o que o algoritmo faz nos primeiros  $m$  passos, quando nenhum braço foi puxado ainda.

# O que o otimismo faz — e o que ele não faz

## UCB (aula passada)

$$a_t = \arg \max_{a \in \mathcal{A}} \underbrace{\hat{Q}_t(a)}_{\text{média empírica}} + \underbrace{\sqrt{\frac{2 \ln t}{N_t(a)}}}_{\text{bônus de incerteza}}$$

- ▶ Arrependimento  $O\left(\sum_{a: \Delta_a > 0} \frac{\ln T}{\Delta_a}\right)$  — logarítmico, ótimo em ordem.
- ▶ Não precisa de nenhum conhecimento prévio além de uma cota nas recompensas.

### Atenção

Três limitações que motivam a aula de hoje:

1. **É determinístico.** Com *feedback* em lote, repete a mesma escolha até chegar retorno.
2. **Ignora conhecimento prévio.** Sabendo que uma droga cura  $\approx 90\%$ , o UCB começa do zero mesmo assim.
3. **O bônus é genérico,** e por isso conservador demais para a distribuição que você de fato tem.

SEÇÃO 2

Inferência bayesiana em vinte minutos

---

02



## A virada bayesiana

Até aqui não supusemos *nada* sobre  $\mathcal{R}$  além de limites nas recompensas. A abordagem bayesiana faz o oposto: parte de uma distribuição **a priori** sobre os parâmetros e a atualiza com os dados.

### Definição — Modelo bayesiano de um braço

A recompensa do braço  $i$  segue  $r \sim p(r \mid \theta_i)$  com  $\theta_i$  **desconhecido**. Damos a  $\theta_i$  um prior  $p(\theta_i)$  e, observado  $r_{i1}$ , atualizamos por Bayes:

$$p(\theta_i \mid r_{i1}) = \frac{p(r_{i1} \mid \theta_i) p(\theta_i)}{p(r_{i1})} = \frac{p(r_{i1} \mid \theta_i) p(\theta_i)}{\int p(r_{i1} \mid \theta_i) p(\theta_i) d\theta_i}.$$

### Intuição

Mudança de objeto: em vez da estimativa pontual  $\hat{Q}(a)$  com uma barra de erro colada por fora, carregamos uma **distribuição inteira** sobre  $Q(a)$ .

# Anatomia da regra de Bayes

$$\underbrace{p(\theta | r)}_{\text{posterior}} = \frac{\overbrace{p(r | \theta)}^{\text{verossimilhança}} \overbrace{p(\theta)}^{\text{prior}}}{\underbrace{\int p(r | \theta) p(\theta) d\theta}_{\text{evidência (constante em } \theta)}} \propto p(r | \theta) p(\theta)$$

- ▶ O denominador não depende de  $\theta$ : serve só para normalizar.
- ▶ **A dificuldade prática é a integral.** Sem estrutura adicional, ela não tem forma fechada — resta MCMC ou inferência variacional.

## Atenção

A cada passo o bandit faz *uma* atualização. Se ela custar um MCMC, o algoritmo é inviável. Conjugação não é elegância matemática: é requisito de engenharia.

# Conjugação

## Definição — Prior conjugado

Um prior  $p(\theta)$  é **conjugado** para uma verossimilhança  $p(r \mid \theta)$  se o posterior  $p(\theta \mid r)$  pertence à *mesma família paramétrica* do prior.

- ▶ A atualização vira um mapa entre hiperparâmetros, tipicamente somas: custo e memória  $O(1)$  por observação.
- ▶ Toda família exponencial admite prior conjugado.

| Recompensa                      | Prior conjugado                        | Uso típico                 |
|---------------------------------|----------------------------------------|----------------------------|
| Bernoulli( $\theta$ )           | Beta( $\alpha, \beta$ )                | clique, cura/falha, acerto |
| Gaussiana, $\sigma^2$ conhecida | $\mathcal{N}(\mu_0, \sigma_0^2)$       | recompensa contínua        |
| Categórica sobre $K$ valores    | Dirichlet( $\alpha_1 \dots \alpha_K$ ) | nota de 1 a 5              |
| Poisson( $\lambda$ )            | Gama( $\alpha, \beta$ )                | contagens                  |

Hoje só a primeira linha; as demais adaptam a aula a outros tipos de recompensa sem mudar a lógica.

## O par Beta–Bernoulli

Recompensa binária:  $r \in \{0, 1\}$ ,  $r \sim \text{Bernoulli}(\theta)$ . Exemplos: clique em anúncio, sucesso/fracasso de um tratamento, conversão de venda.

### Definição — Distribuição Beta

$$p(\theta \mid \alpha, \beta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^{\alpha-1} (1 - \theta)^{\beta-1}, \quad \theta \in [0, 1], \quad \alpha, \beta > 0.$$

$$\mathbb{E}[\theta] = \frac{\alpha}{\alpha + \beta}, \quad \text{moda} = \frac{\alpha - 1}{\alpha + \beta - 2}, \quad \text{Var}[\theta] = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}.$$

- ▶ Beta(1, 1) é a **uniforme** em  $[0, 1]$ : ignorância total.
- ▶ A variância cai como  $1/(\alpha + \beta)$ : quanto mais dados, mais concentrada.

# A atualização é somar 1 em um dos dois contadores

## Conjugação Beta–Bernoulli

Se  $\theta \sim \text{Beta}(\alpha, \beta)$  e observamos  $r \in \{0, 1\}$  com  $r \sim \text{Bernoulli}(\theta)$ , então

$$\theta \mid r \sim \text{Beta}(\alpha + r, \beta + 1 - r).$$

**Demonstração.** Basta acompanhar os expoentes:

$$p(\theta \mid r) \propto \underbrace{\theta^r (1 - \theta)^{1-r}}_{\text{verossimilhança}} \cdot \underbrace{\theta^{\alpha-1} (1 - \theta)^{\beta-1}}_{\text{prior}} = \theta^{(\alpha+r)-1} (1 - \theta)^{(\beta+1-r)-1},$$


o núcleo de uma  $\text{Beta}(\alpha + r, \beta + 1 - r)$ ; a constante se ajusta sozinha.  $\square$

## Intuição

**Pseudo-contagens.**  $\alpha - 1$  e  $\beta - 1$  são sucessos e fracassos *imaginários* embutidos no prior. Partindo de  $\text{Beta}(1, 1)$ , após  $S$  sucessos e  $F$  fracassos a média posterior é  $\frac{S+1}{S+F+2}$  — a estimativa de Laplace, com dois dados fantasmas que impedem a certeza absoluta cedo demais.

## O posterior se concentra

Um braço, cinco estágios:  $\text{Beta}(1, 1) \rightarrow \text{Beta}(2, 1) \rightarrow \text{Beta}(4, 1) \rightarrow \text{Beta}(8, 2) \rightarrow \text{Beta}(30, 4)$



- ▶ A massa migra para a direita e encolhe: a média sobe de 0,5 para  $30/34 \approx 0,88$  e o desvio-padrão cai de 0,29 para 0,055.
- ▶ **A largura da curva é a incerteza** — e é ela que dosará a exploração, sem que precisemos escrever nenhum bônus.

SEÇÃO 3

## Bandits bayesianos

---

03

# Bandits bayesianos

## Definição — Bandit bayesiano

Um bandit em que se explora conhecimento prévio sobre as recompensas,  $p[\mathcal{R}]$ . A cada passo computa-se o posterior  $p[\mathcal{R} \mid h_t]$ , onde  $h_t = (a_1, r_1, \dots, a_{t-1}, r_{t-1})$ , e o posterior guia a exploração.

## Intuição

O posterior é o **estado de conhecimento** do agente. Ele resume o histórico inteiro em  $2m$  números — e, como veremos, é um estado no sentido literal: um MDP se esconde aí dentro.

Duas famílias de algoritmos usam esse posterior para explorar. Vejamos as duas.



## Duas maneiras de explorar com o posterior

### Bayes-UCB

Escolha um quantil alto do posterior:

$$a_t = \arg \max_a q_{1-1/t}(p(Q(a) \mid h_t))$$

Otimismo com o bônus *calibrado pelo posterior*, em vez de uma cota de concentração genérica. (Kaufmann, Cappé e Garivier, 2012.)

### Casamento de probabilidade

Escolha cada ação com a probabilidade de que ela seja a melhor:

$$\pi(a \mid h_t) = \mathbb{P}[Q(a) > Q(a') \ \forall a' \neq a \mid h_t]$$

Sem otimismo explícito — só honestidade sobre a chance de cada braço ser o ótimo.

Se o prior for acurado, ambos batem os métodos que ignoram conhecimento prévio. Se for enganoso, ambos pagam por isso — voltaremos a esse ponto.

## Casamento de probabilidade, de perto

$$\pi(a \mid h_t) = \mathbb{P}[Q(a) > Q(a'), \forall a' \neq a \mid h_t]$$

- ▶ **Por que é razoável.** Ações incertas têm cauda mais gorda, logo maior chance de serem o máximo — a exploração emerge da própria definição, sem bônus ad hoc.
- ▶ **Por que é difícil.** Calcular essa probabilidade analiticamente a partir dos posteriores exige uma integral  $m$ -dimensional a cada passo. Para  $m$  braços com posteriores Beta não há forma fechada simples.

### Atenção

**Cuidado com o nome.** Em psicologia experimental, “*probability matching*” designa escolher a alternativa  $A$  numa fração das vezes igual à *frequência com que  $A$  dá recompensa* — e isso é comprovadamente subótimo. Aqui a probabilidade é outra: a de que  $A$  seja o **melhor braço**, dada a evidência acumulada. Os dois procedimentos coincidem apenas no caso degenerado de um braço só.

SEÇÃO 4

# Amostragem de Thompson

---

04

# O algoritmo

## Algoritmo — Amostragem de Thompson (Thompson, 1933)

1. Inicialize um prior  $p(\mathcal{R}^a)$  para cada braço  $a$ .
2. **para**  $t = 1, 2, \dots$  **faça**
3.   para cada  $a$ , **sorteie**  $\tilde{\mathcal{R}}^a \sim p(\mathcal{R}^a \mid h_t)$  e calcule  $\tilde{Q}(a) = \mathbb{E}[\tilde{\mathcal{R}}^a]$ ;
4.   jogue  $a_t = \arg \max_{a \in \mathcal{A}} \tilde{Q}(a)$ ;
5.   observe  $r_t$  e atualize o posterior de  $a_t$  por Bayes.
6. **fim**

## Intuição

Leia o passo 3 como: “*finja que um dos mundos compatíveis com meus dados é o verdadeiro — e aja de forma ótima nele.*” Daí o outro nome: **amostragem posterior**.

No caso Bernoulli o passo 3 sorteia  $\tilde{\theta}_a \sim \text{Beta}(\alpha_a, \beta_a)$  e o passo 6 soma 1 em  $\alpha_{a_t}$  ou em  $\beta_{a_t}$ .

# Thompson implementa casamento de probabilidade

## Equivalência

A probabilidade de a amostragem de Thompson escolher o braço  $a$  no passo  $t$  é exatamente  $\pi(a \mid h_t)$ , a probabilidade posterior de que  $a$  seja o braço ótimo.

**Demonstração.** O braço jogado por Thompson é  $\arg \max_a \tilde{Q}(a)$ , com  $\tilde{Q} \sim p(\cdot \mid h_t)$ . Logo


$$\begin{aligned}\mathbb{P}[a_t = a] &= \mathbb{E}_{\tilde{Q} \sim p(\cdot \mid h_t)} \left[ \mathbb{1}(a = \arg \max_{a' \in \mathcal{A}} \tilde{Q}(a')) \right] \\ &= \mathbb{P}[Q(a) > Q(a'), \forall a' \neq a \mid h_t] = \pi(a \mid h_t),\end{aligned}$$

onde a segunda igualdade é a definição de esperança de uma indicadora sob o posterior.  $\square$

## Intuição

Em uma frase: **amostrar do posterior e tomar o  $\arg \max$  é um estimador de Monte Carlo com uma única amostra** da integral que não sabíamos calcular — e uma amostra basta, porque tudo de que precisávamos era a ação sorteada segundo aquela distribuição.

## Por que isso equilibra exploração e aproveitamento



- ▶ Sortear um ponto de cada curva e ficar com o maior dá, nesta crença: cirurgia 84,5%, esparadrapo 15,5%, nada  $\approx 0\%$ .
- ▶ O braço quase certamente ruim **some sozinho**; o plausível continua sendo testado *na medida da sua plausibilidade*.
- ▶ Concentrados os posteriores, a aleatoriedade evapora e o algoritmo vira guloso — **sem cronograma, sem hiperparâmetro**.

## Exemplo: três modos de tratar um dedo quebrado

Parâmetros verdadeiros (desconhecidos do agente): cirurgia  $\theta_1 = 0,95$  • esparadrapo  $\theta_2 = 0,90$  • nada  $\theta_3 = 0,10$

Prior:  $\theta_i \sim \text{Beta}(1, 1)$  para os três braços.

| Passo | Posteriores antes    | Amostras       | Escolha | Resultado e atualização                             |
|-------|----------------------|----------------|---------|-----------------------------------------------------|
| 1     | (1, 1) (1, 1) (1, 1) | 0,30 0,50 0,60 | $a_3$   | $r = 0 \Rightarrow \theta_3 \sim \text{Beta}(1, 2)$ |
| 2     | (1, 1) (1, 1) (1, 2) | 0,70 0,50 0,30 | $a_1$   | $r = 1 \Rightarrow \theta_1 \sim \text{Beta}(2, 1)$ |
| 3     | (2, 1) (1, 1) (1, 2) | 0,71 0,65 0,10 | $a_1$   | $r = 1 \Rightarrow \theta_1 \sim \text{Beta}(3, 1)$ |
| 4     | (3, 1) (1, 1) (1, 2) | 0,75 0,45 0,40 | $a_1$   | $r = 1 \Rightarrow \theta_1 \sim \text{Beta}(4, 1)$ |

### Atenção

Exemplo **fictício**: estes não são os desfechos reais das opções de tratamento para um dedo quebrado. O caso serve só para acompanhar a aritmética.

## A mesma sequência, dois algoritmos

| Passo | Otimismo | Thompson |
|-------|----------|----------|
| 1     | $a_1$    | $a_3$    |
| 2     | $a_2$    | $a_1$    |
| 3     | $a_3$    | $a_1$    |
| 4     | $a_1$    | $a_1$    |
| 5     | $a_2$    | $a_1$    |

- ▶ **Otimismo é sistemático:** varre os braços, porque o bônus  $\sqrt{2 \ln t / N_t(a)}$  é enorme quando  $N_t(a)$  é pequeno. Puxar  $a_3$  é obrigatório.
- ▶ **Thompson é oportunista:** começou com azar, mas uma única observação  $r = 0$  bastou para descartar o braço ruim.

### Intuição

O otimismo *tem de* experimentar cada braço até sua incerteza cair; Thompson dispensa braços que a evidência já tornou implausíveis. (Numa amostra o TS ganha, noutra perde — o que se compara é a **média**.)



# Thompson Bernoulli em seis linhas


---

```
alfa = np.ones(K); beta = np.ones(K)    # prior Beta(1,1) por braco
for t in range(T):
    theta = rng.beta(alfa, beta)         # 1 amostra de cada posterior
    a = int(np.argmax(theta))            # otimo no mundo sorteado
    r = puxar(a)                         # recompensa em {0,1}
    alfa[a] += r; beta[a] += 1 - r       # atualizacao conjugada
```

- ▶ Nenhum hiperparâmetro de exploração. Nenhum cronograma. Nenhuma cota de concentração.
- ▶ Custo por passo:  $O(m)$  tempo,  $O(m)$  memória. O mesmo do  $\epsilon$ -guloso.
- ▶ Para recompensas contínuas, troque as duas últimas linhas pela atualização Normal–Normal; a estrutura não muda.

# Evidência empírica no exemplo dos três tratamentos

Arrependimento acumulado médio sobre 1500 execuções,  $\theta = (0,95; 0,90; 0,10)$



A curva de Thompson é a única que visivelmente achata. Em  $T = 2000$ : TS 9,2 • guloso 26,5 • UCB 45,7 • ε-guloso 68,6.

## Uma armadilha que este gráfico esconde

O guloso aparece *acima* do UCB. Isso não contradiz a teoria — expõe o que uma curva média em horizonte curto consegue esconder.

| Horizonte $T$                               | 1.000 | 5.000 | 20.000 |
|---------------------------------------------|-------|-------|--------|
| Guloso — arrependimento médio               | 13,2  | 58,9  | 229,9  |
| Guloso — execuções presas no braço subótimo | 23%   | 23%   | 23%    |
| Thompson — arrependimento médio             | 9,2   | 13,0  | 15,7   |

### Atenção

O guloso tem arrependimento **linear**: em 23% das execuções trava em  $a_2$  e nunca mais sai. Só parece bom porque  $\Delta_2 = 0,05$  é minúsculo — a reta tem inclinação pequena, mas é reta. Quadruplicar  $T$  quadruplica seu arrependimento; o de Thompson cresce como  $\ln T$ .

Moral: nunca compare algoritmos de exploração em um único horizonte, nem olhando só a média

SEÇÃO 5

# Arrependimento bayesiano

---

05

# Dois modos de medir desempenho

## Definição — Frequentista

Parâmetros verdadeiros e fixos  $\theta$ ; a esperança é sobre o histórico gerado pelo algoritmo  $\mathcal{A}$ :

$$\text{Arrep}(\mathcal{A}, T; \theta) = \mathbb{E}_{\mathcal{A}} \left[ \sum_{t=1}^T Q(a^*) - Q(a_t) \mid \theta \right]$$

## Definição — Bayesiano

Há um prior  $p_{\theta}$  sobre os parâmetros, e a média é tirada também sobre ele:

$$\text{ArrepBayes}(\mathcal{A}, T) = \mathbb{E}_{\theta \sim p_{\theta}} [\text{Arrep}(\mathcal{A}, T; \theta)]$$

## Intuição

Consequência imediata:  $\text{ArrepBayes}(\mathcal{A}, T) \leq \sup_{\theta} \text{Arrep}(\mathcal{A}, T; \theta)$  — **toda cota frequentista uniforme já é uma cota bayesiana**. A recíproca é falsa, e aí mora a diferença de dificuldade entre as duas análises.

## Otimismo como técnica de demonstração

Suponha que  $U_t(a)$  seja, com alta probabilidade, uma cota superior de  $Q(a)$ . No evento em que a cota vale,

$$\text{Arrep}(\mathcal{A}, T; \theta) = \mathbb{E} \left[ \sum_{t=1}^T Q(a^*) - Q(a_t) \right] \leq \mathbb{E} \left[ \sum_{t=1}^T U_t(a_t) - Q(a_t) \right].$$

- ▶ O passo usa duas coisas:  $Q(a^*) \leq U_t(a^*)$  (a cota vale para o ótimo) e  $U_t(a^*) \leq U_t(a_t)$  (o algoritmo escolheu  $a_t$  por ter o maior índice).
- ▶ À direita não sobra nada sobre  $a^*$ : o arrependimento virou a soma das larguras de confiança dos braços *efetivamente puxados* — e cotar isso é contar puxadas.

### Intuição

Eis por que o otimismo é onipresente na teoria de bandits: não é só uma heurística, é o artifício que faz a demonstração fechar. E a análise bayesiana de Thompson usa **esse mesmo artifício**, embora o algoritmo não seja otimista.

## O que se sabe provar

| Garantia                           | Cota                 | Observação                                                                              |
|------------------------------------|----------------------|-----------------------------------------------------------------------------------------|
| UCB, frequentista                  | $O(\sqrt{mT \ln T})$ | também $O(\sum_a \ln T / \Delta_a)$ , dependente das lacunas                            |
| Thompson, bayesiano                | $O(\sqrt{mT \ln T})$ | Russo e Van Roy (2014), via <i>razão de informação</i> ; vale para qualquer prior       |
| Thompson, frequentista             | $O(\sqrt{mT \ln T})$ | Agrawal e Goyal (2012, 2013), Bernoulli com prior Beta; constantes piores que as do UCB |
| Cota inferior (qualquer algoritmo) | $\Omega(\sqrt{mT})$  | Lai e Robbins (1985); Auer et al. (2002)                                                |

- ▶ **Em ordem de grandeza, empate:** amostragem posterior tem as mesmas cotas do UCB, a menos de constantes.
- ▶ Na prática o TS costuma vencer — sobretudo em bandits **contextuais**, onde calibrar o bônus de otimismo é difícil.

## Quando o prior atrapalha

As garantias bayesianas são *em média sobre o prior*. Se o prior for ruim, não há promessa nenhuma.

Dois braços:  $\theta_{\text{ruim}} = 0,10$  e  $\theta_{\text{bom}} = 0,50$ .

| Prior do braço ruim     | Puxadas dele | Arrep. em $T = 1000$ |
|-------------------------|--------------|----------------------|
| Beta(1, 1) — uniforme   | 13,6         | 5,4                  |
| Beta(100, 1) — enganoso | 204,0        | 81,6                 |

### Atenção

Beta(100, 1) afirma, antes de qualquer dado, que o braço acerta  $\approx 99\%$  das vezes. Trazê-lo de volta à realidade exige cerca de cem fracassos, cada um deles um passo desperdiçado: o arrependimento fica  $15\times$  maior.

Prática recomendada: priors *fracos* ( $\alpha + \beta$  pequeno), salvo evidência histórica real. Um prior informativo é uma afirmação empírica e deve ser defendida como tal.



## Compreensão guiada: Thompson e otimismo sob *feedback* em lote

### Teste sua compreensão

Um portal de notícias recebe milhares de acessos por segundo. Com frequência, um novo leitor chega **antes** de sabermos se o leitor anterior clicou.

Nesse regime, o que se pode dizer sobre a comparação entre amostragem de Thompson e algoritmos de otimismo? E o que muda se o prior inicial for muito enganoso?

*Pergunta para discussão conduzida em aula.*

- ▶ Vale explorar a natureza **determinística** do UCB (histórico congelado  $\Rightarrow$  índice congelado) e contrastá-la com a natureza **estocástica** do TS.
- ▶ Convém separar a pergunta empírica (o que funciona melhor aqui?) da teórica (quem tem a cota mais forte neste cenário?).

## SEÇÃO 6

# Além de Thompson: Gittins e o MDP de crenças

---

06

## Definição — Bandit contextual

A cada passo, o ambiente sorteia i.i.d. um **contexto**  $x_t$  que afeta a recompensa de cada braço. O agente vê  $x_t$ , escolhe  $a_t$  e recebe  $r_t \sim \mathcal{R}(\cdot \mid x_t, a_t)$ .

- ▶ Recomendação de notícias: braços = artigos; contexto = perfil do leitor; recompensa = 1 se houve clique ( $Q(x, a)$  = taxa de cliques).
- ▶ Fica entre o bandit e o MDP: há generalização entre situações, mas a ação ainda não move o estado.
- ▶ TS estende-se sem esforço: mantenha um posterior sobre os *parâmetros do modelo*  $Q_w(x, a)$  (por exemplo,  $w$  linear com posterior gaussiano), sorteie  $\tilde{w}$ , jogue  $\arg \max_a Q_{\tilde{w}}(x_t, a)$ .
- ▶ Chapelle e Li (2010) mostraram empiricamente que o TS iguala ou supera o LinUCB em recomendação de notícias, com implementação mais simples e maior robustez a atrasos.

## Thompson é ótimo?

Dado um prior e um horizonte conhecido, existe uma política que maximiza a recompensa esperada. TS não é, em geral, essa política.

- ▶ **Formalmente**, o problema bayesiano é um MDP: o estado é a **crença** (todos os pares  $(\alpha_a, \beta_a)$ ), a ação é o braço, e a transição é a atualização de Bayes. Chama-se *MDP de crenças*, e a política ótima sai de programação dinâmica sobre ele.
- ▶ **Computacionalmente**, isso é inviável de forma ingênua: o número de crenças alcançáveis cresce combinatoriamente com o horizonte, e a política é uma função de todo o histórico.

### Intuição

Note a inversão: o bandit começou como o caso *fácil* do MDP (um estado só). Ao exigirmos otimalidade sob incerteza, ele volta a ser um MDP — de estado contínuo e alta dimensão. **A incerteza é, ela própria, um estado.**

# Índice de Gittins

## Definição — Política de índice

Política que calcula um índice de valor real para cada braço, usando somente as estatísticas *daquele braço* e o horizonte, e joga o braço de maior índice. (Definição de Lattimore e Szepesvári, *Bandit Algorithms*, 2019.)

## Teorema do índice (Gittins, 1979)

Para um bandit bayesiano com braços **independentes** e critério de recompensa esperada **descontada** em horizonte infinito, a política ótima é uma política de índice: jogue sempre o braço de maior índice de Gittins.

- ▶ Resultado notável: reduz um problema  $m$ -dimensional a  $m$  problemas unidimensionais independentes.
- ▶ **Limitações.** Exige braços independentes, quebra com horizonte finito, é caro de calcular e não se estende ao caso contextual. Daí o uso de TS ou UCB na prática.

## De volta ao RL: amostragem posterior em MDPs

A ideia de Thompson não depende de o problema ser um bandit.

| Método                  | O que se sorteia                                          | Referência           |
|-------------------------|-----------------------------------------------------------|----------------------|
| PSRL                    | um MDP inteiro do posterior sobre $(P, R)$ , por episódio | Osband et al. (2013) |
| RLSVI                   | pesos ruidosos da função valor linear                     | Osband et al. (2016) |
| <i>Bootstrapped</i> DQN | uma das $K$ cabeças da rede, por episódio                 | Osband et al. (2016) |

### Intuição

O padrão é sempre o mesmo: **sorteie um mundo plausível, aja de forma ótima nele por um episódio inteiro, atualize**. Manter a mesma amostra durante todo o episódio é o que produz *exploração profunda* — uma sequência *coerente* de decisões exploratórias, que o  $\epsilon$ -guloso, sorteando de novo a cada passo, nunca alcança.

SEÇÃO 7

Síntese

---

07

## Quatro estratégias, lado a lado

|                              | $\epsilon$ -guloso          | UCB                | Thompson   | Gittins          |
|------------------------------|-----------------------------|--------------------|------------|------------------|
| Usa conhecimento prévio      | não                         | não                | sim        | sim              |
| Determinístico               | não                         | sim                | não        | sim              |
| Arrependimento               | linear (se $\epsilon$ fixo) | $O(\ln T)$         | $O(\ln T)$ | —                |
| Ótimo (dado prior)           | não                         | não                | não        | sim <sup>†</sup> |
| Custo por passo              | $O(m)$                      | $O(m)$             | $O(m)$     | alto             |
| Estende a contextual         | sim                         | sim                | sim, bem   | não              |
| Hiperparâmetro de exploração | $\epsilon$                  | constante do bônus | nenhum     | —                |

<sup>†</sup> Sob independência entre braços e critério descontado em horizonte infinito.

### Intuição

$\epsilon$ -guloso explora *cegamente*, UCB explora *sistematicamente*, Thompson explora *na proporção da dúvida*. Só o último deixa os dados decidirem quanto.



## Arrependimento e PAC no exemplo-brinquedo

Cirurgia 0,95 • esparadrapo 0,90 • nada 0,10, com tolerância  $\varepsilon = 0,05$

| Otimismo | TS    | Ótimo | Arrep. otimismo | Otimismo em $\varepsilon$ ? | Arrep. TS / TS em $\varepsilon$ ? |
|----------|-------|-------|-----------------|-----------------------------|-----------------------------------|
| $a_1$    | $a_3$ | $a_1$ | 0               | sim                         | 0,85 / não                        |
| $a_2$    | $a_1$ | $a_1$ | 0,05            | sim                         | 0 / sim                           |
| $a_3$    | $a_1$ | $a_1$ | 0,85            | não                         | 0 / sim                           |
| $a_1$    | $a_1$ | $a_1$ | 0               | sim                         | 0 / sim                           |
| $a_2$    | $a_1$ | $a_1$ | 0,05            | sim                         | 0 / sim                           |
| Total    |       |       | 0,95            | 4/5                         | 0,85 / 4/5                        |

- ▶ “Dentro de  $\varepsilon$ ” é o critério **PAC**:  $\mathbb{P}(Q(a_t) \geq Q(a^*) - \varepsilon)$  — conta passos *quase ótimos*, sem pesar o tamanho do erro.
- ▶ Os critérios discordam: o arrependimento penaliza  $a_3$  dezessete vezes mais que  $a_2$ ; o PAC trata  $a_2$  como acerto e  $a_3$  como erro. **Escolher entre eles é decisão de projeto** — dano acumulado num ensaio clínico, boa configuração final numa busca de hiperparâmetros.

## O que você deve dominar

---

- ▶ Explicar como bandits multiarmados se relacionam com MDPs, e por que o bandit isola o problema de exploração.
- ▶ Definir arrependimento e PAC, e dizer em que situação cada um é o critério apropriado.
- ▶ Demonstrar por que o UCB tem arrependimento sublinear, e dar exemplos em que guloso,  $\epsilon$ -guloso e pessimismo têm arrependimento linear.
- ▶ Derivar a conjugação Beta–Bernoulli e ler  $(\alpha, \beta)$  como pseudo-contagens.
- ▶ **Implementar** o UCB e a amostragem de Thompson para recompensas Bernoulli.
- ▶ Demonstrar que amostragem de Thompson implementa casamento de probabilidade.
- ▶ Distinguir arrependimento frequentista de bayesiano e explicar por que cotas frequentistas uniformes implicam cotas bayesianas.

# Onde estamos e para onde vamos

- ▶ **Aula passada:** bandits, arrependimento, otimismo diante da incerteza (UCB) e PAC.
- ▶ **Hoje:** bandits bayesianos, amostragem de Thompson, arrependimento bayesiano e índice de Gittins.
- ▶ **A seguir:** levar exploração eficiente ao MDP completo, onde a ação move o estado e a exploração precisa ser *profunda*, não apenas local.

## Intuição

Para levar: o otimismo age como se o melhor mundo plausível fosse verdade; Thompson, como se um mundo plausível sorteado ao acaso fosse verdade. Ambos exploram o bastante; só o segundo dispensa que você diga quanto.

**Leituras.** Sutton e Barto, *Reinforcement Learning*, 2.<sup>a</sup> ed., cap. 2 (seções 2.7 e 2.9) • Russo, Van Roy, Kazerouni, Osband e Wen, *A Tutorial on Thompson Sampling* (2018) • Lattimore e Szepesvári, *Bandit Algorithms* (2020), caps. 34–36 • Chapelle e Li, *An Empirical Evaluation of Thompson Sampling* (NeurIPS 2011).