

Aula 11 — Bandits bayesianos e amostragem de Thompson

Resumo de estudo • conjugação Beta–Bernoulli, casamento de probabilidade e arrependimento bayesiano

Prof. Marcelo Keese Albertini

Adaptado e expandido de CS234: Reinforcement Learning, Emma Brunskill (Stanford)

Intuição

A aula anterior resolveu a exploração por *otimismo*: aja como se o melhor mundo compatível com seus dados fosse o verdadeiro. Esta aula apresenta a segunda grande família: aja como se *um mundo sorteado ao acaso* entre os compatíveis fosse o verdadeiro. A segunda ideia cabe em seis linhas de código, não tem hiperparâmetro de exploração, e tem essencialmente as mesmas garantias teóricas.

1 O problema, em uma página

Definição — bandit multiarmado

Par $(\mathcal{A}, \mathcal{R})$ com $\mathcal{A}$ um conjunto *conhecido* de m ações (braços) e $\mathcal{R}^a(r) = \mathbb{P}[r \mid a]$ uma distribuição *desconhecida* de recompensas para cada braço. A cada passo t o agente escolhe $a_t \in \mathcal{A}$ e recebe $r_t \sim \mathcal{R}^{a_t}$. Escreve-se $Q(a) = \mathbb{E}[r \mid a]$ e $V^* = \max_a Q(a)$.

Um bandit é um MDP de um único estado. A ação não move o agente; ela só produz recompensa e informação. Com isso, a equação de Bellman degenera em $Q(a) = \mathbb{E}[r \mid a]$ e todo o conteúdo do problema passa a ser *exploração* — por isso o bandit é o laboratório onde as ideias de exploração são inventadas antes de subirem para o MDP completo.

Definição — lacuna, arrependimento por passo e arrependimento total

$\Delta_a = V^* - Q(a)$ é a *lacuna* do braço a ; $\ell_t = \mathbb{E}[V^* - Q(a_t)]$ é o arrependimento do passo t ; e

$$L_T = \mathbb{E} \left[\sum_{t=1}^T V^* - Q(a_t) \right]$$

é o arrependimento total. Maximizar recompensa acumulada equivale a minimizar L_T . O objetivo é *sublinearidade*: $L_T/T \rightarrow 0$.

A identidade que organiza toda a análise

Seja $N_T(a) = \sum_{t=1}^T \mathbb{1}(a_t = a)$ o número de puxadas do braço a . Trocando a ordem da soma:

$$L_T = \mathbb{E} \left[\sum_{t=1}^T \sum_{a \in \mathcal{A}} \mathbb{1}(a_t = a) \Delta_a \right] = \sum_{a \in \mathcal{A}} \mathbb{E}[N_T(a)] \Delta_a. \quad (1)$$

Intuição

A equação (1) diz que **arrependimento é contagem de erros ponderada pela gravidade de**

(continua)

cada erro. Ela transforma toda demonstração de cota de arrependimento em um problema de contagem: basta mostrar que $\mathbb{E}[N_T(a)]$ é pequeno para os braços com Δ_a grande. Guarde-a — ela é usada na demonstração do UCB, na de Thompson e na cota inferior de Lai e Robbins.

Três limitações do otimismo que motivam esta aula

1. **UCB é determinístico.** Dado o histórico, a ação está decidida. Se o retorno chega em lote — mil visitantes num site antes de sabermos se o primeiro clicou — o índice não muda e o algoritmo repete a mesma escolha mil vezes.
2. **UCB ignora conhecimento prévio.** Se dez anos de prontuários indicam que um tratamento cura cerca de 90% dos casos, o UCB começa do zero mesmo assim.
3. **O bônus $\sqrt{2 \ln t / N_t(a)}$ é genérico.** Ele vale para qualquer distribuição limitada, e por isso é conservador demais para a distribuição que você de fato tem.

Para discutir em aula

Num bandit com recompensas *determinísticas* — cada braço devolve sempre o mesmo valor —, o que acontece com o UCB? Ele tem arrependimento sublinear com probabilidade 1, ou existe probabilidade estritamente positiva de arrependimento linear? E a divisão por $N_t(a)$ chega a ser um problema?

Direção da resposta: examinar por que o termo de confiança existe — cobrir o ruído amostral da média empírica — e o que sobra desse papel quando a variância é zero. Vale também discutir a inicialização, em que cada braço é puxado uma vez antes de o índice ser avaliado.

2 Inferência bayesiana: só o necessário

Na visão bayesiana, partimos de um *prior* sobre os parâmetros desconhecidos — aqui, sobre a distribuição de recompensas de cada braço — e o atualizamos com os dados pela regra de Bayes:

$$\underbrace{p(\theta | r)}_{\text{posterior}} = \frac{\overbrace{p(r | \theta)}^{\text{verossimilhança}} \overbrace{p(\theta)}^{\text{prior}}}{\underbrace{\int p(r | \theta) p(\theta) d\theta}_{\text{evidência}}} \propto p(r | \theta) p(\theta). \quad (2)$$

A mudança de objeto é o ponto: em vez da estimativa pontual $\hat{Q}(a)$ com uma barra de erro colada por fora, carregamos uma *distribuição inteira* sobre $Q(a)$. A incerteza deixa de ser um apêndice do algoritmo e passa a ser o estado de conhecimento do agente.

Atenção

O denominador de (2) é uma integral que, sem estrutura adicional, não tem forma fechada — restaria MCMC ou inferência variacional. Como o bandit faz *uma* atualização por passo, isso seria inviável. Conjugação não é elegância matemática: é requisito de engenharia.

Definição — prior conjugado

$p(\theta)$ é *conjugado* para a verossimilhança $p(r | \theta)$ se o posterior $p(\theta | r)$ pertence à mesma família paramétrica do prior. A atualização vira então um mapa entre hiperparâmetros — tipicamente somas — com custo e memória $O(1)$ por observação. Toda família exponencial

(continua)

admite prior conjugado.

Recompensa	Prior conjugado	Uso típico
Bernoulli(θ)	Beta(α, β)	clique, cura/falha, conversão
$\mathcal{N}(\mu, \sigma^2)$, σ conhecido	$\mathcal{N}(\mu_0, \sigma_0^2)$	recompensa contínua
Catégorica em K valores	Dirichlet($\alpha_1, \dots, \alpha_K$)	nota de 1 a 5
Poisson(λ)	Gama(α, β)	contagens

O par Beta–Bernoulli

Definição — distribuição Beta

$$p(\theta \mid \alpha, \beta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^{\alpha-1} (1 - \theta)^{\beta-1}, \quad \theta \in [0, 1], \quad \alpha, \beta > 0,$$

com $\mathbb{E}[\theta] = \frac{\alpha}{\alpha + \beta}$, moda $\frac{\alpha-1}{\alpha+\beta-2}$ (para $\alpha, \beta > 1$) e $\text{Var}[\theta] = \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$. Em particular Beta(1, 1) é a uniforme em $[0, 1]$.

Proposição — conjugação Beta–Bernoulli

Se $\theta \sim \text{Beta}(\alpha, \beta)$ e observamos $r \in \{0, 1\}$ com $r \sim \text{Bernoulli}(\theta)$, então $\theta \mid r \sim \text{Beta}(\alpha + r, \beta + 1 - r)$.

Demonstração

Pela proporcionalidade em (2), basta acompanhar os expoentes:

$$p(\theta \mid r) \propto \underbrace{\theta^r (1 - \theta)^{1-r}}_{\text{verossimilhança Bernoulli}} \cdot \underbrace{\theta^{\alpha-1} (1 - \theta)^{\beta-1}}_{\text{prior Beta}} = \theta^{(\alpha+r)-1} (1 - \theta)^{(\beta+1-r)-1}.$$

O lado direito é o núcleo de uma Beta($\alpha + r, \beta + 1 - r$). Como a família Beta é normalizável e o posterior é uma densidade, a constante de normalização está determinada e não precisa ser calculada. $\square$


Por indução, após S sucessos e F fracassos em qualquer ordem, o posterior é Beta($\alpha + S, \beta + F$) — a ordem das observações é irrelevante, o que era de se esperar, já que as recompensas são i.i.d. dado θ .

Intuição

Leitura em pseudo-contagens. $\alpha - 1$ e $\beta - 1$ são sucessos e fracassos *imaginários* que o prior injeta antes de qualquer dado. Partindo de Beta(1, 1), a média posterior após S sucessos e F fracassos é

$$\mathbb{E}[\theta \mid S, F] = \frac{S + 1}{S + F + 2},$$

a chamada regra de sucessão de Laplace: dois dados fantasmas que impedem o agente de concluir “100% de acerto” depois de um único acerto. A variância cai como $1/(\alpha + \beta)$: mais dados, posterior mais estreito.



O posterior de um braço ao longo de trinta e três observações. A massa migra para a direita e encolhe: a média sobe de 0,5 para $30/34 \approx 0,88$ e o desvio-padrão cai de 0,29 para 0,055. A largura da curva é a incerteza — e é ela que dosará a exploração.

3 Bandits bayesianos

Definição — bandit bayesiano

Bandit em que se assume conhecimento prévio $p[\mathcal{R}]$ sobre as recompensas. A cada passo computa-se o posterior $p[\mathcal{R} \mid h_t]$ com $h_t = (a_1, r_1, \dots, a_{t-1}, r_{t-1})$, e o posterior guia a exploração. No caso Bernoulli, todo o estado de conhecimento cabe em $2m$ números (α_a, β_a) .

Há duas maneiras clássicas de transformar um posterior em uma ação.

Bayes-UCB: otimismo calibrado

Escolha um quantil alto do posterior, $a_t = \arg \max_a q_{1-1/t}(p(Q(a) \mid h_t))$. A ideia é a mesma do UCB, mas o “bônus” vem da forma real do posterior, e não de uma desigualdade de concentração válida para o pior caso. (Kaufmann, Cappé e Garivier, 2012.)

Casamento de probabilidade

Escolha cada ação com a probabilidade de que ela seja a ótima:

$$\pi(a \mid h_t) = \mathbb{P}[Q(a) > Q(a'), \forall a' \neq a \mid h_t]. \quad (3)$$

Ações incertas têm caudas mais gordas e, portanto, maior probabilidade de serem o máximo: a exploração emerge da definição, sem bônus algum. O problema é computar (3), uma integral m -dimensional sem forma fechada simples.

Atenção

Cuidado com o nome. Em psicologia experimental, “*probability matching*” designa escolher a alternativa A numa fração das vezes igual à *frequência com que A é recompensada* — comportamento comprovadamente subótimo. Aqui a probabilidade é outra: a de que A seja o *melhor braço*, dada a evidência acumulada. Os dois procedimentos só coincidem no caso degenerado de um braço único.

4 Amostragem de Thompson

Algoritmo — amostragem de Thompson (Thompson, 1933)

1. Inicialize um prior $p(\mathcal{R}^a)$ para cada braço a .
2. Para $t = 1, 2, \dots$:

(continua)

- (a) para cada braço a , sorteie $\tilde{\mathcal{R}}^a \sim p(\mathcal{R}^a \mid h_t)$ e calcule $\tilde{Q}(a) = \mathbb{E}[\tilde{\mathcal{R}}^a]$;
- (b) jogue $a_t = \arg \max_{a \in \mathcal{A}} \tilde{Q}(a)$;
- (c) observe r_t e atualize o posterior de a_t pela regra de Bayes.

No caso Bernoulli com prior Beta, o passo (a) é $\tilde{\theta}_a \sim \text{Beta}(\alpha_a, \beta_a)$ e o passo (c) soma 1 em α_{a_t} (se $r_t = 1$) ou em β_{a_t} (se $r_t = 0$).

Intuição

Leia o passo (a) como: “finja, por um instante, que um dos mundos compatíveis com meus dados é o mundo verdadeiro — e aja de forma ótima nele”. Daí o nome alternativo, **amostragem posterior**.

Proposição — Thompson implementa casamento de probabilidade

A probabilidade de a amostragem de Thompson jogar o braço a no passo t é exatamente $\pi(a \mid h_t)$, definida em (3).

Demonstração

O braço jogado é $\arg \max_a \tilde{Q}(a)$, com $\tilde{Q}$ sorteado do posterior. Logo

$$\mathbb{P}[a_t = a] = \mathbb{E}_{\tilde{Q} \sim p(\cdot \mid h_t)} \left[\mathbb{1}(a = \arg \max_{a' \in \mathcal{A}} \tilde{Q}(a')) \right] = \mathbb{P}[Q(a) > Q(a'), \forall a' \neq a \mid h_t] = \pi(a \mid h_t),$$

onde a segunda igualdade é apenas a definição de esperança de uma função indicadora sob o posterior. $\square$

Intuição

O conteúdo da proposição, em uma frase: **sortear do posterior e tomar o arg max é um estimador de Monte Carlo com uma única amostra** da integral que não sabíamos calcular. E uma amostra basta, porque não precisamos do *valor* de $\pi(a \mid h_t)$ — precisamos apenas de uma ação *distribuída* segundo ele. É uma das trocas mais elegantes da área: o problema difícil não foi resolvido, foi contornado.

Um exemplo numérico completo

Três tratamentos para um dedo quebrado, com parâmetros verdadeiros (desconhecidos do agente) $\theta_1 = 0,95$ para a cirurgia, $\theta_2 = 0,90$ para o esparadrapo e $\theta_3 = 0,10$ para não fazer nada. Prior Beta(1, 1) nos três braços.

Passo	Posteriores antes	Amostras	Escolha	Resultado e atualização
1	(1, 1) (1, 1) (1, 1)	0,30 0,50 0,60	a_3	$r = 0 \Rightarrow \theta_3 \sim \text{Beta}(1, 2)$
2	(1, 1) (1, 1) (1, 2)	0,70 0,50 0,30	a_1	$r = 1 \Rightarrow \theta_1 \sim \text{Beta}(2, 1)$
3	(2, 1) (1, 1) (1, 2)	0,71 0,65 0,10	a_1	$r = 1 \Rightarrow \theta_1 \sim \text{Beta}(3, 1)$
4	(3, 1) (1, 1) (1, 2)	0,75 0,45 0,40	a_1	$r = 1 \Rightarrow \theta_1 \sim \text{Beta}(4, 1)$

Atenção

Exemplo *fictício*: estes não são os desfechos reais das opções de tratamento para um dedo quebrado. O caso serve apenas para acompanhar a aritmética.

Na mesma instância, o otimismo puxou a sequência a_1, a_2, a_3, a_1, a_2 , e Thompson puxou a_3, a_1 ,

a_1, a_1, a_1 . A diferença é qualitativa: o otimismo *tem de* experimentar cada braço até que sua incerteza caia, porque o bônus é enorme para quem tem poucas puxadas; Thompson descarta braços que a evidência já tornou implausíveis, mesmo com um único dado. Numa amostra o TS ganha, noutra perde — o que se compara é a média.

Implementação

Algoritmo — Thompson Bernoulli, em seis linhas

```

alfa = np.ones(K); beta = np.ones(K)    # prior Beta(1,1) por braço
for t in range(T):
    theta = rng.beta(alfa, beta)         # 1 amostra de cada posterior
    a = int(np.argmax(theta))             # ótimo no mundo sorteado
    r = puxar(a)                         # recompensa em {0,1}
    alfa[a] += r; beta[a] += 1 - r       # atualização conjugada

```

Nenhum hiperparâmetro de exploração, nenhum cronograma, nenhuma cota de concentração. Custo por passo: $O(m)$ em tempo e memória — o mesmo do ϵ -guloso. Para recompensas contínuas, trocam-se as duas últimas linhas pela atualização Normal–Normal; a estrutura do laço não muda.

O que acontece na média

Simulação com $\theta = (0,95; 0,90; 0,10)$ e prior Beta(1, 1), com média sobre 1500 execuções independentes:

Arrependimento acumulado em	$T = 100$	$T = 500$	$T = 1000$	$T = 2000$
Amostragem de Thompson	3,2	6,4	7,9	9,2
Guloso	2,6	7,8	14,1	26,5
UCB	7,3	19,5	29,9	45,7
ϵ -guloso ($\epsilon = 0,1$)	5,1	20,0	36,9	68,6

Atenção

Não conclua que o guloso é bom. O guloso tem arrependimento *linear*: em 23% das execuções ele trava no braço a_2 e nunca mais sai. Ele só parece competitivo porque $\Delta_2 = 0,05$ é minúsculo — a reta tem inclinação pequena, mas é reta. Estendendo o horizonte, seu arrependimento médio vai a 13,2 ($T = 10^3$), 58,9 ($T = 5 \times 10^3$) e 229,9 ($T = 2 \times 10^4$), enquanto o de Thompson vai a 9,2, 13,0 e 15,7 — crescimento logarítmico. *Moral metodológica*: nunca compare algoritmos de exploração em um único horizonte, nem olhando apenas a média.

5 Arrependimento bayesiano

Definição — arrependimento frequentista e bayesiano

Frequentista — supõe parâmetros verdadeiros e fixos θ , com a esperança tomada sobre o histórico gerado pelo algoritmo $\mathcal{A}$:

$$\text{Arrep}(\mathcal{A}, T; \theta) = \mathbb{E}_{\mathcal{A}} \left[\sum_{t=1}^T Q(a^*) - Q(a_t) \mid \theta \right].$$

(continua)

Bayesiano — supõe um prior p_θ e tira a média também sobre ele:

$$\text{ArrepBayes}(\mathcal{A}, T) = \mathbb{E}_{\theta \sim p_\theta} [\text{Arrep}(\mathcal{A}, T; \theta)].$$

Observação — uma cota implica a outra

$\text{ArrepBayes}(\mathcal{A}, T) \leq \sup_\theta \text{Arrep}(\mathcal{A}, T; \theta)$, para todo prior p_θ .

Demonstração

A média de uma função é no máximo o seu supremo: $\mathbb{E}_{\theta \sim p_\theta} [\text{Arrep}(\mathcal{A}, T; \theta)] \leq \sup_\theta \text{Arrep}(\mathcal{A}, T; \theta)$. $\square$

Consequência prática: **toda cota frequentista uniforme já é uma cota bayesiana**. A recíproca é falsa — uma cota bayesiana boa pode conviver com desempenho péssimo em um θ de probabilidade a priori desprezível. É exatamente aí que mora a diferença de dificuldade entre as duas análises, e é por isso que uma cota *frequentista* para Thompson é um resultado bem mais forte (e bem mais recente) do que a bayesiana.

Otimismo como técnica de demonstração

Suponha que $U_t(a)$ seja, com alta probabilidade, uma cota superior de $Q(a)$. No evento em que a cota vale,

$$\text{Arrep}(\mathcal{A}, T; \theta) = \mathbb{E} \left[\sum_{t=1}^T Q(a^*) - Q(a_t) \right] \leq \mathbb{E} \left[\sum_{t=1}^T U_t(a_t) - Q(a_t) \right]. \quad (4)$$

O passo usa duas coisas: $Q(a^*) \leq U_t(a^*)$, porque a cota vale para o braço ótimo; e $U_t(a^*) \leq U_t(a_t)$, porque o algoritmo escolheu a_t justamente por ter o maior índice. À direita não sobra nenhuma referência a a^* : o arrependimento virou a soma das larguras dos intervalos de confiança dos braços *efetivamente puxados* — e cotar isso é contar puxadas, via (1).

Intuição

Eis a razão profunda de o otimismo ser onipresente na teoria de bandits: ele não é apenas uma heurística de exploração, é o artifício que faz a demonstração fechar. O notável é que a análise bayesiana de Thompson usa *esse mesmo artifício* — via a chamada *razão de informação* de Russo e Van Roy — apesar de o algoritmo não ser otimista. Thompson herda as cotas do otimismo sem ser otimista.

Garantia	Cota	Referência e observação
UCB, frequentista	$O(\sqrt{mT \ln T})$	Auer, Cesa-Bianchi e Fischer (2002); também $O(\sum_a \ln T / \Delta_a)$, dependente das lacunas
Thompson, bayesiano	$O(\sqrt{mT \ln T})$	Russo e Van Roy (2014), via razão de informação; vale para qualquer prior
Thompson, frequentista	$O(\sqrt{mT \ln T})$	Agrawal e Goyal (2012, 2013), Bernoulli com prior Beta; constantes piores que as do UCB
Cota inferior (qualquer algoritmo)	$\Omega(\sqrt{mT})$	Lai e Robbins (1985); Auer et al. (2002)

Em ordem de grandeza, portanto, **empate**: amostragem posterior tem as mesmas cotas do UCB a menos de constantes, e ambos são ótimos em ordem. Nas constantes e na prática o TS costuma vencer, sobretudo em bandits contextuais, onde calibrar o bônus de otimismo é difícil.

6 Onde Thompson falha, e o que vem depois

Prior enganoso

As garantias bayesianas são *em média sobre o prior*. Se o prior estiver errado, não há promessa alguma. Com dois braços ($\theta_{\text{ruim}} = 0,10$ e $\theta_{\text{bom}} = 0,50$) e $T = 1000$:

Prior do braço ruim	Puxadas do braço ruim	Arrependimento
Beta(1, 1) — uniforme	13,6	5,4
Beta(100, 1) — enganoso	204,0	81,6

Beta(100, 1) afirma, antes de qualquer dado, que o braço acerta cerca de 99% das vezes. Trazê-lo de volta à realidade exige acumular cerca de cem fracassos, e cada um deles é um passo desperdiçado: o arrependimento fica quinze vezes maior. *Prática recomendada*: priors fracos ($\alpha + \beta$ pequeno), salvo evidência histórica real. Um prior informativo é uma afirmação empírica e deve ser defendida como tal.

Feedback em lote

Quando o retorno demora, o UCB — sendo determinístico — repete a mesma ação até que o histórico mude. Thompson, sorteando a cada decisão, *diversifica naturalmente* dentro do lote: mil decisões tomadas com o mesmo posterior produzem uma mistura de braços na proporção $\pi(a \mid h_t)$. Foi um dos motivos empíricos do sucesso do TS em recomendação em larga escala.

Bandits contextuais

No bandit contextual, o ambiente sorteia i.i.d. um contexto x_t que afeta a recompensa de cada braço; o agente vê x_t , escolhe a_t e recebe $r_t \sim \mathcal{R}(\cdot \mid x_t, a_t)$. É o passo intermediário entre bandit e MDP: já há generalização entre situações, mas a ação ainda não move o estado. O TS se estende sem esforço — mantenha um posterior sobre os *parâmetros* de $Q_w(x, a)$, sorteie $\tilde{w}$, jogue $\arg \max_a Q_{\tilde{w}}(x_t, a)$. Chapelle e Li (2010) mostraram que, em recomendação de notícias, o TS iguala ou supera o LinUCB, com implementação mais simples e maior robustez a atrasos.

A política ótima e o índice de Gittins

Dado um prior e um horizonte, existe uma política que maximiza a recompensa esperada, e TS não é ela. Formalmente, o problema bayesiano é um MDP cujo estado é a *crença* — todos os pares (α_a, β_a) —, cuja ação é o braço e cuja transição é a atualização de Bayes. Chama-se *MDP de crenças*, e a política ótima sai de programação dinâmica sobre ele. Computacionalmente isso é inviável de forma ingênua: o conjunto de crenças alcançáveis cresce combinatoriamente com o horizonte.

Definição — política de índice

Política que calcula um índice de valor real para cada braço usando somente as estatísticas *daquele braço* e o horizonte, e joga o braço de maior índice. (Definição de Lattimore e Szepesvári, *Bandit Algorithms*.)

Teorema do índice (Gittins, 1979)

Para um bandit bayesiano com braços *independentes* e critério de recompensa esperada *descontada* em horizonte infinito, a política ótima é uma política de índice: jogue sempre o braço de maior índice de Gittins.

O resultado é notável: reduz um problema de dimensão m a m problemas unidimensionais independentes. As limitações explicam por que ele não é usado na prática — exige braços independentes, quebra com horizonte finito ou com o critério de recompensa média, o índice é caro de calcular, e não há extensão para o caso contextual.

Intuição

Note a inversão conceitual do parágrafo anterior. O bandit começou como o caso *fácil* do MDP — um único estado. Ao exigirmos otimalidade sob incerteza, ele voltou a ser um MDP, agora de estado contínuo e alta dimensão. **A incerteza é, ela própria, um estado.**

De volta ao RL

A ideia de Thompson não depende de o problema ser um bandit. O padrão geral é: *sorteie um mundo plausível, aja de forma ótima nele por um episódio inteiro, atualize.*

Método	O que se sorteia	Referência
PSRL	um MDP inteiro do posterior sobre (P, R) , uma vez por episódio	Osband et al. (2013)
RLSVI	pesos ruidosos da função valor linear	Osband et al. (2016)
<i>Bootstrapped</i> DQN	uma das K cabeças da rede, uma vez por episódio	Osband et al. (2016)

Manter a *mesma* amostra durante todo o episódio é o que produz **exploração profunda**: uma sequência coerente de decisões exploratórias, capaz de alcançar estados que só compensam depois de muitos passos. O ϵ -guloso, que sorteia de novo a cada passo, executa um passeio aleatório e nunca chega lá.

Para discutir em aula

Um portal de notícias recebe milhares de acessos por segundo, e com frequência um novo leitor chega antes de sabermos se o anterior clicou. Nesse regime, o que se pode dizer da comparação entre amostragem de Thompson e algoritmos de otimismo? E o que muda se o prior inicial for muito enganoso?

Direção da resposta: explorar a natureza determinística do UCB (histórico congelado $\Rightarrow$ índice congelado) contra a natureza estocástica do TS, e separar a pergunta empírica — o que funciona melhor aqui — da teórica — quem tem a cota mais forte neste cenário.

Para discutir em aula

É legítimo usar amostragem de Thompson para alocar pacientes em um ensaio clínico? O algoritmo reduz o número de pacientes expostos ao tratamento inferior, mas produz tamanhos de amostra desbalanceados e dependentes dos dados.

Direção da resposta: contrapor benefício individual (menos pacientes no braço ruim) a poder estatístico e validade da inferência posterior; mencionar desenhos adaptativos com restrição de alocação mínima por braço, e o fato de que a aleatoriedade do TS preserva alguma proteção contra vieses temporais que um desenho determinístico perderia.

7 Síntese

	ϵ -guloso	UCB	Thompson	Gittins
Usa conhecimento prévio	não	não	sim	sim
Determinístico	não	sim	não	sim
Arrependimento	linear se ϵ fixo	$O(\ln T)$	$O(\ln T)$	—
Ótimo dado o prior	não	não	não	sim [†]
Custo por passo	$O(m)$	$O(m)$	$O(m)$	alto
Estende ao caso contextual	sim	sim	sim, bem	não
Hiperparâmetro de exploração	ϵ	constante do bônus	nenhum	—

[†] Sob independência entre braços e critério descontado em horizonte infinito.

Uma leitura útil: o ϵ -guloso explora *cegamente*, o UCB explora *sistematicamente*, e Thompson explora *na proporção da dúvida*. Os três exploram; apenas o último deixa que os dados decidam quanto.

Arrependimento e PAC não são a mesma coisa

Com $\epsilon = 0,05$ no exemplo dos três tratamentos, e definindo o critério PAC como $\mathbb{P}(Q(a_t) \geq Q(a^*) - \epsilon)$:

Otimismo	TS	Ótimo	Arrep. otim.	Otim. em ϵ ?	Arrep. TS	TS em ϵ ?
a_1	a_3	a_1	0	sim	0,85	não
a_2	a_1	a_1	0,05	sim	0	sim
a_3	a_1	a_1	0,85	não	0	sim
a_1	a_1	a_1	0	sim	0	sim
a_2	a_1	a_1	0,05	sim	0	sim
Total			0,95	4/5	0,85	4/5

Os dois critérios discordam de propósito. O arrependimento penaliza a_3 dezessete vezes mais do que a_2 , porque mede *quanto* se perdeu; o PAC trata a_2 como acerto e a_3 como erro, porque só conta *quantas vezes* se errou feio. Escolher entre eles é decisão de projeto: em um ensaio clínico importa o dano acumulado; em uma busca de hiperparâmetros, importa terminar com uma boa configuração.

Formulário

Arrependimento total	$L_T = \sum_a \mathbb{E}[N_T(a)] \Delta_a$, $\Delta_a = V^* - Q(a)$
Regra de Bayes	$p(\theta r) \propto p(r \theta) p(\theta)$
Conjugação Beta–Bernoulli	$\text{Beta}(\alpha, \beta) \rightarrow \text{Beta}(\alpha + S, \beta + F)$
Média posterior (Laplace)	$\mathbb{E}[\theta S, F] = (S + 1) / (S + F + 2)$ a partir de $\text{Beta}(1, 1)$
Casamento de probabilidade	$\pi(a h_t) = \mathbb{P}[Q(a) > Q(a') \forall a' \neq a h_t]$
Passo de Thompson	$\tilde{\theta}_a \sim \text{Beta}(\alpha_a, \beta_a)$; $a_t = \arg \max_a \tilde{\theta}_a$
Arrependimento bayesiano	$\text{ArrepBayes}(\mathcal{A}, T) = \mathbb{E}_{\theta \sim p_\theta}[\text{Arrep}(\mathcal{A}, T; \theta)]$
Cota por otimismo	$\text{Arrep} \leq \mathbb{E}[\sum_t U_t(a_t) - Q(a_t)]$

8 Exercícios

Exercício 11.1 — conjugação para uma sequência

Mostre, por indução em n , que se $\theta \sim \text{Beta}(\alpha, \beta)$ e observamos $r_1, \dots, r_n$ i.i.d. $\text{Bernoulli}(\theta)$ com $S = \sum_i r_i$ sucessos e $F = n - S$ fracassos, então $\theta \mid r_{1:n} \sim \text{Beta}(\alpha + S, \beta + F)$. Conclua que a ordem das observações é irrelevante e explique por quê.

Exercício 11.2 — casamento de probabilidade em forma fechada

Suponha $\theta_1 \sim \text{Beta}(2, 1)$, $\theta_2 \sim \text{Beta}(1, 1)$ e $\theta_3 \sim \text{Beta}(1, 2)$, independentes. Calcule analiticamente $\mathbb{P}[\theta_1 > \theta_2 \text{ e } \theta_1 > \theta_3]$ e as duas probabilidades análogas para os braços 2 e 3. Verifique que somam 1 e compare com a frequência com que a amostragem de Thompson escolheria cada braço.

Exercício 11.3 — o guloso tem arrependimento linear

No exemplo dos três tratamentos, argumente que existe probabilidade estritamente positiva $p > 0$ de o algoritmo guloso ficar preso em a_2 para sempre, e conclua que $L_T \geq p \Delta_2 (T - c)$ para alguma constante c . Por que o arrependimento médio observado (13,2 em $T = 1000$) parecia inofensivo?

Exercício 11.4 — cota bayesiana a partir da frequentista

Prove que $\text{ArrepBayes}(\mathcal{A}, T) \leq \sup_{\theta} \text{Arrep}(\mathcal{A}, T; \theta)$ e dê um exemplo (pode ser esquemático) de algoritmo com arrependimento bayesiano pequeno e arrependimento frequentista grande para algum θ .

Exercício 11.5 — quanto custa um prior errado

Um braço tem $\theta = 0,1$ e prior $\text{Beta}(100, 1)$. Estime quantas puxadas são necessárias para que a média posterior caia abaixo de 0,5, supondo que as recompensas saiam na proporção esperada. Compare com o valor observado na simulação (204 puxadas em $T = 1000$) e explique a diferença.

Exercício 11.6 — Thompson gaussiano

Deduza a atualização conjugada Normal–Normal: se $\theta \sim \mathcal{N}(\mu_0, \sigma_0^2)$ e $r \mid \theta \sim \mathcal{N}(\theta, \sigma^2)$ com σ conhecido, mostre que o posterior é gaussiano com precisão $1/\sigma_1^2 = 1/\sigma_0^2 + 1/\sigma^2$ e média igual à média das duas médias ponderada pelas precisões. Escreva o laço de Thompson correspondente.

Exercício 11.7 — implementação

Reproduza a tabela de arrependimento acumulado deste handout comparando guloso, ϵ -guloso, UCB e Thompson em $T = 2000$, com pelo menos 500 execuções. Estenda para $T = 2 \times 10^4$ e verifique empiricamente qual curva é logarítmica e qual é linear. Reporte também a *dispersão* entre execuções, não só a média.

Respostas comentadas

11.1. Base $n = 1$: é a proposição do texto. Passo: pelo posterior ser um prior para a observação seguinte, $\text{Beta}(\alpha + S_k, \beta + F_k)$ atualizado por r_{k+1} dá $\text{Beta}(\alpha + S_{k+1}, \beta + F_{k+1})$. A irrelevância da ordem decorre de o posterior depender dos dados apenas por (S, F) , que é uma *estatística suficiente* — coerente com as recompensas serem i.i.d. dado θ .

11.2. Com densidades $f_1(t) = 2t$, $f_2(t) = 1$, $f_3(t) = 2(1 - t)$ e acumuladas $F_1(t) = t^2$, $F_2(t) = t$, $F_3(t) = 2t - t^2$:

$$\mathbb{P}[\theta_1 \text{ máx}] = \int_0^1 2t \cdot t \cdot (2t - t^2) dt = \int_0^1 (4t^3 - 2t^4) dt = 1 - \frac{2}{5} = \frac{3}{5} = 0,60.$$

Analogamente, $\mathbb{P}[\theta_2 \text{ máx}] = \int_0^1 t^2(2t - t^2) dt = \frac{3}{10}$ e $\mathbb{P}[\theta_3 \text{ máx}] = \int_0^1 2(1 - t)t^3 dt = \frac{1}{10}$. Somam 1, como devem. Uma simulação com 4×10^5 amostras dá 0,598, 0,301 e 0,101 — e essas são *exatamente* as frequências com que Thompson escolheria cada braço, pela proposição da Seção 4.

11.3. Basta que, nas primeiras puxadas, a_1 falhe e a_2 acerte: esse evento tem probabilidade positiva ($\approx 0,05 \times 0,90$ na inicialização usada), e a partir daí a média empírica de a_2 nunca é superada, porque a_1 deixa de ser puxado. Nesse evento o arrependimento cresce a taxa Δ_2 por passo, o que dá a cota. O arrependimento médio parecia inofensivo porque $\Delta_2 = 0,05$ é minúsculo: a reta tem inclinação pequena. Ao quadruplicar T , o arrependimento do guloso quadruplica ($58,9 \rightarrow 229,9$), enquanto o de Thompson cresce como $\ln T$ ($13,0 \rightarrow 15,7$).

11.4. A primeira parte é a monotonicidade da esperança. Para a segunda, considere um algoritmo que ignore os dados e jogue sempre o braço com maior valor *a priori*: se o prior concentra quase toda a massa num θ em que esse braço é ótimo, o arrependimento bayesiano é quase nulo, mas para o θ (de probabilidade a priori pequena) em que o braço é péssimo o arrependimento frequentista é linear em T .

11.5. A média posterior é $100/(100 + 1 + F)$, com F fracassos acumulados; ela cai abaixo de 0,5 quando $F > 99$. Como $\theta = 0,1$, cerca de 90% das puxadas são fracassos, e são necessárias $\approx 99/0,9 \approx 110$ puxadas. A simulação registra 204 porque o critério real não é a média posterior cair abaixo de 0,5, e sim as *amostras* do posterior deixarem de ganhar do outro braço — o que exige concentração adicional, já que a Beta ainda tem cauda à direita.

11.6. Multiplicando as duas densidades gaussianas e completando o quadrado em θ , os termos quadráticos dão $\sigma_1^{-2} = \sigma_0^{-2} + \sigma^{-2}$ e os lineares dão $\mu_1 = \sigma_1^2(\mu_0/\sigma_0^2 + r/\sigma^2)$. O laço de Thompson passa a sortear $\tilde{\theta}_a \sim \mathcal{N}(\mu_a, \sigma_a^2)$ e a atualizar $(\mu_{a_t}, \sigma_{a_t}^2)$ pela fórmula acima. Note a interpretação: precisões se somam, e a média nova é a média ponderada pelas precisões — o dado “puxa” o prior tanto mais quanto menos ruidoso for.

11.7. Exercício de implementação; o esqueleto de seis linhas da Seção 4 basta para o TS. Um resultado esperado: a dispersão do guloso é bimodal (execuções que acertam o braço bom têm arrependimento quase nulo; as que travam têm arrependimento linear), enquanto a do TS é unimodal e estreita. Essa diferença de *forma* da distribuição é invisível na média e é o argumento mais forte contra o guloso.

9 Autoavaliação e glossário

Você domina esta aula se consegue, sem consultar o material:

- ☐ escrever $L_T = \sum_a \mathbb{E}[N_T(a)] \Delta_a$ e explicar por que ela organiza toda a análise;
- ☐ enunciar e demonstrar a conjugação Beta–Bernoulli;
- ☐ ler (α, β) como pseudo-contagens e recuperar a regra de Laplace;
- ☐ definir casamento de probabilidade e dizer por que é difícil de calcular;
- ☐ escrever o laço de Thompson e implementá-lo em poucas linhas;
- ☐ demonstrar que Thompson implementa casamento de probabilidade;
- ☐ distinguir arrependimento frequentista de bayesiano e provar a desigualdade entre eles;
- ☐ explicar o papel do otimismo como *técnica de demonstração*;
- ☐ dar um exemplo concreto em que um prior enganoso arruína o TS;
- ☐ explicar por que o guloso tem arrependimento linear mesmo parecendo bom em horizonte curto;
- ☐ enunciar o teorema do índice de Gittins e suas três limitações;
- ☐ explicar o que é exploração profunda e por que ϵ -guloso não a produz.

Convenções de tradução fixadas nesta aula

Inglês	Português
regret / Bayesian regret	arrependimento / arrependimento bayesiano
arm / gap	braço / lacuna
prior / posterior	prior / posterior
conjugate prior	prior conjugado
probability matching	casamento de probabilidade
Thompson sampling / posterior sampling	amostragem de Thompson / amostragem posterior
optimism in the face of uncertainty	otimismo diante da incerteza
index policy / Gittins index	política de índice / índice de Gittins
contextual bandit	bandit contextual
belief-state MDP	MDP de crenças
deep exploration	exploração profunda

Leituras. Sutton e Barto, *Reinforcement Learning: An Introduction*, 2.^a ed., cap. 2 (seções 2.7 e 2.9) • Russo, Van Roy, Kazerouni, Osband e Wen, *A Tutorial on Thompson Sampling* (2018) • Lattimore e Szepesvári, *Bandit Algorithms* (2020), caps. 34–36 • Chapelle e Li, *An Empirical Evaluation of Thompson Sampling* (NeurIPS 2011) • Russo e Van Roy, *Learning to Optimize via Posterior Sampling* (2014).

Material adaptado e expandido de **CS234: Reinforcement Learning**, Emma Brunskill, Stanford University. Prof. Marcelo Keese Albertini, Faculdade de Computação, Universidade Federal de Uberlândia.