

Aula 12: Aprendizagem rápida em MDPs garantias PAC, otimismo e amostragem posterior

**PAC • MBIE-EB • Lema da simulação • PSRL • Exploração com
generalização**

Prof. Marcelo Keese Albertini
Universidade Federal de Uberlândia
adaptado de Emma Brunskill, CS234 (Stanford)
2026



De onde viemos

Aula 11 — bandits, arrependimento e a visão bayesiana

Definição — o que já temos

- ▶ **Arrependimento:**

$$\text{Arrep}(T) = T\mu^* - \sum_t \mu_{a_t}.$$

- ▶ **UCB:** otimismo por concentração;
 $\tilde{O}(\sqrt{KT})$.

- ▶ **Thompson:** casamento de probabilidades, conjugação Beta–Bernoulli.

Intuição

Tudo isso valia para *uma única decisão* repetida. Hoje há **estados**: uma ação ruim não custa só a recompensa daquele passo — ela decide *onde* você estará nos próximos mil.

Atenção

É essa dependência temporal que torna a exploração em MDPs *qualitativamente* mais difícil, e não apenas mais cara.

Aquecimento

Conjugação Beta–Bernoulli e amostragem de Thompson

Teste sua compreensão

Os *a priori* são $\text{Beta}(1, 2)$ para o braço 1 e $\text{Beta}(1, 1)$ para o braço 2.

1. Os valores 0,1, 0,5, 0,3 são mais compatíveis com qual dos dois?
2. É impossível que o parâmetro verdadeiro seja 0 sob o *a priori* $\text{Beta}(1, 1)$?
3. Com $\omega_1 = 0,4$, $\omega_2 = 0,6$ verdadeiros e amostras $\tilde{\omega}_1 = 0,50$, $\tilde{\omega}_2 = 0,55$: Thompson foi *otimista*? Escolhe o braço ótimo?

Pergunta para o professor conduzir em aula.

Aquecimento

Conjugação Beta–Bernoulli e amostragem de Thompson

Teste sua compreensão

Os *a priori* são $\text{Beta}(1, 2)$ para o braço 1 e $\text{Beta}(1, 1)$ para o braço 2.

1. Os valores 0,1, 0,5, 0,3 são mais compatíveis com qual dos dois?
2. É impossível que o parâmetro verdadeiro seja 0 sob o *a priori* $\text{Beta}(1, 1)$?
3. Com $\omega_1 = 0,4$, $\omega_2 = 0,6$ verdadeiros e amostras $\tilde{\omega}_1 = 0,50$, $\tilde{\omega}_2 = 0,55$: Thompson foi *otimista*? Escolhe o braço ótimo?

Pergunta para o professor conduzir em aula.

Resposta

1. $\text{Beta}(1, 2)$: densidade $2(1 - \omega)$, favorece valores pequenos.
2. Falso — $\text{Beta}(1, 1)$ é uniforme.
3. Otimista no braço 1, *pessimista* no 2 — o mesmo assim acerta.

1. **Um novo critério: PAC.** Arrependimento mede área sob a curva de erro; PAC conta decisões ruins.
2. **Otimismo em MDPs: MBIE-EB** e sua garantia PAC.
3. **Lema da simulação:** converte erro de *modelo* em erro de *valor*.
4. **PSRL:** amostrar um MDP inteiro por episódio.
5. **Generalização:** o que sobra quando não dá para contar visitas.

A pergunta de fundo

Existe algoritmo que, em *qualquer* MDP tabular, cometa apenas um número **polinomial** de decisões ruins? Sim — e o que decide isso não é a taxa de aprendizado nem a arquitetura.

Intuição

No *RiverSwim* adiante, ϵ -guloso colhe 85 e otimismo colhe 8580 — mesmo ambiente, mesmo orçamento.

SEÇÃO 1

Um novo critério: PAC

01

O mapa da área

Cenários, arcabouços e abordagens são eixos independentes

Definição — Cenários

- ▶ **Bandits** — sem estado.
- ▶ **Bandits contextuais** — estado, sem dinâmica.
- ▶ **MDPs** — a ação move o mundo.

Arcabouços (critérios)

- ▶ Avaliação empírica
- ▶ Convergência assintótica
- ▶ Arrependimento (aula 11)
- ▶ **PAC (hoje)**
- ▶ Arrependimento bayesiano

Algoritmo — Abordagens

- ▶ Guloso, ϵ -guloso
- ▶ **Otimismo**
- ▶ **Thompson**
- ▶ Meta-aprendizagem

Intuição


Não confunda os eixos: *otimismo* é abordagem, *PAC* é critério.

O que o arrependimento não distingue

Dois agentes com o mesmo arrependimento acumulado:

- ▶ **A** erra *pouco, sempre*: perde 0,01 por passo, para sempre.
- ▶ **B** erra *muito, raramente*: 100 escolhas catastróficas; no resto, é ótimo.

Em ensaio clínico, tutor inteligente ou controle de processo, a pergunta não é “quanto perdi no total”, mas “em quantos momentos entreguei uma decisão ruim?”



PAC conta *quantos* passos ficam acima da linha tracejada; arrependimento integra a curva.

Provavelmente aproximadamente correto (PAC)

Definição — Algoritmo PAC

Fixados $\epsilon > 0$ e $\delta \in (0, 1)$, o algoritmo $\mathcal{A}$ é **PAC** se, com probabilidade $\geq 1 - \delta$, em todos os passos exceto no máximo N deles vale $Q^*(s_t, a_t) \geq V^*(s_t) - \epsilon$, com N **polinomial** em $(|\mathcal{S}|, |\mathcal{A}|, \frac{1}{1-\gamma}, \frac{1}{\epsilon}, \frac{1}{\delta})$.

Intuição

Leia os três termos na ordem: *provavelmente* $\rightarrow 1 - \delta$; *aproximadamente* $\rightarrow \epsilon$; *correto* $\rightarrow$ em todos os passos menos N exceções.

Atenção

- ▶ N limita *quantos* passos são ruins, não *quando*.
- ▶ “Polinomial” é o coração: com “exponencial” a definição fica vazia.
- ▶ A garantia é sobre *ações*; Q pode nunca convergir.

PAC e arrependimento, lado a lado

	Arrependimento	PAC
Mede	soma das perdas por passo	nº de passos com perda $> \epsilon$
Pergunta	“quanto perdi ao todo?”	“quantas vezes fui ruim?”
Parâmetros	horizonte T	tolerância ϵ , risco δ
Forma típica	$\tilde{O}(\sqrt{T})$	$N = \tilde{O}\left(\frac{ S \mathcal{A} }{\epsilon^2(1-\gamma)^3}\right)$
Cego a	<i>distribuição</i> dos erros	<i>magnitude</i> dos erros $< \epsilon$

Não são equivalentes

Arrependimento $O(\sqrt{T})$ admite infinitas decisões ϵ -ruins (basta rarearem); e um algoritmo PAC pode ter arrependimento linear se as N decisões ruins forem caríssimas.

Intuição

Na prática, ambos são atendidos pela *mesma* família de algoritmos, porque ambos exigem a mesma coisa: reduzir incerteza de forma *dirigida*, não por sorteio.

SEÇÃO 2

Otimismo em MDPs: MBIE-EB

02

Por que exploração em MDPs é outro problema

O *RiverSwim*: um contraexemplo de seis estados

nadar contra a correnteza: sobe com 0,35, fica com 0,60, desce com 0,05



deixar-se levar pela correnteza: desce com certeza

Atenção

A recompensa grande está a cinco passos improváveis, e o caminho é *contra* a dinâmica. A política ótima ($\gamma = 0,95$) nada à direita em todo estado.

Intuição

Nenhuma quantidade de *ruído local* produz uma *sequência* coerente de cinco escolhas certas. Explorar bem exige um **plano** de exploração.

Quanto isso custa, em números

20 000 passos, 30 execuções, $\gamma = 0,95$

Algoritmo	Recompensa	% do ótimo
ϵ -guloso ($\epsilon = 0,3$)	61	0,7%
ϵ -guloso ($\epsilon = 0,1$)	85	1,0%
PSRL (Thompson)	8 095	92,4%
MBIE-EB (otimismo)	8 580	97,9%
π^* conhecida	8 760	100%

Atenção

Em 20 execuções de 200 000 passos, o ϵ -guloso **nunca** visitou s_6 : as ações aleatórias não se encadeiam.

O escalonamento é exponencial

Passos (mediana) até um explorador aleatório tocar o topo do rio:

$ S $	passos até o topo
4	54
6	763
8	5 897
10	40 179
12	362 322

Dois estados a mais multiplicam o custo por ≈ 8 : assinatura de $e^{\Theta(|S|)}$.

MBIE-EB

Model-Based Interval Estimation with Exploration Bonus — Strehl & Littman (2008)

Algoritmo — MBIE-EB

1: Dados ϵ, δ, m ; $\beta = \frac{1}{1-\gamma} \sqrt{0,5 \ln(2|\mathcal{S}||\mathcal{A}|m/\delta)}$

2: $n(s, a), n(s, a, s'), r_c(s, a) \leftarrow 0$; $\tilde{Q}(s, a) \leftarrow \frac{1}{1-\gamma}$

3: **repita**

4: $a_t = \arg \max_a \tilde{Q}(s_t, a)$ (guloso na Q otimista)

5: **observe** r_t, s_{t+1} ; **atualize** $n(s_t, a_t), n(s_t, a_t, s_{t+1}), r_c$

6: $\hat{R}(s, a) = \frac{r_c(s, a)}{n(s, a)}, \quad \hat{P}(s' | s, a) = \frac{n(s, a, s')}{n(s, a)}$

7: **até convergir:** $\tilde{Q}(s, a) \leftarrow \hat{R}(s, a) + \gamma \sum_{s'} \hat{P}(s' | s, a) \max_{a'} \tilde{Q}(s', a') + \frac{\beta}{\sqrt{n(s, a)}}$

Estime o modelo por contagens, some um *bônus* que decai, *planeje* no modelo otimista e siga o plano — sem nenhum ϵ -guloso: a política executada é determinística.

Anatomia do bônus

De onde vem $\beta/\sqrt{n(s, a)}$

1 — concentração

Com n amostras i.i.d. em $[0, 1]$, Hoeffding dá $|\hat{R} - R| \leq \sqrt{\ln(2/\delta')/(2n)}$ com probabilidade $1 - \delta'$.

2 — limitante da união

Deve valer para $|\mathcal{S}||\mathcal{A}|$ pares e m níveis: troque δ' por $\delta/(2|\mathcal{S}||\mathcal{A}|m)$ — daí o logaritmo em β .

3 — propagação

O erro de um passo se acumula ao longo do horizonte efetivo: daí $\frac{1}{1-\gamma}$.

Definição — o bônus é uma barra de erro

$$\frac{\beta}{\sqrt{n(s, a)}} = \underbrace{\frac{1}{1-\gamma}}_{\text{horizonte}} \times \underbrace{\sqrt{\frac{\ln(\cdot/\delta)}{2n(s, a)}}}_{\text{largura do IC}}$$

Intuição

Estados nunca visitados começam com $\tilde{Q} = \frac{1}{1-\gamma}$, o maior valor possível: o desconhecido é, *por construção*, o mais atraente do mapa.

O bônus *dentro* do planejamento

Definição — Em bandits

$a_t = \arg \max_a [\hat{\mu}(a) + \beta / \sqrt{n(a)}]$. A incerteza de a só influencia a escolha de a .

Definição — Em MDPs

O bônus entra na equação de Bellman e é **propagado para trás**: a incerteza em s_6 torna atraente *o caminho inteiro* até s_6 .

Intuição

É a **exploração profunda**: aceitar perdas imediatas certas em troca de informação distante.

bônus grande
(nunca visitado)



o planejamento carrega o otimismo para trás:
 s_1 “sabe” que vale a pena caminhar até s_5

$$\tilde{Q}(s, a) = \hat{R} + \frac{\beta}{\sqrt{n(s, a)}} + \gamma \sum_{s'} \hat{P} \max_{a'} \tilde{Q}(s', a')$$

Teorema (Strehl & Littman, 2008 — simplificado)

Com probabilidade $\geq 1 - \delta$, o MBIE-EB é ϵ -ótimo em todos os passos exceto no máximo $N = \tilde{O}(|\mathcal{S}|^2 |\mathcal{A}| \epsilon^{-3} (1 - \gamma)^{-6})$.

Definição — Esqueleto da prova

1. $\tilde{Q} \geq Q^*$ sempre (otimismo válido).
2. $n(s, a) \geq m \Rightarrow$ modelo preciso (par conhecido).
3. Lema da simulação: modelo preciso $\Rightarrow$ valor preciso.
4. **Dicotomia:** ou a ação é ϵ -ótima, ou há boa chance de visitar um par desconhecido — e só cabem $m|\mathcal{S}||\mathcal{A}|$ fugas.

Intuição

O passo (4) é o pivô: *ser otimista transforma cada erro em informação*. Se a ação não é boa, $\tilde{Q}$ está inflado em algum ponto do caminho — e só infla onde falta experiência.

Atenção

Os expoentes são frouxos; Azar et al. (2017) atingem a dependência minimax.

Lema da simulação

A ponte entre erro de modelo e erro de valor

Lema (limitante do erro de valor)

Sejam $\mathcal{M}_1$ e $\mathcal{M}_2$ MDPs sobre os mesmos espaços e π uma política fixa. Se para todo (s, a)

$$|R_1(s, a) - R_2(s, a)| \leq \varepsilon_R, \quad \|P_1(\cdot \mid s, a) - P_2(\cdot \mid s, a)\|_1 \leq \varepsilon_P,$$

então, com $V_{\max} = R_{\max}/(1 - \gamma)$,

$$\max_s |V_1^\pi(s) - V_2^\pi(s)| \leq \frac{\varepsilon_R + \gamma V_{\max} \varepsilon_P}{1 - \gamma}.$$

Intuição

Modelos parecidos têm valores parecidos, com amplificação $1/(1 - \gamma)$ — o horizonte efetivo.

Atenção

ε_P entra multiplicado por $V_{\max}$: custa $1/(1 - \gamma)^2$ contra $1/(1 - \gamma)$ de ε_R . *Errar a dinâmica é mais caro.*

Prova do lema da simulação

Some e subtraia $\gamma \sum_{s'} P_1(s'|s, a) V_2^\pi(s')$ na equação de Bellman:

$$\begin{aligned} |Q_1^\pi(s, a) - Q_2^\pi(s, a)| &= \left| R_1 - R_2 + \gamma \sum_{s'} [P_1(s'|s, a) V_1^\pi(s') - P_2(s'|s, a) V_2^\pi(s')] \right| \\ &\leq \underbrace{\varepsilon_R + \gamma \left| \sum_{s'} P_1 [V_1^\pi - V_2^\pi] \right|}_{\text{(a) mesmo modelo, valores diferentes}} + \underbrace{\gamma \left| \sum_{s'} [P_1 - P_2] V_2^\pi \right|}_{\text{(b) modelos diferentes, mesmo valor}}. \end{aligned}$$

- (a): $P_1(\cdot|s, a)$ é distribuição, logo média ponderada $\leq \Delta := \max_s |V_1^\pi(s) - V_2^\pi(s)|$; (b): Hölder dá $\leq \varepsilon_P \|V_2^\pi\|_\infty \leq \varepsilon_P V_{\max}$.

Como $V_i^\pi(s) = Q_i^\pi(s, \pi(s))$, tomando o máximo em s dos dois lados:

$$\Delta \leq \varepsilon_R + \gamma \Delta + \gamma V_{\max} \varepsilon_P \implies \Delta \leq \frac{\varepsilon_R + \gamma V_{\max} \varepsilon_P}{1 - \gamma}. \quad \blacksquare$$

Separar erro de valor de erro de modelo por um termo híbrido é o mesmo padrão da prova de contração da Aula 2.

Fechando o argumento

Como o lema vira uma garantia PAC

Definição — MDP conhecido induzido $\mathcal{M}_K$

Igual ao MDP real nos pares com $n(s, a) \geq m$; nos demais, um estado absorvente de valor $V_{\max}$. Há sempre dois regimes:

- ▶ age dentro de $\mathcal{M}_K$ — o lema garante valor quase ótimo;
- ▶ ou *escapa* para um par desconhecido — e aprende.

Cada fuga incrementa algum $n(s, a)$: cabem no máximo $m|\mathcal{S}||\mathcal{A}|$ delas.

Intuição

“Ou você é quase ótimo, ou aprende algo — e só há um número finito de coisas a aprender” é o esqueleto de *quase toda* prova de eficiência amostral em RL.

Atenção

m maior $\Rightarrow$ lema mais apertado, porém mais fugas: esse balanço fixa o expoente de ϵ .

Teste sua compreensão

Sobre exploração estratégica em MDPs, avalie cada afirmação:

1. “Não importa muito, porque a distribuição dos dados independe da política.”
2. “Pode envolver otimismo simultâneo quanto à dinâmica e à recompensa.”
3. “Chama-se PAC quando o número de decisões não quase-ótimas é menor que uma função *exponencial* dos parâmetros do domínio.”

Pergunta para o professor conduzir em aula.

Teste sua compreensão

Sobre exploração estratégica em MDPs, avalie cada afirmação:

1. “Não importa muito, porque a distribuição dos dados independe da política.”
2. “Pode envolver otimismo simultâneo quanto à dinâmica e à recompensa.”
3. “Chama-se PAC quando o número de decisões não quase-ótimas é menor que uma função *exponencial* dos parâmetros do domínio.”

Pergunta para o professor conduzir em aula.

Resposta

- 1. Falsa** — em RL os dados são *gerados* pela política. **2. Verdadeira** — é o que MBIE-EB e R-MAX fazem. **3. Falsa** — tem de ser *polinomial*.

SEÇÃO 3

MDPs bayesianos e amostragem posterior

03

Retomada: bandits bayesianos

Definição — Bandit de Bernoulli

$r \sim \text{Bernoulli}(\theta_a)$ e *a priori* $\theta_a \sim \text{Beta}(\alpha, \beta)$.
Após observar r , o *a posteriori* é

$$\text{Beta}(\alpha + r, \beta + 1 - r) .$$

Intuição

Atualizar a crença custa *duas somas*. É essa conveniência algébrica que torna Thompson barato o bastante para rodar em produção.

Algoritmo — Thompson (bandits)

- 1: inicialize $p(R_a)$ para cada braço
- 2: **repita**
- 3: amostre $\tilde{R}_a \sim p(R_a \mid h_t)$
- 4: $\tilde{Q}(a) = \mathbb{E}[\tilde{R}_a]$
- 5: $a_t = \arg \max_a \tilde{Q}(a)$
- 6: observe r_t ; atualize por Bayes

Atenção

Com *a priori* concentrado e errado, Thompson pode nunca corrigir — enquanto UCB, que não usa *a priori*, corrige.

Do bandit ao MDP bayesiano

Definição — Crença sobre o modelo

Em vez de um *a posteriori* sobre recompensas médias, mantenha $p(P, R \mid h_t)$ com $h_t = (s_1, a_1, r_1, \dots, s_t)$. Cada amostra é um MDP inteiro.

Conjugação para a dinâmica

Com $P(\cdot \mid s, a) \sim \text{Dir}(\alpha_{s,a,1}, \dots, \alpha_{s,a,|S|})$, observar $(s, a) \rightarrow s'$ apenas incrementa $\alpha_{s,a,s'}$. Dirichlet está para a Multinomial como Beta para a Bernoulli.

Definição — Casamento de probabilidades

Escolha a com probabilidade igual à probabilidade *posterior* de que a seja ótima:

$$\pi(s, a \mid h_t) = \mathbb{E}_{P,R|h_t} [\mathbb{1}(a = \arg \max_{a'} Q(s, a'))].$$

Intuição

Calcular essa probabilidade é intratável, mas *amostrar* dela é trivial: sorteie um MDP, resolva-o, aja de forma ótima nele. A ação já sai distribuída assim, sem nunca calcular a integral.

PSRL — amostragem posterior para RL

Osband, Russo & Van Roy (NeurIPS 2013)

Algoritmo — PSRL

- 1: inicialize *a priori* $p(R_{s,a})$ e $p(P(\cdot \mid s, a))$ para cada (s, a)
- 2: **para** episódio $k = 1, \dots, K$:
- 3: **amostre um MDP** $\tilde{\mathcal{M}}_k$: sorteie $\tilde{P}(\cdot \mid s, a)$ e $\tilde{R}(s, a)$ do *a posteriori*
- 4: resolva $\tilde{\mathcal{M}}_k$, obtendo $Q_{\tilde{\mathcal{M}}_k}^*$
- 5: **para** $t = 1, \dots, H$: $a_t = \arg \max_a Q_{\tilde{\mathcal{M}}_k}^*(s_t, a)$; observe r_t, s_{t+1}
- 6: atualize o *a posteriori* com os dados do episódio

Garantia

Arrependimento *bayesiano* $\tilde{O}(H\sqrt{|S||\mathcal{A}|T})$
— comparável aos melhores algoritmos otimistas, e em geral melhor na prática.

Intuição

Repare no que PSRL *não* tem: nenhum ϵ , nenhum bônus, nenhuma constante de concentração. A exploração emerge da variância do *a posteriori*, que encolhe sozinha.

A granularidade da amostragem é o algoritmo

Atenção

Amostrar um MDP novo *a cada passo*, em vez de a cada episódio, destrói a garantia.

Definição — Por quê

O agente troca de hipótese a cada passo: começa a nadar rio acima com $\tilde{\mathcal{M}}_1$, muda de ideia, volta. O agregado vira um *passeio aleatório*.

Intuição

Comprometer-se com uma hipótese por um episódio é o análogo bayesiano da propagação do bônus: ambos dão *exploração profunda*.

amostra por episódio



amostra por passo



a mesma *a posteriori*, duas granularidades, desempenhos incomparáveis

Otimismo e Thompson: duas leituras da mesma ideia

	Otimismo (MBIE-EB)	Posterior (PSRL)
Incerteza é	conjunto de confiança	distribuição <i>a posteriori</i>
Escolhe	o <i>melhor caso</i> do conjunto	<i>um</i> caso, sorteado
Requer	desigualdade de concentração	<i>a priori</i> + conjugação
Garantia	PAC / arrep. no pior caso	arrependimento bayesiano
Falha se	o bônus é frouxo	o <i>a priori</i> é rígido e errado
RiverSwim	8 580	8 095

Intuição

Ambos transformam “não sei” em “vale a pena ir ver”. Otimismo faz isso *deterministicamente e no pior caso*; Thompson, *estocasticamente e na média*.

Amostragem por semente

Dimakopoulou & Van Roy (2018): com M agentes em paralelo, amostrar independentemente faz todos seguirem hipóteses parecidas. Uma *semente* fixa por agente gera diversidade coordenada.

Teste sua compreensão

Sobre o PSRL apresentado:

1. “Bastaria amostrar a recompensa e usar a média empírica para a dinâmica — o desempenho seria o mesmo.”
2. “É possível replanejar sempre que o *a posteriori* é atualizado.”
3. “O custo computacional por passo é sempre o mesmo do *Q*-learning.”

Pergunta para o professor conduzir em aula.

Teste sua compreensão

Sobre o PSRL apresentado:

1. “Bastaria amostrar a recompensa e usar a média empírica para a dinâmica — o desempenho seria o mesmo.”
2. “É possível replanejar sempre que o *a posteriori* é atualizado.”
3. “O custo computacional por passo é sempre o mesmo do *Q*-learning.”

Pergunta para o professor conduzir em aula.

Resposta

1. **Falsa** — no *RiverSwim* a incerteza que importa é sobre a *dinâmica*.
2. **Verdadeira** no algoritmo mostrado, embora a garantia seja provada para reamostragem por episódio.
3. **Falsa** — PSRL resolve um MDP inteiro por episódio: *troca-se computação por amostras*.

SEÇÃO 4

Generalização e exploração

04

O que quebra em espaços grandes

Atenção

$$\tilde{Q}(s, a) \leftarrow \hat{R} + \gamma \sum_{s'} \hat{P}_{a'} \tilde{Q} + \frac{\beta}{\sqrt{n(s, a)}}$$

Se cada estado é visitado no máximo uma vez, $n(s, a) \in \{0, 1\}$: o bônus deixa de informar.

Definição — Três coisas a reconstruir

1. “Já visitei isto” que respeite *similaridade*.
2. Incerteza sobre *valores*, não contagens.
3. Exploração profunda com aproximação de função

Intuição

A generalização *muda o problema de exploração*: se estados parecidos têm valores parecidos, visitar um informa sobre os outros. A exploração deixa de escalar com $|S|$ e passa a escalar com a *complexidade da classe de funções*.

Roteiro

Primeiro os bandits contextuais lineares; depois, os MDPs.

Bandits contextuais

Definição — Bandit contextual

A cada rodada: o ambiente revela um contexto s_t (não escolhido pelo agente); o agente escolhe a_t ; recebe $r_t \sim R_{a_t, s_t}$. **Sem dinâmica:** s_{t+1} não depende de a_t .

Intuição

Meio-termo exato entre bandit e MDP: tem *estado* (exige generalização) mas não tem *consequência* (não exige exploração profunda). É onde a teoria é completa — e onde vive quase toda a aplicação industrial.

Modelo linear compartilhado

$$r(s, a) = \theta^\top \phi(s, a) + \eta, \quad \eta \sim \mathcal{N}(0, \sigma^2).$$

Modelo linear disjunto

Cada braço tem seu parâmetro: $r(s, a) = \theta_a^\top \phi(s) + \eta$.

Teste sua compreensão

O modelo compartilhado consegue representar um modelo disjunto? Se sim, como? *Pergunta para o professor conduzir em aula.*

Sim — por empilhamento em blocos

Com $|\mathcal{A}| = K$ e $\phi(s) \in \mathbb{R}^d$, defina $\phi(s, a) \in \mathbb{R}^{Kd}$ com $\phi(s)$ no bloco a e zeros nos demais, e empilhe $\theta = (\theta_1, \dots, \theta_K)$. Então

$$\theta^\top \phi(s, a) = \theta_a^\top \phi(s).$$

Atenção

O preço é a dimensão: $d \rightarrow Kd$. E esse é o ponto — o modelo disjunto **não compartilha informação entre braços**, e a dimensão maior é a expressão formal disso. Um $\phi(s, a)$ bem projetado aprende sobre um braço observando outro.

	θ_1	θ_2	θ_3
$\phi(s, a_1)$	$\phi(s)$	0	0
$\phi(s, a_2)$	0	$\phi(s)$	0
$\phi(s, a_3)$	0	0	$\phi(s)$

Intuição

É o LinUCB “disjunto” do artigo de recomendação de notícias do Yahoo! (Li et al., WWW 2010) — talvez o bandit contextual mais implantado da história.

O ganho da generalização, medido


$d = 5$, $\sigma = 0,3$, $T = 4\,000$ rodadas, média de 15 execuções

braços K	UCB (sem contexto)	LinUCB
20	63	49
60	166	66
180	481	78
540	1 282	88

arrendimento acumulado ao fim de T

A leitura teórica

UCB: $\tilde{O}(\sqrt{KT})$; LinUCB: $\tilde{O}(d\sqrt{T})$. O número de braços sai do limitante, substituído pela dimensão.



Atenção

O ganho existe se o modelo linear estiver correto. Sob má especificação, LinUCB converge com confiança para o braço errado — risco que o UCB não corre.

Incerteza sobre um vetor

De intervalos de confiança a elipsoides

Definição — A mudança conceitual

Antes, um intervalo em torno de um *escalar*. Agora a incerteza vive em $\theta \in \mathbb{R}^d$ e o conjunto de confiança é um **elipsoide**:

$$\mathcal{C}_t = \{\theta : \|\theta - \hat{\theta}_t\|_{A_t} \leq \alpha_t\}, \quad A_t = \lambda I + \sum_{\tau < t} \phi_\tau \phi_\tau^\top,$$

com $\hat{\theta}_t = A_t^{-1} \sum_{\tau < t} \phi_\tau r_\tau$ (crista).

Algoritmo — LinUCB

$$a_t = \arg \max_a \hat{\theta}_t^\top \phi(s_t, a) + \alpha \sqrt{\phi(s_t, a)^\top A_t^{-1} \phi(s_t, a)}$$

Intuição

O termo $\sqrt{\phi^\top A_t^{-1} \phi}$ é a largura do elipsoide *na direção* de ϕ : o análogo de $1/\sqrt{n(s, a)}$, sensível à geometria.

Teste sua compreensão

Por que representar a incerteza sobre θ basta para representar a incerteza sobre r ? *Pergunta para o professor conduzir em aula.*

Incerteza epistêmica e incerteza aleatória

Resposta

Porque r é função conhecida de θ mais ruído independente. Dado $\phi(s, a)$, toda a incerteza **epistêmica** — a que se reduz com dados — está em θ . O resto é ruído **aleatório**: irreduzível e sem valor informativo.

Atenção

Explorar para reduzir ruído aleatório é desperdício. Um bônus proporcional à *variância total* exploraria para sempre o braço mais ruidoso, ainda que sua média já fosse conhecida.

Intuição

Esta distinção atravessa a aula inteira:

- ▶ $\beta / \sqrt{n(s, a)}$ no MBIE-EB é epistêmico e decai;
- ▶ a variância do *a posteriori* do PSRL é epistêmica e encolhe;
- ▶ o ruído de recompensa não decai — e nenhum dos dois tenta reduzi-lo.

O *ensemble* do Bootstrapped DQN estima incerteza epistêmica; a variância de retornos, não.

De volta aos MDPs grandes: bônus dentro do gradiente

Definição — Q -learning com aproximação

$$\Delta w = \eta \left(r + \gamma \max_{a'} \hat{Q}(s', a'; w) - \hat{Q}(s, a; w) \right) \nabla_w \hat{Q}$$

Algoritmo — Com bônus de exploração

$$\Delta w = \eta \left(r + r_{\text{bônus}}(s, a) + \gamma \max_{a'} \hat{Q}(s', a'; w) - \hat{Q}(s, a; w) \right) \nabla_w \hat{Q}$$

Idêntico ao MBIE-EB: o bônus entra no *alvo* de Bellman e é propagado para trás. Muda só *como* calculá-lo.

Estimar novidade sem contar

- ▶ **Pseudo-contagens:** ajuste $\rho(s)$ e derive $\hat{n}(s)$ do quanto ρ sobe ao reobservar s (Bellemare et al. 2016).
- ▶ **Hashing:** discretize s e conte *buckets* (Tang et al. 2017).
- ▶ **Erro de predição (RND):** resíduo alto onde há pouca experiência.

Atenção

Todos são substitutos de $1/\sqrt{n}$; nenhum tem garantia PAC em MDPs gerais.

Quando isso importa muito: *Montezuma's Revenge*

Definição — Por que este jogo

Recompensa extremamente esparsa: dezenas de ações corretas encadeadas — pegar a chave, descer a escada, abrir a porta — antes de qualquer sinal. É o *RiverSwim* com $|S|$ enorme.

Resultado

DQN com ϵ -guloso: pontuação praticamente nula após centenas de milhões de quadros. Com bônus de pseudo-contagem: dezenas de salas e pontuação de ordem de grandeza superior (Bellemare et al., 2016).

Atenção

Duas ressalvas práticas:

- ▶ **Bônus envelhecem:** guardado no *buffer*, já não corresponde à incerteza atual quando reamostrado.
- ▶ **Não-estacionariedade:** o alvo de Bellman passa a depender de uma recompensa que muda com o tempo.

Intuição

A diferença entre um agente que funciona e um que não funciona está em *como ele decide o que ainda não sabe*.

Thompson com aproximação de função

Definição — O obstáculo

Amostrar de um *a posteriori* sobre Q^* : não há conjugação, redes neurais não têm *a posteriori* fechado.

Algoritmo — Bootstrapped DQN (Osband et al. 2016)

- ▶ C “cabeças” treinadas em amostras *bootstrap* dos mesmos dados.
- ▶ Por episódio, sorteie *uma* cabeça e siga-a até o fim.

A persistência recupera a exploração profunda.

Algoritmo — Bayesian DQN (Azizzadenesheli et al. 2017)

Rede profunda como extrator de características; na *última camada*, regressão linear bayesiana — que tem *a posteriori* fechado.

Como se comparam

Empiricamente: $\text{bônus} > \text{BDQN} > \text{Bootstrapped DQN} > \epsilon\text{-guloso}$, com inversões por domínio. Nenhum domina.

O BDQN é o LinUCB sobre características aprendidas.

Aprender a explorar

Exploração entre tarefas e meta-RL

Definição — Observação de partida

Tudo o que vimos supõe **ignorância total** no início. Mas um agente real enfrenta tarefas da mesma *família* — robôs em cozinhas diferentes, tutores para alunos diferentes. Havendo estrutura comum, a exploração ótima pode ser *aprendida*.

DREAM (Liu et al., NeurIPS 2022)

Separa *exploração* de *execução*: a política de exploração é treinada para produzir uma representação da tarefa útil à execução, e não para maximizar recompensa.

Decision-Pretrained Transformer (Lee, Xie et al., NeurIPS 2023)

Pré-treine um *transformer* para prever a *ação ótima* a^* a partir do histórico. Em teste ele age *in-context*, sem atualizar pesos. **Chave:** prever a^* *imita* Thompson, com um *a priori* implícito muito mais rico — a distribuição de tarefas de treino.

Intuição

Fecha-se o círculo: começamos exigindo garantias no pior caso e terminamos aprendendo o *a priori* que o torna irrelevante.

SEÇÃO 5

Panorama e fechamento

05

Onde está a teoria hoje

MDPs tabulares — essencialmente resolvido

- ▶ **Arrependimento minimax:** Azar, Osband & Munos, ICML 2017.
- ▶ **PAC:** Dann, Li, Wei & Brunskill, *Policy certificates*, ICML 2019 — com certificados por episódio.
- ▶ **Dependentes da instância:** Zanette & Brunskill (2019); Simchowitz & Jamieson (2019) — adaptam-se a problemas fáceis.

Com aproximação de função — em aberto

- ▶ MDP *linear*: Jin, Yang, Wang & Jordan, COLT 2020.
- ▶ Medidas de complexidade da exploração: **dimensão de Eluder** (Russo & Van Roy), **posto de Bellman** (Jiang et al.).

Atenção

A pergunta em aberto não é “existe algoritmo eficiente?”, e sim *quais propriedades do domínio* tornam a exploração tratável. Fora delas, há limitantes inferiores exponenciais.

Mapa: algoritmo × critério

Algoritmo	Cenário	Abordagem	Critério satisfeito
ϵ -guloso (fixo)	bandit / MDP	aleatório	nenhum
ϵ -guloso (GLIE)	MDP	aleatório	convergência assintótica
UCB	bandit	otimismo	arrependimento $\tilde{O}(\sqrt{KT})$
Thompson	bandit	posterior	arrep. bayesiano e frequentista
LinUCB	bandit contextual	otimismo	arrependimento $\tilde{O}(d\sqrt{T})$
MBIE-EB / R-MAX	MDP tabular	otimismo	PAC
UCRL2, UCBVI	MDP tabular	otimismo	arrependimento (minimax)
PSRL	MDP tabular	posterior	arrependimento bayesiano
Bônus de contagem (deep RL)	MDP grande	otimismo	empírico
Bootstrapped DQN, BDQN	MDP grande	posterior	empírico
DREAM, DPT	família de MDPs	meta	empírico

De cima para baixo, quanto mais realista o cenário, mais fracas as garantias — mas as *duas* abordagens atravessam a tabela inteira.

O que você deve sair sabendo

Definição — Conceitual

- ▶ Enunciar a tensão exploração–exploração e por que ela não aparece em aprendizado supervisionado.
- ▶ Comparar os critérios: empírico, assintótico, arrependimento, PAC.
- ▶ Mapear cada algoritmo ao critério que satisfaz.
- ▶ Dizer por que ϵ -guloso falha no *RiverSwim*.

Definição — Técnico

- ▶ Reproduzir o **lema da simulação** e sua prova.
- ▶ Reconstruir o esboço da prova do UCB (Aula 11) e o da prova PAC de hoje.
- ▶ Escrever MBIE-EB e PSRL, indicando onde entra cada hipótese.
- ▶ Implementar UCB e Thompson para bandit contextual linear.

Próxima aula: busca em árvore de Monte Carlo.

Referências principais

- ▶ A. L. Strehl, M. L. Littman. *An analysis of model-based interval estimation for MDPs*. J. of Computer and System Sciences, 2008.
- ▶ I. Osband, D. Russo, B. Van Roy. *(More) efficient RL via posterior sampling*. NeurIPS 2013.
- ▶ M. Dimakopoulou, B. Van Roy. *Coordinated exploration in concurrent RL*. ICML 2018.
- ▶ L. Li, W. Chu, J. Langford, R. Schapire. *A contextual-bandit approach to personalized news article recommendation*. WWW 2010.
- ▶ M. G. Bellemare et al. *Unifying count-based exploration and intrinsic motivation*. NIPS 2016.
- ▶ I. Osband, C. Blundell, A. Pritzel, B. Van Roy. *Deep exploration via bootstrapped DQN*. NIPS 2016.
- ▶ M. G. Azar, I. Osband, R. Munos. *Minimax regret bounds for RL*. ICML 2017.
- ▶ C. Dann, L. Li, W. Wei, E. Brunskill. *Policy certificates*. ICML 2019.
- ▶ C. Jin, Z. Yang, Z. Wang, M. Jordan. *Provably efficient RL with linear function approximation*. COLT 2020.
- ▶ J. Lee, A. Xie et al. *Supervised pretraining can learn in-context RL*. NeurIPS 2023.
- ▶ T. Lattimore, C. Szepesvári. *Bandit Algorithms*. Cambridge, 2020 — caps. 19 e 36.