

Universidade Federal de Uberlândia

## Aula 12: Aprendizagem rápida em MDPs garantias PAC, otimismo e amostragem posterior

PAC • MBIE-EB • Lema da simulação • PSRL • Exploração com generalização

Prof. Marcelo Keese Albertini  
Universidade Federal de Uberlândia  
adaptado de Emma Brunskill, CS234 (Stanford)  
2026



# De onde viemos

## Aula 11 — bandits, arrependimento e a visão bayesiana

### Definição — o que já temos

- ▶ **Arrependimento:**

$$\text{Arrep}(T) = T\mu^* - \sum_t \mu_{a_t}.$$

- ▶ **UCB:** otimismo por concentração;  
 $\tilde{O}(\sqrt{KT})$ .

- ▶ **Thompson:** casamento de probabilidades, conjugação Beta-Bernoulli.

### Intuição

Tudo isso valia para *uma única decisão* repetida. Hoje há **estados**: uma ação ruim não custa só a recompensa daquele passo — ela decide *onde* você estará nos próximos mil.

### Atenção

É essa dependência temporal que torna a exploração em MDPs *qualitativamente* mais difícil, e não apenas mais cara.

# Aquecimento

## Conjugação Beta-Bernoulli e amostragem de Thompson

### Teste sua compreensão

Os *a priori* são  $\text{Beta}(1, 2)$  para o braço 1 e  $\text{Beta}(1, 1)$  para o braço 2.

1. Os valores 0,1, 0,5, 0,3 são mais compatíveis com qual dos dois?
2. É impossível que o parâmetro verdadeiro seja 0 sob o *a priori*  $\text{Beta}(1, 1)$ ?
3. Com  $\omega_1 = 0,4$ ,  $\omega_2 = 0,6$  verdadeiros e amostras  $\tilde{\omega}_1 = 0,50$ ,  $\tilde{\omega}_2 = 0,55$ : Thompson foi *otimista*? Escolhe o braço ótimo?

*Pergunta para o professor conduzir em aula.*

# Aquecimento

## Conjugação Beta-Bernoulli e amostragem de Thompson

### Teste sua compreensão

Os *a priori* são Beta(1, 2) para o braço 1 e Beta(1, 1) para o braço 2.

1. Os valores 0,1, 0,5, 0,3 são mais compatíveis com qual dos dois?
2. É impossível que o parâmetro verdadeiro seja 0 sob o *a priori* Beta(1, 1)?
3. Com  $\omega_1 = 0,4$ ,  $\omega_2 = 0,6$  verdadeiros e amostras  $\tilde{\omega}_1 = 0,50$ ,  $\tilde{\omega}_2 = 0,55$ : Thompson foi *otimista*? Escolhe o braço ótimo?

*Pergunta para o professor conduzir em aula.*

### Resposta

1. Beta(1, 2): densidade  $2(1 - \omega)$ , favorece valores pequenos.
2. Falso — Beta(1, 1) é uniforme.
3. Otimista no braço 1, pessimista no 2 — e mesmo assim acerta.

1. **Um novo critério: PAC.** Arrependimento mede área sob a curva de erro; PAC conta decisões ruins.
2. **Otimismo em MDPs: MBIE-EB** e sua garantia PAC.
3. **Lema da simulação:** converte erro de *modelo* em erro de *valor*.
4. **PSRL:** amostrar um MDP inteiro por episódio.
5. **Generalização:** o que sobra quando não dá para contar visitas.

### A pergunta de fundo

Existe algoritmo que, em *qualquer* MDP tabular, cometa apenas um número **polinomial** de decisões ruins? Sim — e o que decide isso não é a taxa de aprendizado nem a arquitetura.

### Intuição

No *RiverSwim* adiante,  $\epsilon$ -guloso colhe 85 e otimismo colhe 8 580 — mesmo ambiente, mesmo orçamento.

SEÇÃO 1

# Um novo critério: PAC

---

01

# O mapa da área

Cenários, arcabouços e abordagens são eixos independentes

## Definição — Cenários

- ▶ **Bandits** — sem estado.
- ▶ **Bandits contextuais** — estado, sem dinâmica.
- ▶ **MDPs** — a ação move o mundo.

## Arcabouços (critérios)

- ▶ Avaliação empírica
- ▶ Convergência assintótica
- ▶ Arrependimento (aula 11)
- ▶ **PAC (hoje)**
- ▶ Arrependimento bayesiano

## Algoritmo — Abordagens

- ▶ Guloso,  $\epsilon$ -guloso
- ▶ **Otimismo**
- ▶ **Thompson**
- ▶ Meta-aprendizagem

## Intuição


Não confunda os eixos: *otimismo* é abordagem, *PAC* é critério.

## O que o arrependimento não distingue

Dois agentes com o mesmo arrependimento acumulado:

- ▶ **A** erra *pouco, sempre*: perde 0,01 por passo, para sempre.
- ▶ **B** erra *muito, raramente*: 100 escolhas catastróficas; no resto, é ótimo.

Em ensaio clínico, tutor inteligente ou controle de processo, a pergunta não é “quanto perdi no total”, mas “em quantos momentos entreguei uma decisão ruim?”



PAC conta *quantos* passos ficam acima da linha tracejada; arrependimento integra a curva.



# Provavelmente aproximadamente correto (PAC)

## Definição — Algoritmo PAC

Fixados  $\epsilon > 0$  e  $\delta \in (0, 1)$ , o algoritmo  $\mathcal{A}$  é **PAC** se, com probabilidade  $\geq 1 - \delta$ , em todos os passos exceto no máximo  $N$  deles vale  $Q^*(s_t, a_t) \geq V^*(s_t) - \epsilon$ , com  $N$  **polinomial** em  $(|\mathcal{S}|, |\mathcal{A}|, \frac{1}{1-\gamma}, \frac{1}{\epsilon}, \frac{1}{\delta})$ .

## Intuição

Leia os três termos na ordem: *provavelmente*  $\rightarrow 1 - \delta$ ; *aproximadamente*  $\rightarrow \epsilon$ ; *correto*  $\rightarrow$  em todos os passos menos  $N$  exceções.

## Atenção

- ▶  $N$  limita *quantos* passos são ruins, não *quando*.
- ▶ “Polinomial” é o coração: com “exponencial” a definição fica vazia.
- ▶ A garantia é sobre *ações*;  $Q$  pode nunca convergir.

# PAC e arrependimento, lado a lado

|              | Arrependimento                | PAC                                                                         |
|--------------|-------------------------------|-----------------------------------------------------------------------------|
| Mede         | soma das perdas por passo     | nº de passos com perda $> \epsilon$                                         |
| Pergunta     | “quanto perdi ao todo?”       | “quantas vezes fui ruim?”                                                   |
| Parâmetros   | horizonte $T$                 | tolerância $\epsilon$ , risco $\delta$                                      |
| Forma típica | $\tilde{O}(\sqrt{T})$         | $N = \tilde{O}\left(\frac{ S  \mathcal{A} }{\epsilon^2(1-\gamma)^3}\right)$ |
| Cego a       | <i>distribuição</i> dos erros | <i>magnitude</i> dos erros $< \epsilon$                                     |

## Não são equivalentes

Arrependimento  $O(\sqrt{T})$  admite infinitas decisões  $\epsilon$ -ruins (basta rarearem); e um algoritmo PAC pode ter arrependimento linear se as  $N$  decisões ruins forem caríssimas.

## Intuição

Na prática, ambos são atendidos pela *mesma* família de algoritmos, porque ambos exigem a mesma coisa: reduzir incerteza de forma **dirigida**, não por sorteio.

SEÇÃO 2

## Otimismo em MDPs: MBIE-EB

---

02

# Por que exploração em MDPs é outro problema

O *RiverSwim*: um contraexemplo de seis estados

nadar contra a correnteza: sobe com 0,35, fica com 0,60, desce com 0,05



deixar-se levar pela correnteza: desce com certeza

## Atenção

A recompensa grande está a cinco passos improváveis, e o caminho é *contra* a dinâmica. A política ótima ( $\gamma = 0,95$ ) nada à direita em todo estado.

## Intuição

Nenhuma quantidade de *ruído local* produz uma *sequência* coerente de cinco escolhas certas. Explorar bem exige um **plano** de exploração.

## Quanto isso custa, em números

20 000 passos, 30 execuções,  $\gamma = 0,95$

| Algoritmo                               | Recompensa | % do ótimo |
|-----------------------------------------|------------|------------|
| $\epsilon$ -guloso ( $\epsilon = 0,3$ ) | 61         | 0,7%       |
| $\epsilon$ -guloso ( $\epsilon = 0,1$ ) | 85         | 1,0%       |
| <b>PSRL</b> (Thompson)                  | 8 095      | 92,4%      |
| <b>MBIE-EB</b> (otimismo)               | 8 580      | 97,9%      |
| $\pi^*$ conhecida                       | 8 760      | 100%       |

### Atenção

Em 20 execuções de 200 000 passos, o  $\epsilon$ -guloso **nunca** visitou  $s_6$ : as ações aleatórias não se encadeiam.

### O escalonamento é exponencial

Passos (mediana) até um explorador aleatório tocar o topo do rio:

| $ \mathcal{S} $ | passos até o topo |
|-----------------|-------------------|
| 4               | 54                |
| 6               | 763               |
| 8               | 5 897             |
| 10              | 40 179            |
| 12              | 362 322           |

Dois estados a mais multiplicam o custo por  $\approx 8$ : assinatura de  $e^{\Theta(|\mathcal{S}|)}$ .

## MBIE-EB

Model-Based Interval Estimation with Exploration Bonus — Strehl & Littman (2008)

### Algoritmo — MBIE-EB

- 1: Dados  $\epsilon, \delta, m$ ;  $\beta = \frac{1}{1-\gamma} \sqrt{0,5 \ln(2|\mathcal{S}||\mathcal{A}|m/\delta)}$
- 2:  $n(s, a), n(s, a, s'), r_c(s, a) \leftarrow 0$ ;  $\tilde{Q}(s, a) \leftarrow \frac{1}{1-\gamma}$
- 3: **repita**
- 4:  $a_t = \arg \max_a \tilde{Q}(s_t, a)$  (guloso na  $Q$  otimista)
- 5: **observe**  $r_t, s_{t+1}$ ; **atualize**  $n(s_t, a_t), n(s_t, a_t, s_{t+1}), r_c$
- 6:  $\hat{R}(s, a) = \frac{r_c(s, a)}{n(s, a)}, \quad \hat{P}(s' | s, a) = \frac{n(s, a, s')}{n(s, a)}$
- 7: **até convergir:**  $\tilde{Q}(s, a) \leftarrow \hat{R}(s, a) + \gamma \sum_{s'} \hat{P}(s' | s, a) \max_{a'} \tilde{Q}(s', a') + \frac{\beta}{\sqrt{n(s, a)}}$

Estime o modelo por contagens, some um *bônus* que decai, *planeje* no modelo otimista e siga o plano — sem nenhum  $\epsilon$ -guloso: a política executada é determinística.

# Anatomia do bônus

De onde vem  $\beta / \sqrt{n(s, a)}$

## 1 — concentração

Com  $n$  amostras i.i.d. em  $[0, 1]$ , Hoeffding dá  $|\hat{R} - R| \leq \sqrt{\ln(2/\delta')/(2n)}$  com probabilidade  $1 - \delta'$ .

## 2 — limitante da união

Deve valer para  $|\mathcal{S}||\mathcal{A}|$  pares e  $m$  níveis: troque  $\delta'$  por  $\delta/(2|\mathcal{S}||\mathcal{A}|m)$  — daí o logaritmo em  $\beta$ .

## 3 — propagação

O erro de um passo se acumula ao longo do horizonte efetivo: daí  $\frac{1}{1-\gamma}$ .

## Definição — o bônus é uma barra de erro

$$\frac{\beta}{\sqrt{n(s, a)}} = \underbrace{\frac{1}{1-\gamma}}_{\text{horizonte}} \times \underbrace{\sqrt{\frac{\ln(\cdot/\delta)}{2n(s, a)}}}_{\text{largura do IC}}$$

## Intuição

Estados nunca visitados começam com  $\tilde{Q} = \frac{1}{1-\gamma}$ , o maior valor possível: o desconhecido é, *por construção*, o mais atraente do mapa.

# O bônus *dentro* do planejamento

## Definição — Em bandits

$a_t = \arg \max_a [\hat{\mu}(a) + \beta / \sqrt{n(a)}]$ . A incerteza de  $a$  só influencia a escolha de  $a$ .

## Definição — Em MDPs

O bônus entra na equação de Bellman e é **propagado para trás**: a incerteza em  $s_6$  torna atraente o *caminho inteiro* até  $s_6$ .

## Intuição

É a **exploração profunda**: aceitar perdas imediatas certas em troca de informaçãoção distante.

bônus grande  
(nunca visitado)



o planejamento carrega o otimismo para trás:  
 $s_1$  “sabe” que vale a pena caminhar até  $s_5$

$$\tilde{Q}(s, a) = \hat{R} + \frac{\beta}{\sqrt{n(s, a)}} + \gamma \sum_{s'} \hat{P} \max_{a'} \tilde{Q}(s', a')$$



## Teorema (Strehl & Littman, 2008 — simplificado)

Com probabilidade  $\geq 1 - \delta$ , o MBIE-EB é  $\epsilon$ -ótimo em todos os passos exceto no máximo  $N = \tilde{O}(|\mathcal{S}|^2 |\mathcal{A}| \epsilon^{-3} (1 - \gamma)^{-6})$ .

## Definição — Esqueleto da prova

1.  $\tilde{Q} \geq Q^*$  sempre (otimismo válido).
2.  $n(s, a) \geq m \Rightarrow$  modelo preciso (par conhecido).
3. Lema da simulação: modelo preciso  $\Rightarrow$  valor preciso.
4. **Dicotomia:** ou a ação é  $\epsilon$ -ótima, ou há boa chance de visitar um par desconhecido — e só cabem  $m|\mathcal{S}||\mathcal{A}|$  fugas.

## Intuição

O passo (4) é o pivô: *ser otimista transforma cada erro em informação*. Se a ação não é boa,  $\tilde{Q}$  está inflado em algum ponto do caminho — e só infla onde falta experiência.

## Atenção

Os expoentes são frouxos; Azar et al. (2017) atingem a dependência minimax.

# Lema da simulação

A ponte entre erro de modelo e erro de valor

## Lema (limitante do erro de valor)

Sejam  $\mathcal{M}_1$  e  $\mathcal{M}_2$  MDPs sobre os mesmos espaços e  $\pi$  uma política fixa. Se para todo  $(s, a)$

$$|R_1(s, a) - R_2(s, a)| \leq \varepsilon_R, \quad \|P_1(\cdot \mid s, a) - P_2(\cdot \mid s, a)\|_1 \leq \varepsilon_P,$$

então, com  $V_{\max} = R_{\max}/(1 - \gamma)$ ,

$$\max_s |V_1^\pi(s) - V_2^\pi(s)| \leq \frac{\varepsilon_R + \gamma V_{\max} \varepsilon_P}{1 - \gamma}.$$

## Intuição

*Modelos parecidos têm valores parecidos, com amplificação  $1/(1 - \gamma)$  — o horizonte efetivo.*

## Atenção

$\varepsilon_P$  entra multiplicado por  $V_{\max}$ : custa  $1/(1 - \gamma)^2$  contra  $1/(1 - \gamma)$  de  $\varepsilon_R$ . *Errar a dinâmica é mais caro.*

## Prova do lema da simulação

Some e subtraia  $\gamma \sum_{s'} P_1(s'|s, a) V_2^\pi(s')$  na equação de Bellman:

$$\begin{aligned} |Q_1^\pi(s, a) - Q_2^\pi(s, a)| &= \left| R_1 - R_2 + \gamma \sum_{s'} [P_1(s'|s, a) V_1^\pi(s') - P_2(s'|s, a) V_2^\pi(s')] \right| \\ &\leq \varepsilon_R + \underbrace{\gamma \left| \sum_{s'} P_1 [V_1^\pi - V_2^\pi] \right|}_{\text{(a) mesmo modelo, valores diferentes}} + \underbrace{\gamma \left| \sum_{s'} [P_1 - P_2] V_2^\pi \right|}_{\text{(b) modelos diferentes, mesmo valor}}. \end{aligned}$$

- (a):  $P_1(\cdot|s, a)$  é distribuição, logo média ponderada  $\leq \Delta := \max_s |V_1^\pi(s) - V_2^\pi(s)|$ ; (b): Hölder dá  $\leq \varepsilon_P \|V_2^\pi\|_\infty \leq \varepsilon_P V_{\max}$ .

Como  $V_i^\pi(s) = Q_i^\pi(s, \pi(s))$ , tomando o máximo em  $s$  dos dois lados:

$$\Delta \leq \varepsilon_R + \gamma \Delta + \gamma V_{\max} \varepsilon_P \implies \Delta \leq \frac{\varepsilon_R + \gamma V_{\max} \varepsilon_P}{1 - \gamma}. \quad \blacksquare$$

---

Separar erro de valor de erro de modelo por um termo híbrido é o mesmo padrão da prova de contração da Aula 2.

# Fechando o argumento

Como o lema vira uma garantia PAC

## Definição — MDP conhecido induzido $\mathcal{M}_K$

Igual ao MDP real nos pares com  $n(s, a) \geq m$ ; nos demais, um estado absorvente de valor  $V_{\max}$ . Há sempre dois regimes:

- ▶ age dentro de  $\mathcal{M}_K$  — o lema garante valor quase ótimo;
- ▶ ou *escapa* para um par desconhecido — e aprende.

Cada fuga incrementa algum  $n(s, a)$ : cabem no máximo  $m|\mathcal{S}||\mathcal{A}|$  delas.

## Intuição

“Ou você é quase ótimo, ou aprende algo — e só há um número finito de coisas a aprender” é o esqueleto de *quase toda* prova de eficiência amostral em RL.

## Atenção

$m$  maior  $\Rightarrow$  lema mais apertado, porém mais fugas: esse balanço fixa o expoente de  $\epsilon$ .

### Teste sua compreensão

Sobre exploração estratégica em MDPs, avalie cada afirmação:

1. “Não importa muito, porque a distribuição dos dados independe da política.”
2. “Pode envolver otimismo simultâneo quanto à dinâmica e à recompensa.”
3. “Chama-se PAC quando o número de decisões não quase-ótimas é menor que uma função *exponencial* dos parâmetros do domínio.”

*Pergunta para o professor conduzir em aula.*

### Teste sua compreensão

Sobre exploração estratégica em MDPs, avalie cada afirmação:

1. “Não importa muito, porque a distribuição dos dados independe da política.”
2. “Pode envolver otimismo simultâneo quanto à dinâmica e à recompensa.”
3. “Chama-se PAC quando o número de decisões não quase-ótimas é menor que uma função *exponencial* dos parâmetros do domínio.”

*Pergunta para o professor conduzir em aula.*

### Resposta

- 1. Falsa** — em RL os dados são *gerados* pela política. **2. Verdadeira** — é o que MBIE-EB e R-MAX fazem. **3. Falsa** — tem de ser *polinomial*.

SEÇÃO 3

# MDPs bayesianos e amostragem posterior

---

03

# Retomada: bandits bayesianos

## Definição — Bandit de Bernoulli

$r \sim \text{Bernoulli}(\theta_a)$  e *a priori*  $\theta_a \sim \text{Beta}(\alpha, \beta)$ .  
Após observar  $r$ , o *a posteriori* é

$$\text{Beta}(\alpha + r, \beta + 1 - r).$$

## Intuição

Atualizar a crença custa *duas somas*. É essa conveniência algébrica que torna Thompson barato o bastante para rodar em produção.

## Algoritmo — Thompson (bandits)

- 1: inicialize  $p(R_a)$  para cada braço
- 2: **repita**
- 3:   amostre  $\tilde{R}_a \sim p(R_a \mid h_t)$
- 4:    $\tilde{Q}(a) = \mathbb{E}[\tilde{R}_a]$
- 5:    $a_t = \arg \max_a \tilde{Q}(a)$
- 6:   observe  $r_t$ ; atualize por Bayes

## Atenção

Com *a priori* concentrado e errado, Thompson pode nunca corrigir — enquanto UCB, que não usa *a priori*, corrige.



# Do bandit ao MDP bayesiano

## Definição — Crença sobre o modelo

Em vez de um *a posteriori* sobre recompensas médias, mantenha  $p(P, R \mid h_t)$  com  $h_t = (s_1, a_1, r_1, \dots, s_t)$ . Cada amostra é um **MDP inteiro**.

## Conjugação para a dinâmica

Com  $P(\cdot \mid s, a) \sim \text{Dir}(\alpha_{s,a,1}, \dots, \alpha_{s,a,|S|})$ , observar  $(s, a) \rightarrow s'$  apenas incrementa  $\alpha_{s,a,s'}$ . Dirichlet está para a Multinomial como Beta para a Bernoulli.

## Definição — Casamento de probabilidades

Escolha  $a$  com probabilidade igual à probabilidade *posterior* de que  $a$  seja ótima:

$$\pi(s, a \mid h_t) = \mathbb{E}_{P,R|h_t} [\mathbb{1}(a = \arg \max_{a'} Q(s, a'))].$$

## Intuição

Calcular essa probabilidade é intratável, mas *amostrar* dela é trivial: sorteie um MDP, resolva-o, aja de forma ótima nele. A ação já sai distribuída assim, sem nunca calcular a integral.

# PSRL — amostragem posterior para RL

Osband, Russo & Van Roy (NeurIPS 2013)

## Algoritmo — PSRL

- 1: inicialize *a priori*  $p(R_{s,a})$  e  $p(P(\cdot \mid s, a))$  para cada  $(s, a)$
- 2: **para** episódio  $k = 1, \dots, K$ :
- 3:   **amostre um MDP**  $\tilde{\mathcal{M}}_k$ : sorteie  $\tilde{P}(\cdot \mid s, a)$  e  $\tilde{R}(s, a)$  do *a posteriori*
- 4:   resolva  $\tilde{\mathcal{M}}_k$ , obtendo  $Q_{\tilde{\mathcal{M}}_k}^*$
- 5:   **para**  $t = 1, \dots, H$ :  $a_t = \arg \max_a Q_{\tilde{\mathcal{M}}_k}^*(s_t, a)$ ; observe  $r_t, s_{t+1}$
- 6:   atualize o *a posteriori* com os dados do episódio

## Garantia

Arrependimento bayesiano  $\tilde{O}(H \sqrt{|S||\mathcal{A}|T})$   
— comparável aos melhores algoritmos otimistas, e em geral melhor na prática.

## Intuição

Repare no que PSRL *não* tem: nenhum  $\epsilon$ , nenhum bônus, nenhuma constante de concentração. A exploração emerge da variância do *a posteriori*, que encolhe sozinha.

# A granularidade da amostragem é o algoritmo

## Atenção

Amostrar um MDP novo a cada passo, em vez de a cada episódio, destrói a garantia.

## Definição — Por quê

O agente troca de hipótese a cada passo: começa a nadar rio acima com  $\tilde{\mathcal{M}}_1$ , muda de ideia, volta. O agregado vira um *passeio aleatório*.

## Intuição

Comprometer-se com uma hipótese por um episódio é o análogo bayesiano da propagação do bônus: ambos dão **exploração profunda**.

amostra por episódio



amostra por passo



a mesma *a posteriori*, duas granularidades, desempenhos incomparáveis

## Otimismo e Thompson: duas leituras da mesma ideia

|             | Otimismo (MBIE-EB)               | Posterior (PSRL)                    |
|-------------|----------------------------------|-------------------------------------|
| Incerteza é | conjunto de confiança            | distribuição <i>a posteriori</i>    |
| Escolhe     | o <i>melhor caso</i> do conjunto | <i>um caso</i> , sorteado           |
| Requer      | desigualdade de concentração     | <i>a priori</i> + conjugação        |
| Garantia    | PAC / arrep. no pior caso        | arrependimento bayesiano            |
| Falha se    | o bônus é frouxo                 | o <i>a priori</i> é rígido e errado |
| RiverSwim   | 8 580                            | 8 095                               |

### Intuição

Ambos transformam “não sei” em “vale a pena ir ver”. Otimismo faz isso *deterministicamente e no pior caso*; Thompson, *estocasticamente e na média*.

### Amostragem por semente

Dimakopoulou & Van Roy (2018): com  $M$  agentes em paralelo, amostrar independentemente faz todos seguirem hipóteses parecidas. Uma *semente* fixa por agente gera diversidade coordenada.

### Teste sua compreensão

Sobre o PSRL apresentado:

1. “Bastaria amostrar a recompensa e usar a média empírica para a dinâmica — o desempenho seria o mesmo.”
2. “É possível replanejar sempre que o *a posteriori* é atualizado.”
3. “O custo computacional por passo é sempre o mesmo do *Q*-learning.”

*Pergunta para o professor conduzir em aula.*

### Teste sua compreensão

Sobre o PSRL apresentado:

1. “Bastaria amostrar a recompensa e usar a média empírica para a dinâmica — o desempenho seria o mesmo.”
2. “É possível replanejar sempre que o *a posteriori* é atualizado.”
3. “O custo computacional por passo é sempre o mesmo do *Q*-learning.”

*Pergunta para o professor conduzir em aula.*

### Resposta

1. **Falsa** — no *RiverSwim* a incerteza que importa é sobre a *dinâmica*.
2. **Verdadeira** no algoritmo mostrado, embora a garantia seja provada para reamostragem por episódio.
3. **Falsa** — PSRL resolve um MDP inteiro por episódio: ~~troca-se computação por amostras.~~

SEÇÃO 4

# Generalização e exploração

---

04

# O que quebra em espaços grandes

## Atenção

$$\tilde{Q}(s, a) \leftarrow \hat{R} + \gamma \sum_{s'} \hat{P}_{a'} \tilde{Q} + \frac{\beta}{\sqrt{n(s, a)}}$$

Se cada estado é visitado no máximo uma vez,  $n(s, a) \in \{0, 1\}$ : o bônus deixa de informar.

## Definição — Três coisas a reconstruir

1. “Já visitei isto” que respeite *similaridade*.
2. Incerteza sobre *valores*, não contagens.
3. Exploração profunda com aproximação de função.

## Intuição

A generalização *muda o problema de exploração*: se estados parecidos têm valores parecidos, visitar um informa sobre os outros. A exploração deixa de escalar com  $|\mathcal{S}|$  e passa a escalar com a *complexidade da classe de funções*.

## Roteiro

Primeiro os bandits contextuais lineares; depois, os MDPs.



# Bandits contextuais

## Definição — Bandit contextual

A cada rodada: o ambiente revela um contexto  $s_t$  (não escolhido pelo agente); o agente escolhe  $a_t$ ; recebe  $r_t \sim R_{a_t, s_t}$ . **Sem dinâmica:**  $s_{t+1}$  não depende de  $a_t$ .

## Intuição

Meio-termo exato entre bandit e MDP: tem *estado* (exige generalização) mas não tem *consequência* (não exige exploração profunda). É onde a teoria é completa — e onde vive quase toda a aplicação industrial.

## Modelo linear compartilhado

$$r(s, a) = \theta^\top \phi(s, a) + \eta, \quad \eta \sim \mathcal{N}(0, \sigma^2).$$

## Modelo linear disjunto

Cada braço tem seu parâmetro:  $r(s, a) = \theta_a^\top \phi(s) + \eta$ .

## Teste sua compreensão

O modelo compartilhado consegue representar um modelo disjunto? Se sim, como?  
*Pergunta para o professor conduzir em aula.*

## Sim — por empilhamento em blocos

Com  $|\mathcal{A}| = K$  e  $\phi(s) \in \mathbb{R}^d$ , defina  $\phi(s, a) \in \mathbb{R}^{Kd}$  com  $\phi(s)$  no bloco  $a$  e zeros nos demais, e empilhe  $\theta = (\theta_1, \dots, \theta_K)$ . Então

$$\theta^\top \phi(s, a) = \theta_a^\top \phi(s).$$

### Atenção

O preço é a dimensão:  $d \rightarrow Kd$ . E esse é o ponto — o modelo disjunto **não compartilha informação entre braços**, e a dimensão maior é a expressão formal disso. Um  $\phi(s, a)$  bem projetado aprende sobre um braço observando outro.

|                | $\theta_1$ | $\theta_2$ | $\theta_3$ |
|----------------|------------|------------|------------|
| $\phi(s, a_1)$ | $\phi(s)$  | 0          | 0          |
| $\phi(s, a_2)$ | 0          | $\phi(s)$  | 0          |
| $\phi(s, a_3)$ | 0          | 0          | $\phi(s)$  |

### Intuição

É o LinUCB “disjunto” do artigo de recomendação de notícias do Yahoo! (Li et al., WWW 2010) — talvez o bandit contextual mais implantado da história.

## O ganho da generalização, medido


$d = 5, \sigma = 0,3, T = 4\,000$  rodadas, média de 15 execuções

| braços $K$ | UCB (sem contexto) | LinUCB |
|------------|--------------------|--------|
| 20         | 63                 | 49     |
| 60         | 166                | 66     |
| 180        | 481                | 78     |
| 540        | 1 282              | 88     |

arrependimento acumulado ao fim de  $T$

### A leitura teórica

UCB:  $\tilde{O}(\sqrt{KT})$ ; LinUCB:  $\tilde{O}(d\sqrt{T})$ . O número de braços sai do limitante, substituído pela dimensão.



### Atenção

O ganho existe se o *modelo linear* estiver *correto*. Sob má especificação, LinUCB converge com confiança para o braço errado — risco que o UCB não corre.

# Incerteza sobre um vetor

De intervalos de confiança a elipsoides

## Definição — A mudança conceitual

Antes, um intervalo em torno de um *escalar*. Agora a incerteza vive em  $\theta \in \mathbb{R}^d$  e o conjunto de confiança é um **elipsoide**:

$$\mathcal{C}_t = \{\theta : \|\theta - \hat{\theta}_t\|_{A_t} \leq \alpha_t\}, \quad A_t = \lambda I + \sum_{\tau < t} \phi_\tau \phi_\tau^\top,$$

com  $\hat{\theta}_t = A_t^{-1} \sum_{\tau < t} \phi_\tau r_\tau$  (crista).

## Algoritmo — LinUCB

$$a_t = \arg \max_a \hat{\theta}_t^\top \phi(s_t, a) + \alpha \sqrt{\phi(s_t, a)^\top A_t^{-1} \phi(s_t, a)}$$

## Intuição

O termo  $\sqrt{\phi^\top A_t^{-1} \phi}$  é a largura do elipsoide *na direção* de  $\phi$ : o análogo de  $1/\sqrt{n(s, a)}$ , sensível à geometria.

## Teste sua compreensão

Por que representar a incerteza sobre  $\theta$  basta para representar a incerteza sobre  $r$ ? *Pergunta para o professor conduzir em aula.*

# Incerteza epistêmica e incerteza aleatória

## Resposta

Porque  $r$  é função conhecida de  $\theta$  mais ruído independente. Dado  $\phi(s, a)$ , toda a incerteza **epistêmica** — a que se reduz com dados — está em  $\theta$ . O resto é ruído **aleatório**: irreduzível e sem valor informativo.

## Atenção

Explorar para reduzir ruído aleatório é desperdício. Um bônus proporcional à *variância total* exploraria para sempre o braço mais ruidoso, ainda que sua média já fosse conhecida.

## Intuição

Esta distinção atravessa a aula inteira:

- ▶  $\beta / \sqrt{n(s, a)}$  no MBIE-EB é epistêmico e decai;
- ▶ a variância do *a posteriori* do PSRL é epistêmica e encolhe;
- ▶ o ruído de recompensa não decai — e nenhum dos dois tenta reduzi-lo.

O *ensemble* do Bootstrapped DQN estima incerteza epistêmica; a variância de retornos, não.

# De volta aos MDPs grandes: bônus dentro do gradiente

## Definição — Q-learning com aproximação

$$\Delta w = \eta (r + \gamma \max_{a'} \hat{Q}(s', a'; w) - \hat{Q}(s, a; w)) \nabla_w \hat{Q}$$

## Algoritmo — Com bônus de exploração

$$\Delta w = \eta (r + r_{\text{bônus}}(s, a) + \gamma \max_{a'} \hat{Q}(s', a'; w) - \hat{Q}(s, a; w)) \nabla_w \hat{Q}$$

Idêntico ao MBIE-EB: o bônus entra no alvo de Bellman e é propagado para trás. Muda só como calculá-lo.

## Estimar novidade sem contar

- ▶ **Pseudo-contagens:** ajuste  $\rho(s)$  e derive  $\hat{n}(s)$  do quanto  $\rho$  sobe ao reobservar  $s$  (Bellemare et al. 2016).
- ▶ **Hashing:** discretize  $s$  e conte *buckets* (Tang et al. 2017).
- ▶ **Erro de predição (RND):** resíduo alto onde há pouca experiência.

## Atenção

Todos são substitutos de  $1/\sqrt{n}$ ; nenhum tem garantia PAC em MDPs gerais.

## Quando isso importa muito: *Montezuma's Revenge*

### Definição — Por que este jogo

Recompensa extremamente esparsa: dezenas de ações corretas encadeadas — pegar a chave, descer a escada, abrir a porta — antes de qualquer sinal. É o *RiverSwim* com  $|S|$  enorme.

### Resultado

DQN com  $\epsilon$ -guloso: pontuação praticamente nula após centenas de milhões de quadros. Com bônus de pseudo-contagem: dezenas de salas e pontuação de ordem de grandeza superior (Bellemare et al., 2016).

### Atenção

Duas ressalvas práticas:

- ▶ **Bônus envelhecem:** guardado no *buffer*, já não corresponde à incerteza atual quando reamostrado.
- ▶ **Não-estacionariedade:** o alvo de Bellman passa a depender de uma recompensa que muda com o tempo.

### Intuição

A diferença entre um agente que funciona e um que não funciona está em *como ele decide o que ainda não sabe*.

# Thompson com aproximação de função

## Definição — O obstáculo

Amostrar de um *a posteriori* sobre  $Q^*$ : não há conjugação, redes neurais não têm *a posteriori* fechado.

## Algoritmo — Bootstrapped DQN (Osband et al. 2016)

- ▶  $C$  “cabeças” treinadas em amostras *bootstrap* dos mesmos dados.
- ▶ Por episódio, sorteie *uma* cabeça e siga-a até o fim.

A persistência recupera a exploração profunda.

## Algoritmo — Bayesian DQN (Azizzadenesheli et al. 2017)

Rede profunda como extrator de características; na *última camada*, regressão linear bayesiana — que tem *a posteriori* fechado.

## Como se comparam

Empiricamente:  $\text{bônus} > \text{BDQN} > \text{Bootstrapped DQN} > \epsilon\text{-guloso}$ , com inversões por domínio. Nenhum domina.

O BDQN é o LinUCB sobre características aprendidas.



# Aprender a explorar

## Exploração entre tarefas e meta-RL

### Definição — Observação de partida

Tudo o que vimos supõe **ignorância total** no início. Mas um agente real enfrenta tarefas da mesma *família* — robôs em cozinhas diferentes, tutores para alunos diferentes. Havendo estrutura comum, a exploração ótima pode ser *aprendida*.

### DREAM (Liu et al., NeurIPS 2022)

Separa *exploração* de *execução*: a política de exploração é treinada para produzir uma representação da tarefa útil à execução, e não para maximizar recompensa.

### Decision-Pretrained Transformer (Lee, Xie et al., NeurIPS 2023)

Pré-treine um *transformer* para prever a *ação ótima*  $a^*$  a partir do histórico. Em teste ele age *in-context*, sem atualizar pesos. **Chave:** prever  $a^*$  *imita* Thompson, com um *a priori* implícito muito mais rico — a distribuição de tarefas de treino.

### Intuição

Fecha-se o círculo: começamos exigindo garantias no pior caso e terminamos aprendendo o *a priori* que o torna irrelevante.

SEÇÃO 5

## Panorama e fechamento

---

05

# Onde está a teoria hoje

## MDPs tabulares — essencialmente resolvido

- ▶ **Arrependimento minimax:** Azar, Osband & Munos, ICML 2017.
- ▶ **PAC:** Dann, Li, Wei & Brunskill, *Policy certificates*, ICML 2019 — com certificados por episódio.
- ▶ **Dependentes da instância:** Zanette & Brunskill (2019); Simchowitz & Jamieson (2019) — adaptam-se a problemas fáceis.

## Com aproximação de função — em aberto

- ▶ MDP *linear*: Jin, Yang, Wang & Jordan, COLT 2020.
- ▶ Medidas de complexidade da exploração: **dimensão de Eluder** (Russo & Van Roy), **posto de Bellman** (Jiang et al.).

## Atenção

A pergunta em aberto não é “existe algoritmo eficiente?”, e sim *quais propriedades do domínio* tornam a exploração tratável. Fora delas, há limitantes inferiores exponenciais.

## Mapa: algoritmo × critério

| Algoritmo                   | Cenário           | Abordagem | Critério satisfeito                   |
|-----------------------------|-------------------|-----------|---------------------------------------|
| $\epsilon$ -guloso (fixo)   | bandit / MDP      | aleatório | nenhum                                |
| $\epsilon$ -guloso (GLIE)   | MDP               | aleatório | convergência assintótica              |
| UCB                         | bandit            | otimismo  | arrependimento $\tilde{O}(\sqrt{KT})$ |
| Thompson                    | bandit            | posterior | arrep. bayesiano e frequentista       |
| LinUCB                      | bandit contextual | otimismo  | arrependimento $\tilde{O}(d\sqrt{T})$ |
| <b>MBIE-EB</b> / R-MAX      | MDP tabular       | otimismo  | <b>PAC</b>                            |
| UCRL2, UCBVI                | MDP tabular       | otimismo  | arrependimento (minimax)              |
| <b>PSRL</b>                 | MDP tabular       | posterior | arrependimento bayesiano              |
| Bônus de contagem (deep RL) | MDP grande        | otimismo  | empírico                              |
| Bootstrapped DQN, BDQN      | MDP grande        | posterior | empírico                              |
| DREAM, DPT                  | família de MDPs   | meta      | empírico                              |

De cima para baixo, quanto mais realista o cenário, mais fracas as garantias — mas as *duas* abordagens atravessam a tabela inteira.

# O que você deve sair sabendo

## Definição — Conceitual

- ▶ Enunciar a tensão exploração–exploração e por que ela não aparece em aprendizado supervisionado.
- ▶ Comparar os critérios: empírico, assintótico, arrependimento, PAC.
- ▶ Mapear cada algoritmo ao critério que satisfaz.
- ▶ Dizer por que  $\epsilon$ -guloso falha no *RiverSwim*.

## Definição — Técnico

- ▶ Reproduzir o **lema da simulação** e sua prova.
- ▶ Reconstruir o esboço da prova do UCB (Aula 11) e o da prova PAC de hoje.
- ▶ Escrever MBIE-EB e PSRL, indicando onde entra cada hipótese.
- ▶ Implementar UCB e Thompson para bandit contextual linear.

**Próxima aula:** busca em árvore de Monte Carlo.

## Referências principais

- ▶ A. L. Strehl, M. L. Littman. *An analysis of model-based interval estimation for MDPs*. J. of Computer and System Sciences, 2008.
- ▶ I. Osband, D. Russo, B. Van Roy. *(More) efficient RL via posterior sampling*. NeurIPS 2013.
- ▶ M. Dimakopoulou, B. Van Roy. *Coordinated exploration in concurrent RL*. ICML 2018.
- ▶ L. Li, W. Chu, J. Langford, R. Schapire. *A contextual-bandit approach to personalized news article recommendation*. WWW 2010.
- ▶ M. G. Bellemare et al. *Unifying count-based exploration and intrinsic motivation*. NIPS 2016.
- ▶ I. Osband, C. Blundell, A. Pritzel, B. Van Roy. *Deep exploration via bootstrapped DQN*. NIPS 2016.
- ▶ M. G. Azar, I. Osband, R. Munos. *Minimax regret bounds for RL*. ICML 2017.
- ▶ C. Dann, L. Li, W. Wei, E. Brunskill. *Policy certificates*. ICML 2019.
- ▶ C. Jin, Z. Yang, Z. Wang, M. Jordan. *Provably efficient RL with linear function approximation*. COLT 2020.
- ▶ J. Lee, A. Xie et al. *Supervised pretraining can learn in-context RL*. NeurIPS 2023.
- ▶ T. Lattimore, C. Szepesvári. *Bandit Algorithms*. Cambridge, 2020 — caps. 19 e 36.