

Aprendizagem rápida em MDPs

Critério PAC • MBIE-EB • lema da simulação • PSRL • exploração com generalização

Prof. Marcelo Keese Albertini

Adaptado e expandido de CS234 — Reinforcement Learning, Emma Brunskill (Stanford), Lecture 12

1 A ideia central

Até a aula passada, exploração era um problema de *uma decisão*: qual braço puxar. Em MDPs a ação não muda apenas a recompensa deste instante — ela muda *onde o agente estará* nos próximos mil passos. A consequência é que injetar ruído local na escolha da ação (o ϵ -guloso) deixa de ser uma estratégia de exploração e passa a ser apenas ruído: sequências longas de escolhas corretas nunca se formam por acaso.

Intuição

A aula responde a duas perguntas. **(1)** Como medir se um algoritmo explora bem? — daí o critério **PAC**. **(2)** Que princípios produzem exploração boa? — daí **otimismo** (MBIE-EB) e **amostragem posterior** (PSRL). Tudo o mais na aula é consequência ou aplicação desses dois princípios.

2 Critérios: o que “bom” quer dizer

Já vimos quatro maneiras de julgar um algoritmo de RL. Vale saber *o que cada uma mede* e *o que cada uma ignora*.

Critério	O que garante	Onde é cego
Empírico	desempenho nos domínios testados	não diz nada fora deles
Convergência assintótica	no limite, política ótima	não diz <i>quando</i>
Arrependimento	soma das perdas cresce devagar	não distingue muitos erros pequenos de poucos grandes
PAC	número <i>limitado</i> de decisões ruins	não distingue erros abaixo de ϵ

Definição — Provavelmente aproximadamente correto (PAC)

Fixados uma tolerância $\epsilon > 0$ e um risco $\delta \in (0, 1)$, um algoritmo $\mathcal{A}$ é **PAC** se, com probabilidade ao menos $1 - \delta$, em todos os passos exceto no máximo N deles a ação escolhida satisfaz

$$Q^*(s_t, a_t) \geq V^*(s_t) - \epsilon,$$

com N polinomial em $(|\mathcal{S}|, |\mathcal{A}|, \frac{1}{1-\gamma}, \frac{1}{\epsilon}, \frac{1}{\delta})$.

Leia o nome na ordem: *provavelmente* corresponde a $1 - \delta$; *aproximadamente* a ϵ ; *correto* a “em todos os passos, exceto N ”. Três leituras erradas são comuns:

- N limita *quantos* passos são ruins, não *quando* eles ocorrem. Eles podem estar espalhados


por toda a execução, e não apenas no início.

- ▶ A palavra “polinomial” é o conteúdo inteiro da definição. Trocá-la por “exponencial” torna a definição vazia — um agente que enumerasse todas as políticas já a satisfaria.
- ▶ A garantia é sobre *ações*, não sobre convergência de Q . Um agente pode ser PAC sem que sua função valor jamais convirja.

Atenção

PAC e arrependimento **não são equivalentes**. Um algoritmo com arrependimento $O(\sqrt{T})$ pode cometer infinitas decisões ϵ -ruins, desde que fiquem cada vez mais raras; e um algoritmo PAC pode ter arrependimento linear se as N decisões ruins forem arbitrariamente caras. Na prática, porém, ambos são atendidos pela mesma família de algoritmos, porque ambos exigem a mesma coisa: reduzir incerteza de forma *dirigida*.

3 Por que MDPs são qualitativamente diferentes: o RiverSwim



Nadar contra a correnteza sobe um estado com probabilidade 0,35, fica parado com 0,60 e desce com 0,05. Deixar-se levar desce com certeza. Com $\gamma = 0,95$, a política ótima nada à direita em *todo* estado, e

$$V^* = (4,67; 5,08; 5,90; 6,91; 8,09; 9,47).$$

20 000 passos, média de 30 execuções			Passeio aleatório até o topo	
Algoritmo	Recompensa	% do ótimo	$ S $	passos (mediana)
ϵ -guloso ($\epsilon = 0,3$)	61	0,7%	4	54
ϵ -guloso ($\epsilon = 0,1$)	85	1,0%	6	763
PSRL (Thompson)	8 095	92,4%	8	5 897
MBIE-EB (otimismo)	8 580	97,9%	10	40 179
π^* conhecida	8 760	100%	12	362 322

Três leituras dessa tabela:

1. A diferença entre 85 e 8 580 é de *duas ordens de grandeza*, e não vem de ajuste fino de hiperparâmetro. Vem de qual princípio de exploração o agente usa.
2. Em 20 execuções independentes de 200 000 passos, o ϵ -guloso **nunca** visitou s_6 . Ele aprende rapidamente a recompensa pequena de s_1 , torna-se guloso à esquerda, e as ações aleatórias de 10% não se encadeiam nas cinco subidas consecutivas necessárias.
3. A coluna da direita mostra por quê: dois estados a mais multiplicam o custo por ≈ 8 . É a assinatura de $e^{\Theta(|S|)}$ — exatamente o escalonamento que a definição PAC proíbe.

4 Otimismo: MBIE-EB

Algoritmo — MBIE-EB (Strehl & Littman, 2008)

Entrada: ϵ, δ, m ; $\beta = \frac{1}{1-\gamma} \sqrt{0,5 \ln(2|\mathcal{S}||\mathcal{A}|m/\delta)}$

1. Inicialize $n(s, a) = n(s, a, s') = r_c(s, a) = 0$ e $\tilde{Q}(s, a) = \frac{1}{1-\gamma}$ para todos os pares.
2. A cada passo: execute $a_t = \arg \max_a \tilde{Q}(s_t, a)$, observe r_t e s_{t+1} , e atualize as contagens.
3. Estime $\hat{R}(s, a) = r_c(s, a)/n(s, a)$ e $\hat{P}(s' | s, a) = n(s, a, s')/n(s, a)$.
4. Planeje até convergir no *modelo otimista*:

$$\tilde{Q}(s, a) \leftarrow \hat{R}(s, a) + \gamma \sum_{s'} \hat{P}(s' | s, a) \max_{a'} \tilde{Q}(s', a') + \frac{\beta}{\sqrt{n(s, a)}}.$$

Repare que não há ϵ -guloso em lugar nenhum: a política executada é determinística e gulosa. Toda a exploração vem do bônus.

4.1 De onde vem $\beta/\sqrt{n}$

O bônus é literalmente uma barra de erro, montada em três passos:

1. **Concentração.** Com n amostras i.i.d. de uma recompensa em $[0, 1]$, Hoeffding garante $|\hat{R} - R| \leq \sqrt{\ln(2/\delta')/(2n)}$ com probabilidade $1 - \delta'$. O $\sqrt{n}$ no denominador não é escolha de projeto: é a taxa com que a média empírica se concentra.
2. **Limitante da união.** A garantia precisa valer simultaneamente para os $|\mathcal{S}||\mathcal{A}|$ pares e para m níveis de contagem, o que substitui δ' por $\delta/(2|\mathcal{S}||\mathcal{A}|m)$ — daí o logaritmo dentro de β .
3. **Propagação.** Um erro de um passo se acumula ao longo do horizonte efetivo $1/(1-\gamma)$ — daí o fator multiplicativo em β .

Intuição

Estados nunca visitados começam com $\tilde{Q} = \frac{1}{1-\gamma}$, o maior valor possível no MDP. *O desconhecido é, por construção, o ponto mais atraente do mapa.* Essa é toda a mágica: o agente vai até lá não por curiosidade, mas por ganância mal informada — e é justamente isso que o faz aprender.

4.2 A diferença essencial em relação aos bandits

Em bandits o bônus atua sobre a ação avaliada e nada mais: $a_t = \arg \max_a [\hat{\mu}(a) + \beta/\sqrt{n(a)}]$. Em MDPs o bônus entra *dentro* da equação de Bellman e é **propagado para trás** pelo planejamento: a incerteza sobre s_6 torna atraente o caminho inteiro até s_6 , descontado por γ a cada passo. É isso que a literatura chama de **exploração profunda** — aceitar perdas imediatas *certas* em troca de informação distante. Nenhum ϵ -guloso faz isso, para nenhum valor de ϵ .

5 O lema da simulação

Esta é a peça técnica reutilizável da aula: ela converte erro de *modelo* em erro de *valor*, e reaparece em RL offline, RL baseado em modelo e análise de simuladores.

Lema da simulação

Sejam $\mathcal{M}_1$ e $\mathcal{M}_2$ MDPs sobre os mesmos espaços, e π uma política fixa. Se para todo (s, a)

$$|R_1(s, a) - R_2(s, a)| \leq \varepsilon_R, \quad \|P_1(\cdot | s, a) - P_2(\cdot | s, a)\|_1 \leq \varepsilon_P,$$

então, escrevendo $V_{\max} = R_{\max}/(1 - \gamma)$,

$$\Delta := \max_s |V_1^\pi(s) - V_2^\pi(s)| \leq \frac{\varepsilon_R + \gamma V_{\max} \varepsilon_P}{1 - \gamma}.$$

Demonstração

Pela equação de Bellman, somando e subtraindo o termo híbrido $\gamma \sum_{s'} P_1(s' | s, a) V_2^\pi(s')$:

$$\begin{aligned} |Q_1^\pi(s, a) - Q_2^\pi(s, a)| &= \left| R_1 - R_2 + \gamma \sum_{s'} [P_1(s' | s, a) V_1^\pi(s') - P_2(s' | s, a) V_2^\pi(s')] \right| \\ &\leq \varepsilon_R + \gamma \underbrace{\left| \sum_{s'} P_1(s' | s, a) [V_1^\pi(s') - V_2^\pi(s')] \right|}_{(a)} + \gamma \underbrace{\left| \sum_{s'} [P_1 - P_2](s' | s, a) V_2^\pi(s') \right|}_{(b)}. \end{aligned}$$

Em (a), $P_1(\cdot | s, a)$ é uma distribuição de probabilidade, de modo que a soma é uma média ponderada e portanto (a) $\leq \Delta$. Em (b), a desigualdade de Hölder com o par $\|\cdot\|_1 / \|\cdot\|_\infty$ dá (b) $\leq \varepsilon_P \|V_2^\pi\|_\infty \leq \varepsilon_P V_{\max}$. Como $V_i^\pi(s) = Q_i^\pi(s, \pi(s))$, tomando o máximo em s dos dois lados:

$$\Delta \leq \varepsilon_R + \gamma \Delta + \gamma V_{\max} \varepsilon_P \Rightarrow (1 - \gamma) \Delta \leq \varepsilon_R + \gamma V_{\max} \varepsilon_P \Rightarrow \Delta \leq \frac{\varepsilon_R + \gamma V_{\max} \varepsilon_P}{1 - \gamma}. \quad \blacksquare$$

Intuição

O padrão a memorizar não é a fórmula, e sim a *manobra*: somar e subtrair um termo híbrido para separar “mesmo modelo, valores diferentes” de “modelos diferentes, mesmo valor”. É a mesma manobra da prova de contração do operador de Bellman (Aula 2).

5.1 Uma leitura numérica desconfortável

Tome $\gamma = 0,95$ e $R_{\max} = 1$, logo $V_{\max} = 20$:

ε_R	ε_P	limite para Δ
0,01	0,05	19,2 (vazio: $V_{\max} = 20$)
0,01	0,005	2,10
0,001	0,001	0,40
0,001	$2,1 \times 10^{-4}$	0,10

Atenção

Note a assimetria: ε_P entra multiplicado por $V_{\max}$, custando $1/(1 - \gamma)^2$, contra $1/(1 - \gamma)$ do erro de recompensa. **Erar a dinâmica é muito mais caro que errar a recompensa.** E note a escala: para $\Delta \leq 0,1$ seria preciso $\varepsilon_P \approx 2 \times 10^{-4}$, o que exigiria da ordem de 10^8 amostras por par (s, a) . Os limitantes modernos (Azar et al. 2017) trocam a norma L_1 por desigualdades sensíveis à variância (Bernstein) exatamente para escapar dessa pessimismo.

6 Esqueleto da prova PAC

MBIE-EB é PAC

Com β escolhido como acima, com probabilidade ao menos $1 - \delta$ o MBIE-EB escolhe uma ação ϵ -ótima em todos os passos exceto no máximo $N = \tilde{O}(|S|^2|\mathcal{A}| \epsilon^{-3}(1 - \gamma)^{-6})$.

A prova tem cinco movimentos, e vale conhecê-los porque a estrutura se repete em praticamente toda a literatura de eficiência amostral:

1. **Otimismo válido.** Com probabilidade $1 - \delta$, o bônus cobre o erro de estimação e portanto $\tilde{Q} \geq Q^*$ em todo passo.
2. **Pares conhecidos.** Chame (s, a) de *conhecido* quando $n(s, a) \geq m$. Aí as estimativas $\hat{R}$ e $\hat{P}$ são precisas.
3. **Lema da simulação.** Nos pares conhecidos, modelo preciso implica valor preciso.
4. **Dicotomia da fuga.** Em cada passo, uma de duas coisas vale: ou a ação escolhida é ϵ -ótima, ou o agente tem probabilidade não-desprezível de visitar um par *desconhecido*.
5. **Contagem.** Cada fuga incrementa alguma contagem, e um par deixa de ser desconhecido após m visitas. Logo há no máximo $m|S||\mathcal{A}|$ fugas, e o segundo caso ocorre um número limitado de vezes.

Intuição

O passo (4) é o pivô conceitual: *ser otimista transforma cada erro em informação*. Se a ação escolhida não é boa, é porque $\tilde{Q}$ está inflado em algum ponto do caminho — e $\tilde{Q}$ só fica inflado onde ainda falta experiência. Seguir o plano otimista leva o agente exatamente até lá. O esqueleto “ou você é quase ótimo, ou aprende algo, e só há um número finito de coisas a aprender” vai de R-MAX e E^3 (anos 2000) às provas modernas com dimensão de Eluder.

O parâmetro m é onde o balanço acontece: maior m significa modelo melhor e lema mais apertado, porém mais fugas permitidas. Otimizar esse balanço é o que produz o expoente final de ϵ .

7 Amostragem posterior: PSRL

A alternativa bayesiana ao otimismo. Em vez de um limite superior sobre o que o mundo pode ser, mantenha uma *distribuição* sobre mundos possíveis.

Definição — Crença sobre o modelo

Mantenha $p(P, R \mid h_t)$, com $h_t = (s_1, a_1, r_1, \dots, s_t)$. Cada amostra desse *a posteriori* é um **MDP inteiro**. Com *a priori* de Dirichlet sobre cada linha de transição, $P(\cdot \mid s, a) \sim \text{Dir}(\alpha_{s,a,1}, \dots)$, observar $(s, a) \rightarrow s'$ apenas incrementa $\alpha_{s,a,s'}$ — Dirichlet está para a Multinomial como Beta está para a Bernoulli.

A amostragem de Thompson implementa o *casamento de probabilidades*: escolhe-se a com probabilidade igual à probabilidade posterior de que a seja ótima,

$$\pi(s, a \mid h_t) = \mathbb{E}_{P,R|h_t} \left[\mathbb{1}(a = \arg \max_{a'} Q(s, a')) \right].$$

Calcular essa integral é intratável — mas *amostrar* dela é trivial: sorteie um MDP, resolva-o, e aja de forma ótima nele. A ação já sai distribuída exatamente assim.

Algoritmo — PSRL (Osband, Russo & Van Roy, 2013)

1. Inicialize o *a priori* sobre $R_{s,a}$ e $P(\cdot | s, a)$.
2. Para cada episódio $k = 1, \dots, K$:
 - (a) **amostre um MDP** $\tilde{\mathcal{M}}_k$ do *a posteriori* corrente;
 - (b) resolva $\tilde{\mathcal{M}}_k$, obtendo $Q_{\tilde{\mathcal{M}}_k}^*$;
 - (c) execute $a_t = \arg \max_a Q_{\tilde{\mathcal{M}}_k}^*(s_t, a)$ por H passos;
 - (d) atualize o *a posteriori* com os dados do episódio.

Garantia: arrependimento bayesiano $\tilde{O}(H \sqrt{|S||A|T})$.

Atenção

A granularidade da amostragem é o algoritmo. Trocar “amostre um MDP por episódio” por “amostre um MDP por passo” destrói a garantia — e é um erro fácil de cometer. Amostrando por passo, o agente começa a nadar rio acima acreditando em $\tilde{\mathcal{M}}_1$, muda de ideia no passo seguinte com $\tilde{\mathcal{M}}_2$, e volta. O comportamento agregado vira um passeio aleatório: exatamente o que se queria evitar. Comprometer-se com uma hipótese por um episódio inteiro é o análogo bayesiano da propagação do bônus pelo planejamento; ambos produzem exploração profunda.

	Otimismo (MBIE-EB)	Posterior (PSRL)
Incerteza é	conjunto de confiança	distribuição <i>a posteriori</i>
Escolhe	o <i>melhor caso</i> do conjunto	um caso, sorteado
Requer	desigualdade de concentração	<i>a priori</i> + conjugação
Custo por decisão	planejar no modelo otimista	planejar no MDP amostrado
Garantia	PAC / arrependimento no pior caso	arrependimento bayesiano
Falha quando	o bônus é frouxo (explora demais)	o <i>a priori</i> é rígido e errado
<i>RiverSwim</i>	8 580	8 095

Uma variante útil: quando M agentes exploram o mesmo ambiente em paralelo, amostrar de forma independente faz com que todos sigam hipóteses parecidas. A **amostragem por semente** (Dimakopoulou & Van Roy, 2018) dá a cada agente uma semente fixa e reamostra de maneira determinística dado o histórico comum, gerando diversidade coordenada.

8 Generalização e exploração

8.1 O que quebra

Olhe de novo para $\beta / \sqrt{n(s, a)}$. Se o espaço de estados é contínuo, ou grande o bastante para que cada estado seja visitado no máximo uma vez, então $n(s, a) \in \{0, 1\}$ sempre e o bônus deixa de informar. Há três coisas a reconstruir: uma noção de “já visitei isto” que respeite *similaridade*; uma medida de incerteza sobre *valores* em vez de contagens; e um mecanismo de exploração profunda compatível com aproximação de função.

Intuição

A generalização não é apenas um remédio contra a dimensionalidade: ela *muda o problema de exploração*. Se estados parecidos têm valores parecidos, visitar um informa sobre os outros — e a exploração necessária deixa de escalar com $|S|$ e passa a escalar com a *com-*

(continua)

plexidade da classe de funções.

8.2 Bandits contextuais lineares

O bandit contextual é o meio-termo exato: tem *estado* (logo exige generalização) mas não tem *consequência* (s_{t+1} não depende de a_t , logo não exige exploração profunda). É onde a teoria é mais completa, e onde vive quase toda a aplicação industrial.

Modelo compartilhado	$r(s, a) = \theta^\top \phi(s, a) + \eta$
Modelo disjunto	$r(s, a) = \theta_a^\top \phi(s) + \eta$

O compartilhado *representa* o disjunto: com $|\mathcal{A}| = K$ braços e $\phi(s) \in \mathbb{R}^d$, tome $\phi(s, a) \in \mathbb{R}^{Kd}$ com $\phi(s)$ no bloco a e zeros nos demais, e empilhe $\theta = (\theta_1, \dots, \theta_K)$. Aí $\theta^\top \phi(s, a) = \theta_a^\top \phi(s)$. O preço é a dimensão ($d \rightarrow Kd$) — e esse preço é a expressão formal do fato de que o modelo disjunto *não compartilha informação entre braços*.

A incerteza agora vive em $\mathbb{R}^d$, e o conjunto de confiança é um **elipsoide**:

$$\mathcal{C}_t = \{\theta : \|\theta - \hat{\theta}_t\|_{A_t} \leq \alpha_t\}, \quad A_t = \lambda I + \sum_{\tau < t} \phi_\tau \phi_\tau^\top, \quad \hat{\theta}_t = A_t^{-1} \sum_{\tau < t} \phi_\tau r_\tau,$$

e o LinUCB escolhe

$$a_t = \arg \max_a \left[\hat{\theta}_t^\top \phi(s_t, a) + \alpha \sqrt{\phi(s_t, a)^\top A_t^{-1} \phi(s_t, a)} \right].$$

O termo de bônus é a largura do elipsoide *na direção* de ϕ : direções pouco observadas são largas. É o análogo exato de $1/\sqrt{n(s, a)}$, agora sensível à geometria.

Ganho medido ($d = 5, \sigma = 0,3, T = 4\,000, 15$ execuções)

nº de braços K	UCB (sem contexto)	LinUCB
20	63	49
60	166	66
180	481	78
540	1 282	88

O arrependimento do UCB cresce com K ; o do LinUCB praticamente não se move. É a leitura empírica de $\tilde{O}(\sqrt{KT})$ contra $\tilde{O}(d\sqrt{T})$. A ressalva é honesta: o ganho existe *se o modelo linear estiver correto*. Sob má especificação, o LinUCB pode convergir com confiança para o braço errado — risco que o UCB tabular não corre.

8.3 Epistêmico contra aleatório

Por que representar incerteza sobre θ basta para representar incerteza sobre r ? Porque r é função conhecida de θ mais ruído independente. Dado $\phi(s, a)$, toda a incerteza **epistêmica** — a que se reduz com dados — está em θ ; o resto é ruído **aleatório**, irreduzível e sem valor informativo.

Atenção

Explorar para reduzir ruído aleatório é desperdício puro. Um bônus proporcional à *variância total* da recompensa exploraria para sempre o braço mais ruidoso, ainda que sua

(continua)

média já fosse conhecida com precisão. Essa confusão é uma fonte recorrente de bônus mal calibrados em deep RL: o *ensemble* do Bootstrapped DQN estima incerteza epistêmica; a variância de retornos, não.

8.4 De volta aos MDPs grandes

A modificação é estruturalmente idêntica ao MBIE-EB — o bônus entra no *alvo* de Bellman e é propagado para trás pelo aprendizado:

$$\Delta w = \eta(r + r_{\text{bônus}}(s, a) + \gamma \max_{a'} \hat{Q}(s', a'; w) - \hat{Q}(s, a; w)) \nabla_w \hat{Q}(s, a; w).$$

Muda apenas *como* $r_{\text{bônus}}$ é calculado:

- ▶ **Pseudo-contagens:** ajuste um modelo de densidade $\rho(s)$ e derive $\hat{n}(s)$ de quanto ρ aumenta ao reobservar s (Bellemare et al. 2016; Ostrovski et al. 2017).
- ▶ **Contagens por hashing:** discretize s com um *hash* sensível à localidade e conte os *buckets* (Tang et al. 2017).
- ▶ **Erro de predição** (RND e afins): treine uma rede para prever a saída de uma rede aleatória fixa; o resíduo é alto onde há pouca experiência.

Em *Montezuma's Revenge* — o *RiverSwim* com $|S|$ enorme — DQN com ϵ -guloso obtém pontuação praticamente nula mesmo após centenas de milhões de quadros, enquanto o bônus de pseudo-contagem explora dezenas de salas.

Atenção

Duas ressalvas que a literatura levou anos a explicitar. **Bônus envelhecem:** $r_{\text{bônus}}$ é calculado no instante da visita e armazenado no *buffer* de repetição; quando a transição é reamostrada, o bônus já não corresponde à incerteza atual. **Não-estacionariedade:** o alvo de Bellman passa a depender de uma recompensa que muda com o tempo, ferindo hipóteses de convergência do próprio Q -learning aproximado.

Do lado bayesiano, o obstáculo é que redes neurais não têm *a posteriori* fechado. Duas saídas: o **Bootstrapped DQN** treina C cabeças em amostras *bootstrap* e sorteia uma cabeça por episódio (a persistência recupera a exploração profunda); e o **Bayesian DQN** usa a rede como extrator de características e faz regressão linear bayesiana na última camada — na prática, o LinUCB montado sobre características aprendidas.

8.5 Aprender a explorar

Tudo o que vimos supõe ignorância total sobre o MDP no início. Um agente real, porém, enfrenta muitas tarefas da mesma *família*. Se há estrutura comum, a estratégia de exploração ótima é função dessa estrutura e pode ser *aprendida*: o **DREAM** (Liu et al. 2022) separa explicitamente exploração de execução, e o **Decision-Pretrained Transformer** (Lee, Xie et al. 2023) é pré-treinado para prever a *ação ótima* a partir de um histórico, agindo *in-context* sem atualizar pesos. Treinar para prever a^* *imita* a amostragem de Thompson, mas com um *a priori* implícito muito mais rico: a própria distribuição de tarefas de treino. Fecha-se o círculo da aula — começamos exigindo garantias no pior caso e terminamos aprendendo o *a priori* que torna o pior caso irrelevante na prática.

9 Mapa: algoritmo × critério

Algoritmo	Cenário	Abordagem	Critério satisfeito
ϵ -guloso (fixo)	bandit / MDP	aleatório	nenhum
ϵ -guloso (GLIE)	MDP	aleatório	convergência assintótica
UCB	bandit	otimismo	arrependimento $\tilde{O}(\sqrt{KT})$
Thompson	bandit	posterior	arrep. bayesiano e frequentista
LinUCB	bandit contextual	otimismo	arrependimento $\tilde{O}(d\sqrt{T})$
MBIE-EB / R-MAX	MDP tabular	otimismo	PAC
UCRL2, UCBVI	MDP tabular	otimismo	arrependimento (minimax)
PSRL	MDP tabular	posterior	arrependimento bayesiano
Bônus de contagem (deep RL)	MDP grande	otimismo	empírico
Bootstrapped DQN, BDQN	MDP grande	posterior	empírico
DREAM, DPT	família de MDPs	meta	empírico

Lendo de cima para baixo: quanto mais realista o cenário, mais fracas as garantias — mas as duas abordagens atravessam a tabela inteira. Elas são o conteúdo transferível da aula.

Onde está a teoria hoje. Para MDPs tabulares o problema está essencialmente resolvido: há resultados minimax para arrependimento (Azar, Osband & Munos, ICML 2017) e para PAC (Dann, Li, Wei & Brunskill, ICML 2019), além de limitantes dependentes da instância (Zanette & Brunskill 2019; Simchowitz & Jamieson 2019). Com aproximação de função a questão segue aberta: há garantias sob MDP linear (Jin, Yang, Wang & Jordan, COLT 2020) e medidas de complexidade como a dimensão de Eluder e o posto de Bellman, mas fora dessas condições estruturais existem limitantes inferiores exponenciais. A pergunta em aberto não é “existe algoritmo eficiente?”, e sim *quais propriedades do domínio tornam a exploração tratável*.

10 Armadilhas comuns

- ▶ **Achar que ϵ -guloso “explora devagar”.** No *RiverSwim* ele não explora devagar: ele *não explora*. A falha é qualitativa.
- ▶ **Trocar “polinomial” por “exponencial” na definição PAC.** A definição vira vazia.
- ▶ **Amostrar o MDP por passo no PSRL.** Destrói a exploração profunda.
- ▶ **Fixar a dinâmica na média empírica e amostrar só a recompensa.** No *RiverSwim* a incerteza que importa é sobre a dinâmica.
- ▶ **Confundir incerteza epistêmica com ruído aleatório** ao construir bônus.
- ▶ **Usar as constantes teóricas de β na prática.** Com $|\mathcal{S}| = 6$, $|\mathcal{A}| = 2$, $m = 100$, $\delta = 0,1$ e $\gamma = 0,95$, a fórmula dá $\beta \approx 44,9$ — seriam necessárias $\approx 2 \times 10^5$ visitas para o bônus cair abaixo de 0,1. Nas simulações deste handout, $\beta = 0,15$ funcionou. *Os limitantes são para provar teoremas; a constante é hiperparâmetro.*

11 Exercícios

Exercício L12E1 — lema da simulação, numérico

Com $\gamma = 0,9$, $R_{\max} = 1$, $\varepsilon_R = 0,01$ e $\varepsilon_P = 0,01$, calcule o limite para Δ . Ele é útil?

Exercício L12E2 — otimismo sem bônus

O que acontece com o MBIE-EB se fizermos $\beta = 0$ mas mantivermos a inicialização $\tilde{Q}(s, a) = 1/(1 - \gamma)$? E se além disso inicializarmos $\tilde{Q} = 0$?

Exercício L12E3 — PAC não implica arrependimento pequeno

Construa (informalmente) um algoritmo que seja PAC e ainda assim tenha arrependimento linear em T .

Exercício L12E4 — granularidade em PSRL

Explique, usando o *RiverSwim*, por que amostrar um MDP novo a cada passo produz comportamento próximo a um passeio aleatório.

Exercício L12E5 — modelo disjunto

Escreva explicitamente $\phi(s, a)$ e θ para $K = 3$ braços e $d = 2$, e verifique a identidade $\theta^\top \phi(s, a) = \theta_a^\top \phi(s)$.

Exercício L12E6 — quantas visitas

No MBIE-EB, quantas visitas a um par (s, a) são necessárias para o bônus cair abaixo de um limiar ϵ_b ? Aplique com $\beta = 44,9$ e $\epsilon_b = 1,0$.

Para discutir em aula

Duas perguntas para conduzir em aula, sem resposta escrita aqui.

- ▶ Um algoritmo que fosse PAC com N exponencial ainda diria algo de útil sobre um domínio com $|S| = 10$? E com $|S| = 10^6$? Onde exatamente a exigência de polinomialidade deixa de ser conservadora e passa a ser essencial?
- ▶ Se um agente pré-treinado (DPT) explora bem por ter aprendido o *a priori* certo, em que sentido ainda faz sentido pedir garantias no pior caso? O que se perde ao abandoná-las?

12 Gabarito resumido

- E1. $V_{\max} = 1/(1 - 0,9) = 10$, logo $\Delta \leq (0,01 + 0,9 \cdot 10 \cdot 0,01)/0,1 = 1,0$. Como $V_{\max} = 10$, o limite é informativo (vale 10% da escala), mas já mostra a amplificação: um erro de modelo de 1% vira um erro de valor de até $100\times$ esse valor absoluto.
- E2. Com $\beta = 0$ mas $\tilde{Q}$ inicializado no máximo, ainda há *otimismo inicial*: pares não visitados mantêm valor máximo até serem experimentados uma vez. Isso é essencialmente o R-MAX de uma amostra — explora, mas sem calibração e sem garantia PAC, e pode desistir cedo demais de pares ruidosos. Com $\tilde{Q} = 0$ o algoritmo vira *equivalente-certeza* guloso: no *RiverSwim* ele aprende a recompensa de s_1 e trava à esquerda para sempre.
- E3. Seja um algoritmo que, nos primeiros N passos, escolhe a pior ação possível (perda $V_{\max}$ cada), e depois age de forma ótima — mas em um MDP em que essas N escolhas ruins levam a um estado absorvente de recompensa nula. O agente é PAC (só N decisões ruins), e ainda assim o arrependimento cresce linearmente, porque as consequências das N escolhas duram para sempre. A moral: PAC conta decisões, não consequências.
- E4. Amostrando por passo, cada $\tilde{\mathcal{M}}_t$ é uma hipótese independente sobre a dinâmica. Como o *a posteriori* inicial é largo, cerca de metade das amostras favorece nadar à direita e metade favorece a esquerda. A ação executada alterna quase como uma moeda, e as cinco subidas

consecutivas voltam a ter probabilidade exponencialmente pequena — o mesmo fracasso do ϵ -guloso.

E5. Com $\theta = (\theta_1^\top, \theta_2^\top, \theta_3^\top)^\top \in \mathbb{R}^6$ e

$$\phi(s, a_1) = \begin{pmatrix} \phi(s) \\ 0 \\ 0 \end{pmatrix}, \quad \phi(s, a_2) = \begin{pmatrix} 0 \\ \phi(s) \\ 0 \end{pmatrix}, \quad \phi(s, a_3) = \begin{pmatrix} 0 \\ 0 \\ \phi(s) \end{pmatrix} \in \mathbb{R}^6,$$

o produto interno anula todos os blocos exceto o de a , restando $\theta_a^\top \phi(s)$.

E6. Como $\beta/\sqrt{n} \leq \epsilon_b$ equivale a $n \geq (\beta/\epsilon_b)^2$, com $\beta = 44,9$ e $\epsilon_b = 1,0$ obtemos $n \geq 2017$ visitas *por par*. Em um MDP de 6 estados e 2 ações, isso é ≈ 24000 passos apenas para que o bônus deixe de dominar — mais do que o orçamento total das simulações deste handout, o que confirma que a constante teórica é impraticável.

13 Autoavaliação

Você deve conseguir, sem consultar:

- ▶ enunciar a definição PAC e apontar os três papéis de ϵ , δ e N ;
- ▶ explicar por que ϵ -guloso falha no *RiverSwim* e por que otimismo e PSRL não falham;
- ▶ escrever o MBIE-EB e dizer de onde vem cada fator de β ;
- ▶ reproduzir o lema da simulação e sua prova;
- ▶ enunciar os cinco passos da prova PAC e explicar a dicotomia da fuga;
- ▶ escrever o PSRL e dizer onde a granularidade da amostragem importa;
- ▶ construir $\phi(s, a)$ em blocos para representar um modelo disjunto;
- ▶ distinguir incerteza epistêmica de aleatória e dizer qual delas o bônus deve medir;
- ▶ mapear cada algoritmo do curso ao critério que ele satisfaz.

14 Notação e glossário

Inglês	Português	Símbolo / observação
probably approximately correct regret	provavelmente aproximadamente correto arrependimento	PAC (sigla mantida) $\text{Arrep}(T)$
Bayesian regret	arrependimento bayesiano	
exploration bonus	bônus de exploração	$\beta/\sqrt{n(s, a)}$
optimism under uncertainty	otimismo diante da incerteza	
probability matching	casamento de probabilidades	
posterior sampling	amostragem posterior	PSRL (sigla mantida)
prior / posterior	<i>a priori</i> / <i>a posteriori</i>	em itálico, do latim
deep exploration	exploração profunda	
simulation lemma	lema da simulação	
known state–action pair	par estado–ação conhecido	$n(s, a) \geq m$
escape probability	probabilidade de fuga	
contextual bandit	bandit contextual	“bandit” mantido
disjoint linear model	modelo linear disjunto	$\theta_a^\top \phi(s)$
confidence ellipsoid	elipsoide de confiança	$\mathcal{C}_t$
pseudo-count	pseudo-contagem	$\hat{n}(s)$
epistemic / aleatoric	epistêmica / aleatória	sobre incerteza
bootstrapped	<i>bootstrap</i>	mantido em inglês

15 Leituras

- ▶ A. L. Strehl, M. L. Littman. *An analysis of model-based interval estimation for Markov decision processes*. JCSS, 2008. — o MBIE-EB e a prova PAC.
- ▶ I. Osband, D. Russo, B. Van Roy. *(More) efficient reinforcement learning via posterior sampling*. NeurIPS 2013. — o PSRL.
- ▶ M. Dimakopoulou, B. Van Roy. *Coordinated exploration in concurrent reinforcement learning*. ICML 2018.
- ▶ L. Li, W. Chu, J. Langford, R. Schapire. *A contextual-bandit approach to personalized news article recommendation*. WWW 2010. — o LinUCB disjunto.
- ▶ M. G. Bellemare et al. *Unifying count-based exploration and intrinsic motivation*. NIPS 2016.
- ▶ I. Osband, C. Blundell, A. Pritzel, B. Van Roy. *Deep exploration via bootstrapped DQN*. NIPS 2016.
- ▶ M. G. Azar, I. Osband, R. Munos. *Minimax regret bounds for reinforcement learning*. ICML 2017.
- ▶ C. Dann, L. Li, W. Wei, E. Brunskill. *Policy certificates: towards accountable reinforcement learning*. ICML 2019.
- ▶ C. Jin, Z. Yang, Z. Wang, M. I. Jordan. *Provably efficient reinforcement learning with linear function approximation*. COLT 2020.
- ▶ J. Lee, A. Xie et al. *Supervised pretraining can learn in-context reinforcement learning*. NeurIPS 2023. — o DPT.
- ▶ T. Lattimore, C. Szepesvári. *Bandit Algorithms*. Cambridge, 2020 — capítulos 19 (bandits lineares) e 36 (MDPs).

Material adaptado e expandido de **CS234: Reinforcement Learning**, Emma Brunskill, Stanford University (Lecture 12, *Fast RL Continued*). Os resultados numéricos do *RiverSwim* e do bandit contextual foram obtidos por simulação própria e não constam do material original.